EDRコーパスを用いた深層格選好に基づく照応解析手法

渋木英潔† 荒木健治‡ 桃内佳雄†† 栃内香次‡‡

†北海学園大学ハイテクリサーチセンター 札幌市中央区南26条西11丁目1-1
‡北海道大学大学院情報科学研究科 札幌市北区北14条西9丁目
††北海学園大学工学部 札幌市中央区南26条西11丁目1-1
‡‡北海学園大学経営学部 札幌市豊平区旭町4-1-40

1．はじめに

我々は，自動要約や対話システムなどへの応用を目的として，文章全体を一つのネットワークで表現することを試みている．ネットワーク中のノードを単語とした場合，そのノード間のリンクとして，構文解析や意味解析の結果を利用することが考えられる．しかしながら，構文解析や意味解析は通常1文単位で処理されるため，文の境界を越えた単語にリンクを張ることができない．また，別の課題として，深層格をリンクのラベルとして利用することがあげられる．深層格の利用は，他言語への適用を考えた場合に，共通の枠組みで処理できる可能性があるため有用であると考えられる．以上の背景から，文間照応を自動的に検出し，その深層格を推測する手法を提案する．また，本手法における照応は日本語におけるゼロ代名詞の前方照応を対象としている．

日本語におけるゼロ代名詞照応を対象とした従来研究として，文献[1-5]などが挙げられる．文献[1,2]では，コーパスから自動構築した表層格フレームを用いて照応解析を行っている．文献[1,2]の手法では，先行詞の判断に関係コーパス[6]を用いているが，関係コーパスは新聞記事を対象として照応関係を人手でタグ付けしたコーパスであり，新聞記事以外の分野に適用する際に要求されるコストに関して検討する必要がある．したがって，コストの軽減のために，照応関係が付与されていないコーパスのみを用いて照応解析を行うことが考えられ，その考え方に基づいて本研究は行われている．

文献[3,4]では，先行詞が文内に存在する場合のゼロ代名詞照応において有効な統語構造を学習する手法が述べられている．しかしながら，先行詞の判断に照応関係が付与されたコーパスを用いており，文献[1,2]と同様の問題点が生じる．また，学習された統語構造が文間照応に適用可能であるかについての調査が行われていない．本研究は，1文単位でタグ付けされたコーパスを用いて，文間の照応解析を行おうとする点で異なっている．

文献[5]では，タグ付けのコストを考慮して，照応関係が付与されていないコーパスから意味モデルを構築している．しかしながら，統語モデルの構築には照応関係が付与されたコーパスを用いており，さらなるコストの軽減を行うことができる余地が存在する．

加えて，本手法は，表層格ではなく，深層格を推測するという点で，文献[1-5]の手法と異なっている．

我々は，これまで文献[7]などにおいて，深層格の推測手法に関する研究を行っている．文献[7]の手法は，単語の概念ごとに特定の深層格に解釈される傾向（深層格選好）が存在するという考え方に基づいている．格支配する側の

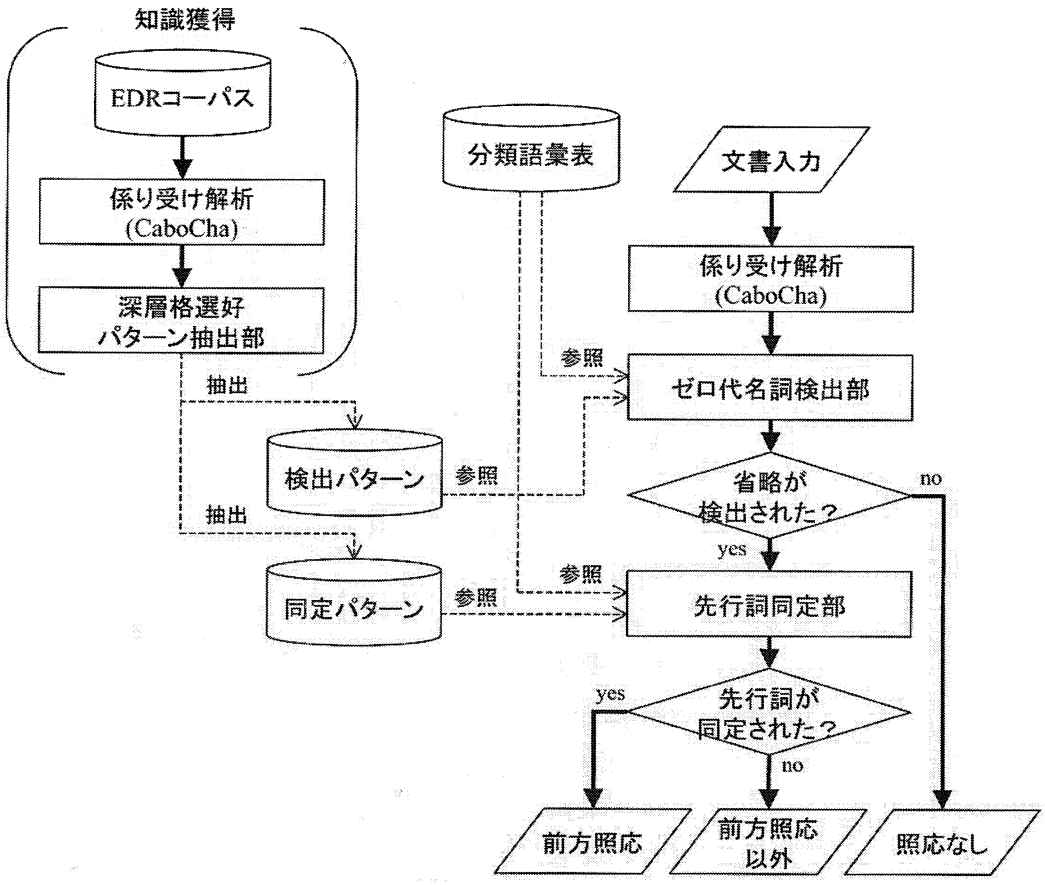


図１　処理の流れ

単語と格支配される側の単語の深層格選好は互いに独立した確率で表現され，両者の値に基づいて深層格を推測する．文献[7]の手法の利点として，格関係にある２単語に付随する機能語などの文法要素を用いずに推測できる点があげられる．文間照応において，先行詞に付随する機能語は，あまり有効な判断材料ではないと考えられるため，文法要素を用いずに推測できるという利点は，文間照応において有効であると考えられる．

以上から，本稿ではEDRコーパスから学習した深層格選好を基に，ゼロ代名詞照応を行った結果について報告する．

２.では，基本的な考え方として，提案手法の全体的な流れを述べ，３.で，知識表現の定義および抽出方法を記述する．４.では，照応処理について記述する．５.では，新聞記事を対象とした定性的評価を行う．６.は，まとめと今後の予定である．

２．基本的な考え方

一般にゼロ代名詞の照応解析は，「ゼロ代名詞検出」と「先行詞同定」の２つの処理で行われる[1]．それぞれの処理で用いられる知識を，「検出パターン」及び「同定パターン」と定義し，EDR コーパスから獲得する．それぞれのパターンの定義に関しては３.で行う．

本手法の流れを図１に示す．入力された文書に対し，CaboCha[8]を用いて係り受け解析を行う．係り受け解析の結果を基に，抽出パターンとのマッチングを行い，省略されているゼロ代名詞の検出と，その深層格を推測する．パターンマッチングにおいて，一致している単語を判断するために分類語彙表[9]を用いる．ゼロ

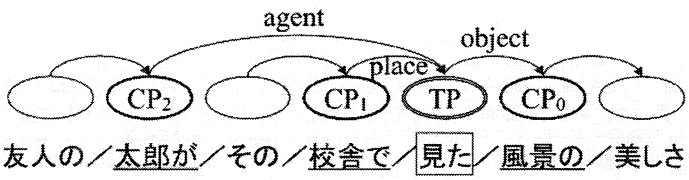


図２　文脈語の例

代名詞を検出できなければ，省略がないと出力して解析を終了する．ゼロ代名詞を検出した場合，同定パターンを用いて，先行詞の同定を行う．先行詞が同定できた場合には，前方照応として先行詞を出力する．同定できなかった場合には，後方照応または外界照応として，照応先を出力せずに解析を終了する．

３．知識表現

3.1 文脈語の定義

検出パターンおよび同定パターンは，「文脈語」のリストとして定義される．文脈語の定義は，ある動詞と係り受け関係にある語であり，図２に文脈語の例を示す．図２は，動詞「見る」を対象語（Target Phrase, TP）としたときの文脈語（Context Phrase, CP）を示しており，文脈語には下線を記している．

動詞に係る文脈語を，単語距離的に動詞と近い順序で CP_1，CP_2，…，CP_n と定義する．図２の例では，「校舎」が CP_1，「太郎」が CP_2 となる．また，動詞が係る先の単語も文脈語に含め，これを CP_0 と定義する．図２では「風景」が CP_0 に相当する．CP_0 を文脈語に含めるのは，修飾節中の述語と底（修飾される名詞）との間に何らかの格関係（内の関係）がある場合を考慮するためである．しかしながら，外の関係である場合や，文末動詞など係り先が存在しない場合も考えられるため，CP_0 の深層格や単語には空になることを許している．

検出パターンおよび同定パターンは，文献[7]における，動詞および名詞の深層格選好と対応付けることができる．しかしながら，文献[7]では格支配される名詞（文脈語に相当）の数を２に限定しているのに対し，本手法ではリスト構造として任意の数の文脈語を扱えるように改善している．

3.2 検出パターンの定義と抽出

ゼロ代名詞検出には，ゼロ代名詞に関係する動詞の格フレームが用いられる[1,5]．したがって，動詞とその文脈語から構成されるリストを，検出パターンと定義する．各リストを構成する要素は，「文脈語」，「付随する文法語」，「文脈語の品詞」，「文脈語が担う深層格」である．本手法で扱う深層格は，文献[7]と同じく EDR コーパスに付与されている概念関係子に基づくものとし，表１に示す 14 種類とした．

検出パターンの抽出は，EDR コーパスの意味フレームと係り受け解析の結果から行われる．EDR コーパスには構文構造が付与されているが，照応解析を行う文章の係り受け構造を判断するためには係り受け解析ツールを利用する必要がある．したがって，構文構造の形式を統一するために，解析ツールの出力形式に合わせることとした．本稿では，解析ツールとして CaboCha[8]を利用しているため，CaboCha を用いて EDR コーパスの文を解析した結果に基づいて抽出を行った．

係り受け解析の結果に含まれる全ての内容語を対象語として次段落に述べる処理を行い，対象語を見出し語として $CP_{1,\ldots,n}$ の文脈語をもつ検出パターンを抽出した．

$CP_{1,\ldots,n}$ に関しては，以下の条件を全て満たす単語とした．

表１　深層格（概念関係子）の一覧

agent	有意志動作を引き起こす主体	父が食べる
object	動作・変化の影響を受ける対象	りんごを食べる
goal	事象の主体または対象の最後の位置	東京に行く
condition	事象・事実の条件関係	雨が降ったので家に帰った
implement	有意志動作における道具・手段	ナイフで切る
material	材料または構成要素	牛乳からバターを作る
place	事象の成立する場所	部屋で遊ぶ
scene	事象の成立する場面	ドラマで演じる
source	事象の主体または対象の最初の位置	京都から来る
cause	原因	病気で倒れる
purpose	目的	映画を見に行く
basis	比較の基準	バラはチューリップより美しい
beneficiary	利益・不利益の移動先[受益[者]と被害[者]の両方を含む]	父に買ってあげる
quantity	物・動作・変化の量	３ｋｇ痩せる

・対象語に係っている．
・EDR コーパスにおいて，対象語が main となる意味フレーム中に含まれている．
・表１の概念関係子が付与されている．

CP_0は対象語の係り先の単語であり，検出フレーム中に必ず存在している．対象語が文末で係り先が存在しない場合，「文脈語」，「付随する文法語」，「文脈語の品詞」，「文脈語が担う深層格」は空として NULL の記号を与える．また，意味フレーム中に存在しない場合，外の関係とみなして「文脈語が担う深層格」に NULL の記号を与える．

図３は抽出された検出パターンの例である．図の上部の文における「注いできた」を対象語として抽出した検出パターンが図の下部である．

業界大手は，新規事業の開拓に懸命で，住友金属鉱山は，５０年代前半までに菱刈金山を除く有力鉱山を閉じ，国内外で 新規事業に 力を 注いできた．(EOS)

注いでくる
CP_0: NULL/NULL -NULL- NULL
CP_1: 力/を -名詞- object
CP_2: 新規事業/に -名詞- goal
CP_3: 国内外/で -名詞- place
CP_4: 住友金属鉱山/は，-名詞- agent
CP_5: 懸命/で，-名詞- condition

図３　検出パターンの抽出例

3.3 同定パターンの定義と抽出

先行詞同定には，ゼロ代名詞の動詞からの選択制限と，ゼロ代名詞からの近距離特性が用いられる[1]．一般に選択制限は，「動詞」-「格」-「名詞（集合）」のように，動詞を中心として名詞までを関連付けた形式で表現され用いられる．本手法では加えて，先行詞となる名詞を中心に動詞から独立させた形式で深層格を捉えた知識を獲得し利用する．これは，担う深層格の傾向は単語ごとに存在するという深層格選好の仮定に基づいている．この名詞を中心とした知識を同定パターンと定義する．

表２　検出パターンの抽出数

	文脈語数２	文脈語数３	文脈語数４	文脈語数５	文脈語数６	文脈語数７	合計
異なり語数	46,464	10,474	1,535	102	5	1	58,581
総パターン	221,641	28,827	2,299	114	5	1	252,887

表３　同定パターンの抽出数

	文脈語数２	文脈語数３	文脈語数４	文脈語数５	文脈語数６	文脈語数７	合計
異なり語数	78,308	25,220	4,563	423	25	6	108,545
総パターン	221,641	57,654	6,897	456	25	6	286,679

同定パターンの抽出は，検出パターン抽出時に $CP_{1,...,n}$ となった，それぞれの文脈語を中心に以下のように再構成することにより行われる．

- 検出パターンの文脈語 $CP_{1,...,n}$ 中の CP_k を同定パターンの見出し語とし，対応する深層格をそのパターンの適用条件深層格とする．
- 残りの $CP_{0,...,k-1,\ k+1,...,n}$ を同定パターンの文脈語 $CP_{0,...,n-1}$ とする．

図４に抽出された同定フレームの例を示す．これは，図３で抽出された検出フレームの CP_4 を中心に同定フレームとして再構成したものである．

EDR コーパスから抽出された検出フレームと同定フレームの数を表２と表３にそれぞれ示す．１段目は見出し語による異なり語数を，２段目は抽出されたフレームの延べ数を示している．また，抽出されたフレーム中で最大の文脈語数は CP_0 から CP_6 までの７語であった．

業界大手は，新規事業の開拓に懸命で，住友金属鉱山は，５０年代前半までに菱刈金山を除く有力鉱山を閉じ，国内外で 新規事業に 力を 注いできた．(EOS)

住友金属鉱山 -名詞- agent
CP_0: NULL/NULL -NULL- NULL
CP_1: 力/を -名詞- object
CP_2: 新規事業/に -名詞- goal
CP_3: 国内外/で -名詞- place
CP_4: 懸命/で，-名詞- condition

図４　同定パターンの抽出例

４．照応処理

4.1 パターンの類似度

パターンは文脈語を基にした任意の数のリストで表現されるため，それぞれのリストごとに類似度を計算し，その類似度を平均化したものをパターンの類似度とする．

リストの類似度は０～１の値をとり，完全一致で１となるように定義する．リストごとの類似度を求めるために，入力文書中の単語に対して，パターン抽出時と同様の方法で文脈語のリストを作成し，「文脈語が担う深層格」以外の項目を作成する．パターンと入力文書とのリスト間の類似度は以下の手順により算出される．

- 「付随する文法語」または「文脈語の品詞」が不一致であれば０とする．
- 上記以外であり，入力側とパターン側の「文脈語」が，一方でも分類語彙表に未登録であれば α （$0<\alpha<1$）とする．
- 上記以外であり，分類コードの上位５桁が一致していれば１，そうでなければ０とする．

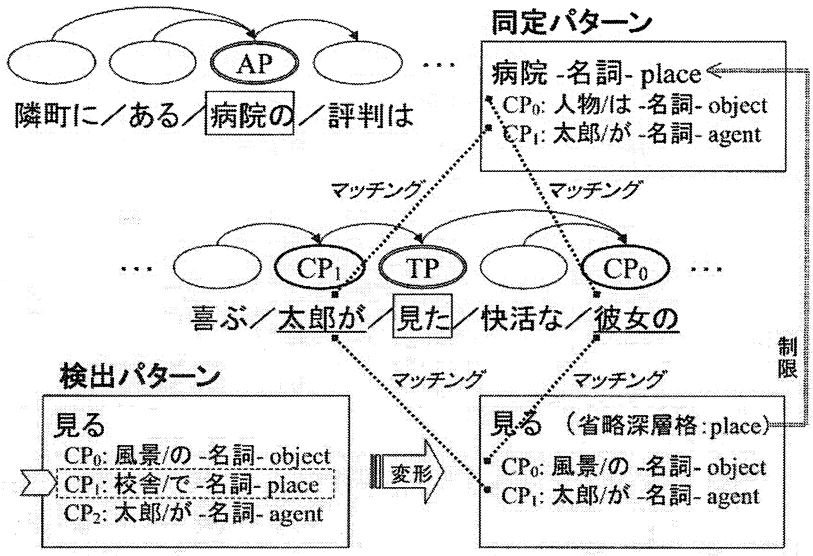


図５　照応解析の例

文脈語が分類語彙表に未登録である場合，分類コードによる一致性の判断ができないため，$0<\alpha<1$ となる値により判断を保留した．本稿ではαの値を 0.5 とした．また，多義語で複数の分類コードをもつ場合には，一致する分類コードが１つでも存在すれば１とした．

4.2 ゼロ代名詞の検出

係り受け解析された結果と検出パターンとのマッチングを行うことでゼロ代名詞の検出を行う．しかしながら，本手法では，先行詞の同定に深層格の情報が必須であることから，深層格を一意に推測できるような検出パターンを選択する必要がある．したがって，入力側の文脈語数より１だけ多い文脈語をもつ検出パターンをマッチングの対象とする．

図５は，本手法による照応解析の例である．「隣町にある病院の評判は…」という文に「…喜ぶ太郎が見た快活な彼女の…」という文が続く文書であり，後文の「見た」におけるゼロ代名詞の検出を行っている．入力側の文脈語は「彼女」と「太郎」の２語であるため，１多い３語の文脈語をもつ検出パターンがマッチングの対象となる．

ゼロ代名詞の深層格を一意に決定するため，検出パターンの文脈語 $CP_{1,\ldots,n}$ 中の任意の CP_k が入力中で省略されていると仮定する．省略と仮定された CP_k を除いた残りの文脈語を $CP_{0,\ldots,n-1}$ として再構成し，再構成されたパターンを用いて入力とのマッチングを行う．マッチングの類似度が閾値 T_1 を超えた場合，CP_k をゼロ代名詞として検出し，対応する深層格をゼロ代名詞の深層格として推測する．図５では CP_1 の文脈語が省略されたと仮定しており，マッチングの結果，place がゼロ代名詞の深層格と推測している．

閾値を超える検出パターンが複数存在する場合には，検出されたゼロ代名詞のうち，推測された深層格が異なるゼロ代名詞の全てが省略されていると判断する．

4.3 先行詞の同定

検出パターンを適用して推測された深層格を条件とし，近距離特性と，同定パターンとのマッチングを用いて先行詞の同定を行う．

まず，単語距離的に近い順に存在する一般名

詞を先行詞の候補とする．その名詞を見出し語にもつ同定パターンの中で，推測された深層格を適用条件深層格にもつパターンをマッチングの対象とする．条件に適合する全てのパターンを用いてマッチングを行い，その類似度が閾値 T_1 を超えた回数を計算する．その回数が閾値 T_2 を超えた場合，その名詞を先行詞として同定する．閾値 T_1 はパターンと入力との類似性，閾値 T_2 は見出し語が深層格を担う可能性を判断するための指標である．

図5の例では，近距離特性から「病院」が先行詞の候補としてあげられている．「病院」を見出し語とし，place を適用条件深層格とする同定パターンを用いて入力とのマッチングを行っている．

5．実験

文間照応を行った先の深層格を推測する手法に関する知見が少ないため，本手法による定性的な特徴を把握するための実験を行った．

学習データである EDR コーパスが新聞，雑誌などの記事を中心に収集していることから，Yahoo! ニュース[10]から，国内-政治 19 記事，国内-社会 27 記事，経済-経済総合 23 記事の合計 69 記事を入力文書とした．今回の実験では，出力数を確保するため，閾値 T_1 を 0.5，T_2 を 1 と低く設定した．

解析の結果，212 のゼロ代名詞を検出し，そのうち 33 のゼロ代名詞を前方照応と判断した．ゼロ代名詞の検出数と先行詞の同定数が記事数に対して全体的に低い値となっている．これは，パターン適用における見出し語の完全一致の条件と，マッチングにおける未登録語の問題が原因であると考えられる．深層格選好を扱った文献[11]では，自動クラスタリングの結果を利用することで，未知語と精度の問題を改善しているため，本手法においても自動クラスタリング手法を利用したいと考えている．

こうした思いを熟知している首相*[agent]*．
結果を出せば政権の追い風になるが，進展がなければ板ばさみになる．

図5　正解の前方照応例

政府*[agent]*は「拉致問題で進展がなければ，エネルギー支援*[object]*はしない」方針*[object]*を貫いた．合意文書に設置が盛り込まれた作業部会について，首相は「北朝鮮*[agent]*こそ，作業部会で拉致問題を解決しなければ，望むものは得られない」と強硬路線維持を強調する．

図6　誤りの前方照応例

前方照応と判断された結果のうち正解であった例を図5に示す．文脈語数が3語である「出す」の検出パターンを用いてマッチングを行った結果から，agent のゼロ代名詞を検出している．また，「首相」の同定パターンから agent を担う可能性を考慮し，先行詞を同定している．

出力数が少ないため，さらなる調査が必要であるが，誤りの多くは，パターンの不備と未登録語によるマッチングの失敗であると考えられ，自動クラスタリングの利用や，抽象化によるパターンの汎化などによる改善を試みる予定である．

しかしながら，本手法での対処が困難と思われる誤りの例を図6に示す．図6では「望む」のゼロ代名詞の格として agent と object を正しく検出しているが，先行詞の同定を誤っている．波線を引いた「北朝鮮」と「エネルギー支援」がそれぞれ正解の照応先である．システムの出力である「政府が方針を望む」という解釈は，名詞-動詞間の局所的な意味関係としては誤りではないため，深層格選好に基づく考え方のみでは限界があると考えられる．この問題を解決するためには，話題の焦点が「北朝鮮」に移っていること，「北朝鮮」と関連する事項が

「エネルギー支援」であること，の２点を把握することが必要である．しかしながら，文章全体としては，「政府」が話題の焦点であるため，複数の話題を並行して管理し，適切に切り替える機構が必要であると考えられる．これは今後の課題である．

６．おわりに

本稿では，日本語ゼロ代名詞の文間前方照応を対象として，EDR コーパスから抽出したパターンを用いて深層格を解析する手法を提案した．本手法は，ゼロ代名詞に関係する動詞と先行詞の名詞との両方の単語から共通の深層格を媒介として推測する点に特徴がある．また，新聞記事を対象として本手法の定性的な評価を行い，今後の改善点を示した．

今後，より大規模な実験データの整備を行い，定量的な評価をする予定である．

謝辞

本研究の一部は，北海学園大学ハイテク・リサーチ・センター研究費，及び，北海学園大学学術研究助成金による補助のもとに行なわれた．

参考文献

[1] 河原大輔，黒橋禎夫，自動構築した格フレーム辞書と先行詞の位置選好順序を用いた省略解析，自然言語処理，Vol.11，No.3，pp.3-19，(2004).

[2] D. Kawahara and S. Kurohashi, Zero Pronoun Resolution based on Automatically Constructed Case Frames and Structural Preference of Antecedents, In Proceedings of the 1st International Joint Conference on Natural Language Processing, pp.334-341 (2004).

[3] 飯田龍，乾健太郎，松本裕治．ゼロ照応解析のための統語的パタンの学習，第５回情報科学技術フォーラム情報技術レターズ，(2006).

[4] R. Iida, K. Inui, Y. Matsumoto, Exploiting Syntactic Patterns as Clues in Zero-Anaphora Resolution, 21st International Conference on Computational Linguistics and 44th Annual Meeting of the Association for Computational Linguistics (2006).

[5] 関和広，藤井敦，石川徹也，確率モデルを用いた日本語ゼロ代名詞の照応解析，自然言語処理，Vol. 9, No. 3, pp. 63-85, (2002).

[6] D. Kawahara, S. Kurohashi and K. Hasida, Construction of a Japanese Relevance-tagged Corpus, In Proceedings of the 3rd International Conference on Language Resources and Evaluation, pp.2008-2013, (2002).

[7] 渋木英潔，荒木健治，桃内佳雄，栃内香次，単語概念の深層格選好に基づく深層格推測手法，電子情報通信学会論文誌 D，Vol.J89-D，No.6，pp.1413-1428，(2006).

[8] CaboCha/南瓜，奈良先端科学技術大学大松本研究室，http://chasen.org/~taku/software/cabocha/

[9] 国立国語研究所，分類語彙表，秀英出版，1964(1993).

[10] Yahoo! ニュース - 国内トピックス，http://headlines.yahoo.co.jp/hl

[11] 渋木英潔，荒木健治，桃内佳雄，栃内香次，深層格の推測手法における自動クラスタリングの利用，第３回情報科学技術フォーラム情報技術レターズ，pp.79-80，(2004).