学習型機械翻訳手法における省略可能性に基づく翻訳ルールの自動獲得手法

寺島　涼　　越前谷　博　　荒木　健治
北海道大学大学院情報科学研究科　北海学園大学工学部　北海道大学大学院情報科学研究科

１．はじめに

これまでに多くの機械翻訳手法が提案されてきたが、解析型の機械翻訳手法[1]では、多様な言語現象にともなう文法規則、辞書の巨大化のために、作成・改良が困難であった。また、用例型の機械翻訳手法では翻訳ルールを獲得するために大量なデータを必要とした。我々が提案してきた学習型機械翻訳手法[2]では、帰納的学習を用いて翻訳例対の差異部分を基に翻訳ルールを獲得する。しかし、データスパースネスなコーパスでは、効率的に翻訳ルールを獲得することが困難である。この問題を解決するために、本稿で我々は省略可能性に基づく翻訳ルールの自動獲得手法を提案する。

２．処理過程

本手法の処理過程を図１に示す。まず英文を入力文として翻訳部で翻訳処理を行う。ここでは翻訳結果として日本語訳文を生成する。次にフィードバック部では、翻訳結果と正しい日本語訳文を比較し、使用された翻訳ルールの評価を行う。学習部では帰納的学習[3]と省略可能性を用いて翻訳ルールの獲得を行う。

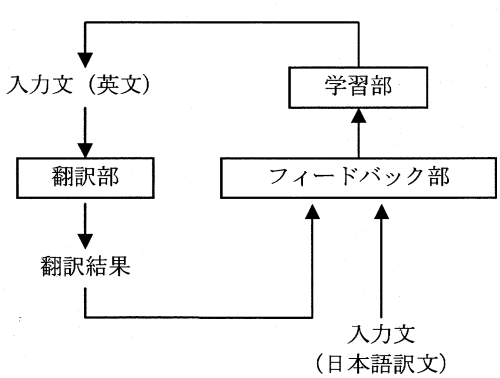


図１　処理過程

３．学習部

３．１　省略可能性によるルールの獲得

入力された翻訳例と、既に獲得されている単語翻訳ルールの共通部分から、省略可能性を元に句を抽出し、単語翻訳ルールとする。次に抽出した句を変数化した文翻訳ルールを獲得する。以下にルール獲得の例を示す。初めに単語翻訳ルールが一致する翻訳例を選択する。

(I'd like a quiet room with a bath . ;
バス/つき/の/静かな/部屋/を/お願い/し/ます。)
(a room ; 部屋)

“quiet”の省略可能性、”a quiet room”と”静かな/部屋”の対応関係の類似度を用いて句を抽出し次のような単語翻訳ルールを獲得する。

(a quiet room ; 静かな/部屋)

この句を変数化した文翻訳ルールとして次のルールを獲得する。

(I'd like @0 with a bath . ;
バス/つき/の/@0/を/お願い/し/ます。)

また、英語フレーズを $A=a_1, a_2,\ldots a_m$、日本語フレーズを $B=b_1, b_2,\ldots b_n$ としたとき、A と B の類似度を式(1)の sim(A, B)で定義する。

$$sim(A,B)=\sum_{i=1}^{m}\frac{1}{2m}\max\left[D(a_i,b_1),\ldots D(a_i,b_n)\right]+\sum_{j=1}^{n}\frac{1}{2n}\max\left[D(b_j,a_1),\ldots D(b_j,a_m)\right] \quad (1)$$

a,b はそれぞれ A,B を構成する単語、m,n はそれぞれ A,B の単語数を表している。また D(a, b)はダイス係数を表し、式(2)で定義される。

$$D(a,b)=\frac{2\times freq(a,b)}{freq(a)+freq(b)} \quad (2)$$

freq(a),freq(b)はそれぞれ単語 a,単語 b が出現する頻度、freq(a, b)は単語 a と単語 b が共出現する頻度を表している。

３．２　置き換え容易性によるルールの獲得

本手法では翻訳例対に帰納的学習と置き換え容易性を用いて、共通部分もしくは差異部分を多段階に抽出し翻訳ルールを獲得する。差異部分だけでなく共通部分からも単語翻訳ルールを獲得することは、データスパースネスなコーパスに対して有効だと考えられる。以下にルール獲得の例を示す。初めに共通部分、差異部分をもつ翻訳例対を選択する。

(I have his book. ;
私/は/彼/の/本/を/持っ/て/い/る。)
(His book is fun. ; 彼/の/本/は/面白い。)

置き換え容易性より、共通部分を抽出し次の単語翻訳ルールを獲得する。

(His book ; 彼/の/本/)

さらに抽出した部分を変数化した次の文翻訳ルールを獲得する

(I have @0. ; 私/は/@0/を/持っ/て/い/る。)
(@0 is fun. ; @0/は/面白い。)

４．翻訳部

翻訳部では既に獲得されている文翻訳ルールと単語翻訳ルールを用いて、翻訳文を生成する。処理手順を以下に示す。

（１）　入力文に対し、適用可能な文翻訳ルールと単語翻訳ルールを選択する。
（２）　選択された文翻訳ルールと単語翻訳ルールを組み合わせ、翻訳文を生成する。
（３）　翻訳文が複数生成された場合は、適用された文翻訳ルールの類似度を用いて順位付けを行う。

５．評価実験

旅行用英会話テキストに掲載された英文１１０文とその日本語訳文を用いて、最初の７０文を学習段階とし、残りの４０文について翻訳結果の評価を行った。実験には、省略可能性、置き換え容易性を導入後のシステムと、導入前のシステムを使用し比較を行った。その結果を表 1 に示す。有効な翻訳とは正しい翻訳と、名詞句または形容詞に限った未登録語を含む正しい翻訳を表す。無効な翻訳とは未登録語を含む誤翻訳と、未登録語を含まない誤翻訳を表す。翻訳結果はシステムが生成した翻訳文の５位以内を使用し、５位以内に正しい翻訳があれば有効な翻訳とした。

表１　翻訳結果

	有効な翻訳	無効な翻訳
導入後	20.0%	80.0%
導入前	10.0%	90.0%

省略可能性、置き換え容易性を導入することで、導入前より有効な翻訳率において 10 ポイント増加した。省略可能性の導入によって、翻訳が可能となった例を示す。

（Do you have a cheaper room？；
もっと/安い/部屋/は/あり/ませ/ん/か？）
（a room；部屋）

この 2 つの翻訳ルールから、省略可能性と対応関係の類似度を用いて次の部分を抽出する。

（a cheaper room；もっと/安い/部屋）

ルールとして次の翻訳ルールを獲得する。

（Do you have @0？；@0/は/あり/ませ/ん/か？）

このルールを用いることによって、次の入力文に対して翻訳が可能となった。

（Do you have anything cheaper？；
もっと/安い/部屋/は/あり/ませ/んか？）

６．考察

省略可能性、置き換え容易性を導入することで、翻訳率は向上したが、それでも無効な翻訳が多かった。評価に用いた４０文には、それ以前の学習データだけでは翻訳することが非常に困難と考えられる文が多数存在した。そこで、そのような文を次のルールで除いた。

（１）　過去に１度も出現していない動詞を含むもの。
（２）　過去に１度も出現していない助動詞＋動詞を含むもの。
（３）　過去に同じ動詞、助動詞＋動詞が出現しているが、日本語訳との対応関係が異なるもの。
（４）　その他、過去の学習データだけでは翻訳が非常に困難と考えられるもの。

以上のルールで文を除いた場合の結果を表２に示す。文を除くためのルールには曖昧さが含まれるため、結果には幅がある。

表２　翻訳結果

	有効な翻訳
導入後	29.6～38.1%
導入前	14.8～19.0%

７．おわりに

評価実験より、省略可能性、置き換え容易性を導入することで翻訳率の向上が確認できた。これはデータスパースネスなコーパスに対しても、学習部で効率的に翻訳ルールを獲得できたからだと考えられる。今後はさらに効率的なルール獲得を目指し、研究を進めていく予定である。

参考文献

[1]野村浩郷(編)，言語処理と機械翻訳，講談社，東京，1991.
[2] 越前谷 博，荒木 健治，桃内 佳雄，栃内 香次：翻訳例に基づく再帰チェーンリンク型学習による機械翻訳手法，電子情報通信学会論文誌 D-Ⅱ，Vol.J85-D-Ⅱ，No.12，Page1840-1852，2002.12
[3] 荒木健治：“自然言語処理ことはじめ−言葉を覚え会話のできるコンピューター”，森北出版，2004