Webを用いた病気の症状抽出における精度の向上

Improvement of Precision and Extraction of Symptoms of Illness Using the Web

下川　尚亮　Naoaki Shimokawa
荒木　健治　Kenji Araki
北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology Hokkaido University

1.　はじめに

近年，インターネットの利用拡大にともなって，誰もが容易に情報発信をできるようになり，Web上には大量の情報が蓄積されている．Webには病気について書かれたWebページも多数存在している．しかし，一つのWebページに書かれていない症状もあり，その場合他のWebページを見なければならない．そこで複数のWebページに書かれている症状を収集する必要がある．

これまでの研究では，Webから病気の症状を文書で取得するという研究がなされている[1]．しかし，文書では文書の表現形式の違いによる見にくさや，日付など病気の症状とは関係ない情報まで取得してしまうという問題がある．

そこで本稿では，病気の症状のリストを用いて，Webから病気の症状のみを取得するシステムを実装し，その性能評価を行った結果について述べる．

2．システム構成

2．1　概要

まず，病気の症状を抽出するシステムの概要を図１に示す．本システムではあらかじめ人手で病名のリストを作成し，その病名に「症状」という単語を追加し「病名　症状」で検索エンジンを用いてWebから必要なHTML文書を取得する．そして，あらかじめ人手で病気の症状を収集した症状リストに含まれる症状が，取得したWeb文書中にあるか調査する．一致する症状があれば症状DBに登録する．

2．2　症状取得

病名リストから病名を１つ取り出し，「病名　症状」を検索クエリーとして，Yahoo!API[2]を用いて1,000件のHTML文書を取得する．取得したHTML文書中に症状リストに含まれる症状があれば，その症状を症状DBに登録する．症状リストの一部を表１に示す．

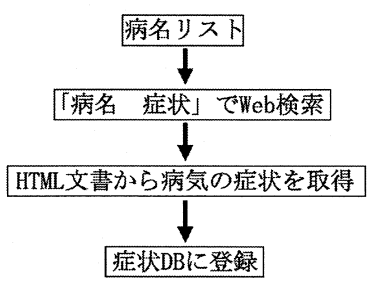


図１　システムの処理の流れ

表１　症状リスト

症状リスト
意識障害
意識混濁
意識消失
意識喪失
意識低下
意識を失う

2．3　症状検索

症状検索画面を図２に示す．病名を入力して症状DBを検索することで，その病気の症状を頻度順に30例出力する．

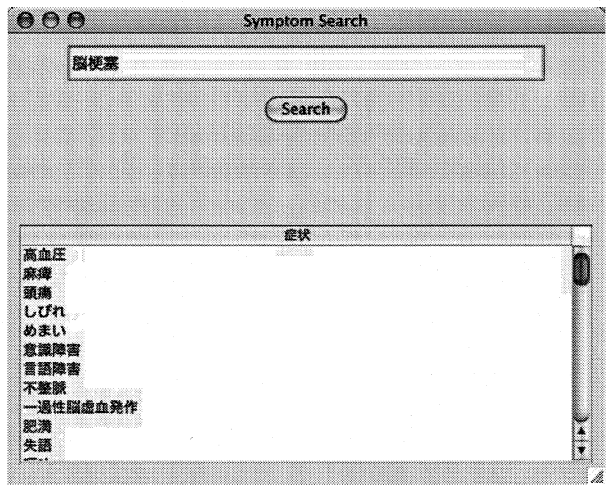


図２　症状検索画面

3．評価実験

本章では，実装した実験システムの評価を行う．実験システムが取得した症状を頻度順に並べ，上位より10例，20例，30例，40例，50例のそれぞれの場合について精度と再現率を求めた．また，F値を求め症状をいくつ表示するのが適切なのかについての検討を行った．

さらに，Wikipedia[3]に書かれていない症状で，その病気の症状であるものを取得できた割合についても調査した．なお，正解の判定は家庭の医学[4]に書かれた症状を参考に人手で行った．F値の計算式を(1)に示す．

$$\text{F値} = \frac{2 \times \text{精度} \times \text{再現率}}{\text{精度} + \text{再現率}} \cdots (1)$$

3.1　実験方法

実験で用いた病名は，脳梗塞，大腸癌，インフルエンザ，心筋梗塞，胃癌である．これらの病名に「症状」という単語を追加して，例えば「脳梗塞　症状」のようにして，Web検索を行った．

3.2　実験結果

システムが取得した症状の精度を図３，再現率を図４，F値を図５に示す．また，Wikipediaに書かれていない症状の割合については図６に示す．

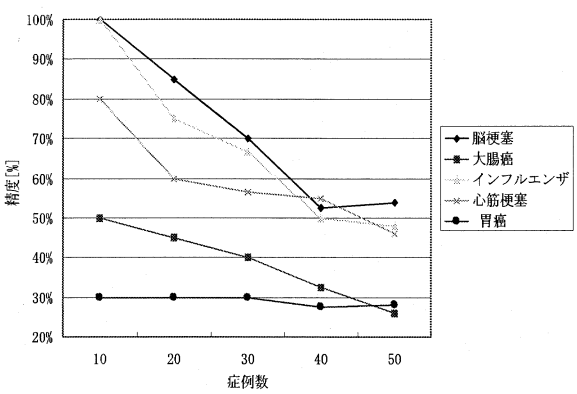


図３　症状の精度

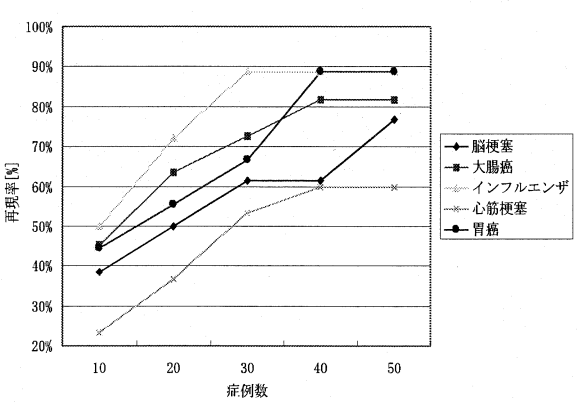


図４　症状の再現率

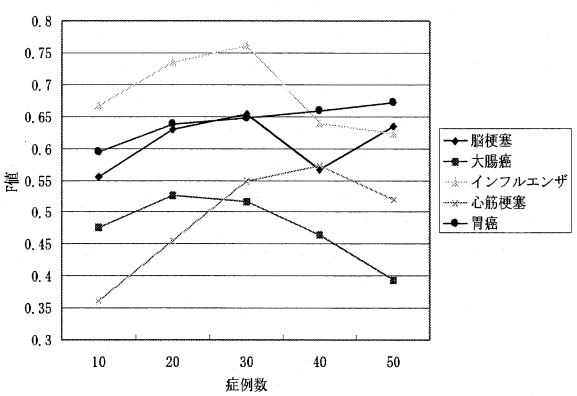


図５　症状のF値

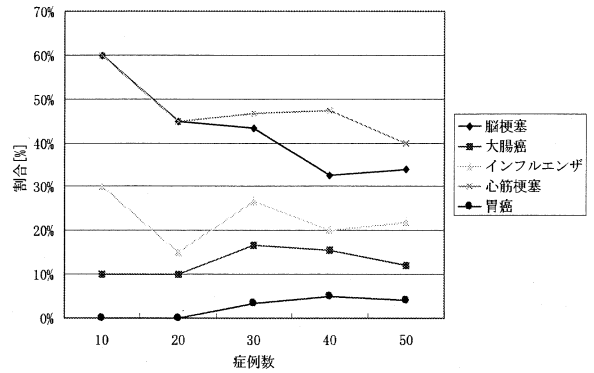


図６　Wikipediaにない症状の割合

4．考察

症状リストを用いて，Webから病気の症状取得実験を行った．その結果，脳梗塞，インフルエンザ，心筋梗塞については，取得した症状の上位10例において80%以上と高い精度を得ることができた．しかし，大腸癌，胃癌については高い精度を得られなかった．この原因としては，症状が少ないことが原因だと考えられる．

次に精度と再現率より得られたF値より，表示する症状数は30例が適切であることが明らかとなった．

また，図７よりWikipediaに書かれていない症状も約21%取得できることが判明した．これより一つのWebページに書かれている以外の症状についても，取得できることが確認された．

5．まとめ

本稿では，Web上から病気の症状を抽出する方法として，症状リストを用いたシステムの構築と評価実験を行った．症状リストを用いることにより，症状の表現形式に一貫性をもたせ，病気の症状以外の情報を表示しないことにより冗長性を排除することができた．また，複数のWebページに書かれている病気の症状の統合や，症状のみを表示することにより本システムの実用性が高まると考えられる．実験を通してWebから症状を取得するのに病気の症状のリストを用いることで高い精度で病気の症状を取得できることが確認された．

今後の課題としては，さらなる精度の向上のため文章の特徴を用いた症状の取得を行うことや，Webから症状リストを自動構築することを予定している．

参考文献

[1] 長沼 潔，速水 悟：医療分野におけるWeb文書からの話題抽出方法，第19回人工知能学会全国大会(2005)

[2] Yahoo!ディベロッパーネットワーク http://developer.yahoo.co.jp/

[3] Wikipedia http://ja.wikipedia.org/

[4] 和田 登：新編 新赤本 家庭の医学，保健同人社，東京，2006