画像に対する発話を対象とした 名詞概念獲得システムＳＩＮＣＡの評価

Evaluation of a system for noun concepts acquisition from utterances about images (SINCA)

内田 ゆず 荒木 健治
Yuzu Uchida Kenji Araki
北海道大学大学院 情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

Abstract: In case of a robot working in an open environment, the task-oriented language ability will not be sufficient. To adapt to the environment, it is necessary to acquire language dynamically. We developed a System for Noun Concepts Acquisition from utterances about Images, called SINCA in short. It is a language acquisition system without knowledge of grammar and vocabulary, which learns noun concepts from a user's input. We collected dialogue data from parents and their children. We evaluated the performance of SINCA with the collected data. In this paper, we describe an algorithm of SINCA and an evaluation experiment.

１．はじめに

近年，"癒し"や"エンターテイメント性"を主眼においたロボットが次々と開発され[1,2,3,4]，ロボットの活躍の場が工場から人間の生活空間に移行しつつある．こうしたロボットの中には，対話能力を備えており，コミュニケーションロボットと呼ばれるものがある.しかし，ユーザを飽きさせないほどの豊かなコミュニケーション能力を持ち合わせているものは今のところ存在しない．これは，シナリオベースの対話システムを用いたり[5,6]，タスクを限定することで対話を成立させていることが原因の一つである．長いスパンでユーザを楽しませ良好な関係を保つためには，新しい知識を次々と学習し，予め定められていない対話を行うような機能をロボットに持たせることが必要だと考えられる．

これまでにも様々な用途の対話システムが開発されてきたが[7,8]，それらは大人の言語処理能力をモデルとして構築されている．つまり，完璧に言語を使いこなせるモデルを一足飛びに作ろうとしているのである．しかし，人間の言語能力とは極めて複雑なものであるため，このようなアプローチでは汎用的な対話システムに到達することは非常に困難であると考えられる．この問題に対して我々は，人が言語を獲得する能力を模倣したシステムを作成することにより，最終的に人間と同等の対話能力の実現が可能なのではないかと考えている[9].

人間の幼児は生まれ育った環境から徐々に言語を学習し，身につけていく．大人がひとつひとつの言葉の意味や定義を繰り返し教え込む，という過程は必要なく，日常生活の中で自然に言葉を覚えることができる．また，幼児の言語獲得過程にはいくつかの発達段階が見られる[10,11]．生後数ヶ月はまだ言葉にならない音（喃語）を発するだけであるが，生後 1 歳から 1 歳半くらいになると意味のある一つの単語を発話するようになる．この時期は「一語期」と呼ばれ，幼児はこの頃から一日 6～10 語という驚異的なスピードで語彙数を増大させていく（語彙爆発）．さらに生後２歳くらいまでに「二語期」といわれる段階に達し，次に「あっち，お兄ちゃんいる」のような「電報文」と呼ばれる発話を行う段階がくる．３歳くらいまでには語彙数も数百語から千語以上になり，発音も大人の言葉に近いものになる．また，幼児の語彙の約７割を名詞が占めることが報告されている[12,13].

これらを踏まえて，我々は言語獲得能力を工学的に実現する第一歩として，幼児の「一語期」に数多く獲得される名詞語彙を獲得することを目指している．

本研究の類似の研究として，幼児の言語獲得過程の研究をシミュレータ制作によって行った Mlas(Multi-Language Acquisition System)がある[14]．Mlas には，与えられた文を単語に分割する，複数の文を比較して異同を判断する，言葉を仮想の生活経験と照らし合わせて言葉と体験を関連させて記憶する，といった初期能力が備わっている．そして，言語に関する知識を持たない状態から，予め用意された仮想の生活世界を介して言葉を与えることによって成長し,徐々に言葉を理解するようになる．しかし，このシステムには，仮想の生活世界の中での言語現象のみを対象としているため実世界に対応できないことや，単語分割の能力を予め与えられていることなどの問題がある．

Mlas の他にも言語獲得システムに関する研究が様々なアプローチで行われてきた．岩橋は，人間とロボットとの言語コミュニケーションによる相互理解のために，ロボットによる言語獲得に関する研究を行っている[15]．田中らは，音声対話によって仮想世界の中に存在する複数のソフトウェアロボットとインタラクションすることができるシステムを開

発している[16]．Rogers らは"The BABY Project"の中で，与えられた例から言語規則などを学習するシステム Babbette を提案している[17]．また，近年では Levinson らが実世界との相互作用から言語を獲得するロボットを用いた研究を進めている[18]．しかし，現実世界に対応することができる言語獲得システムの実現には至っていない．

したがって，本稿では，人間の幼児の言語獲得能力を手がかりに，語彙や文法の知識を持たない状態から現実の世界を対象として名詞概念を獲得するシステム SINCA（System for Noun Concepts Acquisition from utterances about Images）を提案する．幼児の言語獲得能力に基づいたアルゴリズムを用いている点や，入力を限定せずユーザが撮影した画像とそれに対する自由な発話といった実データを対象とする点が，本手法の関連研究との相違である．また，アンケートによって得られた疑似的な大人の発話文と，幼児がいる家庭で撮影されたビデオから得られた大人の発話文を入力として，SINCA の性能評価を行う．

以下，2.と 3.でシステムの概要，処理過程について説明する．4.で評価実験の詳細を述べ，5.で実験結果についての考察を行う．そして最後に 6.で本稿のまとめと今後の課題について述べる．

２．システムの概要

本研究で提案するシステムの概要を図 1 に示す．システムの処理過程の詳細は 3. で述べる．また，システムの外観を図 2 に示す．なお，Microsoft Visual Studio .NET 2005[19] を用いてこのインタフェースの構築を行った．ウィンドウ中の２枚の画像のうち，左はユーザの画像を撮影を補助するために表示される Web カメラからのプレビューである．右はキャプチャ済みの画像となっており，実際に入力画像として使用される．この場合，ユーザは赤ちゃんに消しゴムを見せながら話しかけているという場面を表している．また，右下の赤ちゃんに付随している吹き出しの内容は 3.5 で述べる出力である．赤ちゃんの画像の下には，「(今キャプチャされている画像は) 初めて見る画像である」「前に見たことがある」などの画像処理の結果や，「何か言っています」などのシステムの状態が表示される．

３．処理過程

3.1 入力

入力は画像と文の対である．入力画像は Web カメラ（USB-CAMCHAT2／アイ・オー・データ機器．有効画素数：30 万画素）からキャプチャされた画像（以降画像 P と呼ぶ），入力文は画像 P を見せながらユーザが幼児に話かける発話 1 文（以降文 S と呼ぶ）である．入力画像は，ユーザが自由に被写体を選び撮影するものである．

入力文は全てひらがなで表記され，入力文に形態素解析などの前処理は一切施されない．ひらがなで表記するのは，ユーザによって表記に揺れが生じることと，入力された文字列自体に意味が含まれてしまうことを避けるためであり，形態素解析などを行わないのは，幼児が正確な品詞分割などの能力を持っていないと考えるためである．

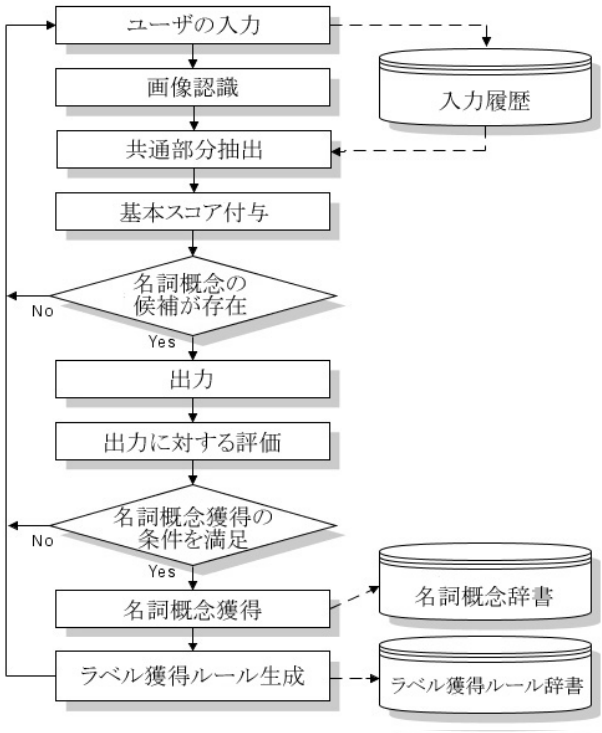


図 1　SINCA の処理の流れ

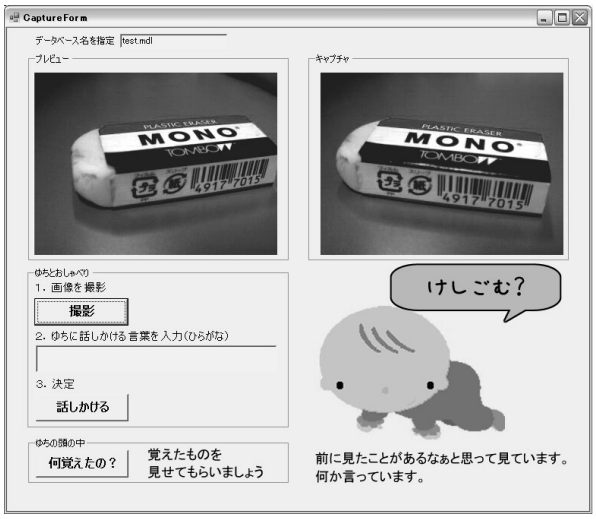


図 2　SINCA のインタフェース

3.2 画像認識

過去に同じ被写体が写った画像が入力されたかどうかを判断する．ここでは，エボリューション・ロボティクス社の ERSP3.1 (Evolution Robotics Software Platform) [20]に含まれる”ERSP ビジョン”を用いた．ERSP 3.1 は，ロボット製品の作成を目的とした総合開発プラットフォームで，照明や物体の位置が管理されていない現実的な環境の中でも，ロボットや装置が２次元と３次元の物体を認識することができる画像認識ツールである．

3.3 共通部分抽出

システムは入力を得ると，過去に画像 P とともに入力された文と文 S を比較して，字面が一致する文字列を切り出す．この切り出された文字列を共通部分と呼ぶ．これ以降の処理で共通部分は，画像 P に対応するラベルの候補として扱われる．

3.4 基本スコア付与

抽出された共通部分には基本スコアが付与される．基本スコアとは，その共通部分のラベルとしての確からしさを表した値であり，出現頻度が高く，文字数が多く，他の画像と共に出現することのない共通部分ほど高いスコアを与えられる．基本スコアの計算式は式(1)のようになる．

$$SCORE = \alpha \times \frac{F}{PN} \times \sqrt{L} \quad \cdots\cdots\cdots (1)$$

(1)式で，αは共通部分が他の画像とともに出現している場合スコアを減少させるようにはたらく係数，F は共通部分が同一画像と共に出現した頻度，PN は画像の出現回数，L は共通部分の文字数である．

3.5 出力

3.4 で述べた方法で求めた基本スコアが閾値 α を超えた共通部分は，画像 P に含まれる事物のラベルに適している可能性が高いと判断され，テキストで出力される．基本スコアが閾値 α を超える共通部分が複数存在する場合は，スコアの上位３つの中からランダムに選択された共通部分が出力される．予備実験の結果，閾値 α は 8.0 とした[21].

3.6 出力に対する評価

システムの出力に対してユーザは次の 3 つのキーワードのうち，最も相応しいものを選び，入力する．

・「じょうず」：ラベルとして適切である
・「おしい」　：ラベルとしては適切でないが意味はわかる
・「ちがうよ」：意味がわからない

幼児がこれらのキーワードを完全に理解するとは考えられないが，実際には，大人の表情や声の調子で感じ取ることのできる情報は多い．本手法ではそれらの情報の代わりにキーワードを用いることとする．

ユーザの反応によってその共通部分のスコアは再計算される．具体的には，基本スコアに係数βを乗ずる．係数βは，予備実験から，ユーザの評価が「じょうず」の場合は 1.5，「おしい」の場合は 0.8，「ちがうよ」の場合は 0.2 とした[21].

3.7 名詞概念獲得

「入力」から「ユーザの評価」の処理を繰り返した結果，再計算されたスコアが閾値 β を超え，さらに「じょうず」という評価を得たことがある共通部分は画像 P のラベルとして獲得される．予備実験の結果，閾値 β は 30.0 とした[21].

3.8 ラベル獲得ルール生成

獲得したラベル　：わんちゃん
過去の入力　　：あっちにわんちゃんがいるよ
↓
ラベル獲得ルール：あっちに@1がいるよ

図 3　ラベル獲得ルールの生成例

ラベル獲得ルールとは，再帰的な名詞獲得を行うためのルールである．人間は過去に得た知識を活用し，より効率的に学習を進めていく．本手法ではそのような再帰的な学習を次のようにして実現している．

システムが文字列 S をある事物に関する正しいラベルとして獲得すると，その事物に関する過去の入力文のうち，文字列 S を含む文から，ラベル獲得ルールを生成する．ラベル獲得ルールとは，図 2 のようにラベルの部分を変数とすることで，入力文を抽象化したものである．次に，生成したラベル獲得ルールに合致する入力文があった場合，変数部@1 に相当する部分を切り出し，スコアを上昇させる．

これは，人間は様々な表現を聞いているうちに，どのような表現がラベルを示すものなのかを学習して，より効率的に学習を進めていると考え，その様子をモデル化したものである．実際に，語彙爆発期の幼児は，一度大人が事物を指して言葉を発するのを聞いただけで，正しくその言葉を使うことができる（即時マッピング）ことが知られている[22]．ラベル獲得ルールを生成することで，本システムでもこれと似た現象を再現することができると考えられる．

ラベル獲得ルールの有効性については，過去に実験によって確認されている[23].

４．実験

4.1 実験の方法

SINCA が実際に名詞概念を獲得できるかどうかについて評価実験を行う．入力文は，アンケートによって収集したものと，ビデオ撮影によって収集したものの 2 種類を用いる．収集した文からランダムに選択したものをキーボードから入力する．画像処理における誤認識が実験結果に反映されることを避けるために，準備した静止画像を Web カメラで撮影したものを入力画像とする．

以下，4.2，4.3 で入力文の収集方法について詳しく述べる．

4.2 アンケートによる入力文収集

10 種類の事物（生物，人工物）に関して「まだ話すことのできない赤ちゃんにその画像に含まれる物を見せながら話しかける」ことを想定した内容を問うアンケートを実施した．回答者は 10 代から 60 代までの 31 名（男性 7 名，女性 24 名）であり，そのうち子育ての経験がある人は 13 名であった．

収集された全文数は 324 文であり，それらの平均モーラ長は 10.98 であった．

入力文の例を以下に示す．

- かわいいねこがいるよ
- おいしそうなりんごだね
- あそこにいるのはくまさんだね

4.3 ビデオ撮影による入力文収集

幼児がいる家庭における日常生活をビデオカメラ（Everio GZ-MG255，Victor）を用いて撮影を行った．撮影対象の家庭は 2 歳 7 ヶ月の男児，12 ヵ月の女児（ビデオ撮影開始の年齢）とその両親の 4 人家族である．

多くの場合，撮影場所は幼児が住む家の中であった．ただし，まれに自家用車内の場合もある．撮影はビデオカメラを親が手で持つか，箪笥の上などのやや高い位置に固定し行った．家庭における自然な発話が行われる場面の撮影を目的としたので，課題などは設けていない．

撮影は 2007 年 7 月 21 日から同年 11 月 23 日にかけて行われ，約 82 時間分の動画データが得られた．外出先など，環境が大きく異なる場面で撮影されたものを除き，前半の約 26 時間分のデータを本稿の実験で用いた．

得られた動画データを視聴し，第一著者がその発話内容を書き起こす作業を行った．書き起こし対象は大人の発話（主に両親）であり，なるべく発声の通りに記述したひらがな表記で記録した．音量が小さく内容が聞き取れない場合など，書き起こしが不可能である場合は何も記録しなかった．このような方法で書き起こされた全文数は 5,091 文であり，それらの平均モーラ長は 7.61 であった．

書き起こされた全データのうち，大人と幼児の間に共同注意（視線や指さしなどを手段として，相手と同じ対象を見ること）が成り立っている場面の発話の抽出を行った．このうち，出現頻度が高い 10 種類の名詞を含む 353 文を実験で用いる入力文の候補とした．なお，これらの 353 文の平均モーラ長は 9.82 であった．

入力文の例を以下に示す．

- ほらかまれるわありんこに
- うえひこうきとんでるひこうき
- こおりとって

4.4 実験結果

2 種類の入力文を用いた結果，どちらの場合も 10 種類の画像に適切なラベルを対応付けることに成功した．一つの名詞概念を獲得するまでに必要な入力回数は，アンケートによる入力文を用いた場合 6.2 回，ビデオによる入力文を用いた場合 5.3 回であった．

獲得されたラベル獲得ルール数はアンケートによる入力文の場合 52 個，ビデオによる入力文の場合 44 個であった．ラベル獲得ルールが適用された回数は，アンケートによる入力文の場合 3 回，ビデオによる入力文の場合 1 回であった．

以下はシステムが「ひこうき」というラベルを獲得するまでに行われたユーザと SINCA の対話である．U はユーザの発話，S は SINCA の出力を意味する．

U：れなちゃんうえひこうきとんでるひこうき
U：ひこうきばいばーい
U：ひこうきー
S：ひこう？
U：ちがうよ
U：ひこうきみえた？
S：ひこうき？
U：じょうずだね
U：うんひこうきー
S：ひこうき！

最後に SINCA が「ひこうき！」と出力しているのは，提示された画像に ”ひこうき ” というラベルを確実に付与したということを表している．

表 1　表現の多様性

	直前	直後
アンケート	19	42
ビデオ	15	22

5．考察

一つの名詞概念を獲得するまでに必要な入力回数は，ビデオによる入力文を用いた場合，アンケートによる入力文を用いた場合と比較して平均 0.9 回少なかった．このような実験結果が得られた要因として，次の三つが考えられる．

一つ目は一語発話の数である．アンケートによって収集された文の平均モーラ長は 10.98，ビデオによって収集された入力文候補の平均モーラ長は 9.82 であった．ここから明らかなように，ビデオによる入力文は短いという傾向がある．アンケートによって収集された入力文の中には一語からなる文は全く含まれていなかったのに対し，ビデオから収集された入力文の候補のうち 66 文（全体の 18.6%）が一語発話であった．実際に実験で SINCA へ入力された文のうち，7 文が一語発話であった．

二つ目は助詞の欠落である．アンケートによって収集された文は書き言葉に近く，助詞が省略されることはまれである．一方，ビデオによって収集された文では「らーめんあちちだからふーふー」，「あいすたべたの」などのように助詞が含まれないことが多く，入力された文のうち，全体の 42.6%にあたる 23 文に助詞の欠落がみられた．

三つ目は表現の多様性である．収集した文からランダムに 100 文ずつを抽出し，それらに含まれるラベルの直前と直後の 1 単語について分析を行った．アンケートによって収集した文，ビデオによって収集した文それぞれの直前・直後に現れた異なり単語数を表 1 に示す．アンケートの回答者は静止画を見て，そこに写る事物を説明しようとするため「～だね」，「～だよ」などの画一的な表現を使用することが多い．しかし，ビデオによって収集された文は日常生活における様々な状況の中での発話であるため，表現が多岐にわたる． これは，ラベル獲得ルールの

適用回数が少ないという結果にも結び付くと考えられる．

上記の要因によって，ビデオから収集された入力文を用いた場合，共通部分抽出処理を行う時にラベルとして適切な文字列を切り出すことが容易になったと考えられる．

６．まとめ

語彙や文法の知識を持たない状態から名詞概念を獲得するシステム SINCA の提案を行った．また，SINCA の性能評価を行うために，アンケートによって収集した入力文と，ビデオ映像からの書き起こしによって収集した入力文を用いて名詞概念を獲得する実験を行った．実験の結果，どちらの入力文を用いた場合でも名詞概念の獲得が可能であることが明らかになった．しかし，用いる入力文によって結果に違いが見られた．ビデオから収集された入力文を用いた場合の方が効率的に名詞概念を獲得することができた．これは，ビデオによる入力文には一語発話が多い（全体の 18.6%），助詞の欠落が多い（全体の 42.6%），表現に多様性がある（ラベルの直後の表現はアンケートの場合の 1.9 倍），などの特徴があるためであると考えられる．このことから，幼児が日常生活の中で聞いている大人の発話は名詞概念獲得に適したものであると考えられる．

今後は，ビデオからの書き起こし文についてさらに分析をすすめ，SINCA の性能向上につなげたい．また，名詞概念だけでなく，動詞や形容詞などの獲得を目指す予定である．

参考文献

[1] 藤田善弘: NEC におけるパーソナルロボットの開発，日本ロボット学会誌，Vol. 20，No. 7，pp. 16-19, 2002

[2] PARO[パロ] 人の心を豊かにするメンタルコミットロボット, http://paro.jp/

[3] 石黒浩，日浦亮太: コミュニケーション支援ロボットビジネス，日本ロボット学会誌，Vol. 20，No. 7, pp. 12-15, 2002

[4] 景山浩二，石田健蔵: エンタテインメントロボットビジネス，日本ロボット学会誌, Vol. 20, No. 7, pp. 8-11, 2002

[5] 駒谷和範，上野晋一，河原達也，奥乃博: ユーザモデルを導入したバス運行情報案内システムの実験的評価，情報処理学会研究報告 SLP-47-12, pp. 59-64, 2003

[6] BDL: 会話型ロボット/製品情報/ハローキティロボ, http://www.businessdesign.co.jp/product/002/

[7] James F. Allen，Lenhart K. Schubert，George Ferguson，Peter Heeman，Chung Hee Hwang，Tsuneaki Kato，Marc Light，Nathaniel G. Martin，Bradford W. Miller，Massimo Poesio and David R. Traum, The TRAINS Project: A case study in building a conversational planning agent, Journal of Experimental and Theoretical AI, Vol. 7, pp. 7-48, 1995

[8] Alison Cawsey: Generating Interactive Explanations, National Conference on Artificial Intelligence, pp. 86-91, 1991

[9] 荒木健治: 自然言語処理ことはじめ―言葉を覚え会話のできるコンピュータ，森北出版, 2004

[10] 今井むつみ，野島久雄: 今井むつみ，野島久雄，人が学ぶということ―認知学習論からの視点，北樹出版, 2003

[11] 今井むつみ: ことばの学習のパラドックス，共立出版, 1997

[12] 但馬香里: 幼児における一語発話の獲得について―1 歳 10 ヶ月から 2 歳 0 ヶ月児の 3 人の幼児による観察報告，東京工芸大学工学部紀要，Vol.27，No.2，pp.59-64, 1997

[13] Joost van de Weijer: How much does an infanthear in a day?, Proceedings of the GALA2001 Conference on Language Acquisition, pp.279-282，2002

[14] 須賀哲夫，久野雅樹: ヴァーチャルインファント－言語獲得の謎を解く，北大路書房, 2000

[15] 岩橋直人: ロボットによる言語獲得:言語処理の新しいパラダイムを目指して，人工知能学会誌, Vol.18，No.1，pp.49-58，2003

[16] 田中穂積，徳永健伸: ロボットとの会話．人工知能からのアプローチ，情報処理，Vol.44，No. 12, pp. 1247-1252, 2003

[17] P.A.P.Rogers and M.Lefley: Machine Conversations, The BABY Project, Kluwer AcademicPublishers, 1997

[18] S.E.Levinson，K.Squire，R.S.Lin and M.McClain: Automatic Language Acquisition by an Autonomous Robot, AAAI Spring Symposium on Developmental Robotics, 2005

[19] Visual Studio ホームページ: http://www.microsoft.com/japan/msdn/vstudio/

[20] エボリューション・ロボティクス社: http://www.evolution.com/products/ersp/.

[21] 内田ゆず，荒木健治: 幼児の普通名詞及び固有名詞獲得モデルに基づく帰納的学習を用いた再帰的獲得手法の提案，言語獲得と理解研究会報告, vol.1, pp. 21-27, 2005

[22] 小林郁夫，古川康一，今井むつみ: 帰納論理プログラムによる幼児の名詞語彙獲得のモデル化，電子情報通信学会技術研究報告言語理解とコミュニケーション研究会(NLC)，Vol.99，No.387，pp.29-36，1999

[23] Yuzu Uchida and Kenji Araki: A System for Acquisition of Noun Concepts from Utterances for Images Using the Label Acquisition Rules, Springer-Verlag Lecture Notes in Artificial Intelligence(LNAI) 4830, pp. 798-802, 2007

連絡先

内田 ゆず

E-mail: yuzu@media.eng.hokudai.ac.jp