情報処理北海道シンポジウム 2008

対訳文の部分対応に着目した機械翻訳自動評価手法

小山田 崇[†]　越前谷 博[††]　荒木 健治[†]

[†]北海道大学大学院情報科学研究科
[††]北海学園大学工学部

1 はじめに

インターネットの普及により様々な機械翻訳システムが利用可能となっている．しかし，それに伴い，機械翻訳システムの評価が大きな課題となっている．機械翻訳の出力文をすべて人手で評価するには多大な労力を要する．そのため，近年，翻訳文を自動的に評価するための翻訳自動評価の研究が盛んに行われている[1][2]. これまでの研究では，ドキュメント単位においては自動評価のスコアと人間の主観評価との間に高い相関があることが明らかとなっている．しかし，文単位においては十分な相関が得られず，問題点として指摘されている．

このような状況において，本稿では，構文情報として機械翻訳システムによる翻訳文と人間による参照訳との間で句に相当する部分的な対応関係を自動的に決定することにより，翻訳文を自動評価する新たな手法を提案する．提案手法では，部分的な対応関係の決定は，対応関係を決定するための対訳知識を学習により自動獲得し，それを適用することにより行う．そして，翻訳文と参照訳との間で対応する部分を抽出し，部分ごとの一致度と部分の文中の位置情報を自動評価スコアに反映させる．その結果，構文情報を利用した，より高度な翻訳自動評価が期待できる．

2 処理内容

2.1 部分抽出ルールの自動獲得

2.1.1 類似度に基づく単語対の抽出

部分的な対応関係を決定するために部分抽出ルールを獲得する．最初に，対訳コーパス中に出現する全単語を対象として，類似度の高い単語対を求める．単語対の類似度は以下の式(1)の重み付き Dice 係数[3]を用いて求める．

$$sim\left(\mathrm{W}_s, \mathrm{W}_t\right) = \log_2 f_{st} \frac{2 \times f_{st}}{f_s + f_t} \quad (1)$$

f_s は単語 W_s が原言語文に独立で出現する頻度，f_t は単語 W_t が目的言語文に独立で出現する頻度，さらに f_{st} は単語 W_s，W_t が対訳文中に共出現する頻度を示している．

この重み付き Dice 係数により求めた類似度が高い単語対の上位 100 組を部分抽出ルールの獲得に利用する．

2.1.2 省略可能部分の決定

抽出した単語対に基づき部分抽出ルールを獲得する．その際には，文中の省略可能性[4]に着目し，省略可能な部分を決定する．まず，対訳文中に出現する原言語，目的言語それぞれの単語対の単語において，その単語に隣接する単語を除き，対象となる単語とその前後 4 単語ずつとの bigram をそれぞれ求める．bigram は式(2)によって求める．

$$p(\mathrm{W}_2 \mid \mathrm{W}_1) = \frac{f\left(\mathrm{W}_1 \mid \mathrm{W}_2\right)}{f\left(\mathrm{W}_1\right)} \quad (2)$$

$p\left(\mathrm{W}_2 \mid \mathrm{W}_1\right)$ は単語 W_1 のすぐ右に単語 W_2 が隣接する確率であり，$f\left(\mathrm{W}_1 \mid \mathrm{W}_2\right)$ は単語 W_1 のすぐ右に単語 W_2 が隣接する頻度で，$f\left(\mathrm{W}_1\right)$ は単語 W_1 の出現頻度である．

単語対の単語 W_1 との bigram が 0 より大きい場合，単語 W_1 と単語 W_2 の間の単語列を省略可能な部分と位置づけ，単語 W_1 から単語 W_2 までの部分を抽出対象とする．また，単語 W_1 の位置により bigram を求める対象の範囲が文頭または文末を超える場合があるが，その場合は単語 W_1 が文頭または文末と共起すると考え bigram が 0 より大きいとして処理を続ける．

このような句レベルの部分の抽出において，問題点として，機能語が付与されてしまうことが挙げられる．機能語は出現頻度が高いため，bigram が高くなる傾向にある．そこで，不必要な機能語を排除するために，単語の重要度を反映することで，省略可能な部分をより高い精

度で決定できる．重要度は以下の Okapi BM25[5][6]を用いて求める．

$$score(D,Q) = \sum_{i=1}^{n} IDF(\mathrm{q_i}) \cdot \frac{f(\mathrm{q_i},D)\cdot(k_1+1)}{f(\mathrm{q_i},D)+k_1\left(1-b+b\cdot\frac{|D|}{avgdl}\right)}$$

$$IDF(\mathrm{q_i}) = \log\frac{N-n(\mathrm{q_i})+0.5}{n(\mathrm{q_i})+0.5} \qquad (3)$$

$f(\mathrm{q_i},\mathrm{D})$はその文中の単語$\mathrm{q_i}$の出現頻度，$|\mathrm{D}|$は文の単語数，$avgdl$は全文の平均単語数を示し，$k_1$，$\mathrm{b}$はパラメータで，それぞれ$k_1$=2.0，$\mathrm{b}$=0.75 を用いた．$\mathrm{N}$は全体の文の数，$n(\mathrm{q_i})$は単語$\mathrm{q_i}$を含む文の数を示している．

① 重み付きDice係数による類似度上位100組を選択

例

原言語	目的言語	重み付き類似度
the	の	4.539
statement	声明	3.322
bank	銀行	2.718
china	中国	2.717
market	市場	2.378

② 対象語の前後5単語についてbigramを求める

例 : (The Seoul stock market is closed on Wednesday for Buddha's Birthday
; ソウル 株式 市場 は 、釈迦 誕生 日 で 休場)
対象語 : (market ; 市場)
bigramを調べる候補 :
(the ; market), (seoul ; market), (market ; closed),
(market ; on), (market ; wendsday), (market ; for)
(ソウル ; 市場), (市場 ; 、), (市場 ; 釈迦), (市場 ; 誕生),
(市場 ; 日)
bigramが0より大きい候補 :
(the ; market) bigram = 4 / 240 = 0.01739
また、"market", "市場"ともに文頭から5単語以内にあるため、文頭と共起していると考え、(; market), (; 市場)も省略可能性のある候補とする

③ 原言語部と目的言語部の共起語と対象語の重要度を求める

例 [(the ; market) ; (; 市場)]
(the ; market)
重要度 : 0.5412
(; 市場)
重要度 : 2.7690
原言語部、目的言語部ともに重要度が閾値0.54を超えているため
[(the ; market) ; (; 市場)]は省略可能とみなす

図 1 省略可能性候補の獲得処理過程

bigram により得られた原言語と目的言語のそれぞれの部分候補に対して重要度を求める．その際，部分が複数の単語からなる場合には，個々の単語の重要度の平均を最終的な重要度とする．重要度の閾値はデータを目視の上最適と考えた上で 0.54 と仮決定した．

そして，重要度が閾値 0.54 を超えた場合のみ単語$\mathrm{W_1}$から単語$\mathrm{W_2}$の間を省略可能とする．省略可能な部分の決定の具体例を図 1 に示す．図 1 においては，“the”と“market”の間の“Seoul stock”と“市場”の左に隣接する“ソウル/株式”が省略可能な部分と決定された．

2.1.3 第 1 部分抽出ルールの獲得

2.1.2 により求めた省略可能性な部分を変数@0 と置換することで，第 1 部分抽出ルールを獲得する．その際には言語間の対応関係を決定しなければならない．例えば(a joint statement ; は 共同 声明)では，“statement”と“声明”が **2.1.1** より得られた単語対で“a”と“は”が bigram より得られた共起語である．この共起語を含めるべきかどうかを類似度によって決定する．この場合，(a joint statement ; は 共同 声明)，(joint statement ; は 共同 声明)，(a joint statement ; 共同 声明)のそれぞれについて類似度を計算する．その結果，それぞれの類似度は 0.7876，0.8260，0.8525 となり，類似度の最も高い(a joint statement ; 共同 声明)が選択される．したがって，省略可能な部分を変数化した(a @0 statement ; @0 声明)が第 1 部分抽出ルールとして獲得される．

ここで類似度は，以下の単語分割方式による類似度より求める．

1) 原言語部と目的言語部の各単語間の類似度を Dice 係数により求める．
2) 原言語部の各単語に対し，類似度の高い目的言語部の単語を対応させる．対応させた際の類似度の平均値を目的言語部に対する原言語部の類似度とする．
3) 同様に，目的言語部の各単語に対し，類似度の高い原言語部の単語を対応させる．対応させた際の類似度の平均値を原言語部に対する目的言語部の類似度とする．
4) 2)，3)で求めた 2 つの値の平均値を原言語部と目的言語部の単語分割方式による類似度とする．

具体例を図 2 に示す．

例 (a joint statement ; は 共同 声明)

	a	joint	statement
は	0.4154	0.0202	0.0874
共同	0.0606	1.0	0.3333
声明	0.2467	0.3636	0.9474

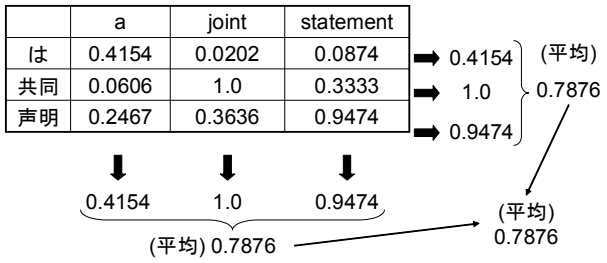


図 2　単語分割方式による類似度計算の例

このようにして獲得された部分抽出ルール間において帰納的学習[7]を適用し，より一般的な，(a @0 ; @0)や，(the @0 ; @0)といった部分抽出ルールを獲得する．

例

(the escudo is a stable currency ; エスクード は 安定 し た 通貨 だ)

	the	escudo	is	a	stable	currency
エスクード	0.0087	1.0000	0.1053	0.0308	1.0000	0.5000
は	0.6150	0.0102	0.1402	0.4154	0.0102	0.0302
安定	0.0258	0.5000	0.0952	0.0597	0.5000	0.3333
し	0.4403	0.0225	0.1698	0.3421	0.0225	0.0440
た	0.5521	0.0159	0.0839	0.4339	0.0159	0.0469
通貨	0.0667	0.1818	0.1429	0.1351	0.1818	0.4615
だ	0.0976	0.1176	0.0588	0.2500	0.1176	0.2105

第1抽出ルール : (the @0 ; @0)

(1) “escudo” に対応する単語を決定する
  ① 原言語である“escudo”から見て最も類似度が高く、閾値0.35以上である単語”エスクード”を仮選択
  ② 目的言語である“エスクード”から見て最も類似度の高い単語が”escudo”であるため、”escudo”と”エスクード”が対応していると決定する

(2) “is”に対応する単語を決定する
  ① 原言語である“is”から見て最も類似度が高く、閾値0.35以上である単語”し”を仮選択
  ② 目的言語である“し”から見て最も類似度の高い単語が”the”であるため、”escudo”と”エスクード”は対応していないとし、探索を終了する

(3) (the escudo ; エスクード)を抽出する

図 3　第 1 部分抽出ルールを用いた部分対応関係の決定

2.1.4 第 2 部分抽出ルールの獲得

更なる部分抽出ルールの獲得を目的に，第 1 部分抽出ルールに基づき第 2 部分抽出ルールを自動獲得する．以下にその処理過程を示す．

(1) 第 1 抽出ルールの変数以外の単語がすべて含まれている対訳文を選択する．

(2) 対訳文の中で，第 1 抽出ルールの変数部分に対応する部分を決定し抽出する．変数部分に対応する部分の決定の仕方は以下の処理のいずれかである．

a) 第 1 抽出ルールの原言語部もしくは目的言語部のいずれかにおいて，変数の両側共通部分である場合，対訳文において 2 つの共通部分にはさまれた部分と共通部分をともに抽出する．

b) 第 1 抽出ルールの原言語部もしくは目的言語部のいずれかにおいて，変数の片側のみに共通部分がある場合，対訳文の共通部分の片側方向を探索範囲とし，類似度を用いて単語の対応関係を決定し，対応部分と共通部分をともに抽出する．

c) 第 1 抽出ルールの原言語部もしくは目的言語部のいずれかにおいて，変数のみの第 1 抽出ルールの場合は，対訳文のすべてを探索範囲とし，類似度を用いて単語の対応関係を決定し，対応部分と共通部分をともに抽出する．

(3) (2)の処理により抽出された部分を変数とした部分抽出対訳文の中から，原言語部，目的言語部の両方において変数に隣接する部分が共通部分である対訳文対を選択する．

(4) 変数と変数に隣接する共通部分を共に抽出して第 2 部分抽出ルールとして獲得する．

2.2 部分抽出ルールを用いた部分的な対応関係の決定

2.1.3 及び **2.1.4** で獲得した部分抽出ルールを用いて，対訳文から句に相当する部分的な対応関係を抽出する．第 1 部分抽出ルールを用いる場合，部分抽出ルールの変数以外の単語も対応関係に含まれる．第 2 部分抽出ルールを用いる場合には，変数に対応する部分のみを抽出する．図 3 に第 1 部分抽出ルールを用いた対応関係決定の具体例を示す．

また，部分的な対応関係が一意に決まらず，複数存在する場合には，以下の基準により一意に決定する．

a) 抽出部分の原言語部または目的言語部が完全一致の場合，抽出部分の単語分割方式による類似度の高い方を選択する．

b) 抽出部分の原言語部, 目的言語部ともに包含関係の場合，長い方を選択する．

c) 抽出部分の原言語部または, 目的言語部のいずれかが包含関係の場合，単語分割方式による類似度の高い方を選択する．

d) 抽出部分の原言語部または，目的言語部のいずれかが部分包含関係の場合，単語分割方式による類似度の高い方を選択する．

3 自動評価手法

原言語文とその対訳となる参照訳と機械翻訳文を用意し，原言語文と参照訳，原言語文と機械翻訳文について 2 により部分対応関係を持つ部分を抽出する．

抽出部分の原言語部が参照訳と機械翻訳文で同じものを指した場合，対応する互いの目的言語部が対応関係にあるとみなす．

対応関係にある部分のスコアを重みとして，非対応関係部分と合わせ計算したものをその目的言語文全体のスコアとする．

対応関係にある部分のスコアは以下のように求める．

(1) 位置情報のスコアを求める．

a) 部分対応関係の相対位置のずれを求める

b) 複数の部分対応関係が存在する場合，ずれの平均を求める．

c) 1 からずれを引いた値を位置情報のスコアとする．

(2) 一致度のスコアを求める．

一致度のスコアは最長共通部分列(LCS:Longest Common Subsequence)を分子とし，対応関係にある部分の単語数を分母とした商とする．

(3) 位置情報のスコアと一致度のスコアの積に重みとして 0.8 乗したものを対応関係にある部分のスコアとする．

目的言語文全体のスコアは対応関係にない部分の LCS と部分対応関係部分のスコアとの積を分子とし，文の単語数を分母とする商とする．このとき機械翻訳文のスコアを適合率，参照訳のスコアを再現率とする．

機械翻訳文と参照訳との相関は機械翻訳文のスコアである適合率と，参照訳のスコアである再現率を用いた F 値を用いて求める．参照訳が複数ある場合，それぞれの適合率，再現率を求め，値が最大の適合率，再現率を用いて式(5)より F 値を求める．また、図 4 に適合率と再現率を求める具体例を示す。

$$F_{lcs} = \frac{\left(1+\beta^2\right)R_{lcs}P_{lcs}}{R_{lcs}+\beta^2 P_{lcs}}$$

$$\beta = \frac{P_{lcs}}{R_{lcs}} \qquad (5)$$

P_{lcs} は適合率，R_{lcs} は再現率を示す．

例：
原　文 : The Seoul stock market is closed on Wednesday for Buddha's Birthday.
機械翻訳文 : ソウル／株式／市場／は／水曜日／に／仏陀／の／ Birthday ／の／ため／に／休業／しま／す／ 。
参照訳 : ソウル／株式／市場／は／ 、／釈迦／誕生／日／で／休場／ 。
省略可能性に基づく部分対応関係
　機械翻訳文 : (Seoul stock market ; ソウル／株式／市場)
　参照訳 : (Seoul stock market ; ソウル／株式／市場)
位置情報のスコアを求める
　①相対位置のずれを求める
　　機械翻訳文: ソウル／株式／市場 → 1/16 = 0.0625
　　参照訳 : ソウル／株式／市場 → 1/11=0.0909
　　位置情報のずれ : |0.0625 – 0.0909|=0.0284
　②複数の対応関係のある部分が存在する場合、ずれの平均を求める
　③"1 – 位置のずれ"を位置情報のスコアとする
　　位置情報のスコア : 1 – 0.0284 = 0.9716
一致度のスコアを求める
　LCSは3、単語数は機械翻訳文、参照訳共に3であるため、機械翻訳文側の一致度 : 3/3=1 ; 参照訳側の一致度 : 3/3=1となる
対応関係にある部分のスコアを求める
　機械翻訳文 : 0.9716×1の0.8乗 → 0.9772
　参照訳 : 0.9716×1の0.8乗 → 0.9772
適合率と再現率を求める
　対応関係にない部分のLCSは3、全体の単語数は機械翻訳文19、参照訳14であるため、対応関係にない部分のスコアは
　適合率 : (3×0.9772) / 19=0.1543
　再現率 : (3×0.9772) / 14=0.2094

図 4 適合率と再現率の具体例

4 実験

4.1 実験方法

ロイターの新聞記事の対訳コーパス[8]を原言語文と参照訳の 1 つとし，その他に翻訳例を 2 つ用意し，合わせて参照文を計 3 種類とした．実験用に原言語文を機械翻訳したものと共にそれぞれ 150 文用意した．それぞれの単語数は対訳コーパスの英文は 3,261 単語，日本語文は 4,466 単語で，他の 2 つの参照訳は 4,191 単語と 4,558 単語，機械翻訳文は 4,716 単語である．

また，機械翻訳の自動評価と人間の手による機械翻訳評価との相関はピアソンの相関係数を用いて求めた．

相関係数に用いたベクトルの要素は各文のスコアであり，150 個である．

4.2 実験結果

提案手法は PER[6]と比較すると，Adequacy，Fluency ともに大きく上回り，Average で約 0.39 上回った．しかし，ROUGE-L[9]と比較すると Average で約 0.012 下回った．表 1 に結果を示す．

また，部分対応の抽出は原言語文 150 文に対し 106 文に対して行われた．その内有効な抽出は 35 文にあり，精度は約 0.33 であった．

表 1　提案手法と従来手法の比較実験の結果

	Adequacy	Fluency	Average
提案手法	0.5024	0.5311	0.5168
ROUGE-L	0.5145	0.5422	0.5284
PER	0.1626	0.0784	0.1205

5 考察

提案手法のスコアが PER のスコアを大きく上回ったが, これは PER が語順の制約を無視して単語の一致度を計算する手法なのに対し，提案手法は語順の制約に厳しい手法なので，その差によるものと考えられる．また，提案手法のスコアが ROUGE-L のスコアを下回った理由だが，これは抽出された部分対応の数，精度が共に十分ではなかったことや，意味的に正しい部分対応でも，表現の違いにより一致度が下がったため部分対応の抽出が逆にスコアを下げる要因になったこと，各パラメータの設定が不十分であったことが考えられる．したがって，提案手法では構文情報の利用による有効性が十分反映されないスコアとなった.

6 今後の予定

本稿では，構文情報として機械翻訳文と参照訳との間の部分的な対応関係を自動的に決定することにより，機械翻訳文を自動評価する新たな手法の提案を行った．実験の結果，提案手法では各パラメータの設定が不十分なため，構文情報の有効利用ができていないことが明らかになった．今後の予定としては，予備実験を行い各パラメータの最適値を求め，より多くの部分対応を高い精度で抽出するための改良を行う．そして，構文情報を十分に反映できるような計算式を求め，自動評価を行う予定である.

参考文献

[1] 安田圭志，隅田英一郎，“機械翻訳の研究・開発における翻訳自動評価技術とその応用”，人工知能学会誌，Vol.23，No.1，pp.2-9，2008.

[2] Hiroshi Echizen-ya , Kenji Araki , “automatic Evaluation of Machine Translation based on Recursive Acquisition of an Intuitive Common Parts Continuum”, Proceedings of the Eleventh Machine Translation Summit (MT SUMMIT XI), pp. 151-158, Copenhagen, Denmark, 2007.

[3] 北村美恵子，松本裕治，“対訳コーパスを利用した対訳表現の自動抽出”，情報処理学会論文誌 Vol.38, No.4，pp.727-735，1997.

[4] 寺島涼, 越前谷博, 荒木健治, “学習型機械翻訳手法における省略可能性を用いた翻訳ルールの自動獲得とその有効性”, 情報処理学会研究報告 2008－NL198（19），pp.127-134，2008.

[5] K. Sparck Jones, S.Walker, S.E. Robertson, “A Probabilistic Model of Information Retrieval: Development and Comparative Experiments Part1”, Information Processing and Management, 36(6), pp.779-808, 2000.

[6] K. Sparck Jones, S.Walker, S.E. Robertson, “A Probabilistic Model of Information Retrieval: Development and Comparative Experiments Part2”, Information Processing and Management, 36(6), pp.809-840, 2000.

[7] 荒木健治（著），自然言語処理ことはじめ―言葉を覚え会話のできるコンピュータ，森北出版，東京，2004.

[8] Masao Utiyama and Hitoshi Isahara. (2003) Reliable Measures for Aligning Japanese-English News Articles and Sentences. ACL-2003, pp. 72-79.

[9] Keh-Yih Su, Ming-Wen Wu, Jing-Shin Chang, “A New Quantitative Quality Measure for Machine Translation Systems”, COLING’97，pp.433-439, 1997.

[10] Chin-Yew Lin , Franz Josef Och , “Automatic Evaluation of Machine Translation Quality Using Longest Common Subsequence and Skip-Bigram Statistics”, ACL’04，pp.605-612，2004.