講演番号　0257
セッション 14 音響・音声・言語

文脈情報を用いた関連語抽出のオンラインゲームへの応用

An Application of Related Term Extraction Using Context Information to Online Game

高松 雅彦 † 荒木 健治 †
Masahiko Takamatsu Kenji Araki
† 北海道大学大学院情報科学研究科
Graduate School of information Science and Technology, Hokkaido University

1 はじめに

ゲームの形態がオフラインからオンラインへと変化していく中で,「MMO-RPG」(Massively Multiplayer Online Role Playing Game - 多人数同時参加型オンラインロールプレイングゲーム）が人気を集めている．オンラインゲームにおいて，ユーザーの要望を把握したりシステムのエラーを発見するために，電子掲示板やチャットの文章が利用されることがある．その内容を把握し時間と共に変化する話題を抽出しようという研究も行われている [1]．しかしオンラインゲームのチャットログには，未知語，インターネット用語，スラングなどが多く含まれるため，機械処理に適した文章とはいえない．またこのことは新たにゲームを始めるユーザーにとっても発話内容の意図が理解しにくくコミュニケーションが阻害される原因となる．

そこで本稿では，大量の文書群を使わずに，単一のオンラインゲームのチャットログから文脈情報を用いて未知語の関連語候補を抽出し，ユーザーに提示することで，ユーザー間のコミュニケーション支援を可能とするシステムを提案する．本稿での関連語とは，同義関係・階層関係・関連関係にある語のことをいう．

2 システムの概要

既存の手法でよく用いられるのは *tf·idf* である [2]．*tf·idf* は，その文書にはよく出現するが，他の文書にはあまり出現しない語を高く評価する．そのため，大規模なコーパスやシソーラスといった語彙資源の集合を必要とする．しかし，それらの語彙資源は一般的な語彙の集合であり，オンラインゲームに特化したコーパスや辞書が存在しない．また，オンラインゲームのチャットログはドキュメント数が少ないため，*tf·idf* の適用は困難であり，有効な結果は得られないと考えられる．

そこで本システムでは，単一のオンラインゲームのチャットログを用い，未知語の直前・直後に出現する単語に着目し未知語の関連語候補を抽出しユーザーに提示する．これは，関連性のある単語は文法的に類似した表現で使われるという考えに基づいている．抽出結果をユーザーに提示することで，ユーザーが未知語の意味を理解し，コミュニケーションの円滑化を実現する．また検索対象になる未知語を含む文をチャットログから全て取り出すことにより，抽出の範囲を広げ抽出のパターンを拡張している．

まず最初に，ユーザーの入力文を MeCab[3] を用いて形態素解析を行う．形態素解析により得られた未知語を獲得し，チャットログからその未知語を含む文を全て抽出する．得られた文から，その未知語の直前・直後に出現する語を出現回数でソートし，出現頻度上位 M 位までの語について，それらの語を含む文をチャットログから全て抽出する．この際，直前（PW）・直後（NW）の語が記号や句読点，数字である場合は，以降の処理で抽象度の高い語が抽出されてしまうため，ブロックワードに設定し抽出しないようにしている．

得られた文から，PW の直後に出現する単語（NPW），NW の語の直前に出現する単語（PNW）を出現回数でソートし，出現回数上位 N 位までの語を取り出す．ここまでの処理で，最大 M × N 語の関連語候補が抽出される．また，M × N 語のうちの重複するものを影響度という．

最後に，関連語候補中で影響度の高い単語をユーザーに提示する．これは，多くの語から影響を受ける語は重要性が高いという考えに基づいている．また，最終的に抽出された関連語候補が助詞・助動詞などの非自立語である場合，それらは単独では意味を成さないため除外している．

3 評価実験

RED STONE[4] のチャットログを用い，チャットログ中の出現回数上位 33 位までの未知語に対して実験を行い，未知語とその関連語候補の関係のタイプについて調査を行う．実験には 10,275 文（864KB）を使用し，209,447 語中 54,888 語（のべ数）が未知語であった．チャットログの発話における品詞内訳を表 1，未知語の出現回数上位 5 位までを表 2 に示す．関係の種類は，日本工業規格 [5] に基づいて同義関係，階層関係，関連関係の 3 つに分類した．出現回数上位 M 位は 5 位，出現回数上位 N 位は 5 位を仮に設定した．ユーザーの負担を考慮し，ユー

表 1: チャットログの発話の品詞内訳

品詞	出現回数
名詞	66,264
未知語	54,888
記号	40,666
助詞	16,561
動詞	14,540
助動詞	11,180
接頭詞	2,115
形容詞	1,993
副詞	555
感動詞	354
接続詞	278
連体詞	43
フィラー	10

表 2: 未知語の出現回数上位 5 位

ポタ（2,240）	
Lv（1,951）	
PT（1,348）	
GV（1,147）	
蟲（879）	

※（）内は出現回数

ザーに提示する関連語候補数は最大 5 語とし，その中に関連語が含まれないときを無効な結果とした．

未知語とその関連語候補の関係の種類について調べた結果を表 3 に示す．また実験結果の例を表 4 に示す．

4　考察

未知語の出現回数上位 33 語において，システムが抽出した関連語候補のうち，同義関係が 18.2%，階層関係が 21.2%，関連関係が 18.2%，合計して関係性のある語は 57.6%であった．しかし未知語の出現回数上位の中に特殊記号や顔文字が存在し，それらは意味を持たないことが多く，無効な結果を増やし精度を下げる要因となっている．精度を向上させるために，顔文字認識やヒューリスティックな機構を組み込んでこれらを除外する必要があると考えられる．また，現状のシステムでは半角文字と全角文字を区別できないので，その点を考慮する必要がある．

オンラインゲームで使用される**「Lv」**とは,「Level（レベル）」の省略語である．この語は，キャラクターの強さや成長度を表す数値である．

例：Lv 上げ手伝います．Lv20-35 の方

表 3 より，本システムで「Lv」の同義語「レベル」を

表 3: 未知語と関連語候補の関係性の分類

関係の種類	語数
同義関係	6
階層関係	7
関連関係	6
無効な結果	14

表 4: 未知語「Lv」の関連語候補

レベル（3）
Ｌｖ（2）
レベ（2）

※（）内は影響度

チャットログから抽出可能なことが確認された．また「レベル」という語は「Lv」と省略されるだけでなく,「レベ」と省略され表記される場合がある．これらの表現についても，本システムで抽出可能なことが確認できた．

5　まとめ

本稿では，単一のオンラインゲームのチャットログから文脈情報を用いて未知語の関連語候補を抽出するシステムを構築し，その評価実験を行った．文脈情報を用いることにより，単一のチャットログから未知語の関連語を抽出することができた．しかし，チャットログに未知語の関連語が含まれていない場合は，有効な結果を得ることはできないという問題がある．

今後の課題としては，文脈情報だけではなく品詞情報も用いることで，さらなる精度向上を目標としたい．またインターネット用語は，オンラインゲーム以外でも WEB で広く使用されるため，チャットログに関連語が存在する可能性が高くない語も存在する．そのような語に対して関連語抽出を可能にするために，WEB をコーパスとして関連語抽出を行うことを予定している．

参考文献

[1] 津田耕平，Ruck Thawonmas，”ゲームマイニングの野望-III：語の影響度の計量による掲示板におけるキーワードの発見” エンタテインメントコンピューティング 2004 講演論文集，pp.155-160，2004.

[2] 坂口朋章，平松丈嗣，平澤茂一，”文脈関連度による検索質問拡張手法の改良”，FIT2006（第 5 回情報科学技術フォーラム），講演論文集，pp.131-132，2006.

[3] MeCab:Yet Another Part-of-Speech and Morphological Analyzer
http://mecab.sourceforge.jp/

[4] 無料オンラインゲーム「RED STONE」
http://www.redsonline.jp/

[5] 日本工業規格（1991）「シソーラスの構成及びその作成方法:JIS X 0901-1991」，日本規格協会：東京，24p.