Webデータを用いた比喩的説明文生成の研究

Research on generating figurative explanations from the Web

近村　亮一　　ジェプカ　ラファウ　　荒木　健治

Ryoichi Chikamura　　Rafal Rzepka　　Kenji Araki

北海道大学大学院情報科学研究科

Graduate School of Information Science and Technology, Hokkaido University

1．まえがき

現在，インターネットの普及等により世の中には電子化されたテキストデータがあふれている．これらのデータの中には、教育の場において非常に利用価値の高いものが多く含まれている．それらの用途としては自己学習のための資料や，子供の知識欲の刺激といったことが考えられる．

しかし，要求された情報の書かれている文章のレベルが，読み手にとって適切な文章レベルであるという保証はない．つまり“欲しい情報が書かれているのだが，難しすぎて内容の理解が進まない”というケースが考えられる．

また，近年の計算機性能の向上や自然言語処理研究の成果を踏まえると，上述したデータを合わせて利用することにより，教育の場に自然言語処理研究からの成果を生かせるのではないかと考えている．

このような背景で，自己学習の支援，教材作成の負担軽減等を目的とし，読み手にとって難しい文章の読解補助を目的としたシステムの構築を目指している．このシステムが行う必要のある処理として，以下を設定した．

(1) 理解の妨げとなる単語，表現の発見

(2) 該当箇所の言い換え及び説明の付与

本稿では (2)における“単語説明の生成” に焦点を当てる．単語の説明付与には，単純に辞書を用いて単語に対する説明を取り出すことや，Web データを用いて辞書的な説明を生成する方法[1]などが考えられる．しかし，これら辞書的説明では，初学者など読み手に説明を理解するための知識がない場合，説明の理解そのものが難しいという状況が考えられる．

そこで我々は比喩による説明に注目した．比喩を用いた説明は，一般に広く用いられている．加えて，教育の場においても，その有効性が多数報告されている[2][3]．本研究では読み手の知らない単語に対して，比喩による説明を付与することで，読み手の直観的理解を助けようというものである．

2. 関連研究

比喩を用いた説明生成の研究として，事前に整備した知識ベースと比喩テンプレートを用いて比喩表現の生成を行うものがある[4]．

これに対して我々は，知識ベース構築等のコストを削減するため，比喩表現の Web データをもとにした自動生成を目指す．

3. WEB データの調査及び収集方法の検討

比喩の生成を目標とした時，WEB 上にはどういったデータが存在しているかの調査とその収集方法の検討を行った．比喩を示す指標として，“に例えると”というようなフレーズを比喩指標と呼ぶこととし，物事の説明によく出現する“単語 A{比喩指標}単語 B”という形を対象にした．具体的には“人に例えれば脳”という形である．このとき，A，B はどのような関係を持つ単語が出現するのかをとらえることで，比喩説明生成のための指針及び資源を得られると考え，調査を行った．また，平行して A，B に当てはまるものの収集方法についても同時に検討する．収集方法については，以下に示す手順を設定した．

まず，｛比喩指標｝をクエリにフレーズ検索を行う．次に，得られた検索結果上位 500 位のスニペット中から，比喩指標を含む文を形態素解析し，比喩指標の前後にある単語のうち，最も比喩指標と接近している自立語[*1] をそれぞれ単語 A，単語 B としてペアの形で抽出する．最後に，得られた単語 A，B のペアを用いて“A｛比喩指標｝B”というクエリを生成する．このクエリで再度フレーズ検索を行い， HIT 数が 0 件のものをノイズとして除去，1 件以上のものを出力する．検索には Yahoo! API[*2] を用いている．処理の過程を図 1 に示す．

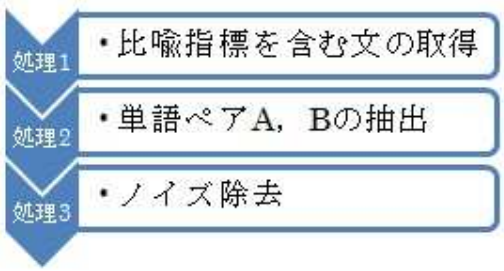


図 1　処理の流れ

比喩指標としては複数のものが考えられるが，本稿では“に例えると”を比喩指標に設定し，これに絞ったデータ収集，分析を行った．この条件で上記の手順に沿い 218 組の単語ペアの収集を行った．

4. 分析

得られた単語 A ，B のペアに対して，その間にはどのような関係があるかについての分析を行う．比喩の中に現れるという点を考えると，A，B の関係は日常の中で理解されるもの，つまりは“常識”に基づいた関係分類が行われることが望ましいと考えた．

“常識”にかかわる研究として，Open Mind Common Sense[5]プロジェクトの常識 DB の ConceptNet[6] が存在

[*1] 形態素解析器 MeCab により自立語であったものを設定．（IPADIC に基づく解析）
MeCab: http://mecab.sourceforge.net/

[*2] Yahoo!API: http://developer.yahoo.co.jp/

する．これは従来の意味関係による単語関の関係付けとは少し離れて，“連想”に基づいた関係により単語間の関係を設定したDBである．

そこでA，Bの関係ついて，ConceptNetで定義されている関係[*3]での分類を試み，最終的に以下の分類を行った．

(a) ConceptNetで用いられる関係のどれに該当するか

(b) 関係をとらえられない（ノイズである）

今回は調査目的であるため，分類は人手で行った．自身の研究にConceptNetを利用している日本人大学院生の協力者1名と，第一著者の計2名が得られたすべてのペア及び図1の処理3でノイズと分類されたすべてのペアに対して独立に分類処理を行った．

5. 結果及び考察

i) 出力中のノイズの割合

第一著者及び協力者がともにノイズであると分類したものをノイズとして扱う．この結果を表1に示す．

表1　出力中のノイズの割合

総数	ノイズ数	ノイズの割合
174	74	42.5%

表1の結果から，出力中にも42%のノイズが含まれている．含まれていたノイズの傾向としてはA，Bのどちらか“何”や“こと”といった疑問詞や代名詞を含むものが多数存在し，“色に例えると何”や“動物に例えることで，”等から抽出されたと考えられる．また“人間に例えると、最近女の子に流行の名前”等A,Bを文節単位の抽出とした方が適切であるケースによるものも含まれていた．

ii) ノイズ除去処理の効果について

図1の処理3に示すノイズ除去の妥当性の評価を行った．

R = システムがノイズと判断したもの

C = 人手によりノイズと判断されたもの

とした適合率，再現率，F値を式(1)～(3)に示す．表2に図1の処理3におけるノイズ判定の適合率，再現率を示す．

$$\text{適合率} = \frac{R \cap C}{R} \quad \cdots(1) \qquad \text{再現率} = \frac{R \cap C}{C} \quad \cdots(2)$$

$$\text{F値} = \frac{2 \times \text{適合率} \times \text{再現率}}{\text{適合率} + \text{再現率}} \quad \cdots(3)$$

表2　図1の処理3におけるノイズ判定の適合率と再現率

適合率	再現率	F値
0.750	0．308	0.436

この結果から，再現率の向上が一番の課題である．これにはhit数に対する適切な閾値を設定することで改善するものと考えられる．

iii) 関係の分類結果

第一著者と協力者による分類の結果に対し，その一致率とその割合を表3に示す．

表3　第一著者と協力者の分類結果の一致数とその割合

分類された総数	一致数	割合
100	43	43.0%

次に，第一著者と協力者の間で分類の一致したペアの数とその割合を表4に示す．

表4　一致した分類結果を持つペアの数と割合

分類カテゴリ	該当ペアの数	一致結果数に対する割合	総数に対する割合
B IsA A	19	44.2%	19%
A HasA B	14	32.5%	14%
A HasProperty B	3	7.0%	3%
A AtLocation B	3	7.0%	3%
A MadeOf B	1	2.3%	1%
A IsA B	1	2.3%	1%
B PartOf　A	1	2.3%	1%
ConceptuallyRelatedTo	1	2.3%	1%

表3より，収集されたペアの分類において，筆者と協力者の間で分類結果が一致するものの割合が全体の50%を下回っていることから，人手による分類では判断の個人差が強く影響していると考えられる．

一致した結果を正解として，単語A，Bのペアの関係について考えると，“に例えると”という比喩指標の元では“BはAの一つである”という具体-抽象の関係と“AはBを持つ”という所有の関係をもつ単語を用いた比喩が広く使われている．

6. まとめと今後の展望

本論文では教育分野への利用を目的とした，Webデータからの比喩による用語説明生成システムの構築に向けた調査を行った．その結果，Web上に比喩を生成するための資源が確かに存在していることを示した．今回は比喩指標“に例えると”に注目した調査にとどまったが，今後別な比喩指標に対する調査が必要である．そのためには比喩指標の収集が必要である．これを行うために，今回収集されたA，Bのペアを元に，たとえばWeb文章中からA，Bに挟まれた文字列を収集，分析することで逆に比喩指標の収集を行うことを考えている．

参考文献

[1]桜井 裕，佐藤 理史：ワールドワイドウェブを利用した角語説明の自動生成
情報処理学会論文誌 43(5)，1470-1480，2002-05-15

[2]Jill L. Quilici，Richard E. Mayer：Role of examples in how students learn to categorize statistics word problems.
Volume 88，Issue 1，March 1996，Pages 144-161

[3]田辺敏明：心理学概念の保持に対する比喩的説明文の特性の効果
教育心理学研究 38(2),166-173，1990-06-30

[4]石田 修一，蔵方 隆宏，森 辰則：知的マニュアルシステムにおける比喩説明文の生成
情報処理学会研究報告.自然言語処理研究会 6(7),1-6

[5]Open Mind Common Sense
http://openmind.media.mit.edu/

[6]Common Sense Computing Initiative
http://csc.media.mit.edu/conceptnet

[*3] 内容，説明については参考文献[6]を参照