Web 上のデータを用いた比喩を含む説明文の自動収集手法

A Method of Collecting Explanations Containing a Simile from the Web

近村　亮一　　ジェプカ　ラファウ　　荒木　健治

Ryoichi Chikamura　　Rafal Rzepka　　Kenji Araki

北海道大学大学院情報科学研究科

Graduate School of Information Science and Technology, Hokkaido University

{chika, kabura, araki}@media.eng.hokudai.ac.jp

1. はじめに

私達が文章を読むときに，意味が不明な単語に出くわすことがある．このとき，辞書を用いて単語の意味を調べ，理解することが必要となる．しかし，辞書を引いた際，そこに記載されている説明を理解するための知識がないなどの理由により，単語の意味を調べるためにまた辞書を引き直す，あるいは調べたが意味が不明のまま終わるという場合がある．

そのような問題を解決する方法として，我々は比喩による説明に注目した．比喩を用いた説明は，一般に広く用いられている．加えて，教育の場においても，その有効性が多数報告されている[1][2]．このことから，比喩による説明が読み手の文章理解の支援につながるということができる．

本研究の目的は，単語に対し，比喩による説明の付与を通し，単語の意味の直観的な理解を促すことである．

2. 関連研究

比喩を用いた説明生成の研究として，事前に整備した知識ベースと比喩テンプレートを用いて比喩表現の生成を行うものがある[3]．

これに対して我々は，知識ベース構築等のコストを削減するため，Web データをもとにした，比喩説明の自動収集・及び生成を目指す．そこで本稿では，単語に対して，比喩を含む説明文を自動収集する手法について述べる．

3. 本研究における比喩

本研究において，比喩文とは，明示的に比喩となる指標“に例えると”及び“のような”を含む文のことを指す．つまり直喩である．このような比喩となる指標については，他にも複数考えられる．加えて，そのような指標が現れない隠喩も比喩文として実世界に存在する．これらすべてについて網羅することは困難であり，今後の課題として現時点では対象としない．

また，比喩と例示の区別について，本研究においてはその区別を行わず，“に例えると”，“のような”を含むもの全てを比喩文として扱う．

4. 提案手法

提案手法について述べる．以下の手順で処理を進める．

1. Web 検索による候補文章の収集
2. 説明文としての適合度計算
3. 比喩文の抽出
4. スコアリング
5. 文整形・出力

4. 1　Web 検索による文章の収集

ここでは入力単語に対して，比喩を交えた説明文を含む文章を収集する．

比喩文の発見のため，2 種類の指標“のような”および“に例え”を用意した．説明文に現れる表現“とは”を利用することで，説明文としての可能性が高いものを収集する．加えて，“とは”が含まれない説明文の収集も行うため，表 1 に示す計 4 種のクエリを用いて，Web 検索エンジン[1]より各クエリから最大 20 件ずつ，計 80 件までの検索スニペットを取得する．スニペット 1 件ずつを，出力候補となる文を含む一まとまりの文章として処理を進める．

表 1．収集に用いるクエリ

“[入力単語]とは”	“に例えると”
“[入力単語]とは”	“のような”
“[入力単語]”	“に例えると”
“[入力単語]”	“のような”

4. 2　説明文の適合度計算

4. 1 で得られた文章には，検索クエリすべてに比喩となる指標を含むため，その検索結果である文章には入力単語に対する説明として不適切なものも含まれる．そのため，それぞれの文章に対して，説明文としての適合性を設定する．ここで言う説明文とは，単語についての定義や実世界にお

[1] YahooAPI
・http://developer.yahoo.co.jp/

ける役割等を説明する文を指す．説明文としての適合性を求める際に，1 つの単語に対する複数の説明文の間では，文脈が似ると仮定を行った．ある文章からそこに含まれる文脈情報を抽出するのは容易ではない．そこで本研究では，文脈情報の一部と考えられる，文章中に含まれる動詞に着目した．動詞単体では，様々な文脈で用いられる種類の動詞から特定文章の文脈情報を表現するのは難しい．そこで動詞に係る語とその格関係を用いることにより，文脈情報を表現する．

辞書等を用いて，説明文の文脈情報の抽出元とする文章を収集することも考えられるが，単語の網羅性や辞書を用意するコストなどを考慮し，本稿では文脈情報の抽出元として“とは検索”を用いる．

クエリ“[入力単語]とは”で Web 検索を行う．得られたスニペット全てを句読点，及びスニペット中の省略記号(... など)で 1 文ずつに区切る．区切られた各文に対し，“[入力単語]とは”を含む文を収集する．収集した文すべてに CaboCha[2]を用いて係り受け解析を行う．文に含まれる動詞とその動詞に係る文節の末尾が格助詞であれば，これらを組で抽出する．収集した文すべてに対してこの処理を行い，抽出される動詞と係る文節の組の出現頻度を求める．入力単語＝“CPU”の時に抽出される動詞と文節の組，及びその出現頻度の一部の例を表 2 に示す．

表 2. 説明文脈を表現する動詞と文節例

文節	動詞	頻度
データを	受け取る	0.049
演算処理を	行う	0.024
演算結果を	通知する	0.024
プログラムを	実行する	0.024

このようにして得られた動詞・文節組とその出現頻度を用いて“説明文としての適合度”の計算を行う．1 つの文章に対して，前述した処理により得られた文節・動詞の組がその文章中に存在している場合，存在した動詞・文節組の頻度の総和を“説明文としての適合度”とする．

この方法により，**4. 1** で収集した文章すべてに対して，“説明文としての適合度”を設定する．

4. 3 比喩文の発見・抽出

文章中に現れる比喩文を抽出する．また，それがどのような比喩であるかを判定するため，比喩文から，何に例えられた比喩であるかを示す“例えの語”を抽出する．

4. 1 で収集した各文章を 1 文ずつに区切り，フレーズ「に例え」「のような」を含むものを各文章から 1 文ずつ抽出し，これを出力の候補文とする．抽出した候補文の各々に係り受け解析を行い，「例え」を含む文節に係る直近の文節の中の名詞，及び「のような」を含む文節から「のような」の直前に現れる名詞を抽出する．抽出した名詞の前に“の”で結ばれる名詞や，名詞が連続していた場合は結合して抽出する．これを文に対する“例えの語”として設定する．表 3 に処理による設定例を示す．

表 3.“例えの語”の抽出・設定例

候補文	例えの語
水に/例えますと、/池に/貯まっ…	水
電流は、/水に例えて/考えると…	水
電圧は/よく水圧/に例えられる…	水圧
…川の流れのような電気…	川の流れ

また，この時「図のような…」等，比喩とは言えないものを取り除くため，ストップワード[3]の設定を行い，抽出された“例えの語”がストップワードとして設定されていた場合，その文は出力候補から除外する．

全ての候補文から“例えの語”を抽出した後，それぞれの“例えの語”の出現回数を求める．表 3 の例にそった場合の“例えの語”の出現回数を求めた結果について，その例を表 4 に示す．

表 4.“例えの語”の出現回数の計算例

候補文	例えの語	頻度
水に例えますと、池に貯…	水	2
電流は、水に例えて考え…		
電圧はよく水圧に例えら…	水圧	1
…川の流れのような電気…	流れ	1

4. 4 スコアリング

ここでは **4. 3** で抽出された出力候補文の順位付けを行う．抽出した候補文には，各々に，“抽出元文章の説明文としての適合性”及び“例えの語とその出現回数”が結び付けられる．これらを用い，以下の式(1)により出力候補文にスコアを与える．

スコア＝例えの語の出現回数×説明文適合度　(1)

---

2 CaboCha
・http://chasen.org/~taku/software/cabocha

3 “この”，“図”，“以下”，“以上”など，計 26 語を設定している．

ここで閾値を設定し,候補文として不適切なものの削除を一度行う．閾値の設定は第一著者が実験的に行った．

30 語の入力を与え,各単語からスコア上位 5 位までの候補文を得る．得られた候補文全てを第一著者が確認したところ,適切と考えられる中で最も低いスコアが 0.4 であった．**4. 5** で述べるが,出力については再度確認を行うため,この段階では適切なものが多く残るように閾値を 0.4 と設定し,閾値未満のものを不適として候補から削除している．

4. 5 整形・出力

候補文は全て Web 上に存在するものであるため,候補文を検索エンジンにより“”を付加して検索する完全一致検索をした場合,最低でも 1 件は発見できると考えられる．また,検索エンジンの特性上,検索クエリにしたものの周辺文が検索スニペットとして現れる可能性が高い．これを利用し,候補文周辺に入力単語が含まれているかを再度確認することで,候補文が入力単語と関係の深いものであるかを判断する．

4. 4 で求めたスコアが高い順に候補文を並び替え,最上位のものを選択する．最上位の候補文を Web 検索により完全一致検索し,検索結果最上位 1 件のスニペットを取得する．取得したスニペット中に入力単語が含まれる場合,入力取得スニペットを省略記号で区切り,区切られたものの中から候補文を含む部分を文章として抽出し，これを出力とする．

以上の条件を満たさなかった場合,候補文を破棄し,次にスコアの高い候補文を選択し,同様に繰り返す．

このようにして提案手法による出力として n 件の出力を行う．システムの出力例を表 5 に示す．また,出力例における比喩が含まれる部分を太字で示した．本稿ではシステムの出力は最上位の 1 件（n=1）としている．

表 5. 提案手法の出力例

入力単語	提案手法の出力
パケット	**・パケットとは小包のような物で**「データ」をある程度「小分けにして送る」のが「パケット通信」になります。送られる「データ」の重量（単位）が「バイト」です。
アフィリエイト	**・アフィリエイトとは販売代理店のようなものです。**販売者の代わりに僕達が商品を売ってあげるのです。僕達が商品を一つ売るたび、販売者はあなたに商品の何%かの報酬を支払ってくれます。アフィリエイトをする人たちの事を、アフィリエイターと言います。
Cookie	**・Cookie とは訪問したサイトのちょっとしたメモのようなものだよ.**Cookie とは、そのサイトにいつ訪れたか、訪問回数などユーザに関する情報をコンピュータの HDD に保存する小型ファイルのこと。別にウィルスとか危険なものではないので安心してください
遺伝子	**・遺伝子とは生き物の体を作る設計図のようなものです。**人間の体はたくさんの細胞でできています。それぞれの細胞には染色体があり、その中に遺伝子は存在しています。人は両親から 1 組ずつ受け継いだ、計 2 組の遺伝子を持っています。
マグニチュード	・マグニチュードは地震の規模を、また、震度は振動（揺れ）の強さを表しますが、これでは分かりにくいので、**これを電球に例えてみますと、「マグニチュード」は、「ワット」に相当し、「震度」は「ルクス」に相当します。**
電圧	**・電圧は水圧に例えられます。**電圧が高いと電気に勢いがあるということなのですが・・・・。触ってみて、ビリビリとするのが強い方が、電圧が強いと覚えておいてください。（笑）まぁ、雷とかは、数億ボルトといわれ、空から落ちてきます。

うつ病	・エネルギーが消失したような状態で、**よくガソリン切れの車に例えられます。**うつ病の人は、とにかく心身ともに安静にし、服薬をしながら回復するまでは極力何もしないことが、一般的な治療法です

5. 予備実験

5. 1 入力単語の作成

提案手法により，比喩を含むわかりやすい説明文を出力できているかの評価を行うため，用いる入力単語，及び比較対象とする説明文の収集を行う．

IT 用語辞典 e-Words[4]から検索順位上位 200 件の単語を抽出し，システムの入力とした。このとき出力を得られたものは 139 語であった．

出力の得られた139語のうち，無作為に100語抽出し，理系大学院生 3 名，文型大学生 2 名，パート・アルバイト 3 名，高校生 1 名の計 10 名に 10 語ずつ割り振り，提案システム出力が“入力単語の説明として誤りと思うか”を五段階評価で尋ねた．これは実験を行う際に，明らかに誤りである出力を評価の対象するのは適切ではないと考えたためである．表 6 に誤りの評価値と提示した基準について示す．

表 6. 誤りの評価値とその提示基準

評価値	選択肢
5	強くそう思う
4	ややそう思う
3	どちらとも言えない
2	ややそう思わない
1	全くそう思わない

誤りの評価値が 4 以上のものは，少なくとも誤りであると判断されたと考えられる．そのため出力の誤り評価値が 3 以下の 64 語を実験に用いる入力単語として収集した．

5. 2 比較対象とする説明文の収集

次に，提案システムによる出力が“わかりやすい”ものであるかを評価するため，収集した単語に対する一般的な説明文を収集する．収集には Web 検索を用いた．

“[入力単語]とは”及び“[入力単語]”で Web 検索を行いそれぞれ最大 20 件ずつ計 40 件までのスニペットを収集する．これらスニペットに **4. 2** で述べた“説明文としての適合性”を計算する．適合性が最も高かったスニペットに対して，スニペットにおける省略記号(...等)での分割を行い，入力単語の含まれる部分を一般的な説明文として収集した．

この方法をベースライン手法とし，先ほど収集した 64 語について一般的な説明文の収集を行う．ここで収集した説明文全てを第一著者が確認したところ，うち 2 語については，比喩の指標“のような”，“に例え”が含まれ，比喩を含む説明文が収集されていたため，この 2 語を除外した．

収集した 62 語とその一般的な説明文に対して，同様に説明文として誤りであるかを尋ねた．評価の揺れを低減するため，各単語とその説明文の評価は先程と同じ評価者に依頼した．

対象とした 62 語のうち，ベースライン手法により得られた説明文について，出力の誤り評価値が 3 以下のものが 48 語存在した．この 48 語を次章で述べる実験用の入力単語とした．

6. 実験

予備実験により得られた 48 語について，システムの出力する説明文と一般的な説明文ではどちらが“わかりやすいのか”を比較する．

先の予備実験において，提案手法による出力，ベースライン手法による出力の誤りの評価を行った被験者に，予備実験により収集した 48 語のうち，それぞれが担当した単語について“わかりやすさ”の評価を依頼した．

各被験者は提案手法による出力を説明文 A，ベースライン手法による出力を説明文 B とし，入力単語と共に両説明文を同時に読む．その後，どちらの説明文が“わかりやすい”かについて 2 択で選択し，わかりやすさの程度について 2 段階の評価を行なった．この評価値に基づき，両手法の性能を比較する．被験者に提示した選択肢を表 7 に示す．

表 7. “わかりやすさ”の評価値とその選択肢

評価値	選択肢
提案手法+2	A の方がわかりやすい
提案手法+1	A の方がややわかりやすい
ベースライン+1	B の方がややわかりやすい
ベースライン+2	B の方がわかりやすい

[4] IT 用語辞典 eWords
・http://e-words.jp/

7. 結果

6 の実験の結果について，“わかりやすい”と選択された割合（表 8），それぞれの評価の分布（表 9），1 出力あたりの平均評価値（表 10）を示す．

表 8. 全入力に対して各手法が選択された割合

提案手法	ベースライン
54.2%	45.8%

表 9. 評価の分布

選択肢	割合
A の方がわかりやすい	31.3%
A の方がややわかりやすい	22.9%
B の方がややわかりやすい	27.1%
B の方がわかりやすい	18.6%

表 10. 全入力に対する各手法の平均評価値

提案手法	ベースライン
0.854	0.646

8. 考察

8.1 評価結果について

得られた被験者の評価について考察を行う．表 8 の結果から，提案手法はベースラインとの比較において“わかりやすい”文を回数の面で 8.4 ポイント多く出力していた．また，特徴として，提案手法では“わかりやすさ”の評価値が 2 のものを 12.9 ポイント多く出力していることが確認できた．これは，提案手法により収集した比喩を含む説明が，一般的な説明文章よりも内容についてイメージしやすく，解釈する上での難易度が比較的小さいことを示していると考えられる．

また，全体に対する 1 文あたりの平均評価値についても提案手法がベースラインを 0.2 ポイント程度上回った．

これらの結果から，提案手法により，“わかりやすい説明文”を収集することは有効であると考えられる．

8.2 成功例

次に，提案手法による出力が成功したものについて，その例を示しながら考察する．

表 11 に示す例では，“SMTP”について，提案手法では具体的にどのような処理が行われるかを“SMTP によるメールの転送はバケツリレーに例えられます。”という比喩を用いて説明されている．このことが評価者への好印象につながったと考えられ，比喩を含む説明文の有効性を示している．

表 12 に示す例では，“VPN”について“専用線”のようなものと表現して説明がなされている．

また，整形処理により，同様に VPN についてどのようなものかを想起することのできる比喩文と言える“離れた拠点をまるで…”の部分の抽出にも成功している．このことから，提案システムが候補として抽出する前後の文についても，入力単語の“わかりやすい”説明として有効な文が存在する可能性が示された．

表 11. 提案手法の成功例 1

入力単語	SMTP
提案手法	・**SMTP によるメールの転送はバケツリレーに例えられます。** SMTP サーバは、とりえあえず受け取ったメールを最適と思われる次の SMTP サーバに送ります。メールを受け取った SMTP サーバは自分宛でなければさらに次の SMTP サーバに送ります。
ベースライン	・SMTP とは？SMTP はメールサーバにメールを送信するためのプロトコルです。SMTP には 2 つの側面があります。一つは、一般のユーザが電子メールアプリケーションを利用してメールサーバにメールデータを送信するという使われ方です。

表 12. 提案手法の成功例 2

入力単語	VPN
提案手法	・その為、**VPN は、安価に専用線のような利用ができるため、**広く普及しています。専用線を VPN に切り替えているケースも珍しくありません。VPN を使用すると、離れた拠点をまるで、LAN と LAN を接続したイメージで利用することができます。
ベースライン	・VPN とは何か. VPN は一般に、「仮想プライベートネットワーク」あるいは「仮想閉域網」と訳される。

8.3 失敗例

提案手法による出力が失敗した，つまりベースライン手法の方が“わかりやすい”とされたものについて，例を示しながら考察する．

表 13. 提案手法の失敗例 1

入力単語	ルータ
提案手法	**・インターネットを接続する際に使用する弁当箱のような形の機械です。**パソコンとネットワークの中継機器で、LAN 接続で構成されており、外部及び内部ネットワークを安全かつ簡単にしている。
ベースライン	・ルータとは、複数のパソコンをネットにつなげて使うために用いるパソコン周辺機器です。

表 14. 提案手法の失敗例 2

入力単語	デバッグ
提案手法	**・小さくて嫌な邪魔者ということで「虫」に例えたのでしょう。その「虫」を取り除く作業を「デバッグ」といいます**「de-」は「取り除く」といった意味を付加する接頭語です。言い換えると『動かないカラクリの不具合を取り除き（治し）ますか？』と聞いているわけです。
ベースライン	・デバッグとは、プログラムに含まれたミスや不具合などを探し出し、修正する作業のこと。プログラムを正常に動作させるためにはデバッグを行い、そこに含まれた誤りを取り除かなくてはならない。

表 13 に示す失敗例は，入力単語“ルータ”を説明する上でその形に関する比喩，“弁当箱のような形の機械”が含まれるが，“ルータ”の役割の面について理解を促せる比喩ではなく，評価者のイメージ・直観へ理解を促すように働きかけられなかった場合である．このような問題に対しての解決は困難であるが，他研究[4]でなされている説明の“観点”を候補文に対して設定する等が考えられる．具体的には，ユーザにどのような面からの説明が欲しいかをシステムが問いかけ，“例えの語”について概念辞書などにより分類を行い，ユーザの要求に答えられるものを優先的に選択するといった方法である．

表 14 に示す失敗例では，提案手法における出力中には何が「虫」に例えられているのかという情報が不足している．この情報不足が“わかりやすさ”を妨げたと考えられる．このような場合に対しては，最終的な出力を抽出する段階において，その抽出範囲の見直しを行うことで改善できるものと考えられる．

9. まとめ

本稿では，ユーザにとっての“わかりやすさ”を考慮し，ある単語に対し比喩を含む説明文の自動収集手法の提案を行った．また，自動収集した一般的な説明文と“わかりやすさ”に関して比較を行った．人手による評価結果から，提案手法の有効性が確認された．

本稿では，提案システムにおいて，優先順位付けた出力候補の最上位のもののみを提案手法における出力として扱ったが，2 位以下となるものにも出力として良質なものが少なくはない．第一著者が今回実験に用いた 48 語について，2 位から 5 位までに説明として適当かつわかりやすいと考えられる出力が存在するかを確認したところ，15 語の単語についてそのような出力が存在した．これらを適切に用いることが課題として挙げられる．この利用方法について，**8.2** で述べたが，ユーザの要求にあった観点からの出力などがあげられる．

また，提案手法の限界ではあるが，Web 上に存在しない説明文に対しては対応できない．このような場合についても今後検討を行う必要がある．

参考文献

[1]Jill L. Quilici, Richard E. Mayer : “Role of examples in how students learn to categorize statistics word problems.” Journal of Educational Psychology Volume 88, Issue 1, pp144-161, March 1996.

[2]田辺敏明：“心理学概念の保持に対する比喩的説明文の特性の効果“教育心理学研究 38(2), pp166-173, 1990.

[3]石田 修一, 蔵方 隆宏, 森 辰則：“知的マニュアルシステムにおける比喩説明文の生成”, 情報処理学会研究報告. 自然言語処理研究会 6(7), pp1-6, 1996.

[4]藤井 敦, 三條場 旭彦：“説明の観点に基づくテキストの分類と要約” 情報処理学会研究報告. 自然言語処理研究会報告 2008(113), pp1-8, 2008.