闘病ブログを対象とした薬剤服用情報抽出手法の医療対象用語辞書を用いた改善

Improvement of Drug Effects Extraction System from Patient's Blogs Using Collection of Clinical Terms

○北嶋　志保，ジェプカ・ラファウ，荒木　健治
○Shiho Kitajima, Rafal Rzepka, Kenji Araki
北海道大学情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

1．はじめに

ネットワークの普及に伴い，個人がウェブ上に情報を発信することが容易になった．日本では個人が匿名で情報を発信することが多いため，体裁を気にすることなく，身近な人には知られたくないような情報も発信できる．そのためウェブからは，率直な意見や感想，悩みといった情報が入手可能である．患者やその家族によって闘病の様子が書かれた闘病ブログや掲示板も多数存在しており，患者にとっては一つの貴重な情報源となっている．しかしウェブ上に散在しているブログの中から，自分に必要な情報だけを取捨選択し集めることは多大な労力が必要となる．

そこで，闘病者によって書かれたブログ記事から医療に関わる情報を抽出・整理することにより，患者の情報入手の手助けとなるようなシステムの構築を目指す．このようなシステムにより，患者は同じ病気をもつ，自分と近い境遇である人の発信した有用な情報を容易に入手でき，病気との向き合い方や治療方針などの決定に役立てることができると考えられる．また，ブログ記事には専門書などには記載されていない新しい情報が含まれる可能性があり，薬や治療効果の把握を支援することができると考えられる．

ブログから取得する医療情報として，まず薬剤情報に着目した．薬剤の服用や使用により引き起こされる結果について，「悪い」「効く」のように一単語で極性をもつ情報ではなく，「痛みがなくなる」「髪がなくなる」のような，対象とセットになることで極性をもち，意味が増す情報の抽出を行いたいと考えている．そのため，本稿では，薬剤の服用による効果や変化に関してブログに記述された情報を（薬剤名，対象，評価）で表される三つ組として抽出する手法の提案を行う．

2．関連研究

近年，自然言語処理技術を中心とした情報技術の医学的応用研究が進められている[1]．大熊らは退院時サマリーから副作用について記述されている箇所を特定するシステムの開発を行なった[2]．彼らのように，副作用の関係抽出には機械学習器であるSVM[3]が用いられることが多い．しかし，SVMによる精度は学習データに依存するため十分な精度が挙げられていない．そこで，篠原らはSVMを用いず構文パターンを用いた薬剤副作用情報の抽出手法の提案を行なった[4]．医療従事者によって書かれた電子カルテと患者によって書かれたブログとでは医学的な専門用語の出現頻度や表現方法が異なる．さらにブログはくだけた話し言葉で書かれていることが多いため，電子カルテに用いた抽出方法をブログに適用することは困難である．

また，ある対象についての意見や評判を三つ組で抽出する研究も行われている．杉木らは，自然言語で記述された検索クエリに該当する商品を，商品レビューテキストとクエリを意見対象・項目・値の三つ組へと変換することで検索できるシステムを作成した[5]．土田らはブログから対象・属性・評価で表される評判情報を，確信度を付与してランキングする手法を提案した[6]．土田らの手法では，評価表現辞書に含まれる表現とセットになる属性単語をSVMにより抽出し，単語間距離により対象と属性を対応付ける．

商品や場所についての評価を抽出する研究では，評価の対象が明らかであり，使われる評価表現も限られているため，辞書を用いた抽出が可能である．我々が対象とするブログは，薬剤評価のためだけに書かれたものではなく，日々の記録から評価部分をいかに抽出するかが課題となる．また，薬剤について記述する際評価表現として，商品レビューなどで用いられるものだけではなく，擬態語も多く使われる．擬態語などを含む，口語での評価表現辞書は存在しない．このため，多彩な擬態語を網羅した，医療用の評価表現辞書を作成するには多大な労力が必要となる．

3．提案手法

我々は（薬剤名，対象，変化）の三つ組で表される薬剤の服用情報を，手がかり語を用いて抽出する手法を提案する．ここで，対象とは薬剤名の服用もしくは使用により変化・効果が引き起こされた部位や性質，評価とは効果・変化のさまを示す表現や態度を示している．

闘病体験情報を共有するサイトであるTOBYO[1]で検索エンジンとして公開されているTOBYO辞典を用いる．薬剤名で検索し，その結果得られたブログの要約文であるスニペットを抽出対象とする．

[1] http://www.tobyo.jp/

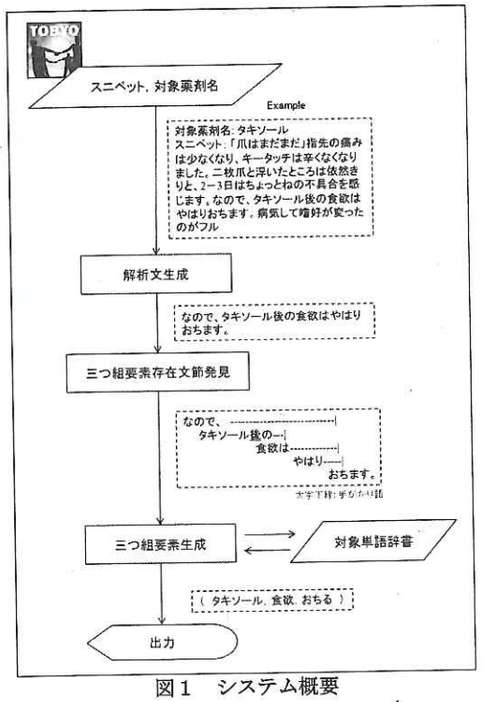


図１　システム概要

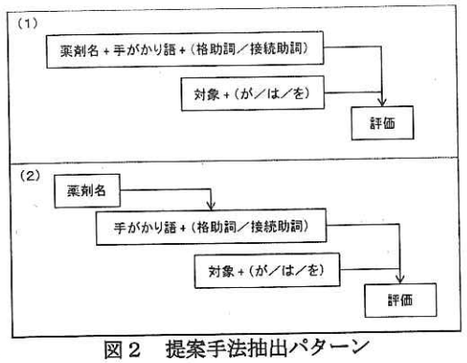


図２　提案手法抽出パターン

TOBYO には闘病 Blog が約 4 万サイト登録されており，あらかじめ筆者が入力した性別，疾患名などがタグ付けされている．今後の研究では，より患者に合わせた情報提供を行うため，タグ付けされた情報も用いる予定である．

システムの概要を図 1 に示し，以下で説明する．

3.1.　手がかり語

1 文中に三つ組で表される服用情報を含む文 181 文のうち 138 文（76.2%）が，薬剤名のあとに特定の服用・使用表現を用いた後，部位や効果を述べていることが予備調査により確認された[7]．これらの服用・使用表現を人手で収集し，32 単語の名詞，動詞（原形）を手がかり語とする．

3.2.　解析文生成

薬剤名をクエリとし，TOBYO 辞典を用いて取得されたスニペットを，句点を区切り文字として文単位に区切る．1 文中に検索に用いた薬剤名（以後「対象薬剤名」と呼ぶ）を含む文に対し，服用情報を抽出する．単語情報の参照先である IPA 辞書に存在しない薬剤名が誤って分割され，構文解析ミスにつながることを防ぐため，解析を行う際には薬剤名を 1 単語の固有名詞に置き換える処理を行う．また，構文解析ミスを防ぐために，対象薬剤名を含まない括弧を削除する．対象薬剤名が含まれていなくても，括弧中に重要な情報が存在する可能性があるため，削除しても差し支えない括弧かどうかの判定をしたのち削除することは今後の課題である．

3.3.　三つ組要素存在文節発見

図 2 に示す手がかり語を用いた係り受けパターンにより，三つ組の要素が存在する文節の位置を特定する．図中の長方形は文節を，矢印は係り受け関係を示しており，いずれも CaboCha[2]による解析の結果得られたものである．各文節末尾に付属する助詞を，以下の理由から条件付けした．予備調査[7]により，対象要素存在文節と評価要素存在文節をつなぐ際，助詞「が」「は」「を」が用いられる割合が高い．格助詞は動作・状態の継続や経過に関する意味を持ち，接続助詞は原因・動機などの意味を持つ．

3.4.　三つ組要素生成

三つ組要素が存在すると判定された文節に対し，助詞が出現するまでの単語をつなげて要素とする．三つ組要素存在文節が連体化の助詞「の」によって修飾されている場合は，その文節を修飾節として付与する．文節中に打ち消しの意味を持つ「ない」が奇数個存在したときには，必要に応じて要素の最後尾形態素の活用を変化させ，「ない」を付加し否定形にする．なお，今回は「〜ません」や「減量」といった手がかり語による意味の反転は考慮しておらず，今後の課題とする．

3.5.　対象要素に対するフィルタリング

薬剤の服用について記述する際，評価表現は多様だが，変化や効果が現れる対象はある程度限定されていると考えた．そのため，既存の薬剤に関する効果や副作用が書かれた文書から，対象単語として用いられる可能性がある部位や状態を示す単語を収集し，辞書を作成した．単語の収集方法は，「 接頭詞 ＋ 名詞 」を基本とし，接頭詞はなくてもかまわない．また，連続する名詞はつなげて登録する．数字が含まれていた場合は登録しない（例：1 時間）．一般向けに優しい表現で書かれた「お薬 110 番[3]」から作成した辞書と，薬剤添付文書[4]から作成した専門用語を多く含む辞書，ふたつを用いて対象要素が適当か判断する．抽出された対象要素を MeCab[5]により形態素解析し，構成要素のうち「 接頭詞（なくても可）＋ 名詞（連続する場合は結合する）」が辞書に含まれている場合に服用情報の三つ組要素として適当であると判断し，出力する．

[2] http://chasen.org/ taku/software/cabocha
[3] http://www.jah.ne.jp/~kako/
[4] http://www.info.pmda.go.jp/index.html
[5] http://mecab.sourceforge.net/

表１　お薬 110 番 辞書単語例

血液中	場合	医師	しびれ
カリウム	不整脈	便秘	不安感
お薬	危険	けいれん	症状
腎不全	腸内	別	持病
とき	カリウム分	薬	アレルギー
作用腎臓	吸着	性質	人
働き	便	胃腸	多発性骨髄腫
十分	排出	病気	慎重
排泄	吸収	ちの人	高齢
結果	高カリウム血症	相談	カリウム値
息切れ	治療	血中カルシウム濃度	低下
手足	便秘がち	副甲状腺機能高進症	副作用

表２　薬剤添付文書 辞書単語例

治癒切除不能	副作用	殿部痛等	口周囲
進行	ショック	筋骨格硬直	あれ
再発	アナフィラキシー様症状	筋力低下	鼻乾燥
結腸	infusion reaction	側腹部痛	異常
直腸癌	蕁麻疹	しゃっくり	場合
扁平上皮癌	呼吸困難	発声障害	投与
切除不能	口唇浮腫	咽頭喉頭痛	消化管瘻
嗄声	咽頭浮腫等	鼻	腸管皮膚瘻
気管支喘息	こと	咳嗽	腸管瘻
手足	観察	気管支炎	消化管出血
しびれ	十分	鼻炎	吐血
口内	行い	低酸素症	下血

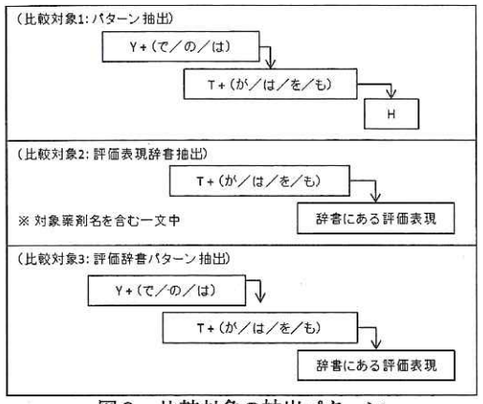


図３　比較対象の抽出パターン

3.5.1.　お薬 110 番辞書

お薬 110 番とは薬専門のサーチエンジンである．患者やその家族向けに，専門的な言葉ではなく優しい表現を用いて書かれているのが特徴である．取得できた 1143 ページの薬剤情報のうち，用法についての記載個所を除く概要，効果，副作用などについての記載情報から辞書を作成する．辞書には 12170 単語が登録された．その一部を表 1 に示す．

3.5.2.　薬剤添付文書辞書

医薬品医療機器総合機構が運営する医薬品医療機器情報提供ホームページから，医療用医薬品と一般用医薬品の添付文書情報を利用する．薬剤添付文書には，医学用語が多く用いられているのが特徴である．TOBYO 辞典を検索する際クエリとして用いた 296 種の薬剤名について添付文書情報を取得し，薬効と副作用についての記述箇所から辞書を作成する．辞書には 5380 単語が登録された．その一部を表 2 に示す．

4．評価実験

図 3 に示す 3 つの抽出手法を比較対象とした．比較対象2,3では意見抽出に用いられることが多い評価表現辞書EVALDIC_ver1.0.1[8]を使用する．さらに対象要素に対するフィルタリングの効果を測定するため，それぞれの対象についてお薬110番辞書，薬剤添付文書辞書を用いたフィルタリングを行う．

評価には以下の式(1)~(3)を用いる．

$$\text{適合率} = \frac{\text{正解抽出三つ組数} \times 100}{\text{抽出三つ組数}} \ [\%] \quad (1)$$

$$\text{再現率} = \frac{\text{正解抽出三つ組数} \times 100}{\text{正解データ数}} \ [\%] \quad (2)$$

$$\text{F値} = \frac{2 \times \text{精度} \times \text{再現率}}{\text{精度} + \text{再現率}} \quad (3)$$

4.1.　正解データ

4.1.1.　アノテーション方法

北海道大学 20 代前半の学生 5 名がアノテーションしたデータを元に，正解データを作成する．評価者の内訳は，理系大学院生 2 名，理系学部生 3 名，男性 3 名，女性 2 名であった．新たに取得したスニペットを句点で区切り，文章中に薬剤名を含む 2000 文に対し，（薬剤・対象・効果）で表される服用情報が含まれると判断される箇所について，各タグを形態素ごとに付与する．ある程度の抽出揺れを容認し 2 人以上一致していた 258 の三つ組を正解データとする．

4.1.2.　アノテーション結果に関する考察

5 人のアノテーションデータについて κ 値を求めたところ，0.41 と低い値であった．完全一致が少ない原因を分析するため，システムの目的を最も理解している第一著者が，2000 文のうち 200 文に対し服用情報のタグ付けを行い，比較した．その結果，第一著者が抽出した三つ組数は，評価者 5 人の平均 17 に対して 32 であった．「最近ステロイドの影響で，血糖値が少々高めです」について（ステロイド，血糖値，高め）と（ステロイド，血糖値，少々高め）を同等と見なすなど，抽出範囲の揺れが完全一致率を下げる大きな要因であった．筆者が誤った表現を用いていること（例．「ある程度はまし」を「程度はまし」と表記）も評価者を混乱させる原因であった．この揺れを容認し，一致しているとした場合，評価者 5 人が抽出した三つ組の異なり総数は 53 であった．アノテーションの揺れが大きかった「今回の数値はプレドニンを飲み始めて風邪をひいた時を除けば最低数値である」について，「プレドニンを飲み始めて風邪をひいた」「プレドニンを飲み始めて最低数値である」のどちらが筆者の意図する意味かどうか

を判定することは，人手でも困難な事例である．

また，「熱が上がったら病院なのでボルタレンなど適切な処置をしてくれることでしょう」という文に対し，(ボルタレン，熱，上げる）とタグ付けした評価者もいたが，上がった熱を下げる働きをもつのがボルタレンである．この文章から「ボルタレンは熱を下げる薬である」という情報を抽出するためには，表層的な情報だけではなく一般常識を用いた推論が必要となるため，システムが判定することは難しい．

第一著者との一致率を計算した結果を表３に示す．第一著者とのある程度の抽出ゆれを認めた一致が最も高い，２人以上一致の三つ組を正解とし，データを作成した．第一著者と評価者とのアノテーション結果に差が出た大きな原因は，説明不足であった．「プレドニンを一年で切ったので，ムーンフェイスになりませんでした」という文に対し，(プレドニン，ムーンフェイス，なりませんでした）とタグ付けした評価者は一人もいなかった．

我々が目指すシステムは，現れていない効果も「現れないことが現れた効果」として意味がある情報であり抽出すべきだと考えているため，(ステロイド，ムーンフェイス，なりませんでした）という情報も正解データとしてタグ付けされるべきである．今後は事前に評価者に対し，システムの目的についてより深く理解してもらい，アノテーションの訓練をするなど，目指すシステムの正解としてふさわしいデータを作成する必要がある．

4.2. 評価実験結果

評価結果を表４示し，各出力例を表５に示す．本稿で提案した手がかり語を用いた抽出が，闘病ブログに対して有効であることが確認された．また，対象単語辞書による適合率の向上が確認された．

4.3. 考察

再現率が低い原因としては，手がかり語存在文節末尾の助詞の限定付け，対象要素存在文節の助詞の限定付けによる抽出の制限が大きい．適合率を上げるためには助詞の条件付けが有効である．しかし，話し言葉で書かれており助詞の抜け落ちが多いブログ記事に対して抽出を行うためには，助詞に依存しない，もしくは助詞を補完した後抽出するなど新たな方法を考える必要がある．

また，登録されていない手がかり語が用いられた場合提案手法では抽出することができないため，今後手がかり語を増やし様々な文に対応可能にする必要がある．手がかり語が存在しない文に対しては他の手法を用いるなど，他手法と組み合わせた抽出が効果的であると考えている．

さらに，構文解析を正確に行うため，「ギャバロンというお薬を飲んで」が「ギャバロンを飲んで」と同義だとシステムに学習させることや，薬剤の併用に関する記述に対し並列関係を考慮する必要がある．スニペットを利用したために句点区切りでは正しい一文に分割できず，情報として不十分な場合や，構文解析ミスを引き起こす原因となる場合があるので，機械学習による適切な分割点の判定やブログ記事全文を対象とすることが必要だと考えられる．

表３　200 文アノテーション結果

	抽出三つ組数	第一著者との比較		
		一致三つ組数	適合率 [%]	再現率 [%]
3人以上一致	12	12	100.00	37.50
2人以上一致	22	20	0.91	0.63
1人以上	53	30	0.57	0.94

表４　評価結果

	抽出数	正解数	適合率[%]	再現率[%]	F値
提案システム	38	14	36.84	5.43	**9.46**
パターン抽出	143	1	0.70	0.39	0.50
評価表現辞書抽出	662	38	5.74	14.73	8.26
評価辞書パターン抽出	35	1	2.86	0.39	0.68
おくすり110番フィルタ					
提案システム	29	13	44.83	5.04	**9.06**
パターン抽出	110	1	0.91	0.39	0.54
評価表現辞書抽出	379	33	8.71	12.79	**10.36**
評価辞書パターン抽出	28	1	3.57	0.39	0.70
薬剤添付文書フィルタ					
提案システム	19	9	**47.37**	3.49	6.50
パターン抽出	49	0	0.00	0.00	
評価表現辞書抽出	166	24	14.46	9.30	11.32
評価辞書パターン抽出	11	0	0.00	0.00	

フィルタリングなしの出力では，対象要素として日時や期間が抽出されている誤り例が存在したが，フィルタリングによりそれらの誤りを除くことができた．抽出三つ組の対象要素に対し，対象用語辞書を用いたフィルタリングが効果的であることが確認された．辞書作成の対象としたページ数の違いもあるが，薬剤添付文書から作成した辞書では，話し言葉で書かれたブログの表現に対応しきれず，フィルタとして厳しすぎる可能性がある．辞書への登録の際，単語の意味まで考慮していないため「こと」「の」といったノイズが，辞書には含まれている．より辞書を有効活用し適合率を向上させるためには，辞書のデータクリーニングが必要である．

どの手法においても再現率の低さが課題であるが，商品の評判などとは違い医療情報を対象としているため，正確な情報を取得することがより重要であると考えている．

5. まとめと今後の課題

闘病ブログのスニペットに対し，(薬剤名・対象・効果）で表される薬剤服用情報を，手がかり語を用いて抽出する手法の提案を行った．また，薬剤に関する既存の文書から対象単語辞書を作成し，フィルタリングに用いる事で適合率を向上させた．提案手法の適合率 47.4%，再現率 3.5%と，決して高い結果ではなかったが，既存手法に比べ最高 36.1 ポイント高い適合率での抽出が可能であった．本稿の実験結果から，闘病ブログから医療情報を抽出するために解決すべき多くの課題を把握することができた．

今後は，手がかり語が未登録である場合や存在しない文についても抽出を行うため，手がかり語を増やすこと，他手法と組み合わせた抽出が必要である．

アノテーションの課題でもあったが，服用情報を要素として抽出するには個人差が大きいことが確認された．要素の抽出では情報量が不十分な場合もあるため，今後は服用情報をフレーズで抽出することも考えている．スニペットを対象としたために，文が適当につなげられ構文解析ミスを引き起こす原因となっている場合があったため，スニペットではなくブログ記事全文を抽出対象とすることを考えている．抽出が高精度で行えた後は，抽出した情報に対しそれが伝聞情報なのか体験情報なのか，事実なのか仮定なのかを判定する予定である．

参考文献

[1] Carolin Kaiser and Freimut Bodendorf, "Mining Patient Experiences on Web 2.0 - A Case Study in the Pharmaceutical Industry.", SRII Global Conference 2012, pp.139-145, 2012.

[2] Eiji Aramaki, Yasuhide Miura, Masatsugu Tonoike, Tomoko Ohkuma, Hiroshi Mashuichi, Kayo Waki, and Kazuhiko Ohe: "*Extraction of Adverse Drug Effects from Clinical Records*", Stud Health Technol Inform. 2010 , pp.739-743, 2010.

[3] Vladimir Vapnik, "*Statistical Learning Theory*", Wiley Interscience, 1998.

[4] 篠原恵美子，服部圭悟，三浦康秀，外池昌嗣，大熊智子，増市博，荒牧英治，大江和彦，"構文パターンに基づく薬剤副作用情報の自動抽出と評価"，医療情報学 31(Suppl.)，pp.521-524, 2011.

[5] Kenji Sugiki and Shigeki Matsubara, "*A product retrieval system robust to subjective queries*", International Journal of Product Lifecycle Management 3(2-3), pp.151-164, 2008.

[6] Masaaki Tsuchida, Hironori Mizuguchi, and Dai Kusui, "*Ranking Method of Object-Attribute-Evaluation Three-Tuples for Opinion Retrieval*", New Frontiers in Artificial Intelligence, JSAI 2008 Conference and Workshops, vol. 5447, pp.87-98, 2009.

[7] 北嶋志保，ジェプカ・ラファウ，荒木健治，"闘病ブログを対象とした手がかり語を用いた薬剤服用情報の抽出手法"，第 28 回ファジィシステムシンポジウム講演論文集 pp.251-256, 2012

[8] 小林のぞみ，乾健太郎，松本裕治，立石健二，福島俊一，"意見抽出のための評価表現の収集自然言語処理"，Vol.12, No.3, pp.203-222, 2005.

表５　各システムの出力例とその判定結果

	入力文	抽出三つ組	フィルタによる対象要素に対する判定		評価結果
			お薬110番	薬剤添付文書	
提案手法	マイスリーを飲むと強い倦怠感が出るので、昨日は飲まずに就寝しました	マイスリー，倦怠感，出る	正	正	正
	たしかにタキソテールの副作用で体全体が浮腫んでいたので、腕は両方とも腫れて重くて痛いな～とはもっと前から思ってたんだけど、これもタキソテールの副作用だと思ってた	タキソテール，体全体，浮腫む	正	誤	正
	朝、プレドニンを飲んで時間がたつとよくなりますが	プレドニン，時間，たつ	誤	誤	誤
パターン抽出	うちの病院では、薬を使った採卵後と次の周期は卵巣を休ませるためピルを飲来事で何も聞けず･･･orzそういや前回の採卵後も･･･プラノバールの効き目が悪くて14日目で中止されました	プラノバール，効き目，悪い	正	誤	正
	今、私はヒスロンの治療を終えて約5ヶ月ほど経ってますが、ヒスロン治療のこ	ヒスロン，治療，終える	誤	正	誤
評価表現辞書抽出	Unknown2007-10-2122:48:19急性ではなく慢性膵炎には漢方薬も有効的と最近は良く言われてます	漢方，慢性膵炎，有効的	正	正	正
	あの、ダルさと吐き気は一体何だったんだろう･･･?リセット5日目からクロミッド飲み始めまして･･･初☆クロミッド!!これにてすくすく良	クロミッド，吐き気，良	正	正	誤
評価辞書パターン抽出	もしかしてプレドニンの副作用???最近体重は変わってないというか以前より減って	プレドニン，副作用???最近体重，変わってない	正	誤	正
	エンブレルの関与は不明ですが、多発性硬化症、視神経の炎症といった	エンブレル，関与，不明	正	誤	誤