単語間類似度を用いた物語ユーモア認識手法の性能評価

Performance Evaluation of Recognition Method of Narrative Humor Using Words Similarity

天谷　祐介　Yusuke Amaya
ジェプカ　ラファウ　Rafal Rzepka
荒木　健治　Kenji Araki

北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

{hv_amaya, kabura, araki}@media.eng.hokudai.ac.jp

1．はじめに

1.1　研究背景

ユーモアは，相手を笑わせようと意図した行動である．対人コミュニケーションにおいて，ユーモアによって引き起こされる笑いにより，敵対心や緊張感を緩和し，親密さや円滑な人間関係を構築する効果が期待できる．

近年，コンピュータでも人間と対話できるシステムが社会に広まりつつある．具体的な例としては，研究段階のものとして，Web 検索と単語 n-gram を用いた対話システム Maru[1]が挙げられる．商用では発話認識・応答インターフェースとして Siri*1が挙げられる．しかし，いずれのシステムも人間が発するすべてのユーモアを自動で認識し，適切な反応を返すことができない．そのため，コンピュータは人間と同等のコミュニケーションを行うことが困難であり，ユーモアを認識することができるシステムが求められる．

近年，ユーモアの生成を自動で行うシステムの研究が広く行われている．日本語を対象としたものでは，なぞなぞの答えを駄洒落として生成するもの[2]，ことわざの文末を変更して意外性による笑いを狙ったもの[3]がある．他にも，対話システムに駄洒落生成システムを組み合わせたもの[4]がある．しかし，ユーモアの自動認識に関する研究は，生成に関する研究と比較して少ない．英語では，One-liner というジョークを対象とした研究がある[5][6]．日本語では，複数の機械学習を用いることにより，物語性のあるテキストをユーモアかノンユーモアかに分類するものがある[7]．この手法は，入力テキストを 2 種類の分類器でそれぞれユーモアかノンユーモアかに分類し，分類結果によって多数決を行うものである．しかし，多数決の結果が同数票で割れた場合の分類性能に改善の余地がある．

そこで，本稿では性能改善を目指し，従来の日本語ユーモアの認識手法をベースに，コンピュータの計算速度の速さを活かして，話の「落ち」を検出することによるユーモアの自動認識手法を提案する．具体的には，入力テキスト中の最後の文と 1 つ前の文の間の意味的類似度を計算し，入力テキストの他の 2 文間の類似度と比較を行う．「落ち」は意外性を持つため，最後の文と 1 つ前の文の間の意味的類似度の値が他と比較して小さければユーモア，大きければノンユーモアとして分類する．意味的類似度の計算には，2 文間に含まれる単語のペアの，既存の概念辞書上での距離を用いる．

以降本稿では，提案手法のアルゴリズムに関する詳細と，性能評価実験の結果および考察について述べる．

1.2　対象とするユーモア

本稿で対象とするユーモアは，話者自身や関係者の体験や知識に基づく，物語性のあるユーモアである．本稿では以降これを「物語ユーモア」として論じていく．物語ユーモアの具体例を図 1*2に示す．

図 1 では，前半に「母」が自分の結婚記念日に送られてきたお祝いのファクスへの喜びが表されている．後半に，ファクスのロール紙が少なくなったことを表す赤いラインを，「母」が勘違いして感心す

*1 Siri: http://www.apple.com/jp/ios/siri/

*2 いわせてもらお:
http://home.att.ne.jp/green/ma22/iwasetemorao.htm

る落ちがある，という構成になっている．

> ファクスを買って間もない母から、うれしそうな声で電話がきた。「結婚記念日のお祝いファクス、ありがとうね。紙の両端に赤いラインまで書いてくれて。赤色も出るんだねえ」

図 1　物語ユーモアの具体例（その 1）

2．提案手法

2.1　処理の流れ

物語ユーモアを認識するための手法として，従来手法をベースに提案手法を加えたシステムを用いる．

従来手法では，ユーモアの認識に教師あり学習である Naïve Bayes (NB)[8] と Support Vector Machine (SVM)[9]を用いている．各分類器を用いて入力テキストがユーモアかノンユーモアかの分類を行い，両分類器の結果が一致した場合と不一致だった場合で分岐を行う．結果が一致した場合，テキストを両分類器が分類した結果へと分類する．結果が不一致だった場合，NB においてテキストを分類する際に用いる事後確率を参照する．事後確率とは，入力テキストがユーモアになる確率，あるいはノンユーモアになる確率である．NB では入力に対してユーモアとノンユーモア両方の事後確率を計算し，より確率の高いクラスへと分類する．従来手法では，両分類器の結果が不一致だった場合に，ユーモアの事後確率の値が 0.001 以上であればテキストをユーモアとして分類した．しかし，両分類器で結果が一致した場合の分類精度は 85%を越えるのに対し，結果が不一致だった場合の分類精度は 55%程度であった．

そこで本稿では，NB のユーモアの事後確率を参照する従来手法の部分を，提案手法と置き換える．提案手法と従来手法を併せたシステム全体の処理の流れを図 2 に示す．

提案手法は，入力テキストの最後の文と 1 つ前の文の間の意味的類似度を入力テキストの他の部分の意味的類似度を比較することによってユーモアかノンユーモアかの分類を行う．提案手法の処理の流れを図 3 に示す．

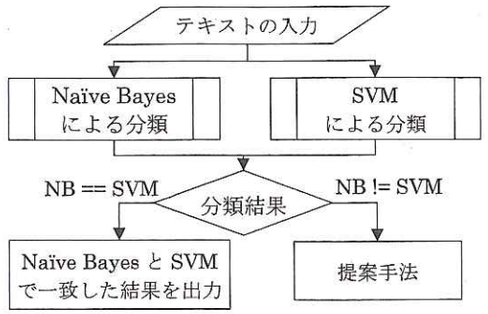


図 2　システム全体の流れ

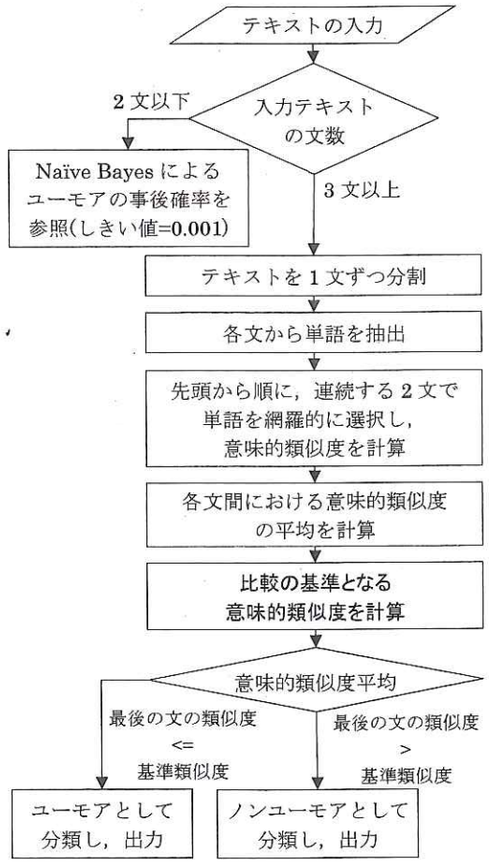


図 3　提案手法の流れ

処理の流れについて述べる．まず入力テキストの文数を数え，3 文以上で構成されているテキストのみを選択する．2 文以下で構成されたテキストは従来手法である NB のユーモアの事後確率によって分類される．これは，2 文以下のテキストには，最後の文と 1 つ前の文の間の意味的類似度と比較する対象が存在しないためである．

次に，入力テキストを 1 文ごとに分割する．分割は，句点や鍵括弧といった，文末となり得る記号を終端文字として自動で行った．その後，各文に形態素解析を行い，単語を抽出する．抽出する単語は，**2.3** で述べる概念辞書である日本語 WordNet*[3]に含まれる名詞，動詞，形容詞，副詞とした．本システムでは，形態素解析には MeCab*[4]を用いた．

続いて，2 文間の意味的類似度を計算する．意味的類似度とは，値が大きくなるほど意味的に近似していることを示す指標である．入力テキスト中の連続する 2 文を選択する．そして，各文中から単語を 1 つずつ選択し，日本語 WordNet を用いて 2 単語間の類似度を計算する．日本語 WordNet を用いた単語間類似度の計算手法は **2.3** で詳述する．2 文間のすべての単語の組み合わせで単語間の意味的類似度を計算する． そして，2 文間のすべての単語の意味的類似度の平均を得る．平均値が 2 文間の意味的類似度である．以上の手順を連続する 2 文のすべての組み合わせで行う．

続いて，最後の文と 1 つ前の文の間の意味的類似度と比較するための基準値を設定する．本稿では，基準値を 2 種類用意した．1 つ目は，最後の文と 1 つ前の文の間の類似度を除いた，他すべての意味的類似度を平均したものである．2 つ目は，最後の文と 1 つ前の文の間の類似度を除いた，他すべての意味的類似度中の最小値である．

最後に，設定した基準値と，最後の文と 1 つ前の文の間の類似度を比較する．最後の文と 1 つ前の文の間の類似度が基準値未満だった場合，それまでの文間の意味的類似度より類似度が低く，意味的な相違が大きいことから入力文をユーモアとして分類する．基準値以上だった場合，ノンユーモアとして分類する．

2.2　日本語 WordNet

WordNet*[5]とは，プリンストン大学で開発された Prinston WordNet を指す．これは，英単語に synset という概念を割り当てた意味辞書である．語を synset という類義語の集合でまとめてあり，1 つの synset が 1 つの概念に対応している．各 synset は上位下位関係等の多様な関係で結ばれている．今回は，Prinston WordNet の synset に対応した日本語が付与された日本語 WordNet を使用した．日本語 WordNet には 57,238 の synset，93,834 語，および synset と単語の 158,058 のペアが収録されている．日本語 WordNet に収録されている単語と関係の例を表 1，表 2 に表す．

表 1　WordNet に登録されている単語の例「犬」

犬					
synset	synset に定義されている他の単語				
10641755-n	飼い犬	ドッグ	洋犬	飼犬	イヌ
02084071-n	間諜	廻し者	工作員	スパイ	諜報員

表 2　WordNet に登録されている関係の例「犬」

犬					
上位概念	動物	家畜	イヌ科動物	生物	密偵
下位概念	仔犬	パグ	プードル	猟犬	小型犬
構成要素	イヌ属	群	群れ	軍隊	軍勢

2.3　単語間の意味的類似度の計算手法

単語間の意味的類似度を計算する手法として，WordNet を利用した手法が広く用いられている．その中でも使用頻度が高いと考えられる以下の 6 つを用いる．

- Path
- Leacock & Chodorow
- Wu & Palmer
- Resnik
- Lin
- Jiang & Conrath

Path は，*length*を，2 つの synset 間を繋ぐ最短パスの上にあるエッジの数とすると，式(1)のように

*3 日本語 WordNet: http://nlpwww.nict.go.jp/wn-ja/
*4 MeCab: http://mecab.googlecode.com/svn/trunk/mecab/doc/index.html?source=navbar
*5 WordNet: http://wordnet.princeton.edu/

表せる．

$$Sim_{Path} = \frac{1}{1 + length} \quad (1)$$

Leacock & Chodorow[10]は，Dを‘is-a’階層上における深さの最大値とすると，式(2)のように表せる．

$$Sim_{lch} = -\log\frac{length}{2 * D} \quad (2)$$

Wu & Palmer[11]は，知識構造上の深さおよび，共有する最上の上位概念を利用する類似度計算手法である．$depth(concept_x)$を概念$concept_x$の深さとし，最小共通上位概念(LCS: Least Common Superconcept)を用いて式(3)のように表せる．

$$Sim_{wup} = \frac{2 * depth(LCS)}{depth(concept_1) + depth(concept_2)} \quad (3)$$

Resnik[12]は，多くの情報を共有する2つの概念の類似性は大きくなりうるという仮説に基づいて類似度を計算する．具体的には，2つの単語間の最小共通上位概念の情報量を求める．LCSおよび概念の情報量(IC: Information Content)を用いたResnikによる類似度を式(4)に示す．

$$Sim_{res} = IC(LCS) \quad (4)$$

Lin[13]は，Linが提案した類似度定理に基づく類似度計算手法である．LCSおよびICを用いると式(5)のように表せる．

$$Sim_{lin} = \frac{2 * IC(LCS)}{IC(concept_1) + IC(concept_2)} \quad (5)$$

Jiang & Conrath[14]は，情報量とエッジの数え上げを組み合わせた単語間の類似度計算手法である．LCSおよびICを用いた類似度を式(6)に示す．

$$Sim_{jcn} = \frac{1}{IC(concept_1) + IC(concept_2) - 2 * IC(LCS)} \quad (6)$$

3．性能評価実験

提案手法が従来手法と比較して，入力テキストをより高い精度で分類できるかを確認するために性能評価実験を行った．

3.1 実験データ

実験で用いるテキストは，Web サイトおよびTwitter[*6]から収集した．Webからは，「笑い話」を掲載する各種サイトから笑い話を 987 テキスト，Twitter からはハッシュタグとして「#twnovel」が付与されたツイートを1,211テキスト収集した．そこからさらに無作為抽出した各400テキストを用いて，テキストがユーモアかノンユーモアかを分類するためのアンケート調査を行った．

アンケートは，北海道の大学に在籍している 20 代前半の学部生 11 名に対して行った．内訳として男性6名，女性5名，文系5名，理系6名であった．アンケートは，各テキストを読んでもらい，「文章の作者が書いた文章によって読者を笑わそうとしているかどうか」を尋ね，回答は，各テキストに対し「そう感じた」か「そう感じなかった」のいずれかで回答していただいた．

集計したアンケートの結果から，過半数以上「そう感じた」と回答があったテキストを物語ユーモア(ユーモア)とし，それ以外のテキストを一般の物語(ノンユーモア)とした．その結果，ユーモアが 438 テキスト，ノンユーモアが 362 テキストとなった．集計結果により分類されたテキストの例を表3に示す．

実験では，集計結果によって分類された各クラスのテキストを各362文ずつ無作為抽出して実験データとした．

表3 アンケート調査を行ったテキストの例

分類	テキストの内容
ユーモア	ある慌て者、銀行がつぶれると聞いて、大急ぎで支店から預金を引き出し、その足で町の本店へ預けに行った。「この建物は、立派だ。安心なもんだ」
ノンユーモア	旅行で撮った滝の写真に二つの顔が浮かび上がっていた。じっと見ていたら妹そっくりの顔が浮かび上がってきた。そういえば、さっきまで隣にいた妹がいない。

3.2 実験方法

実験は，従来手法であるNBのユーモアの事後確率を参照するシステムをベースラインとし，当該部分を提案手法に置き換えたシステムを用いて行った．ユーモアの事後確率のしきい値は，実験[7]で最も分類精度の高かった0.001に設定した．検定にはk-分割交差検定を用い，k=10とした．

[*6] Twitter: https://twitter.com

3.3 実験結果

実験を行った中で，NB と SVM の分類結果が一致しなかったテキストが724テキスト中124テキスト存在した．この124テキストは，ベースラインおよび提案手法による分類対象となるテキストである．ベースラインおよび提案手法による124テキストの分類結果を表4に示す．

表4 提案手法およびベースラインの個別の性能

分類手法	分類精度(%)	再現率(%)	F値
NB Post	56.2	**97.8**	0.695
最後の文と1つ前の文の間の類似度を除いた，テキスト全文の類似度の平均を基準値とした場合			
Path	60.3	91.7	0.708
Lch	**60.4**	91.7	0.708
Wup	59.3	90.2	0.699
Res	60.1	94.3	0.717
Lin	**60.4**	96.9	**0.726**
Jcn	60.1	94.8	0.714
最後の文と1つ前の文の間の類似度を除いた，テキスト全文中で最低となった類似度平均を基準値とした場合			
Path	58.4	88.2	0.684
Lch	58.4	88.2	0.684
Wup	57.0	83.0	0.655
Res	56.4	80.3	0.642
Lin	56.4	80.3	0.642
Jcn	56.9	86.1	0.666

再現率は，ベースラインであるNBのユーモアの事後確率を用いた手法が97.8%と最も大きい値であった．しかし，分類精度ではLeacock & ChodorowやLinの60.4%を最大として，いずれの提案手法もベースラインを上回っている．F値でもLinの0.726が最大であり，これはベースラインの0.695を上回っている．

本稿では，最後の文と1つ前の文の間の意味的類似度の平均と比較する基準値を2種類用意した．分類結果を見ると，Lin を用いた場合ではテキスト全体の類似度を平均したものを用いたシステムとテキスト全体の類似度の平均の中で最低値を用いたシステムと比較すると，分類精度で4.0ポイント，再現率では16.6ポイント上回っている．他の類似度計算手法を用いた場合でも，テキスト全体の類似度を平均した値を用いたシステムが分類精度および再現率においてより優れた結果を出している．

参考として，提案手法およびベースラインを従来手法であるNBとSVMの両分類器による分類システムと組み合わせた場合の性能を表5に示す．

表5 提案手法およびベースラインを従来手法と組み合わせた場合の性能

分類手法	分類精度(%)	再現率(%)	F値
NB Post	81.2	**90.0**	0.853
最後の文と1つ前の文の間の類似度を除いた，テキスト全文の類似度の平均を基準値とした場合			
Path	**82.0**	88.7	0.852
Lch	**82.0**	88.7	0.851
Wup	81.8	88.4	0.850
Res	**82.0**	89.2	0.854
Lin	**82.0**	89.7	**0.856**
Jcn	81.8	89.2	0.853
最後の文と1つ前の文の間の類似度を除いた，テキスト全文中で最低となった類似度平均を基準値とした場合			
Path	81.7	88.1	0.848
Lch	81.7	88.1	0.848
Wup	81.4	87.0	0.841
Res	81.4	86.5	0.839
Lin	81.4	86.5	0.839
Jcn	81.4	87.6	0.844

ベースラインと組み合わせた手法と比較して，提案手法はいずれも再現率において0.3ポイントから3.5ポイント下回っていた．一方で，分類精度においてはいずれも提案手法が0.2ポイントから0.8ポイント上回った．F値を見ると，テキスト全文の類似度平均を基準値に設定し，かつ類似度計算手法に

Resnik や Lin を用いた手法では，ベースラインと比較して最大 0.3 ポイント上回っており，提案手法が優れていることが確認された．

4．考察

図 1 のユーモアは，提案手法ではいずれもユーモアとして分類された．処理内容を見ると，最後の文が『赤色も出るんだねえ』であり，1 つ前の文が『紙の両端に赤いラインまで書いてくれて。』と処理されていた．提案手法では「紙」と「赤色」，「ライン」と「赤色」間の意味的類似度を計算しており，それらの類似度を平均した値が基準値を下回ったため，「落ち」があるとしてユーモアとして分類された．しかし，このテキストは，ロール紙が切れかけたために出てくる赤いラインを，「母」がお祝いだからといって印刷してくれたのと勘違いする点におかしみがあると考えられる．そのため，「紙」や「ライン」と「赤色」の単語間の類似度を求め，基準値と比較することは，前述したおかしみを直接発見し，「落ち」としているわけではないと考えられる．

しかし，提案手法は，文間の意味的類似度を比較することを通じて，ユーモアのテキスト特有の特徴を捉えており，それによって分類精度が向上していると考えられる．特徴とは，「落ち」はテキストの前半と比較して，概念辞書に含まれない単語が多くなることである．具体例として，ユーモアのテキストを図 4，図 5 に挙げる．

いずれも，最後の文から抽出される単語が「その後」や「そう」といった，日本語 WordNet 上に存在しない単語である．そのため，最後の文と 1 つ前の文の間の意味的類似度の平均値が低下するのである．これらは，物語ユーモアの文章が文語体とは異なり，適切な形態素に区切ることが比較的困難であることや，概念辞書に含まれない言葉を用いた文章表現であることを表していると考えられる．以上より，提案手法は物語ユーモアの文章構造を捉え，人間が意味内容を捉えてユーモアを認識するのと近い状態を再現していると言える．

提案手法とベースラインを個別に性能比較を行った場合，提案手法の分類精度は最大 4.2 ポイント，ベースラインを上回っていた．しかし，システム全体の性能を見た場合，最大 0.8 ポイントの向上に留まった．これは，提案手法が適用されるのが従来手法の NB と SVM の結果が不一致だった場合に限るためである．両分類器で結果が不一致になるのは，724 テキスト中 124 テキストと，全体を占める割合としては 17%程度であり，これらテキストのみを対象とした手法のみならず，今後は入力テキスト全般に対して分類を行う手法を提案することが精度向上に繋がるのではないかと考えられる．

> 世界初の猫のためのＣＭがテレビで流れた。すると、一歳の息子がテレビの前にとんできた。じーっと見入った後に跳び上がり、手をたたき、キャッキャッと声を上げて大喜び。しかも、その後しばらく四つんばいになって動き回っていた。

図 4　物語ユーモアの具体例（その 2）

> わたしはよく鼻血を出す子供だった。だから、サラミを食べてはいけなかった。母いわく「サラミは鶏のトサカでできているから、一口食べただけでも、トサカ色の鼻血が流れくるのよ」なのだそうな。

図 5　物語ユーモアの具体例（その 3）

5．まとめ

本稿では，概念辞書である WordNet を用いて単語間の意味的類似度を計算した「落ち」の検出手法によって，物語テキストをユーモアかノンユーモアかの分類を行った．その結果，従来の Naïve Bayes のユーモアの事後確率を用いた手法と比較して，再現率の低下が見られたが，分類精度に最大 4.2 ポイントの向上が見られた．考察の結果，提案手法は「落ち」の文ではその他の文と比較して概念辞書上にない単語の割合が増加し，意味的類似度の平均が下がる，といった物語性のあるユーモア特有の特徴を捉えることによって「落ち」を検出できたと考えられる．

今後の課題として，さらなる分類精度の向上が挙げられる．そのためには，人間のユーモア認識モデルを考慮し，意味内容を踏まえたユーモアの認識システムを構築することが考えられる．ユーモアを含むとされる物語テキストの意味的内容にはどのような特徴があるのかを調査し，その特徴を計算機が検出できるためのアルゴリズムを発見することが必要であると考えられる．

参考文献

[1] 高橋瑞希, Rafal Rzepka, 荒木健治: “Web 検索と単語 n-gram モデルによる対話処理手法における補佐システムの有効性”, ことば工学研究会資料, SIG-LSE-B001, pp.17-24, 2010.

[2] キムビンステッド, 滝澤修: “日本語駄洒落なぞなぞ生成システム「BOKE」”, 人工知能学会誌, Vol. 13, No. 6, pp. 920-927, 1998.

[3] 山根宏彰, 萩原将文: “笑いを生むことわざすかしの自動生成システム”, 知能と情報: 日本知能情報ファジィ学会誌, Vol. 24, No. 2, pp. 671-679, 2012.

[4] Dybala, P., Ptaszynski, M., Higuchi, S., Rzepka, R., Araki, K.: “Humor Prevails! – Implementing a Joke Generator into a Conversational System”, Springer-Verlag Lecture Notes in Artificial Intelligence, Vol. 5360, pp. 214-225, 2008.

[5] Mihalcea, R., Strapparava, C., Pulman, S.: “Computational Models for Incongruity Detection in Humour”, Computational Linguistics and Intelligent Text Processing Lecture Notes in Computer Science, Vol. 6008, pp.364-374, 2010.

[6] Mihalcea, R., Pulman, S.: “Characterizing Humour: An Exploration of Features in Humorous Texts”, CICLing '07 Proceedings of the 8th International Conference on Computational Linguistics and Intelligent Text Processing, pp. 337-347, 2007.

[7] 天谷祐介, 荒木健治, ジェプカラファウ: “テキストの面白さの評価によるユーモアの認識”, ファジィシステムシンポジウム講演論文集, Vol. 28, pp. 233-238, 2012.

[8] Maron, M. E.: "Automatic Indexing: An Experimental Inquiry", Journal of the ACM Vol. 8, No. 3, pp. 404-417, 1961.

[9] Cortes, C., Vapnik, V.: "Support-Vector Networks", Machine Learning, Vol. 20, No. 3, pp. 273-297, 1995.

[10] Leacock, C.,Chodorow, M.: "Combining local context and WordNet sense similarity for word sense identification", WordNet: An Electronic Lexical Database, Vol. 49, pp.265-283, 1998.

[11] Wu, Z., Palmer, M.: "Verb semantics and lexical selection", in ACL'94, pp.133-138, 1994.

[12] Resnik, P.: "Using information content to evaluate semantic similarity in a Taxonomy", in IJCAI'95, pp.448-453, 1995.

[13] Lin, D.: "An Information-Theoretic Definition of Similarity", in ICML'98, pp.296-304, 1998.

[14] Jiang, J.J., Conrath, D.W.: "Semantic similarity based on corpus statistics and lexical taxonomy", in 10th Intl. Conf. Research on Computational Linguistics, pp.1-15, 1997.