商品レビュー文に含まれるオノマトペに基づく商品カテゴリの分類

Classification of Product Categories Based on Onomatopoeia Words in Product Reviews

◯ [1] 内田　ゆず,　[2] 荒木　健治,　[1] 米山　淳
◯ [1]Yuzu Uchida,　[2]Kenji Araki,　[1]Jun Yoneyama

[1] 青山学院大学
[1]Aoyama Gakuin University
[2] 北海道大学大学院情報科学研究科
[2]Graduate School of Information Science and Technology, Hokkaido University

Abstract:
Nowadays, there are a number of product reviews on the Internet. Product reviews written by consumers contain many onomatopoeia words which describe features of each product or consumer's emotions. It is assumed that each onomatopoeia word in a product review provides a valuable clue to a consumer's thoughts. In this paper, we describe the appearance frequency of onomatopoeia words in 729,865 reviews from Yahoo! Shopping. In addition, we classify product categories in terms of the appearance frequency of onomatopoeia words with hierarchical cluster analysis.

1　はじめに

近年，商取引の電子化が進展しており，平成 23 年の日本国内の消費者向け電子商取引市場規模は 8.5 兆円まで拡大している [1)]．それに伴い，Web 上には一般消費者による商品レビューが大量に存在するようになった．それらのレビュー文を分析して商品やサービスの評価を抽出し，消費者の情報収集・企業の市場調査に役立てようという動きが高まっている．

商品レビューには商品に対する消費者の主観的な情報が多く含まれており，商品の特徴や消費者の感情を表すためにオノマトペが用いられることがある．したがって，レビュー記事の分析を行う際に，オノマトペが有効な手がかりになると考えられる．

オノマトペは細かいニュアンスを伝えることに優れている．たとえば，やわらかいことを表す “ぐちゃぐちゃ”，“しんなり”，“ふっくら” では伝わるイメージが全く異なる．日本語オノマトペ辞典 [2)] には，やわらかい様子を表すためのオノマトペだけでも 71 語が掲載されている．一方で，種類が多い，意味や用法にはっきりとした定義がない，といった点でオノマトペは機械的な処理には不向きである．

我々は，商品カテゴリにおけるオノマトペの出現傾向を分析することで，オノマトペ-ドメイン間の関係を明らかにしようとしている．本稿では，Yahoo! ショッピング商品レビュー 729,865 件を対象として，オノマトペの出現頻度を調査する．さらに，“やわらかい”，“かたい” など 13 のカテゴリに属するオノマトペの出現頻度を変数としたクラスタ分析によって商品カテゴリを類型化する．また，得られたクラスタがどのようなオノマトペによって分類されているのかを調査する．

2 章では，対象となる商品レビューデータの詳細について述べる．**3** 章では，商品カテゴリにおけるオノマトペ出現頻度について述べる．**4** 章では，クラスタ分析によって商品カテゴリを類型化し，それぞれのクラスタを特徴づけるオノマトペを決定する実験について述べる．最後に，**5** 章で本稿の結論と今後の課題を述べる．

2　商品レビューデータ

本研究で用いる商品レビューは，Yahoo!Japan 商品レビュー検索 API を用いて収集された Yahoo! ショッピング[1]の商品レビューである．また，API で取得できる商品レビューの要素のうち，ReviewTitle（レビューのタイトル文）と Description（レビューの本文）の 2 つを用いる．

Yahoo! ショッピングでは，商品が階層化されたカテゴリによって管理されている．本研究では最下層の商

[1] http://shopping.yahoo.co.jp/

表 1　商品レビューデータの例（犬用シャンプー）

ReviewTitle	Description
つやつや	静電気もおきませんし、毛がつやつやになりとてもいいです。 うちのパグも気持ちよさそうにブラッシングされています。
高級感のある香り	リンスと一緒に購入しました (^^) 一番のお気に入りです。香りもさらさら感も一番です! うちでは 4 匹の犬がいますので業務用はとってもお得です。 このシャンプーは犬臭さが無くなりますのですぐに匂う子には とてもおすすめ!!

品カテゴリを扱うものとする．レビューは 9,170 の商品カテゴリに対するもので，総件数は 729,865 件，総単語数（ReviewTitle と Description に含まれる単語数）は 35,720,231 語となっている．

表 1 に犬用シャンプーのカテゴリに分類された実際のレビューの例を示す．

3　オノマトペ出現頻度の調査

3.1　手順

日本語オノマトペ辞典 [2] に事物の程度，事物の動き・変化，事物の形・状態，事物の音・道具・金銭を表すオノマトペとして掲載されている 1,049 語（重複している語は除外）のうち，表 2 に示した小カテゴリに属している 637 語を調査の対象とし，9,170 の商品カテゴリのレビューに出現する頻度を調査する．

具体的な手順としては，**2** 章で述べたレビューデータ（ReviewTitle と Description）に形態素解析を施し，上述のオノマトペと字面が完全に一致する形態素をカウントする．このとき，オノマトペはひらがな表記に加えてカタカナ表記も考慮する．

字面の一致のみを基準にすると，オノマトペ以外の同音異義語もカウントの対象になるという問題点がある．実際にこの手法で得られた結果を確認すると，高頻度で “ぼたん[2]”，“きー[3]” などが抽出されていた．これらの単語は，以下のようなレビューによって出現頻度が増加している．

- イヤホンもついてて機能充実です♪でも個人的にボタン が少し押しにくいです。（電子辞書）
- 見た目も綺麗で、キー も打ちやすくてとても気に入ってます。薄くて軽くて扱いやすいです。（日本語キーボード）

[2] 水滴などが高い所から落ちる音/ボタン（button）
[3] かたいものがこすれ合う音/キー（key）

この問題を回避するため，名詞として分割された単語は除外するという条件を設ける．

形態素解析器は日本語形態素解析システム JUMAN 7.0[3] を用いる．形態素辞書には，調査対象のオノマトペを副詞として追加した．

一般に，オノマトペは形態素解析誤りを引き起こしやすい [4]．JUMAN 7.0 のオノマトペに対する解析精度の目安を調査するために，本研究で使用する 637 語のオノマトペをそれぞれ単語の形で入力したところ，614 語が 1 形態素として出力された．文単位で形態素解析を行った場合はさらに解析精度が低下すると予想されるが，ここでは形態素解析誤りについては考慮せず，正しく分割されたオノマトペのみをカウントの対象とする．

3.2　結果と考察

調査の結果，637 語のオノマトペのうち，482 語が合計で 366 カテゴリのレビュー 52,212 件に出現していることが明らかになった．頻度が高い 10 語を順に挙げると，“ぴったり”（10,778 回），“ふわふわ”（2,374 回），“さらさら”（2,357 回），“きらきら”（2,005 回），“さっぱり”（1,736 回），“さらっ”（1,460 回），“ぎりぎり”（1,328 回），“ふんわり”（1,147 回），“つい”（1,011 回），“ふかふか”（983 回）となっている．100 回以上出現したオノマトペは 82 語である．

“ぴったり”の出現頻度が突出して多く，全体の約 21%を占めている．これは，どのような商品カテゴリにも使用される汎用的な語であるためだと考えられる．一方，出現が確認された 482 語のうち 400 語は出現頻度が 1〜99 回となっており，オノマトペの多様性とオノマトペ使用の個人差がうかがえる．

表 2　調査対象としたオノマトペ

大カテゴリ	小カテゴリ	語数	オノマトペの例
程度	やわらかい	71	しんなり
	かたい	35	かちかち
動き・変化	落ちる	72	ばさっ
	折れる	33	ぽきん
	ゆれる	49	ぐらぐら
	切る・切れる	52	すぱっ
	破る・破れる	18	びりびり
	貼る・くっつく	21	ぺたっ
	刺す	28	ちくり
	曲がる・しわがよる	22	うねうね
形・状態	張る・膨らむ	31	むくむく
	光る・輝く	41	ぴかぴか
	焼く・焼ける	15	こんがり
	煮る	7	ぐつぐつ
	粘る・ぬめる	41	ぎとぎと
	かわいた	24	ばさばさ
	のびる・縮む	24	すらり
	乱雑	41	ぐちゃぐちゃ
音・道具・金銭	こすれる・きしむ	87	きーきー

4　商品カテゴリの類型化

オノマトペの出現頻度によって商品カテゴリを類型化するために，階層的クラスタリング手法の一つであるクラスタ分析を行う．

4.1　手順

ケースクラスタ分析により，オノマトペ（変数）を手がかりに商品カテゴリ（ケース）を分類する．このとき，オノマトペは表 2 の小カテゴリを 1 つの単位とし，小カテゴリごとにカテゴリ分析を行う．個体間非類似度計算には平方ユークリッド距離を用い，クラスタ結合手法にはウォード法を用いる [5]．次節以降で実際に分析を行うデータの詳細を述べる．

4.1.1　商品カテゴリの統廃合

9,170 の商品カテゴリとそれらに対するレビューの内容を第一著者が調査したところ，統合あるいは削除すべきものが存在していることが明らかになった．例えば，“サングラス” というカテゴリは 2 つあるが，それらの上位カテゴリはレディースファッションとメンズファッションであった．このようなカテゴリは区別する必要がないと判断し，類似度の高いカテゴリは統合することとした．また，“パーツ（その他）” というカテゴリはオートバイ用品の下位カテゴリであり，ヘルメットホルダーやシートカバー，レッグガードなど，対象となる商品が多岐にわたっている．このような商品カテゴリは削除することとした．

オノマトペを含むレビューが抽出された 366 カテゴリを人手で確認し統廃合を行ったところ，62 カテゴリが 30 カテゴリに統合され（3 カテゴリが統合されたものが 2 例），43 カテゴリが削除された．

表 3　“かわいた” に関する頻度表（一部）

商品カテゴリ	さらさら	さっぱり	さらっ	ぱさぱさ
トリートメント	19.4	1.0	2.3	2.8
シャンプー	11.1	4.3	1.0	2.0
化粧水	1.0	9.0	1.8	0.1
敷パッド	6.0	0.9	5.5	0.1
クリーム	1.3	3.1	3.6	0.0
クレンジング	1.1	8.0	1.5	0.0

4.1.2　頻度表

表 2 の小カテゴリのうち，オノマトペを含むレビューが 1,000 件に満たなかった “折れる”，“貼る・くっつく”，“刺す”，“曲がる・しわがよる”，“焼く・焼ける”，“煮る” はデータ数が十分ではないと判断し，分析の対象外とした．したがって，残る 13 カテゴリについて，頻度表を作成する．

一般に，階層的クラスタリングを用いるのは，サンプルサイズが 50 程度までの場合である．ここでは，以下の条件に基づいて頻度表を作成する．

(i) オノマトペを含むレビューが 5 件以上存在する商品カテゴリのみを分析対象とする．

(ii) 条件 (i) を満たす商品カテゴリからオノマトペを含むレビューの件数が多いものから順に選択する．なお，商品カテゴリは最大で 50 とする．

(iii) 条件 (ii) で選択された商品カテゴリに 5 回以上出現したオノマトペのみを分析対象とする．

なお，抽出されたレビューの件数は商品カテゴリによって異なるため，粗頻度ではなく相対頻度（オノマトペが出現したレビューの当該商品カテゴリにおけるレビュー全体に占める割合）を用いる．実際の頻度表を簡略化したものを表 3 に示す．例えば，“トリートメント” の商品カテゴリに関する商品レビューは 1,000 件[4]抽出され，そのうち 194 件に “さらさら” というオノマトペが含まれていたため，頻度表のデータは 19.4（%）となる．

4.2　結果

クラスタ分析の結果の一例として，“やわらかい” に関するオノマトペを変数にした場合のデンドログラムを図 1 に示す．

階層的クラスタリング手法はあらかじめクラスタ数を定めないでクラスタリングを行う手法である．クラ

[4] Yahoo! Japan 商品レビュー検索 API で抽出できる最大件数

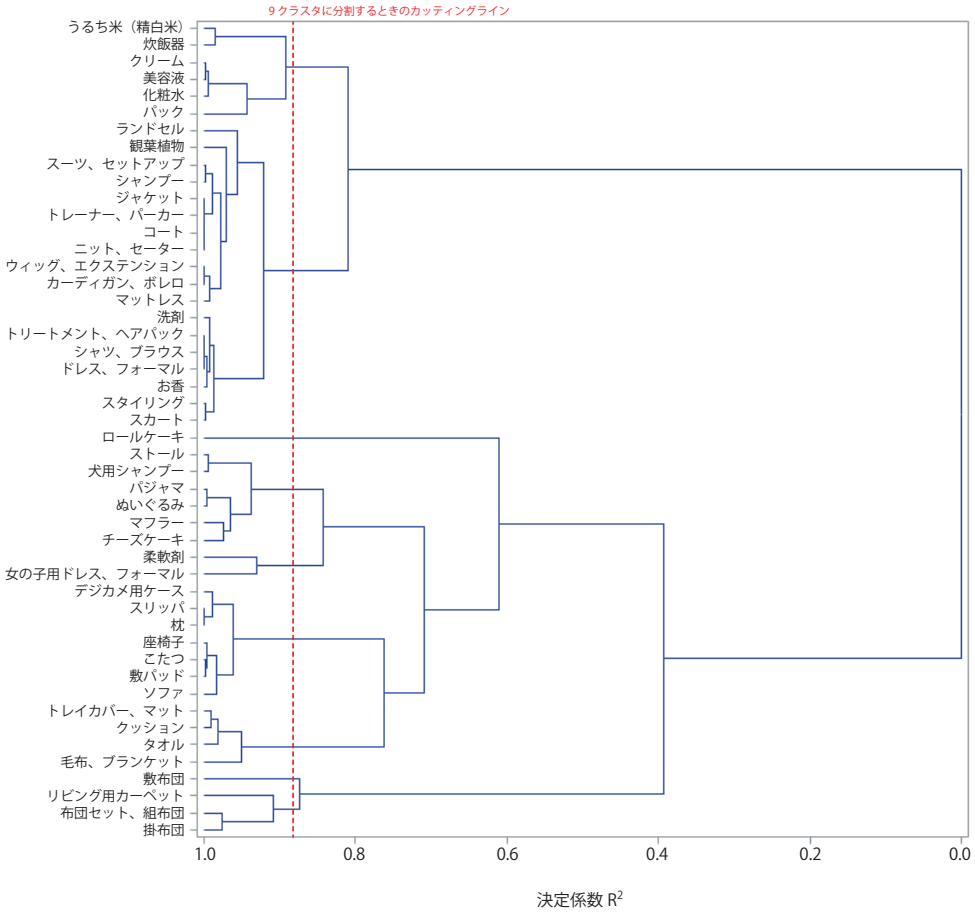


図 1　デンドログラム（やわらかい）

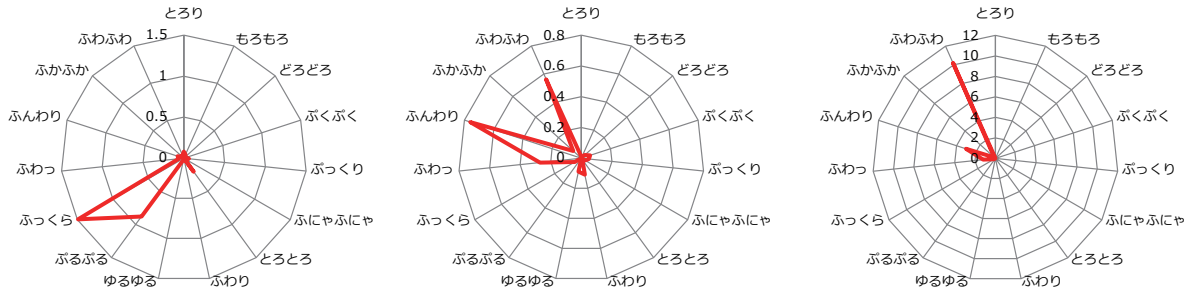
スタ分析では，得られたデンドログラムのどの段階をクラスタリング結果として採用するかを決めなければならない [6) 7)]．クラスタ数の決定には明確な方法がなく，多くの場合，分析者にとって良い解釈が得られる段階を採用することになる．その他の基準としては，結合距離が長くなる段階を選択する，各クラスタにおける各変数の平均値にクラスタ間で有意な差があるかを検討する，各種統計量基準 [8)] を勘案する，などが挙げられる．

本研究ではできるだけ客観的な指標に基づいてクラスタ数を決定するために，疑似 F 統計量 [9)]，疑似 t^2 統計量 [10)]，CCC 基準 [11)] の 3 種類を勘案して判断する．疑似 F 統計量は各ステップでの全クラスタ間の分割度合いを示し，値が大きいほど結びつきが強く，適切に分割されていることを示す．疑似 t^2 統計量はクラスタリングを行う際に結合した 2 つのクラスタ間の分割度合いを示し，正の方向に最も大きく変化する直前のクラスタ数を選ぶと良い．CCC 基準は，最大値となるときに適切と推測されるクラスタ数を表し，2 あるいは 3 以上のスコアが望ましいとされる．図 2 に “やわらかい” の分析結果を対象とした CCC 基準，疑似 F 統計量，疑似 t^2 統計量の値を示す．

以上の方法により，各オノマトペ小カテゴリでクラスタ数を定めた結果を表 4 に示す．オノマトペの小カテゴリ “やわらかい” では，**4.1.2** で述べた条件を満たす 15 語のオノマトペで 48 の商品カテゴリを分類したところ，9 つのクラスタが得られたことを示している．図 1 と照らし合わせると，第 1 クラスタの要素は { うるち米（精白米）, 炊飯器, クリーム, 美容液, 化粧水, パック } の 6 つ，第 9 クラスタの要素は { リビング用カーペット, 布団セット・組布団, 掛布団 } の 3 つとなる．クラスタ番号に優劣などの意味はない．

4.3　考察

“やわらかい” の第 1 クラスタの要素は，食品，電化製品，化粧品で構成されているが，一般的なクラスタリングではこれらの要素が同じクラスタに属するとは



第 1 クラスタ　　第 2 クラスタ　　第 3 クラスタ

図 3　第 1〜3 クラスタの変数の平均値（やわらかい）

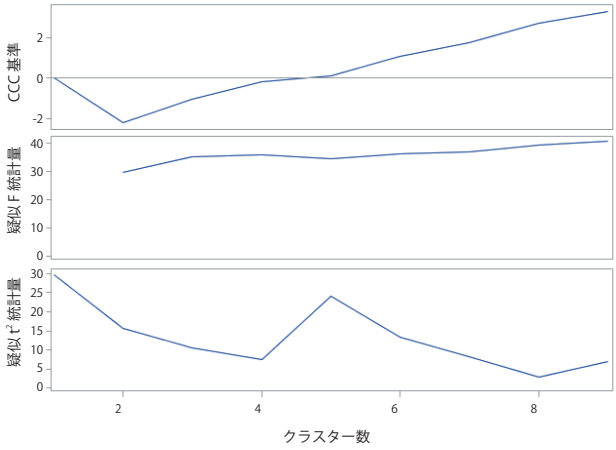


図 2　クラスタ数決定の基準（やわらかい）

表 4　クラスタリング結果

	オノマトペ	商品カテゴリ	クラスタ数
やわらかい	15	48	9
かたい	12	46	9
落ちる	9	47	5
ゆれる	8	46	9
切る・切れる	10	23	4
破る・破れる	9	47	9
張る・膨らむ	12	47	9
光る・輝く	12	49	9
粘る・ぬめる	12	21	5
かわいた	15	47	9
のびる・縮む	13	49	8
乱雑	11	49	8
こすれる・きしむ	20	47	9

考えにくい．この結果は，オノマトペを媒介とすることで，消費者が商品に求める特性で商品カテゴリを分類できることを示唆している．

次に，**4.2** で定めたクラスタを特徴づけているオノマトペを，各クラスタにおける各変数の平均値によって判別する．図 3 に “やわらかい” の第 1 クラスタ〜第 3 クラスタの例を示す．グラフから，“やわらかい” の第 1 クラスタ { うるち米（精白米）, 炊飯器, クリーム, 美容液, 化粧水, パック } には “ふっくら” と “ぷるぷる” が寄与しているといえる．この結果は，日本語母語話者にとって自然なものであると考えられる．このように，オノマトペが一定数含まれる商品カテゴリのレビューのクラスタ分析を行うことによって，妥当性のある類型化が可能であることが示された．

同様にして，13 種類のオノマトペ小カテゴリのすべてのクラスタについて対応するオノマトペを決定し，商品カテゴリ-オノマトペのペアを 1,052 組得た．このデータは，レビュー分析のみならずオノマトペの学習支援にも有益であろう．現在，結果の妥当性を検証するために，複数の被検者を用いた実験による評価を行っている．

5　おわりに

本稿では，Yahoo! ショッピング商品レビュー 729,865 件を対象として，637 語のオノマトペの出現頻度を調査した結果について述べた．637 語のオノマトペのうち，482 語が合計で 52,212 回レビューに出現しており，100 回以上出現したオノマトペは 82 語であった．

さらに，“やわらかい”，“かたい” などの単位で，商品カテゴリをオノマトペの出現頻度で分類するためにクラスタ分析を行った．クラスタ数の決定には疑似 F 統計量，疑似 t^2 統計量，CCC 基準の 3 つの統計量基準を用いた．日本語母語話者にとって違和感のない結果が得られたが，詳細な精度調査は現在進行中である．

今回の調査で，商品カテゴリによって使用されるオ

ノマトペに一定の傾向があることが明らかになった．一方，同じオノマトペでも，商品カテゴリによって使用される意図が異なる場合がある．今後は，レビュー中に含まれるオノマトペ，商品カテゴリ，レビュー評価点の関係を調査する予定である．

謝辞

本研究は科研費（課題番号：23700256）の助成を受けたものである．

参考文献

1) 経済産業省: 平成２３年度我が国情報経済社会における基盤整備（電子商取引に関する市場調査），2012.

2) 小野 正弘: 擬音語・擬態語 4500 日本語オノマトペ辞典, 小学館, 2007.

3) 日本語形態素解析システム JUMAN 7.0, http://nlp.ist.i.kyoto-u.ac.jp/index.php?JUMAN.

4) 古武 泰樹, 佐藤 理史: 用例に基づくオノマトペ用法辞書の編纂, 言語処理学会第 16 回年次大会発表論文集, pp.994-997, 2010.

5) 石川 慎一郎, 前田 忠彦, 山崎 誠 編: 言語研究のための統計入門, くろしお出版, 2010.

6) E. Mooi and M. Sarstedt: Cluster Analysis, IN A Concise Guide to Market Research, pp.237-284, Springer-Verlag Berlin Heidelberg, 2011.

7) 齋藤 堯幸, 宿久 洋: 関連性データの解析法―多次元尺度構成法とクラスタ分析法, 共立出版, 2006.

8) G. Milligan and M. Cooper: An examination of procedures of determining the number of cluster in a data set, Psychometrika, vol.50, no.2, pp.159-179, 1985.

9) T. Calinski, and J. Harabasz : A dendrite method for cluster analysis, Communications in Statistics, vol.3, pp.1-27, 1974.

10) G. Milligan and M. Cooper: Methodology Review: Clustering Methods, Applied Psychological Measurement, vol.11, pp.329-354, 1987.

11) S. Sarle: Cubic Clustering Criterion, SAS Technical Report A-108, Cary, N.C., SAS Institute, 1983.

連絡先

内田 ゆず

E-mail: yuzu@ee.aoyama.ac.jp