特集論文 「オノマトペの利活用」

クラスタ分析を用いた商品レビューに含まれるオノマトペに基づく商品カテゴリの類型化

Classification of Product Categories Based on Onomatopoeia Words in Product Reviews Using Cluster Analysis

内田 ゆず
Yuzu Uchida
北海学園大学
Hokkai-Gakuen University
yuzu@eli.hokkai-s-u.ac.jp

荒木 健治
Kenji Araki
北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University
araki@ist.hokudai.ac.jp

keywords: onomatopoeia, product review, hierarchical cluster analysis

Summary

Nowadays, there are a number of product reviews on the Internet with the development of the consumer generated media as typified by social networking sites, blogs, and customer review sites. These reviews influence a consumer's buying decision and a company's market research. They are a lot valuable to both customers and companies, so that sentiment analysis becomes an active area of research. A sentiment polarity dictionary is essential to the sentiment analysis. We focus attention on onomatopoeia words in product reviews. It is noted that product reviews written by consumers in Japanese contain many onomatopoeia words. Japanese onomatopoeia can convey a subtle sense of features of products and customer's emotion. It is assumed that each onomatopoeia word in a product review provides a valuable clue to understanding a consumer's opinion. In this paper, we describe the appearance frequency of onomatopoeia words. After analysis of 729,865 reviews from Yahoo! Shopping, it is found that 482 words appeared in 52,121 reviews. We classify product categories in terms of the appearance frequency of onomatopoeia words with hierarchical cluster analysis and extract 978 pairs of product categories and onomatopoeia words which are likely connected to each other. Ten subjects judge the validity of these 978 pairs and consequently we conclude that 658 pairs are deemed appropriate for sentiment analysis. Further examination reveals the following two points: (1) it is highly possible that impressions of each product are described in the reviews containing onomatopoeias; and (2) the sentiment polarity of onomatopoeia differs depending on product categories.

1. は じ め に

近年，商取引の電子化が進展している．インターネットショッピングでは商品を実際に手に取ることが難しいため，消費者はインターネット上で情報収集を行い，購入の意思決定を行うことが多い．また，口コミサイトやソーシャルネットワーキングサービスなどの CGM（Consumer Generated Media，消費者生成メディア）の普及により，購入者自らが商品の満足感や使用感を発信し，情報を共有することが容易になっている．経済産業省が行った電子商取引に関する市場調査によると，商品・サービスの「購入」について，ソーシャルメディアは「自身の嗜好に合った商品・サービスの発見」に寄与することが確認されている [経済産業省 2012].

これらの背景から，消費者の情報収集・企業の市場調査への活用に向けて，インターネット上に大量に存在する商品レビューを収集し，対象商品の評判情報を分析する研究が盛んに行われている．評判分析に関する初期の研究は，レビュー文書を肯定的，否定的の 2 値に分類する問題を扱っていた [Pang 2002, Turney 2002]．その後，商品レビューの数が増大するにつれ，消費者が所望の情報を得るための負担が大きくなるという問題を受け，複数のレビュー文書を要約する技術や，有用な評判情報のみを抽出する技術へのニーズが高まっている．

レビュー文書の要約や評判情報の抽出を行うにあたり，評価を示す語とその極性（肯定/否定）をまとめたデータベース（評価表現辞書）が必要不可欠である．日本語を対象にした評価表現辞書としては，[鍛治 2007, 小林 2005, 高村 2006] などがある．さらに，“社会に発信される評価は，ブログ等の普及により細分化・複雑化し，評価極性（肯定・否定）によって情報を分類するだけでは，その多様性を捉えられなくなってきている”[佐野 2012]

ことから，評価表現を極性だけでなく，評価基準によっても分類した辞書も構築されている．

我々は，レビュー文書に記述された商品素材の質感や消費者の心情をより深く分析するために，オノマトペに着目している．オノマトペは細かいニュアンスを伝えることに優れている．たとえば，日本語オノマトペ辞典 [小野 2007] には，やわらかい様子を表すためのオノマトペだけでも 71 語が掲載されており，“ぐちゃぐちゃ”，“しんなり”，“ふっくら” では伝わるイメージが大きく異なる．また，商品レビューには商品に対する消費者の主観的な情報が多く含まれており，オノマトペが多用されるという指摘もある [内田 2013]．したがって，レビュー文書の分析を行う際に，オノマトペが有効な手がかりになると考えられる．一方で，種類が多い，意味や用法にはっきりとした定義がない，ドメインによって使用すべきオノマトペが異なる，といった点でオノマトペは機械的な処理には不向きである．

本研究の目的は，関連性の高いドメイン-オノマトペのペアを自動的に抽出し，それらを評判情報抽出の技術に応用することの有効性を確認することである．具体的には，①商品レビューの分析を行い，各商品カテゴリにおけるオノマトペの出現傾向から商品カテゴリ-オノマトペのペアを抽出し，②それらのペアが適切であるかを人手によって評価し，③適切であると判断されたペアに対して評判情報抽出への応用可能性を調査する．

本論文では，Yahoo! ショッピング[*1]の商品レビュー 729,865 件を対象として，オノマトペの出現頻度を調査する．次に，“やわらかい”，“かたい” など 13 のカテゴリに属するオノマトペを変数としたクラスタ分析によって商品カテゴリを類型化する．また，得られたクラスタがどのようなオノマトペによって分類されているのかを調査し，商品カテゴリ-オノマトペのペアを得る．それらのペアの妥当性を複数被験者によるアンケート調査により評価する．さらに，被験者により適切であると判断されたペアに該当する全ての商品レビューを人手で分析し，次の 2 つの仮説を検証する．

- オノマトペを含む商品レビューには商品についての具体的な記述が含まれている
- 商品カテゴリ-オノマトペのペアには肯否極性がある

2 章では，対象となる商品レビューデータの詳細について述べる．3 章では，商品カテゴリにおけるオノマトペ出現頻度について述べる．4 章では，クラスタ分析によって商品カテゴリを類型化し，それぞれのクラスタを特徴づけるオノマトペを決定する実験について述べる．5 章では，クラスタ分析によって得られた商品カテゴリ-オノマトペペアの妥当性を評価する実験について述べる．6 章では，商品カテゴリ-オノマトペペアを評判情報抽出技術へ応用することの有効性を検証する調査について述べる．最後に，7 章で本論文の結論と今後の課題を述べる．

∗1 http://shopping.yahoo.co.jp/

2. 商品レビューデータ

本研究で用いるデータは，Yahoo!Japan 商品レビュー検索 API を用いて収集された Yahoo! ショッピングの商品レビューである．API で取得できる商品レビューは，レビューのタイトル文，レビューの本文，レビュー評価点，レビュー数，更新時間，購入目的，商品名などの要素から構成されている．これらの要素のうち，ReviewTitle（レビューのタイトル文）と Description（レビューの本文）の 2 つを用いる．ReviewTitle と Description は消費者が自由に記述する項目である．

Yahoo! ショッピングでは，商品を階層化されたカテゴリによって管理している．最上層のカテゴリはファッション，食品，パソコン・周辺機器，AV 機器・カメラ，花・ガーデニング，などの 21 カテゴリである．本研究では最下層の 9,170 カテゴリを扱うものとする．収集したレビューの総件数は 729,865 件，総単語数（ReviewTitle と Description に含まれる単語数）は 35,720,231 語となっている．9,170 個の商品カテゴリのうち，商品レビューが 1 件以上存在したカテゴリは 6,439 個，100 件以上は 1,776 個であった．

表 1 に犬用シャンプーのカテゴリに分類された実際のレビューの例を示す．表中の “つやつや” のように，ReviewTitle がオノマトペ 1 語で構成される（あるいはオノマトペを含む）場合もある．

3. オノマトペ出現頻度の調査

まず，収集した 729,865 件の商品レビューデータに含まれるオノマトペの語彙，および出現頻度の傾向を調査する．

3·1 手　　順

調査対象とするオノマトペは，日本語オノマトペ辞典 [小野 2007] に事物の程度，事物の動き・変化，事物の形・状態，事物の音・道具・金銭を表すオノマトペとして掲載されている 1,049 語（重複している語は除外）のうち，表 2 に示した小カテゴリに属している 637 語である．

オノマトペの出現頻度を調査するために，2 章で述べたレビューデータ（ReviewTitle と Description）に形態素解析を施し，調査対象のオノマトペと字面が完全に一致する形態素をカウントする．形態素解析器には日本語形態素解析システム JUMAN 7.0[*2]を用いる．このとき，JUMAN 付属の形態素辞書に本研究の対象である 637 語のオノマトペを副詞として追加した．なお，オノマトペはひらがな表記に加えてカタカナ表記も許容する．

字面の一致のみを基準にオノマトペのカウントを行うと，オノマトペ以外の同音異義語もカウントの対象になるという問題がある．実際にこの手法で得られた結果を

∗2 http://nlp.ist.i.kyoto-u.ac.jp/index.php?JUMAN.

表 1 商品レビューデータの例（犬用シャンプー）

ReviewTitle	Description
つやつや	静電気もおきませんし、毛がつやつやになりとてもいいです。 うちのパグも気持ちよさそうにブラッシングされています。
高級感のある香り	リンスと一緒に購入しました (^^) 一番のお気に入りです。香りもさらさら感も一番です! うちでは 4 匹の犬がいますので業務用はとってもお得です。 このシャンプーは犬臭さが無くなりますのですぐに匂う子にはとてもおすすめ!!

確認すると，“ぼたん*3”，“ぱん*4”，“きー*5” がそれぞれ 2,840 回，1,263 回，997 回と高頻度で抽出されていた．これらの単語は，以下のようなレビューによって出現頻度が増加している．

- イヤホンもついてて機能充実です♪でも個人的にボタンが少し押しにくいです。（電子辞書）
- 3 日に一度はパンを焼くので、まとめ買い出来て助かります。（牛乳）
- 見た目も綺麗で、キーも打ちやすくてとても気に入ってます。薄くて軽くて扱いやすいです。（日本語キーボード）

このような同音異義語による誤抽出を回避するため，名詞として分割された形態素はオノマトペではないと判断し，除外するという条件を設ける．この条件のもとで上記 3 語をカウントすると，“ぼたん” は 652 回，“ぱん” は 324 回，“きー” は 186 回まで頻度が減少した．

一般に，オノマトペは形態素解析誤りを引き起こしやすい [古武 2010]．JUMAN 7.0 のオノマトペに対する解析精度の目安を調査するために，本研究で使用する 637 語のオノマトペをそれぞれ単語の形で JUMAN に入力したところ，614 語が 1 形態素として出力された．正しく分割された 614 語のオノマトペをカウントの対象とすることで，形態素解析誤りの影響を軽減する．本研究で扱うレビューデータは整形された文ではないため，文単位で形態素解析を行うとさらに解析精度が低下すると予想される．しかし，ここではレビューデータ中のオノマトペの出現傾向を概観することが目的であるため，文脈情報を利用するなどの複雑な処理は行わない．

3·2 結果と考察

調査の結果，614 語のオノマトペのうち，482 語が合計で 366 カテゴリのレビュー 52,212 件に出現していることが明らかになった．頻度が高い 10 語を順に挙げると，“ぴったり”（10,778 回），“ふわふわ”（2,374 回），“さらさら”（2,357 回），“きらきら”（2,005 回），“さっぱり”（1,736 回），“さらっ”（1,460 回），“ぎりぎり”（1,328 回），“ふんわり”（1,147 回），“つい”（1,011 回），“ふかふか”（983 回）となっている．100 回以上出現したオノマトペは 82 語である．

“ぴったり” の出現頻度が突出して多く，全体の約 21%を占めている．これは，どのような商品カテゴリにも使用される汎用的な語であるためだと考えられる．一方，出現が確認された 482 語のうち 400 語は出現頻度が 1〜99 回となっており，オノマトペの多様性とオノマトペ使用の個人差がうかがえる．

レビューが 1 件以上存在する 6,439 の商品カテゴリのうち，オノマトペを含むレビューが存在したのは 366 カテゴリである．この 366 カテゴリに含まれるレビューは 252,550 件であり，そのうち 20.7%のレビューにオノマトペが使用されていることになる．ここから，オノマトペが使用されるドメインには偏りがあり，商品の感想を記述する際に一部のドメインにおいてオノマトペが高頻度で出現していることが明らかになった．

表 2 調査対象としたオノマトペ

大カテゴリ	小カテゴリ	語数	オノマトペの例
程度	やわらかい	71	しんなり
	かたい	35	かちかち
動き・変化	落ちる	72	ばさっ
	折れる	33	ぽきん
	ゆれる	49	ぐらぐら
	切る・切れる	52	すぱっ
	破る・破れる	18	びりびり
	貼る・くっつく	21	ぺたっ
	刺す	28	ちくり
	曲がる・しわがよる	22	うねうね
形・状態	張る・膨らむ	31	むくむく
	光る・輝く	41	ぴかぴか
	焼く・焼ける	15	こんがり
	煮る	7	ぐつぐつ
	粘る・ぬめる	41	ぎとぎと
	かわいた	24	ぱさぱさ
	のびる・縮む	24	すらり
	乱雑	41	ぐちゃぐちゃ
音・道具・金銭	こすれる・きしむ	87	きーきー

4. 商品カテゴリの類型化実験

オノマトペの出現頻度によって，商品カテゴリを類型化（クラスタリング）する．この実験は，各商品カテゴリにおけるオノマトペの出現傾向を明らかにし，商品カ

*3 水滴などが高い所から落ちる音／ボタン（button），牡丹
*4 ものを勢いよく打ったり置いたりするときや，ものが破裂するときのかん高い音／パン（pan，pain（仏））
*5 かたいものがこすれ合う音／キー（key）

テゴリ-オノマトペのペアを得ることを目的としている．

多数の文書データがあるとき，各文書を単語の出現頻度によってクラスタリングする手法として，NMF（Non-negative Matrix Factorization）[澤田 2012] や LDA（Latent Dirichlet Allocation）[Blei 2003] などがある．これらの手法は，データ中に含まれるいくつかの特徴的なトピックを発見する際に有効であるが，得られた特徴によって全てのトピックを解釈することは難しい場合がある．また，原則的にはあらかじめトピック（クラスタ）数を決めておく必要がある．本研究では，クラスタ数が未知であること，対象とする商品カテゴリすべてについて関連するオノマトペを得ようとしていることから，階層的クラスタリング手法の一つであるクラスタ分析を採用する．

4·1 手　　順

ケースクラスタ分析により，オノマトペ（変数）を手がかりに商品カテゴリ（ケース）を分類する．このとき，オノマトペは表 2 の小カテゴリを 1 つの単位とし，小カテゴリごとにクラスタ分析を行う．個体間非類似度計算には平方ユークリッド距離を用い，クラスタ結合手法にはウォード法を用いる [石川 2010]．次節以降で実際に分析を行うデータの詳細を述べる．

§1 商品カテゴリの統廃合

9,170 の商品カテゴリとそれらに含まれる商品の具体例を第一著者が調査したところ，統合あるいは削除すべきカテゴリが存在していることが明らかになった．例えば，“サングラス” というカテゴリは最下層に 2 つあるが，それらの上位カテゴリはレディースファッションとメンズファッションであった．サングラスの特徴を記述する上で，女性用の商品と男性用の商品の間に大きな差異はないと考えられる．したがって，本質的な差がなく区別する必要がないと第一著者が判断したカテゴリは統合することとした．また，“パーツ（その他）” というカテゴリはオートバイ用品の下位カテゴリであり，ヘルメットホルダーやシートカバー，レッグガードなど，対象となる商品が多岐にわたっている．このような商品カテゴリは削除することとした．

オノマトペを含むレビューが抽出された 366 カテゴリを人手で確認し統廃合を行ったところ，62 カテゴリが 30 カテゴリに統合され（3 カテゴリが統合されたものが 2 例），43 カテゴリが削除され，最終的には 291 カテゴリとなった．

§2 頻度表

クラスタ分析の入力として使用する頻度表を作成する．オノマトペが変数，商品カテゴリがケースであるので，ある商品カテゴリのレビュー文に，あるオノマトペが出現する頻度の情報をすべての組み合わせについてまとめたものが必要である．例えば，小カテゴリ “やわらかい” のクラスタ分析を行うには，商品カテゴリ 9,170 ×オノマトペ 71 語の頻度表を作成することになる．ただし，小カテゴリ “やわらかい” では，オノマトペが含まれるレビューが存在する商品カテゴリは 244 個，1 回以上出現したオノマトペは 50 語であるため，分析対象となる頻度表は最大で 244 × 50 のサイズとなる．他の小カテゴリについても同様にカウントすると，商品カテゴリ数は最大で 279 個（小カテゴリ “こすれる・きしむ”），最小で 144 個（小カテゴリ “粘る・ぬめる”），1 回以上出現したオノマトペは最大で 51 語（小カテゴリ “こすれる・きしむ”），最小で 17 語（小カテゴリ “のびる・縮む”）である．

上述した商品カテゴリ 244 ×オノマトペ 50 語の頻度表は，データが疎であるという問題がある．また，極端に出現頻度の低いオノマトペは分析対象として適切ではない．そこで，以下の条件に基づいて頻度表を作成する．

(1) オノマトペを含むレビューが 5 件以上存在する商品カテゴリのみを分析対象とする．
(2) 条件 (1) を満たす商品カテゴリのうちオノマトペを含むレビューの件数が多いものから順に最大 50 個の商品カテゴリを選択する．
(3) 条件 (2) で選択された商品カテゴリに 5 回以上出現したオノマトペのみを分析対象とする．

条件 (2) により排除された商品カテゴリは総じてオノマトペの出現頻度が低い．それらの商品カテゴリを含めてクラスタ分析を行うと，“オノマトペの出現頻度が低い” という特徴をもつクラスタが大きくなり，他のクラスタに変化はないことを予備実験で確認している．したがって，条件 (2) の処理はクラスタ分析の結果に大きな影響を与えない．

なお，抽出されたレビューの件数は商品カテゴリによって異なるため，粗頻度ではなく相対頻度（オノマトペが出現したレビューの当該商品カテゴリにおけるレビュー全体に占める割合）を用いる．実際の頻度表を簡略化したものを表 3 に示す．例えば，“トリートメント” の商品カテゴリに関する商品レビューは 1,000 件[*6]抽出され，そのうち 194 件に “さらさら” というオノマトペが含まれていたため，頻度表の値は 19.4%となる．

表 2 の小カテゴリのうち，オノマトペを含むレビューが 1,000 件に満たなかった “折れる”，“貼る・くっつく”，“刺す”，“曲がる・しわがよる”，“焼く・焼ける”，“煮る” はデータ数が十分ではないと判断し，分析の対象外とした．したがって，残る 13 カテゴリについて頻度表を作成し，クラスタ分析を行った．

4·2 結　　果

クラスタ分析の結果の一例として，“やわらかい” に関するオノマトペを変数にした場合のデンドログラムを図 1 に示す．

階層的クラスタリング手法はあらかじめクラスタ数を定めないでクラスタリングを行う手法であるため，得ら

∗6 Yahoo! Japan 商品レビュー検索 API で抽出できる最大件数

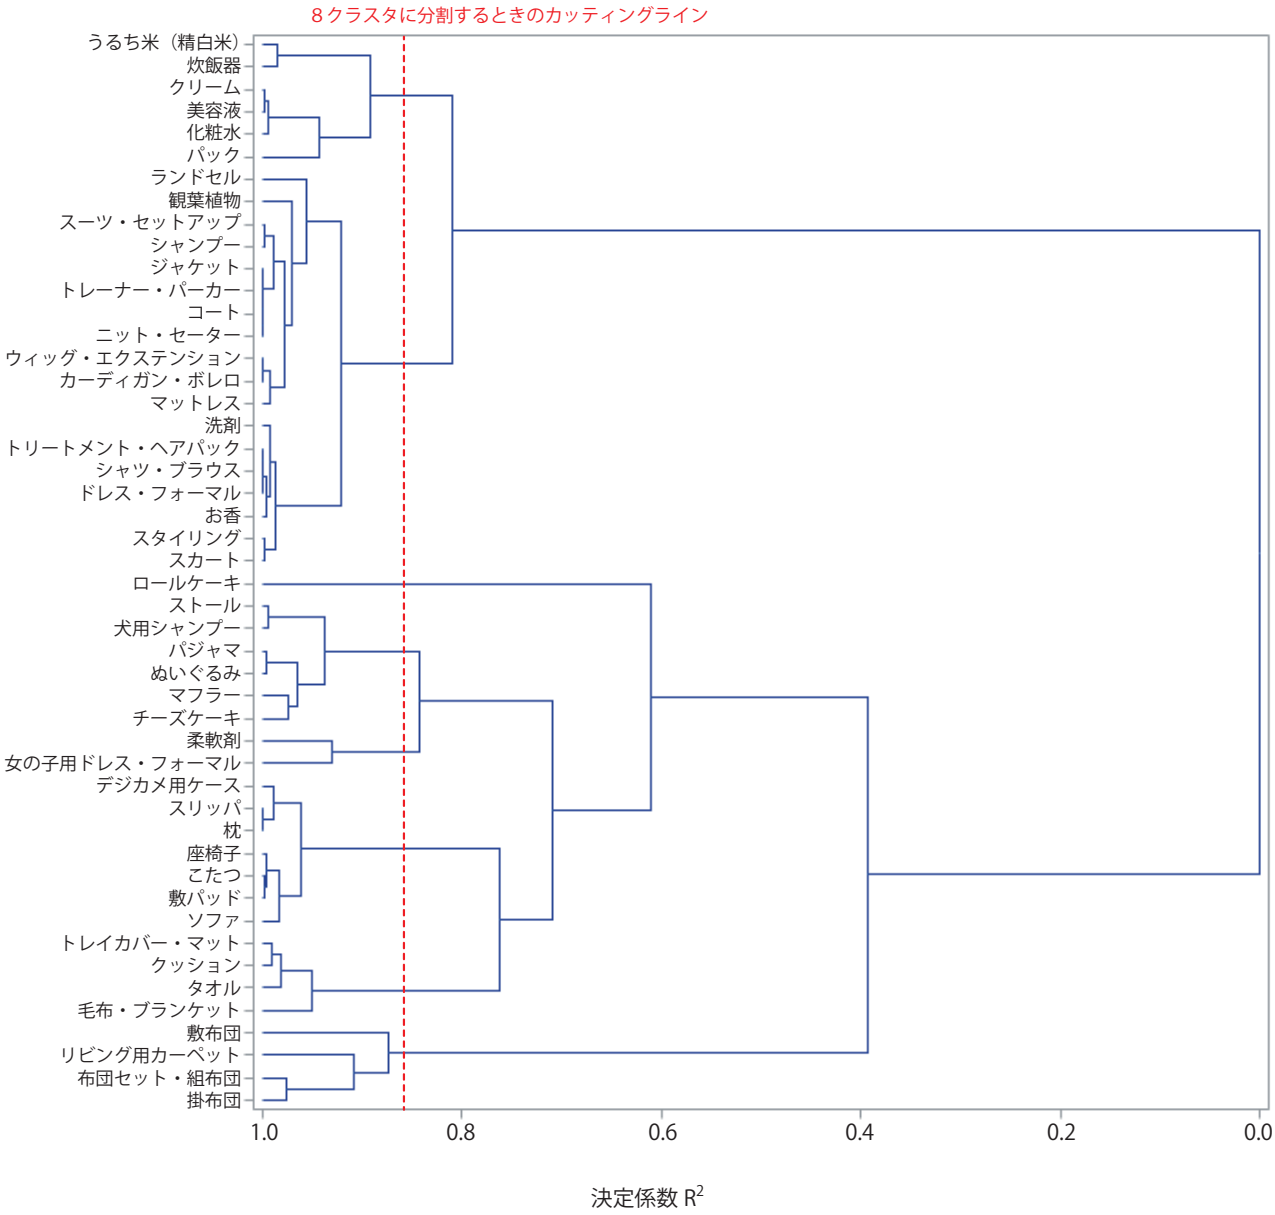


図 1 デンドログラム（やわらかい）

表 3 “かわいた” に関する頻度表（一部）

商品カテゴリ	さらさら	さっぱり	さらっ	ぱさぱさ
トリートメント	19.4	1.0	2.3	2.8
シャンプー	11.1	4.3	1.0	2.0
化粧水	1.0	9.0	1.8	0.1
敷パッド	6.0	0.9	5.5	0.1
クリーム	1.3	3.1	3.6	0.0
クレンジング	1.1	8.0	1.5	0.0

れたデンドログラムのどの段階をクラスタリング結果として採用するかを決めなければならない [Mooi 2011][齋藤 1985]．クラスタ数の決定には明確な方法がなく，多くの場合，分析者にとって良い解釈が得られる段階を採用することになる．その他の基準としては，結合距離が長くなる段階を選択する，各クラスタにおける各変数の平均値にクラスタ間で有意な差があるかを検討する，各種統計量基準 [Milligan 1985] を考慮する，などが挙げられる．

本研究では，できるだけ客観的な指標に基づいてクラスタ数を決定するために，目視での確認に加え，CCC 基準 [Sarle 1983]，疑似 F 統計量 [Calinski 1974]，疑似 t^2 統計量 [Milligan 1987] の 3 種類を考慮して判断する．CCC 基準は，最大値となるときに適切と推測されるクラスタ数を表し，2 あるいは 3 以上のスコアが望ましいとされる．疑似 F 統計量は各ステップでの全クラスタ間の分割度合いを示し，値が大きいほど結びつきが強く，適切に分割されていることを示す．疑似 t^2 統計量はクラスタリングを行う際に結合した 2 つのクラスタ間の分割度合い

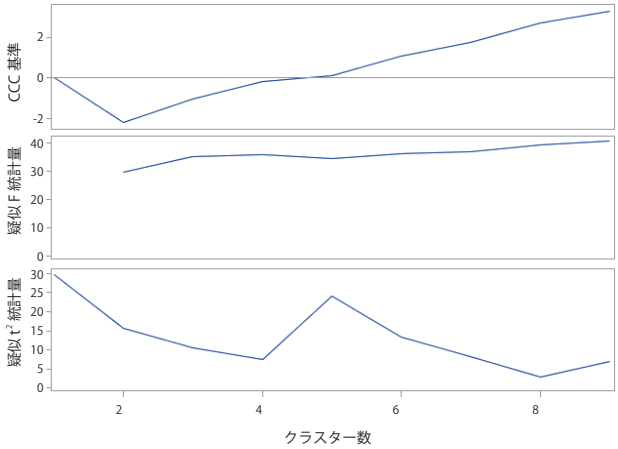


図 2 クラスタ数決定の基準（やわらかい）

表 4 クラスタリング結果

	オノマトペ	商品カテゴリ	クラスタ数
やわらかい	15	48	8
かたい	12	46	9
落ちる	9	47	5
ゆれる	8	46	9
切る・切れる	10	23	4
破る・破れる	9	47	9
張る・膨らむ	12	47	9
光る・輝く	12	49	9
粘る・ぬめる	12	21	5
かわいた	15	47	9
のびる・縮む	13	49	8
乱雑	11	49	8
こすれる・きしむ	20	47	9

を示し，正の方向に最も大きく変化する直前のクラスタ数を選ぶと良い．図 2 に “やわらかい” の分析結果を対象とした CCC 基準，疑似 F 統計量，疑似 t^2 統計量の値を示す．

以上の方法により，各オノマトペ小カテゴリでクラスタ数を定めた結果を表 4 に示す．オノマトペの小カテゴリ “やわらかい” では，4·1·2 節で述べた条件を満たす 15 語のオノマトペで 48 の商品カテゴリを分類したところ，8 つのクラスタが得られたことを示している．図 1 と照らし合わせると，第 1 クラスタの要素は { うるち米（精白米）, 炊飯器, クリーム, 美容液, 化粧水, パック } の 6 つ，第 8 クラスタの要素は { 敷布団，リビング用カーペット, 布団セット・組布団, 掛布団 } の 4 つとなる．クラスタ番号に優劣などの意味はない．

次に，関連性の高い商品カテゴリ-オノマトペのペアを抽出する．表 4 に示した各クラスタを特徴づけているオノマトペを，それぞれのクラスタにおける各変数の平均値（つまり，オノマトペの出現頻度の平均値）によって判別する．例として，図 3 に “やわらかい” の第 1 クラスタ〜第 8 クラスタそれぞれの変数の平均値を示す．グラフより，“やわらかい” の第 1 クラスタ { うるち米（精白米）, 炊飯器, クリーム, 美容液, 化粧水, パック } には “ふっくら” と “ぷるぷる” が寄与しているといえる．この結果から,【うるち米（精白米）-“ふっくら”】や【クリーム-“ぷるぷる”】などの 12 組の商品カテゴリ-オノマトペペアを得る．この実験を通して，13 種類のオノマトペ小カテゴリのすべてのクラスタについて対応するオノマトペを決定し，商品カテゴリ-オノマトペのペアを 978 組得た．

4·3 考　　察

まず，クラスタ分析により得られたクラスタについて考察する．“やわらかい” の第 1 クラスタの要素は，食品，電化製品，化粧品で構成されているが，一般的なクラスタリングではこれらの要素が一つのクラスタに属するとは考えにくい．“かわいた” に関するオノマトペでも，{ アイスクリーム，チーズケーキ，洗顔せっけん，クレンジング，化粧水，せっけん } という一見すると共存しにくい要素から構成されるクラスタが得られた．これらの結果は，オノマトペを媒介とすることで，消費者が商品に求める特性によって商品カテゴリを分類できることを示唆している．

次に，商品カテゴリ-オノマトペのペアについて考察する．“やわらかい” の第 1 クラスタの要素から,【炊飯器-“ふっくら”】や【うるち米（精白米）-“ふっくら”】というペアが得られた．うるち米や炊飯器は，それ自体がやわらかいものではない．しかし，それらの購入者は，うるち米・炊飯器自体の素材や質感を重視するのではなく，炊き上がった米飯についての感想をレビューに記述すると考えられる．したがって，この結果は日本語母語話者にとって自然なものである．オノマトペが一定数含まれる商品カテゴリのレビューに対してクラスタ分析を行うことによって，消費者の嗜好を反映した類型化が可能であることが示された．

表 5 に示すように，実際の頻度表から “ふっくら” が高頻度であった上位 10 カテゴリを抜粋し，詳細を分析する．第 8 クラスタの要素 { 敷布団，リビング用カーペット, 布団セット・組布団, 掛布団 } も，第 1 クラスタと同程度の頻度で “ふっくら” が共起している．しかし，第 8 クラスタでは，“ふかふか”，“ふわふわ”，“ふんわり” が “ふっくら” よりも高頻度で出現しており，その点が第 1 クラスタと第 8 クラスタの相違点である．以上より，第 1 クラスタは，“ふっくら” と高頻度で共起し，“ふかふか”，“ふわふわ” とは共起しにくいという特徴をもった商品カテゴリの集合であるといえる．一方，第 8 クラスタは，“ふっくら” と共起するが，“ふかふか”，“ふわふわ”，“ふんわり” とより高頻度で共起する商品カテゴリの集合である．

ここで注意しなければならないのは，第 1 クラスタの要素が必ずしも “ぷるぷる” と高頻度で共起するとは限らない点である．本研究で使用したデータにおいては，炊飯器やうるち米のレビュー文に “ぷるぷる” は出現していない．しかし，我々は，類似した特徴をもつ商品カテゴ

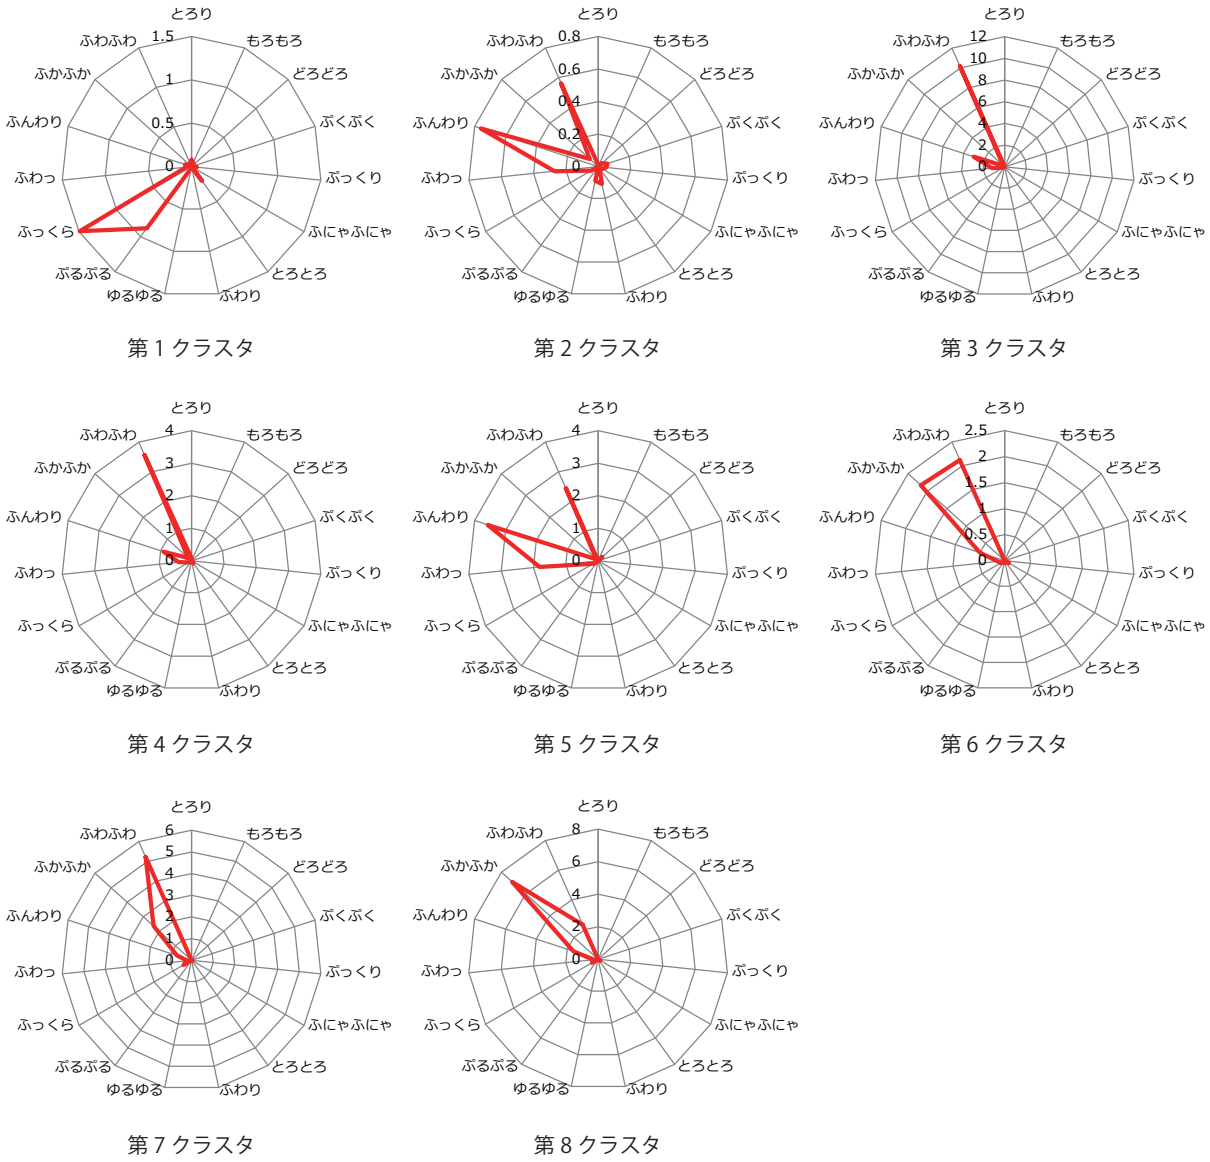


図 3 第 1〜8 クラスタの変数の平均値（やわらかい）

リ間では，オノマトペの使用傾向も類似するのではないかと考えている．つまり，炊飯器やうるち米を描写する際に “ぷるぷる” を用いる可能性があるということである．これより,【炊飯器-“ぷるぷる”】や【うるち米（精白米）-“ぷるぷる”】のような，実験データでは共起していないがクラスタ分析によって抽出されたペアを潜在的なペアと呼ぶこととする．本実験で得られた 978 組のペアには，208 組の潜在的なペアが含まれている．

5. 商品カテゴリ-オノマトペペアの妥当性評価実験

4 章で得られた 978 組の商品カテゴリ-オノマトペのペアの妥当性をアンケートによって評価する．

5·1 手　　順

商品カテゴリ-オノマトペのペアについて，それぞれを 10 名の被験者によって評価していただいた．ただし，被験者の負担を考慮して，978 組のペアを 3 分割し，各被験者は 326 組のペアの評価を行う．被験者は 10 代〜30 代の 30 名で，その内訳は男性：大学院生 8 名，社会人 5 名，女性：大学生 10 名，大学院生 2 名，社会人 5 名である．

被験者にオノマトペと商品カテゴリが印字されたアンケート用紙（イメージ図参照）を配布し，アンケートを実施した．

5·2 結 果 と 考 察

978 組のペアのうち，被験者の過半数が適切だと判断したものは 658 組（67.3%），過半数が不適切だと判断し

表 5 頻度表の抜粋（“ふっくら” の高頻度 10 カテゴリ）

商品カテゴリ	クラスタ	ふっくら	ぷるぷる	とろとろ	ふんわり	ふかふか	ふわふわ
炊飯器	1	3.5573	0.0000	0.0000	0.0000	0.0000	0.1318
うるち米	1	2.2321	0.0000	0.0000	0.1116	0.0000	0.0000
化粧水	1	0.9000	0.5000	0.7000	0.0000	0.0000	0.1000
美容液	1	0.9000	1.2000	0.2000	0.2000	0.0000	0.0000
布団セット・組布団	8	0.8255	0.0000	0.0000	1.6509	8.1368	5.4245
パック	1	0.7508	2.8529	0.3003	0.1502	0.0000	0.0000
リビング用カーペット	8	0.7102	0.0000	0.0000	0.1420	2.8409	4.6875
掛布団	8	0.6000	0.0000	0.0000	2.6000	7.0000	6.0000
クリーム	1	0.6000	0.7000	0.0000	0.0000	0.1000	0.0000
敷布団	8	0.4360	0.0000	0.0000	1.5988	7.1221	2.3256

アンケート用紙のイメージ

「商品カテゴリ」欄に記載された商品の感想を説明するときに「単語」欄に記載されたオノマトペを使うことは適切かどうかを判断してください。わからない場合は「不明」を選択してください。ただし、オノマトペが直接商品を評価しているとします。

例） オムライス-がらがら

正 「がらがらのオムライス」は一般的に使われるか、という観点で判断する

誤 「がらがらに空いている洋食屋さんのオムライス」という想像をして判断する

商品カテゴリ	単語	適切	不適切	不明
指輪	きらきら			
ニット帽	すとん			
ベッド	ゆらゆら			
…	…			

たものは 221 組（32.6%），残りの 99 組は意見が分かれるという結果となった．この実験で適切だと判断された 658 ペアをレコードとする商品カテゴリ-オノマトペペアのデータベースの構築を行った．

適切だと判断された 658 組のペアの中には潜在的なペアが 79 組含まれていた．具体例としては，【T シャツ・カットソー（子供服）-“すとん”】，【スタイリング剤-“ぺたぺた”】，【カーテン-“てろてろ”】などが挙げられる．このことにより，実験データには出現していないが，関連性が高いペアがクラスタ分析によって抽出されていることが明らかになった．この手法を用いることで，商品カテゴリ-オノマトペのペアを得る際のデータスパースネスの問題を解消することにもつながる．

不適切だと判断されたペアの中には，【シャンプー-“ぎしぎし”】，【ワンピース-“ざっくり”】など，一見すると適切だと思われる例も含まれていた．

【シャンプー-“ぎしぎし”】の “ぎしぎし” は，シャンプーを使用した際の毛髪の質感を表現しており，シャンプーそのものを説明していない．今回のアンケートではオノマトペが直接商品を評価しているものだと解釈して判断するよう指示したため，不適切だと判断された．このようなペアは他にも存在し，【フライパン-“ぱりぱり”】，【美容液-“ふっくら”】などが挙げられる．これらのペアの妥当性を評価するために，今後，文脈情報を付与した形式での実験を行う予定である．

“ざっくり” は “豪快にものを切ったり，割ったり突き刺したりする音やさま”，“切り口や割れ目などが見た目にも無惨にえぐられたり，割れたりしているさま” や “衣服などを無造作に着ているさま”，“布地などの手ざわりや織り方，編み方が粗くて厚みの感じられるさま” などの意味をもつ [小野 2007]．ワンピースを描写する場合は，後者 2 つの意味で用いられると考えられる．ワンピースのカテゴリのレビューデータを確認すると，

- 普段着用に ザックリ 着られるものをと思い購入しました。
- ザックリ としていて体型カバーがさりげないのが良い。
- 期待していたより、編み目が ザックリ で薄くて今の時期には向かないかな。

などのフレーズが含まれていた．このように，実際にレビュー中で使用されているペアであるにも関わらず，このペアは男性の被験者に不適切だと判断されることが多かった．（不適切：男性 5 名，女性 1 名）不適切であると判断された明確な理由は不明だが，男性にとってワンピースは馴染みの薄いアイテムであり，ワンピースの質感を描写するという経験が少ないためではないかと考えられる．似たような例として，【口紅-“するする”】，【コート-“すとん”】などのペアが男性から不適切だと判断された．被験者の属性を考慮した実験を行うことも今後の課題である．

6. 商品カテゴリ-オノマトペペアの評判情報抽出に対する有効性

商品カテゴリ-オノマトペのペアを評判情報抽出技術に利活用することの有効性を検証する．

商品レビューには，梱包や配送に対してのクレームのみが記述されているもの，“良い商品でした．”などのように商品についての具体的な記述がないものなども存在する．数ある商品レビューから消費者にとって有益な情報を得るためには，商品の具体的な特徴が記述されている商品レビューを抽出することが重要である．オノマトペは細かいニュアンスを伝えることに長けているため，オノマトペが含まれているレビューは商品についての感想が述べられている可能性が高いと考えられる．

また，オノマトペには多義性があり，使用されるドメインによって異なる意味をもつことがある．その意味の差は，微妙なニュアンスの違いにとどまらず，肯否の反転に及ぶ場合もある．したがって，商品カテゴリ-オノマトペのペアごとに肯否極性が存在すると考えられる．

以上より，①オノマトペが含まれているレビューには，商品の使用感などの感想が記述されているのか，②商品カテゴリ-オノマトペの各ペアに肯否極性が存在するのか，という観点で調査を行う．

6·1 商品に対する感想の有無の調査

§1 手 順

5 章で適切だと判断された商品カテゴリ-オノマトペペア*7に該当するレビューは 5,574 件存在した．これらのレビュー中に出現するオノマトペが，購入した商品の特徴や商品に対する感想を直接表現しているか否かを第一著者が人手で調査した．ここで，オノマトペが商品の特徴や使用感を説明しているレビューを有効レビューと呼ぶ．購入した商品が届く前，あるいは未使用の段階で書かれているレビュー，オノマトペが配送や梱包について説明しているレビュー，オノマトペが商品を使用する前の状態を説明しているレビュー，は有効レビューではないとする．

§2 結果と考察

オノマトペが商品の特徴や使用感を説明しているレビューは 5,280 件（94.73%）存在した．有効レビューが存在する商品カテゴリ-オノマトペペアは 501 組である．したがって，オノマトペが含まれているレビューには，商品の使用感などの感想が高い割合で記述されているといえる．

有効レビューではないと判定されたレビューには，次のような例がある．

- 引越しと同時に前のこたつ布団を捨てたので … まだ使ってないけれど ペラペラ 布団でないことに期待をこめて（こたつ）
- ギフトボックスに入ってきましたが、箱の中で商品が ごちゃごちゃ になっていました。（ペアブレスレット）
- 石鹸シャンプーだけでは バサバサ になりやすいので馬油シャンプーを購入してみました（シャンプー）

*7 潜在的なペアを除いた 579 組

6·2 肯否極性の調査

§1 手 順

全てのレビューには，購入者によってレビュー評価点が付与されている．レビュー評価点は商品に対する満足度を 1〜5 の整数で表したもので，値が大きいほど満足度が高いことを意味する．

商品カテゴリ-オノマトペペアごとに，レビュー評価点の平均値を求め，各ペアの肯否極性を調査する．極性の境界の閾値は，レビュー評価点の分布を考慮して決める必要があるが，ここでは簡易的に以下のように定める．レビュー評価点の平均値が 3.0 未満のペアは否定（Neg），3.0 より大きいペアは肯定（Pos），3.0 のペアは肯定・否定のどちらの評判も含まれていると考えて極性無しとする．

肯否極性の判定の際には，否定表現を考慮しなければならない．商品レビューに含まれるオノマトペのうち，1 割程度は否定表現を伴っていると報告されている [佐藤 2013]．例えば，【クリーム-“べたべた”】ペアに該当するレビューに “伸びがよく べたべた しない最高のクリームです” という記述がある．このレビューに付与されたレビュー評価点は最高点の 5 であるが，【クリーム-“べたべた”】ペアに肯定の極性を結びつけることは望ましくない．否定表現は肯否極性を反転させると考え，否定表現を伴ってオノマトペが出現した場合，レビュー評価点を修正する．具体的には，5 と 1，4 と 2 を入れ替える．否定表現は多様であり，機械的に抽出することは困難なため，5,280 件の有効レビューを第一著者が人手で調査する．

§2 結果と考察

肯定と判定された商品カテゴリ-オノマトペペアは 327 組，否定は 143 組，極性なしは 31 組となった．有効レビューが存在しなかったペア（潜在的なペアも含む）には，そのオノマトペを含むレビュー全体の評価点の平均値で極性を与える．これにより，肯定は 396 組，否定は 225 組，極性なしは 37 組となる．

一例として，表 6 に “もこもこ” に関連するペアの極性判定の結果をまとめる．“もこもこ” が含まれる全ての商品レビューを対象にレビュー評価点の平均値を求めると 4.21 となる．したがって，一般に “もこもこ” は肯定的な意味で用いられることが予想される．一方，表 6 によると，2 つの商品カテゴリが極性無し，2 つの商品カテゴリが否定の極性と判定されている．表 7 に否定の極性をもつ商品カテゴリのレビューの例をまとめる．レビューの内容から，これらの商品カテゴリでは “もこもこ” という特性は好まれないことが読み取れる．

他に，オノマトペがもつ一般的なイメージと異なる極性をもつペアとして，【柔軟剤-“どろどろ”】（Pos）や【ジー

表 6 “もこもこ” の商品カテゴリごとのレビュー評価点と肯否極性

オノマトペ	商品カテゴリ	レビュー評価点平均値	極性
	ウィッグ、エクステンション	1.00	neg
	ダウンジャケット	2.60	neg
	シャツ、ブラウス（レディス）	3.00	-
	スカート	3.00	-
	こたつ	3.20	pos
	コート	3.31	pos
	クッション	3.50	pos
	ニット、セーター	3.50	pos
	ソファ	3.57	pos
	カットソー（レディス・メンズ）	3.67	pos
	カーディガン、ボレロ	3.94	pos
もこもこ	パジャマ	3.96	pos
	ジャケット	4.00	pos
	タオル	4.25	pos
	スリッパ	4.25	pos
	トレーナー、パーカー	4.27	pos
	ブーツ	4.37	pos
	座いす	4.40	pos
	敷パッド	4.60	pos
	枕	4.67	pos
	毛布、ブランケット	4.75	pos
	マットレス（寝具）	5.00	pos
	手芸用生地	-	pos
	トイレカバー、マット	-	pos
	全商品レビュー	4.21	pos

表 7 “もこもこ” が否定的な意味で使用される例

商品カテゴリ	レビュー（抜粋）	レビュー評価点
ウィッグ、エクステンション	おろした初日から束で毛が抜けるし、サイズが大きいのか裏地のネットが もこもこ してフィットしないで浮いてる…	1
ダウンジャケット	ダウンジャケットにありがちな モコモコ 感が無く、スリムなシルエットが気に入りました。	5 → 1（否定）
	見た感じは薄めですが、ボタンもしっかり止まり防寒性は申し分ないですし、モコモコ していないので動き易いです。	5 → 1（否定）

ンズ-“ごわごわ”】（Pos）などが存在した．これらの結果から，簡易的な方法ではあるが，オノマトペは使用されるドメインによって異なる肯否極性をもつ場合があることが示された．

7. お わ り に

本論文では，Yahoo! ショッピング商品レビュー 729,865 件を対象として，614 語のオノマトペの出現頻度を調査した結果について述べた．614 語のオノマトペのうち，482 語が合計で 52,212 回レビューに出現しており，100 回以上出現したオノマトペは 82 語であった．

さらに，“やわらかい”，“かたい” などの単位で，商品カテゴリをオノマトペの出現頻度で分類するためにクラスタ分析を行い，関連性が高いと考えられる商品カテゴリ-オノマトペのペアを 978 組抽出した．抽出された 978 ペアの妥当性を複数被験者によって評価した結果，658 組が適切なペアだと判断された．また，658 組のペアに該当する商品レビューを人手で調査し，オノマトペが含まれているレビューには，商品の使用感などの感想が記述されている可能性が高いこと，商品カテゴリによってオノマトペの肯否極性が異なることを示した．

これらの結果から，オノマトペを評判情報抽出技術へ応用することの有効性を確認した．今後は，オノマトペを活用した商品推薦システムの構築を行う予定である．

謝　　辞

本研究は科研費（課題番号：23700256）の助成を受けたものである．

◇ 参 考 文 献 ◇

[Blei 2003] D. Blei, A. Ng, and M. Jordan: Latent Dirichlet Allocation, Journal of Machine Learning Research, vol.3, pp.993-1022, 2003.
[Calinski 1974] T. Calinski, and J. Harabasz: A dendrite method for cluster analysis, Communications in Statistics, vol.3, pp.1-27, 1974.
[古武 2010] 古武 泰樹, 佐藤 理史: 用例に基づくオノマトペ用法辞書の編纂, 言語処理学会第 16 回年次大会発表論文集, pp.994-997, 2010.
[石川 2010] 石川 慎一郎, 前田 忠彦, 山崎 誠 編: 言語研究のための統計入門, くろしお出版, 2010.
[鍛治 2007] 鍛治 伸裕, 喜連川 優: 自動構築した評価文コーパスからの評価表現辞書の構築, 日本データベース学会論文誌, Vol.6, No.1, pp.41-44, 2007.
[経済産業省 2012] 経済産業省: 平成 24 年度我が国情報経済社会における基盤整備（電子商取引に関する市場調査）, 2013.
[小林 2005] 小林 のぞみ, 乾 健太郎, 松本 裕治, 立石 健二, 福島 俊一: 意見抽出のための評価表現の収集, 自然言語処理 12(3), pp.203-222, 2005.
[Milligan 1985] G. Milligan and M. Cooper: An examination of procedures of determining the number of cluster in a data set, Psychometrika, vol.50, no.2, pp.159-179, 1985.
[Milligan 1987] G. Milligan and M. Cooper: Methodology Review: Clustering Methods, Applied Psychological Measurement, vol.11, pp.329-354, 1987.
[Mooi 2011] E. Mooi and M. Sarstedt: Cluster Analysis, IN A Concise Guide to Market Research, pp.237-284, Springer-Verlag Berlin Heidelberg, 2011.
[小野 2007] 小野 正弘: 擬音語・擬態語 4500 日本語オノマトペ辞典, 小学館, 2007.
[Pang 2002] B. Pang, Lillian Lee, and Shivakumar Vaihyanathan: Thumbs up? Sentiment Classification using Machine Learning Techniques, In Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP), pp.79-86, 2002.
[齋藤 1985] 齋藤 堯幸, 宿久 洋: 関連性データの解析法―多次元尺度構成法とクラスタ分析法, 共立出版, 2006.
[佐野 2012] 佐野 大樹: アプレイザル理論を基底とした評価表現の分類と辞書の構築, 国立国語研究所論集 (NINJAL Research Papers) 3, pp.53-83, 2012.
[Sarle 1983] S. Sarle: Cubic Clustering Criterion, SAS Technical Report A-108, Cary, N.C., SAS Institute, 1983.
[佐藤 2013] 佐藤 宏亮, 内田 ゆず, 米山 淳: 否定表現を考慮したカスタマーレビューに出現するオノマトペに基づく商品カテゴリの分類, 第 29 回ファジィシステムシンポジウム講演論文集, pp.758-761, 2013.
[澤田 2012] 澤田 宏: 非負値行列因子分解 NMF の基礎とデータ/信号解析への応用, 電子情報通信学会誌, Vol.95, No.9, pp.829-833, 2012.
[高村 2006] 高村 大也, 乾 孝司, 奥村 学: スピンモデルによる単語の感情極性抽出, 情報処理学会論文誌, Vol.47, No.02, pp.627-637, 2006.
[Turney 2002] P. Turney: Thumbs Up or Thumbs Down?: semantic orientation applied to unsupervised classification of reviews, Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL'02), pp.417-424, 2002.
[内田 2013] 内田 ゆず, 長谷川 大, 荒木 健治, 米山 淳: 商品レビュー文におけるオノマトペと商品カテゴリの関係についての予備調査, 言語処理学会第 19 回年次大会 (NLP2013) 発表論文集, pp.810-813, 2013.

〔担当委員：小松 孝徳〕

2014 年 04 月 30 日　受理

著 者 紹 介



内田　ゆず（正会員）

2005 年北海道大学工学部情報工学科卒業．2010 年同大大学院博士後期課程修了．博士（情報科学）．同年，青山学院大学理工学部助手．2012 年より同助教．2014 年北海学園大学工学部電子情報工学科准教授，現在に至る．自然言語処理，特に概念獲得システム，日本語オノマトペなどに関する研究に従事．日本知能情報ファジィ学会，電子情報通信学会，言語処理学会，各会員．



荒木　健治（正会員）

1982 年北海道大学工学部電子工学科卒業．1988 年同大学大学院工学研究科電子工学専攻博士後期課程修了．同年，北海学園大学工学部電子情報工学科助手．1998 年同教授．1998 年北海道大学大学院工学研究科電子情報工学専攻助教授．2004 年同大学大学院情報科学研究科メディアネットワーク専攻教授，現在に至る．工学博士．自然言語処理の研究に従事．電子情報通信学会，IEEE 等，各会員．