対して 0.340 勝る結果である．一方，適合率を優先する場合は N を低い値にすれば良い．例えば，抽出ノード数 N を 30 にした場合，適合率は 0.733 となり向上する．第二の有用性は，任意の状況に対応できることである．実験では「睡眠」に注目したが，任意の状況語を入力することであらゆる状況の行動を自動抽出できるため，知識生成に人手コストが発生しない．

5 関連研究

5.1 人手による行動オントロジの作成

人手によって行動と固有名詞との関連性を生成するプロジェクトとしては，MIT の Open Mind Common Sense(OMCS)[8] がある．その後，ConceptNet と名称を変え [3]，他言語化への対応や SQL への対応を行うことでバージョンを更新してきた．2014 年現在では，ConceptNet5[9] に更新しており，DBPedia や FreeBase, WordNet などの大量の web ページから抽出された知識を融合している．DBPedia に代表されるような，固有名詞とそれらの関係を示す構造データは既に存在する一方で，行動とそれらの関係を示す構造データは存在していない．従って，ConceptNet5 内における行動に関する知識は，OMCS のクラウドソーシングによる人手生成に依存している．別の研究としては，室内でのロボットの自動制御を目的に人の日常生活における行動の抽出をする研究 [2] もあるが，同様にクラウドソーシングで人手で生成することを前提としている．

5.2 大規模テキストからの行動情報の自動獲得

倉島ら [11] は，NP と VP で構成される人間の行動を，データ構造（時間，空間，行動，対象，感情）で構造化した．その上で，興味深い行動の推薦として，リフト値を用いた手法を提案した．一方本稿では，行動の前後関係に着目し，行動をノードとするグラフで行動を体系化し，関連性を考慮した知識の獲得手法を提案している．

Fukazawa ら [1] は，手段と目的の関係にある行動の関係性を自己相互情報量を用いて自動構築する手法を提案した．しかしながら，その手法は，名詞句を同じとする行動に限定しており，ある行動に関連する行動を網羅的に抽出する手法とはいえない．一方本稿では，任意の NP を用いることが可能であり，人間の行動に関してより広範な知識の構築が可能である．

6 おわりに

本稿では，特定状況下における実世界行動ネットワークを自動構築する手法を提案し，その精度評価を行った．精度評価では，「睡眠」という状況に注目し，自動構築手法，手動構築手法，オープンデータ (conceptNet5) の三者を比較評価した．評価の結果，本稿で提案した自動構築手法の精度は，手動構築やオープンデータに対して適合率，再現率，F 値全てで勝る精度を示した．また，抽出ノード数を増やした場合は，適合率は若干さがるものの再現率が大幅に上がるために F 値で手動構築に対して 0.151，オープンデータに対して 0.340 勝ることを確認した．

今後の課題は，自動構築の精度向上と行動間の関連性の予測である．特に前者については抽出精度の向上だけでなく，情報源の CGM にユーザ属性推定を追加することで，より個人化した行動ネットの構築とその検証も課題である．

参考文献

[1] Y. Fukazawa and J. Ota. Automatic modeling of user's real world activities from the web for semantic ir. In *Proceedings of the 3rd International Semantic Search Workshop in WWW2010*, page 5. ACM, 2010.

[2] R. Gupta and M. J. Kochenderfer. Common sense data acquisition for indoor mobile robots. In *AAAI*, pages 605–610, 2004.

[3] C. Havasi, R. Speer, and J. Alonso. Conceptnet 3: a flexible, multilingual semantic network for common sense knowledge. In *Recent Advances in Natural Language Processing*, pages 27–29, 2007.

[4] T. Kudo and Y. Matsumoto. Fast methods for kernel-based text analysis. In *Proceedings of the 41st Annual Meeting on Association for Computational Linguistics-Volume 1*, pages 24–31. Association for Computational Linguistics, 2003.

[5] T. Kudo, K. Yamamoto, and Y. Matsumoto. Applying conditional random fields to japanese morphological analysis. In *EMNLP*, volume 4, pages 230–237, 2004.

[6] D. Riboni and C. Bettini. Cosar: Hybrid reasoning for context-aware activity recognition. *Personal Ubiquitous Comput.*, 15(3):271–289, Mar. 2011.

[7] N. D. Rodríguez, M. P. Cuéllar, J. Lilius, and M. D. Calvo-Flores. A survey on ontologies for human behavior recognition. *ACM Computing Surveys (CSUR)*, 46(4):43, 2014.

[8] P. Singh, T. Lin, E. T. Mueller, G. Lim, T. Perkins, and W. L. Zhu. Open mind common sense: Knowledge acquisition from the general public. In *On the Move to Meaningful Internet Systems 2002: CoopIS, DOA, and ODBASE*, pages 1223–1237. Springer, 2002.

[9] R. Speer and C. Havasi. Representing general relational knowledge in conceptnet 5. In *LREC*, pages 3679–3686, 2012.

[10] T. van Kasteren and B. Krose. Bayesian activity recognition in residence for elders. In *Intelligent Environments, 2007. IE 07. 3rd IET International Conference on*, pages 209–212, Sept 2007.

[11] 倉島健, 藤村考, and 奥田英範. 大規模テキストからの経験マイニング. **電子情報通信学会論文誌**, 92(3):301–310, 2009.

[12] 竹内孔一, 乾健太郎, 竹内奈央, and 藤田篤. 意味の包含関係に基づく動詞項構造の細分類. **言語処理学会第 14 回年次大会発表論文集**, pages 1037–1040, 2008.

ARG WI2 No.5, 2014
WI2-2014-33

オノマトペの多義性解消における名詞の有効性

†福島 弘識, ‡内田ゆず, †荒木健治

†北海道大学大学院情報科学研究科, ‡北海学園大学

† *{Fukushima.Hironori,araki}@ist.hokudai.ac.jp*, ‡ *yuzu@hgu.jp*

概要 ブログや SNS には話し言葉による投稿が多く，オノマトペが多数存在する．それらオノマトペは，日本語に多く存在し，自然言語処理のタスクにおいても無視できない．特に複数の意味を持つオノマトペは，文中で使われている意味を判別する必要があり，機械翻訳などのタスクで問題となる．オノマトペの多義性解消にはオノマトペの係り先動詞が有効であることが確認されているが，ブログや SNS には係り先動詞がない文が存在したり，係り先動詞だけでは判別できない文も存在する．そこで本稿では，一語で擬音語と擬態語の 2 つの意味を持つオノマトペが文中においてどちらの意味で使われているか自動的に判別する手がかりとして，名詞の有効性を検証した．オノマトペの意味を決定している名詞を自動で文から抽出する手法を構築し，抽出した名詞を使用して，9 種類のオノマトペの多義性の解消を行った．オノマトペの意味を決定する名詞の自動抽出手法の精度および，文中でのオノマトペが擬音語か擬態語かの判別精度ともに，8割を大きく超える精度を達成し，オノマトペの多義性解消における名詞の有効性が確認された．

キーワード 自然言語処理，意味解析，機械翻訳

1 はじめに

近年，外国人観光客数や外国人労働者数の増加のニュースを耳にすることが多い．さらに 2020 年東京五輪の開催も決定し，日本における異文化間コミュニケーションの増加は不可避である．また，Twitter[1]や Facebook[2] などの SNS の普及に伴い，異なった母国語を持つもの同士の Web 上での交流や，情報交換を行う機会も増大している．それらを補助するために，正確な機械翻訳ツールは大きな役割を果たすと考えられる．しかし，現状では正確な機械翻訳が常に可能であるとは言い難い．特に日本語のオノマトペは 1 つの単語で擬音語としてだけでなく擬態語としても用いられ，擬態語の中でも複数の意味を持つものがあり，それらの意味を自動的に判別し，翻訳することは困難である．

先行研究[1]では，オノマトペを含む文から名詞，形容詞，動詞を抽出して素性とし，機械学習を使用してオノマトペの多義性を解消する手法を提案し，係り先動詞と名詞を素性とすることで，一定の成果を得ている．機械学習はオノマトペの多義性解消に有効な手法の 1 つといえるが，精度が訓練データの規模に依存してしまうという問題がある．オノマトペが使用される場面は小説から SNS，ブログまで多岐にわたるうえ[2]，話し言葉にも多く出現する．それらのオノマトペと共起する名詞を，オノマトペの種類ごとに網羅し，素性とするのは困難である．

そこで本研究では，日本語母語話者が同一単語で擬音語と擬態語の 2 つの意味を持つオノマトペの意味が，文中でどちらの意味で使用されているかを判別する際に，オノマトペが含まれる文中のどの単語に着目するか調査を行った．その調査を基にルールを作成し，9 種類のオノマトペについて多義性解消に必要な名詞を抽出した．抽出された名詞を解析し，名詞の持つどのような性質がオノマトペの多義性解消に有効であるかの検討を行った．

2 予備調査

2.1 多義性解消に有効な単語の調査

オノマトペの多義性解消を行うルールを作成するため，日本語母語話者が，オノマトペを含む文のどの単語に着目し，意味を決定しているのか調査を行った．本実験では，「外国人のための基本語用例辞典[3]」の擬音語，擬態語の項目に含まれ，その中で擬音語としても擬態語としても使用されるオノマトペを対象とした．用法で「〜の音」と説明されているものを擬音語としての用法，「〜の音」以外で説明されているものを擬態語としての用法とし，その両方の用法をもつ全 9 種類をピックアップした．

その 9 種類のうち，Google[3] 検索結果数が最も多かった，“ガタン”についてアメーバブログコーパスを基に作成された YACIS コーパス[4]および Yahoo!リアルタイム検索[4]から抽出した文 192 文について，調査を行った．

Copyright is held by the author(s).
The article has been published without reviewing.

1) https://twitter.com/ 2)http://www.facebook.com

3) www.google.com 4) http://www.yahoo.co.jp/

調査は20代理系男子大学院生2名，20代社会人女性1名を被験者とした．まず，オノマトペが含まれる1文を MeCab[5] を使用して形態素解析を行い，単語単位に分割した．その後，それぞれの文において“ガタン”が擬音語として使用されているか擬態語として使用されているかを判断する単語がどの部分かマークしていただいた．3 人中 2 人以上が同じ単語にマークしていれば，その単語をオノマトペの意味決定単語とした．調査例を図1に示す．

例文 ： 運動/量/が/ガタン/と/落ちる/後半
結果:2 人以上が量をマークした→“量”が必要な単語

図 1 調査例（“ガタン”が擬態語として使用される例）

2.2 調査結果の分析

日本語母語話者が，“ガタン”が文中で擬音語，擬態語のどちらで使用されているか判断するために，感覚的に抽出する単語にどのような共通点があるか分析を行った．先行研究によりオノマトペの多義性判別には，オノマトペの係り先動詞が有効であることがわかっている[5][6]．したがって，オノマトペ意味決定単語とオノマトペの係り先が一致しているかどうかについての分析を行った．結果を表 1 に示す．

結果から考察を行うと，オノマトペの係り先が名詞であった文については，オノマトペの係り先が 9 割近く意味決定単語となっているが，オノマトペの係り先が動詞であった文については，3 割程度にとどまっている．

オノマトペの係り先が動詞だが，意味決定単語とならなかった文には以下のような 2 つのパターンが存在した．

Ⅰ ：オノマトペの係り先動詞が，オノマトペの使用意味に関わらず，どちらの意味でも出現する場合．
例 (1)イスがガタンと落ちる仕掛けのアトラクション
(2)昨日はアクセスがガタンと落ちましたね

Ⅱ ：オノマトペを含む文に“音”という単語が存在する
例 (1)洗濯機と乾燥機のたてるガタンという音
(2)あの日の朝，ガタンという音で目が覚めた

また擬音語か擬態語か判別できなかった 5 文を除く 187 文のうち，オノマトペの係り先以外が意味決定単語になったものは，119 文あり，その全ての単語が名詞であった．これらの結果から，日本語母語話者は，オノマトペの意味を判別する際にオノマトペの係り先動詞だけでなく，オノマトペの係り先名詞，さらには“音”といった特定の名詞により総合的にオノマトペの使用意味を判断していると断定できる．

表 1 オノマトペ“ガタン”の係り先品詞と抽出単語の関係

	オノマトペの係り先		
	動詞	名詞	その他
対象文数	164	18	5
抽出単語	52	16	0

注）擬音語か擬態語か判別不明な5文を除く（単位：文）

5)MeCab:
Yet Another Part-of-Speech and Morphological Analyzer

3 実験準備

3.1 対象オノマトペの決定

本研究で対象とするオノマトペは，**2.1** で述べた「外国人のための基本語用例辞典」の擬音語，擬態語に含まれる語の中で「～の音」として意味を定義され，かつ，それ以外に「～の音」以外の擬態語の意味も定義されている 9 種類を調査対象とした．9 種類は，“ガサガサ”，“ガタガタ”，“ガタン”，“ガンガン”，“ポンポン”，“バタバタ”，“ピイピイ”，“ビリビリ”，“コツコツ”である．

3.2 動詞のみで意味が判別できる場合

オノマトペの多義性の解消が動詞のみで行われる場合があることは，本稿 **2.1** 及び **2.2** の予備調査で裏付けられている．予備調査では“ガタン”を例に調査を行っているが，オノマトペが擬音語が擬態語か判別する際に，オノマトペの係り先動詞を感覚的に抽出している場合が，164 文中，52 文存在している．したがって，オノマトペと動詞の組み合わせだけで，オノマトペの意味を判別できるような動詞が存在する．そのような動詞が文中にオノマトペの係り先動詞として存在していれば，その他の単語を考慮せずに意味を判別できるため，判別は容易である[注1]．したがって，本実験では，オノマトペと動詞だけによって意味が決定されるような動詞が，オノマトペの係り先となっている場合は実験対象としないこととした．

そのために，9 種類のオノマトペそれぞれについて，対象としない動詞をリスト化する．

まず，京都大学格フレーム[7]を用いて，オノマトペと関連のある用言を検索し，その中で出現頻度が 2 以上の動詞をピックアップした．

つぎにピックアップした動詞とオノマトペをペアとし，そのペアのみでオノマトペが擬音語が，擬態語か判別できるか否か，20代理系男子大学院生1名，20代社会人女性1名，40代社会人男性1名に調査を行った．調査方法は 5 段階のリッカート尺度を用いて行う．例えば，（ガタン,鳴る）が擬音語で用いられると考える場合は 1，どちらかといえば擬音語で用いると考える場合は2，といった具合である．5 に近づくほど，オノマトペが擬態語として用いられ，1 に近づくほど擬音語として用いられるイメージが強いとなる．3 人の調査結果の平均を score として，以下のように定義した．

注1)したがって，動詞のみで決定されるオノマトペは，容易に自動で判別することが可能である．

・動詞だけで擬音語と判断する動詞($1 < score \leq 2$)
・動詞だけで擬態語と判断する動詞($4 < score \leq 5$)

3.3 オノマトペの意味決定名詞抽出法の構築

オノマトペの多義性を解消するにあたり，必要な名詞を抽出する手法を構築する．

本手法では，予備調査の結果をもとに，5 つのパターンを作成し，図2に示す．ここで，抽出を試みる名詞をN，それ以外の全ての名詞をn，オノマトペをO，動詞をVとする．また“→”は係り先関係を示す．ただし，名詞 N は，MeCab に使用されている IPA 品詞体系[6]の名詞の中で，予備調査のオノマトペ意味決定単語の名詞 2 語以上で出現した，“一般”，“サ変接続”，“形容動詞語幹”，に加え，それらが接尾辞として使用される “接尾-一般”，“接尾-サ変接続”，“接尾-形容動詞語幹”とした．

図 2 に示す 5 つのパターンを用いて，名詞を抽出する．係り受け解析には CaboCha[7]を用いた．

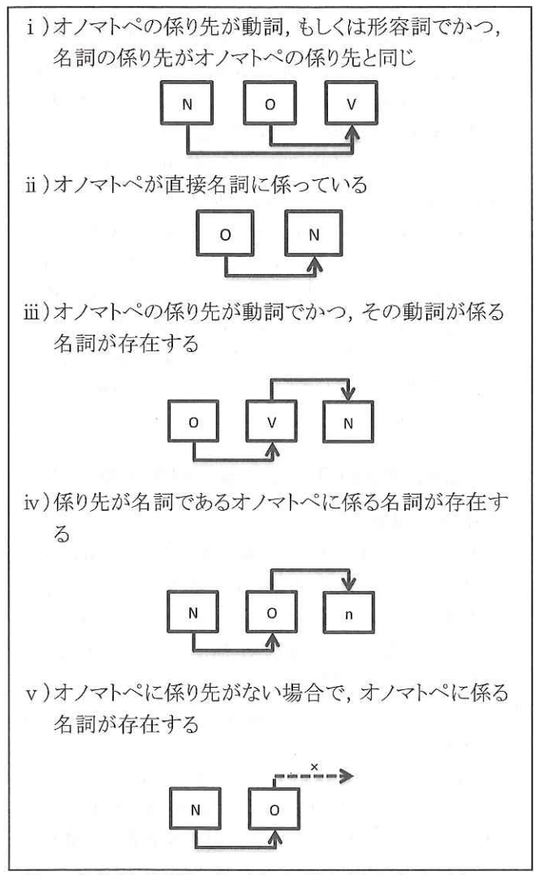


図 2 多義性解消に必要な名詞を抽出するパターン

6) 参照 ipadic version 2.7.0 ユーザーズマニュアル（浅原，松本）
:http://chasen.naist.jp/snapshot/ipadic/ipadic/doc/ipadic-ja.pd
7) CaboCha:YetAnotherJapaneseDependencyStructureAnalyzer
:http://chasen.org/ taku/software/cabocha

しかし，1 文あたりに存在する名詞の個数は 1 つとは限らないため，ⅰ ～ ⅴ に該当する名詞が複数存在することも考えられる．そこで抽出した名詞が複数だった場合，優先順位をつけることとした．まず，予備調査の結果から，名詞を意味決定単語としたもののうち，約 75%がパターンⅰに当てはまることがわかった．また，オノマトペの係り先が名詞である 18 文のうち 16 文でその名詞が抽出単語となっていることから，パターンⅱも同様に重要である．また，オノマトペに係り先がないパターンⅴの場合は，パターンⅰ ～ⅳと同時に起こり得ないので，重要度としてはⅰおよびⅱと同じとした．パターンⅲとパターンⅳは，パターンⅰとパターンⅱの合計に比べ，予備調査における出現頻度が 1 割程度と低かったため，重要度を下げた．

したがって，複数の名詞が抽出された場合は，以下のように重要度を定め，重要度が低い名詞は抽出しない．

重要度 ： ⅰ = ⅱ = ⅴ > ⅲ = ⅳ

続いて，重要度が同一のパターンの名詞が複数存在する場合の優先度を決定する．その際，以下の式(1)，式(2)で計算される 2 つのスコアを用いて優先度を決定する．文を文節ごとに区切り，最初の文節から順に割り当てた整数をチャンク番号とすると，N_{pos} は対象名詞のチャンク番号で，K_{pos} はオノマトペの係り先のチャンク番号，O_{pos} は，オノマトペのチャンク番号を示す．

$$D_{on} = |N_{pos} - O_{pos}| \quad (1)$$
$$D_{kn} = |N_{pos} - K_{pos}| \quad (2)$$

式(1)は，対象名詞とオノマトペそれぞれが含まれるチャンク番号の差を，式(2)は対象名詞と，オノマトペの係り先のチャンク番号の差をそれぞれ絶対値で示している．予備調査を分析した結果，オノマトペの意味決定名詞と，オノマトペそのものとの距離 D_{on} は，平均 1.4 となり，極めて距離が近いことが明らかとなった．また，どのパターンにも対象名詞とオノマトペは存在することから，同一パターンの名詞が複数存在した場合は，D_{on} の距離が短い方を優先することとした．

パターンが同一となり，D_{on} も等しくなった場合は，D_{vn} についても算出し，同様に距離が短い名詞を優先して抽出する．D_{kn} のスコアも等しくなった場合は，判定する要素が極めて乏しくなるため，抽出不可とした．

3.4 オノマトペを含む文の収集

オノマトペを含む文の収集を行った．本実験では，収集元として，**2.1** で用いた YACIS コーパスと Twitter を用いた．ブログは，性質上，口語表現が多くオノマトペが出現しやすいと考えられる．また，Twitter はブログよりさらにカジュアルな表現が用いられたり，短文での投稿

が多く，動詞の省略されたツイートが頻繁に出現する．このため，多義性解消における，名詞の有効性の確認に適していると判断し，用いた．

3.1 で述べた 9 種類のオノマトペについてそれぞれブログコーパスから 25 文，Twitter から 25 文の計 50 文を収集し，全 450 文のオノマトペデータベースを構築した．ただし，オノマトペ“ピイピイ”については，ブログコーパスに出現した文が 18 文のみだったため，Twitter から 32 文を収集した．

また，文に含まれるオノマトペの係り先動詞が，**3.2** で構築した動詞のリストに含まれ，オノマトペと動詞のみで判別できると想定される文や，係り受け解析に明らかに失敗し，**3.3** で構築した手法でどのパターンにも該当せず名詞が抽出されない文についてはあらかじめ，取り除いて収集した．

4 オノマトペの意味決定名詞の抽出

4.1 抽出結果および精度

3.2 および **3.3** で述べた手法により，450 文全てからオノマトペの意味決定名詞の抽出を行った．日本語母語話者が，オノマトペの意味を判断するために抽出する名詞と，構築したルールにより，システムが自動抽出した名詞がどれくらい一致しているかの確認を行った．一致しているか否かは，日本語母語話者である 20 代社会人女性 1 名に回答していただいた．結果として，9 種類のオノマトペの意味決定名詞の抽出の平均精度は，86.2%という高い正解率が得られた．特に，“ガタン”，“ガタガタ”，“ガンガン”，“ポンポン”，“コツコツ”については 9 割を超えており，高確率でオノマトペの意味決定名詞を抽出できている．表 2 に意味決定名詞の抽出精度をオノマトペ別に示す．

4.2 抽出誤りの分析

抽出する名詞を誤った場合について例を挙げて説明する．誤ったのは大きく分けて次の 2 つのパターンである．

表 2 オノマトペ別意味決定名詞の抽出精度

	正解(文)	不正解(文)	精度(%)
ガタン	48	2	96.0
ガタガタ	46	4	92.0
ガンガン	45	5	90.0
ポンポン	45	5	90.0
コツコツ	45	5	90.0
バタバタ	43	7	86.0
ビリビリ	42	8	84.0
ガサガサ	41	9	82.0
ピイピイ	33	17	66.0
全体	388	62	86.2

① オノマトペの係り先動詞のみでオノマトペの意味が決定されるが，係り先動詞が動詞リストに含まれておらず名詞を抽出してしまう誤り．
以下の例ではオノマトペの意味は下線部の動詞によって決定されるが，名詞を抽出している．

例）午後もバタバタと空を飛べるほど動き回るのであります。（抽出された名詞「空」）

② 抽出される名詞を誤った場合

例）背中をポンポンしていってくれた言葉
（抽出された名詞「言葉」）

これらの誤りの原因について考察すると，①の例に関しては，係り先動詞のみでオノマトペの意味を決定する際の動詞リストの種類が少なかったためである．全ての動詞を網羅することは非常に困難だが，”ピイピイ“には動詞リストに 1 種類しかないため，オノマトペの意味決定名詞抽出の際の精度もかなり低くなってしまったと考えられる．続いて②の例に関しては，係り受け解析の誤りである．Twitter やブログには，助詞の欠落やひらがなの多用など係り受け解析を困難とする様々な要因がある．しかし，それが特色でもあるため，本実験では，係り受け解析に失敗する可能性が高い，文中への顔文字挿入や，句読点がなく文が続くもの，**3.3** で構築したルールを使用しても名詞が全く抽出できないもの以外は，文に対して処理を施していない．したがって例②のような誤りも発生してしまった．

5 意味決定名詞を用いた多義性判別法の提案

5.1 手法の提案

本手法では，JUMAN[8] の意味情報を用いる．JUMAN の意味情報では，カテゴリ情報（22 種類）とドメイン情報（12 種類）が与えられている．本実験では，このうちカテゴリ情報を使用して分類を行う．抽出された名詞に付与されたカテゴリ情報をもとに，オノマトペを含む文を仮説によって分類し，擬音語と擬態語に分類できているか精度を測定する．

分類の精度は，日本語を母語とする 20 代理系男子大学院生 1 名，20 代社会人女性 1 名，40 代社会人男性 1 名に判定していただき，2 人以上が正解と判断した場合は正解とする．

5.2 仮説の提唱と検証

予備実験で扱った“ガタン”について抽出された名詞

8） 日本語形態素解析システム JUMAN
http://nlp.ist.i.kyoto-u.ac.jp/index.php?JUMAN

の分析を行った．“ガタン”を含む文 192 文については，先行研究[1]で予め“重いものが落ちたりぶつかったりする音やその様子”と“成績，値段などの物事が急激に落ちる様子”という 2 つの意味に分類されてあり，それぞれラベルが付与されている．このうち，前者を擬音語として定義し，後者を擬態語とする．

2.1 に記述した予備調査で，被験者が多義性解消に必要であると判断し，抽出した名詞に JUMAN の意味情報を付与し分析した結果を表 3 に示す．表 3 において，抽象物のカテゴリに含まれる「音」とは，抽出単語に「音」という文字が含まれる場合のことを示す．

分析結果として，擬音語は金銭を除く，「人工物」や「場所」といったカテゴリに含まれる名詞が抽出され，擬態語は，「抽象物」や「数量」といったカテゴリに含まれる名詞が抽出されていた．しかし，「抽象物」の中でも，抽出名詞に“音”が含まれるものについては，全て擬音語であった．これらから，以下の 2 つの仮説を提唱する．

Ⅰ： 擬音語と擬態語の分類は基本的に，オノマトペの意味を決定する名詞が具体物か，抽象物かに依存する．

Ⅱ： 抽出した名詞に“音（カテゴリは抽象物）”が含まれる場合についは，擬音語となる．

以上の 2 つの仮説から，まず，JUMAN に与えられている 22 種類のカテゴリ情報を具体物と抽象物に分類した．抽象物として分類したのは，「抽象物」「色」「数量」「時間」「形・模様」「人工物-金銭」[8] である．それ以外は具体物とした．

また，抽出した単語そのものにカテゴリが付与されていなくても，その語に上位語があれば，上位語のカテゴリを付与した．

表 3 “ガタン”を含む文の抽出単語のカテゴリ情報

		擬音語	擬態語
抽象物	音	36	0
	音以外	0	45
人工物	乗り物	2	0
	金銭	0	3
	その他	5	3
場所		4	0
数量		0	21
時間		0	1
自然物		0	1
動物		0	1
カテゴリなし		0	7

（単位:文）

8)JUMAN に与えられているカテゴリについては，JUMAN のチュートリアルを参照した．（http://nlp.ist.i.kyoto-u.ac.jp/index.php?JUMAN）

例えば，「ストッキング」はカテゴリが付与されていないが，上位語として，「長靴下」が出力された．その場合は，「長靴下」を JUMAN によりもう一度解析し，カテゴリ「人工物-衣類」を得た．

これら 2 つの仮説を検証するため，9 種類のオノマトペについて，**4.1** で意味決定名詞が正しく抽出された 388 文を対象として実験を行った．388 文のうち，カテゴリが付与されなかった 12 文を除く計 376 文について，自動で擬音語か擬態語かを判別した．その後，それらが正解か不正解かを **5.1** で述べた被験者に判定していただいた．

5.3 意味判別の結果と考察

判別結果を以下の表 4 に示す．オノマトペの意味判別結果は，全 450 文の平均値をとると，71.5%の高い精度が得られた．特に，“コツコツ”や“ガタン”は 9 割を超えており非常に高い精度であった．一方で，“ビリビリ”は 5 割に満たないという結果になり精度が低い．そこで，最も精度が低くなってしまったオノマトペである，“ビリビリ”において判別結果が不正解となった名詞に付与されたカテゴリの割合から，原因の分析を行った．図 3 に，不正解となった文から抽出されている意味決定名詞に付与されているカテゴリの種類の存在割合を示す．

図 3 を分析すると，誤っている文から抽出された名詞に多いカテゴリは，「動物-部位」である．この誤りがあった文には次のようなものがある．

例）寝ようとすると皮膚がビリビリする

ここでの“ビリビリ”は被験者は擬態語と判断しており，痛みを表す擬態語だと推測できる．皮膚や手足など動物の部位は具体物であるが，痛みを表す際は擬態語となるため誤りが生じた．

表 4 オノマトペ別判別精度

	正解(文)	不正解(文)	正解率(%)
コツコツ	43	1	97.7
ガタン	43	4	91.5
バタバタ	33	7	82.5
ガンガン	33	11	75.0
ガタガタ	32	13	71.1
ポンポン	26	18	59.1
ガサガサ	23	17	57.5
ピイピイ	17	14	54.8
ビリビリ	19	22	46.3
全450文	269	107	71.5

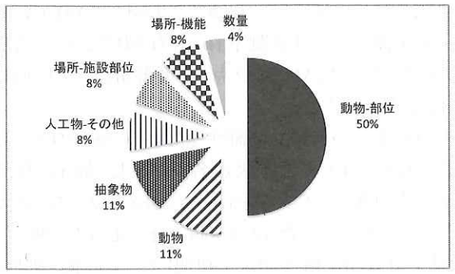


図 3 誤って付与したカテゴリの割合<“ビリビリ”>

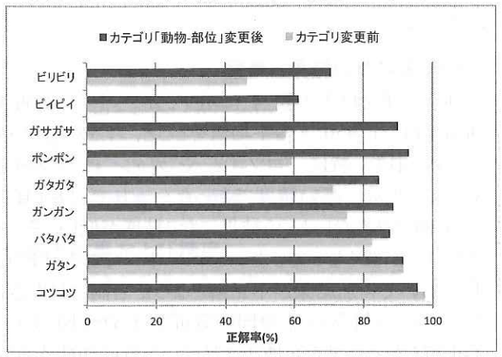


図 4 「動物-部位」カテゴリを変更後の正解率

また「動物-部位」のカテゴリを付与された名詞が抽出されている“ビリビリ”を含む文は全て擬態語と判断されていた．その他のオノマトペにおいて，「動物-部位」のカテゴリが付与された意味決定名詞を抽出した場合は，全体の 91.0%が擬態語で使用されていた．したがって，カテゴリ「動物-部位」が付与された名詞が抽出された時は，擬態語として，再度正解率を測定した．結果を図 4 に示す．

カテゴリのグループを変更したところ，9 種類の平均正解率は，85.6%となり，14.1 ポイント上昇した．また，“ガタン”を除く全ての種類のオノマトペで正解率が上昇した．

この結果から，オノマトペの擬音語，擬態語の分類は基本的に抽象物と具体物に依存するが，動物の部位がオノマトペの意味判別決定名詞となっているときは，擬態語に分類する方が精度が高くなることが確認された．

また，2 つめの仮説は，「音」を含む全 36 文のうち，35 文が擬音語であったことから，妥当であるといえる．

6 まとめ

本研究では，オノマトペの多義性解消のためにどのような名詞が有効であるか，そしてどのくらい有効であるのかについての調査を行った．日本語母語話者は，オノマトペの意味を周辺の単語や文脈によって判断していると考え，アンケート調査によりオノマトペを含む文のどの単語によって，多義を持つオノマトペの意味を判別しているのかを分析した．その分析に基づき，オノマトペの多義性解消に有効な名詞である，オノマトペの意味を決定している名詞を自動で抽出する手法を提案した．オノマトペの係り先やオノマトペに係る名詞に注目した，単純な手法ではあるが意味を決定する名詞の自動抽出は 85%を超える精度を達成した．

その手法により，9 種類のオノマトペについて，分類を行った．その結果，オノマトペの多義性の解消には，意味を決定している名詞が，具体物か抽象物のどちらであるかということや，「音」という単語を含むか否かが非常に関係していることが明らかとなった．さらには，具体物の中でもオノマトペの意味を決定する名詞が，動物の部位を表す場合は，擬態語であることが多いと明らかになった．これらの知見を利用して意味判別を行ったところ，85%を超える正解率を達成した．

本研究で扱った，擬音語と擬態語の 2 種類の意味ではなく，擬態語だけで複数の意味を持つオノマトペも存在することから，今後はそれらの多義性の解消へのアプローチを研究する必要がある．また，オノマトペはそれぞれの語によって，意味判別の精度にばらつきがあることからわかるように，1 つ 1 つが異なる特徴を持つている．それらの特徴を分析し，さらに意味判別の精度を向上し，高精度で自動的に，全てのオノマトペの多義性の解消を行うシステムの構築につなげたいと考えている．

参考文献

[1] Hironori Fukushima, Kenji Araki and Yuzu Uchida: Disambiguation of Japanese Onomatopoeias Using Nouns and Verbs, P.Sojka et al. (Eds.), TSD2014, LNAI 8655, pp.141-149, 2014.

[2] 内田ゆず，荒木健治，米山淳：ブログ記事から抽出したオノマトペの多義性について，第 27 回ファジィシステムシンポジウム講演論文集，pp.853-856, 2011.

[3] 文化庁，外国人のための基本語用例辞典（第三版），大蔵省印刷局，1990.

[4] Michal Ptaszynski, Pawel Dybala, Rafal Rzepka, Kenji Araki and Yoshio Momouchi: YACIS: A Five-Billion-Word Corpus of Japanese Blogs Fully Annotated with Syntactic and Affective Information, in Rzepka R., Ptaszynski, M. and Dybala, P. (Eds.), Linguistic and Cognitive Approaches To Dialogue Agents (AISB/IACAP Symposium), 40-49 ,2012.

[5] 浅賀千里，ユスフムカルラマー，渡辺知恵美：オノマトペ用例辞典における用例を意味により分類するためのクラスタリング手法の諸検討，日本データベース学会 Letters Vol.6, No.2,pp.45-48, 2007.

[6] Chisato Asaga, Mukarramah Yusuf, Chiemi Watanabe: Onomatopedia:Onomatopoeia Online Example Dictionary System from Data on the Web, The 10th Asia Pacific Web Conference(APWeb), 2008.

[7] 河原大輔，黒橋禎夫：自動構築した大規模格フレームに基づく構文・格解析の統合的確率モデル，自然言語処理，Vol.14, No.4, pp.67-81, 2007.

ARG WI2 No.5, 2014
WI2-2014-34

地域の認知と評価の集合知としての SALoT マップ

－場所の特徴的イメージを表す単語や文章の自動抽出－

大森 宏 1, 羽生和紀 2, 山下雅子 3

1 東京大学大学院農学生命科学研究科，2 日本大学文理学部．3 東京有明医療大学

omori@lbm.ab.a.u-tokyo.ac.jp

概要 SALoT マップとは，ある地域において，スナップショット（写真）(S)と撮影した人の属性(A)，位置(Lo)，その時感じたことや印象などのコメントのテキスト文(T)からなる 4 つ組の SALoT データを統合して作成される印象の集合知マップである．SALoT データは，視覚的類似度から分類された見た目グループと撮影地点分布から分類された場所グループ，属性による属性グループに分けられる．形態素解析で単語を抽出し，コメントとグループ文集合の対応分析の結果が SALoT マップである．SALoT マップからグループを特徴づける単語やコメントの得点が算出される．TF-IDF による単語やコメント得点と総合して重要単語や重要文を抽出する．地元大学生による埼玉県川越市内の気に入った景観を撮影する調査を行い，177 名の学生から 242 件の SALoT データが集まった．8 つの見た目グループと 7 つの場所グループが得られた．場所グループのイメージを特徴づける重要語や重要文を抽出し，それらに基づき代表景観が抽出された．

キーワード 集合知，テキストマイニング，対応分析，VisualRank

1 はじめに

ある地域の景観特性を明らかにすることは，地域観光の振興や地元の住民が地域に対する愛着や満足を増進させるために重要である．最近では地域の魅力や評判をブログや twitter などの SNS から抽出する研究が急速に進んでいる[1,2,3]．しかしながら，ウェブからの情報抽出では，投稿者の性別や年齢層などの属性情報の取得は難しく，また，投稿者の自由な意見や感想を受動的に取得する「受け身」の調査である．

一方，従来からあるアンケート調査は，被験者母集団の属性を定め，聞きたい項目や内容は調査主催者が主体的に決められる「攻め」の調査であるが，コストの問題がある．地域の認知と評価を写真投影法[4]を利用して行う参加型景観調査[5]を情報通信技術（ICT）を利用して低コストで行い，集合知を用いて計量的に扱う SALoT(Snapshot-Attribute-Location-Text)マップ法[6,7]を開発した．これは，ある指示を与え，調査対象地域の景観写真を撮ってもらう．撮影した写真（スナップショット）(S)とそれを撮った人の属性 (A)，撮影した位置（緯度・経度）(Lo)，その時の印象や撮影理由などのコメントのテキスト文 (T) の 4 つの情報を 1 つのセットにした SALoT データを集め，それらを統合してその地域が与える印象の集合知を視覚化して具体的に表現するものである．

本稿では SALoT マップからの集合知の自動抽出法の改良点を述べる．SALoT マップから，あるグループを特徴づける単語やコメントの得点を算出し，重要語や重要文の自動抽出を行った．また，VisualRank[8]の補正項にコメント得点を用い，グループの代表景観の自動抽出も行った．

埼玉県川越市で地元大学生（東京国際大学）177 名による景観調査の結果得られた川越市の印章の集合知について報告する．

2 川越 SALoT マップの作成

2.1 多人数からの SALoT データの収集

調査参加者に何らかの指示を与え，自身の所有する撮影機材を携行して対象となった場所を自由に散策させる．そこで，指示に合って目に止まった物や景色のスナップショットを何カ所かで撮ってもらう．このとき，観測者の属性，位置情報，コメントを記録してもらい，電子メール等で収集する．

川越市内の「気に入った」景観を 2, 3 カ所撮影し，その理由やその時感じたことなどを記載してもらう調査を行った．2010 年の調査では 49 名の学生（日本人男子 21 名，日本人女子 23 名，不明・外国人 5 名）から 64 件，2011 年では 128 名の学生（男子 63 名，女子 58 名，不明・外国人 7 名）から 178 件，計 242 件の SALoT データを収集した．その内訳は、男子のものは 104，女子のは 126，不明・外国人のは 12 であった．

SALoT データの具体例は図 1 である．この例では地番から Google MAP で緯度，経度情報に変換した．

Copyright is held by the author(s).
The article has been published without reviewing.