THE IEICE TRANSACTIONS ON INFORMATION AND SYSTEMS (JAPANESE EDITION)

電子情報通信学会 論文誌 D 情報・システム

VOL. J98-D NO. 11
NOVEMBER 2015

本PDFの扱いは、電子情報通信学会著作権規定に従うこと。
なお、本PDFは研究教育目的（非営利）に限り、著者が第三者に直接配布することができる。著者以外からの配布は禁じられている。

情報・システムソサイエティ

一般社団法人 電子情報通信学会
THE INFORMATION AND SYSTEMS SOCIETY
THE INSTITUTE OF ELECTRONICS, INFORMATION AND COMMUNICATION ENGINEERS

論　文

地方議会会議録における節単位による議員の要望抽出

葦原　史敏[†a)]　　木村　泰知[††]　　荒木　健治[†]

Clause-Level Retrieval of Assemblymen's Demand from Local Assemblies Minutes

Fumitoshi ASHIHARA[†a)], Yasutomo KIMURA[††], and Kenji ARAKI[†]

あらまし　本論文では，地方議会会議録を対象として，議員の質問から，要望が含まれる箇所を抽出する手法について述べる．地方議会会議録の特徴としては，首長や議員の発言を書き起こした話し言葉であり，一文が長くなる点が挙げられる．そのため，要望を抽出する単位は，地方議会会議録の特徴を踏まえ，文内の要望を含む箇所のみを抽出するために「節単位」としている．本手法は，機械学習を用いて「節単位」で要望の有無を判定しており，機械学習の素性として，後続の節のモダリティ表現の出現を捉えるパターンや，節境界ラベルなどの構文的情報を利用している．評価実験では適合率，再現率，F 値を用いた評価を行い，節内の bag-of-words のみを用いた場合と，全ての素性を用いた場合を比較し，クローズドデータの F 値で 33.6 ポイント，オープンデータの F 値で 24.3 ポイントの向上が確認された．特に，他の素性に節境界ラベルを追加した際に，適合率を低下させることなく再現率を向上することが確認された．

キーワード　地方議会会議録，要望，モダリティ，節単位

1. まえがき

近年，全国の約 7 割の自治体が，住民への情報公開に向けて，ウェブを利用して地方議会会議録（以下，会議録）を公開しており，住民は自治体の意思決定に関する議員らの議論を閲覧することができるようになっている [1]．議論の過程を閲覧できる会議録は，ブログやマイクロブログなど [2], [3] と比較しても，行政職員や議員の意見が読み取れる重要な言語資源である．しかしながら，会議録は議員の発言を書き起こした話し言葉であり，要約されていない読みづらい膨大なテキストデータであるため，ウェブ上に公開しただけでは，読もうと考える住民がほとんどいない．このため，会議録は公開されているにもかかわらず住民によって閲覧される機会が少なく，情報提供形態を工夫し，会議録の情報を提供することが望まれている [4]．

会議録の内容を理解する難しさの要因としては，行政職員と議員が一つの議題に対して質疑を繰り返す一問一答形式ではなく，一括質問一括回答という形式に起因する一発話の長さが挙げられる．**例 1** に一括質問の一部を示す．

例 1

…次に，生徒の状況調査についてであります．　文部科学省においては，現在，小中学校の通常学級に在籍している，発達障がいの可能性がある児童生徒に関する調査を実施しているところと承知しております．　この調査は，抽出調査ということでありますが，道教委として，小中学校の悉皆調査を実施し，その結果を今後の施策に活用すべきと考えますが，教育長の見解をお伺いいたします．

また，道教委では，昨年の第 3 回定例会における我が会派の同僚議員の提案を受け，既に，道立高等学校に在籍する，発達障がいのある生徒の状況について，調査を実施しているところと承知いたしております．…

† 北海道大学大学院情報科学研究科，札幌市
Graduate School of information Science and Technology, Hokkaido University, Kita 14, Nishi 9, Sapporo-shi, 060–0814 Japan
†† 小樽商科大学商学部社会情報学科，小樽市
Department of Information and Management Science, Otaru University Of Commerce, 3–5–21 Midori, Otaru-shi, 047–8501 Japan
a) E-mail: ashihara@media.eng.hokudai.ac.jp
DOI:10.14923/transinfj.2014JDP7145

 ⓒ一般社団法人電子情報通信学会 2015

このような文書から情報を取得する際にユーザがキーワードで検索することを想定すると，議員の主張がどこにあるかが分かりにくく，ユーザが重要な箇所に焦点を当てることは難しい．

そこで本手法では，議員の質問から主張となるような，自治体に対しての要望を含む発言箇所に着目する．**例 2** は**例 1** 中の要望を含む発言の例である．

例 2

この調査は抽出調査ということでありますが，道教委として小中学校の悉皆調査を実施し，その結果を今後の調査に活かすべきと考えますが，教育長の見解をお伺いいたします．

このような発言には，議員の主張，自治体が抱えている政治問題が現れる．そのため，要望を含む発言の抽出は，住民が議会で行われている議論を容易に把握することにつながると考えられる．

要望を文書から抽出することを対象とした研究には，パブリックコメントを対象にした大塚らの研究 [5] や，商品のレビューなどの CGM（Customer Generated Media）データを対象にした金山らの研究がある [6]．大塚らは文に要望の意図が含まれるかを文単位で bag-of-words の表現を用いた教師あり機械学習（二値分類）により判定している．また，金山らは要望の対象も同時に推定するタスクを設定し，自動的に獲得した構文パターンを用いることで，精度を向上して判定している．

大塚らのように文単位で抽出することは，比較的短い文であれば要約として適していると考えられる．しかしながら，議会会議録中の文書は話し言葉であるため，指示詞の多用により，一文が長くなる傾向がある [7]．一文が長くなる場合，文単位で抽出することは適切な要約になるとは考えにくい．

この問題に対し，丸山らは重要文抽出の処理単位として節単位を抽出単位とすることにより，過剰な部分の抽出や情報の欠落を回避し，より効果的な抽出を行うことを提案している [8]．ここで述べる節とは，「述語を中心としたまとまり」と定義されており [9]，主語，目的語，述語を含むため局所的に意味が分かる断片となる．

そこで本手法では，地方議会会議録にも長文が現れやすい傾向を考慮して，文より短く，意味が分かる断片である節単位で要望が含まれるか判定を行う．本手法の手順を図 1 に示す．

本手法で用いる「節」は，日本語節境界検出プログラム CBAP によって文を節に分割するための節境界を付与することで得られる．CBAP は形態素の局所的な連接を対象としたパターンマッチで節境界の位置を網羅的に検出することによって実現されている [8]．

節単位による要望判定について，**例 2** の文を節単位に分割した図 2 を例に説明する．この場合，**例 2** は CBAP によって与えられた節境界により，四つの節 C_1〜節 C_4 に分割される．本手法では，得られた各節それぞれに対し要望か否かの判定を行う．これらの節が要望か否かを人手で判定すると，全数調査を求める内容である C_2 から，その結果の活用を求める C_3 までが要望を含む節として判断される．

本手法では，人手により得られた節から要望を含む節の特徴を学習するが，要望を含む節を自動で判定するには，「べき」，「てほしい」などの助動詞や文末表現が含まれるか判定することが重要となる．図 1 の例では，C_3 に「べき」が含まれることで要望であると判定できる．

一方，節 C_2 は手がかりとなる表現が出現しないため，節内の単語をの出現情報を用いるだけでは判定が困難である．このように，節単位による判定では後続

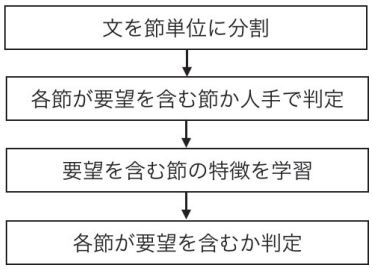


図 1　節単位による要望判定の手順
Fig. 1　The procedure of clause-level demand retrieval.

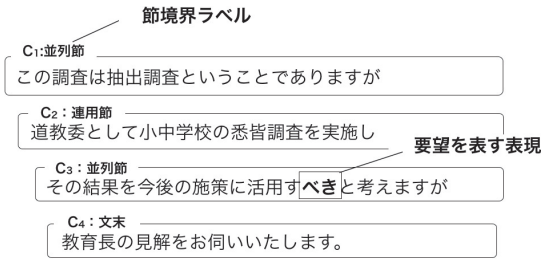


図 2　**例 2** を節単位に分割したもの
Fig. 2　The example2 devided by clause boundary.

の節の単語を用いる必要がある．

そこで本手法では，節単位による要望抽出で起こる問題に対して，節の接続関係を考慮した構文情報を用いることで，判定精度の改善を試みた．これは品詞，係り受け，節境界ラベル(注1)などを機械学習の素性に用いて実現する．

本手法の特徴としては，複数の節から構成される文を対象に節単位で要望を抽出する点，機械学習の素性として，節単位特有の素性（後続の節のモダリティ表現の出現を見る，節境界ラベルなどの構文情報）を適用している点が挙げられる．

以下，本論文の構成について述べる．まず **2.** で，他の議会会議録を対象とした研究や，提案手法で利用する節の構文情報を用いた研究について，本手法との関連について述べる．**3.** で，要望を含む節の実験データを議会会議録のデータから作成し，**4.** でそのデータに対する要望を含む節の判定精度を評価し，抽出手法の問題点を分析する．**5.** では，それらの問題に対応する提案手法について述べ，**6.** では提案手法の有効性を確認する．最後に **7.** で本手法の結果について結論づける．

2. 関 連 研 究

議会会議録のデータに対して可読性の向上を試みた研究としては，山本らの国会会議録に対する要約の研究がある．一つは内容の読解を容易にする報知的要約として冗長用表現の除去 [10]，もう一つは導入段落と結論段落の抽出を行い，文書を読むか判断するための要約を提示するものである [7]．本手法の目的は主張が現れる結論段落を抽出する後者の研究と類似しているが，結論段落に現れない要望による主張を抽出できる点や，文より粒度の細かい節を単位として抽出できる点が異なる．

また，本手法と同様に意見を対象とした研究には，米国の議会会議録における議員のイデオロギーを判定する Diermier の研究 [11] や，発言者の価値観を推定する Takayama [12] らの研究がある．その他には住民と議員をマッチングさせるための能動的な質問文生成を行う木村らの研究 [4] がある．しかしながら，これらの議会のデータを対象とした研究では，議員の要望に着目していない．

(注1)：CBAP が節境界に加えて付与する当該節の文法的情報（連用節，連体節など）

また，本手法で扱う節境界ラベルパターンに類似した構文情報を利用した研究には，高野らの口コミサイトからの評価表現の抽出に関する研究がある [13]．高野らは「駅に近いので便利」という文から，評価表現（「便利」など）を評価要因（「駅に近い」）を利用して抽出し，更にそれらのデータを交互に増加させるという手法を取っている．またこの際，評価表現と評価要因の因果関係を判定するための手がかりとして，接続節（補足節，副詞節，連体節）などの構文情報を用いている．高野らの研究では事前に設定した構文情報を用いているが，本手法では CBAP を用いた節境界ラベルの解析によって，分類に有効なパターンを明示的に設定せずに構文情報を取り入れることができる．

3. 要望を含む議員の発言

本章では要望を含む節の判定を行うための評価用データ作成を行う．実験データの作成は，文を CBAP によって節ごとに分解し，節の内容（形態素列）ごとに要望を含むかを人手で判断することにより行う．この判断は，命令や提案などの要望する意図の強さを考慮することが難しいため，議員が自治体関係者に望むことがらが含まれる節を要望と判定する．

3.1 要望の分類

本手法では，要望意図の強さは分類しないが，表 1 に示すように，要望表現を問題解決要求と説明要求に分類する．問題解決要求は自治体やその関係者に問題の解決を求める要望，説明要求は自治体の首長・職員に説明を求める要望と定義する．本研究の目的は，議員の主張を抽出することである．したがって，表 1 の二つの要望はどちらも相手に対する要望であるが，相手に説明を求める説明要求は本研究の対象ではない．

しかしながら，説明要求にも同じ要望のモダリティを示す語が出現すると，機械学習による分類に影響が生じる可能性があるため，表 1 の二つに分類している．

表 1 要望の 2 分類の定義と例
Table 1 The examples and definitions of two demand types.

	説明要求	問題解決要求
定義	自治体の首長・職員に説明を求める要望	自治体やその関係者に問題の解決を求める要望
例	市長の提案をお聞かせください．	電力に対する全ての情報を公開し，検討する必要があります．

表 2　評価用データ構築の概要
Table 2　Outline of evaluation data construction.

取得先会議録	会派	クローズドデータ	オープンデータ	合計
小樽市議会 平成 23 年度第 1 回，第 3 回の定例会から 6 名の議員の発言を取得.	自民	2 名	0 名	2 名
	公明	2 名	0 名	2 名
	共産	2 名	0 名	2 名
北海道議会 平成 24 年度定例会 3 月 02 号～03 号から 22 名の議員の発言を取得.	自民	1 名	8 名	9 名
	民主	1 名	8 名	9 名
	フロンティア	1 名	1 名	2 名
-	公明	1 名※	2 名※	2 名※
-	-	10 名	19 名	28 名

クローズドデータ (分析用) は 1,629 文 (5,498 節) 小樽市議会 6 名，北海道議会 4 名の発言を含む.

オープンデータ (評価実験用) は 1,526 文 (5,388 節) 北海道議会よりクローズドデータ以降の 19 名の発言を含む.

※クローズドデータとオープンデータの分割は公明党の議員の発言中で行ったため，公明党の議員が 1 名重複している.

3.2　評価用データ

まず，実験データ作成のために，平成 23 年度小樽市市議会会議録（定例会）と平成 24 年度北海道議会会議録（定例会）より，28 人の議員の発言から 3,155 文を取得した．評価用データには，特定会派の議員の発言のみのデータとならないように，幾つかの会派を含むものを選択している.

次に，これらの文を CBAP で分割し，節中に一般動詞が含まれる 10,886 節を得る(注2)．このデータを 1 議員の一括質問中で一つの質問の終わりとなっている箇所で分割し，クローズドデータとして 5,498 節，オープンデータとして 5,388 節を取得した．(注3)

クローズドデータは **3.3** におけるアノテーションの一致率，**4.** における提案手法構築のための分析で用い，オープンデータは分析対象とせずに **6.** における評価実験の対象とする．表 2 にデータ構築の概要を示す.

3.3　節単位の要望抽出のためのアノテーション

実験データ作成のために，クローズドデータに対し，要望を含む節か否かを複数人で判断し，判断が一致するか調査する．調査は各々の節が要望を含まない，問題解決要求，説明要求のいずれになるか判断してもらうことで行う．要望抽出の先行研究である文献 [5] では，評価者が要望文か否かを主観で判断した結果，Cohen の kappa 係数が 0.17 になっており，何も指針がない場合は実験データ作成が難しいことが理解できる．特に本手法は，文を更に区切った節で判断するため，情報が欠如し，より判定が難しくなることが予想される.

そこで，実験データ作成の前に，評価指針を用意し，要望を含む 1,000 節を対象に事前練習を行った．評価指針では大きく次の点について指示を行った.

- 節に含まれることがらの解決を自治体関係者が行うことを望んでいると判断できる場合，要望とする.
  例：「道教委として小中学校の悉皆調査を実施し（図 2 の節 C_2）」
- 一括質問における各質問ごとに答弁を求める表現が現れるため，それらは説明要求と判断する.
  例：「（～と考えますが,）ご所見をお伺いいたします.」
- 単体で意味のない節は要望にしない.
  ただし，前の節や文から省略，代名詞の参照を補うことで意味が通じる場合は要望とする.
  例：「その結果を今後の施策に活用すべきと考えますが」（「その結果」という代名詞が存在する.）
- 理由・目的を表す節は要望にしない.
  例：「次に子どもの健康被害を防止するためには」（健康被害防止を要望しているとも判断できるが，要望としない.）
- 義務的・一般論的な要望は含めない.

(注2)：節に一般動詞が含まれない場合，単体で意味のある節となりにくいため，判断対象としない.
(注3)：話題の区切りである一括質問中で一つの質問の終わりとなっている箇所で分割したため，クローズドデータとオープンデータの分布に偏りが存在する.

表 3　評価者間の判定内訳と kappa 係数
Table 3　Kappa coefficient values for three types of evaluators.

		評価者 A		
		要望なし	説明要求	問題解決要求
評価者 B	要望なし	4,409	18	125
	説明要求	24	337	0
	問題解決要求	72	4	194
kappa 係数				0.79

		第一著者		
		要望なし	説明要求	問題解決要求
評価者 A	要望なし	4,444	12	49
	説明要求	40	318	1
	問題解決要求	135	2	182
kappa 係数				0.79

		第一著者		
		要望なし	説明要求	問題解決要求
評価者 B	要望なし	4,459	10	83
	説明要求	43	318	0
	問題解決要求	117	4	149
kappa 係数				0.76

例：「行政改革というのは，少なくともみずからやっていかなければならない」（一般論的な発言）

その後，クローズドデータである 5,498 節を CBAP で抽出し，第一著者と 2 人の評価者（男子大学生 1 名，男子大学院生 1 名）で行い，その一致率を Cohen の kappa 係数 [14] によって計算した．ただし，5,498 節のうち 315 節に正しく節の文字列が与えられず判定ができないデータがあったため，それらのデータを除いた 5,183 節で kappa 係数の評価を行った．(注4) 各評価者間の判定の内訳と kappa 係数の値を表 3 に示す．なお，表 3 の要望なしは，節に要望を含まない際の分類である．

表 3 に示す結果より，kappa 係数の平均は 0.78 となった．kappa 係数の値については，一般的に 0-0.4 で低い一致，0.4-0.6 で中程度の一致，0.6-0.8 の一致でかなりの一致，0.8-1.0 で高い一致といわれており [15]，作成された実験データはかなりの一致であるといえる．

最終的な正解データの作成は，第一著者と他の評価者の kappa 係数でかなりの一致を示していることから，第一著者が再度確認してクローズドデータの正解を決定した．また，オープンデータについても第一著者がアノテーションすることで正解を決定した．表 4 にアノテーションしたデータの構成を示す．

表 4　評価用データの構成
Table 4　Breakdown of evaluation data.

	要望なし	説明要求	問題解決要求
クローズドデータ	4,904	359	235
オープンデータ	4,736	292	36

4. 節単位による要望抽出の問題点

本手法では，節単位による要望抽出において後続の節の単語が重要になると仮定した．そこで本章では，節単位の要望抽出の問題が，一般的に機械学習の素性として用いられる bag-of-words による抽出で生じるか検証する．この検証は，**3.** で作成したクローズドデータに対し，先行研究 [5] と同様に統計的機械学習の SVM [16] を用いて問題解決要求を含む節の判定を行い，その後，得られた結果の誤り例について分析することで行う．

4.1 節単位による要望抽出の精度検証

実装は LibSVM [17] を用い，学習条件は以下のとおり設定した．

- カーネルは二次多項式カーネル，コスト (C) パラメーターは 0.01 に設定する..
- 素性は節内の語の bag-of-words を用いる．単語は形態素解析器 MeCab(注5) によって分割した．
- 分類は要望を含まない節，問題解決要求，説明要求の 3 値分類の問題とする．多値分類は LibSVM に実装されている，任意のクラスのペア同士での学習データを用いて識別関数を構成する one-against-one アプローチを用いる．
- 分類精度の検証は 10 分割交差検定で問題解決要求の適合率，再現率，F 値を求める．再現率，適合率は，それぞれクラスの真の事例数，予測した事例数に対する正解事例数の比であり，F 値は再現率と適合率の調和平均

(注4)：なお，正しく節の文字列が与えられなかった 315 節は第一著者が再度内容を確認し正解を与えた．

(注5)：http://mecab.googlecode.com/svn/trunk/mecab/doc/index.html

表 5　実験結果
Table 5　Experimental results.

適合率 [%]	再現率 [%]	F 値
91.1	20.3	0.325

である．

この実験で得られた問題解決要求の適合率，再現率，F 値を表 5 に示す．なお，表 5 に示していない説明要求の精度は，**6.** の提案手法（素性 f_1〜f_8 を用いたもの）においてクローズドデータに対し適合率 92.5%，再現率 92.8%，F 値 0.925，オープンデータに対し適合率 93.5%，再現率 93.8%，F 値 0.935 の精度が得られており，十分な精度が確認されている．

表 5 の結果から，再現率が低く，多くの問題解決要求を要望を含まない節として分類していることが確認された．

4.2　実験結果の考察

4.1 で得られた実験結果について，正しく分類できた事例に出現する語彙の特徴と，それに対する誤分類事例の特徴について述べる．

正解した事例数は 41 例であり，それらの事例の語彙の特徴としては，31 例に「べき」，9 例に「なければ〜」という単語が含まれることが確認された．これらの語彙は要望を表す際に用いる特徴的な語彙であり，これらの単語の出現情報によって分類に成功したと考えられる．

一方，分類に失敗した事例は，システムが問題解決要求と誤分類した事例が 5 事例，システムが要望を含まない節であると誤分類した事例が 184 事例である．再現率を大きく低下させる要因である後者において，「べき」,「なければ」が節内に含まれる事例は 30 事例だけであり，残りの 154 事例は節内に学習に十分なほど特徴的な語彙が出現しないことが確認できる．これは，図 2 にある節 C_2 のように，節内に「べき」という単語が出現しないことによるものか，学習データに多く現れない要望に特徴的な語彙が存在するためであると考えられる．

5.　提 案 手 法

4. では，節内の bag-of-words のみを素性としていたが，再現率が著しく低い結果となった．そのため，判定対象の後続の節の語彙を素性として用いる必要があると考えられる．そこで本章では，後続の節の語彙情報を取り入れることや，節間の接続関係を表す節境界ラベルの利用によって分類精度を改善する手法について述べる．

5.1　モダリティ表現による要望判定と制約パターン

要望を含む節では「べき」や「てほしい」などの表現によって話者の相手への要望が表される．このような話者の心的態度を表す表現を本研究では「モダリティ表現」と呼ぶが，要望の判定では学習データに多く現れない語彙をパターンとして用いる必要があると考えられる．また，図 2 の節 C_2 では，節内の「べき」というモダリティ表現が出現しない場合が存在するため，分類精度の向上には後続の節も含めてモダリティ表現が出現するか判定するパターンも必要となる．

一方で，後続の節にモダリティ表現が存在するが，対象の節が要望を含む節ではない場合がある．次に示す例 2 では，節 C'_1 は要望と判定されないが，後続の節 C'_2 にはモダリティ表現「べき」が含まれる．

例 2 節 C'_1

自然災害による被害や今宮崎県のほうでも口蹄疫で大変な被害が出ていますけれども

例 2 節 C'_2

農作物や畜産の病気による被害にも行政としてしっかりと何らかの補償をすべきと考えております．

例 2 では，後続の節にモダリティ表現「べき」が現れるという条件による判定は誤りとなる．そのため，後続の節のモダリティ表現の出現を見る場合は，制約となるパターンが必要となる．

この点について，本手法では制約となるパターンとして，節 C'_1 中の「けれども」という接続助詞に着目する．図 2 の節 C_2 は連用接続であり，節内の述語が後続の節のモダリティ表現に係るが，節 C'_1 のように逆接の副詞節で主題の導入を表す場合は，後続の節のモダリティに係らないと考えられる．このような節の統語的分類は，CBAP が出力する節境界ラベル（節 C'_1 の場合，並列節）によって解析することができる．

そこで提案手法では，節境界ラベルを素性として用いることで，分類精度の向上を試みる．

5.2　節単位による要望抽出のための素性

節単位による要望抽出の課題には，**5.1** で述べたように次の二つの課題がある．

表 6　素性リスト
Table 6　Feature list.

素性	パターンの成立条件
f_1	C_t に含まれる単語の bag-of-words $\mathbf{p} < \mathbf{w_1}, \mathbf{w_2}, ..., \mathbf{w_n} >$.
f_2	$f_{\mathrm{mv_i}} = \begin{cases} 1 & \mathbf{m}_{\mathrm{mv}} \in C_{t+i} \ \{i = 0, 1, 2, 3\} \\ 0 & (otherwise) \end{cases}$ $f_{\mathrm{else_i}} = \begin{cases} 1 & \mathbf{m}_{\mathrm{else}} \in C_{t+i} \ \{i = 0, 1, 2, 3\} \\ 0 & (otherwise) \end{cases}$
f_3	f_{c0} = C_t の節境界ラベル． f_{c1} = C_t と C_{t+1} の節境界ラベルの 2 グラム． f_{c2} = C_t，C_{t+1} と C_{t+2} の節境界ラベルの 3 グラム． f_{c3} = C_t，C_{t+1}，C_{t+2} と C_{t+3} の節境界ラベルの 4 グラム．
f_4	C_t の最後の単語 w_n と，C_{t+1} の先頭 2 単語 w_1，w_2 の品詞 3 グラム．（品詞は MeCab で出力する細分類を用いる）
f_5	$\begin{cases} 1 & (\mathbf{m}_{\mathrm{mv}} \cup \mathbf{m}_{\mathrm{else}}) \in (DP_1 \cup DP_2 \cup DP_3). \\ 0 & (otherwise) \end{cases}$ DP_0 は C_t 内の品詞が動詞の単語で，DP_i は DP_{i-1} が係る(注8)単語である．
f_6	$\begin{cases} 1 & \text{疑問詞（“何”, “どのよう”, “なぜ”, “どこ”, “いつ”, “どう”）} \notin (C_{t-1} \cup C_t \cup C_{t+1}). \\ 0 & (otherwise) \end{cases}$
f_7	$\begin{cases} 1 & \text{理由・目的を表す語彙（“ため”, “向け”）} \ \notin C_t. \\ 0 & (otherwise) \end{cases}$
f_8	$f_{\mathrm{t(s)i}} = \begin{cases} 1 & td_s \in C_{t+i} \ \{i = 0, 1, 2, 3\} \ where \ td_s \in \mathbf{td} \\ 0 & (otherwise) \end{cases}$ （**td** は機能表現辞書つつじの文法的機能が助動詞型（ID:M）の表現で，見出し語は L7 のものを用いる．）

課題 1　判定対象の節内にモダリティ表現が存在しない場合がある．

課題 2　後続の節にモダリティ表現が存在しても，判定対象の節が要望を含む節にならない場合がある．

提案手法では，表 6 に示す素性を機械学習に用いることで，課題 1 と課題 2 の問題に対応する．課題 1 に対応するためには，後続の節のモダリティ表現を見る素性として f_2・f_8 用いる．また，課題 2 に対応するためには，構文情報の観点から，後続の節のモダリティ表現に制約を与える素性として f_3・f_4・f_5・f_6 を用いる．

まず，課題 1 を解決するための素性について説明する．素性 f_2 は後続の節のモダリティ表現を見る素性であり，用いるモダリティ表現の語彙は表 7 に示す 18 の語彙を設定し，判定対象の節と三つ後続の節にこれらの語彙が含まれるか見るパターンを設定した．

これらのパターンによって，**3.** で作成したクローズドデータに含まれる問題解決要求の節 235 のうち 205(87.2%) の節を被覆することが可能であり，十分な量のモダリティ表現を設定できている．加えて，更にモダリティ表現を増やすために，機能表現辞書つつじ(注6)から助動詞型の表現も素性 f_8 として設定した．

表 7　対象とするモダリティ表現
Table 7　Target modalities.

$\mathbf{m_{mv}}$ 助動詞・文末形式の モダリティ表現	べき，てほしい，なければ， ください，いただき
$\mathbf{m_{else}}$ 助動詞・文末形式以外の モダリティ表現	大事，重要，必要，普通，急務， 不可欠，責務，責任，意見， 希望，当然，求め，こそ

次に，課題 2 を解決するための構文情報の素性について説明する．まず，CBAP によって節ごとに与えられる節境界ラベルを用いた素性 f_3 を設定する．節境界ラベルは粒度が細かい分類では傾向を掴みにくくなるため，CBAP が出力する 144 の分類を表 8 に示す 10 種の大分類にまとめて使用する．

なお，小橋らによれば，モダリティ表現には「べき」

(注6)：http://kotoba.nuee.nagoya-u.ac.jp/tsutsuji/

表 8　対象とする節境界ラベル
Table 8　Target clause types.

連用節	～し（用言連用形），～には，～ため， ～だけ，～つつ，～て，～ながら， ～など，～ほか，～ほど，～まで， ～まま，～よう，～より，～なく
並列節	～が，～けれども，～し（並列節）， ～たり，～で，～とか
理由節	～から，～ので
条件節	～かぎり，～結果，～たら，～と，～ところ， ～なら，～ば，～ものの
時間節	～際，～うち，～おり，～瞬間，あいだ， ～たび，～あと，～今，～以来，～時，～前
譲歩節	～ても，～のに，～せよ
補足節	～のは，～ことが，～なのを
間接疑問節	～か
連体節	連体節-形式名詞，～かぎりの，～ための， ～という，～などの，～ほどの，～までの， ～ような，～ことへの，～の+形式名詞， ～の+形容動詞
文末または その他	～．など

や「てほしい」などの助動詞・文末形式に加えて，助動詞・文末形式以外の「～することを確信している」や「～することが必要」といった表現が存在するといわれている [18]．構文情報として用いる節境界ラベルのパターンに対応するモダリティ表現も異なると考えられるため，対象のモダリティ表現を助動詞・文末形式のモダリティ表現 $\mathbf{m_{mv}}$ と，助動詞・文末形式以外のモダリティ表現 $\mathbf{m_{else}}$ の二つに分類し，二次多項式カーネルによって構文情報との組合せとして考慮できるようにする．

また，構文情報として，節境界ラベルの他に有効と考えられる素性も検討する．まず，節境界ラベルと類似した構文情報として，二つの節の間に近い単語の品詞系列を利用する素性 f_4 を設定する．例えば，要望を表す表現として現れる「～する必要がある」という語が含まれる文の場合,「する」の間に節境界（節境界ラベルは連体節）が存在し，動詞→名詞→助詞（細分類省略）の系列パターンが付与される．この品詞の系列パターンを判別に必要な情報として設定する．次に，図 2 にある節 C_2 の動詞「実施し」は，後続の節に存在する「べき」を修飾しているが，このような修飾関係を係り受け解析器の CaboCha [19] を用いて解析し，判定対象の節中の動詞がモダリティ表現に係るか判定する素性 f_5 を設定する．また,「“どう”すべきか～」等，モダリティ表現があっても要望にならなくなる疑問詞が周辺に存在する場合に対応する素性 f_6 も利用する．

なお，(1)，(2) 以外の素性としては **3.** のクローズドデータ作成時に要望としなかった，理由を表す節を対象としないことに対応する素性 f_7 も設定した．

なお，全ての素性は条件が成り立った場合 1 となり，そうではない場合 0 となるバイナリー素性である．これらの素性で構築される素性の数は，$f_5 \cdot f_6 \cdot f_7$ は一つずつ，f_2 は八つであり，それ以外の $f_1 \cdot f_3 \cdot f_4 \cdot f_8$ はそれぞれ，データ中に出現した，語彙・節境界ラベルのパターン・品詞列・機能表現辞書の特定の意味コードの数に依存する．図 3 に，図 2 の節 C_2 において条件が成り立つ素性を示す．

6. の評価実験では，これらの素性を用いて，f_2 のモダリティ表現，f_3 の節境界ラベル，f_4～f_8 の追加の素性の有効性について確認する．

6. 評価実験

本章では，**5.2** で検討した提案手法の精度について評価する．評価実験では表 5 の bow 単体である f_1 に対し，モダリティ表現の出現を判定する f_2，節境界ラベルのパターンを見る f_3，他のモダリティ表現，構文情報を取り入れる f_4～f_8 の有効性を確認する．また，実験対象とするデータは，**3.** で作成したクローズドデータの問題解決要求に対して評価し，また分析対象と異なるデータに対しても提案手法の有効性を確認するために，**3.** で作成したオープンデータである 5,388 節についても評価する．提案手法の有効性は，これら双方のデータに対して 10 分割交差検定を行って検証する．最後に正解事例の特徴と課題について考察する．

6.1 実験条件

学習に用いたパラメータやカーネルの設定は **4.** で述べたものと同様とする．

検証する素性の組合せは，bow 単体である f_1，モダリティ表現を加えた $f_1 + f_2$，それに節境界ラベルのパターンを加えた $f_1 + f_2 + f_3$，モダリティ表現 f_2

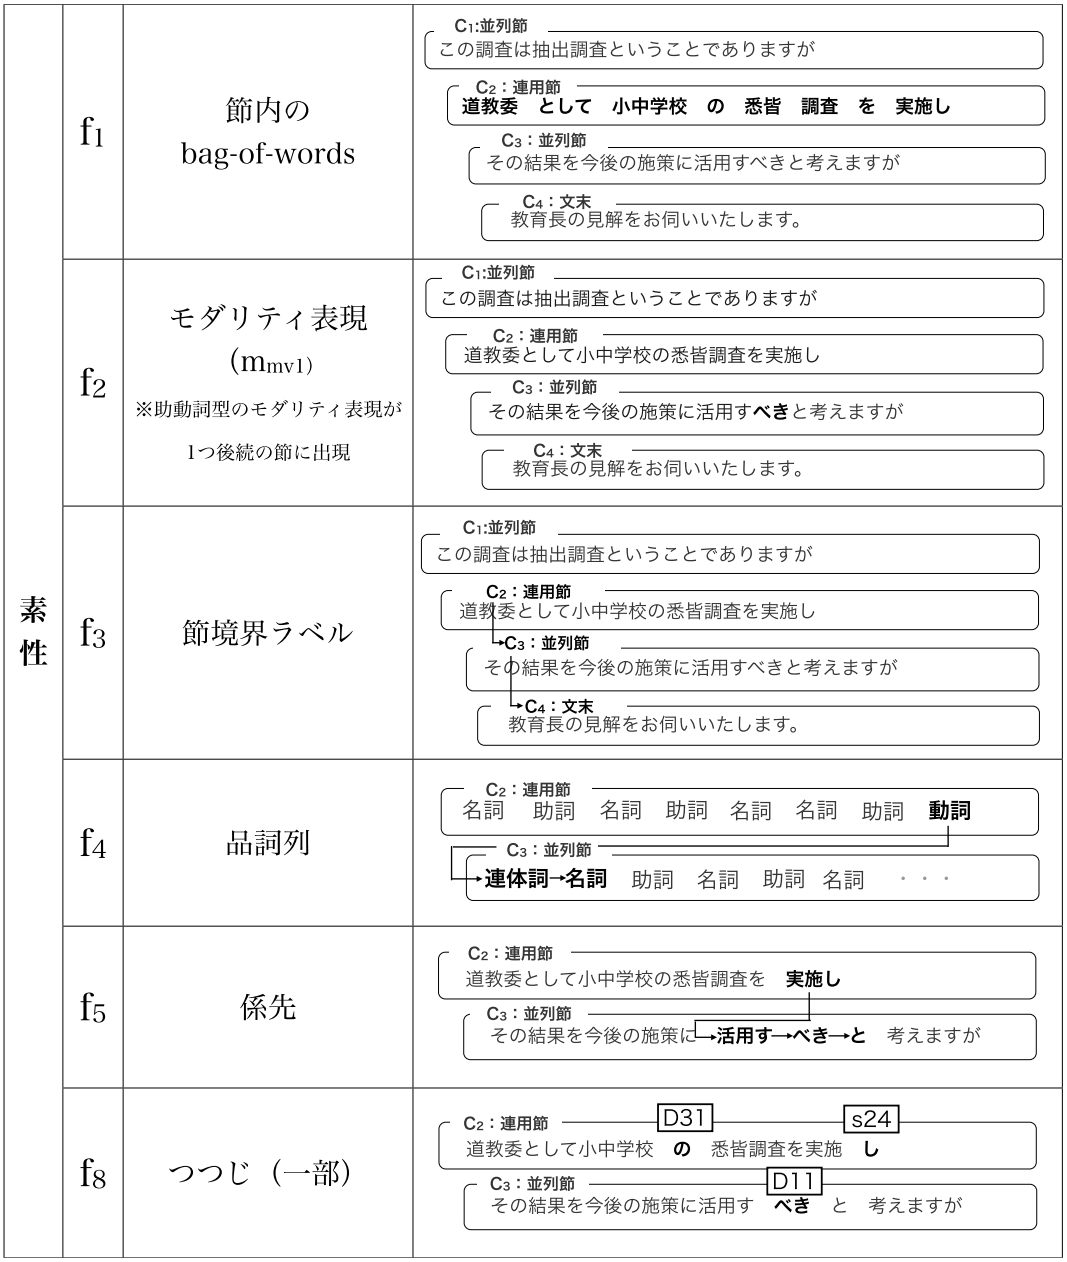


図 3　図 2 の節 C_2 で成り立つ素性の例
Fig. 3　Example of features for C_2.

に他の考慮する必要があると考えられる f_4〜f_8 を加えた $f_1 + f_2 + f_4 \sim f_8$，全素性を用いた $f_1 \sim f_8$ である．これにより，特に有効と考えられるモダリティ表現，節境界ラベルの素性と，他の考慮すべき素性の有効性を検証する．

6.2 実験結果

表 9 にクローズドデータに対する実験の結果を示す．表 9 から以下の 4 点が確認される．

- f_1 にモダリティ表現 f_2 を加えた場合，適合率は低下するが，再現率が上昇する．

表 9　実験結果
Table 9　Experimental results on closed data.

クローズドデータ				
素性	素性数	適合率 [%]	再現率 [%]	F 値
f_1	4,360	91.1	20.3	0.325
$f_1 + f_2$	4,368	84.1	33.5	0.474
$f_1 + f_2 + f_3$	5,713	92.9	38.8	0.539
$f_1 + f_2 + f_4 \sim f_8$	5,420	77.3	50.8	0.607
$f_1 \sim f_8$	6,772	81.8	56.1	0.661

表 10　実験結果
Table 10　Experimental results on open data.

オープンデータ				
素性	素性数	適合率 [%]	再現率 [%]	F 値
f_1	4,087	97.2	31.8	0.477
$f_1 + f_2$	4,095	93.0	38.8	0.544
$f_1 + f_2 + f_3$	5,321	93.1	49.7	0.643
$f_1 + f_2 + f_4 \sim f_8$	5,101	87.9	57.2	0.691
$f_1 \sim f_8$	6,334	87.2	61.5	0.720

- 節境界ラベル f_3 を追加すると，適合率と再現率がともに上昇する．
- 他のモダリティ表現，構文情報を取り入れる $f_4 \sim f_8$ を追加すると再現率が上昇する．
- $f_4 \sim f_8$ に更に f_3 を加えた場合，適合率，再現率が共に上昇する．

したがって，モダリティ表現 f_2，節境界ラベル f_3，他のモダリティ表現，構文情報を取り入れる $f_4 \sim f_8$ の有効性が確認され，特に節境界ラベル f_3 によって適合率の高い分類が可能となっていることが確認された．

次に表 10 にオープンデータに対する実験結果を示す．オープンデータではモダリティ表現，節境界ラベルによって再現率向上が見られ，他のモダリティ表現，構文情報を取り入れる素性は適合率の減少と再現率の向上が見られる．なお，オープンデータでは全体的にクローズドデータと比較して F 値の向上が見られるが，これは問題解決要求の節数がクローズドデータと比較して多いためであると考えられる．

以上の結果より，各素性の有効性，モダリティ表現による再現率向上，節境界ラベルによって適合率を低下させずに学習できることが確認された．

6.3 考　　察

本節ではまず，追加した素性の有効性を確認するために，クローズドデータの正解事例について，bag-of-words のみと全ての素性を用いた際の結果を比較する．次に，誤分類の事例を，事前に分析していないオープンデータの実験結果を用いて考察する．なお，考察では正解事例は問題解決要求の分類に正解した事例を指し，また事例数は 10 分割交差検定における 10 分割された分類対象を全て合計したものとする．

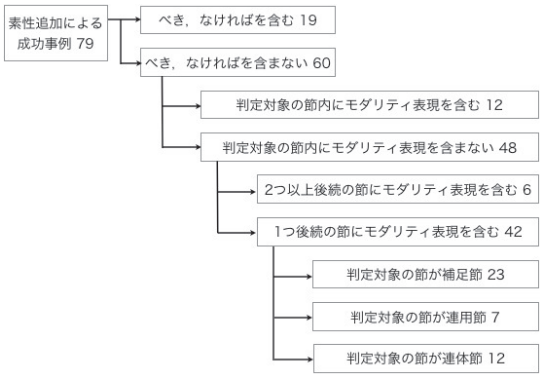


図 4　全素性を用いることで正解できた事例の内訳
Fig. 4　The Itemization of positive case with all features.

全ての素性を用いた場合，クローズドデータで分類に正解した事例数は 129 であり，そのうち 79 事例が f_1 のみの場合と比較して正解できるようになった．図 4 に 79 事例の内訳を示す．

図 4 より，**4.2** で課題であった，判定対象の節にモダリティ表現が含まれない事例 48 が成功しており，提案手法の有効性が確認できる．また，一つ後続の節にモダリティ表現が存在する場合，節境界ラベルは補足節（～することが必要，など）が 23，連用節（～

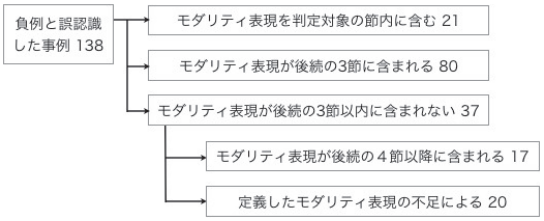


図 5　要望を含まない節であると誤分類した事例の内訳
Fig. 5　The itemization of negative case misclassification.

し，～すべき～，など）が 7，連体節（～する必要がある，など）が 12 となっており，特徴的な節境界ラベルの事例が成功していることが分かる．

次に，オープンデータの実験結果を用いて誤分類の特徴を考察する．誤分類の事例数は，要望を含まない節と誤分類した事例は 138 で，要望を含まない節を問題解決要求と誤分類した事例は 32 である．再現率に影響する前者の内訳を図 5 に示す．

図 5 より，後続の 3 節までにモダリティ表現が含まれる事例数は 80 である．したがって，提案手法で考慮した後続の 3 節にモダリティ表現が含まれる場合は依然として分類が困難であると考えられる．また，判定対象と後続の 3 節に定義したモダリティ表現が含まれない事例は 37 存在する．そのうちの 17 例は後続の 4 節目以降にモダリティ表現が含まれており，残りは定義したモダリティ表現が不足していると考えられる事例である．不足したモダリティ表現は「大切」や「可能」などの単語 1 語で表せるものや，フレーズによる「～することがモデルケースとなり得る」のように，間接的に事態を肯定的に述べる表現も含まれる．したがって，更なるモダリティ表現の拡張や，モダリティ表現が存在する節までに多数の節を経由する場合の分析が必要になると考えられる．

また，問題解決要求と誤分類した事例では，問題解決要求ではないがモダリティ表現は含まれていない節が 35 存在する．その要因は多様であり，他者の引用にモダリティ表現が含まれることや，教育の文脈で見られる「指導者は～しなければならない～」という発言のように，行為の主体が自治体ではないために要望とならない節が含まれる．提案手法はモダリティ表現に依存する手法であるため，モダリティ表現が存在しても要望を含まない節となる事例は学習のノイズになったと考えられる．そのため，類似した事例を調査し，更に考慮すべき素性を検討する必要がある．

7. むすび

本手法では，住民が議会で行われている議論を容易に把握できるようにするために，議員の質問から自治体に対しての要望を含む発言箇所の抽出を行った．要望を含む発言箇所の抽出では，会議録は一文が長くなるため，文単位ではなく，文内で要望に関わる箇所を節単位によって抽出することを検討した．一方，節単位による要望抽出では，判定対象の節内の bag-of-words のみでは再現率が低くなる問題が生じることを確認した．

そこで提案手法として，後続の節に存在するモダリティ表現が出現するか見る素性，節境界ラベルなどの構文情報による素性を追加することで，再現率，適合率の向上を試みた．評価実験では，節内の bag-of-words と全ての素性を用いた場合を比較し，クローズドデータの F 値に 33.6，オープンデータの F 値に 24.3 ポイントの向上を確認した．特に，節境界ラベルの素性を追加した場合，他の素性と比較すると適合率を低下させることなく再現率を向上させることが確認され，節単位による要望抽出では節境界ラベルの構文情報が重要であることが明らかになった．

今後は，学習データ，モダリティ表現，素性の追加を通じて本研究で判定に失敗した事例の分類精度向上を行い，ユーザが抽出した要望によって会議録の理解が容易になったかについて検証していく予定である．

文　献

[1] 高丸圭一，木村泰知，渋木英潔，“全国の市町村議会会議録のウェブ公開とデータ提供の状況，” 宇都宮共和大学都市経済研究年報，第 11 号，pp.47–72, 2012.
[2] A. Tumasjan, T.O. Sprenger, P.G. Sandner, and I.M. Welpe, “Predicting elections with twitter: What 140 characters reveal about political sentiment,” ICWSM, vol.10, pp.178–185, 2010.
[3] W. Weerkamp and M. deRijke, “Credibility-inspired ranking for blog post retrieval,” Information Retrieval, vol.15, no.3-4, pp.243–277, 2012.
[4] 木村泰知，渋木英潔，高丸圭一，乙武北斗，小林哲郎，森辰則，“地方議員マッチングシステムにおける能動的質問のための質問生成手法，” 人工知能学会論文誌，vol.26, no.5, pp.580–593, 2011.
[5] H. Otsuka, M. Uchiyama, and H. Isahara, “Request-intention judging criterion for open-ended questionnaires,” J. Natural Language Processing, vol.11, no.2, pp.21–66, 2004.
[6] H. Kanayama and T. Nasukawa, “Textual demand analysis: Detection of users’ wants and needs from opinions,” COLING ’08 Proc. 22nd International

Conference on Computational Linguistics, vol.1, pp.409–416, 2008.
[7] 川端正法，山本和英，“話題の継続に着目した国会会議録要約，” 言語処理学会第 13 回年次大会，pp.696–699, 2007.
[8] 丸山岳彦，柏岡秀紀，熊野　正，田中英輝，“節境界自動検出ルールの作成と評価，” 言語処理学会第 9 回年次大会，pp.517–520, 2003.
[9] 益岡隆志，田窪行則，基礎日本語文法—改訂版，くろしお出版，1992.
[10] 山本和英，安達康昭，“国会会議録を対象とする話し言葉要約自然言語処理，” 自然言語処理，vol.12, no.1, pp.51–78, 2005.
[11] D. Diermeier, J.-F. Godbout, B. Yu, and S. Kaufmann, “Language and ideology in congress,” Annual Meeting of the Midwest Political Science Association, 2007.
[12] Y. Takayama, Y. Tomiura, E. Ishita, Z. Wang, D. Oard, K. Fleischmann, and A.-S. Cheng, “Improving automatic sentence-level annotation of human values using augmented feature vectors,” Proc. 13th Conference of the Pacific Association for Computational Linguistics, 2013.
[13] 高野敦子，池奥渉太，北村泰彦，“因果関係に着目した口コミ web サイトからの評価表現抽出，” 人工知能学会論文誌，vol.24, no.3, pp.322–332, 2009.
[14] J. Cohen, “A coefficient of agreement for nominal scales,” Educational and Psychological Measurement, vol.20, pp.37–46, 1960.
[15] J.R. Landis and G.G. Koch, “The measurement of observer agreement for categorical data,” Biometrics, pp.159–174, 1977.
[16] J.C. Platt, 12 fast training of support vector machines using sequential minimal optimization, pp.185–208, MIT Press, 1999.
[17] C.-C. Chang and C.-J. Lin, “LIBSVM: A library for support vector machines,” ACM Trans. Intelligent Systems and Technology, vol.2, pp.27:1–27:27, 2011. Software available at http://www.csie.ntu.edu.tw/~cjlin/libsvm
[18] 小橋洋平，坂野達郎，“階層意味論に基づいた心的態度のアノテーション，” 宇都宮共和大学都市経済研究年報，vol.18, pp.323–350, 2011.
[19] 工藤　拓，松本裕治，“チャンキングの段階適用による日本語係り受け解析，” 情処学論，vol.43, no.6, pp.1834–1842, 2002.

（平成 26 年 12 月 18 日受付，27 年 5 月 22 日再受付，
7 月 15 日早期公開）



葦原　史敏

平 24 小樽商科大・商・社会情報学科卒．現在，北大大学院情報科学研究科博士前期課程に在学中．自然言語処理の研究に従事．



木村　泰知　（正員）

平 8 北海学園大・工・電子情報卒．平 16 同大大学院工学研究科博士課程了．工博．平 17 小樽商科大学商学部社会情報学科助教授．平 19 同准教授．自然言語処理　特に，地方議会会議録を対象にした情報抽出に関する研究に従事．



荒木　健治　（正員）

昭 57 北大・工・電子卒．昭 63 同大大学院博士課程了．工博．同年，北海学園大学工学部電子情報工学科助手．平元同講師．平 3 同助教授，平 10 同教授．平 10 北大・工・電子情報工学専攻助教授．平 14 同教授．現在，北大・情報科学・メディアネットワーク専攻教授．自然言語処理，特に機械翻訳，対話処理の研究に従事．情報処理学会，人工知能学会，言語処理学会，ACL，IEEE，AAAI 等各会員．