ことば工学研究会資料
SIG-LSE-B501-5 (9/26)

書籍の季節推定手法における季語の有効性

Effectiveness of Haiku Seasonal Words for Season Estimation Algorithm

伝住颯夏　　ジェプカ ラファウ　　荒木健治
Satsuna Denzumi　　Rafal Rzepka　　Kenji Araki

北海道大学大学院 情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

あらまし
書籍作品の推薦において，読者に注目される要素の一つに書籍の季節が挙げられる．我々は季節の推定について，「俳句に用いられる季語に着目することで間接的に季節の推定が可能になる」という仮説を立て，この仮説を確認するために，一部旧暦を基準とする季語の再分類，誤抽出の多い季語の除去を行い季節推定用季語リストの作成を行った．また，リストと各季節との共起について調査を行い，対応する季節に共起すること及び季節ごとの特徴の確認を行った．次に，季語リストを用いた提案手法と tf-idf 法を用いた手法について推定精度の比較を行った結果，提案手法の平均推定精度は 90.5%であり，tf-idf を用いた手法の平均推定精度 63.5%を大きく上回り，季語に着目することで書籍の季節を効果的に推定できるという本仮説を用いた提案手法の有効性が確認された．
キーワード　書籍推薦，季語，季節推定

Abstract
In the book recommendation task, season can be one of various factors which mirrors reader's interests. We hypothesized that it is possible to indirectly estimate a season by utilizing seasonal words used in Haiku poetry. In order to confirm this hypothesis, we re-classified a seasonal words list that used old lunar calendar and removed misused words in order to perform the season estimation. In addition, we investigated word occurrences for each season and automatically confirmed that the words co-occur with season names. Then, we compared the accuracy of the proposed method with the tf-idf method. The average estimation accuracy of the proposed method is 90.5%, and the tf-idf method is 63.5% which proves that the proposed method is superior and confirms that season recognition is possible for written texts.
Key words:　books recommendation, seasonal words, season estimation

1．まえがき

近代に入りインターネットをはじめとした情報通信技術の発達やストレージの小型化・大容量化に伴い，情報の蓄積とその流通に必要とされる各種コストは過去と比較して大きく減少し，一定の通信環境を確保できる人々は地域やジャンルを問わず古今東西の様々な作品を得ることが容易な環境を得た．そのため，現代において人が触れることのできる情報量は個人が認識し把握できる範囲を遥かに超えるものであり，それ故にそれら膨大な情報の中から自身の希望・嗜好に沿ったものをスムーズかつ正確に探し出して利用者に提供する推薦システムの重要度が増している[1]．その一つである書籍推薦システムの例として，Amazon に登録された商品ページから書籍情報の各種特徴を取得し，それに基づいた内容ベースの推薦を行う Libra[2]がある．Libra が取得する書籍情報の中には書籍のあらすじも含まれているが，登録されたあらすじの記述が内容に対して非常に重要である，作者の来歴など作品の内容とは直接関係のない情報が含まれる，あるいはあらすじ自体が存在しないなど，登録されたあらすじは決して推薦に十分な情報とは言えず，書籍の内容を反映した推薦を行うことが難しいという問題点がある．

その問題を解消し，より書籍の内容を反映した書籍推薦システムを実現するため，書籍作品を構成する要素である 5W1H の中から特に【Who】【Where】【When】の 3 要素に着目した書籍の内容依存推薦システム[3]を提案した(システムの詳細については 2 章で解説する)．このシステムは書籍全体を構成する単語を解析し，3 要素それぞれに該当する出現頻度が上位の単語をその書籍の特徴を表すキーワードとして登録し，キーワードを基準として書籍を比較し推薦を行う．しかし取得するキーワードの中で，書籍内の時間に関する情報を表す【When】の要素は描写が少ない傾向にあり十分な取得を行えず，およそ 5 割の作品で実際の書籍の内容を正しく反映することに失敗した．このことから，書籍内の時間に関する単語を単純に参照するだけでは書籍内の時間に関する情報を十分に取得できず，推薦に反映させることは難しいことが分かる．

その一方で，国内最大の出版販売会社である日本出版販売株式会社が運営するオンライン書店サイトの HonyaClub.com では，指定されたテーマをもとにしたユーザーによる書籍推薦企画[4]が定期的に実施されている．その中には「夏の文庫」といった，季節と深く関わりを持った推薦テーマが複数回提示されており，このことから書籍内の時間に関する情報は推薦において決して不要

なものではなく，その中でも特に季節は重要な要素の一つとなり得ることが推察される．また，システムが文章から知識を獲得することを目的とした machine reading の研究分野において，文書内からそこに記述された時期を発見することは文脈理解に繋がるとも考えられており，そのような視点から見ても書籍内の季節推定を機械的な処理により実現することは，重要なテーマになり得ると考えられる．

今回は書籍内である季節について描写される際，描写量が多い季節ほどその書籍にとって重要な季節であるという仮定のもと，日本特有の文化である俳句を詠む際に季節を表す語句として用いられる季語を書籍の本文全体から抽出し，その出現頻度に着目した季節推定手法について有効性の確認を行う．提案手法は，数百年の歴史を通して多くの人々によって育まれ，時代の変化に伴い新たな要素を取り入れながら洗練されてきた俳句を構成する季語に着目しそれを活用することで，書籍の本文中に直接的な季節に関する単語の描写がなくとも書籍内の季節を間接的な形で効果的に推定することが可能であると考える．

2．関連研究

書籍作品内の時間情報を推定する研究の例としては，奥村・瀧本による物語文章の時系列推定手法が挙げられる[5][6]．ただし，この研究の目的は物語文章の要約を機械的に生成することであり，要約と推薦では必要とする時間情報の種類が若干異なる．要約を行う際は作品中の時系列を正しい順序で認識することが非常に重要であるが，推薦を行う場合は要約ほどに詳細な時系列情報を必ずしも必要とせず，対象となる作品も物語に限らず様々なカテゴリの書籍を扱うとしている．また，概念ベースや関連度計算方式を用いることで登録されていない未知語を処理する機能が備わっているものの，予め人手によって作成された時間に関する単語のデータベースには時間帯単位，年月日単位，季節単位，人生単位の四単位計 511 語しか登録されておらず，著者や時代，ジャンルにより様々な文体・形式で記述される作品に対応するにはデータ不足となるのではないかという不安も挙げられる．

1 章で取り上げた内容依存推薦システムは，ある入力書籍に対してデータベースに登録されている書籍の中から入力書籍と最も似た要素を持つ書籍を推薦するシステムである．このシステムは大きく分けてキーワード取得処理とキーワード比較処理の二つの処理に分かれ，前半のキーワード取得処理では日本語形態素解析システムである JUMAN[7]を用いて本文全体の形態素解析を行う．解析結果から JUMAN 辞書を参照し，該当するカテゴリ情報が登録されている単語を【Who】【Where】【When】の 3 要素にそれぞれ分類し，各要素の出現頻度上位 5 単語，合計で最大 15 単語をその書籍のキーワードとして取得する．ただし，出現頻度が上位であっても多くの作品に共通して出現する単語はストップワードとして扱い，除外して取得処理を行う．そして後半のキーワード比較処理では，前の処理で得た各要素のキーワードとその出現頻度を他の書籍と比較する．初めにキーワードの一致数に，次にキーワードの一致数が同数の場合は一致したキーワードの出現頻度に着目して計算を行い，最も高いスコアを得た作品を入力作品に近い要素を内包する推薦作品として決定し出力する．実際に「蟹工船」のキーワードを取得した例を表 1 に，「蟹工船」を入力書籍とした時に，推薦作品候補として挙げられた「無人島に生きる十六人」と「党生活者」の比較例を表 2 に示す．上位に位置するキーワードほど出現頻度が高く，また下線が引かれている単語が入力書籍と一致したキーワードであり，この場合は「無人島に生きる十六人」が推薦書籍として選択される．

表 1 キーワード取得例

蟹工船		
【Who】	【Where】	【When】
漁夫	海	度
船	日本	瞬間
監督	工場	初め
夫	函館	か月
船長	会社	毎日

表 2 キーワード比較例

無人島に生きる十六人		
【Who】	【Where】	【When】
船	島	時分
魚	海	毎日
あざらし	日本	午後
伝馬船	国	冬
長	矢倉	晩

党生活者		
【Who】	【Where】	【When】
同志	工場	毎日
我々	会社	最近
女工	警察	その後
母親	仲間	昼
母	組織	時期

ただし表 1，表 2 から分かるように時間を表す【When】のキーワードは「毎日」や「その後」，「最近」や「瞬間」など書籍内の季節に関する情報の推定に役立つ単語は少なく，更に短編作品では【When】のキーワード自体がほぼ存在しないケースも確認されている．また，春夏秋冬などの季節を表すキーワードが取得されても，書籍内の季節の一部しか反映できていない場合，あるいは書籍内の季節とキーワードの間に全く関係がない場合があり，キーワードだけを参考に書籍内の季節を推定することは危険である．表 2 でも「無人島に生きる十六人」のキーワードに「冬」という単語が出現しているが，実際に書籍内で描写されている季節は一年を通した四季であり，このキーワードだけでは本当に書籍内の季節は冬なのか，判断基準となる材料が少なく推定結果に不安が残る．

また，筆者は以前にも季語を用いた書籍の季節推定手法[8]について提案を行った．本稿と同様に，季語の出現頻度に着目することで効果的な書籍の季節推定を行えるという仮説のもと実験を行い，季語が書籍の季節推定に対し一定の有効性を持つという結果を示した．しかし，季語の一部が旧暦に対応するために現代の季節認識とずれが生じることを考慮せずに各季節の季語リストの作成を行った，評価実験において季節推定の対象となる書籍作品のサンプル数が全体で 50 作品と少なくその季節にも偏りが生じていた，提案手法と比較する対象であるベースラインが存在しなかったなど，提案手法が有効であることを確認するための信頼性が十分ではなかった．このため，本稿ではそれらの問題に対し対応した上で再度評価を行う．

3．季節

そもそも季節とは何か．辞典を確認すると「1 年を天候の推移にしたがって分けたときの，それぞれの区切り」(デジタル大辞泉)とされている．日本は主に本州を中心として温帯気候に属するため春夏秋冬の四季が存在し，四季の区切り方はまず旧暦か新暦かで変化する．その上で二十四節気や暦月，あるいは年度など季節の区切りを定義する複数の基準が存在するため，春夏秋冬それぞれの期間はおおよそ一年を四等分することに変わりはないものの，採用される基準によって季節の境界線の位置は変化する．

本稿で着目する季語は基本的に旧暦を基準とする一方で，一部では新暦を基準とする混合構成となっているが，現代社会で生活する人々は主に新暦を基準とし，特に気象庁が定めている基準[9]を目にする機会が最も多いため，それを一般的な基準として季節を認識し生活を営んでいると考えられる．また，表 3 に示すように先述した気象庁の基準をもとに考えても旧暦と新暦ではおよそ 1 か月から 2 か月のずれが生じるため，このままずれを放置していると季節推定の精度とその結果への信頼性を損なうことへと繋がる危険性がある．そのため，まず季節推定手法を利用する予定である現代人が普段新暦か旧暦か，またどの基準を参考にして季節を認識しているか調査を行い，季語と人間の間で季節に関する認識を統一する必要がある．

表 3 新暦と旧暦の季節区分

	春	夏	秋	冬
旧暦	2月～4月	5月～7月	8月～10月	11月～1月
新暦	3月～5月	6月～8月	9月～11月	12月～2月

そこで事前調査として，20 代日本人男性，理系大学院生 20 人に対して事前データは何も示さずに「自身が直感的にイメージする季節の区切り」というテーマで聞き取り調査を行った．調査結果を見ると個人によって若干異なる部分があるものの，20 人全員が新暦かつ気象庁が定める基準に基づいた季節感を持っていることが分かった．この結果から，今後四季については新暦かつ前述した気象庁が定める季節区分をベースとして考える．ただし，特に北方地域の出身者は冬の期間を本来よりも長く捉える傾向が見られた．また，20 代ポーランド人男性，理系大学院生 3 人に対しても同様の聞き取りを行った結果，日本人を対象とした調査結果とほぼ同じ結果を得られたことから，近い緯度に位置する国家出身の人々の季節感はある程度近い認識になる傾向があるとも考えられる．

4．季語

季語とは「俳句で，季節と結びついて，その季節を表すと定められている語」(デジタル大辞泉)である．一般的に季語は春夏秋冬の四季と新年を合わせて五季に分類されており，季語辞典や俳句の選択，個人の詠み手によって認識される季語の種類，数，該当する季節は異なる場合がある．また，時代の変化とともに新しい季語が認められる，あるいは季語の対応する季節が変更されるケースも存在する．

その中でも最も認知度が高く，一般に浸透していると考えられる現代俳句協会が作成した季語データベース[10]をもとにして，書籍の季節推定に用いるため春夏秋冬それぞれの季節に対応する季語を収録した季節ごとの季語リストを作成する．

季語データベースは季語 1 語に対してその季語のよみがな，旧仮名，傍題・別名の 3 種の情報が付随しており，データベースには四季に新年の季語を加えて合計で 2,766 種の季語が登録されている．ただし季語の一部は旧暦を基準としているため現代の季節感覚とずれているものが存在しており，前章で確認した季節区分に基づいた形でそれらの季語を再分類する必要がある．また，季節推定において新年の区分は存在しないため，新年の季語も四季に再分類する．

季語の再分類は 20 代日本人男性，理系大学院生 1 人と社会人 2 人の計 3 人に依頼して行った．春夏秋冬の季語については表 3 の季節区分を参考として元々対応していた季節とその一つ前の季節，新年の季語については冬と春を再分類先の対象とする．新年の季語はその時期から冬の季語であると考えられるが，年が明けたことでそれらは春を表すという意見も存在するため，冬と春の二季を対象とする．評価者は季語の意味が分からなければ書籍またはインターネットで調べ，語句の意味または特徴を理解した上でどちらの季節に所属するのが適当であるか考え投票し，過半数の票を得た季節へと季語を再分類する．従来の季語分類とは異なる季節に対応すると判定された季語の数と，その具体例について表 4 に示す．

表 4 該当季節が変化した季語と例

	種類	例
春→冬	29	流氷・旧正月
夏→春	57	母の日・筍
秋→夏	42	中元・七夕
冬→秋	39	焼芋・ボジョレー
新年→冬	231	初日の出・福袋
新年→春	0	

また，季語リストの中には「うに」や「たか」，「のみ」など季語としての意味以外の文脈から誤って抽出されるために推定結果に悪影響を与える可能性が高い語句，また季語データベース内に重複して表記されていた語句がそのまま存在する．それらをストップワードとして季語リストから削除するため，重複語句についてはその片方を削除し，誤抽出の多い語句を把握するため青空文庫[11]の日本文学小説・随筆から無作為に 100 作品を抽出し，各季節の季語リストと本文を参照した．その結果を確認し，100 作品全体を通して 10 回以上抽出された上でその 5 割以上が誤った文脈からの抽出であった季語をストップワードとして認定し，季語リストから削除した．季節ごとに認定されたストップワードの数と，その具体例を表 5 に示す．これらのストップワードの中には，「春」「夏」「秋」「冬」の季節を直接表す語も含まれる．そして，再分類とストップワードの除去を行った結果である最終的な季語リストの語数とその例について表 6 に示す．

表5 ストップワード

	語数	例
春	105	さより・霧島
夏	101	はあり・かに
秋	142	をとり・橙
冬	297	かも・をし

表6 最終的な季語の語数と例

	種類	語数	例
春	645	2,791	桜餅・ピクニック・蛤
夏	802	3,253	鰻・蚊取線香・ヨット
秋	543	2,123	豊作・松虫・秋刀魚
冬	776	2,739	鏡餅・河豚・ゲレンデ

提案手法は季語リストに収録された語句を書籍内の本文から直接検索して抽出し，季節ごとに該当する季語の出現頻度を計測し，最も出現頻度の高い季節が書籍内の季節であると推定して出力する．日本語形態素解析システムである MeCab[12]や JUMAN などを用いて形態素解析を行わずに直接本文を参照するのは，決して少なくない数の季語が，MaCab や JUMAN で形態素解析を行うことでリストに記されている語句以上に分解されてしまい，季語として正確に抽出することが難しいと判断したためである．実際に形態素解析システムが季語を解析した例について，表7に示す．

表7 季語の形態素解析例

季語	解析結果
春季闘争	春季/闘争
時の日	時/の/日
新蕎麦	新/蕎麦
玉子酒	玉子/酒

5．季語と季節の共起

5．1．実験

特定の季節と強い結びつきを持ち，その季節を表すとされる季語であるが，単純に季節を示す文字とも共起する傾向にあるのか．もし季節を示す文字と高い精度で共起が発生するのであれば書籍の季節推定手法の一つとして候補に挙がるため，季節推定の比較実験を行う前に確認を行う．各季節の季語リストに収録された語句と，季節を示す文字である「春」「夏」「秋」「冬」それぞれとの共起頻度について，YACIS コーパス[13]を対象として共起頻度を観測し，対応する季節と最も高い共起頻度を得た語句を正解としてその割合に着目する．

結果を以下に示す．対応する季節と最も高い共起頻度を得た季語の割合と，その季語の中でも次点の共起頻度を得た季節と 2.0 倍以上の差をつけた季語の割合について表7に示す．ただし，割合を計算する際にはいずれの季節とも全く共起を示さなかった語句は除外して計算を行う．それぞれの季節について，春の季語リストにおいて 63.5%の語句が「春」と，夏の季語リストにおいて 74.2%の語句が「夏」と，秋の季語リストにおいて 62.0%の語句が「秋」と，冬の季語リストにおいて 44.1%の語句が「冬」と最も高い共起頻度を得ており，全ての季語リストにおいて収録されている季語群は対応当する季節と最も高い共起頻度を得た．また，該当する季節と最も強く共起した季語のうち，春の季語は 67.5%の割合で，夏の季語は 62.7%の割合で，秋の季語は 69.8%の割合で，冬の季語は 58.1%の割合で次点の共起頻度を得た季節に 2.0 倍以上の共起頻度の差が開き，これらの語句は対応する季節と特に強い結びつきを持つことが確認された．

表8 共起結果

	対応する季節と最も共起した語句	次点季節と共起差2倍
春	63.2%(1087/1719)	67.5%(734/1087)
夏	74.2%(1528/2059)	62.7%(958/1528)
秋	62.0%(870/1403)	69.8%(607/870)
冬	44.1%(731/1659)	58.1%(425/731)

5．2．考察

表8に示したように，各季節の季語リストは対応する季節と最も高い共起を示すことが確認された．また，スコアが最も高かった夏の季語リストとスコアが最も低かった冬の季語リストの間には 30 ポイント以上の差が開く結果となったが，この原因は主に三つに分類される．一つ目は季語とセットで用いられることが多い単語に，季節を示す文字が含まれる場合である．今回作成した冬の季語リストは新年の季語も含んでいるが，新年の季語は新年の挨拶である「迎春」をはじめとした「春」を含む語句とセットで扱われるケースが多かったために，新年の季語は春と強い共起を示す傾向にあることが確認された．また，「なまはげ」や「きりたんぽ」，それに「はたはた」といった語句はいずれも冬の季語リストに収録されている季語であるが，いずれも都道府県で唯一季節を示す文字を含む「秋田県」と関係の深い語句であるために秋と特に強い共起を示している．

二つ目は季語自体に対応する季節とは異なる季節の文字が含まれる場合である．一例を挙げると，冬の季語リストには「小春〜」といった語句が収録されている．これは本来 11 月〜12 月初旬の初冬を示す言葉であるが，現代では真冬や冬の終わりに春が近付いている意味，また春の様子を表す意味で使われることも多い．YACIS コーパスにおいては特に「小春日和」の出現頻度が非常に高く，他の冬の季語もこの語句と共に記述されることで内容としては冬について語っていながら，春と共起を示すと判断された例も存在する．

三つ目は季節に対して人が抱くイメージの傾向が偏りを見せる場合である．冬が最も分かりやすく，例を挙げると冬の悪天候や寒さを受けて「早く春が来てほしい」，あるいは受験において「春を目指して頑張ろう」といった春に関する記述が多く見られた．これは終わりのイメージが強くその気候から陰鬱に感じられる冬を嫌い，始まりのイメージが強く明るさ・暖かさを感じられる春に期待する傾向が人々にあるために，冬の話題であっても春について言及することで共起が春寄りに判断される語句が増加し，その結果冬の季語リストのスコアが他の季節と比べ著しく低くなったと考えられる．逆に夏という

季節は前後の季節について言及されることが比較的少なく，「秋が待ち遠しい」というよりも「夏が終わってほしい」といったあくまで夏を主軸とした記述が多かったことが，共起の高さに繋がったと思われる．これらの考察より，季節の文字と季語の共起を参照する手法では，信頼性の高い季節推定の実現が困難であると考えられる．

6．季節推定精度の比較

6．1．実験

本稿では予め正解データとして，明確に単一の季節について記述している書籍を各季節に対して同じ数だけ用意した．それらの書籍を対象として季節推定を行い，結果から各手法の推定精度を確認，手法間で推定精度の比較と有効性の確認を行う．

推定対象となる書籍は，青空文庫の日本文学から選択されたエッセイ・随筆・日記・詩・小説であり，一つの季節につき 50 作品，四季合計で 200 作品を扱う．

また，提案手法と推定精度を比較するために，ベースラインとして tf-idf 法を利用することでそれぞれの季節の作品に特有な頻出語句を調べ，それらの語句を季節推定のためのキーワードとして用いる季節推定手法を用意した．この手法は各季節 50 作品の中から無作為に 10 作品ずつ，計 40 作品を抽出してそれらを推定対象とし，それ以外の 160 作品をサンプルデータとして tf-idf 法を行う．その結果である上位 50 語，あるいは上位 100 語を各季節の重要語リストとして指定し，提案手法と同様に季節の推定を行う．このままでは結果となるデータが少なく信頼性に不安が残るため，その少なさを補うものとしてこれらの処理および推定を各季節 10 回ずつ，計 40 回繰り返しその平均推定正解率を確認する．その他の分類手法を用いた季節推定については，サンプル数が各季節 50 作品と少ないため今回は見送る．

実験結果を以下に示す．提案手法とベースラインによる季節推定の正解率とその内訳については，表 9 に示す．

表 9 各手法の季節推定正解率

季節	提案手法	ベースライン (上位50語)	ベースライン (上位100語)
春	90.0%(45/50)	70.0%(70/100)	54.0%(54/100)
夏	94.0%(47/50)	60.0%(60/100)	66.0%(66/100)
秋	86.0%(43/50)	64.0%(64/100)	64.0%(64/100)
冬	92.0%(46/50)	62.0%(62/100)	68.0%(68/100)
平均	90.5%	64.0%	63.0%

提案手法による季節の推定正解率は春の作品が 90.0%，夏の作品が 94.0%，秋の作品が 86.0%，冬の作品が 92.0%，全体平均として 90.5%の正解率を得た．また，ベースラインによる季節の推定正解率は tf-idf 法で得た上位 50 語を用いた場合には春の作品が 70.0%，夏の作品が 60.0%，秋の作品が 64.0%，冬の作品が 62.0%，全体平均 64.0%の正解率となった．そして上位 100 語にリストを拡張して用いた場合には春の作品が 54.0%，夏の作品が 66.0%，秋の作品が 64.0%，冬の作品が 68.0%，全体平均 63.0%の正解率を得た．ベースライン全体の季節の推定正解率は春の作品が 63.0%，夏の作品が 63.0%，秋の作品が 64.0%，冬の作品が 65.0%，全体平均 63.5%の正解率であり，提案手法とベースラインの間では，推定正解率に最低でも 20 ポイント以上，最大 30 ポイント以上の差が生じた．

6．2．考察

表 9 に示したように，季語リストを用いた提案手法はベースラインである tf-idf 法を用いた季節推定手法と比較して明らかに高い推定正解率を示し，季語に着目することで季節の効果的な推定を可能とするという本仮説に基づいた書籍の季節推定手法の有効性が確認された．

また，推定の経緯を確認すると提案手法と比較してベースラインはキーワードの抽出された数が少ない傾向にあり，正解であっても正解の季節に関するキーワードがただ一度のみ出現し，その他の季節に関するキーワードの出現が全くないケース，あるいは全ての季節に対して一切キーワードが抽出されなかったケースも複数存在した．仮に正解であっても，このような結果をもとにした推定の信頼性は決して高いとは言えず，正解率の数値以上の差が提案手法とベースラインの間に存在すると考えられる．ただし，これは本実験に用いた書籍のサンプル数が少なく，ことが原因の一つであるため，書籍のサンプル数を更に増やし，それに伴い各季節のキーワードリストの語数を増加させることで，tf-idf 法を用いた季節の推定手法であってもある程度信頼性を確保した結果を得られる可能性があると思われる．

提案手法は書籍 200 作品中，19 作品で季節の推定を誤った．その内容を確認した結果，誤った推定へと至ったことに関しては，大きく分けて主に二つの原因に分類されることが分かった．第一の原因は書籍で記述される主題と書籍内の季節の間に生じるずれが挙げられる．季語はあくまでもその季節と強い結びつきを持つと一般に認められた語句であり，当然のことではあるが必ずしも他の季節と全く関わりを持たないわけではない．例えば「蜘蛛」は夏の季語であり，実際に「夏」と強い共起を示す語句であるが，蜘蛛自体は一年を通して見ることのできる存在である．そのため，本実験では秋の季節を舞台とする作品の中に捕まえた蜘蛛を主題として記述された作品が存在し，この書籍の季節は夏であると誤った推定結果を導く原因となった．同様のケースとして秋の季語である「鹿」を主題に据えて描かれた春の作品も確認されており，全体から見ると多くはないものの，主題と季節にずれが生じている作品は確実に一定数存在する．

第二の原因として，書籍内で主に記述される場所・舞台と実際の季節との環境のずれが挙げられる．3 章で述べたように季節とは天候の推移を基準として分けられた一年の区分であり，それ故に季語を構成する主なジャンルの一つとして自然現象や気候といった環境に関する語句が多く存在する．しかし，書籍内で主に記述される場所や舞台によっては該当する季節と異なる自然現象や気候を示し，それが異なる季節の環境の特徴と酷似しているために誤った推定結果へと導かれるケースがある．本実験で確認された例として，夏の季語でもある登山を主題とした夏の作品であるものの，雪が積もり低温である山の頂上付近の出来事について主に描写されているために，その環境の特徴から冬の作品と判断されたケースが存在した．また，季節による特徴がない場所を舞台とすることで，誤った推定結果へと至る場合もある．本実験では秋の作品であるが人の手によって掘り進められている地下，つまり一種外界と隔絶された場所を舞台として記述された作品が存在し，本来の季節を示す季語を十分に獲得することができずに推定に失敗したケースも存在する．

第三の原因としては，季語リストの元となった季語データベースが網羅できていない季節を表す語の存在が挙げられる．これには二種類のケースが存在し，一つは同じ意味の語句は既に収録されているが，その呼称が収録されていないケースである．例えば「蛙」は春の季語として収録されているが，一方でデータベース内に「カエル」の呼称は収録されていない．本実験ではこのケースを原因とする推定失敗例は存在しなかったが，サンプルである青空文庫の作品は基本的に古い書籍であり，カタカナ語や難字を一部平仮名化して記述に用いる傾向にある現代の書籍を対象とする際に，季節推定の障害となる可能性が高い．また，もう一つは同じ意味を持つ語句自体がそもそも存在しないケースである．数百年前から存在する季語だが一切変化がないわけではなく，主に俳句を詠む日本人の生活様式の変化や歴史的な出来事に伴い，新たな語句が季語として公認されている．一例として春の季語である「昭和の日」や夏の季語である「海の日」，冬の季語である「クリスマス」「ルミナリエ」などが新たに季語として認められた語句として挙げられる．しかし，当然のことではあるがそれらの変化全てに季語の認定が対応出来ているわけではなく，我々が一般的に季節と結びつくと考えているものでも，季語と公認されていない語句は複数存在する．本実験で確認された例として，冬にクリスマスの象徴の一つであるサンタについて語る作品が存在したが「サンタクロース」あるいは「サンタ」は冬の季語として公認されていないため，その記述を冬に関わりがあると認識できず，結果誤った季節を推定するに至った．近年日本でも認知度が増してきた秋の行事である「ハロウィン」あるいは「ハロウィーン」も本稿執筆段階では季語として公認されておらず，特に海外由来の物品やイベントは季語データベースの網をすり抜ける傾向にある．海外の文化の流入が加速し，元々の生活と複雑に融合しつつある現代を舞台とした書籍を対象とする際に，これら季語として公認されていない語句の存在は更に増えると見られ，季節推定を行う際に最も重要な課題の一つになると考えられる．

7．まとめ

本稿では俳句において，ある季節と強い結びつきを持つと定められた語句である季語に着目することで，書籍内の季節を効果的に推定することが可能であると仮定した．季節の推定は推定結果を利用する現代人の感覚に沿う必要があるため，推定に用いる季語は新暦を基準として現代人の感覚に沿った春夏秋冬の四季に再分類し，各季節との共起頻度の確認やその他の季節推定手法と比較することでその有効性について調査を行った．実験の結果，提案手法による書籍の季節推定は 9 割以上の書籍において正解し，仮説に基づき季語に着目した書籍内の季節推定の有効性が確認された．しかし，季節外れのものを主題に記述された書籍や，季節の特徴とは異なる環境を主な舞台とする書籍が存在すること，また季語リストが季節に関する語句を必ずしも網羅しきれていないことなどを原因として推定に失敗するケースも今回の実験を通して確認されており，これらは更に精度の高い書籍の季節推定を実現するため，解決すべき課題として挙げられる．

今後は第一に，書籍の章単位など更に細かい範囲での季節推定の実現を目標とする．これにより書籍内で複数の季節が存在する場合でも，各場面の季節を把握することで，推薦の際に柔軟な対応が可能となると考えられる．第二に「北海道は冬が長く春が短い」「夏でも高山地帯は気温が低く雪が存在する」「地下施設はどの季節であってもその影響を受けにくい」といった，場所による環境の違いを季節推定に反映する手法の導入を試みる．第三に季語の概念を適用することが難しい日本以外を舞台にした日本文学や海外の書籍，特に日本と季節が反転する南半球や四季の概念自体が存在しないとされる乾燥帯地域を舞台とする書籍の季節推定はどのように対応すべきか検討する．これらを踏まえて書籍内の時間に関する情報をより詳細かつ正確に取得し，利用者の希望に丁寧に沿う形で応えられる内容依存推薦システムの実現を目指したい．

参考文献

[1]神嶌敏弘．推薦システムのアルゴリズム(1)，人工知能学会誌，Vol. 22, No. 6, pp. 826-837, 2007.

[2]R. J. Mooney and L. Roy, Content-based book recommending using learning for text categorization, Proceeding of ACM SIGIR Workshop on Recommender Systems: Algorithms and Evaluation, pp. 195-204, 1999.

[3]伝住颯夏，ジェプカ ラファウ，荒木健治，人物・場所・時間情報を用いた内容依存推薦システムの評価，電気・情報関係学会北海道支部連合大会講演論文集，112, 2014-10-26

[4]オンライン書店 HonyaClub.com: みんなで作る本棚，http://www.honyaclub.com/shop/pages/hondana.aspx

[5]瀧本洋喜，奥村紀之，物語文章における時系列情報の抽出，信学技報，Vol.111，No.119，NLC2011-1，pp.1-6，2011.

[6]奥村紀之，瀧本洋喜，物語文章における時系列推定の拡張，情報科学技術フォーラム講演論文集，12(2)，301-306，2013-08-20

[7]日本語形態素解析システム JUMAN，http://nlp.ist.i.kyoto-u.ac.jp/index.php?JUMAN

[8]伝住颯夏，ジェプカ ラファウ，荒木健治，季語を用いた季節推定システム推定システムの評価，言語処理学会第 21 回年次大会発表論文集，pp. 36-39，2015

[9]気象庁 | 予報用語 時に関する用語，http://www.jma.go.jp/jma/kishou/know/yougo_hp/toki.html

[10]現代俳句協会「現代俳句データベース」，http://www.haiku-data.jp/

[11]青空文庫，http://www.aozora.gr.jp/

[12]MeCab - Japanese morphological analyzer -，https://code.google.com/p/mecab/

[13]Michal Ptaszynski, Rafal Rzepka, Kenji Araki, and Yoshio Momouchi. 2012. Automatically annotating a five-billion-word corpus of Japanese blogs for affect and sentiment analysis. In Proceedings of the 3rd Workshop in Computational Approaches to Subjectivity and Sentiment Analysis (WASSA '12). Association for Computational Linguistics, Stroudsburg, PA, USA, 89-98.