語彙チャンクの出現頻度情報に基づく判決文の類似性判定を用いた量刑推定システムの有効性について

The Effectiveness of Sentencing Estimation System Using Word Chunks Frequencies Based Lexical Similarity of Judicial Decisions

田中 匡, ジェプカ ラファウ, 荒木 健治
Tadashi Tanaka, Rafal Rzepka, Kenji Araki
北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

1. はじめに

現在人工知能の目覚ましい進化が見られ，常識的な知識の獲得に関する研究が多くなされている．そのなかで，人工知能が倫理的に善悪を判定する手法の研究もまた多くなされているが[1-2]，善悪の尺度を考慮した研究は存在しない．この試みは人工知能による倫理的な知識の獲得の面において非常に有益であると考えられる．

そこで本研究では“悪さ”に着目し，“悪さ”のレベルを判定する手法を提案する．しかし“悪さ”のレベルを決定することは容易ではない．そこで本研究では過去の判決文から得られる，裁判の有罪判決により決定された量刑を“悪さ“の尺度とした．

2009年に裁判員制度が施行され，重大な罪に対する裁判における判決の審理に，一般人が直接関わるようになった．しかし，裁判の判決文の多くが長文で書かれる傾向にあり，専門知識を持たない一般人が多くの判例について理解し，検討するのは困難である．このため，審理の作業は一般人にとって大きな負担となっていると考えられる．そこで，類似した判決文の検索を行い量刑の範囲や判断材料を提示することで，これらの負担を減らす試みがなされてきた[3-8]．しかしながら，判決文はその特殊性から構文解析が難しく，人手により作成した辞書に頼らざるを得ないため，類似した判決文を正しく提示することは困難であった．

このような背景から，本研究では裁判の判決文に出現する，単語以上の文節や連続単語の頻度情報を用いることにより，判決文の類似性を判定した．また，語彙チャンク（文節・連続単語）を用いることで，単語間の関係性を考慮し，文脈的な関連性を取得できる．さらに，特定の表現の抽出のために辞書を作成する必要性がないため，容易に網羅性を高め，より多くの判決文に対して使用することができる．

本稿では，量刑の推定を行うシステムの構築を行い，判決文の類似性を判定する手法の有効性を評価し，システムの精度向上に向けた今後の改善点を示す．

2. 関連研究

裁判の判決文の類似度を判定する研究として，野坂らは近接グラフを用いて文章間の類似度を計算する手法を提案した[1]．しかしながら，検証に使用された判決文は4文であり，多くの判決文に対して同様の効果を得られるかについては検討を行う必要がある．判決文は多様な書かれ方をしているため，多くの判決文で検証を行うことで一般的に手法が有効であると示すことができる．また，高丸らは量刑の要因を分析することで，新規事例に対して量刑の推定を行い，量刑要因と共に複数の量刑を可視化し，使用者へ提示した[2]．しかしながら量刑判定の要因に関して十分な分析がなされていないため，量刑要因をより詳しく調査することを課題としている．また判定された量刑に関して考察を行っていないため，判定された量刑の成否について疑問が残る．裁判の判決文においては，どのような情報が量刑判定に影響を与えるかを考慮することで，よりシステムによる量刑推定を正確に行うことができる．

そこで神田らは KH Coder[5]及び SPSS Text Analytics for Surveys[6]を用いて量刑理由の分析を

行った[5]．神田らは，量刑の判定には，被告人の行った行為が重要であることは言うまでもないが，事件後の被告人の態度など感情的な要因が関係していることを示した．また阪野らは，手がかり表現に基づく判決文の自動要約を試みた[8]．要約を行う際の重要文抽出において，述語表現に関するルールを人手により作成することで，重要文の判定を行ったが，より詳細なルールを設定する必要があった．そこで阪野らは機械学習を用いて判決文の重要箇所特定を行った[9]．人手により重要箇所を決定し，それらを元に機械学習を行ったが，依然として重要箇所を特定する方法が人手によるものであり，網羅性・信頼性，重要箇所のルール作成に掛かる多大なコストが問題である．

このため，本稿ではこれらの問題に対して，解決策を示し，新たな手法の提案を行った．

3. 研究の概要

本研究では，多くの判決文を使用することで，手法が一般的に判決文の類似性判定を行う際に有効であることを示す．また，本手法では，重要箇所の特定を行わず，bag of words を用いて，判決文の類似性判定を行う．これにより，重要箇所の特定を行う必要がなく，網羅性の問題を解決し，人手によるコストを削減した．

関連研究では，判決文の類似性を判定し量刑の推定を行っているが，推定結果に対する評価方法が確立していない．そのため本研究ではシステムによる推定結果の性能評価を行う手法の提案を行った．

4. 実験概要

本研究では，判決文をチャンク（一定の塊）に分割し，チャンクの出現頻度情報を用いて，判決文の類似度判定を行った．

処理の流れを図 1 に示す．以下で，各処理について説明する．

4.1 データセットの作成

本手法では，判決文中で主文として書かれている裁判により決定した量刑と，判決本文に分割しデータセットを作成した．

判決文は，判例検索サービス LEAGLES[10]に登録されている判決文から，有罪判決が下された判決文を対象として実験を行った．LEAGLES 内に登録されている判決文約 6 万件から 2,656 件の判決文が取得された．この 2,656 件を本実験で使用するデータセットとした．

取得したデータセット中には死刑 48 件，無期懲役

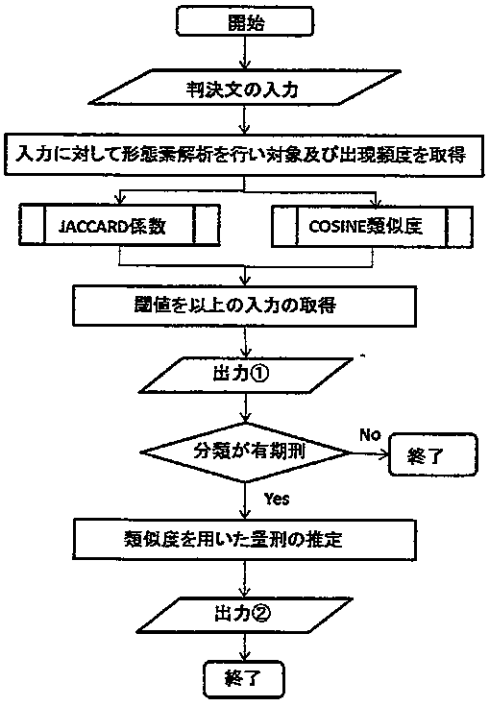


図 1 システムの処理の流れ

158 件，有期刑 2,450 件が含まれている．

本稿では，量刑を【1 年→1.00】，【1 カ月→0.08】と表記する．

4.1.1 テストデータと学習データ

本研究では取得した判決文 270 件をテストデータとし，2386 件を学習データとした．テストデータの内訳は，実験データセットに出現する三種類[死刑，無期懲役，有期刑]の出現頻度を考慮し[死刑:5 件，無期懲役:16 件，有期刑:249 件]とした．

4.2 類似度判定方法

本研究で，類似度判定の手法として JACCARD 係数及びコサイン類似度を用いた．類似度を計算する手法は数多く存在するが，判決文に対して，どのような手法が有効であるか確認されていない．そこで本稿では基本的な方法を用いて実験を行った．

4.2.1 JACCARD 係数

チャンク間の類似度を計算する代表的な手法であり，2 集合の共通要素の割合を求める手法である．JACCAR 係数の算出方法を式（1）に示す．

$$Jaccard(A,B) = \frac{|A \cap B|}{|A \cup B|} \quad (1)$$

A: 文書 A 中の出現する単語の組成

B: 文書 B 中の出現する単語の組成

4.2.2 コサイン類似度

コサイン類似度は，ベクトル空間モデルにおいて，文章を比較する際に用いられる類似度計算手法である．

コサイン類似度では，チャンクの出現頻度を考慮し類似度を計算することができる．コサイン類似度の算出方法を式 (2) に示す．

$$\mathrm{COSINE}(A,B)=\frac{\sum_i^{|v|}A_iB_i}{\sqrt{\sum_i^{|v|}A_i{}^2}\cdot\sqrt{\sum_i^{|v|}B_i{}^2}} \quad (2)$$

A_i: 文書 A 中の単語 i の出現頻度

Bi: 文書 B 中の単語 i の出現頻度

4.2.3 TFIDF 指標を用いたチャンクの重み付け

コサイン類似度を用いて，類似度の判定を行う際に，TFIDF 指標を用いることで，文章を特徴付けるチャンクに対して重み付けを行うことができる．TFIDF 指標の算出方法を式 (3)，(4)，(5)に示す．

$$\mathrm{TFIDF}(t,d)=\mathrm{tf}(t,d)\cdot\mathrm{idf}(t) \quad (3)$$

$$\mathrm{tf}(t,d)=\frac{n_{t,d}}{\sum_{s\in d}n_{s,d}} \quad (4)$$

$$\mathrm{idf}(t)=\log\frac{N}{\mathrm{df}(t)} \quad (5)$$

n:キーワード t の出現回数

d:すべてのキーワードの出現回数

N:判決文の総数

df:キーワード t が出現する判決文数

4.3 閾値の設定

閾値を定めることで，閾値以上の類似度であった場合に判決文が類似していると判断できる．しかしながら，類似度を判定する際の最適な閾値は示されていない．そこで本稿では，閾値を 0.01 から 0.9 まで 0.01 刻みで設定し，各閾値に対して実験を行った．

4.4 三分類問題

有罪判決が下された判決文の中で，有期刑・無期懲役・死刑の 3 種類は，大きく性質が異なり，無期懲役及び死刑の量刑を数値で表すことは難しい．そのため本稿では，判決文を[有期刑・無期懲役・死刑]の 3 種類に分類した．

入力文に対し[有期刑・無期懲役・死刑]との類似度をそれぞれ算出し，閾値を超えた回数をカウントする．さらに，カウントした数をそれぞれ[有期刑・無期懲役・死刑]の出現数で正規化し，最も大きな値となった判定結果を出力①とした．

閾値以上の類似度が得られない場合は出力を行わない．判決文と同様の判定が出力された場合に正解とし，誤った判定及び判定が出力されなかった場合に誤りとした．以下に出力決定に使用した式(6)を示す．なお，各量刑に対し，類似度が閾値を超えた数を有期刑数，無期懲役数，死刑数とする．

$$\text{出力①}=\max\left(\frac{\text{有期刑数}}{2{,}450},\frac{\text{無期懲役数}}{158},\frac{\text{死刑数}}{48}\right) \quad (6)$$

4.5 量刑の推定

有期刑と判断された入力文に対し，量刑を推定する．本研究における量刑の決定方法として，各判決文の類似度を考慮するために，判決文の量刑に正規化した類似度を掛けた合計をシステムの出力②とした．表 1 に例を示す．出力②の計算式を式(7)に示す．

表 1　量刑推定の計算例

閾値[0.2]	量刑	類似度	正規化した類似度	量刑*正規化した閾値
判決①	4	0.67	0.60	2.41
判決②	6	0.24	0.22	1.08
判決③	1	0.20	0.18	0.18
システムの推定した量刑				3.68

出力②=

$$\mathrm{sum}\left(\text{量刑}\times\left(\text{正規化した類似度}\right)\right) \quad (7)$$

4.6 評価手法

システムが推定した量刑の評価手法として，相対誤差を用いた．裁判で下された量刑とシステムの判定した量刑との差を誤差として評価することは好ましくない．以下の表 2 に例を示す．例①と例②では誤差は共に 2 年であるが，例①ではシステムの推定した量刑が本来の量刑の 2 倍である．例②ではシステムの推定した量刑と，本来の量刑との誤差は 11%程度である．単純な誤差を用いて評価を行うと，例①と例②の結果を同様に扱ってしまうが，例②のシステムの方がより精度が高い推定が行えていると考えられる．したがって，誤差を相対的に判定することで，より正確にシステムの精度を判定することができる．相対誤差の計算式を式(8)に示す．

表 2　相対誤差計算例

	入力(裁判で下された量刑)	出力(システムの推定した量刑)	誤差	相対誤差
例①	2.00	4.00	2年	1.00
例②	18.00	16.00	2年	0.11

$$\text{相対誤差}=\frac{\left|\text{正解}-\text{予測値}\right|}{\text{正解}} \quad (8)$$

4.7 実験結果に対する評価

本稿では，閾値が定数で指定されていないため，有期刑が少なくとも一件以上分類された閾値を対象として，平均相対誤差及び正解率の平均値を算出した．

5. 予備実験

予備実験として，判決文中の動詞及びサ変活用の名詞を対象として，実験を行った．動詞情報の取得には形態素解析器MeCab[11]を用いた．判決文では，「殺す」ではなく「殺害する」のようにサ変動詞で書かれることが多いため，サ変活用の名詞を動詞と同様に扱った．本来，サ変活用以外の名詞・副詞・形容詞などについても考慮すべきであるが，計算コストが莫大になるため，本実験では対象としなかった．

5.1 予備実験結果

表 3 に実験結果を示す．予備実験の結果，コサイン類似度を用いることにより，平均相対誤差が 0.43 ポイント減少し，さらに TFIDF 指標を用いて対象の重み付けを行うことにより平均相対誤差が 0.10 ポイント減少した．これにより，対象の出現頻度を考慮することが，システムの精度向上において有効であることが確認された．

しかしながら，類似度を判定する際に使用する単語が少なすぎるため，類似性の判定精度は高くなかった．今後，類似度判定に用いる単語を拡張することにより，精度の向上が望めると考えている．

表 3　動詞を対象とした実験結果

対象:動詞	平均相対誤差	平均正解率
JACCARD 係数	2.31	0.53
COSINE 類似度	1.88	0.51
COSINE 類似度(TFIDF)	1.78	0.47

6. 提案手法

予備実験では，動詞及びサ変活用名詞を対象として実験を行ったが，単語単体では単語間の関係性を考慮することができない．そこで，語彙チャンク（文節・連続単語）を対象とすることで，単語間の関係を考慮する手法を提案する．

6.1 文節

本稿では，形態素解析器 CaboCha[12]を用いて，文節を取得した．その結果，判決文 2,656 件から約 90 万件の文節が取得された．

6.2 連続単語の取得

連続単語・名詞・動詞・副詞・形容詞が連続して出現している箇所の取得を行った．連続単語は文節より大きなチャンクとして取得することができるため，より単語間の関係性を反映させることができると考えられる．

文節と同様に，形態素解析器 CaboCha を用いて，連続単語を取得した．判決文 2,656 件から約 30 万件の連続単語が取得された．

7. 本実験

提案手法である，語彙チャンクを用いて，予備実験と同様の方法で，類似性の判定を行い，量刑推定を行った．

7.1 本実験結果

表 4，表 5 に実験結果を示す．コサイン類似度を用いた場合，JACCARD 係数に比べて，連続単語について 1.50 ポイント，文節について 0.63 ポイントの上昇が確認された．しかし，TFIDF 指標を使い単語の重み付けを行うことにより，平均相対誤差の値が，連続単語について 0.05 ポイント，文節について 0.11 ポイント減少し，精度の向上が確認された．予備実験の動詞とサ変活用名詞のみを対象とした場合と比較して，TFIDF 指標で単語の重み付けを行い，コサイン類似度を用いて量刑を推定した場合に，連続単語では 0.75 ポイント，文節では 0.94 ポイント，平均相対誤差の減少が確認された．このことから，語彙チャンクを用いて，単語間の関係性を考慮することにで，より正確に量刑を推定することができることが確認された．

表 4　連続単語を対象とした実験結果

対象:連続単語	平均相対誤差	平均正解率
JACCARD 係数	1.08	0.28
COSINE 類似度	2.58	0.47
COSINE 類似度(TFIDF)	1.03	0.21

表 5　文節を対象とした実験結果

対象:文節	平均相対誤差	平均正解率
JACCARD 係数	0.95	0.22
COSINE 類似度	1.58	0.26
COSINE 類似度(TFIDF)	0.84	0.17

8. 考察

8.1 連続単語と文節の差異に関する考察

本実験では，連続単語と文節の二種類の語彙チャンクを用いて，量刑推定を行った．

JACCARD 係数を類似度判定に用いた場合，動詞を対象とした場合よりも，平均相対誤差の値が，連続単語で 1.36 ポイント，文節で 1.23 ポイントの減

少が確認された.

コサイン類似度を類似度判定に用いた場合，動詞を対象とした場合よりも，平均相対誤差の値が，連続単語で0.7ポイントの上昇が確認され，文節で0.3ポイントの減少が確認された.

しかしながら，TFIDFを用いて語彙チャンクに対する重み付けを行い，出現頻度を考慮することにより，動詞を対象とした場合よりも，平均相対誤差の値が，連続単語で0.94ポイント，文節で0.75ポイントの減少が確認された.

また，すべての実験において最も平均相対誤差が小さかったのは，「文節をチャンクとし，重み付けを行い，コサイン類似度による判定」を行った場合で0.84ポイントであった.

以上より，単語間の繋がりを考慮することで，より正確な類似度判定を行うことができることが確認された.

また，語彙チャンクが長くなるにつれて，表現の違いや表記の違いにより，意味的に類似しているが，表層的に異なった語彙チャンクの類似性を考慮することができなかった．そのため，このような語彙チャンクの補正を行うことで，正しく類似度を判定することが可能となり，平均相対誤差をさらに減少させることが望めると考えている.

8.2 評価手法に関する考察

平均相対誤差が極端に大きな値になってしまうケースが存在した．表6に例を示す．例①では入力と出力の誤差は3年であり，平均相対誤差は0.17である．しかし例②では誤差は1.75年であるが，平均相対誤差は7である．1.75年という誤差は大きくはないが，平均相対誤差としては大きいと言える．例①と例②の誤差の差は1.25年であり，2倍に満たないが，平均相対誤差の差は6.83と実に41倍になってしまった．このように，入力の値が小さい場合に平均相対誤差が極端に大きくなることが問題である．また例③のように入力が小さいが，誤差が大きくなってしまった場合に平均相対誤差の値が 38 と巨大な値になってしまい，平均を求めた本実験の平均相対誤差に大きな影響を与えてしまった.

裁判における量刑は1年刻みで決定される．そのため，判決文の量刑も1年の幅で変化が見られる．

表 6　相対誤差が大きくなる例

その中で1年以下の量刑のように，一か月単位で量刑が変化する物に関して，同様に評価を行うことは適切ではない．これは，今後の課題とする.

	入力(裁判で下された量刑)	出力(システムの推定した量刑)	相対誤差
例①	18.00	15.00	0.17
例②	0.25	2.00	7.00
例③	0.17	6.50	37.24

8.3 三分類問題に関する考察

8.2でも考察を行ったが，「1年以下の量刑」では，多くは執行猶予が与えられる軽犯罪に相当するが，このような軽犯罪に関しては，他の判決文と同様に扱うべきではないと考えられる．このような軽犯罪は，分類問題として扱い，分類カテゴリーを増やすことによりシステムの精度が改善するものと考えられる.

高い閾値を用いて，三分類問題で正しく分類することができた判決文に関しては，平均相対誤差が小さく，良い精度での推定が可能であることが確認された.

8.4 平均正解率に関する考察

予備実験及び本実験において，平均正解率が最も良い数値であったのは，「動詞を対象としてJACCARD係数を用いて判定」を行った場合であり，正解率が0.53であり，テストデータ270件中約143文が正しく分類された.

また平均相対誤差平均がもっと小さかった「文節を対象として，語彙チャンクに対して重み付けを行い，コサイン類似度による判定」を行った場合では，正解率が0.17であり，正しく分類されたのは，テストデータ270文中46件に留まり，いずれも精度が良いとは言えない.

しかしながら，平均相対誤差で最も良い数値を示した「文節をチャンクとし，重み付けを行い，コサイン類似度による判定」を行った場合，誤りの多くが，「分類を行うことができない」場合であり，連続単語で0.68ポイント，文節で0.83ポイントであった．これは，閾値を超える類似度の判決文を取得することができなかったためである．そのため，類似度の判定精度をあげることにより，正解率の向上が期待できる.

8.5 分類可能な判決文の正解率に関する考察

もっとも平均相対誤差の小さかった「語彙チャンクに重み付けを行い，コサイン類似度を用いて判定」を行った場合について，分類可能な判決文中での適合率を表7に示す.

連続単語を対象とした場合，動詞に比べ0.10ポイントの向上を確認した．また，文節を対象とした場合，動詞に比べ0.14ポイントの向上を確認した。

表 7　分類できた判決文の適合率

	平均適合率
対象：動詞	0.63
対象：連続単語	0.73
対象：文節	0.77

9. まとめ

語彙チャンクを用いて，単語間の関係性を取得し，類似度の計算を行い量刑の推定を行う手法を提案した．従来手法では，人手により辞書を作成する必要があり，すべての表現を網羅性することは難しく，辞書の拡張を課題としていた．本手法では，文章全体を，類似度判定の際の要素とすることで，すべての語彙チャンクを網羅性することができ，人手による辞書作成を必要としない．

語彙チャンクを用いることで，分類可能な判決文について，動詞と比較して，連続単語で 0.10 ポイント，文節で 0.14 ポイントの適合率の向上を確認した．

また，語彙チャンクを用いて，単語間の関係性を類似度判定に反映させることで，連続単語で 0.75 ポイント，文節で 0.94 ポイントの量刑判定の精度向上を確認した．これらの結果から，判決文の類似性判定を用いた量刑推定を行う際に，語彙チャンクの出現頻度情報を用いる本手法の有効性が確認された．

今後の課題として，本稿では【有期刑・無期懲役・死刑】の三種類に分類を行ったが，分類数を増やすことが挙げられる．分類数を増やすことで，同様に量刑判定を行うべきではない判決文を，分類問題として扱い，量刑推定から除外することができるため，分類問題の正解率及び量刑判定の精度向上が望めると考えている．

また，本実験では，取得対象が完全に一致している場合に限り類似度を算出に反映することができたが，表現の違いで，表層的には異なっていても，同一の意味で用いられる単語を考慮する必要がある．具体的には「殺人」「殺害」という二つの単語について，本実験では異なる要素として計算しているが，意味的には類似していることがわかる．この違いを，類似単語や揺らぎを考慮して類似度を計算する手法を用いることで是正し，より詳細かつ正確な類似度判定を行い，量刑推定の精度向上を目指す予定である．

参考文献

[1] Rzepka,R. and Araki, K : What statistics could do for ethics?-the idea of common sense processing based safety valve. In Papers from AAAI Fall Symposium on Machine Ethics, FS-05-06, pages 85– 87, 2005.

[2] Anderson M, Anderson S. : EthEl : toward a principled ethical eldercare robot. In : Proceedings of conference on human-robot Interaction, Amsterdam, The Netherlands, March 2008.

[3] 野坂卓矢，原口誠：文章の隣接グラフ化とグラフマッチングに基づく判例文の類似度計算，人工知能学会全国大会論文集 25, 1-4, 2011

[4] 高丸圭 一，渋木英潔，木村泰知，松原雅文，Rafal Rzepka，村上浩司：情報科学技術フォーラム講演論文集 7(2), 233-234, 2008.

[5] 樋口耕一『社会調査のための計量テキスト分析 —内容分析の継承と発展を目指して—』 ナカニシヤ出版，2014.

[6] SPSS Text Analytics for Surveys : IBM ソフトウェア
http://www-03.ibm.com/software/products/ja/spss-text-analytics-surveys

[7] 神田宏：テキスト・マイニングの手法による量刑理由の分析，科学研究費助成事業研究成果報告書,p.1- 6，2012.

[8] 阪野慎司，松原茂樹，吉川正俊：判例コーパスを用いた判決文の要約手法，Digital libraries (27・28), 3-8, 2005.

[9] 阪野慎司，松原茂樹，吉川正俊：機械学習に基づく判決文の重要箇所特定，言語処理学会第 12 回年次大会発表論文集，1075-1078, 2006.

[10] Leagles-株式会社イントロンワークス
https://leagles.jp/

[11] MeCab : Yet Another Part-of-Speech and Morphological Analyzer
http://mecab.sourceforge.net/

[12] CaboCha : Yet Another Japanese Dependency Structure Analyzer
https://taku910.github.io/cabocha/