地方議会会議録における自治体名の曖昧性解消の検討

Investigation of Local Government Name Disambiguation on Japanese Regional Assembly Minutes

[1] 葦原　史敏,　[2] 木村　泰知,　[1] 荒木　健治
[1]Fumitoshi Ashihara,　[2]Yasutomo Kimura,　[1]Kenji Araki
[1] 北海道大学大学院　情報科学研究科
[1]Graduate School of Information Science and Technology, Hokkaido University
[2] 小樽商科大学　商学部　社会情報学科
[2]Department of Information and Management Science, Otaru University of Commerce

Abstract: In this research, we aim to automatically investigate local government's involvement in important political tasks by retrieving utterances citing other local government actions from regional assemblies minutes corpus of assembly minutes from all over Japan. To achieve this goal, we should retrieve utterances including local government name first, but there are ambiguous names of local government units. In this paper, we discuss location name disambiguation on the corpus local of assemblies minutes. Our approach to the disambiguation is to collect ambiguous location names from address data and determine correct location name candidate in the utterances including collected ambiguous locations. Determining correct location name candidate utilizes lexical information, local government name of assembly minute, and GIS information. We investigate whether these methods are able to disambiguate location name in high precision.

1　はじめに

近年，全国の約 7 割の自治体が，住民への情報公開に向けて，ウェブを利用して地方議会会議録（以下，会議録）を公開しており，住民は自治体の意思決定に関する議員らの議論を閲覧することができるようになっている．会議録は全国の自治体で蓄積されており，利用状況に差があるブログやマイクロブログ (twitter) などの情報源と比較すると，全ての自治体が情報を公開している媒体である．そのため，特定の自治体に限らず，情報を閲覧することが可能である．

会議録の利用法の一つとして，自身の住む自治体以外の会議録を検索し，比較することが考えられる．一方で，同じ政治課題を抱えている自治体や，注目される取組を行っている自治体を調べることは容易ではない．

そこで本研究では，他の自治体から注目される取組を行っている自治体の抽出を目標とする．

注目される取組がある自治体を判別するために有効な手法としては，異なる自治体から参考にされる取組を行っていることを示す発言を会議録から収集することが考えられる．異なる自治体の取組について言及する発言の例を図 1 に示す．

図 1 に示した異なる自治体の取組について言及する発言は，論文の引用のように他人 (他の自治体) の文章や事例を用いて説明する発言であると考えられる．そのため，他の自治体から引用される回数が高いほどその自治体の重要度が高いと推測される．本研究ではこのような発言を「引用発言」と呼ぶ．

次なる森林の取組について注目すべきは企業の森，これは，和歌山県がやはり平成 15 年に全国に先駆けてこれを実施いたしました．

図 1: 異なる自治体の取組について言及する発言の例

引用発言を自動的に収集するには，発言中に自治体名が存在し，かつ当該自治体の政治的取組を含むものを抽出する必要がある．しかしながら，発言中の自治体名には曖昧性のある名称が存在する問題がある．

そこで本稿では，地方議会会議録コーパスに含まれる地名の曖昧性解消を検討する．地名の曖昧性解消は，住所データから曖昧性が存在する地名を収集し，発言中の地名それぞれについて正しい地名候補を決定することで行う．正しい地名候補の決定は，上位地名階層を見つけるパターンマッチ，発言が行われた会議録の地理情報，発言から自動抽出した地名の地理情報に基

づいて行い，それらの手法で高精度に地名の曖昧性解消が可能か検証する．

2 関連研究

文書における地域推定の研究は従来から行われており，文書の地名推定と，文書中に含まれる地名表現の場所を推定する２つの問題が扱われてきた．

金木らは文書の地名推定において，地名やランドマークの情報を用いて推定している [1]．また，平野らは文書中に含まれる地名表現の場所の推定において，地名の候補と文書中で共起する地名の候補との実際の距離，対象地域の想起されやすい度合いを算出する有名度のスコアによって，地名の場所を推定している [2]．さらに，ソーシャルメディア（twitter）を対象とした地名の推定も行われている [3][5]．twitter では，位置情報が付与されたツイートは全発言の 1%にも満たないため，粟村らは位置情報に頼らず，ツイート中の地名の空間的近接性や，過去のツイートも考慮するなどの手法で曖昧性の解消を行っている．

しかし，本研究で扱う地方議会会議録コーパスなどの議会会議録中の地名の曖昧性解消についてはこれまで研究されていない．また，twitter などのデータと異なり，地方議会会議録コーパスは発言が行われた議会の場所が全てに付与されたものである．したがって，先行研究で対象とされてきた Web 文書やソーシャルメディアを対象とした地名推定と異なり，発言場所の情報を地名の曖昧性解消に用いることができる．

そこで，本稿では先行研究で用いられてきた文書中の地名の位置情報に加え，発言が行われた議会の場所を地名の推定に用いることで，高精度に地名を推定できるかどうかについての検証を行う．

3 実験データセットの構築

本節では，本研究で対象とする地名，曖昧性のある自治体名辞書の構築，自治体名を含む発言の抽出について述べる．

3.1 対象とする地名

先行研究では対象とする地名として，住所，駅，公共施設，Wikipedia で GIS 情報（緯度経度情報）が付与された施設などが扱われてきた [3][5]．本研究の目的は，自治体名を含む発言の抽出であるため，対象とする地名は自治体名に対して曖昧性が存在する自治体名と住所名とする．

3.2 曖昧性のある地名候補辞書の構築

曖昧性のある地名候補辞書を構築するためには，まず同一の名称を持つ自治体名，住所を列挙する必要がある．そこで，総務省の地方公共団体コード（25 年度）[1] と，日本郵便株式会社の配布する住所データ [2] を利用した．構築は次の手順で行った．

(i) 住所データのクリーニング（〜条西，丁目，流通センター等の住所特定用表記の除去）．
(ii) 自治体名を含む住所データを検索し，各自治体ごとに同じ地名を持つデータを列挙．
(iii) 列挙したデータから地名以前が同じ文字列であるデータを除外．
(iv) 清水町に対する小清水町など，地名がオーバーラップする可能性がある自治体名を形態素解析器 MeCab[3] を用いて除外．

これらの手順の後，地名が自治体，住所のいずれになるかについて人手で分類し，計 191 の自治体名に対する曖昧性のある地名候補辞書を構築した．表 1 に構築した辞書の例を示す．

表 1: 曖昧性のある地名候補辞書の例

地名	自治体名の候補	住所名の候補
清水町	北海道上川郡清水町, 静岡県駿東郡清水町	三重県四日市市清水町, 三重県松阪市清水町，…

3.3 地名を含む発言の抽出

本研究で対象とするデータは，全国の会議録から文献 [6] に示す方法で収集された 434 の自治体の会議録より，2010 年のデータを対象とする．このとき，データに与えられている発言者や出典議会などのメタデータから出典議会の情報をデータに加えて取得した．

このデータから，曖昧性のある地名候補辞書の構築と同様に，地方公共団体コードに記載された自治体名を含む発言を抽出する．その上で，抽出された 219,663 件のデータから，**3.2** で構築した辞書の地名を含む 10,150 件のデータを取得した．表 2 に曖昧性のある地名を含む発言の例を示す．

[1] http://www.soumu.go.jp/denshijiti/code.html
[2] http://www.post.japanpost.jp/zipcode/dl/oogaki-zip.html
[3] http://taku910.github.io/mecab/

表 2: 曖昧性のある地名を含む発言の例

	データ例
出典議会	大阪府大東市
曖昧性のある地名	栗山町
発言	少なくとも、栗山町、熊取町、伊賀市、流山市という、この基本条例の先例市町においてのベースは、二元代表制という 表現を使う場合は、伊賀市と熊取町みたいに、地方議会はという表現がある。

4 地名の曖昧性解消手法

本研究では，地名の曖昧性解消を以下の 3 つの手順で実現する．

(i) 上位の地名階層を見つけるためのパターンマッチを行う．
(ii) 発言内に存在する地名と，地理上の距離の平均が最小となる候補を選択する．
(iii) 発言が行われた議会の場所（出典情報）と地理上の距離が最小となる候補を選択する．

手順 (i) は，曖昧性のある地名の前にそれを解消する上位の地名が存在するか見つけるものである．例えば，「東京都の港区」を含む発言では，港区の曖昧性を解消するために東京都の情報を使うことができる．曖昧性を解消する上位地名には，住所データから構築した都道府県 47，市や町名などの 1,894 件の辞書を用い，パターンとしては，A の B という形になる「(上位地名）の（曖昧性のある地名)」あるいは名詞連続である「(上位地名）(曖昧性のある地名)」を用いる．

手順 (ii) は，発言内の地名との距離が最小となる候補を選択するものである．まず，発言から地名を抽出するために，手順 (i) で用いたものと同様の辞書を用いて地名を抽出する．この際，地名がオーバーラップするものを除去するために，MeCab によって辞書の地名と発言を形態素解析させてから抽出を行った．

次に，発言中に含まれる地名の位置情報を取得し，曖昧性解消候補と発言中の地名の距離を算出する．地名の位置情報はジオコーダ DAMS を用いる [7].

曖昧性解消候補を $\mathbf{a} = \{a_1, a_2, ..., a_i, ..., a_n\}$ とし，発言から抽出された地名を $\mathbf{l} = \{l_1, l_2, ..., l_j, ..., l_m\}$， 2 地点間の距離を算出する関数を $distance(p1, p2)$ とすると，距離の平均が最小となる地名の候補 a_i を選択することは式 (1) で表される．なお，関数 $distance$ は Harversine formula[4] によって計算する．

$$a_i = \arg\min_i \frac{\sum_{j=1}^{m} distance(a_i, l_j)}{m} \quad (1)$$

手順 (iii) は，発言が行われた場所を曖昧性解消に用いるものである．これは，発言が行われた場所 s と曖昧性解消候補 $\mathbf{a}$ の間で距離が最小となる a_i を選択する式 (2) で実現する．

$$a_i = \arg\min_i distance(a_i, s) \quad (2)$$

5 では，以上の 3 つの手順について，3 つの手順がどの程度曖昧性解消に貢献するかについて検証していく．

5 実験

本節では，**4** で述べた手順について，**3.3** で抽出したデータを対象に曖昧性解消の精度について評価する．

まず，**3.3** の抽出の段階で生じた誤りを検証し，抽出段階の誤りを除いたデータについて精度の検証を行う．精度の検証は適合率，再現率，F 値で行う．

実験データは **3.3** で抽出した 10,150 件のデータからランダムサンプリングした 100 件を対象とする．また，正解の決定は第一著者が前後の発言の地名や施設名，人名などの情報から判断することにより行った．

5.1 実験結果

3.3 の抽出段階における誤りは 100 件のデータのうち，11 件であった．誤りは穂坂町に対し，坂町が曖昧性のある地名として抽出されるオーバーラップの問題や，駅名（JR 小野町駅）から地名として小野町が抽出されるなど，施設名を自治体名として抽出する問題によって生じた．また，正解の判断が難しいデータが 2 件存在した．そのため，これらのデータを除いた 87 件について評価を行う．

次に，表 3 に各手順ごとの実験結果を示す．なお，表 3 中の手順 (i) は上位の地名階層を見つけるパターンマッチ，手順 (ii) は発言内の地名との距離の平均が最小となる候補の選択，手順 (iii) は発言が行われた議会の場所と距離が最小となる候補の選択を表す．

また，3 つの手順を組み合わせることによる精度を検証するために，再現率が最大である手順 (iii) の誤りを手順 (i) と手順 (ii) が改善するかについても評価する．

表 4 に手順 (iii) の誤り 13 件に対する手順 (i) と手順 (ii) の正解数，手順 (iii) の正解例 74 件に対する手順 (i)，手順 (ii) の誤り数を示す．なお，手順 (ii) による改善を確認するために，手順 (ii) の正解数と誤り数

表 3: 実験結果

	手順 (i)	手順 (ii)	手順 (iii)
適合率	1.0	0.788	0.851
再現率	0.069	0.379	1.0
F 値	0.129	0.512	0.920

表 4: 手順 (iii) に対する手順 (i) と手順 (ii) の効果

	正解数	誤り数
手順 (i)	4	0
手順 (ii)	2	2

手順 (iii) の誤りを他の手順で 4 件正解できるようになるため，3 つの手順を組み合わせることで，曖昧性解消の適合率を 89.7%に向上させることができる．

5.2 考察

本節では，各手順の実験結果について考察する．

まず手順 (i) では，再現率は低いが，推定誤りが含まれなかった．また，表 4 から手順 (i) は手順 (iii) の誤りを改善する効果が見られる．誤りを改善させる例としては，山梨県甲斐市の議会における「学校給食費の無償化でありますけれども、…（略）山口県の和木町などでは、学校給食を無償化にしておりまして、…」という発言が存在する．この例から，手順 (i) は，他の地域の自治体について言及する際に，曖昧性をさけるために上位自治体の名を出す場合に有効であると考えられる．

手順 (ii) は，適合率はある程度良いが，再現率が低い状態である，そのため，辞書の追加により抽出する地名を増加させ，地名を抽出する発言を前後にのばすことで再現率を向上させることを検討する必要がある．

最後に，各手順で解決することができない例について述べる．以下に示す福井県越前市の東京都港区について言及する発言では，出典場所に港区が存在せず，また地名を含まず，パターンも適用できない．

「皆さんがパイプを持ちたい港区にぽんとつてができたというのは、やはり …」

この例の正解は，前の発言で「東京都」，また港区に関わる人物が出現するため東京都の港区と特定することができた．したがって，前の発言も地名抽出やパターンの対象とし，またその地名に関連する施設名や人物名などを取得することで，より精度を高めることができると考えられる．

6 おわりに

本稿では，他の自治体から参考にされる取組を行っていることを示す発言（引用発言）を会議録から収集するために，発言中に含まれる地名の曖昧性解消について検討した．曖昧性解消の手順としては，上位の地名階層を見つけるパターンマッチ，発言内の地名との距離の平均が最小となる候補の選択，発言が行われた議会の場所（出典情報）と距離が最小となる候補の選択の 3 つを適用し，その精度を検証した．その結果，3 つの手順を組み合わせることで 89.7%の高い適合率で曖昧性を解消できることがわかった．今後の課題としては，自治体名を含む発言の抽出段階における誤りの減少，発言内の地名候補の抽出の際に辞書を増やし，再現率，適合率を増加させることが考えられる．また，本研究の目的である引用発言抽出について，本稿の手法を適用し，政策的取組を含む発言の抽出を行いたい．

参考文献

[1] 金木雄太, 山田剛一, 絹川博之, 中川裕司.”地名辞書を利用した地名の曖昧性解消と文書の地域分類.” 第 19 回人工知能学会全国大会論文集, 2E1-03, 2005.

[2] 平野徹, 松尾義博, 菊井玄一郎.”地理的距離と有名度を用いた地名の曖昧性解消”, 情報処理学会第 70 回全国大会講演論文集, No.2, pp. 85-86, 2008.

[3] 粟村誉, 荒牧英治, 河原大輔, 柴田知秀, 黒橋禎夫. ”ソーシャルメディアにおける空間的近接性と時間的一貫性を考慮した地名の曖昧性解消.” 情報処理学会研究報告. 自然言語処理研究会報告 2014.

[4] Sinnott, R. W. ”Virtues of the Haversine.”, 1984.

[5] 六瀬聡宏, 内田理, 富田誠, 梶田佳孝, 山本義郎, 鳥海不二夫. ”大規模災害時の情報提供を目的とした地名の曖昧性解消”, 言語処理学会第 21 回年次大会発表論文集, pp.220-225, 2015.

[6] 菅原晃平, 大城卓, 斎藤誠, 永井隆広, 渋木英潔, 木村泰知, 森辰則, 地方議会会議録コーパスの拡充における問題点の分析と対処, 言語処理学会第 18 回年次大会発表論文集, pp.1-15, 2012.

[7] 相良毅, 有川正俊, 坂内正夫.”分散位置参照サービス”, 情報処理学会論文誌, Vol.42, No.12, pp.2928-2940, 2001.