知能と情報（日本知能情報ファジィ学会誌）Vol.28, No.5, pp.875 - 886 (2016)

原著論文

子音の音韻類似性及びSVMを用いた駄洒落検出手法†

谷津　元樹*1・荒木　健治*1

近年，対話システムの普及に伴い，機械が言語的ユーモアを理解する必要性が高まっている．これまでの研究において，駄洒落などの韻文のユーモアを対象に大規模な自然文の集合から検出を試みた例は確認されていない．駄洒落を含む文をブログテキストよりSVMを用いて分類する手法を提案し，有効な素性を調べるため，駄洒落全般の類型別の構成比の標本調査を行った．その結果，文内に音韻的に類似した1形態素およびそれに対応する音素列を有する駄洒落の類型が支配的であることが判明した．このため本論文では，語彙素性に加え，音韻類似度に基づく音韻類似区間の検出ルールを素性としたSupport Vector Machineを用いた分類による検出手法を提案する．検出性能評価実験の結果，提案手法におけるルールベース素性の付加の有効性が確認された．

キーワード：ユーモア，駄洒落，音韻類似性，テキスト発話分類

1. はじめに

近年，機械がユーモアを表出・理解することに対する関心が高まっている．ユーモアへの関心は，機械によるユーモアがそれに接するユーザの生活の質（QOL）を向上させることに対する関心，そして人工知能技術全体の発展への貢献に対するものに大きく分けられる．

ユーモアを使用する人のQOL向上を実証する例として，社会心理学において，ユーモアを交えることによるアサーティブネス（自己表現・意見表明）の向上が報告されている［1］．また，日常的にユーモアを使用する機会の増加による健康増進の効果も期待できる．臨床心理学においては，日常生活におけるユーモアの表出による，表出者自身の心理的ストレスの軽減［2］，抑うつ症状の改善［3］といった報告がある．

このような効果を，人工的なエージェント及びロボットに対するコミュニケーションにおいて得るための研究が進められている．例えばDybalaら［4］は対話エージェントがユーモアを発する条件下では，ユーザがシステムに対し意外性を感じ，システムとの対話を継続する欲求が高められることを示した．宮澤ら［5］は，対話システムとユーザの間の対話の継続性を高める要因の調査を行った．その結果，ユーモア性のある所作が継続性を高めることが示された．

これまでに，人工知能システムがユーモアを発する状況下でのユーモア生成の有効性に対しては多くの研究成果がある［6,7,8］．しかし，システムがユーモアを識別する手法，その意味の曖昧性を解消する手法，識別・理解の結果を利用した応答を行う手法及びそれらの及ぼす効果についての知見は未だ十分に得られているとはいえない．

ユーザはシステムに対し，入力した発話の意味が文字通りに理解され望ましい応答が得られないという不満をもつことがある．システムがユーモアを理解して適切な応答をすることにより，その不満を軽減できると考えられる．システムがユーモアを理解した（と，ユーザが考える）上での動作を行うまでの過程は，次の3つの段階に分解できる．

A. ユーザによる発話をユーモアとして検出する．
B. ユーモアとして識別された場合，内容に対してスコア付けを行う（面白さ等の評価）．
C. 識別したユーモアに対し，面白さ等の評価結果に基づいた適切な応答または反応動作を行う．

ユーモアの理解を確実なものとするためには，上記の過程における**A.**の段階を高い精度で実現しなければならない．

そこで，本論文は韻文ユーモアである駄洒落の検出手法に着目する．駄洒落においては，**2.1**で述べるように一部の音素が異なるが音韻的に類似性の高い2区間を持つものが多くを占めていることが，**2.3**で述べる調査によって判明している．そこで，音韻の類似に着目した3つの駄洒落検出ルールを実装し（詳細は**5**

† A Method for Detecting Japanese Puns using a Support Vector Machine and Consonantal Phonetic Similar Features
Motoki YATSU and Kenji ARAKI

*1 北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

章で述べる），これらに学習データ文の語彙素性を加えた統計的機械学習手法による分類器を用いて検出を行う．本論文においては，**5.2** で述べる Support Vector Machine（SVM）を用いる．SVM は，高い分類性能から文書分類において広く用いられる教師有り機械学習手法であり，線形分類に加え同条件下でのカーネル法を用いた非線形分類を行うことが可能である．

本論文の目的は，駄洒落を含む文を一般的なテキストより SVM を用いて検出する際に有効となる素性及び高精度な検出を妨げる基礎的な問題点を明らかにすることである．素性に関しては，素性単独の有効性に加えその組合せの有効性を評価する必要がある．従って，本論文において検証する仮説を以下に示す．

(1) 駄洒落の検出に対し，分類器に与える素性として語彙素性の適性がある．

(2) 読み仮名の完全一致，音韻類似度による類似部分検出または促音・撥音・長音の付加/脱落を考慮した音韻的類似部分検出に基づくルールベース素性の付加により，検出性能が向上する．

(3) 仮説(1)，(2)で述べた全ての素性を用いた場合，検出性能が最大化する．

本論文の構成を述べる．初めに **2** 章で検出対象となる駄洒落の類型及び基本構造について述べる．続いて **3** 章で，既存の言語的ユーモアの検出・理解のための手法の本論文との差異を述べる．**4** 章では本論文の分析に用いたデータの取得方法について述べる．**5** 章では提案する駄洒落検出手法を，音韻類似度の計算手法とともに概説する．**6** 章では提案手法の検出性能の評価実験について述べる．**7** 章において，得られた結果に関して考察し，前述の仮説**(1)〜(3)**の検証を行う．

なお，「駄洒落」という表現の名称が指す表現の範囲には，文献による異なりがある．よって，従来の研究を把握するにあたり，駄洒落という表現の定義を確認する必要がある．そのため，先に 2 章において対象とする駄洒落の類型を概観し，続いて 3 章において従来の研究を検討する．

2. 対象とする駄洒落の類型

本章では，駄洒落の類型を概観し，中でも，併置型駄洒落を主な検出の対象とする理由について述べる．

駄洒落は，言葉遊びにも分類される言語表現であり，日本語の短文ユーモアの代表例である．駄洒落にはいくつかの類型があるが，最も基本的とされるものは，音韻的に類似するものの意味の乖離が認められる 2 つの音素列の現れた表現（**併置型駄洒落**）である．**2.3** での調査が示すように，併置型駄洒落は駄洒落全体の数に占める割合が大きい．

併置型駄洒落は文内に 2 つの音韻的に類似した区間（**種表現**及び**変形表現**）をもつ．併置型駄洒落において，**種表現**は文内の独立形態素（自立語となる名詞・動詞・形容詞・感動詞）あるいはその句（名詞句・動詞句・形容詞句）を，**変形表現**は種表現との音韻的類似性を持つ文内の任意の区間の音素列を指す．

2.1 駄洒落の主な類型

駄洒落は，対となる 2 音素列の音韻的な類似に基づき生成される比喩表現と捉えられる．類似する対となる音素列が，対象文内に共起する場合と，しない場合とがあり，滝澤[9]は前者を併置型駄洒落，後者(例：図 1 における(v))を**重畳型駄洒落**と定義している．併置型駄洒落における種表現及び変形表現の現れ方については **2.2** で述べる．理想的な例においては，音韻的類似性によるルールのみを用いて可能となる．

Kawahara［10］はこの併置型駄洒落において，種表現と変形表現の音韻が完全に一致するものを **perfect puns**，語音の一部の変化または脱落により一致しないものを **imperfect puns** と呼称している．本論文においては，語音の変化に柔軟な分類器を音韻類似度に基づいて構築するため，perfect/imperfect 双方に属する駄洒落を本論文における提案手法の検出の対象とする．これに加え，音韻類似性によるルールでの検出が困難な重畳型駄洒落を検出の対象に含める．

2.2 併置型駄洒落における種表現・変形表現

本節では，併置型駄洒落のもつ構造について述べる．

1 つの併置型駄洒落において，種表現及び変形表現の対が少なくとも 1 対出現する．図 1 の文(i)及び(ii)はその例である．ただし，文(ii)に表れるように，1 つ

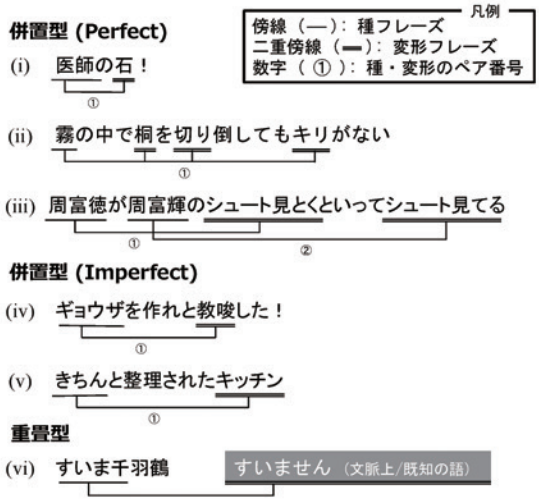


図 1 駄洒落文の例

の種表現に対し複数の変形表現が対応する場合がある．種・変形表現がいずれも交換可能な場合，便宜上先行する表現を種表現とし，その他をこれに対応する変形表現とする．

また，1文において複数の種・変形表現の対が観察される場合もある．この例を図1の文(iii)に示す．文(iii)は，種表現には「周富徳」及び「周富輝」という人名が該当し，それぞれに対応する変形表現は「シュート見とく」及び「シュート見てる」である．

図1の文(iii)では，imperfectな併置型駄洒落における種表現と変形表現の対応を示している．種表現の「ギョウザ(/gyo u za/)」に対する変形表現の「教唆(/kyo u sa)」は異なる子音から構成された語となっている．さらに，imperfectな併置型駄洒落には，促音便(仮名表記による「っ」「ッ」)や撥音便(「ん」「ン」)が種・変形のいずれか一方に含まれる場合がある．この例を図1の文(v)に示す．

2.3 各類型の構成比

2.1で述べた2種の類型のそれぞれが，駄洒落の標本中に占める割合を調査した．調査者は1名（第1著者）である．標本は，**4**章にて述べる分析対象として取得した全駄洒落文45,970文より，600文を無作為抽出した．ここで得られた駄洒落の類型別の構成を表1に示す．この結果より，併置型駄洒落が全体において高い割合を占めること，特に音韻的に類似した2つの区間を持つimperfectな駄洒落の比率が大きいことがわかる．なお，抽出した駄洒落文数は次のように決定した．信頼区間95%（$\lambda=1.96$）において，母比率$P=0.5$に対する標本内誤差dの上限を5%とすると，標本の大きさnの下限は式(1)より求められる［11］．

$$n \geq \frac{N}{\left(\frac{d}{\lambda}\right)^2 \frac{N-1}{P(1-P)}+1} = 380.98.. \qquad (1)$$

ここでは，式(1)において求められた標本の大きさの下限及び調査の所要時間の制限を考慮して標本の大きさを$n=600$とした．

2.4 併置型駄洒落を検出の対象とする理由

併置型駄洒落を検出の対象とする理由は，第一に併置型駄洒落の全駄洒落に占める割合が大きいためである．このことは，**2.3**で述べた類型の構成比の調査において，併置型駄洒落の割合が93.8%であることから確認できる．

第二に，併置型駄洒落でない駄洒落，すなわち**重畳型駄洒落**の検出は次の理由で一般に困難である．まず，

表1 600文の駄洒落の類型及び構成

併置型	perfect	42 (7.00 %)
	imperfect	521 (86.8%)
	計	563 (93.8%)
重畳型		33 (5.50%)
取得失敗		4 (0.667%)

重畳型駄洒落は，種表現が文内または文外の暗黙の文脈中にあると見なしうる駄洒落であるため，種表現が何であるかを変形表現及び文脈より推定する必要がある．

(vii) ブドウを食べて驚いた.「きょほぉぉぉ～～～！」

例えば上記の文(vii)では下線部「きょほぉぉぉ～～～！」が変形表現に当たるが，その種表現となると考えられる形態素の「巨峰」は文内には出現しない．「巨峰」との音韻的類似に基づく一致を求めるには，処理の前に，先頭の形態素「ブドウ」の関連語として同形態素を推定する必要がある．このような文脈情報の付与の必要から，重畳型駄洒落の検出のコストは他の類型に比べて大きい．

一方，併置型駄洒落は，種表現及び変形表現の両方が文内に明示されているため，推定の必要がなく検出に要するコストが小さい．

以上の考察から，本論文における提案手法は，併置型駄洒落の検出を行うことにより駄洒落を検出するものとする．ただし，同手法の検出対象は併置型駄洒落のみに限らず，重畳型駄洒落を含む他類型の駄洒落をも検出対象とする．また，併置型の下位類型のperfect/imperfectは，双方を検出の対象とする．

3. 関連研究

ユーモア・笑いというテーマ全体に対しては，人工知能以外の分野でも研究が活発化してきている［12］．笑いの検出・測定という観点では，ビデオカメラによる入力映像からの表情及び音声入力から笑いの検出手法が，米国ではすでに特許出願されている［13］．

駄洒落文の意味理解を目的とするシステムは，これまでにYokogawa［14］により提案されている．しかし，実験において有効性評価に用いられた駄洒落は100項目に限られ，より多数のデータに対する性能が得られていない．本論文においては，これまでに作成されたものより規模の大きい口語文データより駄洒落を検出する手法を提案する．また，Yokogawaの手法が対象とするのは，2.1で述べた類型のうちimperfectな駄洒落のみであり，同音異義語を利用したperfectな駄洒落の検出は不可能であるのに対し，本論文の提

表 2　駄洒落を含む文の取得元の Web サイト

Webサイト名	URL	取得件数
ダジャレナビ	http://www.dajarenavi.net/pc/i_today_index.htm	39,120
Dajare Station	http://dajare.jp	8,795
ダジャレネット	http://www.dajare.net	1,621
ひとくちダジャレ大集合	http://www.biwa.ne.jp/~aki-ina/gyagu.html	1,067
ダジャレ集 ダジャレ事典	http://dajareshuu.web.fc2.com	982
ダジャレの缶詰	http://www.geocities.jp/pikumin_hiroba/dajare.html	572
駄洒落倶楽部	http://with2.net/dajakura	428
ダジャレ広場	http://www1.ocn.ne.jp/~origo/dazyare	303
駄洒落を言ったのは誰じゃ?	http://wtpage.info/dajare	107
合計（重複文の除去前）		52,995
合計（重複文の除去後）		45,970

案手法は perfect/imperfect に関わらず併置型駄洒落全体を検出の対象にしている．

天谷ら［15］は，単語 bag-of-words を基本とする表層情報を手がかりとした散文ユーモアの SVM 及び Naive-bayes 法を複合的に用いた識別器を構築し，Twitter（https://twitter.com）等より取得したユーモア/ノンユーモア文集合の分類実験において有効性を示した．本論文の提案手法は，語彙素性に加え，韻文のもつ音韻的特徴を考慮した音韻類似度に基づく素性を使用する．

また，システムがユーモアを理解するために用いる基礎的なモデルとして，ファジィ理論に基づくおかしみの誘発モデル［16］が考案されている．現時点において同モデルは，山根らによる駄洒落に類した短文ユーモア（ことわざすかし）の生成手法［17］におけるランキング関数として使用されている．しかし，同手法においては対象文が駄洒落であることを前提に面白さの評価を行うため，評価関数を駄洒落の認識に用いることを意図していない．

上述のように，言語的なユーモアのうち，散文ユーモアの検出に関する研究はすでに行われているが，韻文すなわち言葉遊びとなる駄洒落などのユーモアに対する，オープンデータを対象とした，口語文等からの検出を行う手法に関する研究は，著者らの知るところでは確認されていない．

4. 分析対象のデータ

本論文においては，Web 資源に存在する駄洒落の集積された Web サイトより駄洒落を収集し，分類問題の対象の正例データとした．本来，駄洒落を分析するにあたり，他の言語現象と同様に，できるだけ現実世界における生起頻度や生起のための条件（駄洒落を含む会話が発生する可能性の高いトピックなど）を反映した分析を行う必要がある．しかし，日常会話における駄洒落の使用に関しては，実コーパスやその統計的分析結果がこれまでに得られておらず，具体的な実用例においての検出を行うことが困難である．

従って，正例データの取得をスパイダーを用いて Web より行った．取得の際，重複文を削除した．データの取得元の Web サイト，取得した正例文数の合計及び重複除去後の正例文数を表 2 に示す．

駄洒落を含む文の検出を行うため，駄洒落を含まない文からなる負例データを準備した．負例データは 2011 年より 2012 年の間に Ameba（http://ameblo.jp）において書かれたブログ記事を収集した *YACIS* コーパス［18］より以下で述べる手法を用いて抽出した．すなわち，コーパスに文として収録されている項目をプログラムを用いて無作為抽出を行った．

重複文を除いた全正例文より求めた文長の分布が正規分布に従うかについて，Shapiro-Wilk 検定［19］を行ったところ，正規性が確認されなかった．従って，文長に操作を加えることにより，その分布に偏りの生じる可能性が高いため，取得する負例データに対する文長の制限は設けなかった．

なお，同コーパスの収録文より無作為に抽出した 2,000 文中，駄洒落を含む文が 1 文（0.05%）存在した．このことから，混入する正例の数は非常に少ないため，上記の手法を用いることでブログコーパスより駄洒落を含まない文集合の収集が可能である．

取得した駄洒落ならびにブログ内短文から，開発及び評価用のデータセットを構築した．各データの規模は表 3 に示す通りである．開発データは，**6** 章に述べる検出性能評価実験において，**5.1** 及び **5.2** で述べる SVM を用いた分類器における各カーネル関数内のパラメタ，素性値の計算時に用いられる閾値の決定，及び子音音韻類似度の算出式(4)，(5)を用いた子音ペアデータからの新類似度の事前の算出に使用した．評価データは，**6** 章の検出性能評価実験において分類器に

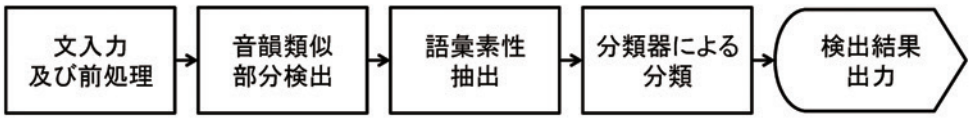


図2 検出システムの処理の流れ

表3 実験対象のデータセット

名称	正例文数	負例文数	計
開発データ	6,000	6,000	12,000
評価データ	39,970	39,970	79,940
計	45,970	45,970	91,940

与える学習データ及びテストデータとして用いた．

5. 提案手法

提案手法のシステムの概要を述べる．システムは入力したテキスト（以下，入力文）を，駄洒落を含む文または含まない文の2クラスに分類する．システムの処理の流れを図2に示す．前処理においては，**5.2**で述べる音韻類似度の計算に適するように入力文を整形するため，入力文より長音符（「ー」）以外の記号を除去する．

5.1 分類器の構築，素性の選択

提案手法における分類器に教師あり機械学習手法であるSupport Vector Machine（SVM）[20]を用いる．SVMは，入力をベクトルとするベクトル空間モデルを利用した2クラスの分類手法である．SVMの実装はscikit-learn（http://scikit-learn.org）を用いた．

入力ベクトル$\boldsymbol{x}$を，重みベクトルを$\boldsymbol{w}$，切片をbとすると，分離超平面を表す関数は

$$f(\boldsymbol{x}) = \boldsymbol{w}\cdot\boldsymbol{x} - b \tag{2}$$

式(2)で表される分離超平面を，学習データの存在する空間において最適な（マージンが最大化された）条件でw及びbを決定することにより，同空間に入力される評価データを識別する．

SVMでは，式(2)の$\boldsymbol{w}\cdot\boldsymbol{x}$を置換するカーネル関数の定義によって，線形分離が困難なデータに対しても，より高次元の空間への写像による非線形の分類が可能になる．分離超平面は学習によって得られるパラメタ$\alpha_i\,(i=1...n)$を伴って式(3)の形になる．

$$f(\boldsymbol{x}) = \sum_{i=1}^{n}\alpha_i k(\boldsymbol{x},\boldsymbol{x}_i) - b \tag{3}$$

検出性能の比較のため，本論文ではp次の多項式カーネル$k(\boldsymbol{x},\boldsymbol{x}_i)=(\boldsymbol{x}\cdot\boldsymbol{x}_i+l)^p$（$p=1,2$）及びRBFカーネル$k(\boldsymbol{x},\boldsymbol{x}_i)=\exp-\frac{\|\boldsymbol{x}-\boldsymbol{x}_i\|^2}{\sigma^2}$を用いる．一般に$p$次の多項式カーネルでは，ある1組の$p$個の素性群の値が全て非0である場合の影響を反映した分類を行うことができる．また，RBFカーネルでは，分離平面の平滑度に影響するパラメタσを適切に選択することにより，学習データへの適合の強さを調節できる．なお，線形分類器の式(2)における$\boldsymbol{w}\cdot\boldsymbol{x}$を，以降では便宜上，線形カーネル関数と呼び，また同分類手法を線形カーネルと呼称する．

分類器に対し学習及び分類を行う際，入力ベクトルには各素性による素性空間に対応する値を代入する．提案手法において用いることの可能な素性は，以下に揚げる語彙素性（bag-of-words）及び3つのルールベース素性である．以下の素性を組み合わせた分類器を構築することにより，**1**章で述べた**仮説(1)，(2)**を検証することができる．**仮説(3)**に関しては下記の全ての素性を用いることにより検証が可能である．

(a) 語彙素性（→仮説(1)に対応）

内容語（名詞，固有名詞，一般動詞，形容詞，副詞，感動詞）の語幹を形態素解析器MeCab（http://taku910.github.io/mecab/）を用いて抽出することにより作成されるbag-of-words素性である．形態素辞書にはIPAdicを用いる．

Bag-of-words素性の値の決定は次のようにして行う．事前に学習データの全ての入力文より取得したbag-of-wordsと素性番号を対応付ける．学習時及び検出時に，システムへの入力文から同様にbag-of-wordsを取得し．事前に指定された素性番号に対応する内容語が得られた素性の値を1とする．

(b) 読み仮名列完全一致素性（→仮説(2)に対応）

MeCabならびに補助形態素解析器として，形態素解析器JUMAN（http://nlp.ist.i.kyoto-u.ac.jp/index.php? JUMAN）を用いて読み仮名列を抽出し，種表現（独立形態素）と読み仮名が完全に一致する区間を変形表現として探索する．ただし1文字の読み仮名に対する一致区間が多数となることによる誤検出を防ぐため，対象の読み仮名は2文字以上とする．検出に成功した場合，素性値を1とする．

なお，他のルールベース素性(c)(d)と異なり，素性(b)は閾値等のパラメタを持たない．

(c) 子音の音韻類似度に基づく一致素性（同上）

種・変形表現の語音の一部が異なるimperfectな併

置型駄洒落が対象駄洒落の 85% 超を占めることから（**2.3**），音韻の類似部分の検出においては語音の異なりの吸収が必要と考えられる．従って，**5.2** で述べる子音の音韻類似度を用いた素性を構築する．

具体的には，素性(b)において抽出した読み仮名列に次の処理を加える．最初に拗音（ゃ，ゅ，ょ，ゎ）が単独で一致することを避けるために，読み仮名をモーラ単位に分割し配列化する．このとき長音を二重母音に変換し，促音及び撥音のモーラに独自の記号を与える．モーラ内の子音音素と母音音素を分離して配列内に格納する．例えば「インターショップ」は {/*, i/, /*, N/, /t, a/, /*, a/, /sh,o/, /*, Q/, /p,u/} という配列に変換される．ここで，**N** は撥音，**Q** は促音を指す．その他の子音部の音素の表記はヘボン式ローマ字による音声表記と同一である．

各モーラを子音部と母音部に分離し，各形態素に対する任意の区間を探索する際に，子音部の類似度を **5.2** に掲げる手法で算出する．この類似度の合計を求め，閾値以上であれば素性値を **1** とする．

(d)促音・撥音の加減を認める類似度一致素性（同上）

種表現内部へ促音・撥音の挿入及び脱落を許容する条件で，子音の音韻類似度に基づき素性値を決定する．例えば，駄洒落「ふとんがふっとんだ！」における種表現「ふとん」に対し，変形表現「ふっとん」において促音「っ」が挿入されている．本素性の値を決定するには，種表現あるいは変形表現における促音・撥音の追加を検出し，追加された促音・撥音を削減した状態で素性(c)と同一の手法を用いて子音類似度スコアの算出を行う．

このようにして，これらの音素の種/変形表現間の加減が許容される．素性(c)と同様に，類似度の合計から素性値を決定する．

5.2 音韻類似度の計算

システムは解析された各形態素の音韻モーラ列に対して，全体のモーラ列との音韻類似度を算出する．このとき，同じ子音については算出の対象としない．異なる子音のペアにおいて音韻類似度の高いものは駄洒落である可能性がより高く，類似度が低く母音のみが一致する子音ペアは，駄洒落ではない表現に偶然表れる可能性が高いと考えられるためである．

音韻類似度の算出手法として，駄洒落コーパスより算出した子音間の音韻類似性の指標による対数 O/E 比の概念を用いる．対数 O/E 比は，Kawahara らによる子音の心理音響的類似性の指摘［21］の他，広く音韻論の分野で 2 音素の共起の度合の指標として用いられる．

異なる子音 p,q に対する対数 O/E 比 $\mathrm{OER}(p,q)$ 及びそれを用いた種表現 t を含む文 S における音韻類似度 *score* は，ある対象コーパスについて，それぞれ式(4)，(5)により定義される．

$$\mathrm{OER}(p,q)=\mathrm{OER}(q,p)=\log\frac{N_{p,q}+N_{q,p}}{N_{\mathrm{pair}}\cdot \mathrm{P}(p)\cdot \mathrm{P}(q)}+c \qquad (4)$$

$$score=\sum_{t\in S}\sum_{i=1}^{|t|}\mathrm{OER}(p_i,q_i) \qquad (5)$$

ただし，p,q はそれぞれ種表現，変形表現に表れる子音を，$N_{p,q}$ は p,q の順に表れる子音の対（p,q）の対象コーパスにおける生起頻度を指す．$\mathrm{OER}(\cdot)$ の計算において p,q は交換可能である．式(5)の $|t|$ は種表現形態素の音素数であり，変形表現候補内の音素数に等しい．N_{pair} は，対象コーパスに存在する子音のペアの総数を表す．$\mathrm{P}(p)$ は N_{pair} 個の子音ペアにおける子音 p が含まれるものの割合である．対数 O/E 比は，N_{pair} 個の全子音ペアについて，式(4)を用いて事前に算出したものを用いる．式(4)における c は定数であり，同じく事前の実験により定める．

p,q が同一の子音である場合は，類似度計算の対象としない．その目的は，$p=q$ である場合に式(5)の *score* が不当に大きくなることの回避及び imperfect な併置型駄洒落の検出率を相対的に高めることである．

式(5)を用いて種表現の形態素と変形表現候補となる全区間の音韻類似度を計算し，*score* が閾値を上回る場合，素性(c)ないし(d)は素性値 1 をとる．例として，次の文(viii)における種表現形態素「**人魚**」と変形表現となる区間「**人情**」の間の音韻類似度を計算する．

(viii) **人魚**の**人情**劇！
{**/n, i/, /*, N/, /gy, o/**, /n, o/, **/n, i/, /*, N/, /j, o/**, /*, u/, /g, e/, /k, i/}

子音間類似度を異なる子音に対して計算する．ここでは子音のペア［gy-j］の対数 O/E 比 OER（gy, j）を利用する．**4** 章で構築した開発データを用いた場合，$\mathrm{OER}(\mathrm{gy},\mathrm{j})=0.1$ となり，$score=0.1$ となる．

1 つの種表現候補に対し複数の変形表現候補が存在する場合は，最も *score* の高いものではなく，全ての変形表現候補を等価なものとして取り扱う．また，複数の変形表現候補が最も高くなる場合も，それに従って全ての変形表現候補を変形表現として検出する．

種・変形表現検出の条件においては，種・変形表現の 1 文内の検出数や，閾値を超えた *score* の大きさは考慮に入れないものとする．ただし，これらの指標は

駄洒落の意味理解や面白さの自動評価において不可欠な表層的情報を与えると考えられる．

5.3 学習データおよびテストデータの規模

6 章の実験において全評価データ（79,940 項目）を用いて 20 分割交差検定を行った場合，学習データが 75,943 文，テストデータが 3,997 文となる．SVM の分類器に入力するデータ量の全体の規模については，文献［22,23］での研究と比較して 2 オーダー以上の差は見られないため，適切なものと考えられる．

文献［22］は SVM を用いた分類問題の研究の例である．この研究は，59 種類の日本語機能表現と内容表現の分類を目的としたものであり，訓練データ 3,083 項目を用いてテストデータ 7,703 項目を分類している．また，文献［23］の地方議会会議録からの要望表現の抽出タスクにおいては，オープンデータ 5,388 項目に対して 10 分割交差検定を実施し，提案手法の有効性を確認している．

ただし，これらの研究は分類対象が異なる点に留意する必要がある．最適なデータ規模の追加調査が必要であるが，本論文においては今後の課題とする．

6. 検出性能評価実験

提案手法を実装したシステムのオープンなデータに対する検出性能の評価を行った．具体的には，まず同一の素性の組合せ（素性セット）に対し 20 分割交差検定による各カーネル関数の検出性能の比較を行った（**6.1**）．次に，負例データに対する正例データの比率を変化させ，正例数の減少に対する各素性セットの示す頑健性の調査を行った（**6.2**）．頑健性とは，負例データに対する正例データ量の比率が低くなる条件において検出性能の低下を抑えられる度合いを指す．最後に，語彙素性の有効性を分析するため，素性(a)と素性(b)(c)(d)の間の比較を行った（**6.3**）．

本章において行った実験における性能を表す尺度には図 3 における式(6)～(9)に示すものを用い，性能評価の結果値は交差検定の全結果の平均値とした．

本実験で使用した素性セットの一覧を表 4 に示す．

5.1 において述べた各カーネル関数におけるパラメタ及び素性(c),(d)の値に影響する閾値は，**4** 章で述べた開発データ計 12,000 文に対し予備検出実験を行い，最も高い検出性能を示したものに決定した．用いた閾値を表 6 において示す．

また，**5.2** にて提案した子音の類似度を示す対数 O/E 比は，同開発データにおける正例文 6,000 文に第 1 著者による種・変形表現のアノテーションを行ったものを用いて事前に算出した．

$$\text{精度} = \frac{\text{正しく検出された駄洒落を含む文の数}}{\text{駄洒落を含む文とした判定の総数}} \times 100 \quad (6)$$

$$\text{再現率} = \frac{\text{正しく検出された駄洒落を含む文の数}}{\text{評価データにおける駄洒落を含む文の総数}} \times 100 \quad (7)$$

$$F\text{ 値} = \frac{2 \times \text{精度} \times \text{再現率}}{\text{精度} + \text{再現率}} \quad (8)$$

$$\text{正解率} = \frac{\text{正しく判定された文の総数}}{\text{評価データの文の総数}} \times 100 \quad (9)$$

図 3 検出性能評価に用いる尺度

表 4 性能評価実験において用いた素性セット(FS)

FS	(a)	(b)	(c)	(d)	FS	(a)	(b)	(c)	(d)
F_1	-	-	-	○	F_9	○	-	-	○
F_2	-	-	○	-	F_{10}	○	-	○	-
F_3	-	-	○	○	F_{11}	○	-	○	○
F_4	-	○	-	-	F_{12}	○	○	-	-
F_5	-	○	-	○	F_{13}	○	○	-	○
F_6	-	○	○	-	F_{14}	○	○	○	-
F_7	-	○	○	○	F_{15}	○	○	○	○
F_8	○	-	-	-					

表 5 素性セット F_{15} に対する各カーネルの検出性能

カーネル	素性セット	精度	再現率	F値	正解率
線形	F_{15}	0.851	0.865	0.858	0.857
2次多項式	F_{15}	0.903	0.894	0.898	0.901
RBF	F_{15}	0.907	0.909	0.908	0.909

6.1 カーネル関数間の比較

線形カーネルを含むカーネル関数の検出性能を比較するため，素性セット F_{15} に対してカーネル毎の検出性能を求めた．学習データ及びテストデータにおける正例数と比例数の比は 1：1 である．この検出性能の比較結果を表 5 に示す．

6.2 正例比率の変化に対する各素性セットの頑健性の評価

雑談対話コーパスなどの実データにおいては，正例数は負例数に比べごく少量になると考えられる．そのような場合，正例数の減少に対して検出性能の低下を抑えられること（頑健性）が求められる．

各素性セットの頑健性を比較するため，予備実験において特に検出性能の高かった素性セット F_8，F_9，F_{10}，F_{11}，F_{12}，F_{13}，F_{14} を用い，評価データに対する 20 分割交差検定を，正例：負例＝0.01：1.0 より 1.0：1.0 となるまで正例文の構成比率を 0.01 ずつ増加させながら繰り返し行った．この結果における正例負例比率を横軸に，検出性能を示す F 値を縦軸にプロットし

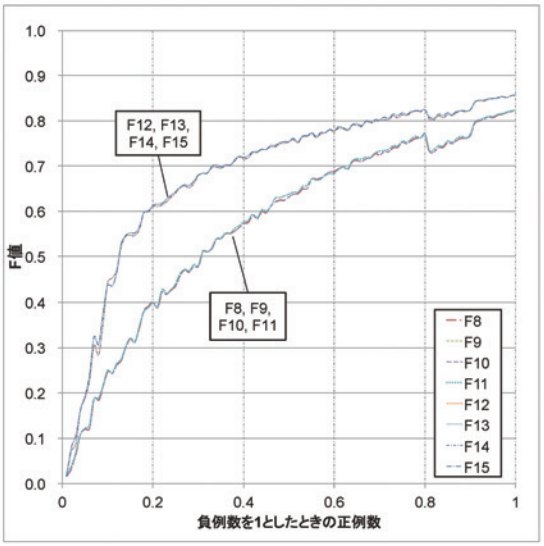


図 4 素性セット F_8〜F_{15} に対する正例数/負例数比に対する F 値のプロット．F 値の差の小さい素性セットのグループをボックスで示した

表 6 各ルール単体での検出性能．*1 は表上段の各ルール素性の閾値を組み合わせて用いたことを示す

ルール(単体) / 手法	閾値	精度	再現率	F値	正解率
(b) 完全一致	-	0.516	0.696	0.593	0.521
(c) 子音類似度	0.28	0.589	0.612	0.600	0.592
(d) 子音類似度 + 促・撥音	0.99	0.610	0.674	0.640	0.621
SVM (F_7)	*1	**0.645**	**0.784**	**0.708**	**0.677**
SVM (F_8)	-	**0.788**	**0.860**	**0.821**	**0.814**
SVM (F_{15})	*1	**0.851**	**0.865**	**0.858**	**0.857**

たものを図 4 に示す．計算資源の制約から，カーネル関数には学習が高速な線形カーネルを用いた．

6.3 語彙素性の有効性に対する分析

(a)語彙素性は，ルールベース素性(b)(c)(d)に付加することにより，文法・音韻上の検出ルールのみでは捉えられない語彙上の傾向を検出に反映することを可能にすると考えられる．これを実証するため，(b, c, d) ルールの単体での検出能力と素性セット F_{15} ともに SVM を用いた分類器との検出性能の比較を行った．結果を表 6 に示す．なお，表 6 において閾値が「－」で示される場合，当該素性が閾値のパラメタを持たないことにより表記を省略している．

7. 考察

本章では，性能評価実験の結果より考察される点について述べ，改善方法を検討する．なお，本章で平均性能値の有意差について述べている場合は，指定のない限り，20 分割交差検定で得られた平均値について，Student の t 分布を用いた片側検定を行ったものとする．有意水準は指定のない限り 1％（$p<0.01$）である．また，素性セット F_n の検出性能が F_m を上回る形での両者の有意差が存在しないことを帰無仮説とした検定を行う場合に，$F_m \rightarrow F_n$ と表記する．

7.1 提案手法の有効性

提案手法の有効性について述べる．提案手法は，ルールベースによる分類結果を素性として用い，語彙素性ともに SVM による学習に用いることにより，検出性能の向上を図るものである．有効性の評価に関して，下記の(1)，(2)の知見が得られた．

(1) RBF カーネル使用時の検出性能の最大化

各カーネル間の性能を比較した **6.1** の実験では，RBF カーネルが最も高い性能を示し，次いで 2 次多項式カーネル・線形カーネルの順となった．ただし，RBF カーネル及び 2 次多項式カーネルは学習に多大な時間を要する（**6.1** において行った実験の場合，20 分割の 1 つの学習にそれぞれ 3,753 秒及び 2,420 秒を要した一方，線形カーネルの学習時間は 6.54 秒であった）ことから，計算資源の単位所要量に対しての性能は線形カーネルの場合が最大となるといえる．

(2) ルールベース素性(b)(d)による性能向上

図 4 が示す通り，線形カーネルを使用した実験では，素性セット F_{12}，F_{13}，F_{14}，F_{15} 間，及び F_8，F_9，F_{10}，F_{11} 間に有意な差が認められなかった．F_8-F_{10}，F_9-F_{11}，$F_{12}-F_{14}$，$F_{13}-F_{15}$ 間は(c)促撥長音挿入を認めない子音類似度素性の有無による差が有意差の要因となるが，有意差は検出されなかった．促撥長音増減を認める音韻類似度素性（$F_8 \rightarrow F_9$，$F_{10} \rightarrow F_{11}$，$F_{12} \rightarrow F_{13}$，$F_{14} \rightarrow F_{15}$ 間）の場合も同様である．素性(d)においては，$F_4 \rightarrow F_5$，$F_6 \rightarrow F_7$ の 2 つの組において有意差が確認されたが，本実験においては素性(c)及び(d)の効果は顕著ではなかったことがわかる．

反対に素性の付加により有意な差が表れている素性は，(b)完全一致素性（$F_8 \rightarrow F_{12}$，$F_9 \rightarrow F_{13}$，$F_{10} \rightarrow F_{14}$，$F_{11} \rightarrow F_{15}$）である．このことから，素性(c)，(d)には改善の余地が残るものの，ルールベース素性(b)の付加により，語彙素性(a)のみの場合（素性セット F_8）と比較し検出性能及び正例データ数の縮小に対する頑健性が向上することを確認できたといえる．

7.2 ルールベース素性(b)(c)(d)追加による効果

以下では，素性(b)，(c)，(d)のそれぞれの追加により新たに検出が可能となった正例を挙げる．また，素性の追加により誤って分類された正例及び負例につ

いても考察する．分析対象はRBFカーネルを使用した場合の検出結果である．

初めに，語彙素性(a)に子音の音韻類似度に基づく一致素性(c)を付加することによって取得が可能となった正例を挙げる．これらの例では，種表現の形態素における子音の音素と変形表現となった区間内の子音との異なりが見受けられる．下記の例においては，こうした音素の差異を吸収した検出に成功したと考えられる．なお，異なる子音のペアを例文右横に示す．

(viii) ユウコという子！[(**y,** *)]
(ix) ヨーグルト食べてから潜ると！[(**y, m**)]
(x) ハンペンを食べる時は，シャンペン！[(**h, sh**)]

一方，語彙素性(a)に完全一致素性(b)を付加することによって取得に成功した正例を以下に挙げる．素性(c)は，音素表現に分解する前での読み仮名表記に完全一致が見られる場合に正の値をとる．従って素性(c)では，表記は同一だが，音韻的には一致のない種表現と変形表現のペアも検出対象となる．

(xi) チーターはどうちーたーん？
(xii) 相談してもいいそうだん！

また，類似度を用いる条件下で，促撥長音付加の場合でのみ取得に成功した例を挙げる．これらの例においては，種表現となる形態素に促音及び撥音が付加されたものが変形表現の候補として検出されたと考えられる．

(xiii) ナタデココおいしくなったで，ここ！
(xiv) 体重が前月比マイナスだよ。まぁ，いいなーっす！

6.3の結果より，3種のルールを素性とするF_7を用いたSVMによる検出性能は，各ルール単体による性能に対し有意差が確認されたことから，ルールベース素性を入力とした場合の機械学習を使用することの有効性を確認できる．

7.3 語彙素性(a)追加による効果

ルールベース素性のみのセットF_7による検出に失敗した駄洒落文においては，明らかに(a)語彙素性の作用により検出されたものも存在する．

(xv) 一見さん，男割り！
(xvi) 君は男なんだから，もっと，お酢飲みなさい！

上記がその例である．(xv)は**2.1**で掲げた重畳型駄洒落に分類され，(xvi)は併置型にも重畳型にも分類できない駄洒落文の例である．これらはルールベースを用いた提案手法のシステムの想定を超えて検出されたものである．語彙素性の効力は，**6.3**に述べたルール単体及びSVMとの比較において，SVMにルールベース素性のみを与える条件（素性セットF_7）に比べ素性セットF_8の条件においてF値が0.113ポイント高いことから明らかである．ただし，一般的に語彙素性の効力は学習データに依存する傾向があることに留意する必要がある．

表7 重畳型駄洒落の検出性能

精度	再現率	F値
1.00 (67/67)	0.475 (67/141)	0.644

7.4 重畳型駄洒落の検出性能

7.3の例文（xv），(xvi）で挙げたように，併置型駄洒落に属さない駄洒落の検出は，主に(a)語彙素性によって検出が可能となっていると考えられる．このような重畳型駄洒落の検出能力を確認するために，**2.3**の構成調査において抽出した重畳型駄洒落141文のみのデータを準備し，同データに対する提案手法の検出性能の追加評価を行った．学習データとして，評価データより当該重畳型駄洒落と重複する文を除去した正負例各39,885文を用いた．また，分類器には線形カーネル及び素性セットF_{15}を使用した．本実験で得られた検出性能を表7に示す．

結果より，提案手法は重畳型駄洒落に対しても高い精度での検出を実現していることが確認できる．

7.5 駄洒落を含まない文の音韻的性質

駄洒落を検出するために正例・負例の分類性能を確認する実験を行うことにより，同時に駄洒落を含まない文（負例）の音韻的な特性を考察することが可能である．その特性は，駄洒落を含む文における種・変形表現内の子音の性質と反対のものであると考えられる．すなわち，入力文から種・変形表現候補を検出した場合，子音ペアの音韻類似度の合計値が閾値に満たない文が，駄洒落を含まない文に多いと推測される．

そこで，駄洒落を含まない文において検出された種・変形ペア候補内の子音ペアと，駄洒落を含む文における子音ペアの音韻類似度の平均値に有意差があるということを仮説として，その検証を行った．

具体的には，**6.1**の実験において非駄洒落と正しく判定された文のうち，種・変形表現候補が検出されたものについて，子音ペアの平均類似度を求め，同じく検出に成功した駄洒落文の平均値との間にMann-Whitneyの片側U検定を適用し，2つの平均値の間に1％水準または5％水準での有意差の存在の有無を確認した．この追加実験の結果を表8に示す．

表 8 Mann-Whitney の U 検定による音韻類似度スコアの比較

子音類似度の平均値		p値
正例	負例	
3.07	2.31	< 0.01

結果から，前述の仮説通り，種・変形表現候補内の子音ペアの平均音韻類似度は，駄洒落を含む文と比較して含まない文のほうが有意に低いものであることが確認された．

7.6 まとめ

7.1 の(1)で確認した，線形カーネルが非線形分類の可能な手法に次ぐ検出性能を示したことの一つの要因として，語彙素性が冗長となっていることが考えられる．駄洒落 Web サイトに収録される駄洒落を含む文がユーザの自由投稿であり，内容語の重複のある文が多数確認されることから，学習データにおける語彙の重複がこの現象の一つの要因と考えられる．語彙の重複については，学習データにおいて語彙・概念の重複を認める限度についての検討が未だなされていないため，また本論文は一般的なテキストへの検出手法の適用を試みることを目的としているため，今後の課題とする．

さらに，ブログ文章以外の評価データを含む多様なデータセットの構築による，多角的な検出性能評価も必要である．ただし，新しいデータセットにどの程度の語彙のばらつきが見られるかの推計の必要があるが，語彙の重複に対する検討と同様の理由より今後の課題となる．

加えて，ルールベース素性にも改善の余地がある．素性(c)及び(d)は子音間のデータに基づく共起頻度の比に基づくが，母音を用いた指標も提唱されている[24]．子音及び母音の音韻類似度を同時に評価する場合，両者の重みの調整手法，及び種・変形表現のアライメント手法を構築する必要がある．手法としては，子音類似度では母音共通部分を，母音類似度では子音共通部分を基点として種・変形表現の検出を行うことが挙げられる．この場合は共通性の確定しない音素列の存在も考慮しなければならず，多量の語彙からの推定が必要となる可能性がある．

ここからは，**1** 章で述べた仮説の妥当性についての結論を検討する．

(1) 駄洒落の検出に対し，分類器に与える素性として語彙素性の適性がある．

この仮説については，**6.3** の実験結果より語彙素性の高い有効性が確認された．次に，

(2) 読み仮名の完全一致，音韻類似度による類似部分検出又は促音・撥音・長音の付加/脱落を考慮した音韻的類似部分検出に基づくルールベース素性の付加により，検出性能が向上する．

(3) 仮説(1)，(2)で述べた全ての素性を用いた場合，検出性能が最大化する．

仮説(3)については，**6.3** の結果において，素性セット $F_8 \rightarrow F_{15}$ の組に 0.037 ポイントの F 値の有意な差（$p < 0.01$）が存在するため，支持される．

一方，(2)については，**6.2** の結果から，3 つのルールベース素性のうち，(b)完全一致素性が相対的に強力である結果が示された．また，(c)ないし(d)の音韻類似度に基づく素性を付加した場合に性能が向上しなかった条件が存在する．例えば，$F_8 \rightarrow F_{10}$，$F_9 \rightarrow F_{11}$，$F_{12} \rightarrow F_{14}$ のそれぞれの素性セットの組では，F 値の有意差がみられなかった．一部の結果はこのように，(b)，(c)，(d)各ルールに改善の余地のあることを示し，従って仮説(2)は全ての条件では成立しないことが判明した．

8. おわりに

本論文では，SVM による教師あり学習に基づいた駄洒落を含む文の検出において，語彙素性に加え，音韻類似度を用いた類似部分の検出及び促撥長音の挿入・脱落を考慮する手法を提案した．検出性能評価実験において，語彙素性の有効性，ルールベース素性の有効性及びそれぞれ検出成功事例を考察において確認し，駄洒落を含まない文の音韻的な性質に並んで提案手法の総合的な有効性が確認された．また，語彙素性の利用により，提案手法が併置型駄洒落に加え重畳型駄洒落に対する一定の検出性能を得ることが示された．ただし，結果の考察においてルールベース素性における改善の余地が指摘され，また語彙素性の学習データへの依存性も **7.3** の分析において示唆された．

今後の方針としては，**7** 章で挙げられた問題点の改善に加え，過去研究でも触れられている駄洒落の面白さ（適切性）を文の内容語から推定することのできる手法の開発が考えられる．有効性の評価方法として，**5** 章で述べた手法との比較が妥当である．そのためには，**2.1** で述べた重畳型・併置型，perfect・imperfect の駄洒落の類型の正確な分類が必要になる．これは多クラス分類になるため，新たに適切な素性群を設定し学習用のデータセットを準備する必要がある．

1 章において，駄洒落文の意味理解の前段階として駄洒落を含む文の精度の高い検出が必要であることを述べた．駄洒落文の意味理解の実際に関しては，駄洒落文の理解を語義曖昧性解消と捉えた研究がある．英

語を対象にした研究ではMillerらの手法［25］，日本語対象では前述のYokogawa［14］の手法があるが，いずれも**2**章で述べた駄洒落の定義における一部の類型にしか対応していない．具体的には，Yokogawaの手法は形態素境界や語音の変化を伴うimperfectな駄洒落に対象を限定している．本論文の手法を応用した意味理解手法をperfectな併置型駄洒落にも適用すれば，自然言語意味理解の対象範囲がより拡大すると考えられる．

参 考 文 献

［1］ 山田浩平，朝野聡，物部博文，“対人葛藤場面での断り行動に対する自己効力感と社会的スキル及びアサーティブな態度，ユーモア対処との関わり”，学校保健研究 Vol. 54, No. 3, pp. 203－210, 2012.

［2］ 塚脇涼太，深田博己，樋口匡貴，“ユーモア表出が表出者自身の不安及び抑うつに及ぼす影響過程”，実験社会心理学研究, Vol. 51, No. 1, pp. 43－51, 2011.

［3］ 椙本知子，山崎勝之，“対人ストレスユーモアコーピングが敵意，意識的防衛性と抑うつに及ぼす影響”，心理学研究，Vol. 82, No. 1, pp. 9－15, 2011.

［4］ Pawel Dybala, Michal Ptaszynski, Jacek Maciejewski, Mizuki Takahashi, Rafal Rzepka, and Kenji Araki. Multiagent system for joke generation: Humor and emotions combined in human-agent conversation. Journal of Ambient Intelligence and Smart Environments, Vol. 2, No. 1, pp. 31－48, 2012.

［5］ 宮澤幸希，常世徹，桝井祐介，松尾智信，菊池英明，“音声対話システムにおける継続欲求の高いインタラクションの要因”，電子情報通信学会論文誌 A, Vol. 95, No. 1, pp. 27－36, 2012.

［6］ Shohei Fujikura, Yoshito Ogawa, and Hideaki Kikuchi. “Humor Utterance Generation for Non-task-oriented Dialogue Systems.” Proceedings of the 3 rd International Conference on Human-Agent Interaction. ACM, pp. 171－173, 2015.

［7］ 吉田裕介，萩原将文，“複数の言語資源を用いたユーモアを含む対話システム．”知能と情報：日本知能情報ファジィ学会誌, Vol. 26, No. 2, pp. 627－636, 2014.

［8］ 松井辰哉，萩原将文．“発話極性を考慮したユーモアを有する非タスク指向型対話システム．”日本感性工学会論文誌，Vol. 14, No. 1, pp. 9－16, 2015.

［9］ 滝澤修，“記述された「併置型駄洒落」の音素上の性質”，自然言語処理，Vol. 2, No. 2, pp. 3－22, 1995.

［10］ Shigeto Kawahara. Probing knowledge of similarity through puns. Proceedings of Sophia University Linguistic Society 23. pp. 110－137, 2009.

［11］ 永田靖，サンプルサイズの決め方，朝倉書店, 2003.

［12］ 木村洋二，笑いを科学するユーモアサイエンスへの招待，新曜社, 2010.

［13］ Gary Zalewski. Laugh detector and system and method for tracking an emotional response to a media presentation, US Patent US 20090195392, 2009.

［14］ Toshihiko Yokogawa. Japanese Pun Analyzer Using Articulation Similarities. Proceedings of the 2002 IEEE International Conference on Fuzzy Systems, pp. 1114－1119, 2002.

［15］ 天谷祐介，ラファウ ジェプカ，荒木健治，“単語間類似度を用いた物語ユーモア認識手法の性能評価”，人工知能学会第2種研究会ことば工学研究会資料，pp. 63－69, 2013.

［16］ 北垣郁雄，“おかしみの誘発モデルに基づいた‘笑うコンピュータ’の開発事例”，知能と情報：日本知能情報ファジィ学会誌, Vol. 15. No. 5, pp. 577－583, 2003.

［17］ 山根宏彰，萩原将文，笑いを生むことわざすかしの自動生成システム”, 知能と情報：日本知能情報ファジィ学会誌，Vol 24, No. 2, pp. 671－679, 2012.

［18］ Michal Ptaszynski, Pawel Dybala, Rafal Rzepka, Kenji Araki and Yoshio Momouchi. YACIS: A Five-Billion-Word Corpus of Japanese Blogs Fully Annotated with Syntactic and Affective Information. Proc. of The AISB/IACAP World Congress in Honour of Alan Turing, workshop of LaCATODA, pp. 40－49, 2012.

［19］ Samuel S. Shapiro, and Martin B. Wilk. An Analysis of Variance Test for Normality（Complete Samples）. Biometrika, Vol. 52, No. 3/4. pp. 591－611, 1965.

［20］ Corinna Cortes, Vladimir Vapnik. Support-vector networks. Machine Learning, vol.20, no.3. pp. 273－297, 1995.

［21］ Shigeto Kawahara and Kazuko Shinohara. The role of psychoacoustic similarity in Japanese puns: A corpus study. Journal of Linguistics, Vol. 45, No. 01 pp. 111－138, 2009.

［22］ 注連隆夫，土屋雅稔，松吉俊，宇津呂武仁，佐藤理史，“日本語機能表現の自動検出と統計的係り受け解析への応用．”自然言語処理Vol. 14, No. 5, pp. 167－197, 2007.

［23］ 葦原史敏，木村泰知，荒木健治，“地方議会会議録における節単位による議員の要望抽出．”電子情報通信学会論文誌 D，Vol. J 98－D, No. 11, pp. 1390－1401, 2015.

［24］ Shigeto Kawahara and Kazuko Shinohara. Calculating vocalic similarity through puns. Journal of the Phonetic Society of Japan. Vol. 13, pp. 101－110, 2009.

［25］ Tristan Miller and Iryna Gurevych. Automatic disambiguation of English puns. Proceedings of the 53 rd Annual Meeting of the Association for Computational Linguistics and the 7 th International Joint Conference on Natural Language Processing. pp. 719－729, 2015.

（2015年12月15日　受付）
（2016年 6 月30日　採録）

［問い合わせ先］
〒060-0814　札幌市北区北14条西9丁目
北海道大学大学院情報科学研究科言語メディア学研究室
谷津　元樹
TEL：011-706-7389
FAX：011-709-6277
E-mail : motoki.yatsu@ist.hokudai.ac.jp

著 者 紹 介



谷津 元樹［非会員］

2010年北海道大学文学部人文科学科卒業. 2012年同大学大学院情報科学研究科修士課程修了. 現在，同博士後期課程在学中. 自然言語処理，特に音声対話処理及びユーモア理解の研究に従事. 言語処理学会，IEEE各学生会員.



荒木 健治［正会員］

1982年北海道大学工学部電子工学科卒業. 1988年同大学大学院博士課程修了. 工学博士. 同年，北海学園大学工学部電子情報工学科助手. 1989年同講師. 1991年同助教授. 1998年同教授. 1998年北海道大学大学院工学研究科電子情報工学専攻助教授. 2002年同教授. 現在北海道大学大学院情報科学研究科メディアネットワーク専攻教授. 自然言語処理，特に，音声対話処理，機械翻訳，ユーモア処理などの研究に従事. 日本知能情報ファジィ学会，電子情報通信学会，情報処理学会，人工知能学会，言語処理学会，日本認知科学会，ACL, IEEE, AAAI各会員.

A Method for Detecting Japanese Puns using a Support Vector Machine and Consonantal Phonetic Similar Features

by

Motoki YATSU and Kenji ARAKI

Abstract :

In recent years, there have been growing needs for computers which comprehend what is meant in humorous texts. However, we have few examples of research that have tried to detect puns from a large corpora of spoken language. A sampling survey of typology and component ratio analysis in Japanese puns revealed that the type of Japanese pun that had the largest proportion was a pun type with two sound sequences, whose consonants are phonetically close to each other in the same sentence which includes the pun. Based on this finding, we constructed three rules to detect pairs of phonetically similar sequences, and used them as features for SVM. Using these features in addition to bag-of-words features, an evaluation experiment confirmed the effectiveness of adding the three phonetic similarity features to the baseline classifier.

Keywords : humor, Japanese puns, phonetic similarity, textual utterance classification

Contact Address : **Motoki YATSU**

Language Media Laboratory, Graduate School of Information Science and Technology, Hokkaido University
Kita-ku, Kita 14, Nishi 9, 060-0814, Sapporo, Japan

Phone : 011-706-7389

Fax : 011-709-6277

E-mail : motoki.yatsu@ist.hokudai.ac.jp