雑談対話システムにおけるLSTMを用いた駄洒落による対話破綻回避の有効性

Effectiveness of Japanese Pun to Avoid Dialogue Breakdown using LSTM on Chat Dialogue System

徐　云帆[1]　　荒木　健治[1]

Yunfan Xu[1]　　Kenji Araki[1]

[1] 北海道大学大学院　情報科学研究科

[1] Graduate School of Information Science and Technology, Hokkaido University

Abstract:. This paper describes a method about avoiding dialogue breakdown using Japanese pun by a recurrent neural network with LSTM(Long short-term memory) cells. We confirm that there are some restriction about avoiding dialogue breakdown by Japanese pun with a preliminary experiment. In order to find out the dialogue breakdown which can be avoided by Japanese pun, we build a corpus about it by an annotation experiment. Then we build a LSTM model to detect the dialogue breakdown which can be avoided. The accuracy of the model is over 50%. And we improve the way of Japanese pun topic selection. According to the result of impression evaluation experiment, it get a higher score than the dialogue system without breakdown avoiding. Therefore, we confirm the effectiveness of our dialogue breakdown avoiding system.

1. はじめに

雑談対話中では多様な話題を扱う必要があるため，雑談対話システムは適切な応答を返すことに様々な困難を抱える．それゆえ，雑談対話システムは未だに多くの対話破綻が存在する．このような対話破綻を回避することにより雑談対話を高精度化することが可能になる．

日常生活では，人間が言いづらい時や言い間違えた場合，よく笑い話や駄洒落などユーモアの表現を使ってミスを誤魔化す．ユーモアの効果から分析すると，その理由は，ユーモアが情緒的な安静や安定にとって有益なものであり，様々なストレスの低減や不快な刺激に対する対処性を高めるためである[1]．会話に破綻が発生する場合，話者にはストレスや不快な感情が生じるので, ユーモアの表現により，このような感情を和らげることができると考えられる．また，ユーモアの生起要因から分析すると，対話破綻が起こる原因はシステム発話とユーザの期待の乖離である．ユーモアの研究において，ユーモアの生起には「不適合理論」がある．大部分のユーモア研究者が，ユーモアの生起に不適合の認知が不可欠であるという点で合意を達成しつつある[2]．ユーモアの研究者は期待と実際のズレからユーモアが生まれると考えている．このように，構造上では，ユーモアと対話破綻には共通点がある．その効果及び構造からユーモアは対話破綻を回避することに有効であると考えられるので，ユーモアを用いることにより対話破綻を回避できる可能性がある．

本研究では対話破綻をユーモアにより回避するという立場から破綻がある応答文を駄洒落ユーモアで置き換えるという破綻を回避する手法を提案し，対話破綻回避システムを構築した．また，印象評価実験により提案システムの有効性を確認した．

対話破綻について，破綻検出チャレンジ[3]が開催されており，最近では機械学習手法の改善やディープラーニングを用いることにより，検出精度が向上している．しかし，対話破綻を検出した後の処理として破綻回避に関する研究は未だに少ない．雑談対話システムに対する駄洒落の応用について，谷津ら[3]は駄洒落ユーモアの生成及び認識の双方を適切な頻度において行う統合型対話システムを開発しているが，そのシステムにおける駄洒落生成の判断は特定のトピックへの関連性により行われていて，対

話破綻の問題点については扱っていない．

本稿では，先行実験により駄洒落を用いて回避可能な対話破綻を考察し，それに関するアノテーションを行い，コーパスを構築した．次に，LSTM を用いた回避可能破綻推定モデルを作成し，構築したコーパスを学習することにより，回避可能破綻箇所の推定を行う．最後に，印象評価実験を実施し，提案システムの有効性を確認した結果について述べる．

2. 提案手法

提案するシステムは三つの部分から構成される．これらの三つの部分はそれぞれベースとなる対話システム，破綻検出モジュール，駄洒落生成モジュールである．

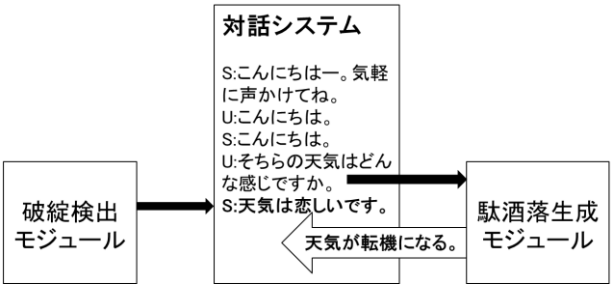


図 1　提案システムの概要

具体的な破綻回避の流れを図 1 に示す．まず，破綻検出モジュールを用いて対話システムの出力に対し破綻検出を行う，破綻を検出した場合，システム発話を出力する前に破綻文の出力を取り消し，その直前のユーザ発話を駄洒落生成モジュールに入力する．その直前のユーザ発話から，駄洒落生成モジュールにより，適切な駄洒落文を生成し，破綻文の代わりに対話システムの出力とする．

3. 予備実験

対話破綻回避に駄洒落を利用することの有効性と回避可能性に影響する要因を考察するために，先行実験を行った．

3.1 実験概要

破綻検出システムを用いて破綻検出を行い，破綻がある箇所の直前のユーザ発話を駄洒落生成システムに入力する．生成された結果と元の破綻文を比較し，人手による評価を行った．

3.2 実験方法

実験に使用したデータは文献[4]の破綻検出チャレンジの評価データであり，NTT ドコモが公開している雑談対話 API を用いて収集された対話データである．破綻検出手法は久保ら[5]の Neural Conversational Model を用いた深層学習に基づく手法を基に開発した．この手法は対話破綻チャレンジ 2 において比較的 F 値が高い手法である．駄洒落生成には図 1 で示したように(1)入力文の改変（漫才のボケ形式）(2)なぞなぞ(3)駄洒落データベースのいずれかのタイプの駄洒落を生成するシステム[6]を用いる．

破綻検出モジュールにより検出された 376 文の破綻文からランダムに 50 文を抽出し，それに対応するユーザ発話を駄洒落生成システムに入力する．生成した駄洒落文と元の破綻文を 1 点(悪い)から 5 点(良い)の五段階で人手により評価した．評価者は 20 代理系男性大学院生 6 名である．

(1)入力文の改変
入力：現代語訳されていれば簡単ですよ，内容がわかりにくいことはありますが.
出力：「最近，現代語訳されていれば簡単ですよ，内容がわかりにくいことはありますがっていう感じでしたよ」「俺の場合，現代語訳されていれば天丼ですよ，ナチョスがわかりにくいことはありますがって感じだけど」「寒い！」
(2)なぞなぞ
入力：海外の女性はキャリアウーマンってイメージあるね.
出力：「海外は海外だけど，食べれる海外はな〜んだ？」「何？」「海貝」
(3)駄洒落データベース
入力：何事は行っていませんが，明日の予定を考えています.
出力：予定と言えば，今日の予定は，飲み会のみかいって言いたくなるよね.

図 1　駄洒落生成の例

3.3 実験結果

表 1　評価実験の結果

	平均値	平均二乗誤差
破綻文	2.023	0.528
駄洒落文	**2.040**	**0.208**

評価実験の結果を表 1 に示す．表 1 で駄洒落文は平均値で 0.017 ポイント破綻文を上回った．破綻文の平均二乗誤差が高い原因は破綻検出モジュールの検出精度が 40%とまだ不十分なため，正しい文を誤って破綻として検出したことが評価に影響を及ぼしたためと考えられる．

表 2　駄洒落のタイプごとの実験結果

	文数	平均値	平均二乗誤差
(1)入力文改変	2	1.833	0.0
(2)なぞなぞ	21	2.024	0.212
(3)データベース	27	**2.068**	0.217

表 2 に示すように，駄洒落データベースの駄洒落が最も良い結果となった．(1)入力文改変と(2)なぞなぞの評価が低い原因は駄洒落自体が会話文のため，一つの発話としては違和感があったためである．

3.4 考察

実験結果から，評価が 2.5 点以上の文は 11 文であった．その中の 1 つの例を以下に示す．

評価が 2.5 点以上の例
U:何事は行っていませんが，明日の予定を考えています．
S:何事を決めてますか？(破綻文)
⇒S:予定と言えば，今日の予定は，飲み会のみかいって言いたくなるよね．(駄洒落文)

評価が 2.5 点以上の文全体から見ると，発話文が平叙文の場合が多く，駄洒落生成システムのお題になる単語の多数は普通名詞である．

評価が 2 点以下の例は以下のように示している．

評価が 2 点以下の例
例 1
U:ゼロさんはどこから来ましたか？
S:何かペットを飼ってますか？(破綻文)
⇒S:さんと言えば，飯田さんはもういいだよ！って言いたくなるよね．(駄洒落文)
例 2
U:ヨーロッパは旅費がかかりますものね．オリンピックを契機に，東京にも観光客が増えると思いますか？
S:レベルが高いですね(破綻文)
⇒S:「東京は東京だけど，食べれる東京はな～んだ？」「何？」「豆乳」(駄洒落文)

評価の悪い例の共通点を見ると，上記の例のように，疑問文に対する駄洒落は有効ではないということである．ユーザはシステムに具体的な答えを求めている場合，駄洒落で誤魔化すことはできないと考えられる．また，例 1 のように，「さん」「そう」という特殊な単語がお題になる場合，ユーザの発話文に関係が薄いため不適切な駄洒落が多い．また，例 2 のように，ユーザ発話に具体的な表現が多い場合も，駄洒落はユーザの発話との雰囲気が大きく異なるため，不適切になることが多い．

実験結果を見ると，評価の良い例と評価の悪い例それぞれ特徴がある．駄洒落を用いた対話破綻回避が有効になる対象文は限定的であり，影響する要因は多様である．また，駄洒落生成のお題になる単語は生成される駄洒落の適切さに関わる．対話破綻回避の精度を上げるため，回避可能な破綻を検出する必要があり，お題の抽出方法も注意しなければならない．そこで，本稿では，機械学習により駄洒落を用いた回避可能な破綻を検出し，特定の対話破綻を駄洒落生成モジュールによりリカバリする手法を提案する．そのために学習に必要となるコーパスを作成した結果と回避可能破綻推定モデルについては，5 章以降に述べる．お題抽出方法に関しては 4 章で述べる．

4. お題抽出手法

より適切な駄洒落文を生成するために，予備実験の結果を踏まえて，お題抽出のルールを設計した．評価の良い例と悪い例の特徴から，お題になる単語が普通名詞の場合，高評価になることが多く，単語単体に意味が持たない代名詞などがお題になる場合，駄洒落文は発話文に関係が薄いことが多いため低評価になることが多いことが明らかになった．

これらの傾向から，お題になる単語の抽出に優先度を設けた，駄洒落生成の対象文である破綻文直前のユーザ発話U_nに対し形態素解析ツール MeCab[7]により形態素解析を行う．発話文に一般名詞・固有名詞が含まれる場合，その中からランダムに一つの単語を抽出し，駄洒落生成のお題としてシステムに入力し，駄洒落を生成する．含まれない場合はサ変名詞・動詞・形容動詞・形容詞から一語を取り出し，システムに入力し，駄洒落生成を行う．いずれも含まれない場合の発話は「そうですか」などの文が多

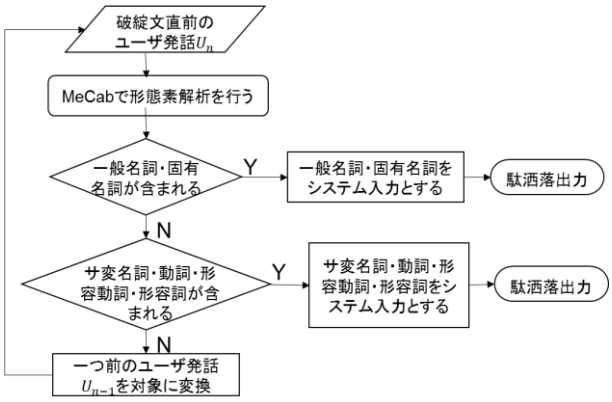


図 2　お題抽出手法

いので，発話文の話題はその前の文に含まれると判断し，更に一つ前のユーザ発話U_{n-1}をお題抽出の対象に変更する．

5. 回避可能破綻コーパス

破綻ラベル付きの雑談対話コーパス[8]に基づき，対話破綻の各箇所の駄洒落使用の妥当性を評価しアノテーションを行い，コーパスを作成した．

5.1 アノテーション方法

破綻ラベルが付いた破綻文直前のユーザ発話に対し駄洒落生成を行い，生成した駄洒落を参考として，文脈から駄洒落の使用が自然か否かを判断する．

アノテーションに使用した駄洒落生成システムは，新たな駄洒落データベースにより作成した駄洒落生成システム[9]である．駄洒落生成の際のお題の抽出手法は 4 章で述べた手法を使用した．

5.2 予備的アノテーション

5.1 で述べたアノテーション方法では，アノテータ間の個人差や生成した駄洒落の質がアノテーションに影響すると考えられる．これらの要素がもたらす影響を考察するため，予備的アノテーションを行った．

5.2.1 実験条件

対話破綻コーパス中からランダムに 20 対話を抽出し，5.1 で述べた方法により駄洒落を生成し，応答文に付与する．前半の 10 対話は個人差の評価に使用するため同じ駄洒落を付与する．後半の 10 対話は駄洒落の質による影響を考察するため，3 種類のアンケートに付与する駄洒落を同じお題の異なる駄洒落文とした． 3 種類のアンケートを用いて 7 人のアノテータ(理系大学院生男性 6 名女性 1 名)により○(駄洒落により対話破綻回避可能)と×(駄洒落により破綻回避不能)の二値でアノテーションを行った．

5.2.2 実験結果及び考察

アノテータの一致度を考察するためにフライスの κ 値を算出した．前半の 10 対話の結果から算出したフライスの κ 値は 0.17 で，後半のフライスの κ 値は 0.24 である．

後半は前半より一致度が高いため，駄洒落の質による評価への影響は少ないと考えられる．全体のフライスの κ 値は 0.2 程度なので，「ランダムではないが，おおむね一致」ということである[10].

また，予備的アノテーション時のアノテータのコメントにより「話題遷移のところの駄洒落の効果が高い」「会話の冒頭に駄洒落を使うのは不自然」「疑問，要求の後に駄洒落を使うのは不自然」などの意見があった．

5.3 コーパス作成

今回収集したコーパスは合計 350 対話である．その中で破綻文数は 799 文で，アノテーションにより決定された回避可能な破綻文数は 259 文である．

6. 回避可能破綻推定モデル

回避可能破綻推定モデルの構築には，RNN の一種である LSTM(Long short-term memory)[11]を使用した．LSTM は時系列データに対し有効性の高いツールで，近年では LSTM を基に構築した対話システムが優れた性能を示している．回避可能破綻の判断は対話文の文脈から判断されるため，LSTM の有効性が期待できると考えられる．

6.1 LSTM の概要

図 3 に LSTM の構成を示す．

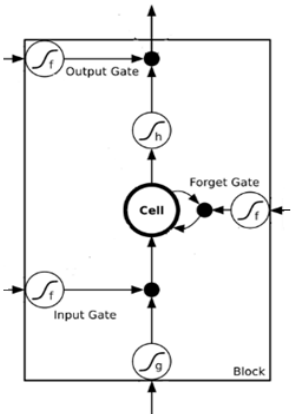


図 3　LSTM の構成

x_tとy_tは時刻 t における入力単語と出力単語の分散表現，LSTM は以下の式(1)～(6)で表される．

$$i_t = \sigma(W_{ix}x_t + W_{im}m_{t-1} + W_{ic}c_{t-1} + b_1) \quad (1)$$

$$f_t = \sigma(W_{fx}x_t + W_{fm}m_{t-1} + W_{fc}c_{t-1} + b_f) \quad (2)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g(W_{cx}x_t + W_{cm}m_{t-1} + b_c) \quad (3)$$

$$o_t = \sigma(W_{ox}x_t + W_{om}m_{t-1} + W_{oc}c_t + b_o) \quad (4)$$

$$m_t = o_t \odot h(c_t) \quad (5)$$

$$y_t = \phi(W_{ym}m_t + b_y) \quad (6)$$

式中でσはシグモイド関数であり，i_t f_t o_tはそれぞれ入力ゲート，忘却ゲート，出力ゲート，c_tは Constant Error Carousel(cec)である．g と h は入力と出力の活性化関数でøはネットワーク出力の活性化関数である．本実験では softmax を使用する．

6.2 学習設定

回避可能破綻の推定は対話の文脈を参考にするため，破綻文直前の発話文だけでなく，更に前の対話文も含めて学習する必要があると考えられる．一方，学習範囲の拡大に伴うノイズの影響も大きくなる恐れがある．適切な学習範囲を確定するために，入力が異なる 3 種類の学習手法を使用して学習を行い，それぞれ結果を考察した．図 4 に手法 2 の処理の流れを示す．

手法１：破綻文直前の発話文$\mathbf{U}_n$だけを学習の入力とする
手法２：破綻文直前の発話文$\mathbf{U}_n$+更に一つ前の発話文U_{n-1}+システム発話S_{n-1}を学習する
手法３：$\mathbf{U}_n$　S_{n-1} U_{n-1} S_{n-2} U_{n-2}を学習する

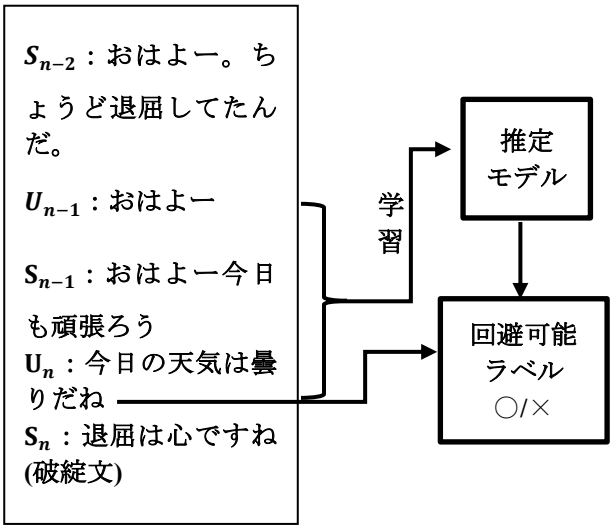


図 4　回避可能破綻推定の流れ(手法 2)

形態素解析には MeCab を使用した．単語分散表現への変換は word2vec を用いて日本語 wikipedia を学習させたもので，次元数は 300 である．学習データは 5 章で述べた 350 対話からランダムに取り出した 300 対話であり，評価データは残りの 50 対話である．

6.3 推定結果

表 3 クローズテストの推定精度

	精度
手法 1	0.676
手法 2	**0.732**
手法 3	**0.732**

バッチサイズを 64 に設定した際に最高精度が得られた．特に手法 2 と手法 3 では，クローズドデータにおける推定精度は 0.732 という高い値が得られた．

オープンデータにおける推定結果を表 4 に示す．

表 4　オープンテストの推定精度
（出力ラベルが 0.5 以上を正解とみなした場合）

	精度	再現率	F 値
手法 1	0.500	0.103	0.171
手法 2	0.500	0.241	**0.325**
手法 3	0.500	0.241	**0.325**

オープンデータにおいて，モデルの推定精度は 3 種類とも 0.500 で，再現率の最高値は 0.241 で相当低い数値である．その原因は学習データのデータ量の不足と考えられる．

モデルの出力は 0 - 1 の値なので 0.5 以上の出力は 1(回避可能)と判断されるが，出力を見ると，0.5 に近い数値が多いため，閾値を 0.4 に設定する場合結果がよくなると考えられる．表 5 に 0.4 に設定する場合の結果を示す．

表 5　オープンテストの推定精度
（出力ラベル 0.4 以上が正解とみなす場合）

	精度	再現率	F 値
手法 1	0.480	0.414	0.445
手法 2	0.464	0.448	**0.456**
手法 3	0.462	0.414	0.437

表 5 で手法 2 の F 値は 0.456 と一番高い数値となった．

オープンテストの結果がクローズドテストより下回った原因は，評価データに使うアノテーションデータが 1 人のアノテータが評価した結果のため，個人差による影響が大きいと考えられる．また，モデルの学習に使われるデータ量が少ないため，未知のデータに対する推定の再現率は比較的低い値になりやすいと考えられる．

7. 印象評価実験

対話破綻回避システムの有効性を検証するため，印象評価実験を行った．

7.1 実験方法

対話破綻コーパスからアノテーションを行っていない対話文をランダムに 100 対話取り出し，回避可能破綻推定モデルにより回避可能な破綻を検出し，4 章で述べたお題抽出手法によりお題を抽出し駄洒落生成を行う，

評価者は 20 代日本人理系大学院生 5 名，基準は予備実験と同じ 1 点(悪い)から 5 点(良い)の五段階評価であり，推定した回避可能な破綻文の数は 20 個である．

7.2 実験結果

表 6　印象評価実験結果

	平均値	平均二乗誤差
破綻文	2.023	0.528
駄洒落文 (ベースライン)	2.068	0.217
駄洒落文 (お題抽出＋回避推定)	**2.900**	**0.212**

表 6 に印象評価実験結果を示す．表 6 でベースラインというのはお題抽出の改善も回避推定も行っていない手法である．実験結果から見ると，お題抽出の改善と回避可能推定を行った駄洒落生成文はベースラインより 0.860 ポイント上回った．平均二乗誤差も最も優れている．これらの結果から提案手法の有効性が確認された．

7.3 考察

破綻回避の例

U:今日は傘が必要だね

S:傘は無事ですね(破綻文)⇒S:傘を貸さん(駄洒落文)

U:どこから来ましたか？

S:傘を壊しましたね(破綻文)

回避可能破綻推定モデルにより，前半の対話は駄洒落による破綻回避可能と推定され，生成された駄洒落文の評価は高い. 後半にも破綻文が出ているが，モデルは駄洒落による回避はできないと推定し，駄洒落による回避は行っていない．後半のユーザ発話はシステムに答えを求めているので，確かに駄洒落文で対応するのは不適切である．これらの例から，提案手法の有効性が確認された．

一方，評価の結果が悪い例には推定失敗の文以外に，駄洒落内容の不適切による影響もある．適切なお題だけでなく，出力する駄洒落の内容に関しても今後検討する必要がある．

8. まとめと今後の課題

本稿では，駄洒落ユーモアにより対話破綻を回避する手法の有効性を考察し，それに関するコーパス構築について述べた．構築したコーパスを LSTM により作成したモデルで学習させた結果，回避可能推定の精度は 50%程度に達した．次に，推定モデル及びお題抽出手法を改善することにより，駄洒落により対話破綻の回避精度が大きく向上した．

今後の課題としては，システム発話をより自然にするため破綻回避に適切な駄洒落の表現手法を検討する必要がある．また，今回データ量が不足していたためモデルのオープンテストの精度はクローズドテストの精度を下回った．データ量を増やすことも今後の課題の一つである．

謝辞

本研究は科研費(基盤研究 (C)17K00294)の助成を受けたものである．

参考文献

[1] 石原俊一，“対人ストレスユーモアコーピングにおける心理学的健康への効果”[J]. 人間科学研究, 36: pp.67-77，2015.

[2] 伊藤 大幸，“ユーモアの生起過程における論理的不適合および構造的不適合の役割”, 認知科学, Vol.17(2), pp. 297-312，2010.

[3] 東中 竜一郎, 船越 孝太郎, 小林 優佳, 稲葉 通将, “対話破綻検出チャレンジ”, SIG-SLUD, Vol.5(02), pp. 27-32，2015.

[4] 谷津元樹，荒木健治，“話題遷移に適応した駄洒落ユーモア統合型対話システムの性能評価”，ことば工学研究会: 人工知能学会第 2 種研究会ことば工学研究会資料，Vol.52，pp.23-27，2016.

[5] 久保隆宏, 中山光樹“Neural Conversational Model を用いた対話と破綻の同時学習”. SIG-SLUD, Vol.5(02), pp.94-97，2016.

[6] Jonas Sjobergh, Kenji Araki, “Evaluation of a Humor Generation System by Real World Application with ￥500,000 to Win. In Proceedings of the Linguistic And Cognitive Approaches To Dialog Agents Symposium”, AISB 2010 convention, pp.59-64, 2010.

[7] Taku Kudo, Kaoru Yamamoto, Yuji Mat- sumoto: Applying Conditional Random Fields to Japanese Morphological Analysis, Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP-2004), pp.230-237, 2004

[8] 東中竜一郎，船越孝太郎，荒木雅弘，塚原裕史，小林優佳，水上雅博，“テキストチャットを用いた雑談対話コーパスの構築と対話破綻の分析”, 自然言語処理, Vol.23(1)，pp.59-86，2016.

[9] 荒木健治，“駄洒落データベースを用いた駄洒落生成システムの性能評価”, 人工知能学会第 2 種研究会:ことば工学研究会資料，SIG-LSE-B Vol.703-8，pp.39-48，2018.

[10] Landis, J. R., Koch, G. G, “The measurement of observer agreement for categorical data. Biometrics”, pp.159-174, 1977.

[11] Hochreiter S, Schmidhuber J. “Long short-term memory[J]”. Neural computation, 9(8), pp. 1735-1780, 1997.