単語分散表現を用いた Earth Mover’s Distance と 文長の違いに基づく類似度による対訳文の自動抽出

田上 諒† 越前谷 博† 荒木 健治‡

† 北海学園大学大学院工学研究科 〒064-0526 北海道札幌市中央区南 26 条西 11 丁目 1-1
‡ 北海道大学大学院情報科学研究科 〒060-0814 北海道札幌市北区北 14 条西 9 丁目
E-mail: † 6717101r@hgu.jp, echi@lst.hokkai-s-u.ac.jp, ‡ araki@ist.hokudai.ac.jp

あらまし 本報告では，対訳辞書などの高品質な対訳知識を用いることなく，コンパラブルコーパスから対訳文を自動抽出する手法を提案する．提案手法では，単語分散表現を用いて翻訳行列と類似度計算を行うことで対訳文を抽出する．その際，類似度計算には Earth Mover’s Distance を用いる．更に，提案手法では文長の違いを重みとして類似度に用いることで抽出精度の向上を図っている．ニュース記事のコンパラブルコーパスを用いた性能評価実験の結果，全記事の平均の F 値はベースラインで 0.13，EMD のみのシステムと提案手法にける文長を考慮しない場合では共に 0.42，文長を考慮した場合は 0.49 となった．これらの結果から，文長を考慮した提案手法の有効性が確認された．

キーワード 対訳文，自動抽出, word2vec, Earth Mover’s Distance，文長

Automatic Extraction of Bilingual Sentences by Similarity based on Earth Mover's Distance using Word Embeddings and Difference of Sentence Length

Ryo TANOUE† Hiroshi ECHIZEN’YA† and Kenji ARAKI‡

† Graduate School of Engineering, Hokkai-Gakuen University,1-1 Minami 26, Nishi 11,Chuo-ku,Sapporo-shi,Hokkaido 064-0526 Japan
‡ Graduate School of Information Science and Technology, Hokkaido University, Kita 14, Nishi 9,Kita-ku,Sapporo-shi,Hokkaido 060-0814 Japan
E-mail: † 6717101r@hgu.jp, echi@lst.hokkai-s-u.ac.jp, ‡ araki@ist.hokudai.ac.jp

Abstract In this paper, we propose new method to automatically extract bilingual sentences from comparable corpus without high quality bilingual knowledge such as bilingual dictionary. In our proposed method, the bilingual sentences are extracted using the translation matrix and the similarity between two language sentences based on the word embeddings. In that case, the Earth Mover's Distance is used to calculate the similarity. Moreover, the weight based on the difference of lengths between two language sentences is applied to the similarity in EMD. The evaluational experiments using the news article's comparable corpus indicate that the average of F-measure of our proposed method was 0.49, those of our proposed method without the weight based on the sentence length and the method based only on EMD were respectively 0.42, and that of the method using sentence length which is the baseline was 0.13. Therefore, we confirmed the effectiveness of our proposed method using the weight based sentence length.

Keywords Bilingual Sentences, Automatic Extraction, word2vec, Earth Mover’s Distance, Sentence Length

1. はじめに

近年のニューラル機械翻訳[1]の進展に伴い，パラレルコーパスは重要な言語資源となっている．しかし，人手によるパラレルコーパスの作成には膨大な労力やコストを要する．その結果，得られる大規模なパラレルコーパスは特定の言語のものであったり，分野が限定されるといった問題が生じる．一方，Wikipedia やニュースサイトなどに代表されるコンパラブルコーパスについては高品質かつ多言語のものが得られるようになっている．このような状況において我々は，コンパラブルコーパスより対訳文を自動抽出することは有効であると考えている．

対訳文を自動抽出するための研究は従来より盛んに行われており，翻訳辞書などの静的な対訳知識を利用する手法[2]や出現回数などの統計的な情報を利用する手法[3][4]などが挙げられる．しかし，静的な対訳知識を利用する手法では，未知語に対して対応が不十分となる問題がある．また，統計的な情報を利用した手法では，単語の意味の観点において十分とはいえない．

そこで，我々は高品質な対訳知識を用いることなく，単語の意味に基づく対訳文の自動抽出手法を提案した[5][6]．提案手法では異言語間の文同士の対応関係を単語の分散表現である word2vec[7]に基づく類似度により決定する．そのために，ある言語の単語の分散表現を翻訳行列[8]を用いて，他の言語の単語の分散表現にマッピングする．その結果，一つのベクトル空間において，異言語間の文間類似度を求めることができる．

その際，2 つの分布間の距離計算法である Earth Mover's Distance(EMD)[9]を用いる．EMD の利用により，単語の分散表現を特徴量とすることで単語の意味に基づいた文間類似度を得ることが可能となる[5]．また，単語間の距離計算においては，他言語のベクトル空間上にマッピングされた単語と最もコサイン距離が近い単語を求め，その単語の表層情報を近似単語として得る．そして，近似単語とマッピング先の言語文の単語が一致している場合と一致していない場合で距離式を変えることで，単語間類似度の精度向上を図っている．これは，word2vec における対義語の類似度が高くなるという問題に対処するためである．更に，重みとして用いる$tfidf$に対して，Wikipedia での出現記事の割合による機能語と内容語の差別化を行い，重み付けをすることで EMD の精度向上を図っている．

このようにして得られる類似度に基づいて，コンパラブルコーパスより対訳文を抽出する．具体的にはビームサーチ[10]を用いて，ある言語文に対応する他の言語文を一意に決定することで対訳文の候補を得る．対訳文の類似度が閾値以上であれば，コンパラブルコーパスからそれらの対訳文を正しい対訳文として抽出する．

本稿では，さらなる対訳文の抽出精度の向上を目的に EMD より得られた類似度に対して，2 つの言語文における文の長さの違いに基づく重みを適用する．これは，2 つの文間で文の長さが大きく異なる場合，異言語間であっても対応関係が存在しない可能性が高いと考えられるためである．このように，提案手法は統計的な情報を利用する手法に対して，単語の意味を考慮した手法となっている．更に，静的な対訳知識を利用する手法に対しては，最新の Wikipedia データに基づいて word2vec を用いて学習を行うことで，未知語にも柔軟に対応できるという利点が考えられる．

性能評価実験は，ニュースサイトに掲載されているコンパラブルコーパスに対して，提案手法を用いて対訳文を自動抽出し，全記事の F 値の平均を求めることにより行なった．その結果，ベースラインとして用いた文長に基づくシステム[11]，特徴量に単語の分散表現，重みに$tfidf$，距離式にコサイン距離のみを用いた EMD のシステム，提案手法に文長の違いを重みとして用いない手法との比較において，提案手法の F 値が最も高かった．これらの結果から，提案手法の有効性が確認された．

2. 提案手法

2.1. 概要

提案手法は文間類似度の計算と対訳文の抽出の 2 つより構成されている．図 1 に文間類似度の計算の処理概要を示す．

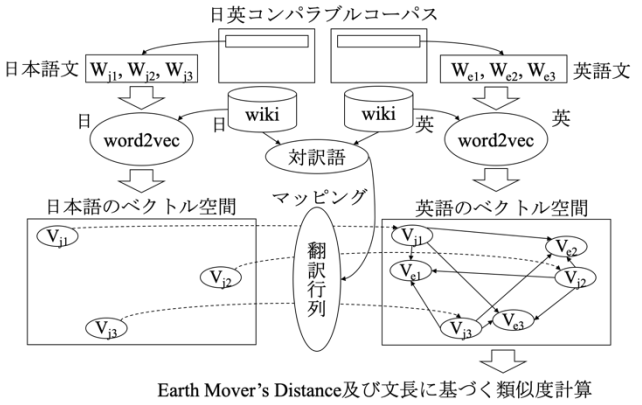


図 1 日英における文間類似度計算の処理概要

図 1 の文間類似度の計算では，初めに日英それぞれの Wikipedia ダンプデータを用いて word2vec によりモデルを生成する．そして，Wikipedia ダンプデータに含まれている出現頻度の高い対訳語ペア 1 万を google 翻訳[12]により生成し，翻訳行列を生成する．これらの処理が文間類似度を計算するための準備段階となる．

次に，日英コンパラブルコーパスに存在する全ての文を用いて文間類似度を計算する．具体的には日英コンパラブルコーパスより 1 文ずつ取り出し，word2vec により単語の分散表現を得る．日本語文中の単語の分散表現は翻訳行列に基づいて英語のベクトル空間にマッピングされる．そのうえで，英語のベクトル空間上にて EMD より文間類似度を求めるとともに，日本語文と英語文との長さの違いを重みとして用いることにより最終的な類似度を求める．

次いで，全ての文同士の文間類似度に基づいてビームサーチによる日英対訳文の候補を決定する．類似度の高い文のペアが日英対訳文の候補となるが，ビームサーチを用いることで類似度が上位の文ペアのみに着目し，効率的に対訳文の候補を一意に決定することが

できる．更に，これまで述べた処理を英日方向においても同様に行う．その結果，英日の対訳文の候補が得られる．このようにして，得られた日英と英日の対訳文の候補が一致した場合のみ閾値と比較する．その結果，閾値より類似度が高い場合には正しい対訳文としてコンパラブルコーパスより抽出する．類似度が閾値未満の場合には誤った対訳文とし，抽出は行わない．

2.2. 処理過程

2.2.1. 翻訳行列の生成

翻訳行列は，ある言語の単語の分散表現を他の言語の単語の分散表現に変換するために用いる．**図 1** で翻訳行列は，word2vec により得られた日本語の単語の分散表現を英語の単語の分散表現にマッピングする際に必要となる．その結果，2 つの異なるベクトル空間上に存在する単語の分散表現を 1 つのベクトル空間上に置くことにより，直接比較することが可能となる．

翻訳行列は，対応関係にある単語ペアの分散表現を用いて生成される[7]．以下の式(1)を用いて翻訳行列Wを得る．

$$W = \underset{W}{\operatorname{argmin}} \sum_{i=1}^{n} \|Wx_i - z_i\|^2 \tag{1}$$

式(1)のx_i，z_iはそれぞれ対訳語の単語の分散表現を示している．また，nは対訳語の数を示している．したがって，式(1)はWx_iとz_iの距離を最小にするようなWを求めることで，翻訳行列が得られることを示している．

本研究では，Wikipedia の出現頻度が上位の単語について google 翻訳を用いて訳語を得た後，その訳が Wikipedia に出現する場合，それを翻訳行列の学習に用いる単語ペアとした．この処理を対訳語ペアが 1 万になるまで繰り返した．

2.2.2. Earth Mover's Distance による類似度計算

ある言語の文の単語の分散表現を翻訳行列に基づき，他の言語の文の単語の分散表現へとマッピングした後，同じベクトル空間上に存在するマッピングされた文の単語とマッピング先に存在している文の単語の分散表現を用いて，EMD による文間類似度を求める．EMD は最適化問題の 1 つである輸送問題を基に定義されており，特徴量，重み，距離式の 3 つを定義することで 2 つの分布間の距離を求める．2 つの分布P, Qがそれぞれm個，n個の集合である時，2 つの分布を$P = \{(p_1, w_{p_1}), \cdots, (p_m, w_{p_m})\}$，$Q = \{(q_1, w_q), \cdots, (q_n, w_{q_n})\}$と表現する．$p_i$，$q_j$は特徴量，$w_{p_i}$，$w_{q_j}$はその特徴量に対する重みである．また，$p_i$と$q_j$の距離を$d_{ij}$とし，$p_i$から$q_j$の輸送量を$f_{ij}$とする．EMD は$f_{ij}$を最小化することで輸送問題の最適化を行うが，その際，4 つの制約条件を満たす必要がある．4 つの制約条件を以下に示す．

$$f_{ij} \geq 0 \qquad 1 \leq i \leq m, 1 \leq j \leq n \tag{2}$$

$$\sum_{j=1}^{n} f_{ij} \leq w_{p_i} \qquad 1 \leq i \leq n \tag{3}$$

$$\sum_{i=1}^{m} f_{ij} \leq w_{qj} \qquad 1 \leq j \leq m \tag{4}$$

$$\sum_{i=1}^{n}\sum_{j=1}^{n} f_{ij} = \min\left(\sum_{i=1}^{m} w_{p_i}, \sum_{j=1}^{n} w_{q_j}\right) \tag{5}$$

式(2)は輸送量f_{ij}が正の値をとる条件である．式(3)と式(4)はp_iやq_jの重みを超えて輸送できないという条件である．また，式(5)は輸送量の上限が分布P，Qのそれぞれの重みの総和の少ない方となる条件である．

輸送量$f_{ij}{}^*$を 4 つの制約条件を満たして最小化された輸送量とすると EMD は以下の式(6)より得られる．

$$EMD(P,Q) = \frac{\sum_{i=1}^{m}\sum_{j=1}^{n} d_{ij} f_{ij}{}^*}{\sum_{i=1}^{m}\sum_{j=1}^{n} f_{ij}{}^*} \tag{6}$$

また，重みである$tfidf$は文毎に総和が 1.0 となるように正規化する．また，得られるコサイン類似度は 0 から 1 までの範囲である．その結果，EMD により得られる距離は 0 から 1 の範囲となる．

本研究では，EMD を利用する際に，対訳文の抽出に向けての独自の工夫を行なっている．まず各単語の重みである$tfidf$に対して，機能語と内容語を差別化し，機能語に対しては負の重みを$tfidf$に付与する．式(7)に提案手法における重み$weight$の計算式を示す．

$$weight = \begin{cases} tfidf \times 0.5 & \left(\frac{df}{N} \geq x\right) \\ tfidf & \left(\frac{df}{N} < x\right) \end{cases} \tag{7}$$

式(7)のN，dfはそれぞれ，Wikipedia における全記事数と任意の単語の出現記事数を示す．また，xは機能語と判定する際の閾値を示す．したがって，閾値x以上の割合で全文書に出現する場合，それらの単語を機能語とみなし，予備実験により得られた 0.5 を負の重みとして掛ける．x未満の割合で出現する単語については$tfidf$の値をそのまま使用する．

更に，提案手法では距離dの計算において，近似単語を用いて表層的な情報を利用している．これは，word2vec を始めとする単語の分散表現では"man"と"woman"のような対義語のコサイン類似度が高くなる傾向が見られるためである．単語の分散表現が類似していても単語の表層が一致してない場合には，距離を相対的に大きくすることで対義語の問題に対処している．近似単語の取得方法を図 2 に示す．

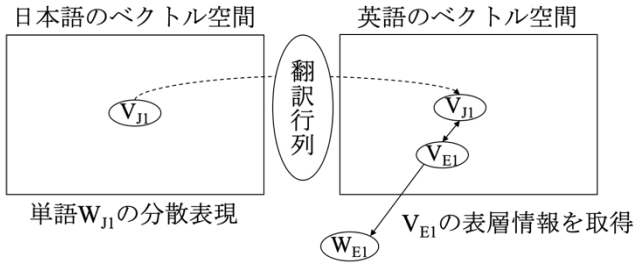


図 2 日英方向における近似単語の取得方法

図 2 では，**図 1** に示すように，任意の日本語の単語の分散表現 V_{J1} が翻訳行列に基づき，英語のベクトル空間にマッピングされている．ここで，英語のベクトル空間においてマッピングされた単語の分散表現 V_{J1} と近い分散表現を持つ英語の単語の分散表現 V_{E1} を取得する．この V_{E1} は word2vec モデルより W_{E1} を分散表現にしたものであるため，V_{E1} の表層情報として得られる．したがって，日本語文の全単語は何らかの英単語の近似単語を持つことになる．この近似単語を用いた距離計算式を式(8)に示す．

$$d = \begin{cases} 1.0 - cos(\text{近似単語と一致}) \\ 1.0 - cos^2(\text{近似単語と不一致}) \end{cases} \tag{8}$$

式(8)のcosは単語の分散表現同士のコサイン距離を示す．式(8)より日本語文の単語の分散表現に基づく近似単語と英語文の単語が一致する場合はcosを 1.0 から引いた値がdとなる．一致しない場合にはcos^2を 1.0 から引く．cosは 0 から 1 の値となるため，一致しない場合には負の重みとなりdが大きくなることを意味する．

提案手法ではこのような重み$weight$と距離dを用いて EMD を計算する．EMD の値は距離計算であるため，類似しているほど 0 に近く，類似していないほど 1 に近くなる．そこで提案手法では，類似しているほど 1 に近くなるように式(9)を用いて変換する．

$$simEMD = 1.0 - EMD \tag{9}$$

2.2.3. 文長の違いを考慮した重み付け

2 つの言語文の対応関係においては文の長さの違いを利用することは有効である[13]．そこで，本手法でも，文の長さの違いを類似度に反映する．具体的には以下の式(10)を **2.2.2** で得られた類似度に対する，ペナルティとして利用する[14]．

$$P_{len} = \begin{cases} e^{1-\frac{ls}{lt}} (l_s > l_t) \\ e^{1-\frac{lt}{ls}} (l_s \leq l_t) \end{cases} \tag{10}$$

式(10)のl_sはマッピング元の言語文の構成単語数，l_tはマッピング先の言語文の構成単語数である．

提案手法では式(10)のP_{len}を **2.2.2** で述べた**式(9)**の EMD に基づく類似度の重みとして利用する．即ち，以下の式(11)を用いて提案手法における最終的な類似度を得る．

$$P_EMD = simEMD \times P_{len} \tag{11}$$

2.3. 対訳文の決定

2.3.1. 対訳文の候補の決定

2.2.2 で述べた類似度計算に基づき，日英と英日の両方でコンパラブルコーパス中の全文に対して類似度を求める．その後，探索アルゴリズムであるビームサーチを用いて効率良く日英の対訳文の候補を一意に決定する．提案手法では，ビームサーチにより類似度の高い上位n個の文ペアに着目にして対訳文の候補を決定する．日英における対訳文の候補の決定の具体例を図 3 に示す．

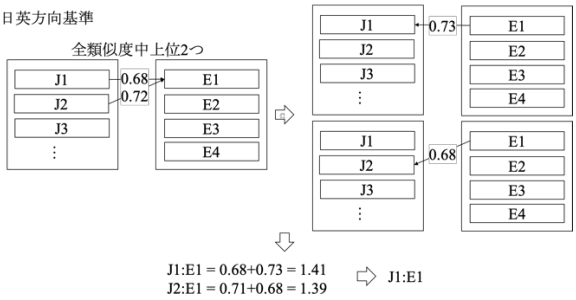


図 3 日英方向における対訳文の候補決定の具体例

図 3 では，上位 2 個に着目して日英対訳文の候補を決定している．初めに，日英方向の全文間の類似度で上位 2 つの文ペアを求める．その結果，J1 と J2 において E1 とのペアが得られる．次いで，E1 を基準とした J1 と J2 の類似度を求める．提案手法では，一方向でのみ高い類似度を持つ文ペアを選択するのではなく，両方向の類似度を利用し，両方の類似度の和の高い方を最終的な対訳文の候補とする．ここでは，J1 と E1 の文ペアの類似度の和が 1.41，J2 と E1 の文ペアの類似度の和が 1.39 となるため，J1 と E1 の文ペアが日英対訳文の候補となる．日英方向と英日方向で類似度が大きく異なることは稀であるが EMD の性質上，常に同じとは限らない．決定された対訳文の候補をコンパラブルコーパスから除外した上で，この処理を全ての日本文を基準とした文ペアが得られるまで繰り返す．

2.3.2. 正しい対訳文の決定

提案手法では **2.2.1** から **2.3.1** までの処理を一方向で行なった後，逆方向でも同様に行う．即ち，日英方向で対訳文の候補を決定し，更に，英日方向でも対訳文の候補を決定する．そして，両方向で一致する対訳文の候補を最終的な対訳文の候補として決定する．このようにして得られた対訳文の候補の類似度と閾値を比較する．対訳文の候補の類似度が閾値より大きい場合，正しい対訳文となる．また，類似度が閾値より小さい場合には誤った対訳文となる．その際の閾値について述べる．提案手法では，得られる対訳文の類似度は全体として 0.0 から 1.0 に均等に位置している訳ではな

表 1 実験結果

手法	ベースライン			EMDシステム			文長を考慮しない提案手法			**提案手法**		
	精度	再現率	F値	精度	再現率	F値	精度	再現率	F値	精度	再現率	F値
記事1	0.17(1/6)	0.06(1/18)	0.08	0.32(13/41)	0.72(13/18)	0.44	0.42(15/36)	0.83(15/18)	0.56	0.41(15/37)	0.83(15/18)	0.55
記事2	0.00(0/0)	0.00(0/13)	0.00	0.27(10/37)	0.77(10/13)	0.40	0.35(8/23)	0.62(8/13)	0.44	0.38(10/26)	0.77(10/13)	0.51
記事3	0.00(0/0)	0.00(0/26)	0.00	0.43(16/37)	0.62(16/26)	0.51	0.48(19/40)	0.73(19/26)	0.58	0.47(18/38)	0.69(18/26)	0.56
記事4	0.00(0/1)	0.00(0/10)	0.00	0.20(6/30)	0.60(6/10)	0.30	0.23(6/26)	0.60(6/10)	0.33	0.19(5/27)	0.50(5/10)	0.27
記事5	0.33(2/6)	0.11(2/19)	0.16	0.47(7/15)	0.37(7/19)	0.41	0.33(3/9)	0.16(3/19)	0.21	0.50(5/10)	0.26(5/19)	0.34
記事6	0.50(3/6)	0.23(3/13)	0.32	0.55(12/22)	0.92(12/13)	0.69	0.56(10/18)	0.77(10/13)	0.65	0.53(9/17)	0.69(9/13)	0.60
記事7	0.67(12/18)	0.43(12/28)	0.52	0.65(17/26)	0.61(17/28)	0.63	0.63(20/32)	0.71(20/28)	0.67	0.63(20/32)	0.71(20/28)	0.67
記事8	0.25(1/4)	0.09(1/11)	0.13	0.07(2/29)	0.18(2/11)	0.00	0.00(0/20)	0.00(0/11)	0.00	0.29(7/24)	0.64(7/11)	0.40
記事9	0.53(9/17)	0.47(9/19)	0.50	0.36(15/42)	0.79(15/19)	0.49	0.16(5/32)	0.26(5/19)	0.20	0.35(14/40)	0.74(14/19)	0.47
記事10	0.33(2/6)	0.11(2/18)	0.17	0.34(12/35)	0.67(12/18)	0.45	0.43(12/28)	0.67(12/18)	0.52	0.43(12/28)	0.67(12/18)	0.52
記事11	0.00(0/0)	0.00(0/29)	0.00	0.58(25/43)	0.86(25/29)	0.69	0.64(25/39)	0.86(25/29)	0.74	0.64(25/39)	0.86(25/29)	0.74
記事12	0.00(0/1)	0.00(0/10)	0.00	0.27(4/15)	0.40(4/10)	0.32	0.41(7/17)	0.70(7/10)	0.52	0.41(7/17)	0.70(7/10)	0.52
記事13	0.25(1/4)	0.04(1/23)	0.07	0.13(3/24)	0.13(3/23)	0.13	0.22(6/27)	0.26(6/23)	0.24	0.20(4/20)	0.17(4/23)	0.19
記事14	0.00(0/0)	0.00(0/26)	0.00	0.33(15/45)	0.58(15/26)	0.42	0.41(16/39)	0.62(16/26)	0.49	0.42(19/45)	0.73(19/26)	0.54
記事15	0.00(0/0)	0.00(0/12)	0.00	0.32(6/19)	0.50(6/12)	0.39	0.32(8/25)	0.67(8/12)	0.43	0.29(9/31)	0.75(9/12)	0.42
平均	0.20	0.10	0.13	0.35	0.58	0.42	0.37	0.52	0.42	**0.41**	**0.65**	**0.49**

く,比較的低い値に集中する傾向がある.したがって,閾値を高めに設定すると正しいと判断される対訳文の数は少なくなると考えられる．そこで閾値は全対訳文候補の類似度の最小値と最大値の間で 3 分割した場合の最小値に近い側の 1/3 とした．以下の式(12)に閾値の決定式を示す.

$$\text{閾値} = \frac{\text{類似度の最大値} - \text{類似度の最小値}}{3.0} + \text{類似度の最小値} \quad (12)$$

3. 性能評価実験

3.1. 実験方法

本実験では,単語の分散表現として word2vec を用いた.翻訳行列の生成においては word2vec の次元数を日英方向では，英語 300 次元，日本語 600 次元とした．英日方向では,英語 600 次元,日本語 300 次元とした．本実験で用いた Wikipedia のデータは日本語が 2016 年 9 月のダンプデータ，英語が 2017 年の 9 月のダンプデータである．また，EMD による類似度計算においては**式(7)**のxには予備実験の結果に基づき 0.1 を用いた．Wikipedia の全記事に出現する割合としては非常に小さい値であるが，句読点等が出現しない記事や非常に少ない文で構成される記事が多く存在していることから,機能語を多く含む割合はそれほど高くないためx値としては 0.1 を用いた．

また，**2.3.1** の対訳文候補の決定においては類似度が最も高い文ペアより上位 10 個を用いたビームサーチによる探索を行った．実験データにはニュースサイト[15]に掲載されている英語記事と対応する日本語記事の 15 ペアを用いて,コンパラブルコーパスを作成した.今回の実験では，1 対 1 対応の対訳文のみを抽出対象とした．正解となる対訳文は第一著者が決定した．その結果，275 の対訳文が得られた．

ベースラインには文長から対訳文を抽出する手法に対して，単語の分散表現に基づく単語アライメントを追加したシステム[11]を用いた．また，提案手法における文長を考慮した重みの有効性を確認するために，機能語と内容語を区別しない$tfidf$，近似単語を用いない距離計算，そして，文長の違いを考慮しない EMD によるシステム(以降，EMD システムと呼ぶ)と文長を考慮しない提案手法によるシステムを用いた．評価方法には，適合率，再現率，F 値を用いた．適合率はシステムにより抽出された全ての対訳文における正しい対訳文の割合，再現率は，全ての正しい対訳文に対する抽出された正しい対訳文の割合である．F 値は適合率と再現率の調和平均である.

3.2. 実験結果

ベースライン，EMD システム，文長を考慮しない提案手法，提案手法の実験結果を表 1 に示す．( )内の数値の分母は適合率においては抽出された対訳文数，再現率においては正しい対訳文数である.分子は適合率,再現率ともに抽出された正しい対訳文数である．平均は全記事の適合率，再現率，F 値の平均である.

3.3. 考察

表 1 の実験結果より，適合率，再現率，F 値の平均全てにおいて，提案手法が最も高い値を示した．特に EMD システムと文長を考慮しない提案手法に比べ,提案手法の F 値の平均は，0.07 高い値となっている．したがって，文長を考慮した提案手法が有効に働いていることがわかる.

提案手法と EMD システムの比較においては，正しい対訳文の数は新たに 23 得られたが,逆に得られなくなった対訳文の数は 7 であった．したがって，提案手法により得られた正しい対訳文の数が 16 増加したことになる．このように，抽出された正しい対訳文の増加が再現率の向上をもたらしたと考えられる．また，

表 2 提案手法において新たに抽出した対訳文の具体例

対訳文	文の単語構成数
the more skilled you are , the more unique your work apparently becomes .	14
熟練するほどプログラマーの仕事には個性が生まれてくる、というわけだ。	18

表 3 提案手法において抽出されなくなった対訳文の具体例

対訳文	文の単語構成数
in just 15 years , roughly 4,000 miles of fiber-optic cables in us coastal cities could go underwater , potentially causing internet outages .	24
あと 15 年もすれば、米国の沿岸部にある都市の光ファイバーケーブルのうち約 4 , 000 マイル（6 , 400 km）分が水面下になり、インターネットのサーヴィス停止を招く可能性があるというのだ。	52

システムが正しいと判定した対訳文の数は 29 減少した．この中で正しい対訳文の数は 7，誤った対訳文の数は 22 であった．したがって，抽出された誤った対訳文が減少したことにより適合率が向上したと考えられる．

表 2 には提案手法により新たに抽出された正しい対訳文の具体例を示す．EMD システムにおいては日英方向と英日方向で異なる対訳文が候補となっていたため，抽出されなかった．提案手法では，文長を考慮することにより類似度は 0.392 となり，閾値は 0.355 となった．その結果，提案手法では正しい対訳文として抽出された．このように文の長さの違いを類似度に反映させたことでより高い精度で類似度計算が可能となった．また，表 3 には提案手法により抽出されなくなった対訳文の具体例を示す．この対訳文では，EMD システムにおいては類似度 0.662 に対して閾値が 0.553 であった．そのため正しい対訳文と判断された．提案手法では，日英方向と英日方向で異なる対訳文の候補となったため，抽出されなかった．このような長文の対訳文については，文の長さが大きく異なっていても対応関係が成立している文ペアが多いため，文の長さも考慮した重み付けが必要になると考えられる．

4. おわりに

本稿では，コンパラブルコーパスから対訳文の抽出手法として未知語に柔軟に対応でき，かつ単語の意味を考慮した新たな手法を提案した．提案手法では，単語の分散表現を用いた Earth Mover’s Distance 及び文長の違いを考慮した重み付けによって類似度計算を行う．コンパラブルコーパスを用いた性能評価実験の結果，提案手法は最も高い抽出精度を示し，その有効性が明らかとなった．

今後は，長文に対する抽出精度向上及び 1 対多の対訳文の抽出のための改良を行う予定である．

文　献

[1] Dzmitry B., Kyunghyun C., Yoshua B., “Neural Machine Translation by Jointly Learning to Align and Translate”, International Conference on Learning Representations, 2015.

[2] Utiyama M., Ishahara H., “Reliable measures for aligning Japanese-English news articles and sentences”, Proceedings of the 41st Annual Meeting on Association for Computational Linguistics, Volume 1, pp.72-79, 2003.

[3] Fung P., Yee L. Y., “An IR approach for translating new words from nonparallel, comparable texts”, Proceedings of the 17th international conference on Computational linguistics, Volume1, pp.414-420, 1998.

[4] Tamura A., Watanabe T., Sumita E., “Bilingual lexicon extraction from comparable corpora using label propagation”, Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning, pp.24-36, 2012.

[5] 田上諒, 越前谷博, 荒木健治, “単語の分散表現を用いた Earth Mover's Distance と文ベクトルによる対訳コーパスの自動生成”, 第 32 回人工知能学会全国大会論文集, 4Pin1-24, 2018.

[6] 田上諒, 越前谷博, 荒木健治, “単語の分散表現に基づく Earth Mover’s Distance を用いたコンパラブルコーパスからの対訳文の自動抽出”, 平成 30 年度電気・情報関係学会北海道支部連合大会, 講演番号 126, 2018.

[7] Tomas M., Ilya C., Kai C., Greg C., Jeffrey D.,” Distributed representations of words and phrases and their compositionality”, In Advances in neural information processing systems, pp.3111-3119, 2013.

[8] Tomas M., Quoc V. Le, Ilya S., “Exploiting similarities among languages for machine translation”, arXiv preprint arXiv:1309.4168, 2013.

[9] Yossi R., Carlo T., Leonidas J. Guibas, “The Earth Mover's Distance as a Metric for Image Retrieval”, International Journal of Computer Vision, Volume 40 Issue 2, pp.99−121, 2000.

[10] 人工知能学編, “人工知能学事典:第 2 章 1-3 最良優先探索とビーム探索.”, p.23, 2006.

[11] SMT-RowLec 2. Sentence alignment, https://github.com/nguyenlab/SMT-LowRec

[12] google 翻訳, https://translate.google.co.jp

[13] Moore, Robert C., “Fast and accurate sentence alignment of bilingual corpora.”, Proceedings of the 5th Conference of the Association for Machine Translation in the Americas, Machine Translation: From Research to Real Users, pp.135-144, 2002.

[14] Boxing C., Hongyu G., ”Representation Based Translation Evaluation Metrics”, the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing, pp.150-155, 2015.

[15] WIRED, https://www.wired.com