単語の分散表現に基づく Earth Mover's Distance を用いたコンパラブルコーパスからの対訳文の自動抽出

Automatic Extraction of Bilingual Sentences from Comparable Corpus Using Earth Mover's Distance based on Word Embeddings

田上諒 [1] 越前谷博 [1] 荒木健治 [2]

Ryo Tanoue Hiroshi Echizen'ya Kenji Araki

北海学園大学大学院工学研究科 [1]

Graduate School of Engineering, Hokkai-Gakuen University

北海道大学大学院情報科学研究科 [2]

Graduate School of Information Science and Technology, Hokkaido University

１．はじめに

近年，ニューラル機械翻訳の進展に伴い，より大規模なパラレルコーパスが求められている．しかし，人手による作成はコスト面がネックとなり，作成されるパラレルコーパスは特定の言語や分野に限定されるといった問題がある．一方，Wikipedia に代表されるコンパラブルコーパスは今後，より充実していくと考えられる．そのため，コンパラブルコーパスより対訳文を自動抽出するための研究が盛んに行われている．

大量の対訳文からなるパラレルコーパスを自動生成する手法には，翻訳辞書を利用した手法[1]や単語の出現回数や文脈情報を利用した手法[2, 3], 潜在的な意味解析を利用した手法[4, 5]などが挙げられる．しかし，これらの手法は高品質な対訳知識が必要となるため，未知語に対しての対応が不十分となる．また，これらの手法では単語の意味が十分に考慮されていないため，高品質なパラレルコーパスの生成には，より大規模なコーパスが必要となる．

そこで，我々は，高品質な対訳知識を用いることなく，かつ，単語の意味を考慮する，コンパラブルコーパスから対訳文を自動抽出するための手法を提案する．提案手法では異言語間の文同士の対応関係を単語の分散表現である word2vec[6]に基づく類似度により決定する．その際，翻訳行列[7]を用いて，単語の分散表現を他の言語の単語の分散表現にマッピングする．そして，そのマッピングをした単語の分散表現に基づき，2 つの分布間の距離計算法である Earth Mover's Distance(EMD)[8]により類似度を得る．EMD において単語の分散表現を特徴量とすることで，単語の意味を考慮した文間の類似度を得ることができる．さらに，単語間の意味的な距離計算においては，他言語にマッピングされた単語に対して，近似単語として表層情報を得た後，マッピング先の言語の単語の表層情報と一致するかどうかを決定することで，word2vec における対義語の問題の解消を図っている[9]．本稿では，コンパラブルコーパスから対訳文を抽出するために，得られた類似度に閾値を設けることで正しい対訳文を決定する．また，提案手法では EMD を適用する際に，機能語と内容語を差別化することで文間類似度の精度向上を図る．

性能評価は，ニュースサイトに掲載されているコンパラブルコーパスに対し，提案手法により対訳文を自動抽出し，F 値を求めることで行なった．その結果，提案手法では，機能語と内容語の差別化をせず，かつ，対義語を考慮しない EMD のみのシステム(EMD システム)と比べ，高い F 値が得られた．

２．提案手法

２．１ 提案手法の概要

図 1 に日本語から英語方向での正しい対訳文の決定の流れを示す．

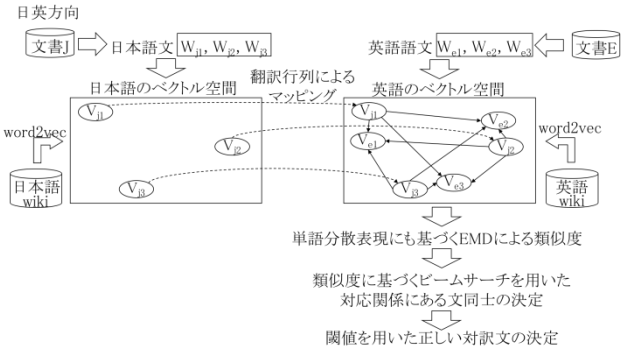


図 1 日英方向における正しい対訳文の決定の流れ

言語が異なる文を比較するため，異言語間の文の単語の分散表現へのマッピングを翻訳行列に基づいて行い，EMD を用いて文間類似度を求める．そして，文書の全文間に対して文間類似度を算出し，ビームサーチを用いて日英方向，英日方向それぞれで対応関係にある文同士を決定する．さらに，双方向に同じ対応関係にある文ペアが得られ，かつ，文ペアの類似度が閾値以上の場合にそれらを正しい対訳文とする．

ここで，EMD による文間類似度を得るためには特徴量，重み，距離式を定義する必要がある．提案手法では，特徴量に word2vec による単語の分散表現，重みに$tfidf$，距離式にコサイン距離を用いている．ただし，重みである$tfidf$と距離式には独自の工夫を行っている．$tfidf$に基づく重み$weight$の計算式を式(1)に示す．式(1)は機能語の$tfidf$を小さくすることが目的である．本手法では Wikipedia ダンプデータにおける全記事数Nに対する任意の単語の出現記事数dfの割合より機能語かどうか判定している．割合がx以上であれば機能語とみなし負の重みとして 0.5 を掛ける．

$$weight = \begin{cases} tfidf \times 0.5 (\frac{df}{N} \geq x) \\ tfidf (\frac{df}{N} < x) \end{cases} \quad (1)$$

また，距離を計算する際に，翻訳行列によりマッピングされた単語の分散表現と最も近い分散表現を持つ単語を近似単語とし，その近似単語がマッピング先の言語の単語と表層的に一致しているかどうかを決定する．そして式(2)に示すように一致していない場合にはコサイン距離の 2 乗を用いて，距離dを大きくする．

$$d = \begin{cases} 1.0 - \cos(\text{表層レベルで一致}) \\ 1.0 - cos^2(\text{表層レベルで不一致}) \end{cases} \quad (2)$$

翻訳行列及び EMD を用いて異言語の文間類似度を求める研究としては藤川ら[10]の研究がある．藤川らは参照訳を用いない機械翻訳の自動評価法のために異言語の文間類似度を求めている．そこでは単語間の距離は単語ベクトル間のコサイン距離と表層情報に基づく Dice 係数を用いることで単語アライメントを行い，文間類似度の精度向上を図っている．一方，提案手法では近似単語を用いることで単語間類似度の精度向上を図っている．これは word2vec では，対義語の関係にある単語間の類似度が高くなるという問題に有効と考えられるためである．また，本手法では機能語と内容語の差別化により単語の分散表現に対して適切な重み付けをし，より精度の高い類似度計算を行う．

３．性能評価実験

３．１ 実験方法

実験データにはニュースサイト[11]にある英語記事と対応する日本語記事の 4 ペアを用いてコンパラブルコーパスを作成した．今回の実験では，1 対 1 対応の対訳文のみを抽出対象とした．その際，正解となる対訳文は第一著者が決定し，その結果 64 の対訳文が得られた．ベースラインとして EMD システムを用いて提案手法の評価を行なった．評価方法には，適合率，再現率，F 値を用いた．提案手法においては，式(1)のx値には 0.1 を用いた．Wikipedia ダンプデータの全記事に出現する割合としては非常に低い値であるが，句読点などが出現しない記事や非常に少ない文で構成される記事が多数含まれているため，機能語を多く含むx値としては 0.1 という小さな値を用いた．また，本実験では，得られた対訳文に対する正しい対訳文の基準となる閾値については，記事ごとに得られた対訳文の最大値と最小値の差を 3 等分し，その結果得られた値を最小値に加えた値を用いた．これは，多くの対訳文の文間類似度が最小値の近くに分布する傾向にあるためである．

３．２ 実験結果

提案手法と EMD の実験結果を表 1 に示す．( )内の数値の分母は適合率においては抽出された対訳文数，再現率においては正しい対訳文数である．分子は適合率，再現率ともに抽出された正しい対訳文数である．

表 1　実験結果

手法	適合率	再現率	F値
EMDシステム	29.8%(45/151)	70.3%(45/64)	41.9%
提案手法	**39.3%(48/121)**	**75.0%(48/64)**	**51.6%**

３．３ 考察

表 1 より提案手法が，適合率，再現率，F 値全てにおいて EMD システムよりも高い値を示した．これにより内容語と機能語の差別化による重み及び距離計算における近似単語の利用が有効であることが明らかとなった．EMD システムと提案手法の比較においては，適合率より，正しい対訳文の抽出の増加及び誤った対訳文の抽出の減少が同時に実現できいていることがわかる．また，提案手法により正しい対訳文は 8 つ増加した．その逆に提案手法により抽出されなくなった正しい対訳文は 5 つであった．したがって，より F 値を向上させるためには，より精度の高い文間類似度を得るための改良が必要である．

４．おわりに

本稿では，単語の分散表現に基づく Earth Mover's Distance を用いたコンパラブルコーパスからの対訳文の自動抽出法を提案した．ベースラインである EMD システムより提案手法の F 値が向上しており，提案手法の有効性が確認された．今後は文長を考慮することで文間類似度の精度向上を図る予定である．

参考文献

[1] 内山将夫, 谷村緑: パラレルコーパスの自動生成技術, 情報通信研究機構季報 53(3), 23-28, 情報通信研究機構 (2007).

[2] Fung P. and Yee L. Y.: An IR approach for translating new words from nonparallel, comparable texts, Proceedings of the 17th international conference on Computational linguistics - Volume 1, 414-420 (1998).

[3] Tamura A., Watanabe T. and Sumita E.: Bilingual lexicon extraction from comparable corpora using label propagation, Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning, 24-36 (2012).

[4] Preiss J.: Identifying comparable corpora using LDA, Proceedings of the 2012 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 558-562 (2012).

[5] 江里口瑛子, 小林一郎: 潜在情報を利用したパラレルコーパス生成, 第 28 回人工知能学会全国大会論文集, 3I4-1, 人工知能学会 (2014).

[6] Tomas M., Kai C., Greg C. and Jeffrey D.: Efficient estimation of word representations in vector space, arXiv:1301.33781v3 (2013).

[7] Tomas M., Quoc V. Le, and Ilya S.: Exploiting similarities among languages for machine translation, arXiv:1309.4168v1 (2013).

[8] Yossi R., Carlo T., Leonidas J. Guibas: The Earth Mover's Distance as a Metric for Image Retrieval, International Journal of Computer Vision November 2000 Volume 40 Issue 2, 99−121 (2000).

[9] 田上 諒, 越前谷 博, 荒木 健治: 単語の分散表現を用いた Earth Mover's Distance と文ベクトルによる対訳コーパスの自動生成, 第 32 回人工知能学会全国大会論文集, 4Pin1-24, 人工知能学会(2018).

[10] 藤川寛基, 越前谷博, 荒木健治: 参照訳を必要としない単語分散表現による異言語間類似度を用いた訳文の自動評価, 信学技報 vol. 118 no. 122 NLC2018-5 pp. 51-56, 電子情報通信学会 (2018).

[11] WIRED: https://www.wired.com