知能と情報（日本知能情報ファジィ学会誌）Vol.31, No.2, pp.645－652（2019）

原著論文

地方議会会議録における発言文推定手法の性能評価†

桧森　拓真*1・木村　泰知*1 *2・坂地　泰紀*3・荒木　健治*4

本研究では，地方議会会議録に含まれるテキストの発言箇所を自動で推定する．実験のデータセットは，平成 23 年 4 月から平成 27 年 3 月までの 4 年間の 4 つの自治体の議会会議録であり，青森県，東京都，大阪府，福岡県の会議録に対して，人手で発言文と発言以外の文にアノテーションを行った．「4 年間のデータを利用した発言文の推定実験」では，学習データと評価データに「同一自治体のデータ」を利用した実験，および，「異なる自治体のデータ」を利用した実験を行なった．実験の結果，SVM の平均正解率が最も高く，それぞれ，0.985，0.951 となった．また，少量の学習データによる「1 年間のデータを利用した推定実験」では，LSTM と SVM の比較を行った．比較実験の結果，LSTM の平均正解率が 0.926 となり SVM の平均正解率よりも 6.1 ポイント上回る結果となった．

キーワード：地方議会会議録，発言文，分類

1．はじめに

近年，公共データの活用に期待が高まっており，自治体のオープンデータ化が進んでいる．ウェブ上に公開されている公共データの一つに地方議会会議録がある．地方議会会議録は地方議会でのすべての発言，すなわち議会における議論の過程を書き起こしたテキストデータであり，いつ，どこで，だれが，なにを発言したのかが記録されている．

このため，地方自治体における政策の決定がどのように行われたのかを確認するために利用することができる．例えば，東京都議会の会議録を読むことで，築地市場の豊洲移転問題について，知事や議員がどの時点でどのような発言をしたのかを知ることができる．

井原らは，全国の自治体のウェブサイトから地方議会会議録を収集し，地方議会会議録コーパスの構築を進めている [1]．それらのコーパスは，自然言語処理や社会言語学の分野において利用され，研究成果を挙げており[1]，それらのコーパスを利用した意見や意思を表す発言の抽出を行っている研究も存在する [2]．

しかしながら，地方議会会議録は，統計量を扱う計量経済学のような分野において期待されているものの [3]，網羅性や正確性の観点から，利用しづらいという問題が存在した．その問題を解決するために，木村らは，政治学・経済学の分野における地方議会会議録コーパスの活用に向けて，会議録中のすべての発言に対して「自治体名」「発言日」「発言者」を正確に付与することを行なっている [4]．その結果，発言者情報を正確に付与することにより，異なる表記（例えば，「梅沢佳一」や「梅澤よしかず」などと記載されている場合）でも同一人物として識別を行えることから，正確に話者を識別しながら，発言文字数を表示することが可能となった．しかしながら，もう一つ大きな問題として，発言を正確に識別しできていないという問題が存在する．ここで，発言とは，知事，議員，職員などの発言を書き起こした記述のことである．例えば，東京都議会の会議録には，下記のように「発言以外の文字列（これ以降，非発言と呼ぶ）」が含まれており，４割弱の「非発言」が含まれている．

議会会議録における「発言」「非発言」の例

発言：これにご異議ありませんか。
非発言：〔「異議なし」と呼ぶ者あり〕
発言：ご異議なしと認めます。
発言：よって、日程第 1 から第 24 までは、議案付託事項表のとおり、それぞれ所管の常任委員会に付託することに決定いたしました。
非発言：（別冊参照）
非発言：――――――――
発言：これより追加日程に入ります。
発言：追加日程第 1、東京都副知事の選任の同意についてを議題といたします。
非発言：〔鈴木議事部長朗読〕
非発言：1、東京都副知事の選任の同意について 1 件
非発言：――――――――
非発言：23 財主議第 133 号
非発言：平成 23 年 6 月 17 日
非発言：東京都知事石原慎太郎

上記のように，地方議会会議録は，状況説明・ト書き・添付資料・朗読[2]のような「非発言」が含まれているため，発言文字数を正確に数えらないという問題がある．この問題に対し，発言文の自動推定を行うことで解決を試みる．

そこで，本論文では，地方議会会議録を対象にした「発言文

† Performance Evaluation of a Method for Recognizing Utterances in Local Assembly Minutes
Takuma HIMORI, Yasutomo KIMURA, Hiroki SAKAJI, and Kenji ARAKI

*1 小樽商科大学
Otaru University of Commerce
*2 理化学研究所 AIP
RIKEN AIP
*3 東京大学
The University of Tokyo
*4 北海道大学
Hokkaido University

1 http://local-politics.jp/

2 「朗読」は履歴書の読み上げなど通常の発言と異なることから，非発言としている．

を推定する」という新しいタスクに対し，既存手法でどの程度解決できるのか明らかにすることを目的とする．

本論文では，2 章で地方議会会議録の発言文のアノテーションについて説明する．3 章では，「発言文を推定する」というタスクにおいて，テキスト分類における既存手法を適用することで，タスクの難しさを明らかにする．4 章では，全 1,788 自治体の地方議会会議録の発言文の推定を行うために，実用上のシチュエーションを想定した場合の「発言文を推定する」タスクの難しさを明らかにする．

2. 地方議会会議録における発言文

2.1 発言文へのアノテーション

本節では，発言文抽出を開発するために行なった，発言文のアノテーションについて述べる．我々は，平成 23 年 4 月から平成 27 年 3 月までの 4 年間を対象として，47 都道府県議会議事録を収集している．また，それらを統一したデータ構造で管理しており，データベースに格納している．現在までに，47 都道府県の地方議会会議録の 4 年間分を漏れなく収集し，異なる表現の名前でも話者を識別することが可能となっている．これらの地方議会会議録コーパスから，4 つの自治体「青森県」「東京都」「大阪府」「福岡県」を対象に，発言文に発言と非発言のアノテーションを行う．対象とした 4 つの自治体は，各地域から偏りのないように選んだ．表 1 に 4 つの対象自治体の平成 23 年 4 月から平成 27 年 3 月までの 4 年間に含まれる行数を示す．

注釈者は 20 代の文系大学生，女性 1 人，男性 3 人の計 4 人（A,B,C and D）であり，アノテーションは一つの自治体（同一データ）に対して，2 人の注釈者が発言と非発言のラベルを一文単位で付与する．また，発言と非発言が混在する場合や判断が難しい場合には「その他」のラベルを付与する．アノテーションのラベルは，次の通りである．

ラベル “1” 発言
- 3 文字以内の「記号」は切り分けない
- 「――」のような記号が含まれる場合も入れる

ラベル “2” 非発言

ラベル “9” その他
- 発言と非発言が混在する場合
- あるいは，判断が難しい場合

図 1 は東京都議会会議録の各行に「発言」「非発言」を付与している例である．表 2 はアノテーションの結果であり，二人の注釈者が一致した発言数，非発言数，合計，二人の注釈者の不一致数，「その他」の行数，合計，κ 値[3]を自治体ごとに記載している．注釈の結果，4 つの自治体に対して，κ 値が 0.8 を超えていることから，2 人の注釈者の判断がほぼ一致していることがわかる．アノテーションには，一人の注釈者が，4 年間の本会議の議会会議録（約 10 万行）に対して 50 時間程度要しており，全自治体に対してアノテーションを行うことは非常にコストがかかることがわかる．そこで，3 章では，アノテーションしたデータ用いて，評価実験を行う．4 章では，アノテーションのコストを削減するために実用性を考え，少量のデータを用いて評価実験を行う．

表 1 4 年間の会議録に含まれる行数

都道府県名	青森県	東京都	大阪府	福岡県
行数	96,095	115,750	95,929	84,918

議長	和田宗春	ただいまから平成二十三年第二回東京都議会定	1
議長	和田宗春	――――――	2
議長	和田宗春	この際、開議に先立ちまして、このたびの東日	1
議会局長	白石弥生子	全員ご起立願います。	1
議会局長	白石弥生子	〔全員起立〕	2
議会局長	白石弥生子	黙祷をお願いいたします。	1
議会局長	白石弥生子	〔黙　　祷〕	2
議会局長	白石弥生子	黙祷を終わります。	1
議会局長	白石弥生子	ご着席願います。	1
議会局長	白石弥生子	――――――	2
知事	石原慎太郎	国家の役割の第一義は――静かに聞けよ。	9
議会局長	白石弥生子	――――――	2

図 1 東京都議会会議録のアノテーションの例

3. 4 年間のデータを利用した推定実験

3.1 目的

本節では，地方議会会議録を対象にした「発言文を推定する」という新しいタスクにおいて，大規模とは言えない学習データに対し，テキスト分類における既存手法を適用し，タスクの難しさを明らかにすることを目的とする．本実験で利用する地方議会会議録は，3 ヶ月おきに更新されるデータであり，頻繁に更新する必要がない．そのため，既存手法として，オンライン学習による識別器ではなく，バッチ処理による学習を用いることとする．

3.2 実験 1「同一自治体のデータ」

3.2.1 目的

本実験では，訓練データと評価データに「同一自治体のデータ」を利用して，地方議会会議録に含まれるテキストの発言箇所を自動で，発言か非発言かを推定することを目的とする．

3.2.2 実験方法

地方議会会議録のテキストから特徴語辞書を作成し，さらに特徴ベクトルを作成する．特徴語辞書を作成するために，テキストを 1 文ずつ形態素解析ツール Mecab [5] を使用して形態素解析を行い，特徴語辞書を作成する．また，今回は，形態素誤りについて修正を行わず，そのまま使用した．作成した特徴語辞書を，Bag-of-words モデルを用いて特徴語ベクトルを作成する．作成した特徴語ベクトルを LSI（Latent Semantic Indexing）[6] を用いて 100 次元のベクトルに圧縮する．作成した特徴語ベクトルを判別器を使用して発言か非発言かを判別する．学習データには，推定する発言文と同一自治体の発言文を使用する．例を挙げると，東京都の発言文推定には，東京都の発言文を学習データに使用する．判別の精度は十分割交差検証によって評価する．

本実験では，推定結果を評価するために，表 3 のように，

3 R の library（irr）の kappa2 関数を用いて計算した．

表２　4つの自治体に対するアノテーションの結果

自治体	注釈者	一致			不一致	その他	合計	κ
		発言	非発言	合計				
青森県	C,D	91,714	2,875	94,588	882	625	96,095	0.807
東京都	A,B	72,604	42,909	115,512	215	23	115,750	0.996
大阪府	C,D	74,592	18,320	92,912	167	2,850	95,929	0.914
福岡県	A,B	78,930	5,638	84,568	276	74	84,918	0.992

表３　予測結果の評価

		正解（注釈結果）	
		正（発言）	負（非発言）
予測結果	正（発言）	TP	FP
	負（非発言）	FN	TN

True Positive（TP），False Positive（FP），False Negative（FN）and True Negative（TN）に分ける．正解数及び正解率の計算方法は，次の通りである．

$$\text{正解数} = TP + TN$$
$$\text{正解率} = \frac{TP + TN}{TP + FP + FN + TN}$$

また，各自治体の正解数を足したものを，各自治体の総文数の総和で割ったものを平均正解率とする．以上の予測結果の評価方法に基づいて実験結果を評価する．

3.2.3　実験データ

実験データには，平成 23 年 4 月から平成 27 年 3 月までの定例会を対象とした会議録を使用する．対象となる自治体は，青森県，東京都，大阪府，福岡県の 4 つである．本実験では，注釈者の二人が一致したデータだけを用いることとした．つまり，各自治体の発言および非発言のデータ数は，表 2 における「一致」と記載されている「発言」「非発言」の値である．

3.2.4　実験結果

実験結果を表 4，表 6 に示す．ここで，RF はランダムフォレスト [7]，LR はロジスティック回帰 [8] を示す．東京都では，SVM の正解率が 0.952 と最も高く，決定木は 0.862 と最も低い正解率となった．青森県，大阪府及び福岡県では SVM，RF の正解率が 0.999 と非常に高い正解率であった．表 6 の平均正解率をみると，SVM が 0.987 と最も正解率が高いことがわかる．

3.3　実験２　「異なる自治体のデータ」

3.3.1　目的

本実験では，学習データと評価データに「異なる自治体のデータ」を利用して，地方議会会議録に含まれるテキストの発言箇所を自動で，発言か非発言かを推定することを目的とする．

3.3.2　実験方法

本実験では，東京都の発言文を学習データとし，青森県，大阪府及び福岡県の発言文を判別器を用いて推定する．それ以外の実験の方法，及び評価方法は実験 1 と同様である．

3.3.3　実験データ

実験データは，学習データを東京都の発言文，テストデータには他の 3 つの自治体の発言文を使用する．東京都議会のデータは，議員定数が 127 人であり，議員数が日本で最も多いことから，様々な発言が含まれる．また，非発言がデータの約 4 割と多く含み、正例と負例のバランスが良いことから，学習データとした．

3.3.4　実験結果

実験結果を表 5 と表 6 に示す．表 5 からは青森県と福岡県では，RF が 0.953，0.958 と最も正解率が高く，大阪府では SVM が 0.968 と最も正解率が高いことがわかる．表 6 から，平均正解率では，SVM が平均正解率 0.951 と他の手法よりも高いことがわかる．

3.4　考察

本節では，実験 1，2 において最も平均正解率の高かった SVM の結果について考察を行う．表 4 に示した通り，青森県，大阪府，福岡県の SVM の正解率は 0.999 である．これは 2.1 節で行った二人の注釈者の一致率と同程度の精度であり，十分に高い精度といえる．

ここで，誤りを引き起こしている主な原因を明らかにするために，非発言の出現する位置を調査することにした．非発言の出現する位置を明らかにするために，発言者の役職に分けて，非発言の出現回数を調べた．会議録データは，発言者の情報に加えて，役職の情報を得ることができる．図 2 に，役職ごとの非発言数を示す．図 2 からわかるように，非発言の多くは，議長の発言として扱われている．これは，議長の発言箇所に説明資料が追加されているためである．また，大阪府の「空欄」は発言者情報が付与されていない箇所であり，会議録の冒頭部分（目次や議題など）である．さらに，表 4 に示す通り，誤りの多くは，非発言を発言と間違う FP である．そのため，発言者の役職や発言者の名前の有無など地方議会会議録特有の特徴を機械学習の素性に加えることで，東京都においても精度の向上の可能性があると考えられる．

実験結果から，他の手法と比較して，SVM の平均正解率が最も高くなることがわかった．SVM は，過学習を起こすことなく，高い汎化性能で学習を行えることで知られている [9, 10]．本実験では，表 2 の一致した合計が示すように，最も少ない自治体でも，学習データが 84,568 あり，十分に学習を行えたため，SVM の平均正解率が最も高くなったと考えられる．

表４ 同一自治体の会議録を学習データとした 10 分割交差検定の実験結果

評価データ	手法	パラメータ	TP	FP	FN	TN	総文数	適合率	再現率	F 値	正解率
東京都	SVM	kernel=rbf	71,693	4,613	911	38,295	115,512	0.940	0.987	0.963	0.952
東京都	決定木	深さ=3	69,039	12,351	3,565	30,557	115,512	0.848	0.951	0.897	0.862
東京都	RF	標本数=10	72,045	6,005	559	36,903	115,512	0.923	0.992	0.956	0.943
東京都	LR	C=1	70,501	5,607	2,103	37,301	115,512	0.926	0.971	0.948	0.933
青森県	SVM	kernel=rbf	91,647	47	66	2,828	94,588	0.999	0.999	0.999	0.999
青森県	決定木	深さ=3	91,449	100	264	2,775	94,588	0.999	0.997	0.998	0.996
青森県	RF	標本数=10	91,704	22	9	2,583	94,588	0.999	0.999	0.998	0.999
青森県	LR	C=1	91,643	75	70	2,800	94,588	0.999	0.999	0.999	0.998
大阪府	SVM	kernel=rbf	74,562	59	30	18,261	92,912	0.999	0.999	0.999	0.999
大阪府	決定木	深さ=3	73,851	408	741	17,912	92,912	0.995	0.996	0.995	0.988
大阪府	RF	標本数=10	74,588	57	4	18,263	92,912	0.999	0.999	0.999	0.999
大阪府	LR	C=1	74,506	58	86	18,262	92,912	0.998	0.999	0.999	0.998
福岡県	SVM	kernel=rbf	78,907	66	23	5,572	84,568	0.999	0.936	0.967	0.999
福岡県	決定木	深さ=3	78,595	398	335	5,240	84,568	0.999	0.913	0.954	0.991
福岡県	RF	標本数=10	78,927	44	3	5,594	84,568	0.999	0.996	0.998	0.999
福岡県	LR	C=1	78,873	107	57	5,531	84,568	0.996	0.938	0.966	0.998

表５ 学習データを東京都として，評価データを異なる自治体とした場合の比較実験

評価データ	学習データ	手法	パラメータ	TP	FP	FN	TN	総文数	適合率	再現率	F 値	正解率
青森県	東京都	SVM	kernel=rbf	85,840	1	5,873	2,874	94,588	0.999	0.936	0.967	0.938
青森県	東京都	決定木	深さ=3	83,698	34	8,015	2,841	94,588	0.999	0.913	0.954	0.915
青森県	東京都	RF	標本数=10	87,334	25	4,379	2,850	94,588	0.999	0.996	0.998	0.953
青森県	東京都	LR	C=1	86,035	384	5,678	2,491	94,588	0.996	0.938	0.966	0.936
大阪府	東京都	SVM	kernel=rbf	72,479	1,099	2,113	17,221	92,912	0.985	0.972	0.978	0.968
大阪府	東京都	決定木	深さ=3	59,584	125	15,008	18,195	92,912	0.998	0.799	0.887	0.837
大阪府	東京都	RF	標本数=10	71,311	7,789	3,281	10,531	92,912	0.902	0.956	0.928	0.881
大阪府	東京都	LR	C=1	70,634	1,464	3,958	16,856	92,912	0.980	0.947	0.963	0.942
福岡県	東京都	SVM	kernel=rbf	76,299	1,483	2,631	4,155	84,568	0.980	0.967	0.974	0.951
福岡県	東京都	決定木	深さ=3	71,689	1,514	7,241	4,124	84,568	0.979	0.908	0.942	0.896
福岡県	東京都	RF	標本数=10	76,814	1,449	2,116	4,189	84,568	0.981	0.951	0.966	0.958
福岡県	東京都	LR	C=1	74,882	1,781	4,048	3,857	84,568	0.977	0.949	0.963	0.931

表６ 学習データごとの平均正解率

学習データ	手法	パラメータ	平均正解率
同一自治体	SVM	kernel=rbf	0.985
同一自治体	決定木	深さ=3	0.953
同一自治体	RF	標本数=10	0.983
同一自治体	LR	C=1	0.979
東京都	SVM	kernel=rbf	0.951
東京都	決定木	深さ=3	0.882
東京都	RF	標本数=10	0.930
東京都	LR	C=1	0.936

	議長	知事	副知事	議員	その他	空欄	非発言の合計
青森県	2,632	78	4	31	130	0	2,875
東京都	39,136	294	32	856	2,587	4	42,909
大阪府	1,761	12	0	11	2	16,534	18,320
福岡県	4,587	5	0	1,019	4	23	5,638
合計	48,116	389	36	1,917	2,723	16,561	69,742
割合	0.69	0.01	0.00	0.03	0.04	0.24	1.00

図２ 地方議会会議録に含まれる非発言と役職の関係

次に，SVM について，実験 1，2 の誤りの分類を行なった．誤り分類の結果を表 7 に示す．実験 1 の東京，実験 2 の各自治体については，誤りであったもの（FP，FN）からランダムに，100 件抽出したものを分類した．表 7 の「1. 資料の記述」とは，図 3 下部の「記名投票結果（後略）」のように，投票結果や議員の発言を引用した，質問表などの資料を，発言と誤ったものである．議員の発言を引用した非発言は，文脈を考慮しなければ，実際の議員の発言と区別がつかないため，誤りが多かった．「2. 名前の列挙」とは，図 3 の「十一番　小山くにひこ君」のように議員の役職と氏名のみからなる文である．このような文には，議長の呼名や投票結果の記述に見られる表現で，資料の記述と同様に文脈を考慮しなければ，推定が難しく，誤りが多かった．「3. 記号付きの非発言」とは，図 4 の「*議長選挙」のように，文の先頭が記号で始まっている文のことである．記号付きの非発言は，各自治体によって，記号の記述が異なり，学習の仕方により誤りに大きく差が出た．「4. 実際の発言」とは，図 3 の議長の発言である「次に，会議録署名議員の氏名を行います。」のように，実際に議員が議会で行なった発言のことである．議員の発言は，各自治体の議題によって出現する単語が異なるため，学習データを異なるものにした実験 2 では増加の傾向があった．また，どの自治体においても，固有名詞など，出現頻度の低いものを含む発言については，誤りが多く見られた．このような出現頻度の低い単語には，「ILC（大型直線加速器）」などが挙げられる．

次に，SVM において，正解と不正解の多かった特徴的な例を挙げて考察を行う．実験 1 の結果の例を図 3 に示す．図 3 の上部に「知事石原慎太郎君」と「〔知事石原慎太郎君登壇〕」という文がある．このように同じ文字列を含む発言文に対して，括弧のない文の場合には発言として推定し，括弧のある文に対しては非発言として推定できることを確認した．推定が困難な

表７　実験 1,2 の誤り分類

	実験 1				実験 2		
誤りの分類	青森	東京	大阪	福岡	青森	大阪	福岡
1. 資料の記述	0	82	9	0	0	15	1
2. 名前の列挙	51	1	40	13	39	42	11
3. 記号つきの非発言	47	3	14	54	0	10	39
4. 実際の発言	15	14	26	22	61	33	49

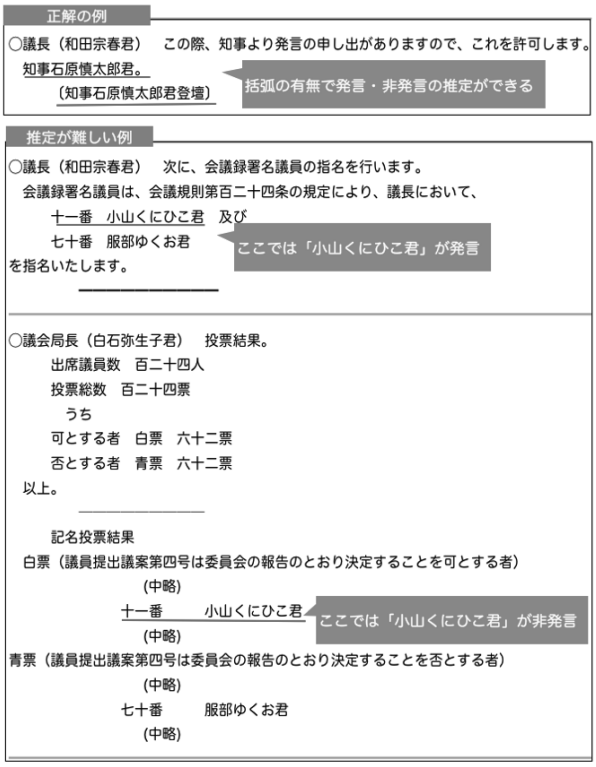


図３　実験 1 における正解例および誤りの例

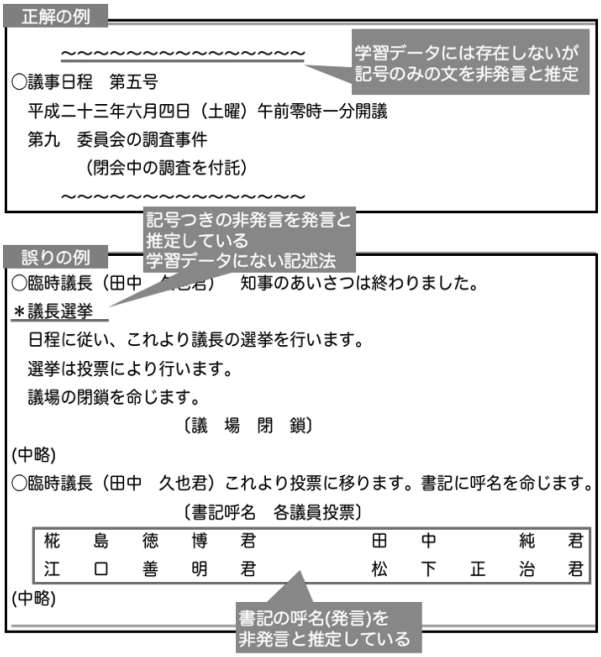


図４　実験 2 における正解例および誤りの例

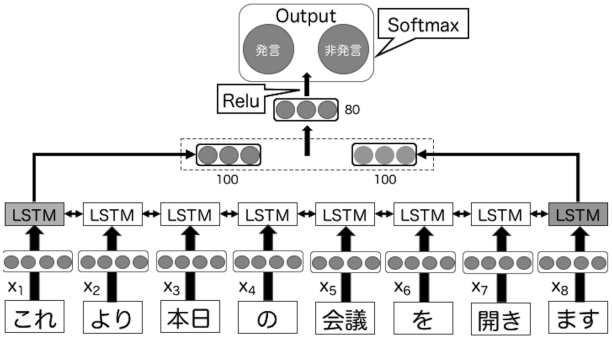


図５　LSTM のモデル図

例として，図 3 の下部が挙げられる．図 3 には「十一番　小山くにひこ君」という文が二箇所ある．前者は議長の発言であり，後者は資料中の記述である．このように，文脈によって発言か非発言か変わってしまうものについては，自動推定することが困難であった．

実験 2 の結果の例を図 4 に示す．図 4 の上部に波線だけからなる「～～～（後略）」という区切り線がある．学習データである，東京都のデータにはこのような区切り線はなかったが，記号のみという情報で非発言に推定できている．図 4 下部の「*議長選挙」は記号から始まっている非発言であるが，学習データにはない記述法であるため，発言と誤っている．また赤線で括られている「梶 島 徳 博 君（後略）」という部分は，書記の呼名（発言）である．しかし，学習データでは，氏名のみの発言文は資料中に多く存在するため，非発言と誤って推定している．

本節では，4 つの自治体を対象に 4 年間分のデータで学習を行った．2.1 節でも述べたように全ての自治体を対象とした場合，4 年間分のデータを用意することは難しいため，次節では，実用上のシチュエーションを想定し，1 年間分のデータを用いた実験を行う．

4. １年間のデータを利用した推定実験

4.1　実験の目的

本実験の目的は，実用性を考え，学習データを 1 年分にした場合の性能評価を行うことである．近年では，LSTM[11] が SVM よりも良いという研究結果がある [12]．そこで，本実験では，東京都議会会議録の 1 年間のデータを用いて，実験 1, 2 において最も精度の高い手法であった SVM と LSTM の比較実験を行い，どちらの精度が高いかを確認する．

4.2　実験方法

本実験では，LSTM を用いて発言文の推定を行う．また，実験 1，2 で最も結果の良かった SVM との比較も行う．SVM には実験 1 と同様の方法で作成した特徴語ベクトルを使用する．また，今回は，双方向の LSTM（bi-directional LSTM[13]）を用いた．LSTM のモデルを図 5 に示す．LSTM には，Mecab を用いて，発言文を形態素に分割する．実験 1 と同様に，形態素誤りは修正を行わず，そのまま使用する．分割した形態素ごとに，word2vec を用いて特徴語ベクトルを作成する．作成し

た特徴語ベクトルを LSTM の入力データとする．発言文の最初と最後の形態素を入力とした，100 次元の LSTM の出力を合わせて 200 次元のベクトルを作成する．200 次元のベクトルを入力とし，80 次元のベクトルに出力する．この 80 次元のベクトルを入力とし，2 次元のベクトルに活性化関数を使用して出力する．最後に，出力された 2 次元のベクトルに再度，活性化関数を使用して，発言，非発言の 2 値の出力とする．実験データを，訓練データ，開発データ，評価データに分け，開発データを使用して最適パラメータの探索も行う．評価方法は実験 1 と同様である．

4.3 実験データ

実験データを表 8 に示す．実験データには，平成 24 年 4 月から平成 25 年 3 月までの定例会を対象とした会議録を使用する．対象期間において，第一回定例会から第四回定例会までである．第一回，第二回定例会のデータを訓練データとし，第三回定例会のデータを開発データ，第四回定例会のデータを評価データとする．

4.4 最適パラメータの探索

本節では，LSTM と SVM の最適パラメータを探索する．訓練データを用いて学習を行い，開発データを用いてテストを行う．評価には，F 値を用いる．LSTM では，unit 数，隠れ層の活性化関数，出力層の活性化関数のパラメータ探索を行う．SVM では，コストパラメータ"C"とカーネル関数を scikit-learn の GridSearch を利用して最適パラメータを決定する．LSTM の最適パラメータの探索の結果を表 9 に示す．その結果，F 値の最も高い 40units，softmax 関数，Relu 関数を，評価データの判別に使用する．SVM においては GridSearch の結果，コストパラメータ"C"は 100，カーネル関数は linear が最も高くなった．SVM の評価データの判別にはこのパラメータを使用する．

4.5 実験結果

4.4 節において，LSTM および SVM の最適パラメータがわかった．このパラメータを使用し，評価データの発言，非発言を判別する．実験結果を表 10 に示す．4.2 節において，word2vec で特徴語ベクトルを作成できなかった発言文については評価データから除外している．表 10 からは，LSTM の平均正解率が 0.926 となり，SVM の平均正解率 0.865 よりも 0.061 高くなったことがわかる．本実験から，LSTM のほうが SVM よりも結果がよくなることがわかった．

4.6 考察

本節では，1 年間のデータを利用した推定実験において正解と不正解の多かった特徴的な例を挙げて考察を行う．3.4 節と同様に，SVM，LSTM について，誤りであったもの（FP，FN）からランダムに 100 件抽出し，誤りの分類を行なった．誤り分類の結果を表 11 に示す．誤りの分類については，3.4 節で述べたものと同様である．「2. 名前の列挙」については，SVM の方が少ない傾向にあった．また，「1. 資料の記述」，「3. 記号付きの非発言」については，LSTM の方が少ない傾向にあった．

表 8　1 年間のデータを利用した推定実験に使用するデータ

実験データ	対象自治体	対象年度	対象会議録	行数
訓練データ	東京都	平成二十四年度	第一回定例会	9,426
			第二回定例会	6,206
開発データ	東京都	平成二十四年度	第三回定例会	6,694
評価データ	東京都	平成二十四年度	第四回定例会	3,668

表 9　LSTM の最適パラメータ探索

40units		隠れ層の活性化関数	
出力層の活性化関数	評価値	tanh	Relu
log softmax	適合率	0.878	0.886
	再現率	0.973	0.966
	F　値	0.923	0.924
softmax	適合率	0.891	0.896
	再現率	0.974	0.976
	F　値	0.931	0.934
80units		隠れ層の活性化関数	
出力層の活性化関数	評価値	tanh	Relu
log softmax	適合率	0.887	0.887
	再現率	0.970	0.972
	F　値	0.927	0.928
softmax	適合率	0.888	0.889
	再現率	0.982	0.981
	F　値	0.933	0.933

表 10　LSTM と SVM の比較実験

手法	TP	FP	FN	TN	適合率	再現率	F 値	正解率
LSTM	1,461	206	56	1,816	0.876	0.963	0.918	0.926
SVM	1,463	441	54	1,710	0.768	0.964	0.855	0.865

SVM の正解例を図 6 に示す．図 6 の赤線で括られている，「在職二十年以上、比留間敏夫。（後略）」という部分は，議長の呼名である．SVM では読点が重要な情報になっており，そのため SVM では上手く推定できた．LSTM の正解例を図 7 に示す．図 7 の赤線で括られている，「衆議院議長　¬（後略）」という部分は，資料中の記述である．LSTM では，単語の文脈を考慮するため，文頭や文末に句点以外の記号がある場合には上手く推定できている．SVM，LSTM ともに不正解だった例を図 8 に示す．図 8 赤線で括られている，「一つは，職員の派遣です。（後略）」という部分は，箇条書きではない資料中の文章（非発言）である．このような文章には，実際の議員の発言が使われており．一文だけでは，議員の発言なのか，議員の発言を引用した資料なのか判断できない．そのため，その文の前後に，資料の記述である目印を見つけるなど，文中だけではなく，文を跨いだ情報を利用しなければ，推定が難しい．本実験で用いた SVM，LSTM はともに，一文だけを見て，発言か非発言かを推定しているため，このような例については，ともに推定できなかった．

1 年間のデータを学習データとした場合，SVM は汎化性能を高めることができず，記号付きの非発言を多く間違えてしまったと考えられる．それに対して LSTM は，少ない学習データでも学習することができ，SVM と比べて，資料の記述や，記号付きの非発言を上手く推定することができた．

表 11　実験 2 の誤り分類

誤りの分類	SVM	LSTM
1. 資料の記述	68	63
2. 名前の列挙	2	10
3. 記号つきの非発言	17	11
4. 実際の発言	13	16

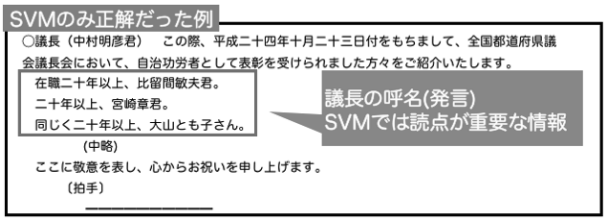


図 6　SVM の正解例

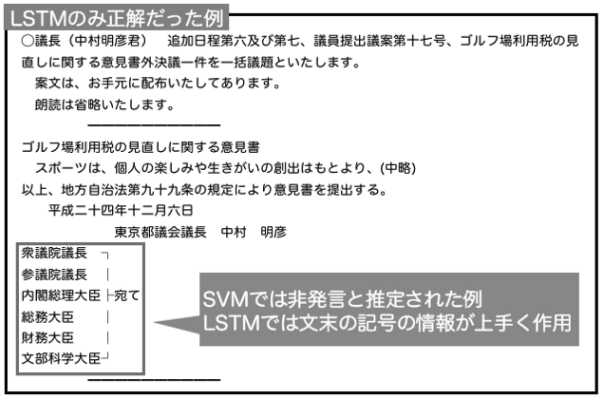


図 7　LSTM の正解例

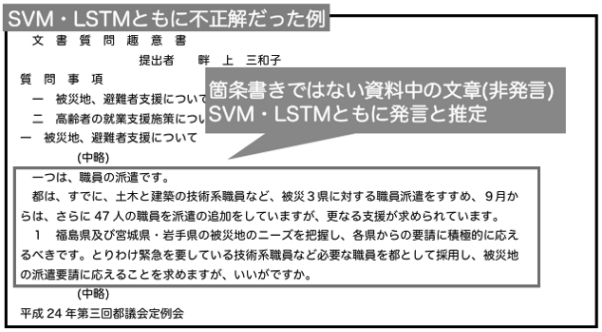


図 8　SVM・LSTM ともに不正解の例

5. おわりに

本論文では，正確な統計データの作成に向けて，地方議会会議録に含まれる発言および非発言の調査を行うとともに，発言文の自動推定の性能評価実験について述べた．4 年間のデータを利用した推定実験では，SVM が十分に学習を行えたため，高い汎化性能を示した．同一自治体の発言文の推定実験では，SVM の手法が最も高く，平均正解率 0.985 を得られるタスクであることを確認した．次に，1 つの自治体のデータがあれば，十分に精度が出せるかを確認するため，東京都のデータを学習データとして利用した実験を行なった．学習データと評価データを異なる自治体にした比較実験では，SVM の手法が，前実験と同様に最も高く，平均正解率 0.951 を得られるタスクであることを確認した．1 年間のデータを利用した推定実験では，LSTM の手法の場合，SVM の平均正解率よりも 0.061 高い，0.926 であることを確認した．1 年間のデータを利用した場合，LSTM の方が SVM よりも学習することができ，資料の記述や，記号付きの非発言を上手く推定することができた．以上の実験結果より，「発言文の推定」というタスクの難しさを明らかにした．また，一文のみで，発言か非発言か判断できないような文の推定は難しいことも明らかとなった．

今後は，そのような文に対し，前後の文脈を考慮した手法について検討する予定である．

謝辞

本研究は，JSPS 科研費 JP16H02912 の助成，および，国立国語研究所プロジェクト「議会会議録を活用した日本語のスタイル変異研究」の助成を受けたものです．

参　考　文　献

[1] 井原大将, 内田ゆず, 高丸圭一, 木村泰知, 江崎浩: “全地方議会会議録の横断検索に向けたデータ収集とデータ構造の検討,” 第 233 回自然言語処理研究会, 2017.
[2] 坂地泰紀, 酒井浩之, 小林暁雄, 内田ゆず, 乙武北斗, 高丸圭一, 木村泰知: “都道府県議会会議録からの意見や意志を表す発言の抽出," 言語処理学会第 23 回年次大会, pp.426-429, 2017.
[3] A. Kawaura, Y. Kimura, K. Takamaru, and Y. Uchida: “Elected Officials in the Local Assembly,” *Analysis of Prefectural Plenary Session Transcripts*, Doshisha University Center for the Study of the Creative Economy, Discussion Paper Series No.2018-02, 2018.
[4] 木村泰知, 内田ゆず, 高丸圭一: “都道府県議会会議録のパネルデータ作成に向けた発言者情報の付与,” 第 33 回ファジィシステムシンポジウム講演論文集, pp. 701-706, 2017.
[5] T. Kudo, K. Yamamoto, and Y. Matsumoto: “Applying Conditional Random Fields to Japanese Morphological Analysis,” *Proc. of the 2004 Conf. on Empirical Methods in Natural Language Processing*, pp. 230-237, 2004.
[6] S. Deerwester, S. Dumais, G. W. Furnas, T. K. Landauer, and R. Harshman: “Indexing by Latent Semantic Analysis,” *J. of the American Society for Information Science,* Vol.41, No.6, pp. 391-407, 1990.
[7] L. Breiman: “Random Forests,” *Machine Learning*, Vol.45, No.1, pp. 5-32, 2001.
[8] T. Hastie, R. Tibshirani, and J. Friedman: “The Elements of Statistical Learning: Data Mining, Inference, and Prediction,” *Springer-Verlag*, New York Berlin Heidelberg, 2001.
[9] V. N. Vapni: Statistical Learning Theory, A Wiley-Interscience Publication, 1998.
[10] 山田寛泰, 工藤拓, 松本裕治: “Support Vector Machine を用いた日本語表現抽出,” 情報処理学会論文誌, Vol.43, No.1, pp. 44-53, 2002.
[11] S. Hochreiter and J.Schmidhuber: “Long Short-Term Memory,” *Neural Computation*, Vol.9, No.8, pp. 1735-1780, 1997.
[12] H. Kuang, C. Che, Q. Zhang, and X. Wei: “LSTM based classification model and its application for doctor-patient relationship evaluation,” *2017 IEEE 19th Int. Conf. on e-Health Networking, Applications and Services*, pp. 1-5, 2017.
[13] X. Ma and E. Hovy: “End-to-end Sequence Labeling via Bi-directional LSTM-CNNsCRF,” *Proc. of the 54th Annual Meeting of the Association for Computational Linguistics*, Vol.1, pp. 1064-1074, 2016

（2018 年 5 月 1 日　受付）
（2018 年 10 月 3 日　採録）

［問い合わせ先］
〒047-0034　北海道小樽市緑 3-5-21
小樽商科大学
桧森　拓真
E-mail: takuma.himori@gmail.com

著 者 紹 介



桧森（ひもり）　拓真（たくま）［非会員］

現在，小樽商科大学在学中．自然言語処理の研究に従事.



木村（きむら）　泰知（やすとも）［非会員］

2004 年 9 月 北海道大学大学院工学研究科電子情報工学専攻 修了．2005 年 4 月-2007 年 3 月 小樽商科大学助教授．2007 年 4 月-2018 年 9 月現在 小樽商科大学准教授．2018 年 10 月-現在小樽商科大学教授．2010 年 10 月-2011 年 09 月 New York University 訪問研究員．2017 年 10 月-現在 理化学研究所 AIP センター客員研究員．自然言語処理の研究，特に，地方議会会議録を対象としたコーパス構築の整備に従事．電子情報通信学会，情報処理学会，人工知能学会，言語処理学会 各会員.



坂地（さかじ）　泰紀（ひろき）［非会員］

2012 年 豊橋技術科学大学大学院工学研究科博士後期課程 電子・情報工学専攻 修了．博士 (工学)．2012 年 株式会社ドワンゴ 入社．2013 年 成蹊大学 理工学部 情報科学科 助教．2017 年 東京大学 大学院工学系研究科 システム創成学専攻 助教．2018 年 東京大学 大学院工学系研究科 システム創成学専攻 特任講師．自然言語処理，特に，テキストマイニングの研究に従事．IEEE，人工知能学会，電子情報通信学会，言語処理学会等会員.



荒木（あらき）　健治（けんじ）［正会員］

1982 年北海道大学工学部電子工学科卒業.1988 年同大学大学院博士課程修了. 工学博士. 同年，北海学園大学工学部電子情報工学科助手.1989 年同講師.1991 年同助教授.1998 年同教 授.1998 年北海道大学大学院工学研究科電子情報工学専攻助教授 .2002 年同教授. 現在北海道大学大学院情報科学研究科メディアネットワーク専攻教授. 自然言語処理，特に，対話処理，機械翻訳，ユーモア処理などの研究に従事．日本知能情報ファジィ学会，電子情報通信学会，情報処理学会，人工知能学会，言語処理学会，日本認知科学会，ACL，IEEE，AAAI 各会員.

Performance Evaluation of a Method for Recognizing Utterances in Local Assembly Minutes

by

Takuma HIMORI, Yasutomo KIMURA, Hiroki SAKAJI, and Kenji ARAKI

Abstract:

We describe performance evaluation of a method for recognizing utterances in local assembly minutes. The experimental datasets were collected from local assembly minutes of four municipalities for 4 years from April 2011 to March, 2013. The four municipalities are Tokyo, Aomori, Osaka and Fukuoka. We manually annotated each sentence whether the sentence is an utterance or not. In the experiment using the data of 4 years, we conducted two experiments using the different dataset between learning data and test data. In other words, we used "data of same municipality" and "data of different municipalities" for the learning data and the test data. As a result, the average correct answer rate of SVM was the highest, 0.985, 0.951 respectively. In addition, we conducted an experiment for reducing learning data that the dataset consists of assembly minutes of one year. As a result, the average correct answer rate of LSTM was 0.926, which was 0.061 higher than the average correct answer rate of SVM.

Keywords: local assembly minutes, utterance, classification

Contact Address: **Takuma HIMORI**
Otaru University of Commerce
3-5-21 Midori, Otaru, Hokkaido 047-8501, Japan
E-mail: takuma.himori@gmail.com