The 33rd Annual Conference of the Japanese Society for Artificial Intelligence, 2019

講義代行システムにおける講義シナリオ自動生成のための会話コーパスを用いた質問文生成

Generation of Question Sentences Using Conversation Corpus for Automatic Generation of Lecture Scenario on Lecture Substitution System

芳尾 哲[*1] Satoshi Yoshio
荒木 健治[*1] Kenji Araki

[*1] 北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

A scenario of conventional lecture substitution systems is described by hand. Automatic generation of scenario makes it possible to generate scenario without a lot of labor, which is expected to lead to further progress in research on lecture substitution systems. This paper proposes the automatic question sentence generation method, the proposed method extracts questions from conversation corpus and replaces a noun with one of lecture corpus.

1. 研究背景

近年，高性能なヒューマノイドロボットの登場により，ヒューマノイドロボットを用いて講義を行う試み[橋本 2012]がなされている．しかし，講義時に用いるシナリオは人手で作成されたものであり，労力が大きくかかるのが現状である．そこで，我々の従来の研究[芳尾 2017]では，教科書の内容をもとにシナリオを自動生成することで，労力の削減を試みた．しかし，教科書から抽出した内容のみを用いた講義では，単調な口調でロボットが一方的に話すシステムであったことから，講義に飽きてしまう被験者が多いという結果となった．そこで，聞き手が飽きない講義を目指し，講義に変化をつけるため，講義シナリオに質問文を挿入することが必要であると考える．本研究は，そのような自動生成により作られた講義シナリオに挿入するための質問文を自動生成することを目指すものである．

2. 関連研究

日本語による講義のコーパスとして，土屋らが作成した日本語講義音声コンテンツコーパス(CJLC)がある[土屋 2009]．このコーパスは理系大学の講義の書き起こし，音声，スライドなどの情報を含んでおり，40 分以上の長さの講義を 7 回分収録している．また，日本語による会話のコーパスとして，藤村らが作成した名大会話コーパスがある[藤村 2012]．このコーパスは，129 会話(約 13 万， 合計約 100 時間の日本語母語話者同士の雑談を文字化したコーパスである．本研究では，CJLC を講義文データ，名大会話コーパスを質問文データとして用い，これらを基にして講義で用いる質問文の自動生成を行う．コーパスを用いることで，多様な質問文の生成が期待される．

3. 質問文の生成

3.1. 用いるデータ

質問文データとして，名大会話コーパス中の，文末に「？」が付いている質問文と考えられる発話のみを抽出する．さらに，それらの文を MeCab[Kudo 2004]で形態素解析し，名詞を 1 つのみもつ文のみを抽出した．また，感動詞を含むものを除外した．これは，感動詞を含む質問文が講義という形式に適さないと考えられるためである．以下にその例を示す．

例1. **ふーん**，どういう機能？
例2. **えーっ**，そういう時ってびびらない？

「えーっ」，「ふーん」，などの感動詞は主に会話において相手に対する反応として使われる表現であり，講義のように話し手が一方的に話す場合の表現としては適さないと考えられる．また，名詞1つと「？」のみの文を削除した．例を以下に示す．

F023：中のお店は普通のショップなんだけど，床が．あのー
M023：**木？**
F023：木で，フロアとかが木で，で，このところの柱も木で．

このような質問文は前後の文が密接に対応していなければならないため，講義シナリオに挿入するという目的には不適切であると考えたためである．そして最後に，コーパスに元々含まれる話者 ID を削除した．この手順により，結果として 2,798 文の質問文を得た．

また，講義文データとしては，CJLC の書き起こしデータを XML 形式から 1 発話ごとに分けて発話のリストを構築した．まず，XML の〈Utterance〉タグで囲まれている部分の発話文を抽出し，〈Utterance〉タグ 1 つにつき 1 発話とした．発話文を抽出する際，フィラーや言い直しなどのタグは削除した．これは，その後の形態素解析で正しい結果が得られないことに繋がる場合があることや，言い直しのような訂正された部分が入ることは不適切だと考えたためである．上記の手順により，講義文データとして 5,376 文の講義文を得た．講義文データの例を図 1 に示す．

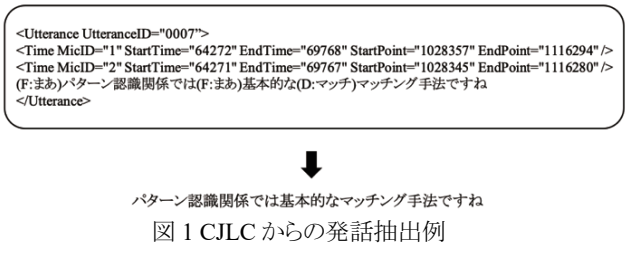


図 1 CJLC からの発話抽出例

連絡先： 北海道大学大学院情報科学研究科メディアネットワーク専攻
北海道札幌市中央区北 14 条西 15 丁目 2-10
E-mail: syoshio@eis.hokudai.ac.jp

3.2 質問文生成の処理過程

日本語講義音声コンテンツコーパスの書き起こしデータの一発話ごとに，質問文生成を行うシステムを構築した．質問文生成の処理過程を図 2 に示す．

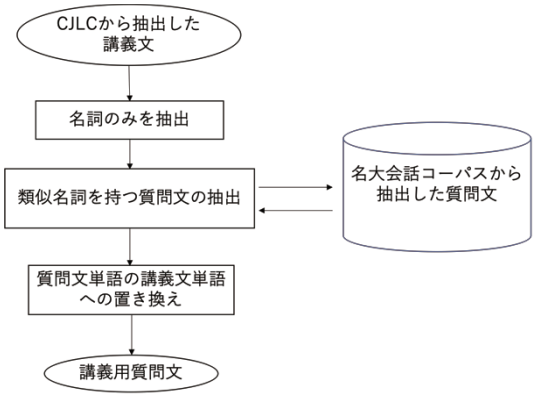


図 2 質問文生成の処理過程

まず，講義文データの 1 発話ごとに，含まれている名詞を抽出する．次に，その名詞と名大会話コーパスから得た質問文中の名詞との単語分散表現間のコサイン類似度がしきい値(今回は 0.6 とした)を超えた場合，質問文中の名詞を講義文中の名詞で置き換えることで新しい質問文を生成する．ここで，単語分散表現の生成ツールとして Word2Vec[Mikolov 2013]を用いた．Word2Vec の学習には，Wikipedia ダンプデータ*1(2018 年 2 月 7 日取得，2.6GB)と CJLC から抽出した発話文データを用いた．表 1 に質問文生成の例を示す．

表 1 講義文「情報理論とここらこの四五なんかは情報理論と関係があります」の質問文生成例

ID	変換前の単語	変換後の単語	コサイン類似度	生成文
生成文 1	記号論	情報理論	0.62	情報理論っておもしろい？
生成文 2	数学	情報理論	0.63	あーあー，情報理論でー？

名大会話コーパスから取得した質問文リストから，講義コーパス文の単語「情報理論」に対してしきい値 0.6 以上のコサイン 類似度を持つ単語を持つ質問文を取得する．これにより，「記号論っておもしろい？」という質問文を取得する．次に，質問文の単語を講義発話文の単語に置き換え，意味的に類似した名詞に置き換えることで，最終的に講義文に応じた質問文「情報理論っておもしろい？」を生成する．

3.3 ストップワードを含む質問文の除外

名詞を置き換え対象にする場合，一般的な名詞(例:「こと」，「もの」，「ため」)同士は単語分散表現が類似しているため，数多く置き換え可能と判断されてしまう．また，このような一般的な単語はどのような文脈においても出現しやすい．そのため，不適切な質問文が生成される原因となる．そのため，本手法ではこれらの一般的な名詞を含んだ質問文を除外している．一般的な名詞かどうかの判定には，SlothLib*2 が提供する日本語ストップワードのリストを用いており，上記の例は全て含まれている．

4. 結果と考察

提案手法によって生成された質問文について考察を行う．まず，生成された質問文のうち，講義文に対して妥当だと考えられる質問文について考察する．

まず，表 1 のような，用語の置き換えによって，元々質問文データにはなかった専門用語を用いた質問文を生成することができた．ただし，このような例は一般的な名詞に比べると少なく，質問文データを日常会話のコーパスから抽出したためか，講義文中の専門用語とコサイン類似度が高い値になるような名詞を持つ質問文が少なかったため，一般的な名詞を使った質問文の方が多く生成された．一般的な名詞を使った質問文で妥当なものの例を表 2 に示す．

表 2 講義文「そう．，携帯電話の中継塔ですよね」の質問文生成例

ID	変換前の単語	変換後の単語	コサイン類似度	生成文
生成文 1	電話番号	携帯電話	0.62	携帯電話持ってる？
生成文 2	インターネット	携帯電話	0.62	携帯電話よく使ってる？

これらの例はいずれも知識を問う質問文ではないが，本研究の目的である聞き手の興味を引くという役割の質問文となっており，これらの例は良い生成結果であると言える．しかし，今回質問文データとして用いた名大会話コーパスは少人数での会話コーパスであったため，講義で大人数を相手に話をする場合の言い回しとは異なっており，少し違和感のある質問文となっているものが多かった．その解決策として，上記の例1では，文頭に「皆さんは，」などの大人数に向けたフレーズを追加することで，「皆さんは，携帯電話持ってる？」のように違和感を軽減した質問文が生成できると考えられるため，今後はこのような手段も検討したい．

また，以上のような講義文に対して妥当な質問文が生成された一方で，妥当でない質問文も生成された．以下に妥当でない質問文の例を表3に示す．この例の「推論を？」や「研究を？」のように，非常に文が短かく情報が少ないために質問の意味がわからない例が数多く見られた．今後はこのような文を除去するために，適切な文字数や単語の数についても検証したい．

*1 https://dumps.wikipedia.org/jawiki/latest

*2 http://svn.sourceforge.jp/svnroot/slothlib/CSharp/Version1/SlothLib/NLP/Filter/StopWord/word/Japanese.txt

表 3 講義文「ただ定理証明のこれいろいろな推論のこと推論が形式的にできることが非常にいろんな研究されてますんでそういう意味では対話の推論の部分ではうまく」の質問文生成例

ID	変換前の単語	変換後の単語	コサイン類似度	生成文
生成文 1	考察	研究	0.67	研究を？
生成文 2	考察	推論	0.64	推論を？

また，意味的に明らかに間違っている文が生成されてしまう場合もあった．以下がその例である．

表 4 講義文「横に何個進んだか，標準パターンです．これ入力パターンね」の質問文生成例

ID	変換前の単語	変換後の単語	コサイン類似度	生成文
生成文 1	ボタン	入力	0.63	入力咲いた？

この原因は，本提案手法では名詞という品詞情報しか考慮していないためである．実際には表 5 に示すように，「ボタン（牡丹）」と「入力」では MeCab が出力する詳細な品詞情報は異なっている．

表 5 MeCab による形態素情報

表層形	品詞情報 1	品詞情報 2
ボタン	名詞	一般
入力	名詞	サ変接続

この問題の解決策として，MeCab により得られる品詞情報のより詳細な情報も一致しているかどうかも名詞の置き換え可能な条件に含めることが考えられる．また，その他にも，名詞同士の置き換えの条件であるコサイン類似度のしきい値を調整することや，今回行なっていない複数の名詞を含む質問文の生成も試みることで，妥当でない生成文を減らし，妥当な生成文を増やすことができると考えられる．

5. まとめ

異なる2つのコーパスを基にし，講義で用いるための質問文を生成した．生成された質問文の中には講義コーパス中に挿入するには妥当でない文も多かったが，有効なものも確認できた．今後の課題としては，生成された質問文が妥当なものであるか，生成した質問文を講義中のどの場所に挿入するかを自動判定することが挙げられる．それらの実現のために，学習データを作成し，SVM などの機械学習手法を用いることを予定している．

参考文献

[橋本 2012] Takuya Hashimoto, Igor M. Verner, Hiroshi-Kobayashi, Human-Like Robot as Teacher's Representative in a Science Lesson: An Elementary School Experiment, Robot Intelligence Technology and Applications, pp.775-786, 2012.

[芳尾 2017] 芳尾哲，荒木健治，“ヒューマノイドロボットを用いた講義代行システムのための講義シナリオ文自動生成手法”，電気・情報関係学会北海道支部連合大会，pp218-219, 2017.

[土屋 2009] 土屋雅稔，太田健吾，小暮悟，山本一公 ,西崎博光，中川聖一，“日本語講義音声コンテンツコーパスの作成と分析”，情報処理学会論文誌 Vol. 50 No. 2 448-459 2009

[藤村 2012] Fujimura Itsuko, Shoju Chiba, Mieko Ohso, Lexical and Grammatical Features of Spoken and Written Japanese in Contrast: Exploring a lexical profiling approach to comparing spoken and Written corpora, Proceedings of the VIIth GSCP International Conference. Speech and Corpora, p393-398, 2012.

[Kudo 2004] Taku Kudo, Kaoru Yamamoto, Yuji Matsumoto: Applying Conditional Random Fields to Japanese Morphological Analysis, Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP-2004), pp.230-237, 2004.

[Mikolov 2013] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S. Corrado, Jeff Dean, Distributed representations of words and phrases and their compositionality, In Advances in neural information processing systems, pp. 3111-3119, 2013.