# 日本語の単語埋め込みにおける 文字種による性別バイアスの相違の分析及び緩和の試み

Attempt to Analyze Differences in Gender Bias by Character Type in Japanese Word Embedding and to Mitigate the Bias

竹下昌志[1]，ジェプカ・ラファウ[2]，荒木健治[2]

Masashi Takeshita[1], Rafal Rzepka[2], Kenji Araki[2]

[1] 北海道大学大学院情報科学院，[2] 北海道大学大学院情報科学研究院

[1]Graduate School of Information Science and Technology, Hokkaido University, [2]Faculty of Information Science and Technology, Hokkaido University

## 1 まえがき

word2vec[1] を代表として，自然言語処理分野では単語埋め込みが広く用いられている．しかし単語埋め込みには，事前学習に用いられるコーパスに内在する社会的バイアスが影響を及ぼす [2]．例えば，人は「プログラマ」は男性の仕事，「主ふ」[*1]は女性の仕事であると類推してしまう．同じことが単語埋め込みでも起きる [2]．しかしどちらの単語も性別に無関係であるべきであり，このような類推の成立には問題がある．そこで近年，単語埋め込みに内在する性別バイアスを緩和する研究が行われている [2]．だが既存研究のほとんどは英語の単語埋め込みを対象としており，日本語を対象に分析・緩和した研究は存在しない．そこで本稿では，事前学習済みの日本語版 word2vec[3] を対象として，文字種によって性別バイアスが異なるかどうかを分析し，既存手法 [2] を用いて性別バイアスの緩和を行う．

## 2 関連研究

Bolukbasi らは，単語埋め込みに性別バイアスが内在していることを示し，それを緩和するために Hard Debias を提案した [2]．また先行研究のほとんどは英語の単語埋め込みを対象としているが [4]，言語の特徴によって性別バイアスの特徴が異なる可能性がある．例えば日本語ではひらがなや漢字など文字種が複数あり，それによって性別バイアスが異なる可能性がある．そこで我々は，単語埋め込みに含まれる性別バイアスの分析を行い，文字種によって性別バイアスが異なるかを調査する．次に Hard Debias を用いて性別バイアスの緩和を試みる．

## 3 実験方法

本章ではまず単語に含まれる性別バイアスの分析手法を説明し，次に Hard debias について説明する．

### 3.1 実験設定

単語埋め込みには Web 上で公開されている日本語 Wikipedia エンティティベクトル [3] を用いる[*2]．また我々は分析対象として，既存研究にしたがって使用頻度の最も高い 5 万語を選び [2]，ひらがなのみ，カタカナのみ，漢字のみで構成される単語を正規表現を用いて抽出する．抽出の結果，ひらがなのみの単語は 2,214 語，カタカナは 4,684 語，漢字は 18,523 語となった．分析には，各単語と，「女」と「男」の埋め込みベクトルの余弦類似度の差を用いる．そしてその文字種全ての単語の余弦類似度の差の平均値と標準偏差が異なるかを調査する．我々は，ひらがなは女性的なイメージがあるため「女」との類似度が高く，カタカナや漢字はどちらの性別を表すことにも使われるため平均値は 0 に近いだろうと仮定した．

### 3.2 バイアス緩和手法：Hard Debias

単語埋め込みに含まれる各単語を以下のように定義する [2]．まず「女優」や「父」のように性別を含意する単語を性別固有語と定義し，他のすべての単語を性別中立語と定義する．次に，性別固有語から性別の意味のみが異なる単語ペアを選び，性別定義ペアと定義する．ペアの例として，「彼女」と「彼」や「母」と「父」などがある．そして各性別定義ペアのベクトルの差をとり，それらに主成分分析を行い，第一主成分を性別方向とする．

Hard Debias は，性別中立語の単語ベクトルを性別方向に射影し，射影後のベクトルを元のベクトルから減算することで性別バイアスを緩和する手法である [2]．我々はこれを用いて単語埋め込みの性別バイアスを緩和する．

Bolukbasi らの提案した Hard Debias では，すべての単語ベクトルの大きさが 1 に正規化されており，また性別方向成分の減算後に「母」と「父」のように性別方向に関して対称的である単語ペアに対して「平等化」という計

[*1] 原語は “homemaker” であり，英語ではこれは性別中立語であるが，「主婦」と訳すと中立ではなくなる．ポリティカルコレクトネスを考慮し，「主婦」と「主夫」のどちらもを意味する性別中立語として「主ふ」とした．

[*2] 我々は以下の Web ページの 2017 年 2 月 1 日版を用いる．http://www.cl.ecei.tohoku.ac.jp/~m-suzuki/jawiki_vector/[閲覧日：2020-09-07]

表 1　各文字種の性別バイアスの平均と標準偏差．平均値が正の値であれば「女」に，負の値であれば「男」に全体的に類似していることを意味する．

| 文字種 | ひらがな | | カタカナ | | 漢字 | |
|---|---|---|---|---|---|---|
| 単語埋め込み | 平均 | 標準偏差 | 平均 | 標準偏差 | 平均 | 標準偏差 |
| word2vec | 0.0256 | 0.0486 | -0.0273 | 0.0482 | 0.002014 | 0.04805 |
| Hard debiased word2vec | 0.0221 | 0.0442 | -0.0254 | 0.0459 | 0.002013 | 0.04616 |

算を行う．しかし Ethayarajh らは，単語を正規化すべきでないという指摘を行っている [5]．また我々は，一般に単語ペアを十分に特定するのは現実的ではないと考える．そのため我々は正規化および平等化を行わない．

バイアス緩和の評価には各文字種の性別バイアスの平均と標準偏差の変化を調査する．値が 0 に近づけば性別バイアスを緩和できていることを意味する．

## 4　実験結果

実験結果を表 1 に示す．平均値が正の値であればその文字種の単語は全体として「女」に類似し，負の値であれば「男」に類似することを示している．実験の結果，Hard Debias によって全ての文字種で平均値と標準偏差が 0 に近づき，バイアス緩和できていることがわかった．

## 5　考察

3 章で述べたように，我々は，ひらがなは女性的であり，漢字は中性的であると考えた．実験結果は我々の仮説を支持する．一方でカタカナの平均値は負の値であり，全体として「男」に類似している．そこでカタカナの単語のうち，使用頻度が最も高い 10 個の単語の余弦類似度の差を表 2 に示す．10 個中 8 個の単語が負の値をもっており，全体的に「男」に類似している．表 2 より，カタカナの単語で使用頻度の高い単語には，スポーツや歌手についての単語が多いことがわかる．これらの単語が「男」に類似していることから，スポーツや歌手についての他の単語も「男」に類似しており，それゆえカタカナの単語は全体として「男」に類似していると考えられる．

表 2　使用頻度が高い 10 個のカタカナの単語の余弦類似度の差を小数点第三位で四捨五入した値．

| 単語 | 余弦類似度の差 |
|---|---|
| チーム | -0.091 |
| シーズン | -0.065 |
| シリーズ | -0.013 |
| デビュー | 0.007 |
| アメリカ | 0.001 |
| アルバム | -0.064 |
| メンバー | -0.095 |
| グループ | -0.082 |
| リリース | -0.053 |
| システム | -0.080 |

## 6　まとめ

本稿では日本語の単語埋め込みの性別バイアスの分析を行い，全体としてひらがなは女性的，カタカナは男性的，漢字は中性的であることが確認された．また性別バイアスの緩和を試み，全ての文字種で緩和できた．今後は全体ではなく個々の単語の持つバイアスを分析する．

## 参考文献

[1] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. and Dean, J.: Distributed Representations of Words and Phrases and Their Compositionality, *Proceedings of the 26th International Conference on Neural Information Processing Systems - Volume 2*, Red Hook, NY, USA, Curran Associates Inc., pp. 3111—3119 (2013).

[2] Bolukbasi, T., Chang, K.-W., Zou, J., Saligrama, V. and Kalai, A.: Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings, *Proceedings of the 30th International Conference on Neural Information Processing Systems*, Red Hook, NY, USA, Curran Associates Inc., pp. 4356—4364 (2016).

[3] 鈴木正敏，松田耕史，関根　聡，岡崎直観，乾健太郎 Wikipedia 記事に対する拡張固有表現ラベルの多重付与，言語処理学会第 22 回年次大会 (NLP2016)，pp. 797–800 (2016).

[4] Blodgett, S. L., Barocas, S., Daumé III, H. and Wallach, H.: Language (Technology) is Power: A Critical Survey of “Bias” in NLP, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, Online, Association for Computational Linguistics, pp. 5454–5476 (2020).

[5] Ethayarajh, K., Duvenaud, D. and Hirst, G.: Understanding Undesirable Word Embedding Associations, *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, Florence, Italy, Association for Computational Linguistics, pp. 1696–1705 (2019).