論文の構造とタイトルを独立して考慮した医学論文検索モデルの提案

Medical Publications Retrieval Model Considering Paper Structure and the Title Separately

吉井瑞貴 [1] , 竹下昌志 [1]，ジェプカ・ラファウ [2]，荒木健治 [2]

Mizuki Yoshii[1], Masashi Takeshita[1], Rafal Rzepka[1], Kenji Araki[1]

[1] 北海道大学大学院情報科学院,[2] 北海道大学大学院情報科学研究院

[1] Graduate School of Information Science and Technology, Hokkaido University,

[2]Faculty of Information Science and Technology, Hokkaido University

1　概要

近年，医療情報をインターネット上のニュース記事で収集するケースが増えており，その際には，記事の信憑性を見極めることが重要である．記事の信憑性を調べる方法の一つとして，記事の主張の根拠となる適切な論文の有無を検索する方法がある．本研究では，記事の見出しと記事で引用されている論文が対になったデータを用いて，記事の見出しから引用論文を検索するタスクに取り組む．我々は本タスクに取り組むにあたって，論文アブストラクトの構造を生かしたモデルを作成し，実験を行なった．その結果，既存手法を超える検索精度を実現し，アブレーションスタディを行うことで提案手法の有効性を検証した．

2　はじめに

近年，医療情報をインターネット上で収集するケースが増えている [1]．その中でも，医療ニュース記事で情報収集を行うケースが多いことがわかっており，オンライン上の医療ニュース記事が，研究調査から得られた医学的知見を広める役割を果たしていると言える [2]．しかし，それと同時に根拠のない主張をしている記事も存在しているため，記事の信憑性を判断することが重要である．記事の主張の根拠となる論文の有無で信憑性を判断する方法があるが，本研究で用いるデータセット [3] の作成時の調査で，信頼性のある論文を引用したケースは 24.6%（17,712 件/72,028 件）しかなかったことがわかっている．

そこで，本研究では，記事の見出しを用いてその記事の主張の根拠となる論文の有無を検索することを目的としている．本研究では，その第一段階として，記事の見出しとその記事で引用されている論文のアブストラクトがセットとなっているデータを用いて，記事の見出しの情報を元に，引用論文を検索するタスクに取り組む．このタスクを解く際には，計算時間の短縮のため，**3.1** で述べるようにタスクを (Ⅰ) 候補抽出タスクと (Ⅱ) リランキングタスクの二段階に分けることが多い [4, 5].

本研究では，(Ⅰ) の候補抽出タスクで抽出された論文アブストラクトを用いて (Ⅱ) のリランキングタスクに取り組み，計算時間と精度のトレードオフを考慮したモデルと論文の特徴を生かしたモデルの作成を行う．そして，データセットを用いて実験を行い，結果を考察することで，記事の根拠論文抽出を行う際に最良のモデルを分析する．

3　関連研究

3.1　医療分野における情報検索

医療分野においては，専門用語が多く使われている，論文が多数存在するなどドメイン固有の特徴が存在するため情報検索においても，その特徴を生かした多様な研究が行われている．Zheng ら [6] は，近年，健康情報の入手が可能な電子健康記録 (EHR) システムの発達に焦点を当て，ニューラルネットワーク手法を用いて EHR の可読性の評価を行った．Rae ら [7] は，研究医学論文への索引付けを，医療文献でトレーニングされた BioBERT[8] や PubmedBERT[9] を用いて行う手法を提案した．Mohan ら [10] は，医学文献では，一つの概念を表現する複数の技術的な語彙が存在することに着目し，キーワード形式のクエリに対する医学文献の関連性を評価するモデルを提案した．Zamil ら [11] は，ユーザーからの最小限の入力で、文脈に基づく検索とランキングのパフォーマンスを最大化するために，医学・臨床文書間の意味的関係を抽出するモデルを提案した．医療分野に特徴的な研究は行われているが，その際使用されているアルゴリズムは一般的な情報検索タスクで用いられる手法である．そのため，本研究では，論文の特徴を生かしたモデルの作成を行う．

3.2　一般的な情報検索

一般に，情報検索を行う際には，クエリを元に膨大なデータから関連するドキュメントを抽出するため，タスクを (Ⅰ) 候補抽出タスクと (Ⅱ) リランキングタスクの二段階に分けることが多い [4, 5]．(Ⅰ) の候補抽出タスクでは，記事見出しに関連するとされる論文アブストラクト

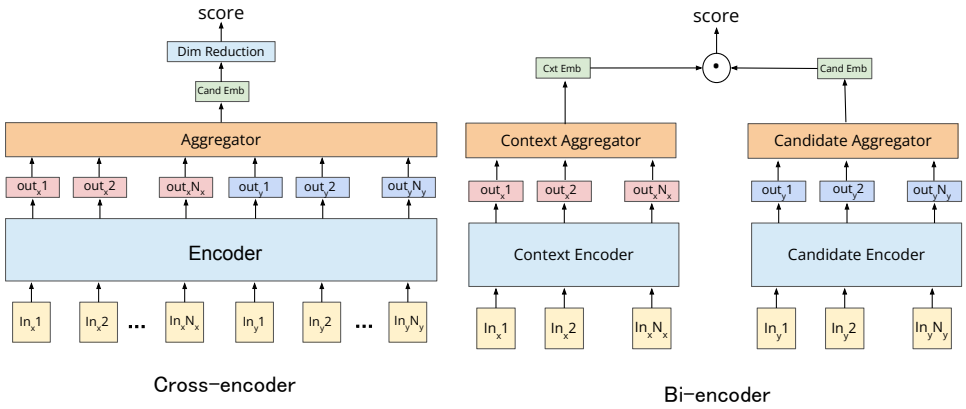


図 1: Cross-Encoder と Bi-Encoder．In_x がクエリトークン，In_y がドキュメントトークンを表している．Bi-Encoder では，独立に得られたクエリとドキュメントの分散表現を用いて内積を計算し，スコアを求めている．

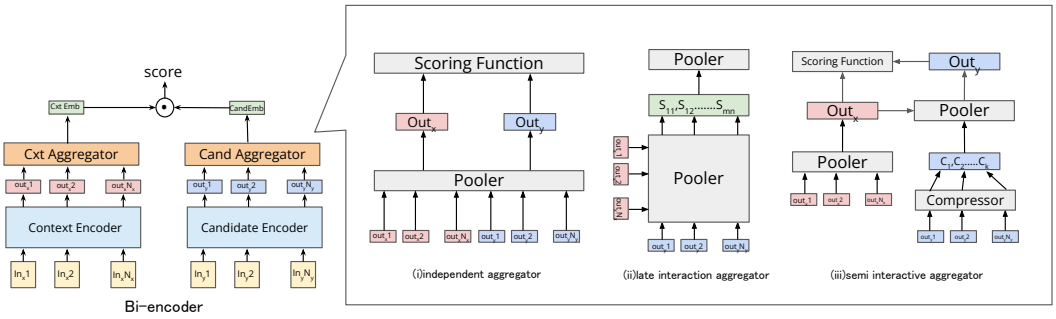


図 2: Bi-Encoder Aggregators． Bi-Enocoder は，ドキュメントとクエリの分散表現が計算された後に入力される aggregator が 3 種類存在する．[12]

の候補を抽出する (例:500 個)．(Ⅱ) のリランキングタスクでは，(Ⅰ) で抽出した候補を用いてリランキングを行う．(Ⅰ) のタスクを分けることによって検索空間を縮小することができ，(Ⅱ) リランキングタスクの計算時間を短縮することができる．

情報検索を行う際の手法には，トークンベースの手法とニューラルネットワークの手法が存在する．トークンベースの手法では，単語の一致度や単語の出現頻度を用いてクエリとドキュメントの類似度を計算する [13, 14, 15, 16]．その結果，クエリとの単語の一致度が高いドキュメントや，重要な単語を複数回使用しているドキュメントには高いスコアが算出されることになる．さらに，学習データが必要なく，計算時間も比較的短いことが特徴である．しかし，単語単位の検索では意味表現を考慮することができないため，検索精度に限界がある．それに対して，ニューラルネットワークの手法では，クエリとドキュメントをニューラルネットを用いたエンコーダーにより分散表現にすることによって，意味表現を表すベクトル同士のスコア計算を行う．この手法では，意味表現を考慮したスコア計算が可能となるため，トークンベースに比べ検索精度が高くなるという特徴がある．しかし，高い検索精度を出すためには学習データが必要であり，さらに計算時間も膨大となる．

リランキングの手法では，正しいアブストラクトを上

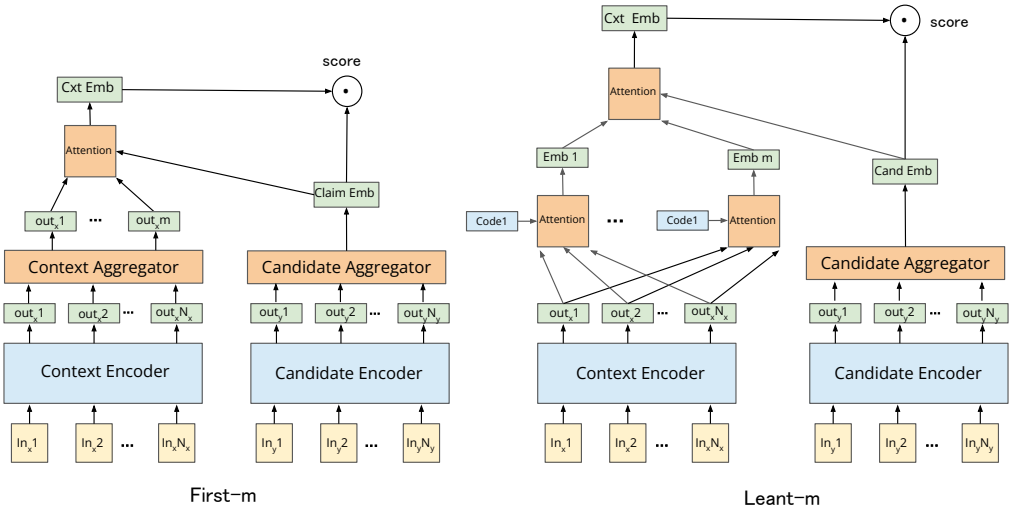


図 3: Poly-Encoders. ドキュメントの最初の m 個のトークンを圧縮された分散表現とするモデルを First-m とする．m 個のコードベクトルを用いて圧縮するモデルを Leant-m とする．

位にリランキングすることが重要であるため，意味表現を考慮でき，高い検索精度を出すことができるニューラルネットワークの手法を用いることが多い．ニューラルネットワークの手法では，エンコーダーの種類で多様な研究がされているが，精度を高くすると計算時間が長くなり，計算時間の短縮を実現すると精度が低くなるという問題がある．以下では，既存のエンコーダーの種類とその特徴について説明する．

3.3 Cross-Encoder

クエリとドキュメントを連結してエンコードする方法である [17, 18]．この方法は，クエリとドキュメントが双方の意味表現を考慮した分散表現を作成することができるため，精度が高くなるという特徴がある．しかし，毎回クエリとドキュメントを連結してエンコードしなければならないため，同じクエリやドキュメントに対して複数回分散表現の計算を行わなければならず，計算時間が膨大となる．

3.4 Bi-Encoder

クエリとドキュメントを独立してエンコードする手法である [19, 20]．この手法は，あらかじめクエリとドキュメントをそれぞれエンコードし，分散表現の形にしたデータを保存することが可能であるため，計算時間の縮小が可能であることが特徴である．しかし，クエリとドキュメントを独立にエンコードしているため，クエリとドキュメントの双方の意味表現を考慮した分散表現を作成できず，精度は Cross-Encoder に比べ劣る．Bi-Encoder には，クエリとドキュメントの分散表現の計算の後，各文で一つずつの分散表現にするために aggregator の段階が存在する．aggregator の種類は 3 種類存在する [12].

3.4.1 Independent-aggregator[21]

クエリとドキュメントをトークンごとに分散表現にした後，それぞれを 1 つの分散表現に pooling し，スコア計算を行う手法である．Pooling には max-Pooling（分散表現の最大値を取る方法）や mean-Pooling（分散表現の平均を取る方法）が存在するが，いずれの方法においても，分散表現を大幅に圧縮することになるため，情報損失が大きく，精度が低くなる傾向がある．しかし，スコア計算を 1 回のみ行うため，計算時間をかなり短縮することができる．

3.4.2 Late-interaction aggregator[22]

クエリとドキュメントをトークンごとに分散表現にし，全てのトークン同士ののスコア計算を行い，最終的にスコアを Pooling する手法である．全てのクエリとドキュメントのトークン同士のスコア計算を行うため，精度は高くなるが，計算時間が膨大となる．

3.4.3 Semi-interactive aggregator[23]

テキストサイズの大きいドキュメントの分散表現を一定の大きさまで圧縮することを特徴とする計算方法である．クエリとドキュメントをトークンごとに分散表現にした後，ドキュメントの分散表現を圧縮し，その圧縮された分散表現にクエリによるアテンションをかけることによって，一つの分散表現にし，クエリとのスコア計算

を行う．この方法は，計算時間と精度のトレードオフを考慮しながらモデルの考案が可能である．

■Poly-Encoder[24]　Semi-interactive aggregator を用いたモデルに Poly-Encoder がある．Poly-Encoder には First-m と Leant-m の二つのモデルが存在する．First-m モデルでは，ドキュメントの最初の m 個の分散表現を圧縮された分散表現とする．Leant-m モデルでは，ドキュメントの分散表現を圧縮する際にコードベクトルを用いることによって，m 個の圧縮された分散表現を作成する．双方のモデルで作成した圧縮されたドキュメントの分散表現を，クエリによってアテンションをかけることによって，1 つの分散表現にする．そして最終的に，クエリとドキュメントの分散表現の内積を取ることによってスコアを計算する．

Semi-interactive aggregator は計算時間と検索精度のトレードオフを考慮することができるが，ドキュメントの圧縮を行うため，情報損失が起こっている可能性が高い．特に論文アブストラクトでは，アブストラクトの最後に”conclusion”が存在し，その論文での主張が記述されているため，圧縮された際に欠損してはいけない情報である．そのため，Poly-Encoder（First-m）で，ドキュメントの最初の k 個のトークンの分散表現を抽出することは本研究で用いるデータセットには用いるべきではないと言える．

我々は，論文の特徴に着目し，論文アブストラクトの構成や論文タイトルを生かしたモデルの作成を行うことで，より引用論文検索に特化したモデルの提案を行う．

4　データセット

今回使用するデータセットは Zuo ら [3] によって公開されたデータセットであり，医療ニュース記事の見出しとそれに対応する論文のアブストラクトがセットになっている．

4.1　作成方法

Zuo らは，まず 18 ヶ月間（2018 年 10 月〜2020 年 3 月）にわたり複数の医療系ニュースサイトの RSS フィードと人気のある一般ニュースサイト上の health カテゴリ上の記事を合計 72,028 件収集した．そして，その中から査読付き科学出版物を引用した記事を抽出し，その結果 17,712 件 (24.6%) が抽出された．さらに，検索タスクに使用するため，単一の研究や，一連の関連した研究について報告する記事のみを抽出した結果，5,034 記事が抽出された．これらの記事では，記事の見出しが引用された研究の主張を反映している．これは，371 件の論文（データセットの 7.4%）を無作為に抽出した 3 人の読者によってこの事実が確認されている．そして，全ての研究がオープンアクセスではないため，論文全体ではなくアブストラクトのみが抽出された．

最終的なデータセットには，記事見出しが 5,034 件，論文アブストラクトが 4,566 件存在する．データセット例は Appendix に掲載している．論文アブストラクトデータには，最初に論文タイトルも含んでいる．一件の論文アブストラクトが複数の記事で引用されているケースがあるため，記事見出し件数が論文アブストラクトの件数より多くなっている．また，タスクに利用するためのネガティブサンプルとして，生物医学研究文献から，記事で引用されていない論文アブストラクト 217,665 件も追加している．これは PubMed Central から非商用利用のオープンアクセスサブセット 5 から収集された論文である．

本研究では，リランキングにニューラルネットワークの手法を用いるため，データ train セット，development セット，そして test セットに分割する．Training に記事見出し 3,000 件，development セットに 1,000 件，そして test セットに 1,034 件を用いた．

4.2　データの整形

全論文アブストラクトのうち 36% は，ラベル付けされたセクション（“Background”，“Results”，“Conclusion” など）に分かれている．既存研究 [3] で，論文アブストラクト全体をエンコードするよりもラベル付きセクションの “Background” と “Conclusion” のみをエンコードした時の方が検索精度が上がることが報告されている．そのため，本研究でもラベル付きセクションに分かれている論文アブストラクトについては，“Background” と “Conclusion” のみを抽出・連結し，論文アブストラクトのデータとして用いる．さらに，セクションに分かれていないデータについても，既存研究 [3] で，論文アブストラクト全体をエンコードするよりも最初と最後の三文のみをエンコードした時の方が検索精度が上がったことが報告されている．そのため，本研究でも，ラベル付きセクションに分かれていない論文アブストラクトについては，最初と最後の三文のみを抽出し，モデルにエンコードした．

5　提案手法

我々は，エンコーダーの特徴や論文アブストラクトの特徴を生かした二つの手法を提案する．分散表現を作成する際には，生物医学文献によって事前訓練された Bio+ClinicalBERT[25] を用いた．

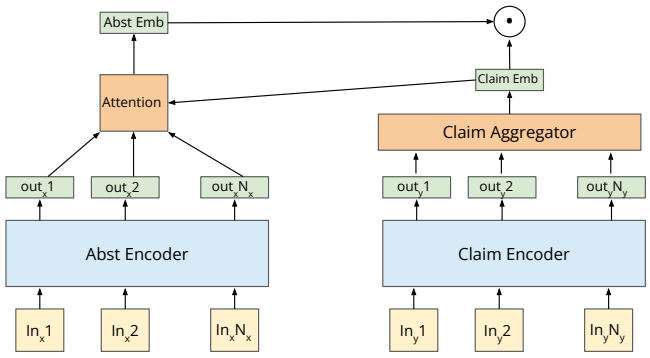


図 4: Poly-Enocoder(First-all)．全てのドキュメントトークンの分散表現にクエリのアテンションをかける．クエリには記事見出し，key と value には論文アブストラクトを用いている．最終的には，アブストラクトとクエリの分散表現の内積の計算を行う．

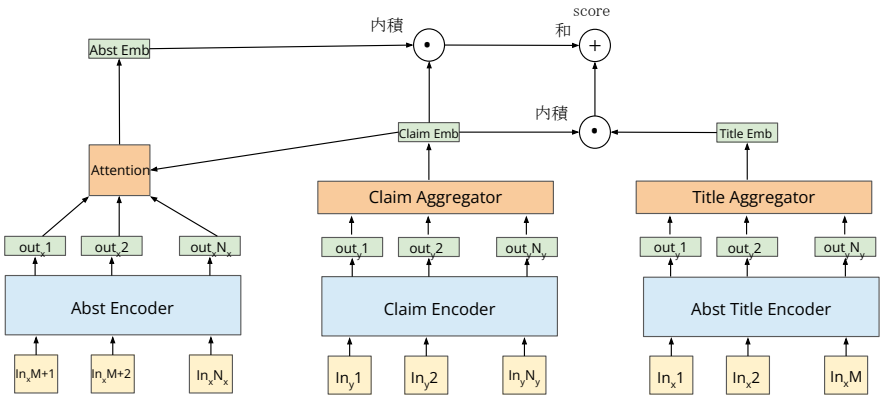


図 5: Paper-TA-Encoder．論文タイトルと論文アブストラクトを分割し，別のエンコーダーに入力する．そして論文タイトルと記事見出し，論文アブストラクトと記事見出しの分散表現のない席を取ることでスコア算出を行う．最終的には，それぞれで算出されたスコアの和を求める．

5.1 Poly-Encoder(First-all)

本研究では，**3.4.3** で説明した Poly-Encoder を改良したモデルを作成した．Poly-Encoder は，最初の段階で，長いトークンを持つドキュメントを圧縮するが，この段階で重要な情報を損失している可能性があると考える．そのため，ドキュメントの圧縮する段階を削除し，全てのドキュメントのトークンの分散表現に対して，クエリの attention をかけることによって，最終的に一つのドキュメントの分散表現とする．そして，その分散表現とクエリの分散表現のスコア計算を行する．これにより，late interaction aggregator に比べ，クエリの分散表現が 1 つになっているため計算量は削減されるが，全てのドキュメントトークンにクエリの attention をかけることができるので，ドキュメントの情報を損失することなくスコア計算を行うことができる．

5.2 Paper-TA-Encoder

論文タイトルは，その論文の主張が反映されていることが多いが，論文アブストラクトと連結された状態でエンコードされているため，記事見出しとのスコア計算を行う際に論文タイトルと記事見出しのスコアが的確に反映されていないのではないか，という仮説を立てた．これらに基づいて作成したモデルが，**図 5** であり，Paper-

TA-Encoder (Paper-TitleAbstract-Encoder) と名付ける．

Paper-TA-Encoder では連結してエンコードされる論文のアブストラクトと論文タイトルを分離し，独立したエンコーダーに入力する．そして，論文アブストラクトと記事見出し，そして論文タイトルと記事見出しのそれぞれのスコア計算を行い，最終的にそれらのスコアを足し合わせる．これにより，論文アブストラクトのエンコーダーでエンコードできる論文アブストラクトのトークン数を増やすことができ，また，独立した論文タイトルと記事見出しのスコアを反映することができる．

5.3 評価指標

本研究では，候補抽出のタスクに取り組んでおり，この候補を用いてリランキングを行う．そのため，抽出した候補の中に正解を含んでいることが非常に重要であるため，我々は評価指標として再現率 (式 (1)) を使用した．

$$\text{再現率} = \frac{\text{検索結果の正解データ数}}{\text{正解データ数}} \tag{1}$$

さらに，本研究で取り組むタスクでは，正解のアブストラクトがランク付けされた順位が重要であるため，MRR スコア式 (2, 3) も評価指標に用いた．MRR スコアとは，検索課題ごとに正解がランク付けされた順位の逆数 (RR) を求め，全検索課題に対する RR の値を平均することによってシステムの検索精度を評価する指標である．

$$RR_i = \frac{1}{R} \tag{2}$$

$$MRR = \frac{1}{N}\sum_{i}^{N} RR_i \tag{3}$$

5.4 実験設定

本研究では，ネガティブサンプルの選択に In-batch-negative[26] 手法を用いる．In-batch-negative 手法とは，バッチ内のある記事に対する正解データ以外のデータをネガティブサンプルとして扱う方法である．22 万存在するネガティブサンプルからランダムに抽出するよりも学習効率が高くなると考える．本研究では、batch 数を 14 として実験を行う．

既存研究では，ネガティブサンプルを，(Ⅰ) 候補抽出タスクで BM25+ によって抽出したアブストラクト候補のうち，最上位にランク付けされたアブストラクトをネガティブサンプルとしている（BM25-negative とする）．我々の手法と条件を揃えるため，正解データからネガティブサンプルを選択するモデルも作成した (In-answer-neagtive とする)．そのため，本研究では，既存手法について，In-answer-negative と BM25-negative の二つの実験を行なった．

6 実験結果

実験結果を**表 1** に示す．

表 1: 実験結果．BM25+-neg は BM25+ で抽出した候補のうち，最上位にランク付けされたアブストラクトをネガティブサンプルとする手法である．In-answer-neg は正解データからネガティブサンプルを選択する手法である．R@k は，上位 k 個に対する再現率を表している．

Model	R@1	R@3	R@5	R@10	R@20	MRR
Cross-BC-BERT(BM25-neg)	0.311	0.527	0.601	0.775	0.821	0.447
Cross-BC-BERT(In-answer-neg)	0.215	0.363	**0.447**	**0.532**	**0.629**	0.324
Poly-BERT-cased(learnt-16)	0.215	0.337	0.386	0.466	0.544	0.302
Poly-BC-BERT(leant-16)	0.162	0.257	0.331	0.430	0.535	0.247
Poly-Encoder(First-all)	0.220	0.367	0.431	0.518	0.593	0.320
Paper-TA-Encoder	**0.258**	**0.380**	0.439	0.520	0.601	**0.348**

Poly-Encoder(First-all) の結果が Poly-Encoder の結果を上回った．そして，既存手法のネガティブサンプルを in-batch-negative で選択した際の結果では，Paper-TA-Encoder が既存手法の結果を上回ることができた．

7 考察

作成した二つのモデルを元に考察を行なった．

Poly-Encoder(First-all) と Paper-TA-Encoder の結果を比較することにより，論文アブストラクトのタイトルを分離し，スコア計算を行うモデルの有効性が示された．具体例を元に，有効である要因を分析した．

次に，アブレーションスタディを行なった．Poly-Encoder(First-all) のモデルの AbstEncoder に，論文タイトルのみをエンコードした場合，論文アブストラクトのみをエンコードした場合のスコアを求めた．

表 2: スコア比較．”abstract”は論文アブストラクトのみをエンコードしてスコア計算を行なったモデル, ”papertitle”は，論文タイトルのみをエンコードしてスコア計算を行なったモデルである．R@k は，上位 k 個に対する再現率を表している．

Model	R@1	R@3	R@5	R@10	R@20	MRR
Poly-Encoder(First-all)	0.220	0.367	0.431	0.518	0.593	0.320
Paper-TA-Encoder	0.258	0.380	0.439	0.520	0.601	0.348
Abstract	0.188	0.328	0.400	0.486	0.568	0.288
Paper-title	0.208	0.329	0.395	0.465	0.549	0.296

その結果，**表 2** の結果となった．Poly-Encoder(First-

all) の結果と論文アブストラクトのみをエンコードした場合のスコアの差が大きいため，論文タイトルには重要は情報が含まれていることがわかった．さらに，Paper-TA-Encoder と論文タイトル，論文アブストラクトとを単独でエンコードしたモデルの結果を比較すると，Paper-TA-Encoder の結果が上回っているため，論文タイトルと論文アブストラクトの両方の情報が必要であることもわかった．

8 まとめ

本稿では，医療ニュース記事の見出しから，引用されている論文のアブストラクト候補をリランキングするタスクに取り組んだ．そして，Poly-encoder の改良手法（Poly-Encoder(First-all)）と，論文アブストラクトの特徴を生かした手法（Paper-TA-Encoder）を提案した．その結果，既存手法である poly-encoder に比べ MRR スコアが 0.08 ポイント向上し，embedding の圧縮を行う際に情報損失が起こっていることがわかった．また，論文タイトルには論文の主張が反映されていることに焦点を当てたモデルである Paper-TA-Encoder に対しては，既存手法である cross-encoder の MRR スコアを 0.02 ポイント上回ることができた．これにより，我々の提案手法が有効であることが示された．今後は，具体例を用いて更なる考察を行い，手法の改善を行なっていく予定である．

参考文献

[1] Fox, S. et al.: *The social life of health information, 2011*, California Healthcare Foundation (2011).

[2] Fox, S. and Duggan, M.: Health online 2013, *Health*, Vol. 2013, pp. 1–55 (2013).

[3] Zuo, C., Acharya, N. and Banerjee, R.: Querying Across Genres for Medical Claims in News, *EMNLP'20*, pp. 1783–1789 (2020).

[4] MacAvaney, S., Yates, A., Cohan, A. and Goharian, N.: CEDR, *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, (online), 10.1145/3331184.3331317 (2019).

[5] Dai, Z. and Callan, J.: Deeper Text Understanding for IR with Contextual Neural Language Modeling, *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR'19, New York, NY, USA, Association for Computing Machinery, p. 985–988 (online), 10.1145/3331184.3331303 (2019).

[6] Zheng, J. and Yu, H.: Assessing the Readability of Medical Documents: A Ranking Approach, *JMIR Med Inform*, Vol. 6, No. 1, p. e17 (online), 10.2196/medinform.8611 (2018).

[7] Rae, A., Mork, J. and Demner-Fushman, D.: A neural text ranking approach for automatic mesh indexing, *CLEF (Working Notes)* (2021).

[8] Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H. and Kang, J.: BioBERT: a pre-trained biomedical language representation model for biomedical text mining, *Bioinformatics*, Vol. 36, No. 4, pp. 1234–1240 (2020).

[9] Gu, Y., Tinn, R., Cheng, H., Lucas, M., Usuyama, N., Liu, X., Naumann, T., Gao, J. and Poon, H.: Domain-specific language model pretraining for biomedical natural language processing, *ACM Transactions on Computing for Healthcare (HEALTH)*, Vol. 3, No. 1, pp. 1–23 (2021).

[10] Mohan, S., Fiorini, N., Kim, S. and Lu, Z.: A Fast Deep Learning Model for Textual Relevance in Biomedical Information Retrieval, *Proceedings of the 2018 World Wide Web Conference*, WWW '18, Republic and Canton of Geneva, CHE, International World Wide Web Conferences Steering Committee, p. 77–86 (online), 10.1145/3178876.3186049 (2018).

[11] Zamil, M. G. H. A. and Can, A. B.: A model based on multi-features to enhance healthcare and medical document retrieval, *Informatics for Health and Social Care*, Vol. 36, No. 2, pp. 100–115 (online), 10.3109/17538157.2010.506252 (2011).

[12] Tang, H., Sun, X., Jin, B., Wang, J., Zhang, F. and Wu, W.: Improving Document Representations by Generating Pseudo Query Embeddings for Dense Retrieval, *arXiv preprint arXiv:2105.03599* (2021).

[13] Singhal, A., Choi, J., Hindle, D., Lewis, D. D. and Pereira, F.: At&t at trec-7, *NIST SPECIAL PUBLICATION SP*, pp. 239–252 (1999).

[14] Robertson, S. E. and Walker, S.: Some simple effective approximations to the 2-poisson model for probabilistic weighted retrieval, SIGIR' 94, Springer, pp. 232–241 (1994).

[15] Lv, Y. and Zhai, C.: When Documents Are Very Long, BM25 Fails!, *ACM SIGIR'11*, pp. 1103–1104 (2011).

[16] Robertson, S. and Zaragoza, H.: *The probabilistic rel-*

evance framework: BM25 and beyond, Now Publishers Inc (2009).

[17] Wolf, T., Sanh, V., Chaumond, J. and Delangue, C.: TransferTransfo: A Transfer Learning Approach for Neural Network Based Conversational Agents (2019).

[18] Vig, J. and Ramea, K.: Comparison of transfer-learning approaches for response selection in multi-turn conversations, *Workshop on DSTC7* (2019).

[19] Mazaré, P.-E., Humeau, S., Raison, M. and Bordes, A.: Training millions of personalized dialogue agents, *arXiv preprint arXiv:1809.01984* (2018).

[20] Dinan, E., Roller, S., Shuster, K., Fan, A., Auli, M. and Weston, J.: Wizard of wikipedia: Knowledge-powered conversational agents, *arXiv preprint arXiv:1811.01241* (2018).

[21] Zhan, J., Mao, J., Liu, Y., Zhang, M. and Ma, S.: RepBERT: Contextualized Text Embeddings for First-Stage Retrieval (2020).

[22] Khattab, O. and Zaharia, M.: ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT (2020).

[23] Luan, Y., Eisenstein, J., Toutanova, K. and Collins, M.: Sparse, Dense, and Attentional Representations for Text Retrieval (2021).

[24] Humeau, S., Shuster, K., Lachaux, M.-A. and Weston, J.: Poly-encoders: Transformer Architectures and Pre-training Strategies for Fast and Accurate Multi-sentence Scoring (2020).

[25] Alsentzer, E., Murphy, J. R., Boag, W., Weng, W.-H., Jin, D., Naumann, T. and McDermott, M. B. A.: Publicly Available Clinical BERT Embeddings (2019).

[26] Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D. and tau Yih, W.: Dense Passage Retrieval for Open-Domain Question Answering (2020).