議論データ抽出における意見と Key Point のスタンス分類から Match Scoring までの自動化に向けて

Toward Automation from Stance Classification to Match Scoring of Arguments and Key Points for Debate Data Extraction

桝田大貴 [1], 白藤大幹 [1] , ジェプカ・ラファウ [2], 荒木健治 [2]

Daiki Masuda [1], Daiki Shirafuji [1], Rafal Rzepka [2], Kenji Araki [2]

[1] 北海道大学大学院情報科学院,[2] 北海道大学大学院情報科学研究院

[1] Graduate School of Information Science and Technology, Hokkaido University, [2] Faculty of Information Science and Technology, Hokkaido University

1 はじめに

討論や議論は自然言語処理分野において広く研究されているテーマの一つである [1][2]. 議論に関する研究分野は議論マイニングと呼ばれ, この 10 年間でますます注目を集めている. 議論マイニングの研究はディベート, 裁判の自動化・支援, 世論調査, フェイクニュースの検出等に応用される. 議論マイニングにおいて, 議論における主張, 前提, 根拠等の要素は通常, 非構造化されたテキストもしくは発話から抽出される [3]. これら議論の要素を検出する試みにより, 著者や話者による主な主張や主張の根拠がどこに存在するか, 議論の具体例がどこで表現されているかが明らかにしてきた. 現在, 上述の要素を判別する精度は驚くべきほど改善されてきている. それゆえ, 議論マイニング領域の主な研究対象は異なるトピックに変化しつつある. 議論マイニングの研究者は, 意見の説得力を測る [4][5], 意見間のずれを埋める [6][7], 意見の賛成か反対かのスタンスを予測する [8][9] といったテーマに着目し始めている. これらのタスクはディベート, 議論, 演説, 論文等からなる莫大な量の意見 (argument) データを必要とする.

一方, 大量の意見を集約するタスクは避けられてきたように思われる. 大量の意見が存在すると, 一般的に誰がそれを論ずるべきなのか分からなくなり, ユーザが議論のトピックについての正確な意見を見つけることができなくなる問題が発生する. これらの問題を解消するためには意見の絞り込みが必要となる. つまり, 数多くの意見をいくつかの核となる内容に要約する必要がある. このタスクに取り組むための準備として意見を集約するタスクに取り組む必要がある. 意見の集約には通常 2 つの方法がある. 1 つ目の方法は, オンラインディベートリソース（iDebate[*1]や CreateDebate[*2]など）からそれらを取得することである. もう 1 つの方法は, 意見を述べるディベートの観客から意見をあつめる方法である [2]. 両方の方法を使用すると, 1 つのトピックに対して収集される意見の数が数百を超えることがよくある. 大量の意見を簡潔に把握するために, 大量の意見データを読み込んで, 意見を要約するタスクに取り組む必要がある. この課題を解決するために Reimers ら [10] は, ELMo[11] および BERT[12] の文脈に応じた単語埋め込み表現を活用して, トピックに依存した意見を Argument Facet Similarity Corpus[13] から分類し集約した. この研究により関連する意見は集約されたが, 意見の要約生成は行われなかった. この問題は, Key Point を定義した Bar-Haim ら [14] により述べられている. Key Point とは通常, 似たような意見について述べた 1 つの文, つまり意見の要約文を指している（表 1 参照）.

Bar-Haim らによると 1 つのトピックにおいて 14 個の Key Point で凡そ 72.5 %の意見を網羅していることが分かっている. 従って, 従って Bar-Haim らは意見と key point のペアを大量に作成した. そして次に Match Scoring と Match Classification の 2 つタスクの実験を行った. Match Scoring では意見と key point のマッチスコアが計算される. データセットには ArgKP データセット [14] が用いられており, 表 1 はその例を示している. Match Classification では, マッチスコアからそれぞれの意見に一致する key point の検出を行う. Bar-Haim らは Match Scoring と Match Classification のタスクにおいて, BERT-large[12] を fine-tuning したモデルが教師あり学習の中で最も良い結果を示した. また教師なしの手法の中においては, BERT-large の埋め込み手法が最も良い結果を示した. Bar-Haim らは, 自身の研究は意見の要約を実用化

[*1] https://idebate.org

[*2] https://www.createdebate.com

表 1: ある特定のトピックの意見と key point のペアの例. トピックに対しての意見と key point 共通のスタンス (賛成 (1), 反対 (-1)) ラベル付けがされている. また意見と key point がマッチしているか (1) 否か (0) ラベル付けがされている.

Debate Topic: **We should ban human cloning**

意見	Key Points	Stance	Match
human cloning is sick and morally wrong.	Cloning is unethical/anti-religious	1	1
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning can be used for organ replication	-1	0

していると主張しているが, ただ単に意見と key point の関連性を計算しているだけである. つまりこれは, Match Scoring と Match Classification の実験が Reimers らの研究 [10] で行われた実験と殆ど同一であることを意味している. さらに, Match Scoring と Match Classification ではこと前に key point が作成されている必要がある. つまりこれは, 彼らの手法は key point が存在しない新しいトピックには用いることができないことを示している. 従って新しい議論のトピックに適用するためには, 一連の意見から key points を自動的に生成する必要がある. マッピングステップは意見のまとまりから key point を生み出すのに役立つ. Match Scoring は上述の通り, 与えられた意見と key point が関連しているか否かを判定する. この Match Scoring ステップに続いて, key point 生成のための意見のまとまりを作成することが可能になる.

白藤らは [15] 大量の意見を 1 つの key point に要約するための重要な要因は, 1 つの意見を複数の key points にマッピングすることであると考え, Match Scoring に取り組んでいる. Bar-Haim らの研究 [14] では, Match Scoring タスクにおいて教師ありの手法と教師なしの手法について実験を試みている. 白藤らは Bar-Haim らの教師なし手法について着目し, 既存手法では各単語の embedding を平均化しているだけで, 重要単語が充分に活用できていないという問題点を発見した. この問題点を解決するために Sentence-BERT[16] を用いた複数の手法と MoverScore[17] の手法を提案し, 共に既存手法の精度を上回り MoverScore が最も良い精度となることをを示した. Bar-Haim ら, 白藤らは共に ArgKP データセットを用いて Match Scoring に取り組んでいる. しかしこれらの既存研究はスタンスが一致している意見と key point のペアからなるデータセットをもとに行っており, 意見と key point マッチングの全自動化には至っていない. そこで本研究では意見と key point のスタンスの一致を前提としないデータセット NoStanceArgKP データセットを作成し, 意見と key point のスタンスの一致を前提としない, より現実に近い分類タスクを設計した. 人手によるスタンスのラベルの情報を元に Match Scoring を行った結果と, 教師なし学習である STANCY[9] によるスタンス予測の情報を元に Match Scoring 結果の精度比較実験を行った.

本論文の主な貢献は以下の通りである:

1) 既存の Match Scoring の手法では, スタンスが一致している意見と key point のペアからなるデータセットをもとに行っており, 意見と key point マッチングの全自動化には至っていないことを指摘した.

2) 意見と key point のスタンスの一致を前提としないデータセット NoStanceArgKP データセットを作成し, 意見と key point のスタンスの一致を前提としない, より現実に近い分類タスクを設計した.

3) 設計した新しい分類タスクにおいて, 提案手法がベースラインを上回ることを示した.

2 関連研究

この章では, 本研究に関連する研究について説明する. **2.1** では, この研究分野の歴史と, 議論マイニングの分野における同様のトピックについて説明する. **2.2** では, Match scoring の際に最も重要な, テキスト間の類似度を計算する手法に関する研究について述べる. **2.3** ではスタンス分類の手法に関する研究について述べる.

2.1 議論マイニング

議論マイニングの研究は, ディベートや討論, 学生論文における議論の要素 [3] を明らかにする科学的な文章の新しいタイプの修辞レベルでの分析 (argumentative zoning) の分野において働いている研究者たちによって始められたものである. Aharoni ら [3] は 33 のディベートトピックにおける 2,683 の議論を含む argument zoning のためのベンチマークを作成した. Lippi と Torroni[18] は物議を醸す文章に含まれる主張部分を見つけ出すため

に SVM ベースの手法を提案した. このタスクにおいて, Stab と Gurevych[19] は整数線形計画法 (Integer Linear Programming) を用いて F 値で 0.76 という値を出している. これらのモデルは異なる 2 種類の談話構造において他のモデルよりも優れている.

議論構造が徐々に明らかになり始めた頃, 多くの研究者はより説得力のある議論を生み出すために, 意見の説得力 [4], また議論全体の説得力 [20] を測る分野に取り組み始めた. スタンス予測もまた議論マイニングにおいて積極的に研究されるテーマとなった. 与えられた意見が特定のディベートトピックに対して賛成意見なのか否かについての研究が行われた [8][9]. 最近では, 様々な視点から意見に関する研究を行うために, 大規模な意見のデータセットが作成された [21][22]. Stab ら [21] は様々なディベートトピックの意見を検索できる意見検索システムを構築した. このシステムはオンラインディベートポータル (ProCon[*3]) から専門家が厳選した意見リストの約 89 %を網羅している. 同様に, Bar-Haim ら [14] が作成した ArgKP データセットは, 専門家のよって作成された key point リストと意見の間で高い一致度を示し, コーエンのカッパ係数の値は 0.82 を出している. より最近では, Misra ら [13] はディベートポータル (iDebate と ProCon). 上の意見同士の類似度を測ろうと試みている. 故に, 彼らは 2 つのディベートポータルを用いた Argument Facet Similarity Corpus を提案している. 彼らの研究の目的は, 意見が複数のディベートに渡って他の意見と同じ側面を持つかどうかを明らかにすることである. いくつかの研究では, 論理規則や文脈に応じた embedding モデルを用いて側面についての処理を行っている [10][23]. これらの研究は意見を key point にマッピングする研究に類似しているが, 意見と側面の類似度は計算していない. また彼らの研究は key point を明確にしておらず, 我々の研究とは明確に異なる.

意見の key points へのマッピングとして, Match Scoring と Match Classification のタスク [23][24] は最もよく知られている既存研究の例である. Boltužić と Šnajder[24] は arugment のクラスタリングを行った. 彼らの研究では, あるオンラインディベートポータル (ProCon) 上の意見を他のポータル (iDebate) にマッピングしている. しかしそのシステムは, 400 未満の意見を持つ 2 つのトピックまでしか対応していない. Ber-Haim ら [14] らは関連しているかどうかラベル付けされた意見と key points のペアを含む大規模データセットを作成しさらに, Match Scoring と Match Classification が意見要約の最初のステップであると提案した.

[*3] https://www.procon.org

2.2 テキスト間の類似度

最近自然言語処理の研究者は, テキスト間の類似度を測るために文ベクトルや単語ベクトルを活用している. 通常, 単語ベクトルは単語 embedding, 文 embedding, または言語モデルにより計算される. 最もよく知られているアルゴリズムの 1 つである word2vec[25] は, 単語をベクトルとして表すためのこと前学習された skip-gram または Bag-of-Words (CBOW) モデルである. こと前学習された単語埋め込みモデルに続き, 文及びドキュメントの埋め込みモデルも開発された. 例えば, Skip-Thought Vectors[26] はエンコーダデコーダモデルに基づいており, エンコーダは単語を文ベクトルにマップし, デコーダは周いの文を生成する. Reimers と Gurevych により提案された Sentence Transformers[16] は, シャムネットワーク [27] またはトリプレットネットワーク [28] に基づく英文のための文 embedding モデルである. Reimers と Gurevych は BERT[12] などの言語モデルをシャムネットワークもしくはトリプレットネットワークに挿入した. 彼らはそれら BERT-based のシャムネットワークまたはトリプレットネットワークを Sentence-BERT と呼称した. テキストの類似度を計算する方法は他にも存在する. Word Mover's Distance[29] は word2vec を使用してテキスト間の距離を計算し, Earth Mover's Distance[30] を自然言語処理の分野に導入している. これに触発された Zhao ら [17] はエンコーディングシステムの調査により, 要約または機械翻訳タスクにおけるテキスト品質の人間の判定と高い相関関係を示す評価指標を考案した. 彼らはその評価指標を Mover Score と名づけた.

Misra らは自然言語処理分野の議論マイニングの研究として, 単一の文で構成された意見同士の類似度を測定するために Argument Facet Similarity タスクを提案した. 彼らの研究の最終目標は複数の意見の要約を生成することであり, 我々の研究の最終目標と類似している. ディベートトピックにおける意見は通常言い換えることが可能であるため, 討論者はよく議論の要約を作成する. 側面を検出することにより, 意見を対応する側面にマッピングできるため, Argument Facet Similarity タスクは要約に役立つ. 故に, 本研究で取り組む Match Scoring タスクでは, Argument Facet Similarity データセットで事前学習された Sentence-BERT を用いる.

Misra らは意見の類似度を測定するために, LIWC (Lin-

guistics Inquiry Word Count) ツールと word2vec をリッジ回帰 (RR) とサポートベクター回帰 (SVR) に導入した. LIWC ツールを用いた SVR は銃規制, 同性結婚, 死刑という 3 つのディベートトピックで, ピアソン相関でそれぞれ 0.59, 0.26, 0.40 が得られた. LIWC ツールを用いた RR では, これらのトピックでそれぞれ 0.50, 0.27, 0.34 が得られた. SVR と RR の平均した結果はそれぞれ 0.42, 0.37 であった. Reimers と Gurevych は上述したように, 意見と側面の類似度を測定するために Sentence-BERT[16] を提案した. そして, fine-tuned された BERT モデルと fine-tuned された Sentence-BERT モデルを比較した. Arguments Facet Similarity データセットで fine-tuned された BERT-base と BERT-large はピアソン相関でそれぞれ 0.77, 0.79 を得ることができた. Sentence-BERT-base と Sentence-BERT-large はそれぞれ 0.77, 0.78 を得ることができた. しかしながら, Sentence-BERT を構築する方法は, ラベル付けされた文のペアで構成される高品質なデータセットで学習することである. よって, ラベル付けされたデータの数が非常に少ないタスクにしか応用できない. Zhang ら [31] はこの問題点を解決するために, 文ベクトルを生成するための教師なし手法 Info-Sentence BERT (IS-BERT) を提案した. IS-BERT は, 教師なし手法により重要な文 embedding を獲得するために, 相互情報量最大化戦略に基づく新しい教師なし学習目標を追加している. 彼らのアルゴリズムは, BERT モデルと異なるウィンドウサイズの CNN を使用して文を読み込み, 連結されたローカル n-gram トークンの embedding を取得する. 分類器は, 文とトークンの表現のすべてのペアを入力として受け取り, 特定のペアの 2 つの文が同じ文から捉えられているかどうかを識別する. IS-BERT モデルは Argument Facet Similarity データセットのピアソン相関で 0.49 を得た. 教師ありの手法は IS-BERT の結果よりも優れていたが, 十分なラベル付けされたデータセットがない領域では, IS-BERT は競争力のある結果を示した. しかし本研究で扱うディベートトピックでは, Sentence-BERT は IS-BERT と同等に機能するため, IS-BERT の代わりに Sentence-BERT を用いる.

2.3 スタンス分類

以前のスタンス分類の手法は Somasundaran と Wiebe[32], Anad ら [33], Walker ら [34], Hasan と Ng[35], Sridhar ら [36], Sun ら [37] によって提案されているが, これらは物議を醸すトピックに対しての意見のスタンスを決定するために, n-grams, 依存関係解析ツリー (dependency parse tree), 意見辞書 (opinion lexicon), また感情情報 (sentiment) が用いられている. Ferreira と Vlachos[38] はさらに自然言語の主張 (natural language claims) を取り入れ, トピックや意見に含まれる語彙や意味的な特徴を用いたロジスティック回帰モデルを提案した. SemEval タスク [39][40] やその他の手法 [41][42] では, ツイートのみにおけるスタンス決定に焦点を当てている. Bar-Haim ら [8] はスタンス分類のために, 意見に含まれる重要なフレーズと主張の一貫性を識別する手書き辞書に基づく分類器を提案した. スタンス分類のためのニューラルネットワークに基づく手法はトピックの固有表現と意見の固有表現をそれぞれ別々に学習した後, Augenstein ら [43] の条件付き LSTM エンコーディング, Du ら [44] のアテンション機構, もしくは Mohtarami ら [45] の Memory Networks と組み合わせられている. Riedel ら [46] や Hanselowski ら [47] によるニューラルネットワークモデルは語彙的な特徴 (lexical features) を取り入れた. しかし, これらの手法はいずれも大規模な外部コーパスから得た知識を活用していない. この問題点を解決する手法として Popat ら [9] の STANCY と呼ばれるスタンス分類のためのニューラルネットワークモデルを提案した. STANCY は大規模な外部コーパスで学習した BERT 表現と, トピックと意見を共同でモデル化するための新しい一貫性制約を活用したスタンス分類のためのニューラルネットワークモデルである.

STANCY はベンチマーク実験により, 既存手法を上回る結果を示した. 本研究ではスタンス分類における教師なし学習の手法の中で比較的良い精度を出した STANCY をスタンス分類の手法として適用する.

3 提案手法

本研究では, 意見と key point のスタンスの一致を前提としないデータを作成し, 意見と aey point のスタンスの一致を前提としない, より現実に近い分類タスクを設計した. また Match Scoring の前にスタンス分類を行うことによる分類精度の変化を分析した. **3.1** では, スタンスの一致を前提としないデータの作成とデータ詳細について述べる. **3.2** では本研究で設計した分類タスクの説明を行う. スタンス分類と Match Scoring で用いた手法の紹介も行う. **3.3** では評価指標について述べる.

3.1 データセット

データセットには ArgKP データセット [14] を整形し, 新たに作成した NoStanceArgKP データセットを用いる. ArgKP データセットは 24,093 組の意見と key point の組からなる. トピックに対する意見と key point のスタンス

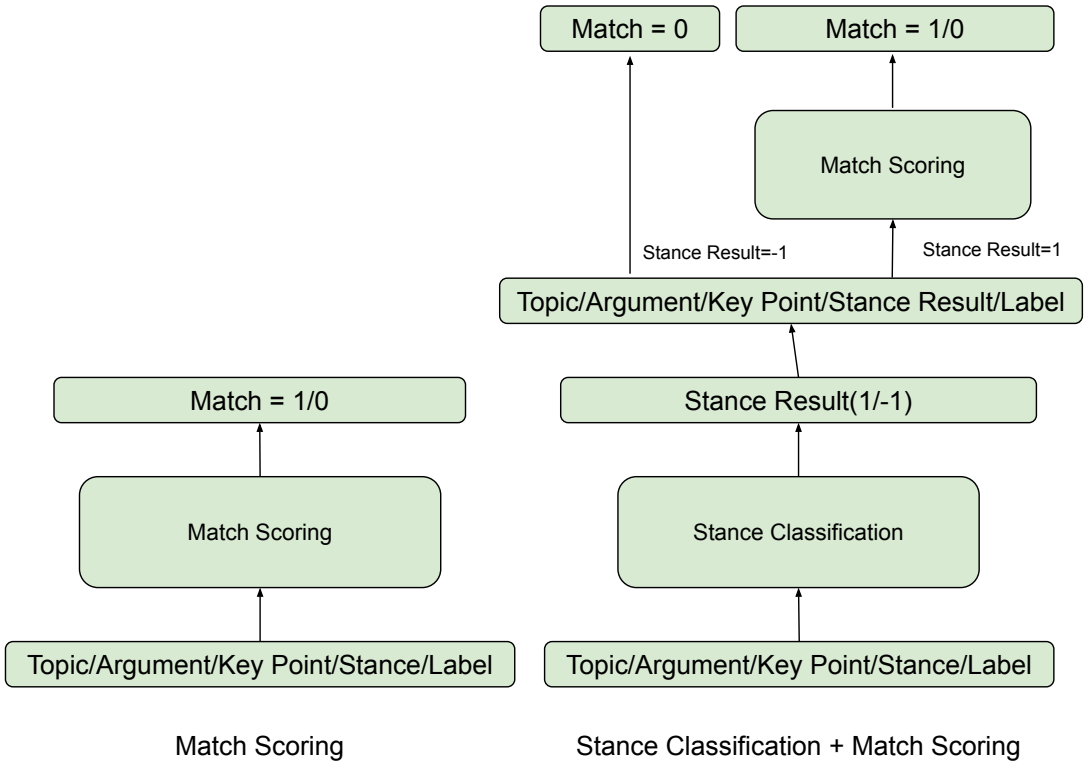


図 1: スタンス分類を考慮した Match Scoring のフローチャート. 左は既存手法の Match Scoring, 右は提案手法であるスタンス分類を考慮した Match Scoring のフローチャートを示している.

のラベルと, これらがマッチしているか否かのラベルが含まれている. データ整形の方法としてまず元データのスタンスラベルを元に意見と key point にそれぞれのスタンスのラベルを付与する. 次に同じトピックの意見と key point をスタンスが一致しているかに関わらずペアにすることで, 意見と key point それぞれにスタンスのラベル付けがされた NoStanceArgKP データセットを作成する. データセットの例を表 2 に示す. NoStanceArgKP データセットは 52,429 組からなる. このデータセットを用いてスタンス分類を行い, そのスタンス情報を考慮して Match Scoring を行う.

3.2 スタンス分類を考慮した Match Scoring

スタンス分類を考慮した上で Match Scoring を行う方法について説明する (図 1 参照). まず, key point のスタンスに対して意見のスタンスが一致しているか否かを判別する. 判別の結果, スタンスが一致していないものについてはマッチしていないものと判別する. スタンスが一致していると判別されたものについては Match Scoring を行いマッチしているか否かの判別を行う.

本文類タスクでは, 人手によるスタンスのラベルを比較しスタンス分類した結果を用いて Match Scoring した結果が新しいベースラインとなる. 本研究ではスタンス分類から Match Scoring までを自動で行うことを目標としているため, まず NoStanceArgKP データセットの意見と key point のペアに対して, 教師なし学習モデルの STANCY[9] を用いてスタンス分類を行う. スタンス予測の結果として, 意見と key point のスタンスが一致している判定された場合はそのまま Match Scoring を行い, スタンスが一致していないと判定された場合はマッチしていないものとする. スタンス分類では Popat ら [9] によって提案されたスタンス分類のための教師なし学習モデル STANCY を用いる. Match Scoring では白藤ら [15] により, Match Scoring の提案手法として提案された BERT-base を SNN に導入し, SNLI と MultiNLI で訓練した SBERT-base, BERT-large を SNN に導入し, SNLI と MultiNLI で訓練した SBERT-large, BERT-base を SNN に導入し, SNLI と MultiNLI で訓練した SBERT を STS ベンチマークで fine-tune した SBERT-STSb-base, BERT-large を SNN に導入し, SNLI と MultiNLI で訓練した SBERT を STS ベンチマークで fine-tune した SBERT-

STSb-large と MoverScore[17] を用いる.

3.3 評価指標

本研究の新しい分類タスクの評価は, ベースラインと提案手法ともに最終的な Match Scoring の結果を用いる. そのため, Bar-Haim ら [14] に続き, Match Scoring のための 4 つの評価指標, 正解率 (Accuracy), 適合率 (Precision), 再現率 (Recall), F 値を用いる. これらの評価指標の計算方法は式 (1), (2), (3), (4) に示す.

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \tag{1}$$

$$Precision = \frac{TP}{TP + FP} \tag{2}$$

$$Recall = \frac{TP}{TP + FN} \tag{3}$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \tag{4}$$

4 実験結果

各モデルで実験した正解率 (Accuracy), 適合率 (Precision), 再現率 (Recall), F 値 (F1) の値を表 3 に示す. 正解率に関しては全手法がベースラインを上回る結果となったため, 単に分類の予測精度だけでみると提案手法に優位性があると言える. 一方再現率は全てベースラインを下回った. ここでテストデータの Match のラベル付けがされているもの (ポジティブサンプル) とマッチしていないラベル付けがされているもの (ネガティブサンプル) の数を比べると, ポジティブサンプルの数が 4,998 個, ネガティブサンプルの数が 47,433 個とネガティブサンプルがポジティブサンプルに比べて比類のないほど存在する. 従って, 分類の手法に十分な予測能力がない場合, ネガティブサンプルの数が遥かに多く存在するため, ペアをネガティブとラベル付けしてしまう傾向がある. 従って, 正に対する正答率を示す再現率よりも正予測の正答率である適合率に重点を置く必要がある. 適合率に関してみると, 全手法ベースラインを上回っているため, 提案手法の優位性が示されたと言える. F 値に関しては適合率と再現率の調和平均をとっており, 適合率と再現率はトレードオフの関係にある. 適合率の上昇に対して, そのため, 再現率の低下率が特に大きい SBERT-large と SBERT-STSb-large は F 値が若干低下する結果となった.

5 エラー分析

この章では, Moverscore の結果に関するエラーの一例を紹介し, エラーの原因と精度向上につながる手掛かりについて考察を行う.

まず, 本来スタンスがしているかつマッチしていないペアで, スタンスが一致してると誤判定され Match Scoring においてもマッチしていると誤判定されてしまったペアが存在した. その一例として “We should prohibit women in combat”「女性の戦争への参加を禁止すべき」というトピックに関して, 意見が “women should be able to fight if they are strong enough”「女性は十分に強靭であるならば戦えるようになるべきだ」で, key point が “Women should be able to serve in combat if they choose to”「女性は自身が望むのならば, 戦争で奉仕できるようになるべきだ」のペアが存在する. 共に「女性の戦争への参加を禁止するべき」トピックに対して反対のスタンスを示しており, スタンス分類では共に同じ主張をしているため正しく判定されたと考えられる. しかし, Match Scoring では距離スコアの値がテストデータ全体の中で 2 番目の 0.383 と高くマッチしていると誤判定された. これは意見と key point 共に「女性の戦争への参加」について話しており, 文の構造自体も非常に似ていたためであると考えられる. しかし, 意見も key point も「女性の戦争への参加」については賛成的な意見だが, その条件が異なっているため, 異なる内容を示している. このように意見の側面を考慮するべきであった.

また本来スタンスが一致しているかつマッチしているペアで, スタンスに関しては正確に判定れたが, マッチはしていないと誤判定されてしまったペアが存在した. その一例として, “We should subsidize journalism”「ジャーナリズムに助成するべきだ」というトピックに関して, 意見が “it could become partial to whoever pays”「それは支払い対象が部分的になる可能性がある」で, key point が “Government intervention has the risk of inserting bias/harming objectivity”「政府の介入は偏見が生まれたり, 客観性が失われるリスクがある」のペアが存在する. 「ジャーナリズムへの助成」というトピックに対して意見は「部分的になる」, key point は「リスクがある」という共に否定的な意味を示しており, 他に文全体のスタンスを決定づける表現がなかったため, スタンス分類では正確な判定がされたと考えられる. しかし, Match Scoring では距離スコアの値がテストデータ全体の中で 2 番目の 0.03 と 7 番目に低くマッチしていないと誤判定された. これは意見に関して, 重要な主語となる部分が “it” になってしまっており, トピックが不明となってしまっている. また key point とも文構造が異なっていたためであると考えられる. これに関しては意見と key point にトピックの情報を組み込んだ上で比較できるようにする必要があると考えられる.

表 2: ArgKP データセットを元に作成された NoStanceArgKP データセットの例. ある特定のトピックの意見と key point のペアの例. 意見と key point それぞれのトピックに対するスタンス (賛成 (1), 反対 (-1)) ラベル付けがされている. また意見と key point がマッチしているか (1) 否か (0) ラベル付けがされている.

Debate Topic: **We should ban human cloning**

意見	Key Points	Argstance	KPstance	Match
human cloning is sick and morally wrong.	Cloning is unethical/anti-religious	1	1	1
human cloning is sick and morally wrong.	Cloning can be used for organ replication	1	-1	0
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning can be used for organ replication	-1	-1	0
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning is unethical/anti-religious	-1	1	0

表 3: スタンス分類の結果を考慮した Match Scoring の実験結果. 上がベースラインで, 下が提案手法.

Model	Accuracy	Precision	Recall	F1
Moverscore	0.827	0.239	0.417	0.304
SBERT-base	0.790	0.253	**0.677**	0.368
SBERT-large	**0.844**	**0.309**	0.579	**0.402**
SBERT-STSb-base	0.782	0.230	0.599	0.333
SBERT-STSb-large	0.796	0.238	0.568	0.335
STANCY+MoverScore	**0.878**	0.325	0.323	0.324
STANCY+SBERT-base	0.860	0.328	**0.518**	**0.402**
STANCY+SBERT-large	0.867	**0.338**	0.493	0.401
STANCY+SBERT-STSb-base	0.826	0.261	0.503	0.344
STANCY+SBERT-STSb-large	0.858	0.287	0.386	0.329

また, 本来スタンスが一致しているかつマッチしているペアで, スタンスに関しては正確に判定れたが, マッチはしていないと誤判定されてしまったものの中には, 意見が長文または 2 文以上で構成されているものが数多く存在した. これについては, 意見の文の長さや文の数に対しては別の手法を適用することで精度向上を図る. 具体的な手法の検討ついては今後の課題である. また本来スタンスが一致しているかつマッチしているペアで, スタンスに関して誤判定されてしまった結果マッチしていないと誤判定されてしまったペアが存在した. その一例として, “We should subsidize space exploration”「宇宙開発に助成するべきだ」というトピックに関して, 意見が “we have much bigger issues that need our money”「私たちはお金を必要とするより大きな問題を抱えている」で, key point が “There are issues more important to fund than space exploration”「宇宙開発に投資するよりもっと重要な問題がある」のペアが存在する. 「宇宙開発を助成すべき」というトピックに対して, 意見と key point 共に「宇宙開発よりも他のことにもっとお金をかけるべき」と同じ内容かつ同じ主張をしているのも関わらずスタンス分類ではスタンスが一致していないと誤判定されてしまった. これに関しては, スタンス分類では key point をトピックと捉えて意見のスタンスを見ているが, 意味的にも意見は key point と全く同じ内容を示しているため, 本来スタンスが一致していると判定されるはずである. これについては今後スタンス分類の手法に関する分析を詳細に行い, 検討していく.

6 まとめ

本稿では, 意見と key point のスタンスの一致を前提としないデータセット NoStanceArgKP データセットを作成し, 意見と key point のスタンスの一致を前提としない, より現実に近い分類タスクを設計した. 設計した新しい分類タスクにおいて, 提案手法の精度がベースラインを上回ることを示し, Match Scoring の過程におけるスタンス分類の有効性を示した. 今後の課題として, エラー分析を元に正確に Match の判定がされていない部分を改善する新たな手法で実験を行い, さらなる精度向上を目指す. また現状, スタンス分類から Match Scoring までが自動化されているが, 意見と key point のトピックが一致していないことを前提とした Match Scoring は行われていない.

従ってトピック分類からスタンス分類, Match Scoring までを自動化することにより, 完全な End-to-End の Match Scoring の自動化を目指す.

参考文献

[1] Cabrio, E. and Villata, S.: Five Years of Argument Mining: a Data-driven Analysis, *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, IJCAI-18*, International Joint Conferences on Artificial Intelligence Organization, pp. 5427–5433 (online), 10.24963/ijcai.2018/766 (2018).

[2] Lawrence, J. and Reed, C.: Argument Mining: A Survey, *Comput. Linguist.*, Vol. 45, No. 4, p. 765–818 (online), 10.1162/coli$_{a0}$0364(2020).

[3] Aharoni, E., Polnarov, A., Lavee, T., Hershcovich, D., Levy, R., Rinott, R., Gutfreund, D. and Slonim, N.: A Benchmark Dataset for Automatic Detection of Claims and Evidence in the Context of Controversial Topics, *Proceedings of the First Workshop on Argumentation Mining*, Baltimore, Maryland, Association for Computational Linguistics, pp. 64–68 (online), 10.3115/v1/W14-2109 (2014).

[4] Habernal, I. and Gurevych, I.: Which argument is more convincing? Analyzing and predicting convincingness of Web arguments using bidirectional LSTM, *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Berlin, Germany, Association for Computational Linguistics, pp. 1589–1599 (online), 10.18653/v1/P16-1150 (2016).

[5] Persing, I. and Ng, V.: Why Can't You Convince Me? Modeling Weaknesses in Unpersuasive Arguments, *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI-17*, pp. 4082–4088 (online), 10.24963/ijcai.2017/570 (2017).

[6] Boltužić, F. and Šnajder, J.: Fill the Gap! Analyzing Implicit Premises between Claims from Online Debates, *Proceedings of the Third Workshop on Argument Mining (ArgMining2016)*, Berlin, Germany, Association for Computational Linguistics, pp. 124–133 (online), 10.18653/v1/W16-2815 (2016).

[7] Habernal, I., Wachsmuth, H., Gurevych, I. and Stein, B.: Before Name-Calling: Dynamics and Triggers of Ad Hominem Fallacies in Web Argumentation, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics, pp. 386–396 (online), 10.18653/v1/N18-1036 (2018).

[8] Bar-Haim, R., Bhattacharya, I., Dinuzzo, F., Saha, A. and Slonim, N.: Stance Classification of Context-Dependent Claims, *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers*, Valencia, Spain, Association for Computational Linguistics, pp. 251–261 (online), https://aclanthology.org/E17-1024 (2017).

[9] Popat, K., Mukherjee, S., Yates, A. and Weikum, G.: STANCY: Stance Classification Based on Consistency Cues, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, Association for Computational Linguistics, pp. 6413–6418 (online), 10.18653/v1/D19-1675 (2019).

[10] Reimers, N., Schiller, B., Beck, T., Daxenberger, J., Stab, C. and Gurevych, I.: Classification and Clustering of Arguments with Contextualized Word Embeddings, *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, Florence, Italy, Association for Computational Linguistics, pp. 567–578 (online), 10.18653/v1/P19-1054 (2019).

[11] Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K. and Zettlemoyer, L.: Deep Contextualized Word Representations, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics, pp. 2227–2237 (online), 10.18653/v1/N18-1202 (2018).

[12] Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, *Proceedings of the 2019 Conference of the North American Chap-*

ter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), Minneapolis, Minnesota, Association for Computational Linguistics, pp. 4171–4186 (online), 10.18653/v1/N19-1423 (2019).

[13] Misra, A., Ecker, B. and Walker, M.: Measuring the Similarity of Sentential Arguments in Dialogue, *Proceedings of the 17th Annual Meeting of the Special Interest Group on Discourse and Dialogue*, Los Angeles, Association for Computational Linguistics, pp. 276–287 (online), 10.18653/v1/W16-3636 (2016).

[14] Bar-Haim, R., Eden, L., Friedman, R., Kantor, Y., Lahav, D. and Slonim, N.: From Arguments to Key Points: Towards Automatic Argument Summarization, *CoRR*, Vol. abs/2005.01619 (online), https://arxiv.org/abs/2005.01619 (2020).

[15] Shirafuji, D., Rzepka, R. and Araki, K.: Argument Extraction for Key Point Generation Using MMR-Based Methods, *IEEE Access*, Vol. 9, pp. 103091–103109 (online), 10.1109/ACCESS.2021.3097976 (2021).

[16] Reimers, N. and Gurevych, I.: Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks, *CoRR*, Vol. abs/1908.10084 (online), http://arxiv.org/abs/1908.10084 (2019).

[17] Zhao, W., Peyrard, M., Liu, F., Gao, Y., Meyer, C. M. and Eger, S.: MoverScore: Text Generation Evaluating with Contextualized Embeddings and Earth Mover Distance, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, Association for Computational Linguistics, pp. 563–578 (online), 10.18653/v1/D19-1053 (2019).

[18] Lippi, M. and Torroni, P.: Context-Independent Claim Detection for Argument Mining, *Proceedings of the 24th International Conference on Artificial Intelligence*, IJCAI'15, AAAI Press, p. 185–191 (2015).

[19] Stab, C. and Gurevych, I.: Parsing Argumentation Structures in Persuasive Essays, *CoRR*, Vol. abs/1604.07370 (online), http://arxiv.org/abs/1604.07370 (2016).

[20] Shirafuji, D., Rzepka, R. and Araki, K.: Debate Outcome Prediction using Automatic Persuasiveness Evaluation and Counterargument Relations (2019).

[21] Stab, C., Daxenberger, J., Stahlhut, C., Miller, T., Schiller, B., Tauchmann, C., Eger, S. and Gurevych, I.: ArgumenText: Searching for Arguments in Heterogeneous Sources, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, New Orleans, Louisiana, Association for Computational Linguistics, pp. 21–25 (online), 10.18653/v1/N18-5005 (2018).

[22] Ein-Dor, L., Shnarch, E., Dankin, L., Halfon, A., Sznajder, B., Gera, A., Alzate, C., Gleize, M., Choshen, L., Hou, Y., Bilu, Y., Aharonov, R. and Slonim, N.: Corpus Wide Argument Mining—A Working Solution, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 34, No. 05, pp. 7683–7691 (online), 10.1609/aaai.v34i05.6270 (2020).

[23] Amgoud, L. and David, V.: Measuring Similarity between Logical Arguments, *Sixteenth International Conference on Principles of Knowledge Representation and Reasoning*, Tempe, United States, (online), https://hal.archives-ouvertes.fr/hal-02325829 (2018).

[24] Boltužić, F. and Šnajder, J.: Back up your Stance: Recognizing Arguments in Online Discussions, *Proceedings of the First Workshop on Argumentation Mining*, Baltimore, Maryland, Association for Computational Linguistics, pp. 49–58 (online), 10.3115/v1/W14-2107 (2014).

[25] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. and Dean, J.: Distributed Representations of Words and Phrases and their Compositionality, *CoRR*, Vol. abs/1310.4546 (online), http://arxiv.org/abs/1310.4546 (2013).

[26] Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A. and Fidler, S.: Skip-Thought Vectors, *Advances in Neural Information Processing Systems* (Cortes, C., Lawrence, N., Lee, D., Sugiyama, M. and Garnett, R., eds.), Vol. 28, Curran Associates, Inc. (2015).

[27] Hadsell, R., Chopra, S. and LeCun, Y.: Dimensionality Reduction by Learning an Invariant Mapping, *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06)*, Vol. 2,

pp. 1735–1742 (online), 10.1109/CVPR.2006.100 (2006).

[28] Hoffer, E. and Ailon, N.: Deep Metric Learning Using Triplet Network, *Similarity-Based Pattern Recognition* (Feragen, A., Pelillo, M. and Loog, M., eds.), Cham, Springer International Publishing, pp. 84–92 (2015).

[29] Kusner, M., Sun, Y., Kolkin, N. and Weinberger, K.: From Word Embeddings To Document Distances, *Proceedings of the 32nd International Conference on Machine Learning* (Bach, F. and Blei, D., eds.), Proceedings of Machine Learning Research, Vol. 37, Lille, France, PMLR, pp. 957–966 (online), https://proceedings.mlr.press/v37/kusnerb15.html (2015).

[30] Rubner, Y., Tomasi, C. and Guibas, L. J.: The Earth Mover's Distance as a Metric for Image Retrieval, *International Journal of Computer Vision*, Vol. 40, No. 2, pp. 99–121 (online), 10.1023/A:1026543900054 (2000).

[31] Zhang, Y., He, R., Liu, Z., Lim, K. H. and Bing, L.: An Unsupervised Sentence Embedding Method by Mutual Information Maximization, *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Online, Association for Computational Linguistics, pp. 1601–1610 (online), 10.18653/v1/2020.emnlp-main.124 (2020).

[32] Somasundaran, S. and Wiebe, J.: Recognizing Stances in Ideological On-Line Debates, *Proceedings of the NAACL HLT 2010 Workshop on Computational Approaches to Analysis and Generation of Emotion in Text*, Los Angeles, CA, Association for Computational Linguistics, pp. 116–124 (online), https://aclanthology.org/W10-0214 (2010).

[33] Anand, P., Walker, M., Abbott, R., Fox Tree, J. E., Bowmani, R. and Minor, M.: Cats Rule and Dogs Drool!: Classifying Stance in Online Debate, *Proceedings of the 2nd Workshop on Computational Approaches to Subjectivity and Sentiment Analysis (WASSA 2.011)*, Portland, Oregon, Association for Computational Linguistics, pp. 1–9 (online), https://aclanthology.org/W11-1701 (2011).

[34] Walker, M., Anand, P., Abbott, R. and Grant, R.: Stance Classification using Dialogic Properties of Persuasion, *Proceedings of the 2012 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Montréal, Canada, Association for Computational Linguistics, pp. 592–596 (online), https://aclanthology.org/N12-1072 (2012).

[35] Hasan, K. S. and Ng, V.: Stance Classification of Ideological Debates: Data, Models, Features, and Constraints, *Proceedings of the Sixth International Joint Conference on Natural Language Processing*, Nagoya, Japan, Asian Federation of Natural Language Processing, pp. 1348–1356 (online), https://aclanthology.org/I13-1191 (2013).

[36] Sridhar, D., Foulds, J., Huang, B., Getoor, L. and Walker, M.: Joint Models of Disagreement and Stance in Online Debate, *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, Beijing, China, Association for Computational Linguistics, pp. 116–125 (online), 10.3115/v1/P15-1012 (2015).

[37] Sun, Q., Wang, Z., Zhu, Q. and Zhou, G.: Stance Detection with Hierarchical Attention Network, *Proceedings of the 27th International Conference on Computational Linguistics*, Santa Fe, New Mexico, USA, Association for Computational Linguistics, pp. 2399–2409 (online), https://aclanthology.org/C18-1203 (2018).

[38] Ferreira, W. and Vlachos, A.: Emergent: a novel data-set for stance classification, *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, San Diego, California, Association for Computational Linguistics, pp. 1163–1168 (online), 10.18653/v1/N16-1138 (2016).

[39] Mohammad, S., Kiritchenko, S., Sobhani, P., Zhu, X. and Cherry, C.: SemEval-2016 Task 6: Detecting Stance in Tweets, *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016)*, San Diego, California, Association for Computational Linguistics, pp. 31–41 (online), 10.18653/v1/S16-1003 (2016).

[40] Kochkina, E., Liakata, M. and Augenstein, I.: Tur-

ing at SemEval-2017 Task 8: Sequential Approach to Rumour Stance Classification with Branch-LSTM, *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, Vancouver, Canada, Association for Computational Linguistics, pp. 475–480 (online), 10.18653/v1/S17-2083 (2017).

[41] Chen, W.-F. and Ku, L.-W.: UTCNN: a Deep Learning Model of Stance Classification on Social Media Text, *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers*, Osaka, Japan, The COLING 2016 Organizing Committee, pp. 1635–1645 (online), https://aclanthology.org/C16-1154 (2016).

[42] Sobhani, P., Inkpen, D. and Zhu, X.: A Dataset for Multi-Target Stance Detection, *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*, Valencia, Spain, Association for Computational Linguistics, pp. 551–557 (online), https://aclanthology.org/E17-2088 (2017).

[43] Augenstein, I., Rocktäschel, T., Vlachos, A. and Bontcheva, K.: Stance Detection with Bidirectional Conditional Encoding, *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, Austin, Texas, Association for Computational Linguistics, pp. 876–885 (online), 10.18653/v1/D16-1084 (2016).

[44] Du, J., Xu, R., He, Y. and Gui, L.: Stance Classification with Target-Specific Neural Attention Networks, *Proceedings of the 26th International Joint Conference on Artificial Intelligence*, IJCAI'17, AAAI Press, p. 3988–3994 (2017).

[45] Mohtarami, M., Baly, R., Glass, J., Nakov, P., Màrquez, L. and Moschitti, A.: Automatic Stance Detection Using End-to-End Memory Networks, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics, pp. 767–776 (online), 10.18653/v1/N18-1070 (2018).

[46] Riedel, B., Augenstein, I., Spithourakis, G. P. and Riedel, S.: A simple but tough-to-beat baseline for the Fake News Challenge stance detection task, *CoRR*, Vol. abs/1707.03264 (online), http://arxiv.org/abs/1707.03264 (2017).

[47] Hanselowski, A., PVS, A., Schiller, B., Caspelherr, F., Chaudhuri, D., Meyer, C. M. and Gurevych, I.: A Retrospective Analysis of the Fake News Challenge Stance-Detection Task, *Proceedings of the 27th International Conference on Computational Linguistics*, Santa Fe, New Mexico, USA, Association for Computational Linguistics, pp. 1859–1874 (online), https://aclanthology.org/C18-1158 (2018).