深層格解析を用いた駄洒落質問応答ペアの自動生成
Automatic Generation of Japanese Pun Question Answer Pairs using Deep Case Analysis

王　格格 [1]　荒木　健治 [2]
Gege Wang[1]　Kenji Araki[2]
北海道大学大学院情報科学院 [1]　北海道大学大学院情報科学研究院 [2]
Graduate School of Information Science and Technology, Hokkaido University[1]
Faculty of Information Science and Technology, Hokkaido University[2]

1 はじめに

最近，新型コロナウイルスの感染が拡大に伴い，うつ病などの精神疾患の罹患者が増加する傾向にある．自粛生活や在宅勤務などの原因で周りの人とのコミュニケーションが少なくなったことも一つの原因である．このため，友人とオンラインで話す時間を作るなど，無理のない範囲でコミュニケーションをとることで心の安定が図ることができると考えられる．また，臨床心理学において ,笑いとユーモアによる治療法が成人のうつ病や不安を軽減することが知られている．また，笑いが長く継続する程，うつ状態に対して効果的であるとされている．さらに，ユーモアが人の葛藤や感情の表出を促進することがあるとの報告もある[1]．しかし，人と接することを恐れていて，友達とのコミュニケーションを取ることが難しいといった問題を抱えている人もいる．

近年，これらの問題を解決する手段として自動的に対話を行う雑談システムが注目を集めている．See らの研究[2]によると，人間は雑談システムと会話するとき，雑談システムが人間のように論理的でなくても楽しい時間を過ごすことができる．さらに，Liu らの研究[3]によると，ユーモアを有する文は助動詞や否定文，修辞疑問などを用いることで，より生き生きとした文になる傾向があるとされている．

また，雑談対話システムにおいては，ユーザが長時間利用し続けたいと思うようなデザインが求められる．さらに，Dybala らの研究[4]によると，ユーモアを理解できる雑談システムの対話は継続性を高めると指摘されている．本研究では日本語の短文ユーモアの代表例として駄洒落に着目した．駄洒落は音韻的に似ている二つの語を一文中に含めることで，意外性によるユーモアを表現するものである．我々は，質問を交えた駄洒落を生成することで，人間と雑談システムの会話を自然にユーモアのあるものにできると考えている．そこで，本稿では，大規模な駄洒落データベース[5]と深層格解析を用いて，駄洒落の質問応答ペアを生成する手法を提案し，質問応答ペアに変換した駄洒落が面白いものであるかを検証するために評価実験を行った結果について述べる．

2 関連研究

ユーモアの生成に関する研究としては，滝澤ら[6]の日本語駄洒落のなぞなぞ生成が挙げられる．そこで滝澤らは，テンプレートとそれを埋めたスキーマを定義して生成実験を行った．荒木らは駄洒落データベースを用い，駄洒落の自動生成システムを構築した[7]．また，畠山らは Transformer という機械学習手法を用いて駄洒落の自動生成実験を行った[8]．本研究では，Pamulapati が定義したユーモアのスキーマ[9]に基づいて深層格解析という従来手法を採用して駄洒落のスキーマを変更する．

Pamulapati らの研究[9]では，ユーモアのスーキマを会話型及び非会話型に分け，また会話型を Dialogue-会話型や Monologue-会話型に分類した．次に，それぞれに対して例を挙げて説明する．

まず，非会話型ユーモアでは，雑談システムと人間の対話中で，雑談システムのみがユーモアを単独で用いる．図 2-1 に例を示す．

ユーザ：ロボットちゃん、つまらない
システム：ユーモアのある話を聞きたいですか？
ユーザ：はい
システム：夏季に食べた柿

図 2-1　非会話型ユーモアの例

Monologue-会話型ユーモアでは，雑談システムが一人芝居でユーモアのある対話を読み上げる．図 2-2 に例を示す．

ユーザ：ロボットちゃん、つまらない
システム：ユーモアのある話を聞きたいですか？
ユーザ：はい
システム：ある日，警察署、
上司:なぜあの人を連れもどしたのか？
部下:無症状感染者
上司:それは病院に連れて行くべきだった
部下:いや、その人は無免許運転で人をはねてしまったのだ

図 2-2　Monologue-会話型ユーモアの例

Dialogue-会話型ユーモアでは，ユーモアを雑談システムとユーザの対話の形で用いる．図 2-3 では駄洒落をなぞなぞクイズの形で対話に用いた例を示す．

ユーザ：ロボットちゃん、つまらない
システム：ユーモアのある話を聞きたいですか？
システム：はい
システム：海に落ちた馬はどうになった
ユーザ：わかりません
システム：海馬になったよ

図 2-3　Dialogue-会話型ユーモアの例

本研究では，非会話型駄洒落の名詞を疑問詞に置き換えて，質問応答ペアの形として Dialogue-会話型駄洒落の生成を行う．

また，Liu らの研究[3]によると，質問が多く会話的な文章はユーモアの度合いが強くなるとされている．そのため本研究における駄洒落の質問応答ペアの生成は，雑談システムとユーザの対話をユーモアの度合いを強くすることができると考えられる．

3 実験方法

3.1 生成実験

3.1.1 提案手法

本手法では，従来手法である深層格解析を用いる．深層格解析とは述語（主に動詞）を文の中心に据え，その周りにある述語以外の構文要素に述語との意味的関係（深層格）を割り付けるというものである．深層格解析では，一般的に格フレームを用いて解析する[10][11]．格フレームとは，用言とそれに関係する名詞を用言の各用法ごとに整理したものである[12]．

牧野ら[13]は機械学習の手法で質問応答ペアを自動生成したが，本研究では機械学習の推論ベース手法を使用しなかった．使用しなかった理由として，以下に述べる三つがある．

一つ目は，推論ベース手法では機械学習モデルを構築するために人手で大量の学習データを用意しなければならず，また推論ベース手法は日本語の単語の間にある特有な知識を獲得し難しいと考えられているからである．二つ目は，深層格解析では日本語の形態素の依存関係に応じて，疑問詞を埋めることができるようになる利点があるからである．三つ目は，深層格解析は推論ベース手法よりシンプルかつ実現しやすいと考えられるからである．

また，三つのステップで提案手法を実現する．提案手法を説明するために，以下に例を挙げる．

例：「私がうどんを食べたいです.」

まず，上記文に対して係り受け解析を行う．係り受け関係は形態素の依存関係を示すものである．図 3-1 に係り受け解析結果を示す．

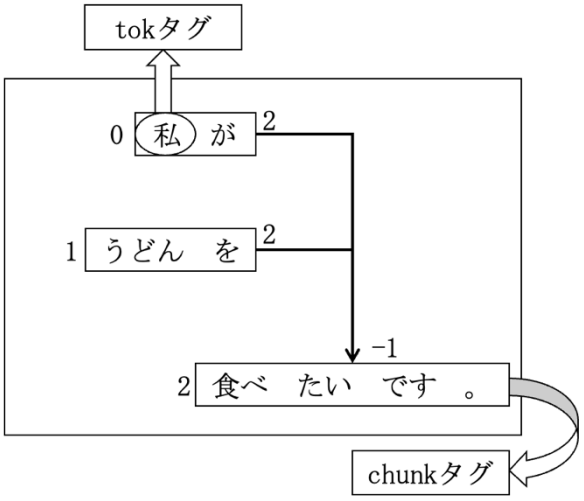


図 3-1　係り受け解析を行った結果

図 3-1 で tok タグが形態素に対応しており，chunk タグが文節に対応している．chunk タグに link プロパティがあるが，この文節は link 先の文節との依存関係を示している．各 chunk タグの左側には文節番号，右側または上にはかかり先の文節番号が書かれている．グラフ構造にしたものを図 3-2 に示す．

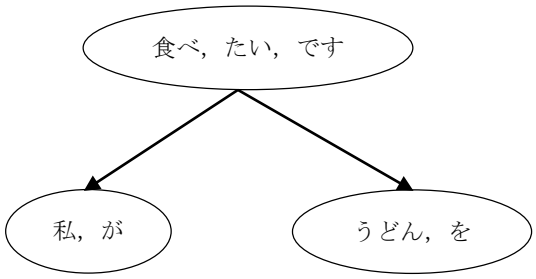


図 3-2　依存関係のグラフ構造

次に，係り受け解析した文節に意味ラベルを付与する．意味ラベルを付与するために，深層格解析を使用する．深層格[14]については，チャールズ・フィルモアが提案した 8 つの深層格[15]，動作主格，対象格，経験者格，道具格，源泉格，目標格，場所格，時間格が一般によく知られており，本実験ではこれらの深層格の定義を使用する．

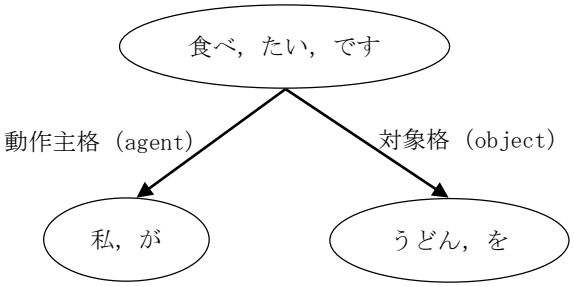


図 3-3　グラフのエッジに意味ラベル付与した結果

最後に，意味ラベルから質問応答ペアを生成する．深層格解析により文節間の意味的関係を解析できたので，例えば図 3-3 の「動作主格」から「誰が」を質問でき，「対象格」から「何を」を質問できる．このようにして以下のような質問応答を自動生成することができる．

・「誰が食べたいですか」→「私が」
・「何を食べたいですか」→「うどんを」

本実験では，荒木らが開発した 67,000 文の大規模な駄洒落データベース[5]を使用する．駄洒落データベースでは，駄洒落を種表現（文内の独立形態素）と変形表現（種表現との音韻的類似性を持つ文内の任意の区間の音素列を指す）の関係から 4 つの類型に分類した．表 3-1 にそれぞれの例を示す．

・Perfect：種表現と変形表現が字面上完全に一致するもの
・Imperfect：種表現と変形表現が字面上完全には一致しないもの
・重畳型：変形表現しか存在しないもの
・不明：駄洒落として解釈できないもの

表3-1 駄洒落の種類と例

種類		例
併置型	1. perfect	炭のすみか
	2. imperfect	きちんと作ったチキン
3. 重畳型		すいま千羽鶴
4. 不明		李と相撲もするよ

生成実験は 67,000 文のデータを使用して行うが，併置型駄洒落のみに種表現や変形表現が含まれているため，考察及び評価実験は併置型駄洒落に対してのみ行う．

3.1.2 実験結果

今回，67,000 文の駄洒落に対して生成実験を行った．結果を表 3-2 に示す．

表3-2　67,000 文駄洒落の生成結果

	駄洒落数	生成数	生成率	精度	生成不能率
全体	67,000	36,782	0.549	0.548	0.451
併置型駄洒落	62,918	34,996	0.555	0.555	0.445

まず，生成率，精度，生成不能率の計算方法をそれぞれ説明する．生成率は，生成された質問応答数(生成数)を駄洒落数で割って算出する．精度は，生成された質問応答から無意味な質問応答を削除し，駄洒落数で割って算出する．また，生成不能率は，質問応答が生成されない駄洒落数を駄洒落数で割って算出する．表 3-2 では，併置型駄洒落においては，無意味な生成が少なかったため，生成率と精度がほぼ等しい結果となっている．

また，前述した無意味な生成について例を挙げて説明する．例えば，“孟宗竹<もうそうだけ>を食べたのは、妄想だっけ？”という駄洒落から生成された質問応答ペアの質問は“孟宗竹<もうそうだけ何を食べたのは、妄想だっけか？”，回答は“>”である．回答は記号のみであるため，無意味な生成と考えられ，人手で削除した．

無意味な生成を削除した後のデータは整理済みとしてマークされる．整理済みのデータにおける各駄洒落から生成された質問応答ペアの数を図 3-4 に示す．図 3-4 によると，約 70%の駄洒落には少なくとも 1 文の質問応答ペアが生成されたことが明らかになった．

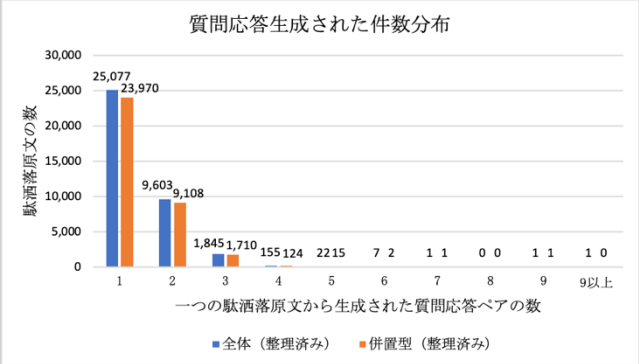


図 3-4　各駄洒落（原文）が生成された駄洒落応答ペアの数

本実験において，最も多く駄洒落質問応答ペアが生成された駄洒落は“月曜、本をよまんでー。火曜、パパとママがチューずでー。水曜、木を植えんずでー。木曜、蜂が刺ーずでー。金曜、おかずはフライでー。土曜、恋人が去ったでー。日曜、とうとう破産でー。”であり，合計 14 件の質問応答ペアが生成された．その 14 件の中から一つの質問応答ペアを例として挙げると，質問は“月曜、何を読まんでー火曜、パパとママがチューずでー水曜、木を植えんずでー木曜、蜂が刺ーずでー金曜、おかずはフライでー土曜、恋人が去ったでー日曜、とうとう破産でーか？”，回答は“本”であった．また，1 件のみ駄洒落質問応答ペアが生成された “暗いと、ライトをつける！”という駄洒落では，生成された駄洒落質問応答ペアの質問は“暗いと、何をつけるか？”，回答は“ライト”であった．

重畳型や不明の駄洒落には，種表現や変形表現が含まれていないため，併置型駄洒落のみに関して考察する．まず，種表現または変形表現と完全に一致している回答をもつ質問応答ペアは正しい生成と考えられる．質問応答ペアの生成数が一つのものを統計したデータを表 3-3 に示す．

表 3-3　質問応答ペアの回答は種表現または変形表現と完全に一致しているもの

	種表現	変形表現
完全一致	19, 256	1, 360
生成数	34, 930	34, 930
精度	0. 551	0. 039

一方，質問応答ペアの回答が種表現または変形表現と完全に一致していないが，正しい生成として考慮すべき生成もある．その例は 2 パターン考えられ，具体例をあげてそれぞれ説明する．

一つ目は，生成ルールベースにより余分な部分を削除できるものである．例えば，“横須賀から洋行すか？”という駄洒落から生成された質問応答ペアの質問は“何処から洋行すか？”であり，回答は“横須賀から”である．回答の中の“から”は，生成ルールベースを使用して取り除くことができるが，質問応答ペアの一貫性を確保するために削除しなかった．

二つ目は，種表現または変形表現と一体のものとして考慮することができるものである．例えば，“メロン食べるのは、やめろん”という駄洒落から生成された質問応答ペアの質問は“何が、やめろんか？”であり，回答は“メロン食べる”である．回答の中の“食べる”は“メロン”と一体であることを考慮すると，“メロン”をやめるのではなく，“メロン食べる”のことをやめるのが正しい．

以上のことを考慮して正しく生成された質問応答ペアについて，統計データを表 3-4 に示す．

表 3-4　正しく生成された質問応答ペア

	種表現	変形表現
完全一致	19, 256	1, 360
合計	28, 810	1, 846
生成数	34, 930	34, 930
精度	0. 551	0. 039
生成率	0. 825	0. 063
生成不能率	0. 175	0. 947

まず，精度，生成率，生成不能率の計算方法をそれぞれ説明する．精度は，種表現または変形表現と完全に一致している回答の質問応答ペアの数を生成された質問応答ペアの数(生成数)で割って算出する．生成率は，種表現または変形表現と完全に一致している回答の質問応答ペアの数や種表現または変形表現と完全に一致していない質問応答ペアの数の合計を生成された質問応答ペアの数(生成数)で割って算出する．生成不能率は，種表現また変形表現が含まれていない回答の質問応答ペアの数を生成された質問応答ペアの数(生成数)で割って算出する．

表 3-4 に示す生成率と精度によると，種表現または変形表現と完全に一致していない質問応答ペアも正しい生

成として考慮すると，質問応答の生成精度が顕著に向上することが判明した．

3.2 評価実験

3.2.1 サンプル数計算

サンプリング方法でデータを抽出し，人手で評価実験を行う．

$$n = \frac{\frac{z^2 \times p(1-p)}{e^2}}{1 + \left(\frac{z^2 \times p(1-p)}{e^2 N} \right)} \quad (3\text{-}1)$$

サンプル数の計算方法を式(3-1)に示す．n はサンプル数，z は信頼レベル，N は併置型駄洒落から生成された質問応答ペアの数，p は正解率，e は許容誤差である．一般的に「許容誤差」5%，「信頼レベル」95%で統計上は十分意味があるとされるため，本実験ではこのように設定することで必要なサンプル数を求めることができる．

3.2.2 実験結果

3.2.1 で述べたように算出したサンプル数は 226 文であるが，実際の評価実験ではそれより多めに抽出することで，信頼レベルが高くなると考えられる．したがって，250 文の駄洒落原文と 250 文の駄洒落の質問応答ペア，合計 500 文のデータを抽出した．

20 代理系男性大学生 2 名と 20 代理系男性大学院生 3 名が，それぞれ可読性（理解できるか），流暢さ（文法的に正確か），面白さの評価項目について 5 段階で評価を行った．その結果を表 3-5 に示す．

表 3-5　評価結果

	可読性	流暢さ	面白さ
駄洒落原型	4.11	4.53	3.02
駄洒落の質問応答ペア	3.56	4.07	2.68

可読性と流暢さについては，予想通りに駄洒落の質問応答ペアの方が駄洒落原型より低下していた．しかし，質問応答ペアにすることで向上すると期待していた面白さも低下していたため，その原因について調査した．その結果を表 3-6 に示す．表の 1 行目は，駄洒落の質問応答ペアの面白さが駄洒落原型より低下したデータである．2 行目は，駄洒落の質問応答ペアの面白さが駄洒落原型と同じデータである．3 行目は，駄洒落の質問応答ペアの面白さが駄洒落原型より向上したデータである．

表 3-6　評価結果

駄洒落原型			駄洒落の質問応答ペア		
可読性	流暢さ	面白さ	可読性	流暢さ	面白さ
4.16	4.49	3.61	3.29	3.85	2.14
3.98	4.56	2.69	3.63	4.14	2.69
4.00	4.48	2.16	3.78	4.28	3.43

表 3-6 から，可読性と流暢さが高い駄洒落を駄洒落質問応答ペアに変更することで可読性や流暢さに大きな悪影響を与え，面白さが低下することが明らかになった．しかし，面白くない駄洒落とそれらから生成された駄洒落の質問応答ペアの可読性と流暢さに少し差があると面白さが向上することが明らかになった．

4 まとめ

本稿では，深層格解析という手法を用いて，67,000 文の大規模な駄洒落データベースを使用して生成実験を行った．また，併置型駄洒落に対してサンプリング手法を利用し，大学生 2 名と大学院生 3 名による評価実験を行った．

まず，生成実験では，全体のデータの約 70%の駄洒落からは少なくとも一つの駄洒落の質問応答ペアが生成された．また，併置型駄洒落の中でも種表現の方は名詞が多いので，種表現に基づいた質問応答ペアの生成精度が高いと考えられる．さらに，生成された質問応答ペアの中に回答が種表現または変形表現と完全に一致していない文があるが，それを生成の成功例として考慮すると，質問応答の生成精度が顕著に向上する．最後に，可読性と流暢さが良い駄洒落原型を駄洒落質問応答ペアに変更することで面白さが低下するが，面白くない駄洒落原型とその生成された駄洒落の質問応答ペアの可読性と流暢さに少し差があっても面白さが向上することが判明した．

今後の予定として，本研究の手法では，質問応答ペアを生成することができなかった駄洒落もあったため，生成ルールを追加することでより多くの駄洒落の質問応答ペアを生成することができると考えている．また，生成された駄洒落の質問応答ペアの可読性や流暢さとその駄洒落の可読性や流暢さに大きな差があると，面白さが低下することがわかった．今後は質問応答ペアの可読性や流暢さを向上させる方法を検討していく予定である．

謝辞

本研究は JSPS 科研費 21K12007 の助成を受けたものである.

参考文献

[1] 森田亜矢子. "心理的援助への笑いとユーモアの適用に関する研究の動向と課題 心理療法, 精神疾患, ユーモアと笑いのセラピーに焦点をあてて." 笑い学研究 25, pp.17-41, 2018.

[2] See, Abigail, et al. "What makes a good conversation? how controllable attributes affect human judments." arXiv preprint arXiv:1902. 08654, 2019.

[3] Liu, Lizhen, Donghai Zhang, and Wei Song. "Exploiting syntactic structures for humor recognition." Proceedings of the 27th international conference on computational linguistics. pp. 1875-1883, 2018.

[4] Dybala, P., Ptaszynski, M., Maciejewski, J., Takahashi, M., Rzepka, R., Araki, K. Multiagent system for joke generation: Humor and emotions combined in human-agent conversation. Journal of Ambient Intelligence and Smart Environments, 2(1), pp. 31-48, 2010.

[5] 荒木健治, 内田ゆず, 佐山公一, 谷津元樹: 駄洒落データベースの構築及び分析, 人工知能学会第 2 種研究会 ことば工学研究会資料, SIG-LSE-B702-3, pp. 13-24, 2017.

[6] 滝澤修. 日本語駄洒落なぞなぞ生成システム"BOKE". 人工知能, 13(6), pp. 920-927, 1998.

[7] 荒木健治：駄洒落データベースを用いた駄洒落生成システムの性能評価, 人工知能学会第 2 種研究会 ことば工学研究会資料, SIG-LSE-B703-8, pp. 39-48, 2018.

[8] 畠山和久, 徳永健伸. Transformer を用いた日本語併置型駄洒落の自動生成, 言語処理学会第 27 回年次大会 (NLP2021), 言語処理学会第 27 回年次大会 (NLP2021)発表論文集, pp. 455-460 (B3-4), Mar. 2021.

[9] Pamulapati, V., Purigilla, G., Mamidi, R. A Novel Annotation Schema for Conversational Humor: Capturing the Cultural Nuances in Kanyasulkam. In Proceedings of the 14th Linguistic Annotation Workshop, pp. 34-47. Dec, 2020.

[10] Fillmore,C., 田中春美, 船城道雄（訳）：格文法の原理, 三省党, 1975.

[11] 水谷静夫（編）：朝倉日本語新講座 3 文法と意味 I, pp. 81-134, 朝倉書店, 1983.

[12] 河原大輔, 黒橋禎夫. 格フレーム辞書の漸次的自動構築. 自然言語処理, 12(2), pp. 109-131, 2005.

[13] 牧野拓哉, 野呂智哉, 吉川和, 岩倉友哉, 関根聡, 乾健太郎. 自動生成した質問に基づく質問応答学習手法の提案と評価, 言語処理学会第 24 回年次大会発表論文集, pp. 861-864, 2018.

[14] 国立国語研究所. 「日本語における表層格と深層格の対応関係(国立国語研究所)」三省堂. 1997.

[15] Fillmore, Charles J. “The Case for Case”, in Bach and Harms eds. Universals in Linguistic Theory, New York: Holt, Rinehart, and Winston, pp. 1–88, 1968.