議論データ抽出における意見と Key Point のスタンス分類を考慮した Match Scoring タスクの評価

Toward Automation from Stance Classification to Match Scoring of Arguments and Key Points for Debate Data Extraction

桝田大貴 [1], 白藤大幹 [1] , ジェプカ・ラファウ [2], 荒木健治 [2]

Daiki Masuda [1], Daiki Shirafuji [1], Rafal Rzepka [2], Kenji Araki [2]

[1] 北海道大学大学院情報科学院,[2] 北海道大学大学院情報科学研究院

[1] Graduate School of Information Science and Technology, Hokkaido University,

[2] Faculty of Information Science and Technology, Hokkaido University

1 はじめに

討論や議論は自然言語処理分野において注目されている研究テーマの一つである [1][2]. 議論に関する研究分野は議論マイニングと呼ばれ, この 10 年間でますます注目を集めている. 議論マイニングの中でも, 意見の説得力測定 [3][4], 意見同士のずれの解消 [5][6], 意見のスタンス (賛成/反対) を予測する [7][8] といったテーマは現在特に注目を集めている.

このタスクに取り組むには, ディベート, 議論, 論文等から収集された大量の意見 (argument) データを必要とする. 意見はオンラインディベートデータに大量に存在しているが, 人間がその全てを読み切ることは不可能である. そこで Bar-Haim ら [9] は意見データを集め, 1 つのトピックにおいて 14 個の key point で 72.5 %の意見を網羅していることを統計的に示した. Key point とは, 意味的に類似している意見を示す発言群を 1 つの意見に集約したものである. 本研究では, 人手で集約したものを key point として扱う. Ber-Haim らは意見と key point のペアを大量に作成し, Match Scoring タスクに取り組んだ. Match Scoring では意見と key point が同じ内容を示すかどうかを判別する. データセットには ArgKP データセット [9] が用いられており, 表 1 はその例を示している. Ber-Haim らは Match Scoring タスクにおいて, BERT-large[10] を fine-tune したモデルが教師ありの手法の中で最も精度が良いことを示した. また, BERT-large の embedding 手法が教師なしの手法の中で最も精度が良いことを示した. この Match Scoring によって, 複数の意見を同じ内容の意見ごとにクラスタリングすることで, 新しい key point 生成を容易にする.

白藤ら [11] は Match Scoring タスクに関して, Bar-Haim らの教師なし手法は各単語の embedding を平均化しているだけで, 重要単語が充分に活用できていないという問題点を指摘した. この問題点を解決するために Sentence-BERT[12] と MoverScore[13] を用いた手法を提案し, 共に既存手法の精度を上回り MoverScore が最も良い精度となることを示した.

討論や議論では賛成や反対などの意見の立場が明確ではない. しかし既存研究はスタンスが一致している意見と key point のペアから構成されるデータセットをもとに行っており, 意見と key point が同じ内容を示すか否かを事前のスタンス情報を持たずに分類するには至っていない. そこで桝田ら [14] は意見と key point のスタンスの一致を前提としない, より現実に近い分類タスクを設計した. それに伴い, 意見と key point のスタンスの一致を前提としないデータセットを作成した. また教師なし学習による分類器である STANCY[8] によってスタンス予測した情報を元にペア同士が同じ内容を示すか否かを判別する手法を提案した. 桝田らの手法と, スタンス分類を行わずに設計したモデルとを比較することで, Match Scoring の過程におけるスタンス分類器の有効性を示した. しかし, 最も精度の高い手法であっても, F 値で 40% であった. そのため, ハイパーパラメータの調整や学習データ量を増やすことによって, BERT の精度を大幅に上回ることに成功した RoBERTa[15] を用いた Sentence-RoBERTa[12] などを用いて精度向上の必要がある.

そこで本研究ではスタンスの一致を前提としない Match Scoring 分類タスクについて, Sentence-RoBERTa[12] を Match Scoring の手法に適用し, ベースラインとの比較評価実験により, 精度向上を実現した.

表 1: ArgKP データセットの例. データセットはある特定のトピックの意見と key point のペアで構成される. トピックに対しての意見と key point 共通のスタンス (賛成 (1), 反対 (-1)) ラベル付けされている. また意見と key point がマッチしているか (1) 否か (0) ラベル付けされている.

トピック: **We should ban human cloning**

意見	Key Point	スタンス	Match
human cloning is sick and morally wrong.	Cloning is unethical/anti-religious	1	1
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning can be used for organ replication	-1	0

2 関連研究

本章では, 本研究に関連する研究について説明する. **2.1** では, Match Scoring の際に最も重要な, テキスト間の類似度を計算する手法に関する関連研究について述べる. **2.2** ではスタンスの一致を前提としない Match Scoring タスクにおいて, スタンス分類器に用いるスタンス分類の手法に関する関連研究について述べる.

2.1 テキスト間の類似度

最近の研究ではテキスト間の類似度を算出するため, 文ベクトルや単語ベクトルを用いている. 単語ベクトルは単語 embedding, 文 embedding, または言語モデルにより計算される. 最もよく知られている手法の 1 つである word2vec[16] は, 単語をベクトルとして表現するために事前学習された skip-gram または Bag-of-Words (CBOW) モデルである. 事前学習された単語 embedding モデルに続き提案された, 文 embedding モデルである Skip-Thought Vectors[17] は, エンコーダデコーダモデルに基づいている. エンコーダでは単語を文ベクトルにマッピングし, デコーダでは周囲の文を生成する. Word Mover's Distance[18] は word2vec を使用してテキスト間の距離を算出し, Earth Mover's Distance[19] を自然言語処理の分野に導入している. これに影響を受けた Zhao ら [13] は, エンコーディングシステムの研究により, 要約または機械翻訳タスクを評価するための堅牢な評価指標, MoverScore を考案した. テキストの類似度の計算手法は他にも存在する. Reimers と Gurevych により提案された Sentence-BERT[12] は, シャムネットワーク [20] またはトリプレットネットワーク [21] に基づく文 embedding モデルである. このモデルでは, BERT[10] などの言語モデルをシャムネットワークもしくはトリプレットネットワークに導入している. 本研究では Match Scoring モデルに Mover Score と Sentence-BERT を用いた手法を比較手法としている.

2.2 スタンス分類

既存のスタンス分類の手法として, Ferreira と Vlachos[22] は, トピックや意見に含まれる語彙や, 意味的な特徴を活用したロジスティック回帰モデルを考案した. SemEval タスク [23][24] では, ツイートにおけるスタンス判定に取り組んだ. Bar-Haim ら [7] はスタンス分類のために, トピックと意見の主張の一貫性を識別する手書き辞書に基づく分類手法を考案した. これはスタンス分類のためのニューラルネットワークに基づく手法で, トピックの固有表現と意見の固有表現を別々に学習した後, Augenstein ら [25] の条件付き LSTM エンコーディング, Du ら [26] のアテンション機構, または Mohtarami ら [27] の Memory Networks と組み合わせられている. また Riedel ら [28] や Hanselowski ら [29] によるニューラルネットワークモデルは語彙的な特徴が取り入れられている. しかし, これらの手法には大規模な外部コーパスから得た知識を活用していないという問題点が存在した. この問題点を解決する手法として, Popat ら [8] は STANCY と呼ばれるスタンス分類のためのニューラルネットワークモデルを考案した. STANCY は大規模外部コーパスで学習した BERT と, トピックと意見の主張の一貫性制約を活用したスタンス分類のためのニューラルネットワークモデルである. STANCY はベンチマーク実験により, 既存手法を上回る結果を示した. 本研究ではスタンス分類における教師なし学習の手法の中で比較的良い精度を出した STANCY をスタンス分類の手法として適用する.

3 提案手法

本研究は, 意見と key point のスタンスが一致していないケースに対応した, スタンスの一致を前提としない分類タスク [14] に取り組んだ. **3.1** では, 本研究取り組むタスクについて述べる. 次に **3.2** では, Sentence-RoBERTa について, **3.3** では, 提案手法について説明する.

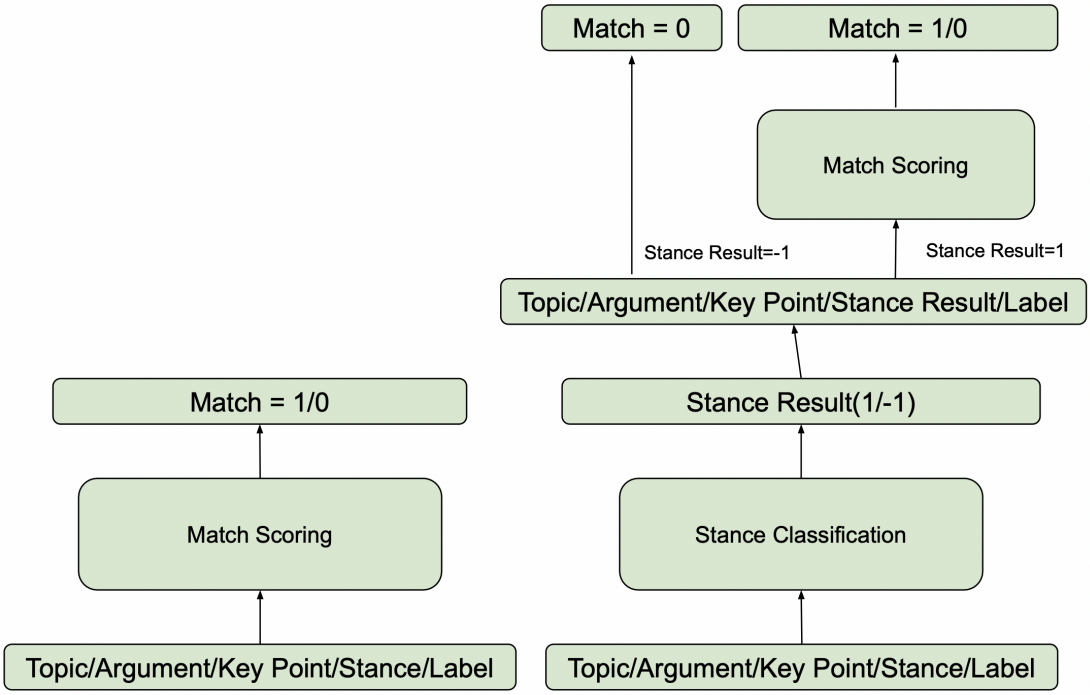


図 1: ベースライン（左）と提案手法（右）の概略図 [14]

3.1 タスク

本節では, 本研究で取り組むタスクについて述べる. 既存研究では, 意見と key point のスタンスが同一であることを前提としたタスクが多かった. しかし, 実際の議論の場で得られる意見はトピックに対してのスタンス (賛成/反対) がラベル付けされているわけではない. このようなタスク設定では, 生のディベートデータを集約するという研究目的は達成できない. したがって, 我々は Match Scoring の中でも, 意見のスタンスを考慮した Match Scoring に取り組む.

Match Scoring では表 1 のように, スタンスの同じ意見と key point のペアのみ見ていたが, 本タスクでは, スタンスの異なる意見と key point 同士のペアについても分類する.

3.2 Sentence-RoBERTa

初めに RoBERTa について説明した後, Sentence-RoBERTa について説明する. BERT は複数の Transformer エンコーダで構成された事前学習済み言語モデルである. BERT では, マスク穴埋め問題と次文予測によって, 大規模データで自己教師あり学習を行うことにより言語知識を獲得し, 文脈に応じた単語 embedding を出力する. マスク穴埋め問題は, 入力文中のトークンを, 一定割合で [MASK] という特殊なトークンに置換した上で入力し, [MASK] に対応する位置の最終層の embedding を用いて, 置換前のトークンを予測するタスクである. 次文予測は, 文を区切るトークン [SEP] で繋がれた 2 つの文を BERT に入力した際, 文頭に与えられた特殊なトークン [CLS] の出力をもとに, それらが元データで連続する文であるか否かを予測するタスクである. 本研究の提案手法で用いる RoBERTa は, BERT と同様の構造をしているが, BERT で事前学習時に行われていた次文予測を排除し, データサイズ, バッチサイズを大きくすることで BERT の改善を試みたモデルである.

このモデルを用いた Sentence-ROBERTa について以下で説明する. Siamese Neural Network (SNN) に RoBERTa を導入して, 文同士が類似しているか否かを判別できるように fine-tune したモデルが Sentence-RoBERTa (SRoBERTa) である. SRoBERTa の概要図を図 2 に示す.

Fine-tune には SNLI データセット [30] 及び, MultiNLI データセット [31] を用いている. まず文を RoBERTa に入力し, その出力を pooling することで文ベクトルを構成する. Pooling 手法には以下の 3 種類が用いられる.

1. CLS: BERT の事前学習時に次文予測で用いられる

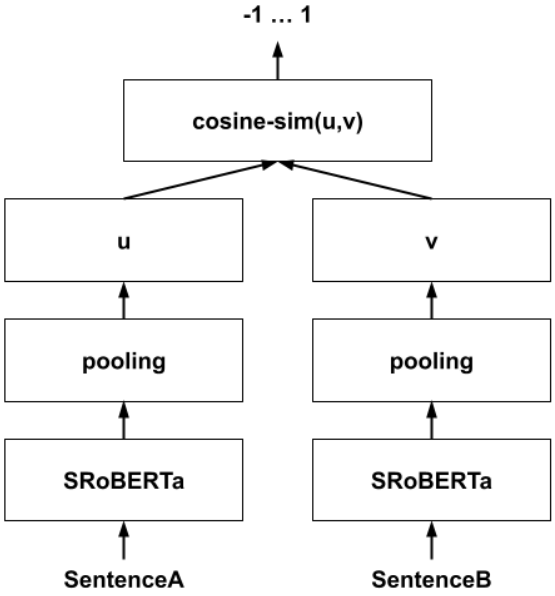


図 2: Sentence-RoBERTa の概要図

[CLS] トークンの embedding を用いる. 本研究では RoBERTa を用いるため [CLS] は存在しない.

2. Mean: 文を構成する全単語の文脈を考慮した単語 embedding の平均を用いる.
3. Max: 文を構成する全単語の文脈を考慮した単語 embedding の次元ごとの最大値を用いる.

Pooling により得られる文ペアのそれぞれの文ベクトルを **u**, **v** とする. 本研究で用いる RoBERTa には Reimers と Gurevych[12] らの Sentence-RoBERTa と同様, Mean pooling を採用している.

3.3 提案手法

本節では提案手法を説明する. 提案手法の概略図を図 1 に示す. 提案手法では初めに, 意見と key point のスタンスを判別する. 次に, ペア同士の類似度を測定し分類する.

3.3.1 スタンス分類

意見と key point それぞれについて, STANCY[8] を用いてスタンス分類を行う. STANCY とは, Popat らによって提案された, 教師なし学習によるスタンス分類器である. その予測値がペア同士で一致していなければ, 同じ内容を示していないものとする. なぜなら, スタンスの異なる意見同士は異なる内容を示すと仮定できるからである. 逆に, 同じスタンスであれば, 次節の類似度計算を行う.

3.3.2 類似度計算

意見と key point の文ベクトル同士の cos 類似度を算出し, cos 類似度が閾値を超えていれば同じ内容を示す, 逆に超えていなければ同じ内容を示さないと判定する. 判定に用いる閾値は, Bar-Haim ら [9] によって定められた方法に則り, F 値が最も大きくなるように設定する. 文ベクトルを獲得するために, 我々は SRoBERTa を導入する. SRoBERTa は, RoBERTa-base と RoBERTa-large を SNN に導入し, SNLI と MultiNLI で fine-tune した SRoBERTa-base と SRoBERTa-large がある. さらに, これらの学習済みモデルを STS データセットで再度学習した SRoBERTa-STSb-base と SRoBERTa-STSb-large がある. 本研究では, これら 4 種類の Sentence-RoBERTa に対して実験を行う.

4 評価実験

4.1 データセット

データセットには ArgKP データセット [9] を整形した NoStanceArgKP データセット [14] を用いる. ArgKP データセットは 24,093 組の意見と key point の組である. トピックに対する意見と key point のスタンスラベルと, ペア同士が同じ内容を示しているか否かのラベルを含む. ArgKP データセットのスタンスラベルを元に, 意見と key point にそれぞれのスタンスのラベルを付与する. 次に同じトピックの意見と key point を, スタンスが一致しているかに関わらずペアにし, 意見と key point それぞれにスタンスのラベルが付与されたデータセットが NoStanceArgKP データセットである. NoStanceArgKP データセットの例を表 2 に示す. NoStanceArgKP データセットは 52,429 組からなる. このデータセットを用いてスタンスの一致を前提としない Match Scoring タスクに取り組む.

4.2 評価指標

本研究のスタンスの一致を前提としない Match Scoring タスクの評価は, 比較手法と提案手法ともに最終的な Match Scoring の結果を用いる. そのため Bar-Haim ら [9] に続き, Match Scoring のための 4 つの評価指標, 正解率 (Accuracy), 適合率 (Precision), 再現率 (Recall), F 値を用いる. これらの評価指標の計算方法は式 (1) 〜 (4) に示す.

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \tag{1}$$

$$Precision = \frac{TP}{TP + FP} \tag{2}$$

$$Recall = \frac{TP}{TP + FN} \tag{3}$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \tag{4}$$

表 2: ArgKP データセットを元に作成された NoStanceArgKP データセットの例. データセットはある特定のトピックの意見と key point のペアで構成される. 意見と key point それぞれはトピックに対するスタンス (賛成 (1), 反対 (-1)) ラベル付けされている. また意見がペアとなる key point に集約される (1) か否か (0) についてもラベル付けされている.

トピック: **We should ban human cloning**

意見	Key Point	Argstance	KPstance	Match
human cloning is sick and morally wrong.	Cloning is unethical/anti-religious	1	1	1
human cloning is sick and morally wrong.	Cloning can be used for organ replication	1	-1	0
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning can be used for organ replication	-1	-1	0
human cloning is an important step in prolonging life, ending disease and ending suffering.	Cloning is unethical/anti-religious	-1	1	0

4.3 比較手法

本研究では, はじめに, ベースラインとして, スタンス分類器を導入しないモデルと提案手法を比較する. これはスタンス分類器の導入の有効性を示すためである. ベースラインの概略図は図 1 (左) に示す. ベースラインでは, 意見と key point のペアを入力として 3.3.2 節で類似度計算手法によって分類する. この手法では, 提案手法とは異なり, ディベートテーマやそのテーマに対する意見や key point のスタンスは考慮しない.

またベースラインの他に, 桝田らが提案した手法を比較手法として用いる. この比較手法は, 提案手法の類似度計算に MoverScore もしくは Sentence-BERT を用いたものである.

5 実験結果

各手法の正解率, 適合率, 再現率, F 値を表 3 に示す. 正解率, 適合率, F 値の観点において, Sentence-RoBERTa-large を用いた提案手法が最も高い精度を示した. 一方再現率に関してみると, 全ての提案手法において, 対応するベースラインと比べて低い再現率を算出した.

表 3: 評価実験結果

Model	Accuracy	Precision	Recall	F1
MoverScore	0.827	0.239	0.417	0.304
SBERT-base	0.790	0.253	0.677	0.368
SBERT-large	0.844	0.309	0.579	0.402
SBERT-STSb-base	0.782	0.230	0.599	0.333
SBERT-STSb-large	0.796	0.238	0.568	0.335
SRoBERTa-base	0.863	0.324	0.473	0.385
SRoBERTa-large	0.798	0.271	**0.728**	0.395
SRoBERTa-STSb-base	0.814	0.234	0.461	0.310
SRoBERTa-STSb-large	0.852	0.285	0.420	0.339
STANCY+MoverScore	0.878	0.325	0.323	0.324
STANCY+SBERT-base	0.860	0.328	0.518	0.402
STANCY+SBERT-large	0.867	0.338	0.493	0.401
STANCY+SBERT-STSb-base	0.826	0.261	0.503	0.344
STANCY+SBERT-STSb-large	0.858	0.287	0.386	0.329
STANCY+SRoBERTa-base	0.876	0.344	0.408	0.373
STANCY+SRoBERTa-large	**0.901**	**0.447**	0.378	**0.410**
STANCY+SRoBERTa-STSb-base	0.865	0.306	0.389	0.342
STANCY+SRoBERTa-STSb-large	0.880	0.337	0.338	0.338

6 考察

この章では, 提案手法の実験結果に対して考察を行う. はじめに, テストデータの正例と負例の数を比べると, 正例の数が 4,998 個, 負例の数が 47,433 個であった. 負例が正例に比べて約 10 倍存在する. 従って, 分類手法の予測能力が不足している場合, 負例の数が遥かに多く存在するため, ペアを負例と分類しやすい. 従って, 再現率よりも適合率に重点を置く必要がある. 適合率に関してみると, スタンス分類器に STANCY を導入し, RoBERTa-large を NLI で fine-tune したモデルを用いた手法が最も高い精度を示した.

そのため, 提案手法の優位性が示されたと言える. しかし, 再現率に関して見ると, 全ての提案手法において, それぞれのベースラインを下回る結果となった. これは, 提案手法ではスタンス分類で誤判定されてしまう正例のサン

プルが増えてしまったためである. そのため, スタンス分類器の精度を向上させることができれば, 再現率向上に繋がる. 従って, 今後はスタンス分類器の精度向上を図る.

次に, 類似度計算に用いた手法である, RoBERTa-large を NLI と MultiNLI で fine-tune したモデルを用いた手法の結果について, エラー分析を行った. ペア同士の内容が同じであるのにも関わらず, 提案手法によって負例と誤分類されたサンプルとして, “We should prohibit women in combat” というトピックの, “if they want equal rights they should be drafted and fight in wars just like men.” という意見と, “There should be equality between men and women.” という key point のペアがある. 意見と key point は共にトピックに対して同じ内容を示しているにも関わらず, cos 類似度は 0.497 と低い. これに関しては意見と key point は共に, 男女平等であるべきだという同じ主張をしているが, key point は戦争への参加というトピックに関する内容が含まれていないため, 類似度が低くなってしまったと考えられる. 同トピックに関して, “we should not prohibit women in combat as women are as vital as men in this situation and can bring new skills and opinions in a war environment.” という意見と, “Women can create unique skills/strategies” という key point のペアを挙げる. このペアに関しても cos 類似度が 0.479 と低い. これに関しては, 意見はトピックに対する明確なスタンスを示しており, その根拠に関しても明確に示されているのに対して, key point はスタンスを直接示す文が明確に書かれておらず, 根拠についてのみ述べられている. このようなペアは, 同じ内容の意見を示しているのにも関わらず, 類似度が低くなってしまっている. そのため, 予めトピックに関する情報を追加するなどにより, 類似度計算の精度向上が期待できる.

7 まとめ

本稿では, Match Scoring タスクの中でも, 実データに活用するため, key point と意見とのスタンスの一致を前提としない分類タスクに取り組んだ. Sentence-RoBERTa を用いた手法を提案し, 評価実験により正解率が, MoverScore を用いた手法と比べて, 12.3% 向上した. 今後の課題として, ディベートトピックを考慮した文ベクトルの生成により, 類似度計算の精度向上を図る. また, 提案手法の再現率向上のために, スタンス分類器についても精度向上を図る.

参考文献

[1] Cabrio, E. and Villata, S.: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, IJCAI-18*.

[2] Lawrence, J. and Reed, C.: Argument Mining: A Survey, Vol. 45, No. 4 (2020).

[3] Habernal, I. and Gurevych, I.: Which argument is more convincing? Analyzing and predicting convincingness of Web arguments using bidirectional LSTM, *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Berlin, Germany, Association for Computational Linguistics (2016).

[4] Persing, I. and Ng, V.: *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI-17*.

[5] Boltužić, F. and Šnajder, J.: Fill the Gap! Analyzing Implicit Premises between Claims from Online Debates, *Proceedings of the Third Workshop on Argument Mining (ArgMining2016)*, Berlin, Germany, Association for Computational Linguistics (2016).

[6] Habernal, I., Wachsmuth, H., Gurevych, I. and Stein, B.: Before Name-Calling: Dynamics and Triggers of Ad Hominem Fallacies in Web Argumentation, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics (2018).

[7] Bar-Haim, R., Bhattacharya, I., Dinuzzo, F., Saha, A. and Slonim, N.: Stance Classification of Context-Dependent Claims, *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers*, Valencia, Spain, Association for Computational Linguistics (2017).

[8] Popat, K., Mukherjee, S., Yates, A. and Weikum, G.: STANCY: Stance Classification Based on Consistency Cues, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, Association for Computational Linguis-

tics (2019).

[9] Bar-Haim, R., Eden, L., Friedman, R., Kantor, Y., Lahav, D. and Slonim, N.: From Arguments to Key Points: Towards Automatic Argument Summarization, *CoRR*, Vol. abs/2005.01619 (2020).

[10] Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, Minneapolis, Minnesota, Association for Computational Linguistics (2019).

[11] Shirafuji, D., Rzepka, R. and Araki, K.: Argument Extraction for Key Point Generation Using MMR-Based Methods, *IEEE Access*, Vol. 9, pp. 103091–103109 (2021).

[12] Reimers, N. and Gurevych, I.: Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks, *CoRR*.

[13] Zhao, W., Peyrard, M., Liu, F., Gao, Y., Meyer, C. M. and Eger, S.: MoverScore: Text Generation Evaluating with Contextualized Embeddings and Earth Mover Distance, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, Association for Computational Linguistics (2019).

[14] 桝田大貴, 白藤大幹, ジェプカ・ラファウ, 荒木健治 議論データ抽出における意見と Key Point の スタンス分類から Match Scoring までの自動化に向けて, 人工知能学会第 2 種研究会, ことば工学研究会資料, SIG-LSE ことば工学研究会 (第 67 回) (2021).

[15] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L. and Stoyanov, V.: RoBERTa: A Robustly Optimized BERT Pretraining Approach, *CoRR*, Vol. abs/1907.11692 (online), http://arxiv.org/abs/1907.11692 (2019).

[16] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. and Dean, J.: Distributed Representations of Words and Phrases and their Compositionality, *CoRR*, Vol. abs/1310.4546 (2013).

[17] Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A. and Fidler, S.: Skip-Thought Vectors, *Advances in Neural Information Processing Systems* (Cortes, C., Lawrence, N., Lee, D., Sugiyama, M. and Garnett, R., eds.), Vol. 28, Curran Associates, Inc. (2015).

[18] Kusner, M., Sun, Y., Kolkin, N. and Weinberger, K.: From Word Embeddings To Document Distances, *Proceedings of the 32nd International Conference on Machine Learning* (Bach, F. and Blei, D., eds.), Proceedings of Machine Learning Research, Vol. 37, Lille, France, PMLR, pp. 957–966 (2015).

[19] Rubner, Y., Tomasi, C. and Guibas, L. J.: The Earth Mover's Distance as a Metric for Image Retrieval, *International Journal of Computer Vision*, Vol. 40, No. 2, pp. 99–121 (online), 10.1023/A:1026543900054 (2000).

[20] Hadsell, R., Chopra, S. and LeCun, Y.: Dimensionality Reduction by Learning an Invariant Mapping, *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06)*, Vol. 2, pp. 1735–1742 (2006).

[21] Hoffer, E. and Ailon, N.: *Similarity-Based Pattern Recognition* (Feragen, A., Pelillo, M. and Loog, M., eds.), Cham.

[22] Ferreira, W. and Vlachos, A.: Emergent: a novel data-set for stance classification, *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, San Diego, California, Association for Computational Linguistics (2016).

[23] Mohammad, S., Kiritchenko, S., Sobhani, P., Zhu, X. and Cherry, C.: SemEval-2016 Task 6: Detecting Stance in Tweets, *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016)*, San Diego, California, Association for Computational Linguistics (2016).

[24] Kochkina, E., Liakata, M. and Augenstein, I.: Turing at SemEval-2017 Task 8: Sequential Approach to Rumour Stance Classification with Branch-LSTM, *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, Vancouver, Canada, Association for Computational Linguistics (2017).

[25] Augenstein, I., Rocktäschel, T., Vlachos, A. and

Bontcheva, K.: Stance Detection with Bidirectional Conditional Encoding, *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, Austin, Texas, Association for Computational Linguistics (2016).

[26] Du, J., Xu, R., He, Y. and Gui, L.: Stance Classification with Target-Specific Neural Attention Networks (2017).

[27] Mohtarami, M., Baly, R., Glass, J., Nakov, P., Màrquez, L. and Moschitti, A.: Automatic Stance Detection Using End-to-End Memory Networks, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics (2018).

[28] Riedel, B., Augenstein, I., Spithourakis, G. P. and Riedel, S.: A simple but tough-to-beat baseline for the Fake News Challenge stance detection task, *CoRR*, Vol. abs/1707.03264 (2017).

[29] Hanselowski, A., PVS, A., Schiller, B., Caspelherr, F., Chaudhuri, D., Meyer, C. M. and Gurevych, I.: A Retrospective Analysis of the Fake News Challenge Stance-Detection Task, *Proceedings of the 27th International Conference on Computational Linguistics*, Santa Fe, New Mexico, USA, Association for Computational Linguistics (2018).

[30] Bowman, S. R., Angeli, G., Potts, C. and Manning, C. D.: A large annotated corpus for learning natural language inference, *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, Lisbon, Portugal, Association for Computational Linguistics (2015).

[31] Williams, A., Nangia, N. and Bowman, S.: A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, Association for Computational Linguistics (2018).