辞書中の用法から生成したルールによるオノマトペ語義分類に関する一考察

Toward Onomatopoeia Disambiguation Using Rules Generated From Dictionary Definitions

藤田実智斗[*1] 内田ゆず[*2] 荒木健治[*1]
Michito Fujita Yuzu Uchida Kenji Araki
[*1]北海道大学 Hokkaido University
[*2]北海学園大学 Hokkai-Gakuen University

1. はじめに

オノマトペ（擬音語および擬態語）は，音や物事の様子，動作の状態を表現する語である．日本語オノマトペの多くは複数の語義を持ち，それらの語義は周辺の文脈によって判別される．オノマトペの語義の曖昧さは，日本語母語話者において感覚的に解消されるものであるが，日本語学習者にとっては日本語を理解する際の妨げとなる．そこで我々は用例と語義決定に寄与するコロケーションを収集し，オノマトペコロケーションデータベースを構築することを目指している．

オノマトペコロケーションデータベースを構築するためには，収集した用例を語義ごとに分類する必要がある．乙武らは BERT[1]から得られるオノマトペのベクトル表現を用いることで，小規模な訓練データにおける語義分類の自動化を提案している[2]．この手法はどのような用例を入力してもベクトル表現が得られるため網羅的であるといえる．一方で，訓練データが少ない場合や文脈に特徴がない場合では分類精度が悪く，文脈を考慮したベクトル表現のみによる自動分類は困難である．そこで，より精度の高い分類手法と組み合わせることで網羅的かつ高精度な自動分類が実現すると考えられる．高精度な自動分類を行うためには，Precision を重視する必要がある．

本研究では Precision に重点を置いた手法として，オノマトペの辞書にある用法から生成したルールによる語義分類を行う．

2. 使用するデータ

本研究で用いる語義および用法は『擬音語擬態語使い方辞典』[3]で定義されたものとする．『擬音語擬態語使い方辞典』にはオノマトペが見出し語として 738 語収録されており，語義ごとに用法と用例が記載されている．例えば「かんかん」の語義①は以下のように記載されている．

> 語義① 金属質の物体が連続して打ち当たる済んだ音.
> ［用法］〈物〉が…(と)鳴る，響く
> ［例文］この踏切ではかんかんと警報が鳴って遮断機がおりる.

対象とするオノマトペは，多義でコーパス上に多く含まれるものが望ましい．本稿では対象オノマトペを「がたがた」と「ごろごろ」とする．

対象のオノマトペを含む用例は『現代日本語書き言葉均衡コーパス（BCCWJ）』[4]から抽出する．BCCWJ から字面一致で用例を抽出した結果，「がたがた」が 375 例，「ごろごろ」が 640 例であった．各用例の語義は第一著者がアノテーションを行った．ただし「なんかごろごろします．」のように文脈が不足していて語義が一意に決められないものは実験対象外とする．その結果，実験対象の用例は「がたがた」が 320 例，「ごろごろ」が 553 例となった．それぞれの語義と用法の一部を以下に示す．

> **がたがた**
> ①堅い物体が揺れ動いて周辺の堅い部分にぶつかってたてる連続音.
> ［用法］〈物・機械・車〉が…(と)音をたてる、振動する
> ②寒さや恐怖，驚がく，興奮，不安などの緊張で体が震えるようす.
> ［用法］〈体〉が…(と)震える
> ③不安，不平があって落ち着きをなくし言い騒ぐようす.
> ［用法］〈人・組織〉が…騒ぐ
> ④強固に組み合っているものが解体して不安定になったり崩れたりするようす.
> ［用法］〈構築物・道路〉が…と崩れる、折れる、落ちる
> ⑤力量，勢力が急激に下がるようす.
> ［用法］〈体力・気力・馬力・効力・景気〉が…(と)下がる、落ちる、減る、衰える

> **ごろごろ**
> ①雷が鳴る音．また，雷が鳴るような音.
> ［用法］〈雷・物・腹〉が…(と)鳴る
> ②かなり重量のある物体や肉体が連続してころがるようす.
> ［用法］〈物・肉体〉が…(と)ころがる、落ちる
> ③何もしないで時を過ごすようす.
> ［用法］〈人〉が…(と)暮らす、過ごす
> ④たくさんありすぎて珍しくも貴重でもないようす.
> ［用法］〈物・人〉が…している
> ⑤かたまりや異物がはいり込んでいて違和感を感じるようす.
> ［用法］〈目・寝具・袋〉が…する

3. 語義分類ルールの概要

3.1 用法に基づく正規表現

まず，各語義の用法から正規表現を生成する．例えば「ごろごろ」の語義①の用法の一つから正規表現を生成すると以下のようになる．

> ［用法］
> 〈雷・物・腹〉が…(と)鳴る
> ↑体言 ↑述語
> ［正規表現］
> (雷|物|腹)が¥.＊ごろごろ(と)?¥.＊鳴る

<体言>+助詞の後および述語の前にワイルドカードを入れることで，一致する条件を緩和する．ただし「オノマトペ+する」のようにオノマトペがサ変名詞として使われている場合や「オノマトペ+だ」の形をとる場合はワイルドカードを入れない．また，活用が原因で一致しないことを考慮して，述語が一致しない場合は基本形に変換してマッチさせる．

語義分類の基本ルールは，この正規表現に一致した用例は語義①に分類するというものである．しかし，用法に記載されている<体言>だけでは一致しない例が多く想定され

る．そこで<体言>を拡張する必要がある．

3.2 <体言>の拡張

日本語 WordNet[1]を用いて，用法中の<体言>の同義語と下位語を追加する．例えば「腹」の同義語には「お腹」「ぽんぽん」，下位語には「下腹部」などがある．

また『擬音語擬態語使い方辞典』で定義される用法の体言には「人」「物」が多く使われている．そこで Juman++[2]の意味カテゴリ情報を用いた抽象化を行う．用例を Juman++で形態素解析し，意味カテゴリが「人」となった名詞は「人」に変換し，「人工物」「自然物」「抽象物」となった名詞は「物」に変換して正規表現とマッチさせる．

4. 語義分類実験

4.1 実験手順

2 章で述べた実験対象の用例について，以下の順でルールを適用し，一致した段階で語義を確定させる．

(1)日本語 WordNet によって<体言>を拡張した上でマッチ
(2)用例中の名詞を「人」「物」に抽象化した上でマッチ
(3)動詞を基本形に変換した上でマッチ
複数の語義のルールに一致した場合は，その段階では語義が確定しなかったこととする．

評価尺度には Accuracy と各語義の Recall，Precision を用いる．ただし，Recall の計算にはルールで語義を分類できなかった用例を含めることに留意する．また，正規表現の効果の分析のために，述語を除いた正規表現（体言のみ），体言を除いた正規表現（述語のみ）を用いた語義分類をそれぞれ行い，結果を比較する．

4.2 実験結果と考察

分類結果を表 1，2 に示す．「がたがた」は述語が一致したときの Precision が全体的に高いことがわかる．これは各語義の用法で定義されている動詞が特徴的で，かつ用例でよく用いられているためであると考えられる．一方「ごろごろ」の体言と述語が両方一致した場合の Accuracy は低い．これは正解が語義④であるにも関わらず語義②に誤分類された事例が多いことに起因する．「ある程度カッコイイ曲がカンタンにつくれてしまう手がかりがゴロゴロころがっているのです．」という例では接尾辞「いる」が語義④の「ある」に近い文脈で用いられているが，語義②の「ころがる」が文中に含まれているため語義②に分類される．このような誤分類は接尾辞の処理ができていないことが原因であると考えられる．

また，述語のみのマッチにおいて「用のない日は午前中いっぱい蒲団の中でごろごろしている．」という例では，語義②の「する」より先に語義④の「している」に一致するため正しく分類できていない．ごろごろしているのは<人>であると考えられるが，文中に明示されていないため体言を一致条件に加えても分類できない．

表 1 「がたがた」の分類結果

評価指標	体言と述語	体言のみ	述語のみ
Accuracy	100.0%	41.7%	87.9%
Precision①	100.0%	61.5%	100.0%
Precision②	100.0%	55.6%	97.7%
Precision③	-	0.0%	100.0%
Precision④	-	15.4%	56.3%
Precision⑤	-	-	100.0%
Recall①	3.3%	6.5%	0.8%
Recall②	4.9%	6.2%	51.9%
Recall③	0.0%	0.0%	16.1%
Recall④	0.0%	3.1%	13.8%
Recall⑤	0.0%	0.0%	5.0%

表 2 「ごろごろ」の分類結果

評価指標	体言と述語	体言のみ	述語のみ
Accuracy	61.8%	80.8%	71.0%
Precision①	100.0%	100.0%	100.0%
Precision②	10.5%	0.0%	63.6%
Precision③	0.0%	-	100.0%
Precision④	91.3%	-	58.3%
Precision⑤	100.0%	75.0%	-
Recall①	6.5%	14.6%	21.1%
Recall②	2.9%	0.0%	10.0%
Recall③	0.0%	0.0%	1.7%
Recall④	13.2%	0.0%	22.0%
Recall⑤	15.0%	15.0%	0.0%

5. まとめ

本研究では Precision を重視したオノマトペ語義分類手法として，辞書中の用法から生成したルールによるオノマトペの語義分類手法を提案した．「がたがた」「ごろごろ」を対象オノマトペとして分類実験を行った結果，いくつかの語義において高い精度が得られた．精度が低い結果については接尾辞や表層格を含めた処理をして文脈を考慮することで改善が期待できると考えられる．また，用法で定義されている述語は代表的な語のみのため，より網羅的に語義分類を行うための動詞の拡張が今後の課題となる．

謝辞

本研究は JSPS 科研費（17K12791，21K12584）の助成を受けたものである．

参考文献

[1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova: BERT: Pre-training of deep bidirectional transformers for language understanding, *Proc. of North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp.4171-4186, 2019.

[2] 乙武北斗，内田ゆず，高丸圭一，木村泰知：BERT による周辺文脈を考慮したオノマトペの語義分類手法の提案，知能と情報（日本知能情報ファジィ学会誌），32(1)，pp.518-522，2020.

[3] 阿刀田稔子，星野和子：擬音語・擬態語使い方辞典 第 2 版，創拓社，1995.

[4] K. Maekawa, M. Yamazaki, T. Ogiso, T. Maruyama, H. Ogura, W. Kashino, H. Koiso, M. Yamaguchi, M. Tanaka, and Y. Den: Balanced corpus of contemporary written Japanese, *Language Resources and Evaluation 48*(2), pp.345-371, 2014.

[1] http://compling.hss.ntu.edu.sg/wnja/
[2] https://nlp.ist.i.kyoto-u.ac.jp/?JUMAN%2B%2B