BM25T を用いたオンライン上の医療ニュース記事の根拠論文候補抽出

Using BM25 to Identify Publications as Potential Sources of Evidence for Online Medical News Articles

吉井瑞貴 [1] , 竹下昌志 [1]，ジェプカ・ラファウ [2]，荒木健治 [2]

Mizuki Yoshii[1], Masashi Takeshita[1], Rafal Rzepka[1], Kenji Araki[1]

[1] 北海道大学大学院情報科学院,[2] 北海道大学大学院情報科学研究院

[1] Graduate School of Information Science and Technology, Hokkaido University,

[2]Faculty of Information Science and Technology, Hokkaido University

1 まえがき

近年，オンライン上の医療記事を用いて医療情報を収集するケースが増えている．その際，閲覧している記事の信頼性を判断するのは困難である．客観的に信頼性の評価を行うための評価指標の一つとして，記事の主張の根拠となる論文の有無を探索する方法がある．そこで本研究では，記事見出しに対して，関連する論文の候補を抽出するタスクに取り組んだ．抽出に用いたのはトークンベース手法である BM25 の改善手法で，単語ごとに固有のパラメータを持つ BM25T[1] である．その結果，500 個の論文アブストラクト候補を抽出した際に，既存手法である BM25 に比べ再現率の向上が見られた．

2 関連研究

情報検索分野の一つとして，医療ニュース記事に関する情報検索の研究が盛んに行われている．情報検索を行う際，トークンベースの手法とニューラルネットワークを用いた手法が主流であるが, ニューラルネットワークを用いる手法では計算量が膨大となる．そのため，検索対象となるデータのサイズが大きい場合には, トークンベースの手法が適していると言える．トークンベースの手法としては，単語に重み付けを行う TF-IDF 値や BM25[2], そしてその改善手法 (BM25+[3],BM25L[4]) などがある．しかしこれらのモデルは，文書長や単語の出現回数に影響を受けやすいという欠点を持つ．そのため，本研究では，BM25 に単語ごとに固有なパラメータを加えたモデルである BM25T を用いて情報検索タスクに取り組む．

3 データセット

今回使用するデータセットは Zuo ら [5] によって公開されたデータセットであり，医療ニュース記事の見出しとそれに対応する論文のアブストラクトが対になっている．記事見出しは 5,034 件，論文アブストラクトは 4,566 件存在する．ここで，一件の論文アブストラクトが複数の記事で引用されているケースがあるため，記事見出し件数が論文アブストラクトの件数より多くなっている．

4 実験方法

私たちは，BM25 を改良したモデルである BM25T を用いて記事見出しに対応するアブストラクトの再現率の向上を試みる．

4.1 BM25

BM25 を用いた単語ごとのスコアの計算方法を式 (1) に示す．

$$score(t_k, d_j) = \log\left(\frac{n - df(t_k) + 0.5}{df(t_k) + 0.5}\right) \cdot \frac{tf(t_k, d_j) \cdot (k_1 + 1)}{tf(t_k, d_j) + k_1 \cdot (1 - b + b \cdot \frac{dl(d_j)}{avgdl}} \quad (1)$$

n は論文の総数，df_t は単語 t_k が出現する論文アブストラクト数，$tf(t_k, d_j)$ は (論文アブストラクト d_j 中の単語 t_k の出現回数) / (文書 d_j 中の全ての単語の出現回数の和) で求められる．k_1 は TF-IDF 値の影響の大きさを調整するパラメータであり，$k_1 = 2.0$ が最も効果的であると確認されている．b は，文書の単語数による影響の大きさを調整するパラメータであり，0.75 が最も効果的であることが確認されているため，$b = 0.75$ とする．$dl(d_j)$ は文書 d_j 中の全ての単語の出現回数の和であり，$avgdl$ は，文書全体の平均単語数である．

4.2 BM25T

単語ごとに特異的なパラメータを使用する．前処理 (単語の小文字への変換, 機能語の消去, ステミング) を施した記事見出し中の単語 (t_k) と論文アブストラクトの集合 (d_j) に対して，スコアは式 (2) のようになる，

$$score(t_k, d_j) = \log\left(\frac{n + 1}{df_t + 0.5}\right) \cdot \frac{tf(t_k, d_j) \cdot (k_1' + 1)}{tf(t_k, d_j) + k_1' \cdot (1 - b + b \cdot \frac{dl(d_j)}{avgdl}} \quad (2)$$

ここで，$tf'(t_k, d_j)$ を式 (3) とすると単語ごとに固有のパラメータ k_1' は式 (4)，g_{k_1} は式 (5) のようになる．

$$tf'(t_k, d_j) = \frac{tf(t_k, d_j)}{1 - b + b \cdot \frac{dl(d_j)}{avgdl}} \quad (3)$$

$$k_1' = \arg\min_{k_1} \left(g_{k_1} - \frac{\sum_{d_j \in C_\omega} \log(tf'(t_k, d_j) + 1)}{df_t} \right)^2 \quad (4)$$

$$g_{k_1} = \begin{cases} \frac{k_1}{k_1 - 1} \log(k_1) & if k_1 \neq 1 \\ 1 & otherwise \end{cases} \quad (5)$$

ここで，C_ω は単語 t_k を含む全ての論文アブストラクトの集合である．式 (4) によって k_1' を求める際，k_1 の値を 0.01 ずつ変化させる探索によって単語ごとに最適な値を決定した．さらに先行研究 [1] では，パラメータ k_1' はほとんど $(0, 2]$ 内にあるとされていたが，我々の実験で $k_1' > 2$ となるケースが 5,472 語中 211 語 (約 3.86%) 存在することがわかった．そのため，今回は k_1 の最適値を $(0, 3]$ の範囲で探索し，それを k_1' とした．その結果，$k_1' > 3$ となるケースは 53 語 (約 0.97%) 存在した．

4.3 評価指標

今回は，候補抽出のタスクに取り組んでおり，この候補を用いてリランキングを行う．そのため，抽出した候補の中に正解を含んでいることが非常に重要であるため，我々は評価指標として再現率 (式 (6)) を使用した．

$$\text{再現率} = \frac{\text{検索結果の正解データ数}}{\text{正解データ数}} \quad (6)$$

5 実験結果

実験結果を**表 1** に示す．okapi BM25, BM25+,BM25+† は Zuo ら [5] の結果を引用した.BM25T[3] では，既存手法である BM25+(前処理済) に比べて，上位 500 件に含まれる正解アブストラクトの数を 50 件増やすことができた．この結果から，単語ごとに固有のパラメータを使用することは有効であることが確認された．

表 1: 候補抽出タスクの実験結果

model	R@1	R@5	R@20	R@100	R@500
okapi BM25	0.295	0.428	0.538	0.653	0.761
BM25+	0.301	0.436	0.543	0.660	0.768
BM25+†	0.376	**0.530**	0.630	0.738	0.830
BM25T[2]‡	**0.378**	0.528	**0.634**	**0.742**	0.830
BM25T[3]¶	0.377	0.527	0.633	**0.742**	**0.831**

† 前処理済み (単語の小文字への変換, 機能語の消去, ステミングを行ったもの) の BM25+ モデル
‡ k_1 を (0,2] で探索した場合
¶ (0,3] で探索した場合

6 考察

今回の実験では，既存手法では単語間で固定であったパラメータを，単語ごとに固有な値とすることによって再現率の向上を実現した．しかし，リランキングタスクを考慮すると更なる再現率の向上が必要である．そのため，今回の手法を用いた結果について分析を行った．

既存手法と実験手法で計算した単語ごとのスコアを**表 2** に示す．BM25+ では，”cancer”や”patient”などの単語のスコアが低く計算されてしまったため, 下位にランク付されたと考えられる．それに対して BM25T では, 事前に計算された単語ごとのパラメータにより”cancer”と”patient”の単語のスコアが高く計算されたと考えられる．これによって既存手法では 18 位にランク付けされた正解アブストラクトを 7 位にランク付けすることができた．

表 2: 記事見出し“Heart doctors recommend cardiac rehab for cancer patients”に含まれる単語スコア

	heart	doctor	recommend	cardiac	rehab	cancer	patient
BM25+	8.37	5.05	3.04	10.56	9.75	6.05	2.30
BM25T	7.99	5.05	3.04	10.07	9.75	6.55	2.54

7 まとめ

本稿では，記事見出しを与えられた際に，その記事に対応する論文アブストラクトの候補を抽出するタスクに取り組んだ．その際，単語ごとに固有なパラメータを用いて重み付けを行う BM25T を用いた手法で，上位 500 件の候補抽出時に，既存手法に比べて正解アブストラクトを 50 件多く含むことができた．今後は，医療辞書を用いた単語の重み付けを行った場合についても実験を行う予定である．さらに，今回の手法を用いても上位 500 件の候補に含むことができなかった 762 例の論文についての原因を分析し，ハイパーパラメータ設定の改善を行うことによって，更なる再現率の向上を目指す予定である．

参考文献

[1] Lv, Y. and Zhai, C.: A Log-Logistic Model-Based Interpretation of TF Normalization of BM25, *Proceedings of the 34th European Conference on Advances in Information Retrieval*, p. 244–255 (2012).

[2] Robertson, S. E. and Zaragoza, H.: The Probabilistic Relevance Framework: BM25 and Beyond, *Found. Trends Inf. Retr.*, Vol. 3, No. 4, pp. 333–389 (2009).

[3] Lv, Y. and Zhai, C.: Lower-Bounding Term Frequency Normalization, *CIKM ’11*, p. 7–16 (2011).

[4] Lv, Y. and Zhai, C.: When Documents Are Very Long, BM25 Fails!, *ACM SIGIR’11*, pp. 1103–1104 (2011).

[5] Zuo, C., Acharya, N. and Banerjee, R.: Querying Across Genres for Medical Claims in News, *EMNLP’20*, pp. 1783–1789 (2020).