日本語回文の大規模自動生成に向けて

Towards Massive Automatic Generation of Japanese Palindromes

古澤智博 [1]，荒木健治 [2]

Tomohiro Furusawa [1], Kenji Araki [2]

[1] 北海道大学大学院情報科学院，[2] 北海道大学大学院情報科学研究院

[1] Graduate School of Information Science and Technology, Hokkaido University,

[2] Faculty of Information Science and Technology, Hokkaido University

1 概要

回文とは言葉遊びの一種で，上から読んでも下から読んでも読みが同じになっている文のことである．例として「竹やぶ焼けた」「私負けましたわ」等がある．インターネット上には回文投稿サイト[1]があり，文として流暢な回文が多数投稿されている．

本稿では，回文を以下のように定義し，回文の音の条件を満たすように自動生成された文のことを回文候補と呼ぶことにする．

- 上から読んでも下から読んでも読みが同じになっている（音の条件）
- 文として意味が通っている（通意条件）
- 同じ単語の繰り返しではない（例えば「ああああああ」「痛い痛い痛い」等は回文として認めない）

本研究では，既存研究に基づく手法と提案手法において，自動生成された回文候補から回文になっている割合について比較を行う．実験結果から，大規模なコーパスを想定しない場合において，既存研究に基づく手法よりも提案手法の方が効率的に回文を生成できることが確認された．

2 関連研究

日本語での回文自動生成の研究について，鈴木ら [1, 2] は，まず文節単位での日本語語彙の集合を生成し，各文節を総当たりで組み合わせることにより回文候補を生成する手法を提案している．この手法では，回文候補生成の計算に莫大な時間がかかり，通意条件を満たすような文の割合も非常に低い．

清野ら [3] は，コーパスから bi-gram の情報を取得し，bi-gram で成り立つ文節対のみで探索を行う手法を提案している．bi-gram の情報を使用することで，文節の連結の組み合わせが大幅に減少し，生成速度の向上と通意条件を満たす割合の向上が実現されている．しかし，約 2,000 万文のコーパスを使用して生成されており，生成時の計算コストについて課題が残っている．また，巨大なコーパスを用いているにも関わらず，生成される回文候補のバリエーションが非常に限定されている．提案手法では，日本語コーパスに対する前処理として，文節単位よりも細かい単位を用いることで，生成される回文候補のバリエーションを豊富にすることを試みた．

英語での回文自動生成の研究については，Papadopoulos ら [4] は回文グラフという概念を導入している．回文グラフは，bi-gram の情報と，回文の音の条件の両方を使用して生成された，高速に回文候補を生成するための有向グラフである．回文グラフは任意のコーパスから生成でき，そのコーパスから生成し得る全ての回文候補の情報を有向グラフとして保持する．回文グラフの生成自体には時間を要するが，回文グラフから回文候補を生成する時間は非常に短く，大規模に高速生成できる．提案手法では，この回文グラフによる手法を日本語用に改良を加え，回文候補生成に用いた．

3 提案手法

3.1 コーパス事前処理

3.1.1 文節内での長単位二分割

文献 [1, 2, 3] では，CaboCha[2]を用いて日本語コーパス内の文章を文節単位に分割していた．提案手法では，以下の手順で，さらに細かい単位に文章を分割する．

1. CaboCha により，文章を文節単位に分割する（例：「今日/リンゴを/食べなかった」）
2. 文節内の MeCab[3]によって分割された各単語について順番に分析する
3. 文節内の全単語が自立語，または全単語が付属語である場合は，その文節を一つの語として扱う（例：「今日」）
   → この語にはフラグ 0 を付ける
4. 文節内に自立語，付属語の切れ目がある場合は，その最初の切れ目の前後で分割し，二つの語に分け

[1] https://kaibun.jp/ranking/

[2] https://taku910.github.io/cabocha/

[3] https://taku910.github.io/mecab/

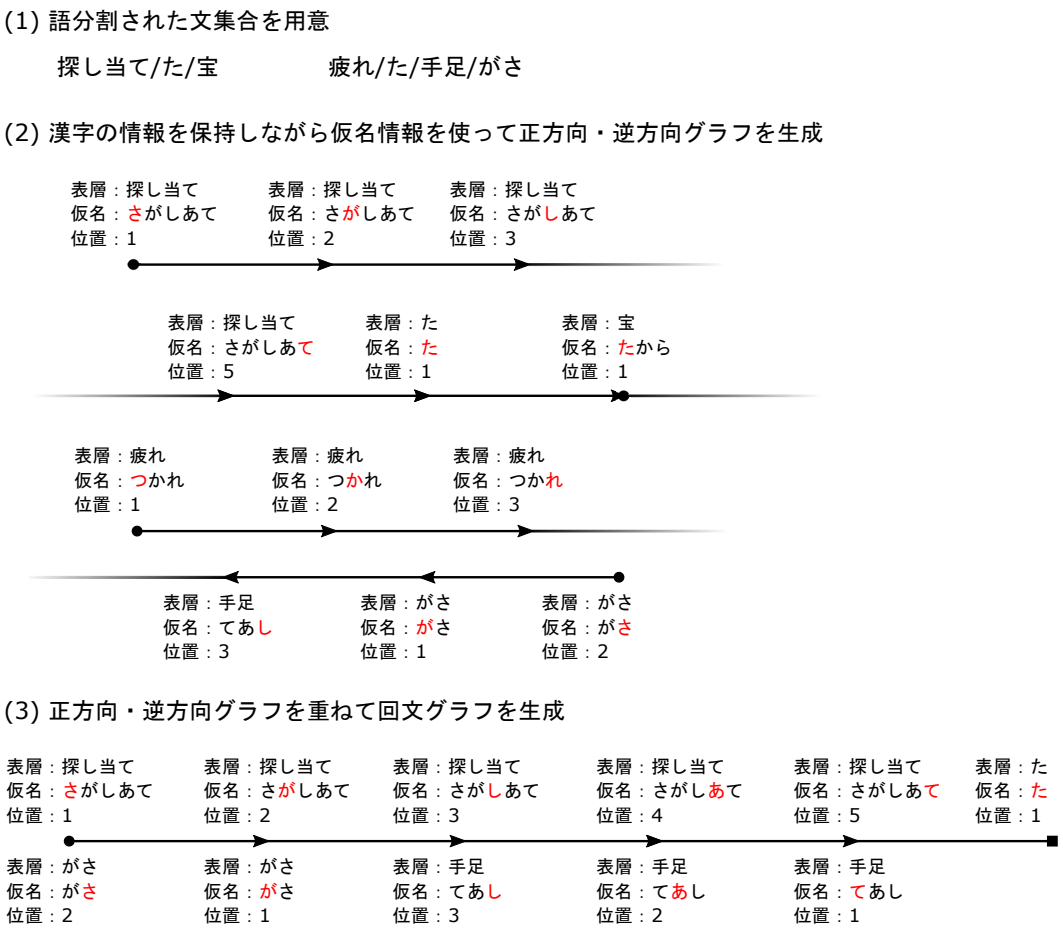


図 1: 日本語版回文グラフの生成過程

て扱う（例：「リンゴ/を」，「食べ/なかった」）→ 前側の語にはフラグ 1 を，後ろ側の語にはフラグ 2 を付ける

例えばフラグ 2 が付いている語は文頭に来ると不自然な可能性が高いため，**3.2** の回文グラフ生成の際にフラグの情報を用いて，そうした不適切な文の生成を防ぐ．

3.1.2 句点の挿入

CaboCha で解析する際に，不自然な記号の出現を防ぐため，記号類を取り除く処理を解析時に行う．この影響で，生成される回文が長い一文になってしまう問題が生じる．これを解決するため，以下の手法を用いて句点付きの bi-gram 情報を追加する．

1. **3.1.1** の手法で，文章を分割する
2. 「最後から 2 番目の語」，「最後の語」，「最初の語」を取り出す（例：「食べ」，「なかった」，「今日」）
3. 「最後から 2 番目の語」から「最後の語に句点をつけたもの」，及び「最後の語に句点をつけたもの」から「最初の語」を bi-gram の情報として追加する（例：「食べ」→「なかった。」，「なかった。」→「今日」）

3.2 日本語版回文グラフ

回文グラフの生成アルゴリズムについては，Papadopoulos らの手法に従う．日本語では，文章を仮名で表記した際の一文字を，一つの頂点に割り当てる．具体的な生成過程を図示したものを，図 1 に示す．また，語にフラグ 1 が付いていた場合は，逆方向グラフ生成時に始点として扱わない．これにより，自立語の接続形などで文が終わるのを防ぐ．同様に，語にフラグ 2 が付いていた場合は，正方向グラフ生成時に始点として扱わない．これにより，助詞や助動詞などで文が始まるのを防ぐ．

4 実験と考察

提案手法では，Tatoeba プロジェクト[4]に含まれる日本語文（約 20 万文）を用いた．また，CaboCha の内部で使われる MeCab によって発音の情報が得られない単語を含む文については，その文を使用しないこととした．既存研究と同じく文節単位で分割したもの，及び提案手

[4] https://tatoeba.org/ja/

表 1: 各仮名文字数指定において 200 文の回文候補をアノテーションした結果

	仮名文字数	定義を満たす文数	異なり文数
既	7 または 8	64	6
存	9 または 10	0	7
手	11 または 12	0	6
法	13 または 14	0	6
提	7 または 8	42	183
案	9 または 10	30	185
手	11 または 12	17	196
法	13 または 14	5	197

表 2: 既存研究に基づく手法によって生成された回文候補

回文候補	定義を満たすか
この子にこの子	True
残る。あるこの	False
川のそのその分	False
あああああああああああ	False
痛い痛い痛い痛い	False
はい何かほかにない。は	False
ろ。この子にこの子にこのころ	False
ろ。この頃この頃この頃	False

法の分割を用いたもので，それぞれ回文グラフを生成した．C++を用いて実装を行い，回文グラフの生成には，Intel Xeon E5-2630 シングルコアで，それぞれ約 7 時間を要した．指定した仮名文字数において，それぞれ 200 文の回文候補を第一著者がアノテーションした結果を表 1 に示す．また，実際に生成された回文候補の例を，表 2 及び表 3 に示す． アノテーションの結果から，既存手法では比較的長い回文を全く生成することができず，回文を生成できる割合が 0 になっていることがわかる．提案手法では，比較的多い仮名文字数においても，回文を生成できる割合が 0 にならず，回文生成の可能性が残っていることがわかる．また，既存手法で生成された回文候補の異なり文数は，提案手法に比べて極端に少なく，既存手法では回文候補の文としてのバリエーションが非常に限定されていることがわかる．考察として，今回使用したコーパスは既存研究で用いられたコーパスに比べてサイズが 100 分の 1 であり，既存手法の文節分割では回文生成に十分な情報を得られなかったと考えられる．これにより，同じ単語の繰り返しといった回文として不適切な文のみが出力される結果となったと考えられる．

表 3: 提案手法によって生成された回文候補

回文候補	定義を満たすか
とる気でできると	True
きがきて敵が来	False
めの手伝って飲め	False
竜巻で決まった	True
血も気のことと子の気持ち。	False
言い張った二つはいい。	True
いたいの靴に着くの。いたい	False
居ない喧嘩が関係ない	True

5 まとめと今後の課題

本研究では，既存手法よりも細かい単位での語分割を行う手法を提案し，回文候補の生成を試みた．実験では，仮名文字数を 7 から 14 まで指定して回文候補を 200 文生成した．各仮名文字数指定において，既存手法では異なり文数が約 6 文となったのに対して，提案手法では異なり文数が 180 文を超える結果となった．このことから，比較的小規模なコーパスを用いても，提案手法では豊富なバリエーションの回文候補が生成できることを確認された．また，回文候補のバリエーションが豊富になったことにより，比較的長い回文生成においても，定義を満たす回文を生成できる可能性が確認された．今後の課題として，bi-gram 以上の情報を用いて，より効率的に回文の定義を満たす文を生成することが挙げられる．

参考文献

[1] 鈴木啓輔, 佐藤理史．文節結合による回文の自動生成．人工知能学会全国大会論文集 第 24 回. 一般社団法人人工知能学会, 2010.

[2] 鈴木啓輔, 佐藤理史, 駒谷和範．文頭固定法による効率的な回文生成．言語処理学会 第 17 回年次大会 発表論文集, 2011.

[3] 清野舜, 渡邉研斗, 岡崎直観, 乾健太郎．Bi-gram 連接表と単語列変形規則に基づく回文自動生成．人工知能学会全国大会論文集 第 29 回. 一般社団法人人工知能学会, 2015.

[4] Alexandre Papadopoulos, Pierre Roy, Jean-Charles Régin, and François Pachet. Generating all possible palindromes from ngram corpora. In *Twenty-Fourth International Joint Conference on Artificial Intelligence*, 2015.