BERT モデルと補助文自動生成に基づいた日本語アスペクトベース感情分析の精度向上

Using BERT and Auxiliary Sentences Generation to Improve Accuracy of Japanese Aspect-based Sentiment Analysis

張 懿陽 †　　ラファウ・ジェプカ ‡　　荒木 健治 ‡

Yiyang ZHANG †　　Rafal RZEPKA ‡　　Kenji ARAKI ‡

† 北海道大学大学院情報科学院

† Graduate School of Information Science and Technology, Hokkaido University

† Email: yiyang.zhang.s4@elms.hokudai.ac.jp

‡ 北海道大学大学院情報科学研究院

‡ Faculty of Information Science and Technology, Hokkaido University

‡ Email: {rzepka,araki}@ist.hokudai.ac.jp

Abstract

アスペクトベース感情分析 (Aspect-Based Sentiment Analysis (ABSA)) とは，テキスト内の特定のアスペクトに対する意見の極性を特定する感情分析タスクである．アスペクトベース感情分析は細かい粒度の感情分析であり，より詳細で有用な情報が扱えるため，NLP 分野で注目され続けている．しかし，日本語に特化した研究はまだ少ない．本研究では，「chABSA」データセットを用いた日本語 ABSA タスクのアスペクト感情分類 (Aspect Sentiment Classification (ASC)) サブタスクの精度の向上を目的とし，補助文を自動的に生成し，対象文と補助文を組み合わせた文ペアで BERT モデルを fine-tuning するという英語のために提案された手法を改良した上で日本語に適用した．性能評価実験を行った結果，同じデータセットを使用した先行研究の実験結果より accuracy が 7.8 ポイント改善し，提案手法の有効性が確認された．今回の実験結果は，先行研究で対象としていない neutral クラスを対象としたものであり，提案手法の全体的な有効性が確認されたと考えられる．

1　はじめに

感情分析とは，書かれた文章を読み取り，ポジティブな内容か，ネガティブな内容か，あるいはニュートラルの内容かを判定するタスクのことである．感情分析というタスクは主に 3 つの粒度がある．1 つ目は，ドキュメントレベルであり，ドキュメント単位で感情極性を判定するタスクである．2 つ目は，文レベルであり，文単位で感情極性を判定するタスクである．3 つ目は，アスペクトレベルであり，アスペクト単位で感情極性を判定するタスクである．アスペクトとは，ある対象の 1 つの側面である．例えば，「この車の外見はきれいだが，値段が高い」という文の中に，「車」という対象は「外見」と「値段」という 2 つの側面がある．話者が「外見」というアスペクトに対して「きれい」と言っているため，「外見」に対して「肯定的」な感情をもっており，一方で「値段」というアスペクトに対して「高い」と言っているため，「値段」に「否定的」な感情をもっている．このような分析を行うのがアスペクトベース感情分析である．アスペクトベース感情分析は，ドキュメントレベルの感情分析とドキュメントレベルの感情分析より細かい粒度で感情分析を

行え，提供できる情報が比較的多いため，多くの場面で実用できると想定している．例えば，ある会社が自社が発売した商品の各アスペクトに対し，消費者がどんな感情をもっているかを分析したい場合，アスペクトレベルの感情分析が必要となる．本稿では，アスペクトレベルの感情分析，すなわちアスペクトベース感情分析に注目して研究する．

アスペクトベース感情分析は主に 2 つのサブタスクから構成されている．1 つ目は，文中に含まれているアスペクトを抽出するタスク (Aspect Extraction (AE)) である．2 つ目は，各アスペクトに対する感情極性を特定するタスク (Aspect Sentiment Classification (ASC)) である．日本語アスペクトベース感情分析の先行研究では 2 つ目のサブタスクの精度は比較的低いという問題を解決するため，本研究では，2 つ目のサブタスクを扱う．

英語分野では，アスペクトベース感情分析について多くの研究が行われているが，日本語分野では，我々が知っている範囲では，アスペクトベース感情分析についての研究はまだ 2 件しかない．

本研究では，日本語分野のアスペクトベース感情分析の先行研究より高い感情分類精度を達成することを目的としている．我々は補助文を自動的に生成し，対象文と補助文を組み合わせた文ペアで BERT モデルを fine-tuning するという英語のために提案された手法を用い，補助文の生成方法を改良した上で日本語に適用し，「chABSA」データセット [1] という日本語のアスペクト感情分析データセットを用いて実験を行った．その結果，同じデータセットに基づいた先行研究より高い分類精度を達成した．

本研究の貢献は以下の 2 つである．

1. 補助文を自動的に生成し，対象文と補助文を組み合わせた文ペアで BERT モデルを fine-tuning するという英語のために提案された手法を改良した上で日本語に適用し，先行研究より高い精度を達成した．さらに，先行研究では「chABSA」データセットの中の neutral という感情極性を扱っていないことに対し，本研究では初めて neutral クラスを扱った．

2. 前述の手法で補助文を生成する際，より適切な補助文を構築すれば，より高い精度を達成できることを示した．

2 関連研究

英語分野における ABSA の初期の研究では，Wagner ら [2] の研究と Kiritchenko ら [3] の研究は feature engineering (特徴量エンジニアリング) に大きく依存していた．その後，Nguyen と Shirai ら [4]，Wang ら [5]，Tang ら [6][7]，Wang ら [8] はニューラルネットワークベースの手法を用い，より高い精度を達成した．最近，Ma ら [9] は有用な常識知識をディープニューラルネットワークに組み込み，モデルの結果をさらに向上させた．Liu ら [10] は言語構造をよりよく捉えるためにメモリネットワークを最適化し，Liu らのモデルに適用した．

もっと最近では，事前学習済み言語モデルが注目されつつあり，Peters ら [11] が提案した ELMo モデル，Radford ら [12] が提案した OpenAI GPT モデル，Devlin ら [13] が提案した BERT モデルのような事前学習された言語モデルが feature engineering の手間を軽減する効果を示している．特に BERT モデルは「隣接文予測」(next sentence prediction) というタスクで事前学習されたため，QA タスクと NLI タスクのような文と文の関係を理解するタスクにおいて優れた成果を上げている．そこで，Sun ら [14] は BERT モデルが QA タスクと NLI タスクに優れるという特徴を活かした手法を提案した．

日本語分野では，赤井ら [15] は英語分野の先行研究で使われていた自己注意機構を使ったニューラルネットワークモデルを日本語に適用し，KNB コーパス [16] のうち評判情報の感情タグが付いた文で実験を行った結果，感情分類の accuracy は 85%に達した．三浦ら [17] は BERT を組み込んだアスペクトカテゴリ分類ネットとアスペクトセンチメント分析ネットからなる文に含まれている複数アスペクトのセンチメント分析のための自己注意ニューラルネットワークモデルを提案し，「chABSA」データセットで実験を行った結果，感情分類の accuracy は最高 85.6%まで達した．

しかし，日本語分野の前述の研究では主に 2 つの問題が存在している．1 つ目は BERT モデルの fine-tuning 手法である．我々は BERT モデルに対してより適切な fine-tuning 手法が存在しており，それで BERT モ

デルを fine-tuning すれば，より高い分類精度を達成できると考えている．2 つ目は neutral クラスを扱っていないことである．しかし，「chABSA」データセットの中に感情極性が neutral のアスペクトが 258 個含まれている．

以上の問題点を解決するために, 本研究では, neutral クラスを扱う上で，BERT モデルのより適切な fine-tuning 手法を探し，三浦ら [17] が達成した分類精度より高い精度を達成することを目標とした．

3 データセット

本研究では,「chABSA」というデータセットを使っている.「chABSA」データセットは上場企業の有価証券報告書（2016 年度）をベースに作成されたデータセットで, 各文に対して「Positive」・「Negative」・「Neutral」の感情分類だけでなく, その文の中に含まれている各アスペクトに対して「Positive」・「Negative」・「Neutral」なのかという観点を表す情報が含まれている。

このデータセットの合計アスペクトカテゴリー数は 26 個で，company，business，product，NULL という 4 つのエンティティと general，sales，profit，amount，price，cost という 6 つのアトリビュートの組み合わせ（例：company#general，business#sales）及び market#general と OOD#general（OOD: Out of Domain）からなっている．各文中の各アスペクトは，これらのアスペクトカテゴリーに属している．

本研究では，このデータセットの中の感情情報が含まれている 3,215 文を扱う．合計のアスペクトの数は 7,723 個で，感情極性がポジティブ・ネガティブ・ニュートラルのアスペクトの数はそれぞれ 4,334 個・3,131 個・258 個である．したがって，各文に平均約 2.4 個のアスペクトが含まれている．

提案手法の中の QA-M と NLI-M では，各アスペクトに対して 1 つの補助文を生成するため，データの数は 7,723 個になる．それに対し，提案手法の QA-B と NLI-B では各アスペクトに対して 3 つの補助文を生成するため，データの数は 23,169 個になる．このデータセットを 85:15 の割合で，訓練データとテストデータに分けて実験を行った．

4 提案手法

本研究では，Sun ら [14] が提案した補助文を自動的に生成し，対象文と補助文を組み合わせて生成した文ペアで BERT モデルを fine-tuning という手法を用い，補助文の構成方法を改良した上で日本語に適用し，実験を行った．さらに，適用方法についても研究した．

以下では BERT モデル，補助文の生成方法，文ペアで fine-tuning した BERT-pair モデルについて詳しく説明する．

4.1 BERT モデル

BERT とは，「Bidirectional Encoder Representations from Transformers」の略で, 日本語では,「Transformer による双方向のエンコード表現」である. BERT は 2018 年 10 月に Google 社が発表した自然言語処理モデルであり，自然言語処理の多くのタスクで最高水準を達成した. BERT の特徴は, 文脈を考慮した上で単語のエンコード表現を得ることができることと，様々なタスクに適用する際に，訓練に必要なデータ量が少ないことである．訓練に必要なデータ量が少ない理由は，BERT は既に大規模なデータセットで事前学習が行われているからである．事前学習では 2 つの学習方法が施されている．1 つ目は,「マスク予測」(masked language model) で，文章の一部分を穴抜けにしてモデルに予測させることである．2 つ目は,「隣接文予測」(next sentence prediction) で，2 つの文をモデルに与え，隣接した文であるかどうかを判別させることである．この 2 つの学習方法により，BERT モデルは文脈を考慮した上での各単語の意味，及び文と文の関係をよく捉えられるようになっている．

本研究では，東北大学が訓練した日本語版の BERT モデル「cl-tohoku/bert-base-japanese-whole-word-masking」[1]を利用した．このモデルは日本語版のウィキペディアで事前学習されたものである．

4.2 補助文の生成方法

補助文の生成方法を**表 1** に示す．それぞれの補助文生成方法について説明する．

[1] https://huggingface.co/cl-tohoku/bert-base-japanese-whole-word-masking

QA-M: QA は英語の Question & Answer(質問と答え) という意味で，M は英語の Multi の略で，分類するクラスはバイナリーではなく，複数であるという意味である．この方法では，質問の形式で補助文を生成し，システムにその質問の答えを出すようにする．具体的な生成方法は，感情極性を判断したい対象，すなわちアスペクトと「についてどう思いますか」という文を結合して補助文を生成することである．

QA-M-Improve: 我々が QA-M を基にして改良した補助文構築方法である．Sun ら [14] の元々の QA-M 補助文構築方法では，質問文を「についてどう思いますか」に設定しているが，我々はより適切な質問文が存在していると考えており，質問文を「に対する感情極性は何ですか」にした方が感情極性について直接質問しているから，BERT モデルを正しい結果を出すように誘導でき，より良い精度を得られると仮定して実験を行った．

NLI-M: NLI は英語の Natural Language Inference (自然言語推論) という意味で，M は QA-M の M の意味と同じである．この方法では，感情極性を判断したい対象，すなわちアスペクトだけで補助文を生成する．

QA-B: QA は QA-M の QA と同じ意味である．B は英語の binary の略で，分類するクラスはバイナリーであるという意味である．この方法では，感情極性を判断したい対象，すなわちアスペクトと「に対する極性は肯定的だ」・「に対する極性は否定的だ」・「に対する極性は中立的だ」という 3 つのフレーズとそれぞれ結合して 3 つの補助文を生成する．分類するカテゴリーは「Yes」と「No」という 2 つのカテゴリーになる．テストデータで検証する時，3 つの文の中の「Yes」の確率が一番高い文を選び，その文が示している極性をモデルが判断した極性とする．例えば，3 つの文の中に「(アスペクト) に対する極性は肯定的だ」の極性が一番高いならモデルが判断した極性は「Positive」だとする．さらに，感情極性を表す時，漢字語の「肯定的・否定的・中立的」とカタカナ語「ポジティブ・ネガティブ・ニュートラル」のどちらがより高い精度を達成できる補助文を構築できるかを検証するために，漢字語で感情極性を表す補助文とカタカナ語で感情極性を表す補助文をそれぞれ生成して実験を行った．

NLI-B: NLI は NLI-M の NLI と同じ意味である．B は QA-B の B と同じ意味である．この方法では，感情極性を判断したい対象，すなわちアスペクトと「肯定的」・「否定的」・「中立的」という 3 つのフレーズとそれぞれを「-」で結合して 3 つの補助文を生成する．分類するカテゴリーは「Yes」と「No」という 2 つのカテゴリーになる．テストデータで検証する時，QA-B の方法と同じで 3 つの文の中の「Yes」の確率が一番高い文を選び，その文が示している極性をモデルが判断した極性とする．例えば，3 つの文の中に「(アスペクト) -肯定的」の極性が一番高いならモデルが判断した極性は「Positive」だとする．QA-B と同じく，漢字語で感情極性を表す補助文とカタカナ語で感情極性を表す補助文をそれぞれ生成して実験を行った．

表 1: 補助文の生成方法

方法	補助文	出力
QA-M	(アスペクト) についてどう思いますか	Pos・Neg・Neu
QA-M-Improve	(アスペクト) に対する感情極性は何ですか	Pos・Neg・Neu
NLI-M	(アスペクト)	Pos・Neg・Neu
QA-B	・(アスペクト) に対する感情極性は肯定的/ポジティブだ ・(アスペクト) に対する感情極性は否定的/ネガティブだ ・(アスペクト) に対する感情極性は中立的/ニュートラルだ	Yes・No
NLI-B	・(アスペクト)-肯定的/ポジティブ ・(アスペクト)-否定的/ネガティブ ・(アスペクト)-中立的/ニュートラル	Yes・No

4.3 BERT-pair モデル

対象文と前述の補助文生成方法によって生成した補助文を [SEP] というトークンで結合した文で fine-tuning した BERT モデルをそれぞれの補助文生成方法に対応して BERT-pair-QA-M，BERT-pair-QA-

M-Improve，BERT-pair-NLI-M，BERT-pair-QA-B，BERT-pair-NLI-B と名付ける．

5 実験

5.1 ハイパーパラメータ

本研究では，ハイパーパラメータを以下の通りに設定して実験を行った．

学習率は 2e-5 とし，エポック数は 3 とし，バッチサイズは BERT-pair-QA-M・BERT-pair-QA-M-Improve・BERT-pair-NLI-M の実験では 16 で，BERT-pair-QA-B・BERT-pair-NLI-B の実験では 48 とし，ドロップアウト率は 0.1 とし，pandas.DataFrame.sample の random_state は 4,040 とし，Pytorch のランダムシードは 2,020 とした．

ここで，BERT-pair-QA-M・BERT-pair-QA-M-Improve・NLI-M の実験でのバッチサイズは 16 で BERT-pair-QA-B・BERT-pair-NLI-B の実験でのバッチサイズは 16 の 3 倍の 48 に設定した理由は，BERT-pair-QA-B・BERT-pair-NLI-B 方法では 1 つの文とその文の中に含まれている 1 つのアスペクト毎に，3 つの感情極性に対応して 3 つの文を生成しており，その 3 つの文を 1 つのまとまりとして BERT モデルに学習させたいからである．

5.2 実験結果

実験結果を**表** 2 に示す．

表 2: 実験結果

方法	Accuracy	F1 Score
三浦ら [17] の手法	85.6	なし
BERT-pair-QA-M	93.0	86.6
BERT-pair-QA-M-Improve	**93.4**	**90.6**
BERT-pair-NLI-M	93.3	89.4
BERT-pair-QA-B(カタカナ語)	92.7	87.9
BERT-pair-QA-B(漢字語)	93.0	88.7
BERT-pair-NLI-B(カタカナ語)	91.8	82.0
BERT-pair-NLI-B(漢字語)	92.2	85.6

我々が補助文生成方法 QA-M を改良した補助文生成方法 QA-M-Improve で生成した補助文で fine-tuning した BERT-pair-QA-M-Improve モデルは既存手法を結果を上回った上で，全ての手法の中で一番高い accuracy と F1 score が得られた．

また，BERT-pair-QA-M・BERT-pair-QA-M-Improve・BERT-pair-NLI-M では BERT-pair-QA-B・BERT-pair-NLI-B より高い accuracy と F1 score を得られ，BERT-pair-QA-B（漢字語）は BERT-pair-QA-B（カタカナ語）より，BERT-pair-NLI-B（漢字語）は BERT-pair-NLI-B（カタカナ語）より高い accuracy と F1 score が得られた．

6 考察

実験結果から，提案手法が既存手法より良い精度を達成したことが確認された．その原因は主に 2 つあると考えられる．1 つ目の原因は，各文の中の各アスペクト毎に 1 つの文を生成したため，1 つの文がその文に含まれているアスペクトと同じ数の文に拡張された．そのため，データセットが拡張され，訓練に用いられる文の数が増加し，モデルの学習データが増加したからである．2 つ目の原因は，BERT モデルは「隣接文予測」(next sentence prediction) タスクで事前学習されており，文と文の関係をよく捉えているため，QA タスクと NLI タスクのような文ペア分類問題が得意だからである．

また，BERT-pair-QA-B(漢字語) と BERT-pair-QA-B(カタカナ語)，BERT-pair-NLI-B(漢字語) と BERT-pair-NLI-B(カタカナ語) の実験結果を比較した結果，補助文の中で感情極性を表す時，「ポジティブ・ネガティブ・ニュートラル」というカタカナ語より，「肯定的・否定的・中立的」という漢字語を使う方が高い accuracy と F1 score を得られることがわかった．その原因は，日本語 BERT モデルが日本語版のウィキペディアで事前学習され，このコーパスの中に「ポジティブ・ネガティブ・ニュートラル」というカタカナ語より，「肯定的・否定的・中立的」という漢字語で感情極性を表す場合が多く，モデルが「ポジティブ・ネガティブ・ニュートラル」より，「肯定的・否定的・中立的」の方がよく意味を捉えているからだと考えられる．また，BERT-pair-QA-M-Improve と BERT-pair-QA-M の実験結果を比較した結果，補助文生成方法 QA-M では，補助文を「(アスペクト) についてどう思いますか」にするより，「(アスペクト) に

対する感情極性は何ですか」にした方が高い accuracy と F1 score が得られた．その理由は後者の補助文の方が感情極性について直接質問しているから，BERT モデルを正しい結果を出すように誘導できたためだと考えられる．以上の結果より，より適切な補助文を構築すれば，より高い精度を得られることが確認された．

7 まとめ

本研究では, 日本語アスペクトベース感情分析タスクのアスペクト感情分類 (Aspect Sentiment Classification (ASC)) サブタスクにおいて, 補助文を自動的に生成し，対象文と補助文を組み合わせた文ペアで BERT モデルを fine-tuning するという英語のために提案された手法を改良した上で日本語に適用し，「chABSA」データセットで実験を行った結果，同じデータセットで実験を行った先行研究より高い精度を達成できた．さらに，補助文の構成に少し変化を加えて比較実験を行った結果から，より適切な補助文を構築すれば，より高い精度を達成できることを示した．今後，アスペクトベース感情分析の 1 つ目のサブタスク，すなわち文中に含まれているアスペクトを抽出するというサブタスク (Aspect Extraction (AE)) においてこの手法を用いて研究を進める予定である．

参考文献

[1] Takahiro Kubo, Hiroki Nakayama. chABSA: Aspect Based Sentiment Analysis dataset in Japanese. URL https://github.com/chakki-works/chABSA-dataset

[2] Joachim Wagner, Piyush Arora, Santiago Cortes, Utsab Barman, Dasha Bogdanova, Jennifer Foster, and Lamia Tounsi. 2014. Dcu: Aspect-based polarity classification for semeval task 4. In Proceedings of the 8th international workshop on semantic evaluation (SemEval 2014), pages 223 – 229.

[3] Svetlana Kiritchenko, Xiaodan Zhu, Colin Cherry, and Saif Mohammad. 2014. Nrc-canada-2014: Detecting aspects and sentiment in customer reviews. In Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), pages 437442.

[4] Thien Hai Nguyen and Kiyoaki Shirai. 2015. Phrasernn: Phrase recursive neural network for aspect-based sentiment analysis. In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, pages 2509 – 2514.

[5] Yequan Wang, Minlie Huang, Li Zhao, et al. 2016. Attention-based lstm for aspect-level sentiment clas- sification. In Proceedings of the 2016 conference on empirical methods in natural language processing, pages 606 – 615.

[6] Duyu Tang, Bing Qin, Xiaocheng Feng, and Ting Liu. 2015. Effective lstms for target- dependent sentiment classification. arXiv preprint arXiv:1512.01100.

[7] Duyu Tang, Bing Qin, and Ting Liu. 2016. Aspect level sentiment classification with deep memory net- work. arXiv preprint arXiv:1605.08900.

[8] Bo Wang, Maria Liakata, Arkaitz Zubiaga, and Rob Procter. 2017. Tdparse: Multi-target-specific sen- timent recognition on twitter. In Proceedings of the 15th Conference of the European Chapter of the As- sociation for Computational Linguistics: Volume 1, Long Papers, volume 1, pages 483 – 493.

[9] Yukun Ma, Haiyun Peng, and Erik Cambria. 2018. Targeted aspect-based sentiment analysis via em- bedding commonsense knowledge into an attentive lstm. In Proceedings of AAAI.

[10] Fei Liu, Trevor Cohn, and Timothy Baldwin. 2018. Re- current entity networks with delayed memory update for targeted aspect-based sentiment analysis. arXiv preprint arXiv:1804.11019.

[11] Matthew E Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018. Deep contextualized word rep- resentations. arXiv preprint arXiv:1802.05365.

[12] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. 2018. Improv- ing language understanding by generative pre- training. URL https://s3-us-west-2. amazon- aws. com/openai-assets/research-covers/language- unsupervised/language understanding paper. pdf.

[13] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understand- ing. arXiv preprint arXiv:1810.04805.

[14] Sun, Chi, Luyao Huang, and Xipeng Qiu. 2019. Utilizing BERT for aspect-based sentiment analysis via constructing auxiliary sentence. Proceedings of NAACL-HLT 2019, pages 380 – 385.

[15] 赤井 龍一, 渥美 雅保．2019．自己注意機構を利用したアスペクトベースの感情分析の日本語文への適用，2020 年度人工知能学会全国大会（第 33 回）.

[16] 橋本力, 黒橋禎夫, 河原大輔, 新里圭司, 永田昌明. 2011. 構文・照応・評判情報つきブログコーパスの構築. 自然言語処理 Volume 18, Number 2, pp.175-201.

[17] 三浦 義栄, 赤井 龍一, 渥美 雅保．2020．文中の複数アスペクトのセンチメント分析のための自己注意ニューラルネットワーク，2020 年度人工知能学会全国大会（第 34 回）.