一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report
NLC2022-23(2023-03)

日本語知識グラフを用いた質問応答システムの構築とグラフサイズの影響の検証

矢野　一樹[†a)]　　ジェプカ　ラファウ[††b)]　　荒木　健治[††c)]

Creation of Question and Answer System Using Japanese Knowledge Graph and Investigation of the Graph Size Influence

Kazuki YANO[†a)], Rafal RZEPKA[††b)], and Kenji ARAKI[††c)]

あらまし　近年では言語モデルと知識グラフを組み合わせることで，推論能力を向上させるモデルが提案されている．そこで本稿では日本語データセットと日本語知識グラフを用いた実験を行った．その結果から言語モデルが正答できなかった質問を知識グラフと組み合わせることで正答できたものがある一方, 精度面に関していえば差がほとんど見られなかった．そこで日本語知識グラフと英語知識グラフの差異を指摘し，英語知識グラフの質問応答システムの精度に対する影響を調査した．その結果から知識グラフは精度に大きな影響を及ぼすことが明らかになった．

キーワード　質問応答，言語モデル，知識グラフ，コモンセンス

1. はじめに

質問応答タスクの目的は人間によって与えられた質問に対し，自動で応答を出力をするようなシステムを構築することである．そのようなシステムの構築にはシステムが文章を理解するだけでなく，回答に必要な情報源をシステムが保持する必要がある．近年活用が進み，有力視されるものとして主に二つの情報源が存在する．一つ目は訓練データに含まれる文脈を情報源とした言語モデルである．二つ目は対象物間の関係をグラフの形で表した知識グラフである．言語モデルは訓練データで得た大量の知識をもとに数々の質問応答タスクに対し高精度な応答を実現した [1]．しかし否定といった推論，いわゆる構造化された推論を上手く扱えないことが指摘されている [2]．一方，知識グラフはより推論能力には長けているが，言語モデルよりも含まれる情報量としては劣ることがわかっている [3]．近年では言語モデルと知識グラフを組み合わせることで，両者の長所をうまく取り入れるようなモデルが，いくつか提案されている．

言語モデルと知識グラフを組み合わせたモデルの実験は英語のデータセットに対しては行われているものの, 日本語のデータセットに対する結果は報告されていない．そこで本稿では先述したモデルのうち代表的な 2 つのモデルである QAGNN [4] と GSC [6] を日本語のデータセットである KUCI [7] と JCommonsenseQA [8] に対して使用した．

また，本実験結果を受けて，実験に使用した日本語知識グラフと英語知識グラフのサイズの差異に注目し，質問応答システムに対し知識グラフのサイズが及ぼす影響を検証した．

2. 関連研究

言語モデルは質問応答システムにおいて高い精度を達成しているが，構造化された推論をうまく扱えないという問題がある．一方、知識グラフは推論能力に長けているが知識量は言語モデルに劣る．そのため，近年では言語モデルと知識グラフを組み合わせたモデルが考案されている．

† 北海道大学工学部
School of Engineering, Hokkaido University
†† 北海道大学大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University
a) E-mail: k-yano402@eis.hokudai.ac.jp
b) E-mail: rzepka@ist.hokudai.ac.jp
c) E-mail: araki@ist.hokudai.ac.jp
DOI:10.14923/transfunj.

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©2023 by IEICE

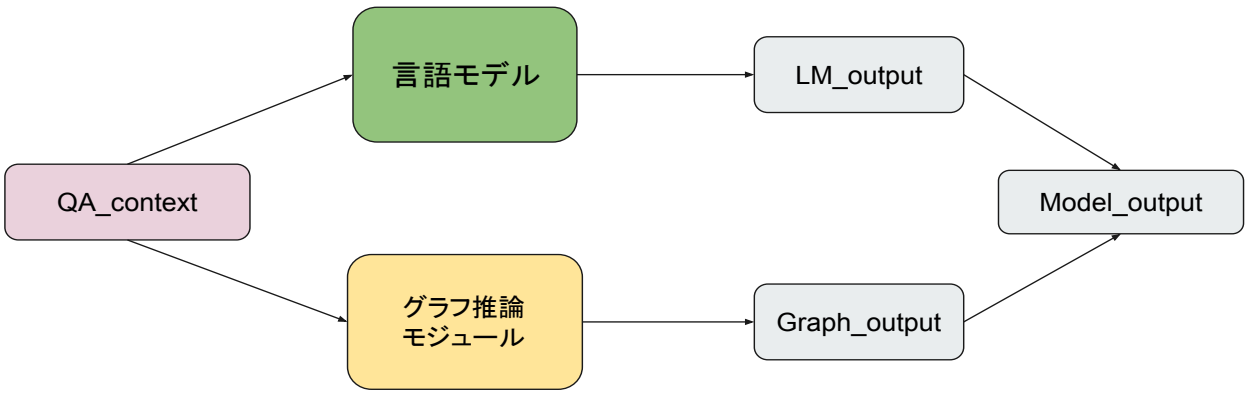


図 1　言語モデルとグラフ推論モジュールの構築例

既存研究 [4], [6], [9] ではこのようなモデルを設計する際，言語モデルとグラフ推論モジュールは独立したモジュールとして構築される．図 1 は既存研究に共通して見られるアーキテクチャーを簡潔に表現したものである．

言語モデルの役割は入力された QA_context に対し出力，LM_output を得ることである．またグラフ推論モジュールの役割は与えられた QAcontext から知識グラフを用いて推論を行い，Graph_output を出力することである．LM_output と Graph_output を何らかの方法で組み合わせたものを全体的なモデルの出力とするのが一般的なアプローチである．

Wang ら [6] は一般にこのようなグラフ推論モジュールにおいて，既存研究に共通してみられるプロセスが存在し，大きく二つのステップに分けられることを指摘した．Schema Graph Grounding と Graph Modeling for Inference である．Schema Graph とは，与えられた QA_context に関連するようなノードを持つように知識グラフから抽出されたサブグラフのことである．Schema Graph Grounding とはそのような Schema Graph を抽出するステップのことで，Graph Modeling for Inference とは Schema Graph に対して何らかのモジュールを用いて，回答に必要な出力を得るステップのことである．

この二つのステップに付随して主に二つの課題が存在する．一つ目は質問に対し必要な Schema Graph をどのように知識グラフから抽出するか．二つ目は Schema Graph 上でどのようなモジュールを設計してグラフ上で推論を行ない，結果を出力するかである．一つ目の課題に対処するために，Yasunaga ら [4] は質問文に出現したエンティティとそこから数ホップ内に存在するエンティティを抽出したものをサブグラフとし，またエンティティを言語モデルに入力しその結果を重要度としてスコアリングすることでより重要でないエンティティを除く抽出方法を提案し，精度が向上することを示した．二つ目の課題に関しては，Yasunaga ら [4] による QAGNN はグラフニューラルネットワークに Self-Attention の構造を組み込んだ手法である Graph Attention Network (GAT) を知識グラフ上の推論に用いることで精度向上を達成した．また Wang ら [6] による GSC はグラフニューラルネットワークを用いず，エッジエンコーダによる埋め込み表現を組み込んだグラフ上で簡単なアルゴリズムを用いるだけで SOTA を達成できることを示した．

3. 日本語知識グラフを用いた質問応答システムの実験と考察

3.1 データセット

本実験ではデータセットとして京都大学常識推論データセット (KUCI) [7] と JCommonsenseQA [8] の二つを使用した．これらのデータセットを採用したのは，どちらも常識推論能力を問うものであり，質問応答システムの推論能力を評価するのに最適であると考えられるためである．

3.1.1 KUCI

KUCI は基本的なイベント表現間における蓋然的関係 (ある程度続けて起こりうる関係) を問う多肢選択式問題からなる日本語常識推論データセットである．

3.1.2 JCommonsenseQA

JCommmonsenseQA は日本語言語理解ベンチマーク JGLUE に含まれるデータセットの内の一つである．JCommonsenseQA は CommonsenseQA [5] の日本語版データセットであり，常識推論能力を評価するための 5 択 QA 問題で構成されている．本稿執筆時において JCommonsenseQA は test データが公開されていないため，train データセットを IH-train データ，IH-dev データに分割し，dev データを IH-test データとして実験を行った．

3.2 モ デ ル

3.2.1 QAGNN

QAGNN [4] は知識グラフ上の推論のために attention 機構を組み込んだグラフニューラルネットワークを用いたモデルである．そのモジュールでは与えられたグラフに対して，何らかのエンコーダを用いることでノードやエッジのベクトル表現を得，それをニューラルネット入力し，出力を得る．またエンティティスコアリングを用いることで抽出した知識グラフのうち関連度が高いものを推論に用いることを可能にしている．QAGNN はグラフニューラルネットワークを用いたモデルの内最も精度が高いモデルであるため本実験に採用した．

3.2.2 GSC

GSC [6] はグラフの埋め込み表現のためのエッジエンコーダと，グラフ上の推論のため，GSC Layer と呼ばれるモジュールを用いたモデルである．GSC Layer はグラフ上で簡単な演算を行うのみで，ニューラルネットのような複雑な計算機構を持たないモジュールである．GSC はグラフニューラルネットワークを用いずとも英語のデータで SOTA を達成したモデルであるため本実験に採用した．

3.3 知識グラフ

知識グラフは様々なエンティティとの関係をエッジとしてグラフ構造として表したものである．またノード・リレーション・ノードを一つとしたものをエッジという．本実験では知識グラフとして ConceptNet [10] を使用した．ConceptNet はある自然言語の単語をノードとし，あらかじめラベル付けされたフレーズをノード間の関係として表したグラフ構造である．ConceptNet はテキストデータに現れない暗黙的な情報を含んでおり，常識推論タスクでよく使用される知識グラフである．本実験では ConceptNet の元データ[1]から日本語の Concept のみを抽出し，それを知識グラフとして使用した．日本語 ConceptNet のエッジは 83,454 個，含まれる Concept の個数は 28,495 個である．

表 1　KUCI データセットに対する実験結果

モデル	Acc (%)
RoBERTa-base-japanese	88.8
+QAGNN	86.7
+GSC	86.6
RoBERTa-large-japanese	90.1
+QAGNN	89.6
+GSC	**90.5**

表 2　JCommonsenseQA データセットに対する実験結果

モデル	Acc (%)
RoBERTa-base-japanese	87.7
+QAGNN	84.5
+GSC	84.6
RoBERTa-large-japanese	91.6
+QAGNN	90.7
+GSC	**91.8**

3.4 実 験 設 定

本実験ではベンチマークとモデルに用いる言語モデルの両方に Huggingface による transformers ライブラリにて提供される日本語の RoBERTa-base[2], RoBERTa-large[3]を使用した．KUCI, JCommonsenseQA 両方とも質問文と各選択肢を結合し，多肢選択肢問題を解く形式でモデルをファインチューニング及び訓練を行った．

3.5 実験結果と考察

3.5.1 実 験 結 果

KUCI, JCommonsenseQA データセットに対する Accuracy はそれぞれ表 1，表 2 のような結果となった．

3.5.2 考　　察

ベンチマークである言語モデルのみを使用したモデルとグラフを組み合わせたモデルの性能を比較するために，言語モデル (RoBERTa-large-japanese) が不正解となったが，QAGNN が正解した例を JCommonsenseQA データセットから集計した．集計結果によるとそのようなデータは全 test データ 1,619 例の内，42 例であった．

これらの例に対してモデルが上手く正答することができた理由として，グラフの有効活用が考えられる．例えばモデルが抽出したサブグラフに着目すると，図 2

（注1）：https://s3.amazonaws.com/conceptnet/downloads/2018/edges/conceptnet-assertions-5.6.0.csv.gz
（注2）：https://huggingface.co/nlp-waseda/roberta-base-japanese
（注3）：https://huggingface.co/nlp-waseda/roberta-large-japanese

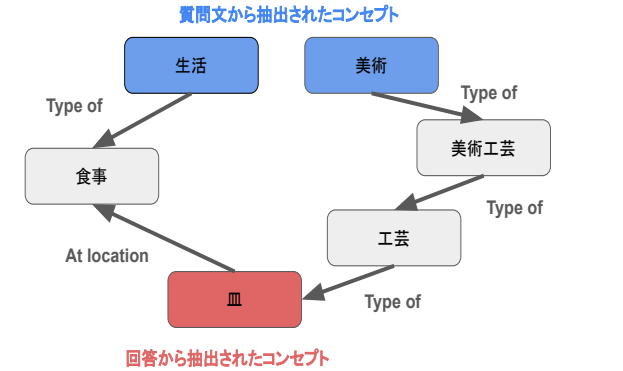


図 2　抽出されたサブグラフ

表 3　日本語 ConceptNet と英語 ConceptNet の比較

抽出先 ConceptNet	エッジ数	コンセプト数
日本語 ConceptNet	83,453	28,495
英語 ConceptNet	2,487,810	799,273

のようなサブグラフが抽出できていることが確認できた．図 2 に示すように，質問文から抽出されたコンセプトと回答から抽出されたコンセプトの間の関係を上手く知識グラフ内から取り出すことで，推論モジュールが効果的に働き，正答できたと考えられる．

英語の既存研究では QAGNN，GSC ともに言語モデル単体の精度よりも上回っていることが確認されているが，表 1，表 2 に示すように，本実験結果からはこれらのモデルのどちらも KUCI データセット，JCommonsenseQA データセットともに，ベースラインである言語モデルのみを使ったモデルと，精度に関して言えばほとんど変化していないことがわかる．考えられる要因として本稿では日本語の ConceptNet に焦点を当てる．つまり，日本語の ConceptNet の性能が精度に影響を及ぼしているのではないかという点である．日本語と英語知識グラフのエッジ数やノード数についての差異を表 3 に示す．

表 3 に示すように日本語の ConceptNet は英語の ConceptNet を比べて，エッジ数，コンセプト数ともに約 30 倍程度の差が見られる．英語の実験では精度が向上するのにも関わらず，日本語の実験ではほとんど性能に差が見られなかったのはおそらく，この知識グラフに含まれる情報量の差異に起因すると考えらるる．したがって，英語 ConceptNet と言語モデルを用いて，知識グラフのサイズは質問応答システムの精度に影響を与えるかどうかを次の実験で調査する．

表 4　グラフサイズの影響を調べるために使用したグラフのエッジ数とコンセプト数

抽出した ConceptNet	エッジ数	コンセプト数
ConceptNet-same-edge_ja	83,453	95,886
ConceptNet-small	829,344	457,695
ConceptNet-medium	1,658,696	657,245
ConceptNet (元サイズ)	2,487,810	799,273

4.　知識グラフの影響に関する実験と考察

4.1　英語 ConceptNet のサイズ調節

ConceptNet のような heterogeneous graph では個々のエンティティの関係が多くの種類を持つリレーションで表されるため，たとえ二つのエンティティが同じであっても複数のリレーションで表すことができる例が少なくない．そのため知識グラフではエッジを一つの構成要素としてみなす方がエンティティ単体よりも一般的である．したがって英語の ConceptNet の影響を調査するのにあたって，本稿ではエッジに焦点を当てて知識グラフの影響を検証する．

そこで英語の ConceptNet からサイズをあらかじめ設定し，そのサイズにしたがって元のコンセプトネットから実験に使用するグラフをランダムに抽出する必要がある．本実験では英語 ConceptNet の各 Relation の比率を調査し，その比率を保存するように元の ConceptNet から抽出した．また，抽出した ConceptNet は全部で 3 種類あり，一つ目は日本語 ConceptNet と同エッジサイズの ConceptNet-same-edge_ja，二つ目は元サイズの 3 分の 1 のエッジサイズの ConceptNet-small，三つ目は元サイズの 3 分の 2 のエッジサイズの ConceptNet-medium である．詳しいサイズ数を表 4 に示す．

4.2　グラフの影響に関する実験

4.2.1　データセットとモデル

本実験ではグラフの影響を調査するにあたって，CommonsenseQA データセットを用いた．CommonsenseQA データセットは JCommonsenseQA と同様に常識的な推論を要求するデータセットであり，5 択 QA 問題で構成されている．またテストデータが構成されていないため，Lin [9] らの論文で用いられている IH データスプリットと同様に実験を行った．またモデルは QAGNN を採用し，言語モデルは RoBERTa-large を使用した．

表 5　抽出した ConceptNet に対する実験結果

Methods	IH-test Acc (%)
roberta-large	68.69
+ConceptNet-same-japanese	69.94
+ConceptNet-small	70.82
+ConceptNet-medium	71.47
+ConceptNet (元サイズ)	73.41

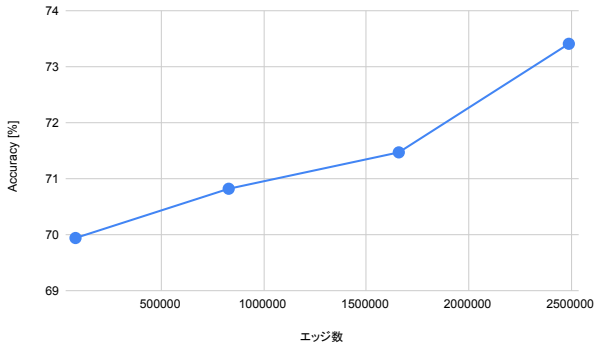


図 3　エッジ数と accuracy の関係

4.2.2　実験結果と考察

表 5 や図 3 からわかるように，エッジ数が上昇するほど accuracy が上昇することが見て取れる．また，この結果から，エッジ数を説明変数，accuracy を目的変数として線形回帰を用いて，フィッティングを行うと回帰直線は

$$y = 1.38 \times 10^{-6} x + 69.67$$

となり, 相関係数 r は

$$r = 0.97$$

となり，正の相関があることがわかる．しかし精度を 1% 上昇させるのに, エッジを約 73 万ほど増やす必要があることもわかる．また，これらの英語の ConceptNet に関する実験結果が日本語の ConceptNet にも当てはまるとすれば，日本語の ConceptNet のサイズの少なさのために質問応答システムの精度が向上しなかったと考えられる．また同時に，日本語 ConceptNet の拡大がグラフを使用しするモデルの精度向上に，非常に密接な関係があることも示唆している．

5.　おわりに

本稿では英語の実験結果しか未だ存在しなかった言語モデルと知識グラフを組み合わせた手法を日本語データセットを用いて実験を行った．この実験結果では言語モデルのみを用いた精度とほとんど変化がみられなかった．そこで本稿では英語 ConceptNet と日本語 ConceptNet のサイズの違いを指摘し，ConceptNet のサイズが精度に影響を及ぼすのかを検証するために，英語 ConceptNet のエッジ数を調整したグラフを用意し，QAGNN と CommonsenseQA データに対して，それぞれの ConceptNet を用いて実験を行った．するとエッジ数と精度の間に正の相関があることがわかった．これは日本語 ConceptNet の拡大が質問応答システムの精度向上に結びつくことを示唆している．

今後の課題としては，本稿ではエッジ数と精度の関係しか調査しなかったが，さらに知識グラフのサイズと精度の関係を調査するため，コンセプト数と精度に関する実験が必要である．また今後は知識グラフを用いる質問応答システムの精度向上のため，日本語の ConceptNet のサイズの拡大への議論もまた必要である．

文　献

[1] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *preprint arXiv:1907.11692*. 2019

[2] Nora Kassner and Hinrich Schütze. Negated and misprimed probes for pretrained language models: Birds can talk, but cannot fly. In *Association for Computational Linguistics (ACL)*. 2020.

[3] Hongyu Ren, Weihua Hu, and Jure Leskovec. Query2box: Reasoning over knowledge graphs in vector space using box embeddings. In *International Conference on Learning Representations (ICLR)*. 2020.

[4] Michihiro Yasunaga, Hongyu Ren, Antoine Bosselut Percy Liang, Jure Leskovec. QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering. In *North American Chapter of the Association for Computational Linguistics (NAACL)*. 2021

[5] Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. Commonsenseqa: A question answering challenge targeting commonsense knowledge. In *North American Chapter of the Association for Computational Linguistics (NAACL)*. 2019.

[6] Kuan Wang, Yuyu Zhang, Diyi Yang, Le Song, Tao Qin. GNN is a Counter? Revisiting GNN for Question Answering. In *International Conference on Learning Representations (ICLR)*. 2022.

[7] Kazumasa Omura, Daisuke Kawahara and Sadao Kurohashi: A Method for Building a Commonsense Inference Dataset based on Basic Events, In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. 2020.

[8] Kentaro Kurihara, Daisuke Kawahara, and Tomohide Shibata. JGLUE: Japanese General Language Understanding Evaluation. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*. 2022.

[9] Bill Yuchen Lin, Xinyue Chen, Jamin Chen, and Xiang Ren. KagNet: Knowledge-aware Graph Networks for Commonsense Reasoning. In *Empirical Methods in Natural Language Processing*

(EMNLP). 2019.

[10] Robyn Speer, Joshua Chin, and Catherine Havasi. Conceptnet 5.5: An Open Multilingual Graph of General Knowledge. In *Proceedings of the AAAI Conference on Artificial Intelligence*. 2017.