The 36th Annual Conference of the Japanese Society for Artificial Intelligence, 2022

雑談対話システムにおけるユーモアを用いた対話破綻回復処理の有効性

Effectiveness of Humor to Recovery from Dialogue Breakdown on Chat-oriented Dialogue Systems

原直大 *1　荒木健治 *2
Naohiro Hara　Kenji Araki

*1北海道大学 大学院情報科学院
Graduate School of Information Science and Technology, Hokkaido University

*2北海道大学 大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University

In this study, we propose a method of Tsukomi which is one of Japanese humor, to recover from the state of dialogue breakdown to the original dialogue flow more naturally in Chat-oriented dialogue system. Specifically, in addition to the chat dialogue system and the user, we prepare a third system that acts as a Tsukomi. The third system corrects the broken dialogue flow and recovers the broken dialogue by pointing out the mistakes in the dialogue. In order to verify the effectiveness of the proposed method, we conducted a dialogue evaluation experiment by incorporating the proposed method into an existing chat dialogue system and having users actually interact with the system. The results of the evaluation experiments showed that the proposed method was highly evaluated compared to the existing system without the proposed method and the system with the existing method. We also discuss the improvements of the proposed method using the dialogue logs obtained in the experiments.

1. はじめに

本研究では，雑談対話システムにおいて，対話破綻の状態から元の対話の流れにより自然に回復するために，日本のユーモアの 1 つである漫才のツッコミを利用する方法を提案する．具体的には，雑談対話システムとユーザのほかに，3 人目となるツッコミ役のシステムを用意する．そのシステムが対話システムの起こした対話破綻に対して，間違いを指摘するようなツッコミを行うことによって，破綻してしまった対話の流れを訂正し，対話破綻回復を行う．提案手法による対話破綻回復の有効性を確かめるために，既存の雑談対話システムに提案手法による対話破綻回復処理を組み込んで，実際にユーザに対話してもらうことで，評価実験を行った．評価実験の結果，対話破綻回復をしないものや既存手法による対話破綻回復処理を行うものと比較して，高い評価を得た．さらに，実験で得られた対話ログを用いて提案手法の改善点を考察する．

2. 関連研究

近年，雑談対話システムの研究が盛んに行われ，その性能は向上している．しかし，依然として対話システムが不適切な応答をすることで，対話破綻が生じるという問題が報告されている．

対話破綻を回復するための既存研究は稲葉ら [稲葉 19] や徐ら [徐 18] 山崎ら [山崎 20] の研究のように，主に対話破綻を事前に回避することを目的としている．しかし，人間同士の対話でも文脈の勘違いや知識の不足などが原因で対話破綻は起きてしまうため，対話破綻の事前回避では破綻を軽減することは可能であっても，完全な問題の解決には至らないと考えられる．雑談対話システムにおける対話破綻の問題の解決のためには，人間同士の会話のように一度対話破綻になった状態からでも，元の対話の流れに回復できる手法が必要である．

連絡先: 原直大，北海道大学大学院情報科学院，harahappy0208@eis.hokudai.ac.jp

対話破綻回復に関する研究としては坪倉ら [坪倉 21] による研究がある．この研究では，「すみません。話の流れを理解できていなかったかもしれません。」と謝ることで対話破綻回復を試みている．実験で得られた対話ログについて分析を行うことで，対話破綻検出が適切に行われたとしても，対話破綻後のユーザの発話によっては必ずしも対話破綻回復が有効でないことを明らかにした．しかし，対話破綻回復処理を組み込んだ対話システムのユーザ評価は低く，比較実験なども行われていないため，対話破綻回復処理自体の有効性は示されていない．

そこで本研究では，ユーモアの 1 つである漫才のツッコミを用いて対話破綻回復を行う手法を提案し，その有効性を検証する．具体的には，対話破綻文の直後に 3 人目となるシステムがツッコミを行うことによって，対話破綻後のユーザの発話前にすぐに対話破綻回復を行う．また，既存研究では行われていない対話破綻回復ありと対話破綻回復なしの対話システムの比較実験により，対話破綻回復の有効性を確認する．

3. 提案システム

本章では，提案システムの構成について説明する．対話システムは，坪倉らの提案システムと同様に，ユーザ発話に対してメイン対話システムとして応答を生成する対話応答生成部，対話応答生成部の対話破綻を検出する対話破綻検出部，対話破綻検出部によって検出された対話破綻に対して破綻回復処理を行う対話破綻回復部の 3 つで構成される．本章では，提案システムの各処理部について説明する．

3.1 対話応答生成部

対話応答生成部には，ILYS aoba bot[藤原 20] の系列変換応答生成モジュールを用いる．ILYS aoba bot は，系列変換応答生成モジュールと知識ベース応答生成モジュール，応答フィルタリングモジュールの 3 つのモジュールで構成され，その中の系列変換応答生成モジュールが公開されている．本研究では，坪倉らの提案システムと同様に，この系列変換応答生成モジュールをメイン対話システムとして，対話応答生成部に利用

する．系列変換モジュールでは 1 回の発話で 5 つの異なる応答候補が得られるため，1 つ目の応答候補が既に使われている場合は次の応答候補を利用することで，対話中に全く同じ発話をしない設定にする．また，対話応答生成部による発話文には，文頭に「SYS1：」と加える．

3.2 対話破綻検出部

対話破綻検出部には，『Python でつくる対話システム』[東中 20] で公開されている対話破綻検出器を用いる．『Python で作る対話システム』では，対話システムを構築する際に利用できるソースコードやデータが GitHub 上で公開されている．今回の提案システムでは，このソースコードを用いて，BERT[Devlin 18] を対話破綻検出チャレンジ 2[東中 16] のデータセットにより，fine-tuning することで対話破綻検出器を作成する．

3.3 対話破綻回復部

串田ら [串田 17] によると，人間同士の対話破綻回復（修復）では，破綻の部分を指摘する修復の開始の段階と，破綻の解決を行う修復の実行の段階があるとされる．以下では，2 つの段階におけるシステムの対話破綻回復処理について説明する．

3.3.1 修復の開始

坪倉らの手法 [坪倉 21] での対話破綻回復処理では，「すみません．話の流れを理解できていなかったかもしれません．」と発話することで，1 つ前の自分の発話文が破綻であったことを示している．このような自分の発話による対話破綻を自分で指摘する修復の開始の方法を自己開始という [串田 17]．

提案手法である「ツッコミを用いた対話回復処理」では，修復の開始の段階にツッコミを用いる．対話応答生成部の破綻文にツッコミを入れることで，破綻文の存在を示す．自己開始に対して，破綻を他人が指摘する修復の開始を他者開始という [串田 17]．今回のシステムでは，ツッコミは事前に作成したリストからランダムに選択される．また，ツッコミ文の直前に「SYS2：」と加えることで，ユーザにツッコミ発話が破綻文とは異なる話者によって発話されたものだと判別できるようにする．

3.3.2 修復の実行

修復の実行については，坪倉らの手法と同様に，対話破綻前の対話の履歴から話題を抽出し，「＜話題＞についての話でしたよね。」と発話することで，対話破綻検出前に話題を戻し回復する．直前のシステム発話とユーザ発話から，一般名詞を話題として抽出する．なお，一般名詞は Mecab の形態素解析の結果により判別する．ツッコミによる対話破綻回復は，対話中に頻繁に行われるとユーザに違和感を与えてしまう可能性があることから坪倉らの手法と同様に，提案手法（ツッコミ）による対話破綻回復は一度行った後は，その後 3 ターンは行わない．実際の対話で作成された対話破綻回復文の例を以下に記述する．

- SYS2：なるほどなるほど…ってなんでやねん！SYS1 !! ホンマ頼むわ…

  SYS2：食べ物についての話でしたよね。

- SYS2：そうそうそう…ってなに言うてんねん !!!

  SYS2：ジンギスカンについての話でしたよね。

4. 実験方法

本研究では，実際にシステムと対話を行ったユーザに人手で評価をしてもらい，比較実験を行う．提案手法との比較に用いる対話システムは，対話破綻回復を行わない対話応答生成部のみの対話システムと坪倉らの手法による対話破綻回復を行う対話システムである．これらの対話システムはすべてメッセージアプリ Telegram 上でチャットボットとして作成され，対話及び評価はすべてこの Telegram 上で行われる．

4.1 対話設定

対話は，対話システムライブコンペティション 4[東中 21] の対話設定を参考に，システム発話から開始し，システムとユーザが交互に発話を行い，それぞれが 15 発話（15 ターン）した時点で終了する．また，参加人数に対する対話数を増やすため，新名ら [新名 19] を参考に，システムによる開始発話を，以下の 5 種類用意する．

- 早速ですけど，あなたの趣味は何ですか？
- 早速ですけど，好きな食べ物は何ですか？
- 早速ですけど，旅行で行きたい国はどこですか？
- 早速ですけど，好きな動物は何ですか？
- 早速ですけど，休日によくすることは何ですか？

4.2 評価指標

対話システムの性能を比較するために，以下の 4 つの評価指標について 5 段階で評価する．稲葉ら [稲葉 19] と同様に，対話破綻回復による対話の自然さと面白さ（楽しさ）への影響を調査する．また，提案手法による対話破綻回復を行うと，ユーザ視点ではシステムが 2 人に見えるため，疎外感を感じる可能性がある．親密さの評価により，システムが 2 人になることに対するユーザの印象の変化を調査する．最後に，もう一度対話したいかの評価でその対話の総合的な評価を行う．

5. 実験結果

評価実験には，合計で 8 人の参加者が得られたが，1 人当たりの対話数を等しくするために，評価および分析には 5 種類の開始発話すべてを評価した 4 人分のデータを利用する．各対話システムについて，15 ターンの対話が**合計 20 対話**（5 種類の開始発話×対話参加者 4 人）得られた．また，対話破綻回復部による発話数は，坪倉らの手法による対話破綻回復を行う対話システムが 20 対話中に計 58 対話，提案手法の対話システムが計 65 発話であった．つまり，対話破綻回復は 1 対話中に，坪倉らの手法では平均で **2.9** 回，提案手法では平均 **3.6** 回行われたことがわかった．

表 1 に，3 つの対話システムの評価スコアの平均値を示す．提案手法による対話システムが，すべての評価指標について，他の 2 つを上回っていることがわかる．「親密さ」の評価指標に関しても，評価スコアは上がっているため，システムがユーザ視点で 2 人になる影響はなかったと考えられる．

表 1: 評価スコアの平均値

	破綻回復なし	坪倉らの手法	提案手法
自然さ	2.20	2.35	**2.60**
親密さ	2.55	2.65	**2.85**
面白さ	2.30	2.45	**2.80**
もう一度対話	1.90	2.15	**2.25**

注）太字は各評価指標で最も高い値

表 2，**表 3**，**表 4** には，それぞれの対話システムの評価スコアの分布を示す．評価スコアの分布には，あまり大きな違いは見られないが,「もう一度対話したいか」の評価指標に着目すると，提案手法のシステムのみに評価スコア 4 以上の評価がされていることがわかる．

表 2: 評価スコアの分布（破綻回復なし）

評価スコア	自然さ	親密さ	面白さ	もう一度
5	0（ 0%）	0（ 0%）	1（ 5%）	0（ 0%）
4	4（20%）	4（20%）	1（ 5%）	0（ 0%）
3	2（10%）	6（30%）	6（30%）	6（30%）
2	8（40%）	7（35%）	7（35%）	6（30%）
1	6（30%）	3（15%）	5（25%）	8（40%）

表 3: 評価スコアの分布（坪倉らの手法による破綻回復）

評価スコア	自然さ	親密さ	面白さ	もう一度
5	0（ 0%）	0（ 0%）	0（ 0%）	0（ 0%）
4	3（15%）	2（10%）	3（15%）	0（ 0%）
3	8（40%）	9（45%）	7（35%）	7（35%）
2	6（30%）	9（45%）	6（30%）	9（45%）
1	3（15%）	0（ 0%）	4（20%）	4（20%）

表 4: 評価スコアの分布（提案手法による破綻回復）

評価スコア	自然さ	親密さ	面白さ	もう一度
5	1（ 5%）	1（ 5%）	2（10%）	1（ 5%）
4	4（20%）	4（20%）	3（15%）	2（10%）
3	5（25%）	6（30%）	8（40%）	3（15%）
2	6（30%）	9（45%）	3（15%）	9（45%）
1	4（20%）	0（ 0%）	4（20%）	5（25%）

6. 考察

比較実験の結果から，提案手法による対話破綻回復が雑談対話システムの性能向上にある程度効果があることが確認された．本章では，得られた対話例とアノテーションの 2 つの観点から，提案手法の改善点を考察する．

6.1 対話例を用いた考察

本節では，評価が高かった対話例と低かった対話例から，提案手法が有効であった点と問題点を考察する．

表 5 の対話例は，評価スコアが（自然さ : 4，親密さ : 4，面白さ : 5，もう一度対話したいか : 4）と高かった対話例の中から対話破綻回復部による発話周辺を抜粋したものである．この対話例では，検出された対話応答生成部の「犬種は犬が好きですね」という破綻文に対して,「そうそうそう…っておい！SYS1 !! 犬についての話でしたよね。」とツッコミを入れることで，好きな犬種についての話に対話破綻を回復している．

この例のように，破綻文に対して適切なタイミングかつ適切な内容のツッコミによって対話破綻回復が行われると，ユーザから対話の自然さと面白さの両方について高い評価を得るということが示唆される．実際のユーザの意見にも「ツッコミが会話にハマっていると面白かった.」というものがあった．

次に，評価スコアの低かった対話例を分析することで，ツッコミによる破綻回復が失敗した原因を明らかにし，提案手法の問題点を考察する．**表 6**，**7** は，評価スコアの低かった対話例から，対話破綻回復部による破綻回復が失敗していると考えられる部分を抜粋したものである．

表 6 の例では，対話破綻検出に誤りがあったため，対話破綻ではない部分で，ツッコミが不適切なタイミングで発話されてしまっている．不適切なタイミングでのツッコミは，ユーザと対話応答生成部の円滑な対話の邪魔をしたり，対話破綻回復文自体が対話破綻となってしまうため，ユーザの評価を下げてしまうと考えられる．

表 7 の例では，ツッコミ後の「＜話題＞についての話でしたよね。」という発話文の生成における話題の抽出に失敗していると考えられる．話題の抽出が適切に行われない場合，対話破綻回復は失敗となり，ユーザが「Sys2」に対して違和感や不信感を感じる原因になると考えられる．

また，少数であるが対話中に対話破綻回復部による発話後に，ユーザがツッコミ役である SYS2 に話しかけてしまうことで対話が成り立たなくなる例もあったことから，ツッコミによる対話破綻回復をより自然に行うためには，第三者であるツッコミ役のシステムが対話破綻回復時以外にも雑談に参加できるような手法の検討が必要である可能性がある．

表 5: 評価の高い対話例（評価スコア : 4, 4, 5, 4）

Sys1 : 私がメインで対話をします。
　　早速ですけど，好きな動物は何ですか？
User : 犬が好きです！
Sys1 : なるほど!犬は可愛いですね!
User : はい！昔飼っていました。
Sys1 : どんな犬種が好きですか?
User : ゴールデンレトリバーが好きです！
Sys1 : ゴールデンレトリバーは可愛いですね
User : あなたはどの犬種が好きですか？
Sys1 : 犬種は犬が好きですね
Sys2 : そうそうそう…っておい！SYS1 !!
Sys2 : 犬についての話でしたよね。
User : そうですね。どの犬種が好きですか？
Sys1 : 私は柴犬が好きです。
User : 柴犬ですか！かわいいですよね！
Sys1 : 柴犬は可愛いですね。
…

表 6: 評価の低い対話例（評価スコア : 1, 2, 1, 1）

Sys1 : 私がメインで対話をします。
　　早速ですけど，好きな食べ物は何ですか？
User : きゅうりが好きです！
Sys1 : きゅうりですか!いいですね!
User : 何も付けずに食べるのが好きです。
Sys1 : きゅうり美味しいですよね!私も大好きです!
Sys2 : っておい！なんでやねん！SYS1 !!
Sys2 : きゅうりについての話でしたよね。
User : そうですね。
…

表 7: 評価の低い対話例（評価スコア：1, 2, 1, 1）

…
User：難易度とかあったら一番高いのでやってしまうから，無駄に時間かかってしまう
Sys1：難易度は低いのがいいよね
User：たぶんそのほうがいい
Sys1：難易度は低い方がいいよね
Sys2：そうそうそう…ってなんやねんそれ！
Sys2：難易についての話でしたよね。
User：だからのんびりできるゲームがいいです
Sys1：ゲームは時間をかけますよねえ。
…

6.2 アノテーションを用いた考察

対話破綻回復が適切であったかについての定量的な分析を行うために，提案システムの対話破綻回復部によって出力された全 65 発話について，第一著者によって以下の 2 つのアノテーションを行った．1 つ目の「対話破綻検出が適切に行われていたか」については，対話破綻検出チャレンジ [東中 16] の対話破綻アノテーションの基準を参考に行った．2 つ目の「対話破綻回復処理が適切であったか」については，対話破綻回復部による発話後のユーザ発話をもとにアノテーションを行った．

- 対話破綻検出が適切に行われていたか
- 対話破綻回復処理が適切であったか

アノテーションの結果，65 発話中 43 発話については適切に対話破綻検出が行われていたことがわかった．残りの 22 発話は，**6.1** で述べた不適切なタイミングでのツッコミであり，評価を下げる原因になっていると考えられる．しかし，雑談対話における応答の多様性を考慮すると，対話破綻検出の精度を改善し完璧に行うことは困難である．対話破綻検出が失敗し不適切なタイミングになってしまったとしても，ユーザにあまり違和感を与えない対話破綻回復手法の検討が必要である．

対話破綻検出が適切に行われていた 43 発話中で，その検出された対話破綻が対話破綻回復処理によって適切に対話破綻回復できていた発話は，17 発話であった．2 発話は対話破綻回復部の発話がその対話中の最後の発話であった．残りの 24 発話は対話破綻回復に失敗しており，ユーザからも「違います」と訂正されたり，無視されたりしていた．対話破綻回復が失敗した原因としては，**6.1** で述べた話題の抽出が不適切であったことが挙げられる．必ずしも直前の一般名詞について対話を戻すことが，適切な対話破綻回復ではないことが考えられる．改善案としては，話題の抽出の対象に一般名詞だけではなく固有名詞も含めること，連続する名詞を 1 つの名詞として抽出することなどが考えられるが，おそらく不十分である．対話破綻回復後の話題としては，直前の名詞ではなく少し前の名詞のほうが適切である場合もあったため，話題の抽出方法についても検討が必要である．

7. まとめ

本研究では，雑談対話システムにおける対話破綻を回復する手法として，ユーモアの 1 つである漫才のツッコミを用いる手法を提案した．評価実験の結果，提案手法は対話破綻回復なしや既存手法による対話破綻回復と比較して，ユーザから高い評価を得ることができた．対話ログを用いた考察の結果，対話破綻検出の誤りや話題の抽出の失敗がツッコミによる対話破綻回復の評価を下げる原因になっていることが明らかとなった．

今後の課題としては，対話破綻検出が失敗していたとしてもユーザにあまり違和感を与えない対話破綻回復の手法の考案や修復の実行における話題の抽出の仕方の改善が挙げられる．より自然な対話破綻回復を行うために，第 3 者であるツッコミが対話破綻回復時以外にも雑談に参加できる方法の検討を行う．さらに，ツッコミ以外のユーモアを用いた対話破綻回復手法も検討する．今回の実験では，対話参加者の性別と年齢に偏りがあったため，将来的には参加者を増やした大規模な評価実験を行う予定である．また，他の対話システムについてもツッコミによる対話破綻回復の有効性を検証する必要があると考えられる．

参考文献

[Devlin 18] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K.: Bert: Pre-training of deep bidirectional transformers for language understanding, *arXiv preprint arXiv:1810.04805* (2018)

[稲葉 19] 稲葉通将, 高橋健一 : 対話破綻検出の対話システムへの適用, 人工知能学会論文誌, Vol. 34, No. 3, pp. B–I64_1–8 (2019)

[串田 17] 串田秀也, 平本毅, 林誠 : 会話分析入門, 勁草書房 (2017)

[山崎 20] 山崎翔太, 寺岡丈博 : 対話破綻の特徴に応じた回避手法の提案, 第 82 回全国大会講演論文集, 第 2020 巻, pp. 421–422 (2020)

[徐 18] 徐 云帆, 荒木 健治　他 : 雑談対話システムにおける LSTM を用いた駄洒落による対話破綻回避の有効性, *SIG-SLUD*, Vol. 5, No. 02, pp. 143–148 (2018)

[新名 19] 新名 和也, 嶋田 和孝 : トリビア文および雑学文を利用する対話システムの構築, 火の国情報シンポジウム (2019)

[坪倉 21] 坪倉 和哉, 永野 葉月, 入部 百合絵, 北岡 教英 : 対話システムにおける破綻回復処理の検討, 人工知能学会研究会資料言語・音声理解と対話処理研究会, Vol. 93, pp. 214–217 (2021)

[東中 16] 東中竜一郎, 船越孝太郎, 稲葉通将, 荒瀬由紀, 角森唯子　他 : 対話破綻検出チャレンジ 2, *SIG-SLUD*, Vol. 5, No. 02, pp. 64–69 (2016)

[東中 20] 東中竜一郎, 稲葉通将, 水上雅博 : Python でつくる対話システム, オーム社 (2020)

[東中 21] 東中 竜一郎, 船越 孝太郎, 高橋 哲朗, 稲葉 通将, 赤間 怜奈, 佐藤 志貴, 堀内 颯太, ドルサ テヨルス, 小室 允人, 西川 寛之, 宇佐美 まゆみ : 対話システムライブコンペティション 4, 人工知能学会研究会資料言語・音声理解と対話処理研究会, Vol. 93, pp. 92–100 (2021)

[藤原 20] 藤原吏生, 岸波洋介, 今野颯人, 佐藤志貴, 佐藤汰亮, 宮脇峻平, 加藤拓真, 鈴木潤, 乾健太郎 : ILYS aoba bot: 大規模ニューラル応答生成モデルとルールベースを統合した雑談対話システム, 第 90 回人工知能学会言語・音声理解と対話処理研究会 (第 11 回対話システムシンポジウム) (2020)