Transformer を用いたアイヌ語-日本語間機械翻訳における精度と対訳コーパスの関係

Relationship between Performance and Parallel Corpus in Machine Translation for Ainu-Japanese using Transformer

田中蒼大郎† 越前谷博† 荒木健治‡
Sotaro Tanaka† Hiroshi Echizen'ya† Kenji Araki‡

†北海学園大学
†Hokkai-Gakuen University

‡北海道大学大学院情報科学研究院
‡Faculty of Information Science and Technology, Hokkaido University

１．はじめに

近年のニューラル翻訳の著しい発展により様々な言語間の翻訳精度が向上している．しかし，ニューラル翻訳の精度は対訳コーパスの量に強く依存することから大規模な対訳コーパスの入手が困難な低資源言語に対しては十分な精度を得ることが困難となる．すなわち，低資源翻訳では出現頻度の低い単語が数多く存在するためニューラル翻訳においては十分に学習が行われない可能性がある．

そこで本稿では言語資源が非常に乏しい言語の 1 つであるアイヌ語を対象とした，アイヌ語と日本語間のニューラル翻訳を通して対訳コーパスのサイズおよび対訳コーパス中の低頻度語と翻訳精度の関係を調査した結果について述べる．

２．アイヌ語-日本語間機械翻訳システム

アイヌ語-日本語間の機械翻訳システムの構築は代表的なニューラル翻訳のアーキテクチャである Transformer[1] を用いて行った．Transformer の最大の特徴は Attention 機構のみを用いて Encoder-Decoder モデルを実現している点にある．

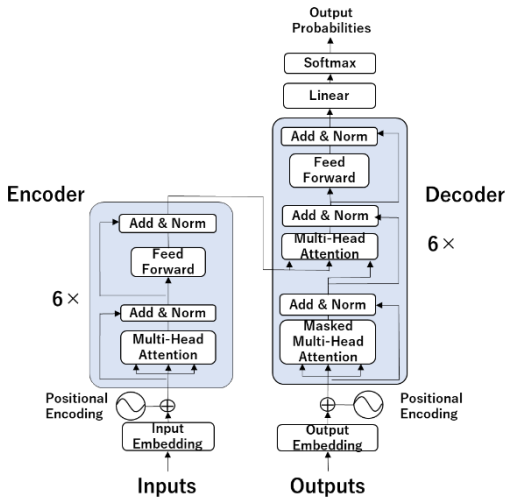


図 1　Transformer のアーキテクチャ

図 1 に Transformer のアーキテクチャを示す．Transformer は大きく Encoder と Decoder に分かれており，それぞれ 6 回繰り返される．Transformer では Embedding 層により入力文と出力文の全トークンをベクトルに変換する．変換された入力文と出力文の単語ベクトルにはそれぞれ Positional Encoding 層による語順情報が付与され，入力文の単語ベクトルは Encoder，出力文の単語ベクトルは Decoder の入力となる．したがって，Encoder， Decoder 共にベクトルを内部表現として処理を行う．Transformer は RNN[2]のように語順の情報を再帰により取り入れるのではなく，Positional Encoding 層を用いて語順の情報を付与することで高速化を実現している．

Encoder と Decoder の内部の詳細は割愛するが，両方に存在する Multi-Head Attention を構成している Self-Attention 機構は Transformer の最大の特徴であるため，Self-Attention 機構について簡単に述べる．Self-Attention 機構は文中の任意の単語がその単語も含めた文中のすべての単語との関連度を算出する．例えば“That is a pen .”という文においては Self-Attention 機構により“That”と“pen”の関連度が高くなる．このように指示語が存在する場合，その指示語がどの単語に焦点を当てるべきかを決定する役割を担うことで高度な意味処理を実現している．

３．性能評価実験

３．１　実験方法

アイヌ語-日本語間の Transformer モデルのために用いたアイヌ語と日本語の対訳文の数は 91,168 文であり，その内訳を表 1 に示す．

表 1　使用したデータの内訳

データ	対訳数
アイヌ語口承文書コーパス[3]	7,630
オルシペスウオプ[4]	27
アイヌ神謡集[5]	1,295
トピック別アイヌ語会話辞典[6]	2,969
ＡＡ研アイヌ語資料公開プロジェクト[7]	9,263
国立アイヌ民族博物館アイヌ語アーカイブ[8]	69,984
合計	91,168

本実験は対訳コーパスサイズと翻訳精度の関係を調べるためにサイズの異なる 2 種類の対訳コーパスを用いて行った．具体的には全データ数の半分である 45,584 をランダムに抜き出し，使用した対訳コーパス A とすべてのデータ 91,168 を使用した対訳コーパス B である．このように使用

Confidential

する対訳コーパスが 2 種類となることで Transformer モデルも複数となる．ここでは対訳コーパス A による Transformer モデルをモデル A，対訳コーパス B による Transformer モデルをモデル B とする．モデル A と B 共に使用するデータは対訳コーパス A と B それぞれの 80%を学習データ，10%を検証データ，残り 10%を評価データとしてランダムに抽出し，使用した．

モデル A とモデル B いずれも学習の際のエポック数は 100，学習率は 0.001，バッチサイズは 100 である．さらに本実験ではアイヌ語-日本語の双方向での翻訳を行う．したがって，モデル A，B はそれぞれアイヌ語から日本語への翻訳モデルと日本語からアイヌ語への翻訳モデルの 2 つのモデルが存在することとなり，モデルの数は計 4 つとなる．

３．２　実験結果

表 2 の評価データに対する翻訳精度は BLEU[9]スコアを用いて得た．表 2 にモデル A と B の BLEU スコアを示す．

表 2　BLEU スコア

	モデル A	モデル B
アイヌ語-日本語	22.2	12.1
日本語-アイヌ語	25.2	14.1

３．３　考察

表 2 より，モデル A の BLEU スコアはアイヌ語-日本語双方向においてモデル B の BLEU スコアを上回っており，対訳コーパスサイズの小さい翻訳モデルの精度が高くなった．

したがって，対訳コーパスと翻訳精度の関係においては，対訳コーパスのサイズの規模が翻訳精度に依存しないことが明らかとなった．そこで対訳コーパス中の全出現単語における低頻度語の割合と翻訳精度の関係について調査した．

図 2 に対訳コーパス A，図 3 に対訳コーパス B に占める出現頻度別の単語の割合を示す．

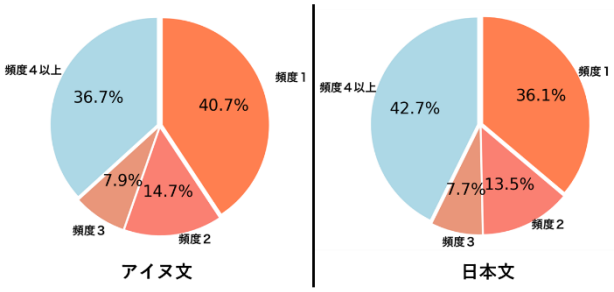


図 2 対訳コーパス A における単語の出現頻度の割合

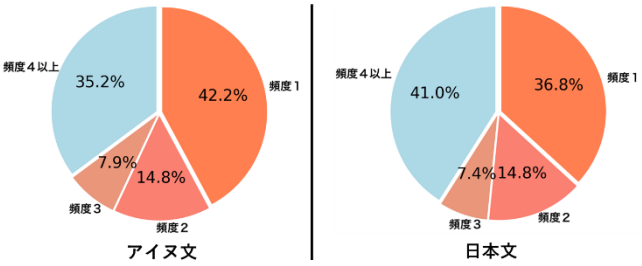


図 3 対訳コーパス B における単語の出現頻度の割合

図 2 と図 3 より，出現頻度 1～3 の単語の占める割合に大きな差は見られなかった．そこで，低頻度語について *idf* の観点より調査を行った．*idf* は全文数 *N* に対する任意の単語の出現回数 *df* の割合の逆数に *log* を付与した以下の式(1)によって得られる．

$$idf = log(N/df) \quad (1)$$

この *idf* 値が大きい単語ほど文全体に対する出現割合は小さく，*idf* 値が小さい単語ほど文全体に対する出現割合が大きいことを意味する．調査の結果，対訳コーパス A と B において出現頻度が 1 である単語の *idf* 値は，アイヌ語と日本語いずれもそれぞれ 10.504 と 11.197 となった．したがって，対訳コーパス B の方が *idf* 値は大きく，文全体に対する出現の割合は小さいことがわかった．これらの調査結果より，アイヌ語-日本語間機械翻訳システムの精度は対訳コーパスのサイズや出現単語における低頻度語の割合に単純に依存するのではなく，個々の低頻度語に着目した際にその単語を含む文数と対訳コーパス中の文数に基づく *idf* 値に依存することが明らかになった．

４．おわりに

本稿では低資源言語であるアイヌ語を対象とした，Transformer を用いたアイヌ語-日本語間機械翻訳システムにおいて対訳コーパスと翻訳精度の関係について翻訳実験に基づき述べた．その結果，対訳コーパス中の文数に対する低頻度語を含む文数の割合の逆数である *idf* 値に依存することが明らかとなった．

今後は，このような結果が他言語においても同様なのかについて調査を行う．また，低頻度語の *idf* 値を下げるためのデータ・オーギュメンテーションに取り組むことで，翻訳精度の向上を図る予定である．

謝辞

本研究の一部は一般社団法人アイヌ文化学術研究会との共同研究により行われた．

参考文献

[1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, Attention Is All You Need, Proceedings of the 31st Conference on Neural Information Processing Systems, pp.6000-6010, 2017.
[2] D. Bahdanau, K. Cho, and Y. Bengio, Neural Machine Translation by Jointly Learning to Align and Translate, Proceedings of 3rd International Conference on Learning Representations, 2015.
[3] https://ainu.ninjal.ac.jp/folklore/corpus/jp/
[4] https://www.ff-ainu.or.jp/web/learn/language/animation/index.html
[5] https://www.aozora.gr.jp/cards/001529/card44909.html
[6] https://ainu.ninjal.ac.jp/topic/dictionary/jp/
[7] https://ainugo.aa-ken.jp/
[8] https://ainugo.nam.go.jp/
[9] K. Papineni, S. Roukos, T. Ward, and Wei-Jing Zhu, BLEU: a Method for Automatic Evaluation of Machine Translation, Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, pp.311-318, 2002.

Confidential