原著論文

対話文脈付き駄洒落データベース構築のための駄洒落を含む対話の面白さの評価及び分析†

花房　竜馬*1・荒木　健治*2

現在，スマートフォンやスマートスピーカーの普及によって人と対話エージェントとの対話は日常的に行われている．しかし，これらのデバイスに搭載されている対話エージェントは雑談システムとしての能力が不十分であり，人同士の対話と同等の面白さを感じることはできない．この問題を解決するためには，対話中の文脈情報を考慮した高度なユーモア処理を実現する必要がある．これまでの研究において，対話中の文脈情報を含むユーモアの面白さや文脈情報が面白さに与える影響については明らかにされていない．本論文では対話文脈を考慮した駄洒落の面白さを評価する標準データベースを構築するために，駄洒落を含む対話を収集し，12,000 件の駄洒落が含まれる対話に対して対話の面白さを複数人で評価した．それに加えて，対話文脈による駄洒落の面白さの変化について分析を行った．

キーワード：駄洒落，対話文脈，面白さの評価，データベース構築

1．はじめに

近年，日本では新型コロナウイルス感染症の蔓延による生活様式の大きな変化に伴い，精神的ストレスを感じる人が急増している [1]．それに加えて，少子高齢化及び晩婚化の影響により，高齢者単身世帯も急増している．これらの社会的問題に対処するために，新たな生活様式に沿った孤独や不安を緩和するためのメンタルケアの確立が必要となる．

不安や孤独を緩和するためのメンタルケアとして，友人や家族との対話によって面白さや楽しさを感じることが挙げられる．対話中に生じる笑いに精神的ストレスを解消する効果があることは医学的に実証されている．しかし，対話相手の心理状態によっては笑いを生むことが困難なことも少なくない．これらのことから，精神的ストレスを緩和するための対話相手を担う存在として，対話によって面白さや楽しさを与える対話システムの実現が緊急の課題となっている．

このような背景のもと，現在スマートフォンやスマートスピーカーの普及によって，人と対話エージェントとの対話が日常的に行われている．これらのデバイスに搭載された対話エージェントは対話によって何らかのタスクを実行することを目的としたタスク指向型対話システムである．そのため，対話によって面白さや楽しさを与えることができない．この点を踏まえ，対話による面白さや楽しさを目的とした非タスク指向型システム（雑談システム）の研究が行われている [2, 3]．しかし，これらの研究では人間同士の対話と同等以上の面白さや楽しさを与えるというレベルに達していない．

この問題を解決するためには，人間と同等の応答精度に加えて，対話中の文脈情報からユーモア表現を理解して笑い，適切なタイミングで対話相手を飽きさせないようにユーモアを発話するといった高度なユーモア処理が必要となる．

これまでのユーモアに関する研究として，はじめになぞなぞの答えを駄洒落として生成するキムらの研究 [4] がある．キムらは手作業で小規模な辞書を作成し，駄洒落を自動生成する実験を行った．その結果，システムの性能は使用する辞書に大きく依存することが確認された．

次に，画像からユーモア表現を含む発話を自動生成する二又らの研究 [5] がある．二又らは対話システムにおける対話継続欲求を向上させるために，画像からユーモアを生成する手法を対話システムに導入した．結果として，ユーモアを生成することで対話が途切れた場合でも対話を継続したいという欲求が向上することを確認している．

しかし，これらの研究において，実験に使用されたユーモアは少数となっている．これは一般的なユーモアの性質を議論することが困難であることを意味する．

荒木らはユーモアに関する研究について，文献 [6–9] などで数多く行っている．文献 [6] では駄洒落の自動生成手法，文献 [7, 8] では対話システムと駄洒落生成システムを組み合わせたシステム，文献 [9] では子音の音韻類似性及び SVM を用いた駄洒落検出手法をそれぞれ提案している．しかし，これらの研究では面白さの評価を行うための大規模なデータセットが存在せず，他の手法との比較を正確に行うことができないという問題があった．

この点を踏まえ，荒木らは 67,000 件の駄洒落を収録した大規模なデータベースの構築 [10, 11] を行った．駄洒落の面白さを評価するための手法を確立するために，複数人による駄洒落の面白さの評価及び分析 [12] も行った．

これらの研究において，文脈情報は 1 文内の文内文脈に限定されている．そのため，対話中の文脈情報がユーモアの面白

---

† Evaluation and Analysis of Fun of Dialogue Contained Puns for Construction of Pun Database with Dialogue Context

Ryoma HANABUSA and Kenji ARAKI

*1 北海道大学 大学院情報科学院
Graduate School of Information Science and Technology, Hokkaido University

*2 北海道大学 大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University

さにどのような影響を及ぼすかについて，分析はなされていない．対話文脈を含む駄洒落の面白さを評価するための手法の確立は，雑談システム上に高度なユーモア処理を実現するために必須のものである．

本論文では，対話文脈を考慮した駄洒落の面白さを評価する標準データベースを構築するために，駄洒落を含む対話の収集を行った．その後，収集した対話に対して，複数人によって対話の面白さを評価し，対話文脈によって駄洒落の面白さがどのように変化するのかについて分析を行った．

本論文の構成は次のようになっている．2 章では駄洒落を含む対話の構成と収集について述べる．3 章では 2 章で収集した駄洒落を含む対話に対して複数名による面白さの評価を行った結果と分析について述べる．4 章では対話文脈による駄洒落の面白さの変化について分析した結果及び考察について述べる．5 章では結論及び今後の課題について述べる．

2. 駄洒落を含む対話の収集

2 章では，駄洒落を含む対話の構成，収集方法及び収集結果について述べる．

2.1 駄洒落を含む対話の構成

本論文では対話文脈が及ぼす駄洒落の面白さへの影響についての分析を行う．しかし，これまでに行われた駄洒落の研究において，対話文脈を含む駄洒落を対象としたデータベースは構築されていない．このことから，対話文脈を含む駄洒落の面白さの指標となるデータベースを構築するために，駄洒落を含む対話の文章を収集する．

現在 Web 上で公開されている人同士の雑談対話を収録したコーパスとして，日本語日常会話コーパス [13] や名大会話コーパス [14] が挙げられる．しかし，これらのコーパスは一般的な会話文章を収録しているため，コーパス中に含まれる駄洒落は非常に少ないと考えられる．このことから，既存のコーパスから駄洒落を含む対話を大量に収集することは困難である．

ユーザ同士の対話が Web 上で公開されたソーシャル・ネットワーキング・サービス（SNS）として，Twitter[1] が挙げられる．Twitter は日本国内において，2021 年時点で約 5,310 万人に利用されており，多種多様な話題のもとユーザ同士の対話及び会話が行われている．そのため，既存のコーパスと比べて，Twitter には駄洒落を含む対話が比較的多いと考えられる．

これらのことから，本論文では駄洒落を含む対話を大量に収集するための手段として，Twitter を利用する．

図 1 に示すように，一般的に Twitter 上の駄洒落を含む対話の構成は以下の 3 種類の分類が考えられる．

①最初に駄洒落を含むツイートが出現する対話
②中間に駄洒落を含むツイートが出現する対話
③最後に駄洒落を含むツイートが出現する対話

駄洒落を含む対話の面白さは駄洒落を含むツイートの前後のツイートによって変化すると考えられる．また，駄洒落を含むツイートから前後 5 件以上のツイートは駄洒落とは関連性のない話題が進行すると考えられる．これらのことから，駄洒落を含む対話の範囲は駄洒落を含むツイートを基準とした前後それぞれ 0 から 5 つのツイートとする．

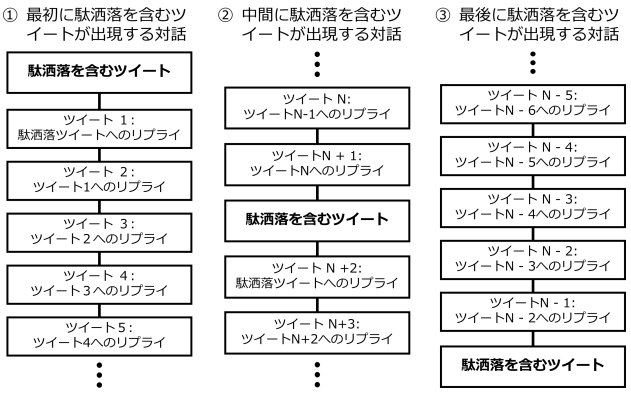


図 1　Twitter 上の駄洒落を含む対話の構成

本論文において，駄洒落を含むツイートの前後のツイートの数が 0 となるものは駄洒落を含むツイート単体とする．

2.2 収集方法

駄洒落を含む対話を収集するために，10,000 件の駄洒落を用いて，Twitter 上で完全一致検索を行い，検索結果をクローリングする．ここで，駄洒落を含む対話の範囲の基準となるツイートは完全一致検索に用いた駄洒落を含むツイートとする．そのため，対話中に複数の駄洒落が存在する場合についても，対話の範囲の基準となるツイートは検索対象の駄洒落によって一意に定まる．

完全一致検索には駄洒落データベース[2]に収録されている番号 1〜10,000 の駄洒落を使用する．

駄洒落データベースは 67,000 件の駄洒落が収録された大規模なデータベースであり，Web サイト[2]上で一般公開されている．収録された駄洒落には面白さの度合いを 5 段階で示す面白さのスコアが付与されている．駄洒落データベースにおける面白さのスコアの評価はクラウドソーシングによって雇用した 3 名の評価者によって行われている．

クローリングには Twitter から提供されている学術研究向け API である Twitter API for Academic Research[3] を使用する．本論文では駄洒落を含む対話の内容とその対話中のツイートごとに含まれるユーザ情報，いいね，リツイートの数を収集する．

2.3 収集結果

表 1 に収集結果の件数及び割合を示す．本論文における対話は「2 者による言葉の掛け合い」，会話は「3 者以上による言葉の掛け合い」と定義する．表 1 に示すように，駄洒落を含む対話は 26,739 件となった．また，駄洒落を含むツイート単体の件数は 341,902 件となった．このことから，Twitter 上で行われる駄洒落を含む対話は駄洒落を含むツイート単体よりも比較的少ないことが確認された．

1　https://twitter.com

2　http://arakilab.media.eng.hokudai.ac.jp/~araki/dajare.htm

3　https://developer.twitter.com/ja/products/twitter-api/academic-research

表 1　収集結果の件数及び割合

	件数	割合[%]
駄洒落を含む対話	26,739	5.7
駄洒落を含む会話	81,454	17.2
1者による連続発話	1,758	0.4
画像が含まれる対話	20,300	4.3
引用リツイートが含まれる対話	555	0.1
駄洒落を含むツイート単体	341,902	72.3
総計	472,708	100.00

収集されたものには駄洒落を含む会話が 81,454 件（17.2%），1 者による連続発話が 1,758 件（0.4%），が含まれている．

また，引用リツイート及び画像が含まれる対話は 20,855 件（4.4%）となった．これらの Twitter 特有の表現を含む対話は一般的な駄洒落を含む対話とは異なる文脈を持つと考えられる．

完全一致検索に用いた駄洒落 10,000 件のうち，収集された駄洒落は 1,147 件（11.5%）となった．

3. 駄洒落を含む対話の面白さの評価

3 章では，駄洒落を含む対話の面白さの評価方法及び評価結果の分析について述べる．

3.1 評価方法

対話文脈による駄洒落の面白さの変化を分析するためには，駄洒落単体の面白さの指標と駄洒落を含む対話の面白さの指標が必要となる．駄洒落単体の面白さの指標としては駄洒落データベースの駄洒落に付与された評価者 3 名分の面白さのスコアがある．しかし，対話文脈を含む駄洒落の面白さの指標は存在しない．このことから，収集した駄洒落を含む対話に対して，クラウドソーシングを用いて雇用した評価者に面白さの評価を行っていただいた．

2.3 節で述べたように Twitter 特有の表現である引用リツイートや画像を含む対話は一般的な駄洒落を含む対話とは異なる文脈を持つ．このことから，評価対象は駄洒落を含む対話 26,739 件から無作為に抽出した 12,000 件とする．

12,000 件の駄洒落を含む対話に対して，クラウドソーシングで雇用した 16 名の評価者に各自 1,000～3,000 件の対話の面白さを評価していただいた．各評価者には雇用前に 1,000 件単位の作業希望件数と評価者の年代，性別，経歴について聴取した．

駄洒落データベース内の駄洒落に付与されている駄洒落単体の面白さとの比較を行うために，駄洒落を含む対話 1 件に対しても 3 名の評価者による対話の面白さの評価を付与する．駄洒落を含む対話の面白さの評価には 200 件あたり 1 時間前後が必要である．そのため，12,000 件の作業には膨大な時間的コストがかかる．それに加えて，駄洒落単体の面白さの評価 [12] において，膨大な量の駄洒落を評価すると駄洒落に対する飽きが生じ，面白さが低く評価されることも確認されている．これらのことから，12,000 件の駄洒落を含む対話を 1,000 件単位で分割した．次に，評価者の作業希望件数に応じて 3 名による評価が付与されるように評価者を割り当てた．1,000 件単位の対話に対する評価者の割り当ては評価者の雇用順に沿って行った．

表 2　評価者の属性及び評価番号

作業者名	年代	性別	経歴	評価番号
評価者1	30代前半	女性	自営業	1~3,000
評価者2	30代前半	女性	その他職種	1~3,000
評価者3	30代前半	男性	営業職	1~3,000
評価者4	50代前半	女性	請負	3,001~4,000
評価者5	30代後半	女性	専業主婦	4,001~6,000
評価者6	30代前半	女性	薬剤師	3,001~6,000
評価者7	30代後半	男性	事務職	3,001~6,000
評価者8	50代後半	女性	プログラマ	6,001~9,000
評価者9	20代後半	女性	事務職	6,001~9,000
評価者10	30代前半	男性	その他職種	6,001~9,000
評価者11	40代前半	女性	専業主婦	9,001~11,000
評価者12	40代後半	女性	旅行業	11,001~12,000
評価者13	20代後半	男性	その他職種	9,001~12,000
評価者14	30代前半	女性	事務職	9,001~10,000
評価者15	20代後半	女性	学生	10,001~11,000
評価者16	40代前半	女性	専業主婦	11,001~12,000

◆対話番号:	8030
◆ID:	378933
◆対話に含まれる駄洒落: **敗者**は**歯医者**	
~~	~~~~
U1:	虫歯稀なら滅多に蝕まれないよ
U2:	今虫歯に蝕まれてるっぽくて厳しい
U1:	**敗者**は**歯医者**にかかるしかねえな
U2:	敗者なのでオイオイ泣いてる
~~	~~~~
☆対話の面白さの評価:	4
----	----

図 2　駄洒落を含む対話の面白さの評価の例

表 3　面白さのスコア

スコア	説明
5	とても面白い
4	面白い
3	普通
2	面白くない
1	非常に面白くない （駄洒落ではないと思うものを含む）

表 2 に評価者の属性及び評価を実施した評価番号を示す．クラウドソーシングの Web サイト上には業務の依頼者から作業者に対して返信速度・納品実績などを 5 段階で評価した数値が与えられている．今回の評価者は全員評価値が 5.0 であるため，一定レベルの能力を満たしているものと考えられる．

図 2，表 3 に駄洒落を含む対話の面白さの評価の例と 5 段階の面白さの度合いのスコアを示す．図 2 における対話番号は 1～12,000 件の駄洒落を含む対話の番号を示す．ID は収集した駄洒落を含む対話及び駄洒落を含むツイート単体に付与された番号である．この ID を用いて駄洒落を含む対話及びツイート単体に付与されたいいねの数，リツイートの数などを参照できる．

U1，U2 はそれぞれ対話中の話者を示す記号である．対話の

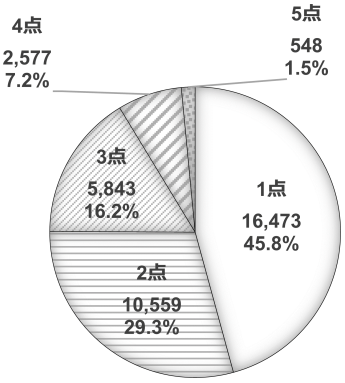


図３　評価者全員のスコアの分布

面白さの評価は評価者によって表 3 に示す面白さのスコアが付与される．面白さのスコアは面白さの度合いを示す 1 ～ 5 の整数値である．

各評価者に対して，図 2 に示すように対話に含まれる駄洒落と U1，U2 の 2 者による対話文章を提示し，可能な限り直感的に面白さを評価していただいた．

3.2　評価結果の分析

3.1 節で述べた方法に基づいて行った 12,000 件の駄洒落を含む対話に対する面白さの評価の結果を分析する．

図 3 に評価者全員のスコアの分布を示す．ここで，3.1 節で述べたように駄洒落を含む対話 1 件に対して 3 名分の評価が付与されているため，全体の件数は 36,000 件となる．図 3 に示すように 1 点から 3 点が全体の 91.3% を占めている．一方，4 点は 7.2%，5 点は 1.5% と極端に少ない結果となった．そのため，評価者全員のスコアの平均は 1.89 ポイントとなった．

1 点から 3 点の割合が 91.3% と比較的多い要因として，Twitter 上の対話には第三者から面白さを評価される前提がないことが挙げられる．Twitter における対話はユーザ同士のコミュニケーションとして行われる．そのため，一般的なユーザは第三者から面白いと感じられるような対話をするという意図がない．Twitter 上の対話における駄洒落もユーザ同士の親睦を深める用途で用いられることが多い．これらのことから，駄洒落を含む対話に対して第三者が対話の面白さを評価した場合，面白くないまたは普通と感じるものが比較的多いと考えられる．

3.2.1　評価者間の一致度

駄洒落を含む対話における人の感じる面白さの異なりについて，評価者間の面白さのスコアの一致度を用いて分析する．一致度を評価するための指標として，コーエンの重み付き κ 係数を用いる．ここで，分析する一致度は駄洒落を含む対話に対して 5 段階の面白さの度合いを付与するという順序尺度に基づいた評価に対する一致度である．

3.1 節で述べたように，駄洒落を含む対話の面白さの評価は駄洒落を含む対話 1 件につき 3 名分の評価が付与されるように 12,000 件を 1,000～3,000 件に分割し，評価者 16 名に対して対話のデータを割り当てた．この点を踏まえ，12,000 件の面白さのスコアに対する一致度を算出するために，まず 1,000 件ごとの 2 者間の一致度を算出する．ここで，評価者の組み合わせは 3 通りであるため，1,000 件ごとに 3 つの一致度が算出される．その後，36 個の一致度の平均を面白さの評価における全体の一致度として算出する．

表４　評価者間の一致数と割合

	件数	割合[%]
3名一致	2,956	24.6
2名一致	6,709	55.9
3名不一致	2,335	19.5

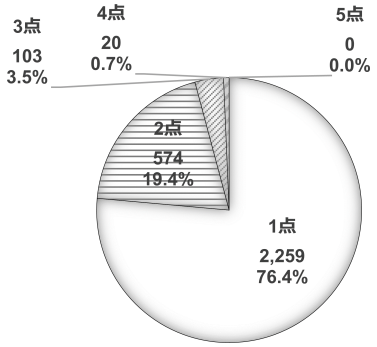


図４　評価者 3 名のスコアが全て一致したものの分布

12,000 件の駄洒落を含む対話の面白さの評価に対する一致度は 0.29 となり，おおむね一致という結果となった．

駄洒落単体の面白さの評価 [12] における評価者間の一致度は 0.10 以下となっている．このことから，駄洒落を含む対話の面白さの評価は駄洒落単体の評価に比べて比較的評価者間で一致する割合が高い結果となった．

3.2.2　評価者間の一致数と割合

駄洒落を含む対話における人の感じる面白さの異なりについて，評価者間の一致数と割合を用いて考察する．

表 4 に評価者間の一致数と割合を示す．表 4 に示すように，評価者 3 名のスコアが一致した件数は 2,956 件（24.6%），2 名で一致した件数は 6,709 件（55.9%）となった．これらのことから，文章に 5 段階の面白さの度合いを付与するような全く主観的な評価においても，比較的一致したものが多いと考えられる．一方，評価者 3 名が全て異なるスコアを付与した件数は 2,335 件（19.5%）となった．これは評価者 3 名が一致した件数と同程度の件数であり，それぞれ全く異なる評価を付与した件数が少ないことを示していると考えられる．

図 4 に評価者 3 名のスコアが全て一致したものの分布を示す．図 4 に示すように，評価者 3 名でスコアが一致した 2,956 件のうち，スコア 1 点及び 2 点で一致した件数が 2,833 件（95.8%）と最も多い結果となった．また，3 点以上で一致した件数は 123 件（4.2%）となった．1 点及び 2 点の一致件数が最も多い要因として，普通以上の面白さに比べて，評価者全員の面白くないと感じる感性は比較的一致することが考えられる．

図 5 に評価者 3 名のスコアが異なったもののスコアの組み合わせを示す．図 5 に示すように，1 点，2 点，3 点の組み合わせは 1,010 件と最も多く，3 点，4 点，5 点の組み合わせは 32 件

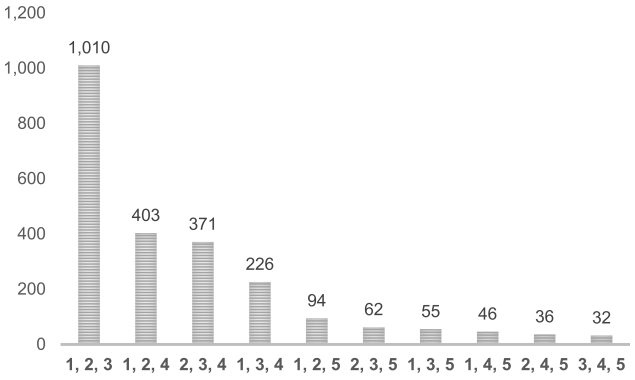


図５ 評価者 3 名のスコアが全て異なったもののスコアの組み合わせ

と最も少ない．これらは 3.2 節で述べたように評価者全員のスコアの分布において，1 点，2 点及び 3 点が 91.3% を占めていることが要因として考えられる．

次に多い組み合わせは 1 点，2 点，4 点で 403 件となった．この組み合わせは評価者間で最大 3 点の差があり，4 点の面白い，1 点の非常に面白くないで意見が分かれている．このように評価者間で面白い，面白くないで意見が分かれたものは 1,293 件確認された．

4. 対話文脈による面白さの変化

4 章では，対話文脈による駄洒落の面白さの変化について分析及び考察した結果を述べる．

4.1 面白さの変化量

対話文脈によって駄洒落の面白さがどの程度変化するかについて分析する．ここで，対話文脈による駄洒落の面白さの変化の度合いを示す指標として，面白さの変化量を定義する．面白さの変化量は 3.2 節で述べた駄洒落を含む対話の面白さの指標から文献 [12] における駄洒落単体の面白さの指標を減算したスコアとする．

対話番号に対応する駄洒落を含む対話の面白さを CP_n，対話に含まれた駄洒落単体の面白さを P_n として，式 (1) に面白さの変化量 HD_n の算出式を示す．

$$HD_n = \frac{1}{a}\sum_{i=1}^{a} CP_{n,i} - \frac{1}{b}\sum_{j=1}^{b} P_{n,j} \tag{1}$$

式 (1) における n は 1 から 12,000 の駄洒落を含む対話の番号である．a，b はそれぞれ対話及び駄洒落単体に付与された面白さのスコアの数であり，どちらも 3 名分の評価が付与されているため，$a = b = 3$ となる．

式 (1) に示すように，面白さの変化量は駄洒落を含む対話における評価者 3 名分の平均スコアから対話に含まれている駄洒落単体における 3 名分の平均スコアを減算することで算出される．

また，駄洒落を含む対話 12,000 件中に複数の駄洒落が含まれるものが 971 件（8.1%）存在する．このような場合は対話の収集時に対象とした駄洒落のみを対話に含まれる駄洒落として，駄洒落単体のスコアを参照する．

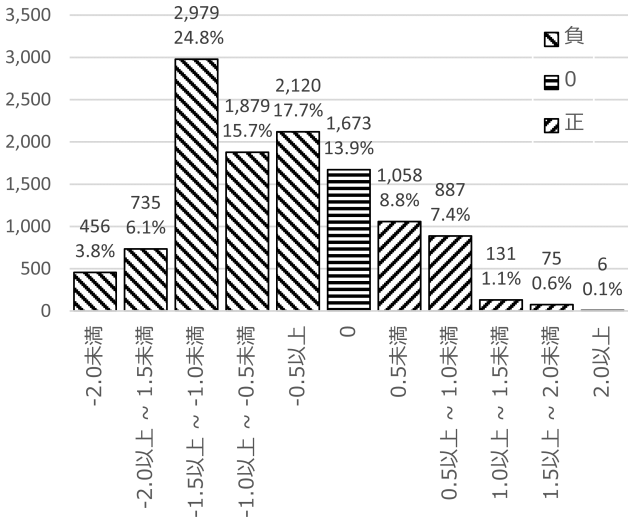


図６ 面白さの変化量の分布

これらのことから，12,000 件の駄洒落を含む対話に対して式 (1) により面白さの変化量を算出する．ここで，面白さの変化量が正の値となる場合は対話文脈によって駄洒落の面白さが増加したことを示す．また，面白さの変化量が負の値となる場合は対話文脈によって駄洒落の面白さが減少したことを示す．

図 6 に面白さの変化量の分布を示す．図 6 に示すように，対話文脈によって駄洒落の面白さが増加したものの件数は 2,157 件（18.0%），変化しなかったものは 1,673 件（13.9%）となった．また，面白さが減少した件数は 8,169 件（68.1%）と比較的多い結果となった．

Twitter ではユーザ同士で幅広いジャンルに関するコミュニティが形成されている．そのため，コミュニティ外のユーザからは文面上読み取ることができない前提知識や文脈が含まれている対話が多い．文脈を理解することができない対話に対して，評価者が面白いまたは非常に面白いと感じることは困難である．このことから，駄洒落の面白さが減少したものの割合が 68.1% と比較的高い要因は Twitter 上に第三者が理解できない文脈を持つ対話が多いことだと考えられる．

4.2 対話文脈における話者反応の分析

対話文脈によって駄洒落の面白さが変化する要因として，駄洒落に対する話者の反応が考えられる．このことから，話者反応に着目した対話文脈の分析を行う．

一般的に，駄洒落を含む発話に対する話者の反応は (a) 駄洒落に関連する表現や別の駄洒落を含む発話を返す，(b) 駄洒落を認識した旨を示す発話や駄洒落に関連性のない別の駄洒落を含む発話を返す，(c) 駄洒落を無視し，駄洒落とは無関係な話題に関する発話を返すことが挙げられる．

(a)，(b)，(c) を基に，4 種類の駄洒落に対する話者の反応を定義する．

表 5 に駄洒落に対する話者反応の定義と例を示す．表 5 の例における U1，U2 はそれぞれ対話中の話者を示す記号である．

表 5 において，第一に，高度なノリは駄洒落に対して関連性のある表現や駄洒落を返す発話によって展開される対話と定

表５ 話者反応の定義と例

種類	説明	例
高度なノリ	駄洒落に対して関連性のある表現またはその駄洒落に関連した別の駄洒落を返す発話によって展開する対話	U1: **モンブラン**に変な**もんぶらーん**※
		U2: 変なもんぶらーんしてたのでびっクリした訳ですね
		U1: これは一本取られてしまった(＾ω＾)＼
単純なノリ	駄洒落に対して関連性のない駄洒落または同じ駄洒落を返す発話や駄洒落を認識した旨を示す発話によって展開する対話	U1: **アルミ缶**の上にある**ミカン**※
		U2: **廊下**を走**ろうか**※
		U1: **布団**が**吹っ飛ん**だ※
無反応	駄洒落に対して関連性のない話題を返すような発話によって展開する対話	U1: **海藻**を**買いそう**w※
		U2: お誕生日おめでとうございます！
		U1: ありがとうございます！
その他	支離滅裂な対話，センシティブな内容を含む対話，文面上から文脈を理解することが困難な発話を含む対話	U1: **イラン**は**いらん**のころ？※
		U2: そうかあ。10才でこのくらい可愛くないとサエルみたくなれないのかあむむむ。

※：太字は駄洒落における種表現と変形表現

義する．表 5 の高度なノリの例では，U1 の駄洒落「モンブランに変なもんぶらーん」の発話に対して，U2 がモンブランにおける栗と関連性のある「びっクリ」という表現を用いて発話する．

第二に，単純なノリは駄洒落に対して関連性のない駄洒落または同じ駄洒落を返す発話や駄洒落を認識した旨を示す発話によって構成される対話と定義する．表 5 の単純なノリの例では，U1 の駄洒落「アルミ缶の上にあるミカン」の発話に対して，U2 がその駄洒落に関連のない「廊下を走ろうか」という駄洒落を発話する．それに対して，U1 も「布団が吹っ缶飛んだ」という駄洒落を発話する．

第三に，無反応は駄洒落に対して関連性のない話題を返すような発話によって展開する対話と定義する．表 5 の無反応の例では U1 の駄洒落「海藻を買いそう」の発話に対して，U2 が駄洒落とは無関係な発話をすることで，対話が進行している．

第四に，その他は支離滅裂な対話など，Twitter 上にのみ存在する話者の反応として定義する．表 5 のその他の例では U1 の「イランはいらんのころ？」という駄洒落の発話に対して，U2 は文面上から内容を理解することができない発話を行っている．

これらの定義をもとに，対話文脈によって駄洒落の面白さがどのように変化するのかを分析する．そのために，面白さの変化量が正の値となる対話上位 1,000 件を抽出し，面白さの変化量が −2.0 未満から −1.0 以下となる対話から 1,000 件を無作為に抽出する．その後，抽出した対話計 2,000 件に対して，高度なノリ，単純なノリ，無反応，その他の 4 種類の話者反応に分類し，面白さの変化量が正の値，負の値となる対話における話者反応の割合を分析する．

3 章の面白さの評価と同様に，話者反応についても人によって分類が異なる可能性がある．このことから，話者反応の分類におけるアノテーションは 5 名で行った．

表 6 に話者反応の分類におけるアノテータの属性を示す．各アノテータには表 5 に示した話者反応の定義と例について説明し，面白さの変化量が正の値，負の値となる対話の計 2,000 件に対する話者反応の分類を依頼した．

5 名による話者反応の分類結果について，駄洒落を含む対話に対して 4 種類の話者反応に分類するという名義尺度に基づいた一致度を評価する．一致度を評価するための指標として，フライスの κ 係数を用いる．その結果，5 名間の話者反応の分類における一致度は 0.22 となり，おおむね一致となった．

表６ アノテータ一覧

作業者名	年代	性別	経歴
アノテータA	20代後半	男性	工学系大学院生
アノテータB	20代後半	男性	工学系大学院生
アノテータC	20代前半	男性	工学系大学院生
アノテータD	50代前半	女性	その他職種
アノテータE	50代後半	男性	その他職種

・対話に含まれる駄洒落: **犬**が**いぬ**
・5名の分類結果: 高度なノリ: 2名, 単純なノリ: 3名
U1: **犬**が**いぬ**
U2: **駄洒落**を言うたんは**誰じゃ**
U1: **おらん**だ
U2: **今居ま**せんでした？
U1: **今いま**した
U2: (……勝てる気がしねぇ)

図７ アノテータで意見が分かれた対話の例

図 7 にアノテータ間で分類が分かれた対話の例を示す．図 7 における U1，U2 はそれぞれ対話中の話者を示す記号である．図 7 の例に対して，2 名が高度なノリ，3 名が単純なノリに分類している．高度なノリに分類した 2 名は U1 と U2 がそれぞれ発話した駄洒落に対して関連性のある別の駄洒落を返していると感じたことが考えられる．一方，単純なノリに分類した 3 名は U1 と U2 の駄洒落がそれぞれ関連性のない駄洒落を返していると感じたことが考えられる．このように，アノテータの駄洒落に対する関連性の感じ方によって意見が分かれたものが散見された．

本論文では，話者反応の分類で意見が異なるケースを考慮し，5 名のアノテータによる多数決で決定した話者反応を分析対象とする．ここで，最多投票となった話者反応が複数存在する場合は，アノテータ間で意見が完全に分かれたものとして，分析対象から除外する．

表 7 に話者反応の分析結果を示す．表 7 の左から面白さの

表 7　話者反応の分析結果

	面白さの変化量			
	負の値		正の値	
	件数	割合[%]	件数	割合[%]
高度なノリ	7	0.8	126	13.9
単純なノリ	94	10.2	486	53.7
無反応	480	52.3	193	21.3
その他	337	36.7	100	11.0

・対話に含まれる駄洒落: **糖分**は**当分**控えなさい
・駄洒落単体の面白さのスコア: 2.33
・駄洒落が含まれる対話の面白さのスコア: 4.33
・面白さの変化量: +2.00
U1: **糖分**は**当分**控えなさい
U2: **塩分**に関しては言**えん分**、糖分については言うんだ…
U1: 、、、

図 8　面白さが増加した対話の高度なノリの例

・対話に含まれる駄洒落: **ダジャレ**を言うのは**誰じゃ**
・駄洒落単体の面白さのスコア: 2.67
・駄洒落が含まれる対話の面白さスコア: 4.00
・面白さの変化量: +1.33
U1: **ダジャレ**を言うのは**誰じゃ**！！！
U2: **たいよう**が目にい**たいよう**！！！（?）
U1: **アルミカン**の上にある**ミカン**！！
U2: **ハゲ**を**はげ**ます！！！
U1: **おちゃ**が**おっちゃん**にかかった！！！！
U2: **イクラ**は**いくら**！！！！

図 9　面白さが増加した対話の単純なノリの例

変化量が負の値となる対話 918 件のうち，高度なノリは 7 件（0.8%），単純なノリは 94 件（10.2%），無反応及びその他は 817 件（89.0%）となった．また，表 7 の右から正の値となる対話 905 件のうち，高度なノリは 126 件（13.9%），単純なノリは 486 件（53.7%），無反応及びその他は 293 件（32.3%）となった．

これらの結果から，駄洒落の面白さを増加させる対話には話者反応における高度なノリ，単純なノリが 67.6% の割合で含まれていることが確認された．また，面白さを減少させる対話の 89.0% が無反応及びその他であることも確認された．

4.3　面白さが変化した対話の話者反応の考察

対話文脈により駄洒落の面白さが増加及び減少した対話における話者の反応について考察する．

4.3.1　面白さが増加した対話の話者反応

図 8，図 9 に面白さが増加した対話における高度なノリ及び単純なノリの例を示す．図 8，図 9 における U1，U2 はそれぞれ対話中の話者を示す記号である．また，図 8，図 9 における面白さの変化量はそれぞれ +2.00 ポイント，+1.33 ポイントとなっている．図 8 の例では，はじめに U1 が「糖分は当分控えなさい」という駄洒落を発話する．その後，U2 がその駄洒落に関連した別の駄洒落「塩分に関しては言えん分」を含む発話をしている．

また，図 9 の例では，はじめに U1 が「ダジャレを言うのは誰じゃ」という駄洒落を発話し，U2 がその駄洒落と関連性のない別の駄洒落「たいようが目にいたいよう」を発話する．それ以降の発話は U1，U2 が互いに発話された駄洒落に関連性のない駄洒落を発話している．

図 8，図 9 のような対話には駄洒落に関連する発話や，駄洒落をもとに別の駄洒落を返すといった話者同士の掛け合いが含まれている．こういった掛け合いは，お笑いの分野におけるノリと類似しており，駄洒落の面白さを引き立たせる．そのため，駄洒落単体に比べて対話全体をより面白くしていると考えられる．

面白さの変化量が正の値となる対話は負の値となる対話と比べて，高度なノリ，単純なノリの割合は 67.6% と比較的高い．これらのことから，高度なノリ，単純なノリのような対話文脈は駄洒落の面白さを増加させることが考えられる．

・対話に含まれる駄洒落: **しょーゆうこと**
・駄洒落単体の面白さのスコア: 1.33
・駄洒落が含まれる対話の面白さのスコア: 2.33
・面白さの変化量: +1.00
U1: え！おい！どゆこと！
U2: **しょーゆうこと**よ、笑笑
U1: ココはちょっとあれやから
　また話し聞かせて？
　てかなんで今日どしたんよー。
U2: みて！みて！みてひかる！
　ひかる！みて！
　ミードボール！！！！！！
　んー。体調悪かったってことにしといて
U1: 朝から笑うやんけ爆笑

図 10　面白さが増加した対話の無反応の例

図 10 に面白さが増加した対話における無反応の例を示す．図 10 においても対話中の話者を U1，U2 と表記する．また，面白さの変化量は +1.00 ポイントとなっている．図 10 の例では，U1 の発話に対して，U2 が駄洒落「しょーゆうことよ」などのユーモア表現を多用している．U1 は駄洒落に対して反応を示していないが，ユーモア表現を多用していることに反応を示している．

このように駄洒落を含む発話に対する反応がない場合でも対話自体の面白さによって面白さが増加したものが 32.3% の割合で存在した．

4.3.2　面白さが減少した対話の話者反応

図 11，図 12 に面白さが減少した対話における無反応及びその他の例を示す．図 11，図 12 においても対話中の話者を U1，U2 と表記する．また，面白さの変化量はそれぞれ −1.33 ポイント，−2.34 ポイントとなっている．

図 11 の例では U1 が U2 に対してタピオカを奢るという話題から駄洒落「勝手に買って」を含む発話を行っている．こ

・対話に含まれる駄洒落: **勝手**に**買って**
・駄洒落単体の面白さのスコア: 3.00
・駄洒落が含まれる対話の面白さのスコア: 1.67
・面白さの変化量: -1.33
U1: いや、もうタピオカ奢らせて下さい！！笑
U2: そっか！買いたいもの買えるといいねー！そちらも熱中症にはお気をつけて！
U2: いやいや、いいですよ！（笑）
U1: ポイントカード溜まってるし奢る、てか奢らせてください！！笑
U2: い、いらんですよ！
U1: いんや、**勝手**に**買って**押し付けるから！！笑
U2: うーん、でしたらありがたく頂きます...！すみません！
U1: いや、こちらこそごめんよ！！

図 11　面白さが減少した対話の無反応の例

・対話に含まれる駄洒落: **アラスカ**を**荒らすか**
・駄洒落単体の面白さのスコア: 3.67
・駄洒落が含まれる対話の面白さのスコア: 1.33
・面白さの変化量: -2.34
U1: Edition　Steamにて大好評発売中
U2: 私メリーさん。今駅にいるの
U1: Edition　Steamにて大好評発売中！！
U2: 私メリーさん。お前達に名乗る名はないッ！
U1: 金をくれないか？
U2: 私メリーさん。アラスカなう。**アラスカ**を**荒らすか**？なんちゃって
U1: 今どの時代だ？
U2: 私メリーさん。今、墓場にいるの・・・ゆ、幽霊なんてこ、怖くないもんっ！
U1: いいよ
U2: 私メリーさん。花子かと思った？私だよ！
U1: もっと町の人を作れ

図 12　面白さが減少した対話のその他の例

の対話において，U1 は駄洒落を意図して発話しておらず，発話内容が偶然駄洒落になっていた可能性がある．また，U2 も U1 の駄洒落に対して，反応を示していない．この要因として，U2 も U1 の発話内容が駄洒落であることを認識していないことが挙げられる．このような対話は話者同士が駄洒落をユーモア表現として認識していないため，駄洒落単体から面白さが 1.33 ポイント減少したと考えられる．

図 12 の例は対話内容及び文脈を第三者から理解することができない．この例における U2 は人工無能（Bot）である．Twitter における Bot はユーザの投稿またはリプライに対して，あらかじめ設定されたテキストをランダムに返す．そのため，対話全体が支離滅裂なものとなっている．このことから，駄洒落単体の面白さから 2.34 ポイント減少したと考えられる．

面白さの変化量が負の値となる対話のうち，89.0% が無反応，その他の話者反応を含んでいた．この割合は正の値となる対話における無反応及びその他の割合よりも 56.7% 高いものとなっている．これらのことから，無反応，その他のような対話文脈は駄洒落の面白さを減少させることが考えられる．

・対話中に含まれる駄洒落: **露骨**な**肋骨**
・駄洒落単体の面白さスコア: 3.00
・駄洒落を含む対話の面白さスコア: 1.33
・面白さの変化量: -1.67
U1: 秋葉原のゲーセンのグッズ、ほとんど鬼滅の刃にするのやめてほしい。これじゃオタクの街じゃなくて鬼滅の街だし、大人の全力な商法が**露骨**な**肋骨**で笑っちゃう。あ、SEGA2号店、電気街Laviに続き、アドワーズも今月閉店。。誰か秋葉原を復興せよ。。
U2: **憎き肉**片的な感じってことね。了解
U1: もはや使命感を背負いゲーセンを徘徊してますからね、私。

図 13　面白さが減少した対話の高度なノリの例

図 13 に面白さが減少した対話における高度なノリの例を示す．図 13 においても対話中の話者を U1，U2 と表記する．また，面白さの変化量は –1.67 ポイントとなっている．図 13 の例では，U1 の「露骨な肋骨」という駄洒落を含む発話に対して，U2 が駄洒落「憎き肉片」という駄洒落を返すことで対話が進行している．これらの駄洒落はジョジョの奇妙な冒険というアニメに登場する技名であり，技名自体が駄洒落となっている．そのため，U1 の駄洒落に対して，U2 はその駄洒落に関連した別の駄洒落を返していると考えられる．図 13 のような対話には 4.1 節で述べたようにコミュニティ外の人が文面上理解することができない前提知識が含まれている．

このように高度なノリを持つ対話でも文脈を理解するために前提知識が必要となる場合は，面白さが減少することが考えられる．

5. おわりに

これまで行われてきたユーモアに関する研究において，背景知識や文脈情報がユーモアにどのような影響を及ぼすかについての分析はなされていない．このことから，本論文では対話の文脈によるユーモアの面白さへの影響を分析するために，Twitter 上に存在する 26,739 件の駄洒落を含む対話を収集した．

収集したもののうち，駄洒落を含む対話 12,000 件に対して対話の面白さの評価を行った．ここで，評価にかかる時間的コストの高さと評価者の駄洒落を含む対話に対する飽きを考慮し，クラウドソーシングを用いて 16 名の評価者を雇用した．評価者 16 名には 1 件の対話に対して，3 名の評価が付与されるように 1,000～3,000 件の作業を割り当てた．評価の結果として，第一に評価者 16 名のスコアの 91.3% は 1 点，2 点及び 3 点であることが確認された．この要因として，Twitter 上の対話には第三者から面白さを評価される前提がないことが考えられる．第二に，人によって異なる面白さの度合いについて分析を行った．評価者間の一致度をコーエンの重み付き κ 係数を用いて算出した結果，κ 係数 0.29 となり，おおむね一致していることが確認された．それに加えて，評価者組間の一致数と割

合についても分析を行った．その結果，2 者一致しているものが約 5 割，3 者一致しているものが約 2 割，3 者一致していないものが約 2 割であることが確認された．次に，面白さに影響を及ぼす対話文脈がどのような特徴を持つかについて，駄洒落に対する話者の反応に着目した分析を行った．ここで，一般的な駄洒落に対する話者の反応をもとに，高度なノリ，単純なノリ，無反応，その他の 4 種類の話者反応を定義した．これらの定義をもとに，面白さが増加及び減少した対話 2,000 件に対して話者反応の分類を複数人で行い，多数決によって定めた話者反応の割合を分析した．ここで，アノテータ間で完全に意見が分かれたものを分析対象から除外した．その結果，面白さが増加した対話 905 件のうち，67.6% が高度なノリ，単純なノリの話者反応を含む対話となった．このことから，駄洒落を含む発話に対して，関連性のある表現または駄洒落を返すような対話文脈は駄洒落の面白さを増加させることが考えられる．また，面白さが減少した対話 918 件のうち，89.0% は無反応，その他の話者反応を含む対話となった．このことから，対話中の駄洒落に対して反応がないまたは対話内容の解釈が困難な対話文脈は駄洒落の面白さを減少させることが考えられる．

今後の課題として，はじめに駄洒落データベース中の 10,001 番以降の駄洒落を用いた駄洒落を含む対話の追加収集を行うことが挙げられる．次に，第三者から面白いと感じられる対話をより多く収集するために，駄洒落が好きな人に駄洒落を含む対話を作成していただくことが挙げられる．これにより，第三者に面白さを与える意図がある対話の収集を行った上で，これらの対話をもとに，対話文脈を含む駄洒落の面白さを評価する標準データベースを構築する．

謝辞

本研究は JSPS 科研費 21K12007 の助成を受けたものである．

参 考 文 献

[1] 厚生労働省: “新型コロナウイルス感染症に係るメンタルヘルスに関する調査結果の概要について,” https://www.mhlw.go.jp/stf/newpage_15766.html [accessed Aug. 1, 2020]

[2] R. Rzepka, S. Higuchi, M. Ptaszynski, P. Dybala, and K. Araki: “When Your Users Are Not Serious,” 人工知能学会論文誌, Vol.25, No.1, pp. 114-121, 2010.

[3] A. Jordan and K. Araki: “Real-Time Language-Independent Algorithm for Dialogue Agents,” 知能と情報, Vol.28, No.1, pp. 535-555, 2016.

[4] キム・ビンステッド, 滝澤修: “日本語駄洒落なぞなぞ生成システム“BOKE”,” 人工知能学会誌, Vol.13, No.6, pp. 920-927, 1998.

[5] 二又航介, 藤倉将平, 菊池英明: “対話システムにおける画像からのユーモア発話の自動生成とそれによる対話継続欲求の向上,” 言語処理学会第 24 回年次大会発表論文集, pp. 520-523, 2018.

[6] J. Sjöbergh and K. Araki: “Robots Make Things Funnier, New Frontiers in Artificial Intelligence,” *Lecture Notes in Artificial Intelligence: The 22nd Annual Conf. of the Japanese Society for Artificial Intelligence Proc.*, pp. 306-313, 2009.

[7] P. Dybala, R. Rzepka, and K. Araki: “Humor Prevails! – Implementing a Joke Generator into a Conversational System,” *Lecture Notes in Artificial Intelligence: 21st Australasian Joint Conf. on Artificial Intelligence Proc.*, pp. 214-225, 2008.

[8] 谷津元樹, 荒木健治: “話題遷移に適応した駄洒落ユーモア統合型対話システムの性能評価,” 人工知能学会第 2 種研究会ことば工学研究会資料, pp. 23-27, 2016.

[9] 谷津元樹, 荒木健治: “子音の音韻類似性及び SVM を用いた駄洒落検出手法,” 知能と情報, Vol.28, No.5, pp. 875-886, 2016.

[10] 荒木健治, 内田ゆず, 佐山公一, 谷津元樹: “駄洒落データベースの構築及び分析,” 人工知能学会第 2 種研究会ことば工学研究会資料, pp. 13-24, 2017.

[11] 荒木健治, 佐山公一, 内田ゆず, 谷津元樹: “駄洒落データベースの拡張及び分析,” 人工知能学会第 2 種研究会ことば工学研究会資料, pp. 1-15, 2018.

[12] 荒木健治, 内田ゆず, 佐山公一, 谷津元樹: “駄洒落データベースを用いた面白さの評価及び分析,” 人工知能学会第 2 種研究会ことば工学研究会資料, pp. 63-76, 2019.

[13] I. Fujimura, S. Chiba, and M. Ohso: “Lexical and Grammatical Features of Spoken and Written Japanese in Contrast: Exploring a lexical profiling approach to comparing spoken and written corpora,” *Proc. of the 7th GSCP Int. Conf.: Speech and Corpora*, pp. 393-398, 2012.

[14] H. Koiso, H. Amatani, Y. Den, Y. Iseki, Y. Ishimoto, W. Kashino, Y. Kawabata, K. Nishikawa, Y. Tanaka, Y. Usuda, and Y. Watanabe: “Design and Evaluation of the Corpus of Everyday Japanese Conversation,” *Proc. of the 13th Language Resources and Evaluation Conf.*, pp. 5587-5594, 2022.

（2022 年 12 月 2 日　受付）
（2023 年 4 月 24 日　採録）

［問い合わせ先］
〒060-0814　北海道札幌市北区北 14 条西 9 丁目
北海道大学 大学院情報科学院 言語メディア学研究室
花房　竜馬
TEL: 011-706-7389
FAX: 011-709-6277
E-mail: hanabusa@ist.hokudai.ac.jp

著 者 紹 介



花房（はなぶさ）　竜馬（りょうま）［非会員］

2018 年旭川工業高等専門学校システム制御情報工学科卒業．2020 年同工業高等専門学校専攻科生産システム工学専攻修了．2022 年北海道大学大学院情報科学院修士課程修了．現在同大学大学院情報科学院博士課程在学中．自然言語処理，特に自然言語処理を用いた精神治療の支援，ユーモア処理の研究に従事．



荒木（あらき）　健治（けんじ）［正会員］

1982 年北海道大学工学部電子工学科卒業．1988 年同大学大学院博士課程修了．工学博士．同年，北海学園大学工学部電子情報工学科助手．1989 年同講師．1991 年同助教授．1998 年同教授．1998 年北海道大学大学院工学研究科電子情報工学専攻助教授．2003 年同教授．現在北海道大学大学院情報科学研究院メディアネットワーク部門特任教授．自然言語処理，特に，音声対話処理，機械翻訳，ユーモア処理などの研究に従事．日本知能情報ファジィ学会，電子情報通信学会，情報処理学会，人工知能学会，言語処理学会，日本認知科学会，ACL，IEEE，AAAI 各会員．

Evaluation and Analysis of Fun of Dialogue Contained Puns for Construction of Pun Database with Dialogue Context

by

Ryoma HANABUSA and Kenji ARAKI

Abstract:

There are more opportunities to interact with dialogue agents by the spread of smartphones and smart speakers. However, the dialogue agents in these devices lack the ability to entertain people. Dialogues with these agents are not as enjoyable as talking with a close friend. In order for dialogue agents to provide enjoyment to people, the system needs to recognize and generate humor from the context of the dialogue. At the moment, it is not clear whether humor that includes contextual information during dialogue is funny or how contextual information affects the funny. Therefore, to construct a standard database for evaluating the fun of puns considering the dialogue context, we collected dialogues containing puns on Twitter. Using the collected dialogues, multiple people evaluated the fun. Moreover, we analyzed the characteristics of a dialogue context that affects the fun of puns.

Keywords: pun, dialogue context, evaluation of fun, construction of database

Contact Address: **Ryoma HANABUSA**
Language Media Laboratory, Graduate School of Information Science and Technology, Hokkaido University
Nishi 9, Kita 14, Kita-ku, Sapporo, Hokkaido 060-0814, Japan
TEL: +81-11-706-7389
FAX: +81-11-706-6277
E-mail: hanabusa@ist.hokudai.ac.jp