一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report
NLC2023-3(2023-09)

国会および地方議会会議録をコーパスとした事前学習済み言語モデルの構築と検証

永渕　景祐†　佐藤　栄作††　木村　泰知††　門脇　一真†††　荒木　健治†

† 北海道大学
〒060-0814 北海道札幌市北区北 14 条西 9 丁目
†† 小樽商科大学
〒047-0034 北海道小樽市緑 3 丁目 5 番 21 号
††† 株式会社日本総合研究所
〒141-0022 東京都品川区東五反田 2 丁目 18 番 1 号
E-mail: †{nagafuchi,araki}@ist.hokudai.ac.jp,
††{g2020149@edu,kimura@res}.otaru-uc.ac.jp, †††kadowaki.kazuma@jri.co.jp

あらまし　近年，Web から収集されたデータである Common Crawl に基づく大規模なコーパスを用いた事前学習済み言語モデルの研究が盛んである．このようなコーパスはモデルの性能向上に大きく貢献するが，虚偽情報が含まれており，生成 AI において問題視されるハルシネーションの原因となりえる．そこで本研究では，国会および地方議会の会議録の品質と信頼性に着目し，大規模な会議録コーパスを構築した．また，このコーパスを基に事前学習済み言語モデルを構築し，その性能を一般ドメインのタスクにおいて検証した．さらに，会議録コーパスとの関連性を持つ政治ドメインのタスクにおいてもその有効性を評価した．

キーワード　事前学習済み言語モデル，コーパス構築，議会会議録，ドメイン適応

Construction and Validation of Pre-trained Language Model Using Corpus of National and Local Assembly Minutes

Keiyu NAGAFUCHI†, Eisaku SATOU††, Yasutomo KIMURA††, Kazuma KADOWAKI†††, and Kenji ARAKI†

† Hokkaido University
Kita 14, Nishi 9, Kita-ku, Sapporo-shi, Hokkaido, 060-0814, Japan
†† Otaru University of Commerce
3-5-21 Midori, Otaru-shi, Hokkaido, 060-0814, Japan
††† The Japan Research Institute, Limited
2-18-1 Higashi-Gotanda, Shinagawa-ku, Tokyo, 141-0022, Japan
E-mail: †{nagafuchi,araki}@ist.hokudai.ac.jp,
††{g2020149@edu,kimura@res}.otaru-uc.ac.jp, †††kadowaki.kazuma@jri.co.jp

Abstract　In recent years, there has been a surge in pre-trained language models based on the large-scale corpora derived from the Common Crawl data collected from the Web. While such corpora significantly enhance the performance of the models, they can contain false information, potentially leading to hallucinations in generated AI content. In this study, we focused on the quality and reliability of the minutes from assemblies, constructing a large-scale corpus of these records. Based on this corpus, we developed pre-trained language models and evaluated their performance on general domain tasks. In addition, we also evaluated their effectiveness on political domain tasks related to the minutes' corpus.

Key words　pre-trained language model, corpus construction, assembly minutes, domain adaptation

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©2023 by IEICE

1. はじめに

近年，BERT [1] をはじめとする Transformer [2] に基づく事前学習済み言語モデルの台頭により，様々なドメインへの自然言語処理技術の適用がなされている．また，スケーリング則の確認 [3] や GPT-3 [4] の登場をきっかけとして，モデルの事前学習に用いるコーパスの大規模化も進みつつある．日本語においても，当初は Wikipedia だけを使った事前学習済み言語モデルが主流であったが，CC-100 [5] [6]，mC4 [7]，OSCAR [8] [9] といった大規模なデータをコーパスとした事前学習済み言語モデルが多数公開されている．これらのコーパスに共通する点として，Web から収集されたデータである Common Crawl に基づいていることが挙げられる．そのため，コーパスにはデマやフェイクニュースなどの虚偽情報も含まれており，こういったデータは生成 AI において問題視されているハルシネーションの一因となりえる．

日本では，オープンデータへの取り組みの推進のように，国および地方公共団体が保有する公共データを積極的に公開しようとする動きが盛んである．その公開されている情報の一つに，会議録が存在する．会議録とは，その議論の内容をテキストとして記録したものであり，文法の修正やフィラーの削除などの整文作業も含めて，人の手によって作成される．議事公開の原則が日本国憲法や地方自治法により定められているため，過去の会議録も公開されており，大規模に入手することができる．また，国会や地方議会で行われる本会議や委員会では，予算案や法律・条例案などの議論がなされているが，それらは人々の生活に密接に関連した広範な内容を含むとともに，フォーマルな場で行われる議論であることから含まれる情報の信頼性も高いと考えられる．これらのことから，国会や地方議会の会議録は，虚偽の少ない重要な情報を広範に含み，人の手によって処理された高品質で大規模なテキストデータと捉えることができる．

そこで本研究は，このような国会および地方議会会議録をコーパスとした事前学習済み言語モデルの構築と検証を目的とする．具体的には，各団体が公開する国会および地方議会の会議録を収集し，Web に基づくコーパスに匹敵する大規模な会議録のコーパスを構築する．また，構築したコーパスを用いた事前学習を行い BERT モデルを構築する．このとき，会議録のコーパスを用いて一から事前学習を行うモデルや，Wikipedia のコーパスで事前学習を行った後に会議録のコーパスを用いて追加の事前学習を行うモデルなどの複数の派生系を構築する．

構築したモデルの効果を評価するため，一般ドメインのタスクである JGLUE [10] を用いて比較検証を行う．さらに，会議録コーパスは政治ドメインのコーパスであると捉えられるため，政治ドメインのタスクである NTCIR-14 QA Lab-PoliInfo Classification task を用いた比較検証も行う．

なお，構築したモデルについては Hugging Face Hub[1]にて公開する．

本研究の貢献は以下の通りである．

- 国会および地方議会の会議録を用いた大規模な会議録コーパスの構築
- 構築した会議録コーパスを用いて事前学習を行った複数のモデルの構築と公開
- 構築したモデルの一般ドメインにおける有効性の検証
- 構築したモデルの政治ドメインにおける有効性の検証

2. 関連研究

2.1 BERT

BERT (Bidirectional Encoder Representations from Transformers) [1] は，Transformer [2] に基づく事前学習済み言語モデルの一つである．BERT の事前学習は，大規模なコーパスを用いて，Masked Language Modeling (MLM) と Next Sentence Prediction (NSP) の 2 つの教師なし学習タスクを同時に実行することで行われる．MLM は，入力文の一部の単語をランダムにマスクし，マスクされる前の単語を予測するタスクである．NSP は，2 つの入力文が隣接しているかを識別するタスクである．これら 2 つのタスクによって，BERT は双方向から文を学習できる．また，BERT は fine-tuning を行うことで，様々なタスクに適用することができる．

2.2 事前学習済み言語モデルのドメイン適応

事前学習済み言語モデルの構築の際は，Wikipedia や Common Crawl に基づくコーパスで事前学習を行うことが一般的である．しかし，モデルのドメイン適応に関する研究では，これらのコーパス以外を用いてモデルを構築する手法が多く提案されている．

英語においては，モデルのドメイン適応に関する研究は盛んに行われている．Lee ら [11] は，一般的なドメインのテキストと専門的なドメインのテキストでは，単語分布が大きく異なるため，専門的なドメインのタスクにおいて BERT のような事前学習済み言語モデルが性能を発揮するには，専門的なドメインのコーパスで事前学習を行う必要があることを主張し，生物医学ドメインのコーパスを用いて BERT の追加の事前学習を行ったモデルである BioBERT を提案した．その結果，生物医学ドメインのタスクにおいて，BioBERT は従来のモデルを上回る性能を示した．そのほか，科学 [12] や法律 [13] などの専門的なドメインにおいても，適応したモデルが提案されている．

日本語においても，事前学習済み言語モデルのドメイン適応に関する研究が注目されつつある．医療 [14]，金融 [15]，法律 [16] のドメインに適応した事前学習済み言語モデルが提案され，各ドメインのタスクにおいて優れた性能を示している．これらの研究の共通点として，事前学習に用いる専門的なドメインのコーパスの規模はそれほど大きくないことが挙げられる．

モデルをドメイン適応する際の事前学習手法についても議論がなされている．Chalkidis ら [13] と Miyazaki ら [16] は，法律ドメインのコーパスを用いた BERT のドメイン適応を行う際に，SciBERT [12] のように事前学習を一から行う SC (pre-training from scratch) と，一般ドメインで学習されたモデルに BioBERT のように追加の事前学習を行う FP (further pre-training) の 2 つ

(注1)：https://huggingface.co/local-politics-jp

手法で比較を行っている．また，Gururangan ら [17] は，FP と同義である DAPT (domain adaptive pre-training) の他に，与えられるタスクのラベルなしデータセットを用いて追加の事前学習を行う TAPT (task adaptive pre-training) を提案している．しかし，これらの事前学習手法のどれが良いかは，構築することができるコーパスの規模や与えられるタスクによって変動し，常に有効な手法があるわけではない．

3. 事前学習済みモデルの構築

3.1 事前学習用コーパスの構築

本研究では，事前学習に用いるコーパスとして，3 つのコーパスを構築する．

1 つ目は，国会会議録のコーパスである．国会会議録は，国会にて行われる会議の内容をテキストに起こしたものである．本研究では，国会会議録検索システム検索用 API[2]を用いて国会会議録を収集した．収集する対象は，1947 年 1 月 1 日から 2022 年 12 月 31 日までの期間に開かれた本会議および委員会の会議録とし，合計で 104,969 件を収集した．また，収集した時点の国会会議録は JSON ファイルであり，特殊記号や非発言部分などのノイズが多く含まれているため，クリーニング処理を施しテキストファイルとした．その結果，処理前は約 17 GB，処理後は約 12 GB のデータサイズとなった．

2 つ目は，地方議会会議録のコーパスである．地方議会会議録は，各地方公共団体の議会にて行われる会議の内容をテキストに起こしたものである．本研究では，各地方公共団体の Web サイトにおいて公開されている地方議会会議録を収集した．収集する対象は，地方議会が設置されている 47 都道府県，1,718 市町村，23 特別区のうちの，710 団体の 2022 年 12 月 31 日までの期間に開かれた地方議会の本会議および委員会の会議録とし，合計で 553,823 件を収集した．また，収集した時点の地方議会会議録は HTML ファイルであり，国会会議録と同じくノイズが多く含まれているため，こちらもクリーニング処理を施しテキストファイルとした．その結果，処理前は約 72 GB，処理後は約 58 GB のデータサイズとなった．

3 つ目は, Wikipedia のコーパスである．本研究では, Wikipedia 日本語版の 2021 年 8 月 23 日時点のダンプデータからコーパスを構築した．約 4.3 GB のデータサイズとなった．

本研究では，国会および地方議会の会議録のコーパスをモデルの構築に主に使用し，Wikipedia のコーパスを比較に用いる派生系のモデルの構築に使用する．

3.2 モデルの事前学習

本研究では, **3.1** で構築した会議録のコーパスを用いて, BERT の事前学習を行いモデルを構築する．また，Wikipedia のコーパスも用いたモデルや，日本語における事前学習済み言語モデルのドメイン適応に関する研究に倣ったモデルなどの派生系も含めて構築する．ここでは，Chalkidis ら [13] に倣い，一から事前学習を行う手法を SC (pre-training from scratch)，追加の事前学習を行う手法を FP (further pre-training) と呼ぶ．

派生系を含んだ 4 つの構築するモデルを以下に示す．

- **SC_min**: 会議録
- **SC_minwiki**: 会議録 + Wikipedia
- **FP_min**: Wikipedia → 会議録
- **FP_minwiki**: Wikipedia → 会議録 + Wikipedia

1 つ目のモデルは，会議録のコーパスを用いて SC による事前学習を行うモデルの SC_min である．2 つ目のモデルは，SC_min に Wikipedia のコーパスも加えて事前学習を行うモデルの SC_minwiki である．また，前述したように会議録のコーパスは政治ドメインのコーパスと捉えることができる．Suzuki ら [15] や Miyazaki ら [16] は，金融や法律のドメインにモデルを適応する際，FP による事前学習を行ったモデルも提案している．それらの FP のモデルは，SC と比較して優れた性能を示しているため，本研究においても FP のモデルを構築する．3 つ目のモデルは，Wikipedia のコーパスを用いて事前学習を行った後に，会議録のコーパスを用いて FP による事前学習を行うモデルの FP_min である．4 つ目のモデルは，FP_min の追加の事前学習の際に，Wikipedia のコーパスも再度用いて事前学習を行うモデルの FP_minwiki である．

また，それぞれのモデルの最初の事前学習に用いるコーパスから，トークナイザを学習する．すなわち，SC_min については会議録のコーパス，SC_minwiki については会議録と Wikipedia のコーパスから学習を行った一方, FP の 2 つのモデルは Wikipedia のコーパスから学習された東北大学の BERT[3]のトークナイザをそのまま用いる．本研究では，形態素解析器の MeCab[4]と辞書の Unidic[5]を用いて分かち書きを行った後に，WordPiece [18] によってサブワードに分割することで，トークナイザを学習した．語彙数は，[CLS] などの特殊なトークンも含めて，32,768 語となっている．

モデルの事前学習の際のハイパーパラメータは，東北大学が公開する BERT の GitHub リポジトリ[6]と同一のものを使用した[7]．SC の learning rate は 1e-4，FP の learning rate に関しては，Google が公開する情報[8]を参考に 2e-5 に設定した．事前学習は 8 枚の NVIDIA A100 GPU を用いて行い，それぞれ約 44 時間で完了した．

4. 一般ドメインのタスクによる検証

4.1 実 験 概 要

本実験の目的は，一般ドメインのタスクにおいて構築したモデルが有効であるか明らかにすることである．そのため，従来の一般的なドメインで事前学習を行ったモデルと比較を行う．また，モデルの派生系間での比較を行うことにより，それぞれ

(注2)：https://kokkai.ndl.go.jp/api.html

(注3)：https://huggingface.co/cl-tohoku/bert-base-japanese-v2

(注4)：https://taku910.github.io/mecab/

(注5)：https://clrd.ninjal.ac.jp/unidic/

(注6)：https://github.com/cl-tohoku/bert-japanese/tree/v2.0

(注7)：具体的には，batch size は 256，ステップ数は 1,000,000，warmup steps は 10,000，max seq length は 512，short seq prob は 0.1，masked LM prob は 0.15 とし，whole word masking を適用した．

(注8)：BERT の GitHub リポジトリ (https://github.com/google-research/bert) の “Pre-training tips and caveats” セクション．

表 1　JGLUE による実験結果．太字は比較対象 5 モデルの，下線は全モデルのベストを示す

Model	MARC-ja	JSTS	JNLI	JSQuAD	JCommonsenseQA
	Accuracy	Pearson / Spearman	Accuracy	EM / F1	Accuracy
SC_min	0.960	0.889 / 0.847	0.884	0.851 / 0.928	0.693
SC_minwiki	**0.962**	0.901 / 0.858	0.880	0.864 / 0.937	0.751
FP_min	0.960	**0.909** / **0.869**	0.900	0.871 / **0.942**	0.797
FP_minwiki	**0.962**	**0.909** / 0.866	**0.903**	**0.873** / 0.941	**0.810**
SC_wiki (Tohoku)	0.958	**0.909** / 0.868	0.899	0.871 / 0.941	0.808
NICT	0.958	0.910 / 0.871	0.902	0.897 / 0.947	0.823
Waseda	0.962	0.913 / 0.873	0.895	0.864 / 0.927	0.840

の事前学習手法の分析を行う．

4.2 実験設定

本実験には，日本語言語理解ベンチマークである JGLUE [10] のデータセットを使用する．JGLUE のデータセットには，MARC-ja (感情分類)，JSTS (意味的類似度計算)，JNLI (自然言語推論)，JSQuAD (機械読解)，JCommonsenseQA (常識推論) が含まれている．fine-tuning の際のハイパーパラメータや評価指標は，JGLUE の GitHub リポジトリ[9]に記載されているものに従った[10]．

4.3 実験結果

表 1 に本実験の結果を示す．表中で SC_wiki と示しているものは東北大学が公開する BERT であり，これは本実験で構築した SC_min，SC_minwiki と同じハイパーパラメータで学習されコーパスのみが異なるため，比較対象とする[11]．

タスク別に，構築したモデルと SC_wiki の比較結果を述べる．MARC-ja においては，構築したモデルすべてが SC_wiki を上回るスコアを示し，SC_minwiki と FP_minwiki が最も高いスコア 0.962 を示している．その他のタスクにおいては，SC_wiki を SC のモデルは下回るスコア，FP のモデルは上回るスコアを示す傾向が見られる．JSTS においては，Pearson と Spearman の両方で FP_min が最も高いスコア 0.909 / 0.869 を示している．JNLI においては，FP_minwiki が最も高いスコア 0.903 を示している．JSQuAD においては，EM では FP_minwiki が最も高いスコア 0.873，F1 では FP_min が最も高いスコア 0.942 を示している．JCommonsenseQA においては，FP_minwiki が最も高いスコア 0.810 を示している．総括して，SC のモデルよりも FP のモデルの方が高いスコアを示す傾向が見られる．

また，構築したモデルと NICT と Waseda との比較結果も述べる．MARC-ja と JNLI においては，構築したモデルが最も高いスコアを示しており，JSTS においても，最もスコアの高い Waseda と FP_min のスコアの差は，EM と F1 の両方で 0.004 とわずかである．しかし，JSQuAD においては，最もスコアの高い NICT と FP_minwiki のスコアの差は，EM では 0.024 と顕著な差が残っている．同様に，JCommonsenseQA においても，最もスコアの高い Waseda と FP_minwiki のスコアの差は，0.030 と顕著な差が残っている．

4.4 考　　察

タスク別に，構築したモデルと SC_wiki・NICT・Waseda の比較結果から考察する．MARC-ja においては，構築したモデルが最も高いスコアを示した．MARC-ja は，Amazon の商品レビューから構築されたデータセットであり，話し言葉に近い書き言葉である性質が見られる．構築したモデルの事前学習に用いた会議録コーパスは，同様に話し言葉に近い書き言葉のデータであるため，このことがスコア向上に寄与したと考えられる．JSTS や JNLI においては，構築したモデルは，比較対象のモデルと同等かそれ以上のスコアを示した．このことから，意味的類似度計算や自然言語推論といった基本的なタスクは，会議録コーパスでもスコア向上が期待できることがわかる．JSQuAD においては，SC_wiki と比較して，FP_minwiki が高いスコアを示しているが，NICT や Waseda と比較すると，スコアに顕著な差が残っていた．これは，トークナイザの学習に使用する辞書と学習回数による影響が考えられる．構築したモデルと SC_wiki は，トークナイザの学習の辞書に Unidic を用いている．Unidic は単語を短単位に分割する性質があり，JSQuAD の質問に解答する際に単語を短く分割し過ぎてしまっている可能性がある．また，NICT は他のモデルと比較して大きなバッチサイズで事前学習を行っているため，学習エポック数が大きい．構築したモデル間においても，SC のモデルと比べて学習ステップ数が多い FP のモデルがより高いスコアを示していることから，学習回数が影響を与えやすいタスクであることが考えられる．JCommonsenseQA においては，SC_wiki と比較して，FP_minwiki が高いスコアを示しているが，NICT や Waseda と比較すると，スコアに顕著な差が残っていた．これは，学習回数の他に，事前学習コーパスによる影響が考えられる．Kurihara ら [10] は，Common Crawl に基づくコーパスによる事前学習が，一般常識を推論するタスクである JCommonsenseQA において効果的である可能性を述べている．このことから，会議録のコーパスには一般常識に関する知識が不足している可能性が考

(注9)：https://github.com/yahoojapan/JGLUE

(注10)：具体的には，batch size は 32，warmup ratio は 0.1 に設定した．max seq length は，タスクに応じて変更し，MARC-ja では 512，JSTS・JNLI では 128，JSQuAD では 384，JCommonsenseQA では 64 に設定した．また，learning rate は {5e-5, 3e-5, 2e-5}，epoch は {3, 4} の中から選択し，探索の結果のうち最も良かったスコアを示す．評価指標としては，MARC-ja，JNLI，JCommonsenseQA では Accuracy，JSTS では Pearson および Spearman 相関係数，JSQuAD では Exact Match と F1-score を使用した．

(注11)：実験結果は JGLUE の GitHub リポジトリ (https://github.com/yahoojapan/JGLUE) に記載された値を用いた．このほか，参考値として JGLUE の GitHub リポジトリで示されている NICT (BPE あり)，Waseda (roberta-base-japanese) の結果も示した．

表 2　NTCIR-14 QA Lab-PoliInfo の Classification task のデータ例

表記	label	例
Topic	-	築地市場を豊洲に移転するべきである
Utterance	-	豊洲は，新市場移転により千客万来施設ができるなど， 今後，観光客の集客が大いに期待できるエリアであります．
Relevance	関連あり / 関連なし	あり
Fact-checkability	事実検証可能 / 事実検証不可能	可能
Stance	賛成 / 反対 / どちらでもない	賛成

表 3　NTCIR-14 QA Lab-PoliInfo の Classification task のデータ数

表記	label	train	test
Relevance	あり	901	308
	なし	9,390	3,104
Fact-checkability	可能	2,915	991
	不可能	7,376	2,421
Stance	賛成	910	355
	反対	602	225
	どちらでもない	8,779	2,832

表 4　NTCIR-14 QA Lab-PoliInfo Classification task による実験結果．太字・下線はベストを示す

Model	Relevance		Fact-checkability		Stance	
	Accuracy	F1	Accuracy	F1	Accuracy	F1
SC_min	0.928	0.953	0.856	**0.731**	0.596	0.628
SC_minwiki	0.928	0.954	0.852	0.723	0.586	0.622
FP_min	0.931	0.955	**0.860**	**0.731**	**0.612**	**0.641**
FP_minwiki	**0.933**	**0.956**	0.859	0.725	0.607	0.636
SC_wiki (Tohoku)	0.921	0.949	0.851	0.720	0.553	0.587

えられる．

また，構築したモデル間の比較結果から考察する．FP_min と FP_minwiki を比較すると，全体的に FP_minwiki の方が優れた性能を示す傾向が見られた．この結果から，FP による事前学習の際に，初めの事前学習に使用したコーパスも重ねて使用することで，初めの事前学習で得た知識の忘却を抑制できることが考えられる．SC_min とそれ以外の派生系を比較すると，JNLI を除くすべてのタスクにおいて SC_min 以外の派生系がより優れたスコアを示している．この結果から，Wikipedia のコーパスから得られる知識が効果的であることが考えられる．

5. 政治ドメインのタスクによる検証

5.1 実験概要

本研究で構築したモデルは一般ドメインでのタスク性能の向上を目指したものであるが，コーパスとして政治に深く関連する会議録を利用したため，政治ドメインや，議会で議論されることの多い金融ドメイン，法律ドメインにおいてはさらに優れた性能を発揮することが期待される．本実験では，政治ドメインのタスクにおいて構築したモデルがどの程度有効となるのかを明らかにする．一般ドメインのタスクによる検証と同様に，従来の一般的なドメインで事前学習を行ったモデルと比較を行う．また，構築したモデルの派生系間での比較を行うことにより，それぞれの事前学習手法の分析を行う．

本実験には，NTCIR-14 QA Lab-PoliInfo [19] の Classification task を用いる．本タスクは，議題 (Topic) と議員の発言 (Utterance) を比較し，関連があるか (Relevance)，事実検証が可能か (Fact-checkability)，議員はどの立場をとっているか (Stance) について分類することで，根拠のある意見を見つけることを目的としたタスクである．表 2 にデータの例を示す．Relevance, Fact-checkability の label は 2 値，Stance の label は 3 値となっている．本タスクのデータセットは，1 つの Utterance に対して 3 人または 5 人の注釈者による複数の正解ラベルが付与されている．本研究では，評価の単純化のため，多数決により正解ラベルが 1 つとなるようにデータセットに加工を施した．なお，この加工によってデータが欠損することはなかった．表 3 にデータセットに含まれるデータの数を示す．

5.2 実験設定

本タスクは, Relevance の分類, Fact-checkability の分類, Stance の分類を 3 つのサブタスクと捉え，分割して解くことができる．そのため，Relevance の分類タスクは Topic と Utterance の 2 文をモデルに入力する文ペア分類タスクとし，Fact-checkability と Stance の分類タスクは Utterance のみの 1 文をモデルに入力する文章分類タスクとする．また，train データセットの 10 %を層化分割し，validation データセットとして用いる．fine-tuning のハイパーパラメータは，Mosbach ら [20] を参考に設定する[12]．評価指標には，Accuracy と F1-score のマクロ平均を用いる．このとき，5 つの異なるシード値を用いて実験を行い，そのスコアの平均で評価を行う．

5.3 実験結果

表 4 に本実験の結果を示す．

構築したモデルの派生系を SC_wiki を比較すると，Relevance，Fact-checkability，Stance のすべてにおいて，高いスコアを示している．Relevance では FP_minwiki が 0.933 / 0.956, Fact-checkability では SC_min が 0.860 / 0.731，Stance では FP_min が 0.612 / 0.641 と，それぞれ最も高い Acccuracy/F1-Score を示している．このように，SC のモデルよりも FP のモデルの方が高いスコアを示す傾向が見られる．

5.4 考　　察

構築したモデルの派生系は，Relevance，Fact-checkability，

(注 12)：具体的には，batch size は 32，learning rate は 2e-5，epoch は 20，warmup ratio は 0.1 に設定した．また，max seq length は，タスクに応じて変更し，Relevance の分類では 256，Fact-checkability と Stance の分類では 128 に設定した．

Stance のすべてにおいて SC_wiki を上回る性能を示したことから，政治ドメインにおいて会議録コーパスによる事前学習は優れた性能を発揮することがわかる．また，一般ドメインのタスクによる検証と同様に，SC のモデルよりも FP のモデルの方がより優れた性能を示す傾向が見られた．このことから，学習ステップ数が影響していることが考えられる．

6. おわりに

本研究では，モデルの事前学習に用いられるコーパスの品質や信頼性に着目し，人手により作成されている国会および地方議会の会議録から大規模な会議録コーパスを構築した．また，構築したコーパスを用いて，一から会議録コーパスを用いて事前学習を行う SC と会議録コーパスを用いて追加の事前学習を行う FP といった，複数の派生系を含む事前学習済み言語モデルを構築した．一般ドメインのタスクによる検証の結果，構築したモデルは，一部のタスクにおいて従来のモデルと同等かそれ以上の性能を示した．このことから，会議録コーパスはモデルの事前学習において有効であること，FP による事前学習の際に初めの事前学習に使用したコーパスを再度使用することにより知識の忘却を抑制できること，会議録コーパスには常識に関する知識が欠けていることを明らかにした．また，政治ドメインのタスクによる検証の結果，構築したモデルは，従来のモデルを上回る性能を示した．このことから，会議録コーパスを用いた事前学習は政治ドメインにおいて優れた性能を発揮することを明らかにした．さらに，両方の検証において，SC のモデルと比較して，FP のモデルの方が優れた性能を示す傾向にあることがわかった．

今後は，会議録コーパスに不足している常識に関する知識を，信頼性を損なわずに補うことができるデータを調査する．また，会議録はその性質上，今回検証を行った政治ドメインの他に，金融や法律ドメインとも密接に関連しているため，それらのドメインでの検証も行う．最終的には，信頼性の高いコーパスを用いた LLM の構築を目指す．

文　献

[1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), pp.4171–4186, June 2019.

[2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” Advances in Neural Information Processing Systems, vol.30, pp.5998–6008, 2017.

[3] J. Kaplan, S. McCandlish, T. Henighan, T.B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, and D. Amodei, “Scaling laws for neural language models,” 2020.

[4] T. Brown, B. Mann, N. Ryder, M. Subbiah, J.D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, “Language models are few-shot learners,” Advances in Neural Information Processing Systems, vol.33, pp.1877–1901, Curran Associates, Inc., 2020.

[5] G. Wenzek, M.-A. Lachaux, A. Conneau, V. Chaudhary, F. Guzmán, A. Joulin, and E. Grave, “CCNet: Extracting high quality monolingual datasets from web crawl data,” Proceedings of the 12th Language Resources and Evaluation Conference, pp.4003–4012, European Language Resources Association, Marseille, France, May 2020.

[6] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, “Unsupervised cross-lingual representation learning at scale,” Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp.8440–8451, Association for Computational Linguistics, Online, July 2020.

[7] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P.J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” Jan. 2020.

[8] P.J. Ortiz Suárez, B. Sagot, and L. Romary, “Asynchronous pipelines for processing huge corpora on medium to low resource infrastructures,” Proceedings of the Workshop on Challenges in the Management of Large Corpora (CMLC-7), pp.9–16, Leibniz-Institut für Deutsche Sprache, Mannheim, 2019.

[9] P.J. Ortiz Suárez, L. Romary, and B. Sagot, “A monolingual approach to contextualized word embeddings for mid-resource languages,” Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp.1703–1714, Association for Computational Linguistics, Online, July 2020.

[10] K. Kurihara, D. Kawahara, and T. Shibata, “JGLUE: Japanese general language understanding evaluation,” Proceedings of the Thirteenth Language Resources and Evaluation Conference, pp.2957–2966, June 2022.

[11] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C.H. So, and J. Kang, “BioBERT: a pre-trained biomedical language representation model for biomedical text mining,” Bioinformatics, vol.36, no.4, pp.1234–1240, Sept. 2019.

[12] I. Beltagy, K. Lo, and A. Cohan, “SciBERT: A pretrained language model for scientific text,” Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pp.3615–3620, Nov. 2019.

[13] I. Chalkidis, M. Fergadiotis, P. Malakasiotis, N. Aletras, and I. Androutsopoulos, “LEGAL-BERT: The muppets straight out of law school,” Findings of the Association for Computational Linguistics: EMNLP 2020, pp.2898–2904, Nov. 2020.

[14] Y. Kawazoe, D. Shibata, E. Shinohara, E. Aramaki, and K. Ohe, “A clinical specific BERT developed using a huge Japanese clinical text corpus,” PLOS ONE, vol.16, no.11, pp.1–11, Nov. 2021.

[15] M. Suzuki, H. Sakaji, M. Hirano, and K. Izumi, “Constructing and analyzing domain-specific language model for financial text mining,” Information Processing & Management, vol.60, no.2, p.103194, 2023.

[16] K. Miyazaki, H. Yamada, and T. Tokunaga, “Cross-domain analysis on Japanese legal pretrained language models,” Findings of the Association for Computational Linguistics: AACL-IJCNLP 2022, pp.274–281, Nov. 2022.

[17] S. Gururangan, A. Marasović, S. Swayamdipta, K. Lo, I. Beltagy, D. Downey, and N.A. Smith, “Don’t stop pretraining: Adapt language models to domains and tasks,” Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp.8342–8360, Association for Computational Linguistics, Online, July 2020.

[18] M. Schuster and K. Nakajima, “Japanese and Korean voice search,” 2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pp.5149–5152, 2012.

[19] Y. Kimura, H. Shibuki, H. Ototake, Y. Uchida, K. Takamaru, K. Sakamoto, M. Ishioroshi, T. Mitamura, N. Kando, T. Mori, H. Yuasa, S. Sekine, and K. Inui, “Overview of the NTCIR-14 QA Lab-PoliInfo task,” June 2019.

[20] M. Mosbach, M. Andriushchenko, and D. Klakow, “On the Stability of Fine-tuning BERT: Misconceptions, Explanations, and Strong Baselines,” 2021.