一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report
NLC2023-8(2023-09)

ChatGPTを利用したユーモア応答生成の分析

原直大† 荒木健治††

† 北海道大学 大学院情報科学院
†† 北海道大学 大学院情報科学研究院
E-mail: †harahappy0208@eis.hokudai.ac.jp, ††araki@ist.hokudai.ac.jp

あらまし 本研究では，ユーザとの雑談中にユーモア発話を行う雑談対話システムを実現するために，ChatGPT を利用したユーモア応答生成の分析を行う．具体的には，対話文脈に対して ChatGPT を用いて，日本のユーモアの 1 つである漫才の「ボケ・ツッコミ」発話を生成し，その発話に対してユーザ評価を行う．今回の実験では，1,344 対話について生成したボケ・ツッコミ発話を評価した．評価の結果，ChatGPT は，対話によって面白いボケ・ツッコミ発話を生成することができることを明らかにし，適切な「ボケ・ツッコミ」発話を行うことができる雑談対話システムに活用するにあたって，ChatGPT は十分なユーモア応答生成能力を持っていることを確認した．また，評価結果から，生成されるボケ・ツッコミ発話は，いくつかのパターンに分けられることを確認した．

キーワード ユーモア，非タスク指向型対話システム，ChatGPT

Analysis of Humorous Response Generation Using ChatGPT

Naohiro HARA† and Kenji ARAKI††

† Graduate School of Information Science and Technology, Hokkaido University
†† Faculty of Information Science and Technology, Hokkaido University
E-mail: †harahappy0208@eis.hokudai.ac.jp, ††araki@ist.hokudai.ac.jp

Abstract In this study, we analyze the generation of humorous responses using ChatGPT in order to realize a dialogue system that generates humorous utterances during chat with a user. Specifically, we generated ”Boke-Tsukkomi” utterances, one of Japanese humor, using ChatGPT in a dialogue context, and evaluated them for the user. In this experiment, we evaluated the generated ”Boke-Tsukkomi” utterances for 1,344 dialogues. As a result of the evaluation, we confirmed that ChatGPT is capable of generating appropriate and funny ”Boke-Tsukkomi” utterances through dialogue, and that ChatGPT has sufficient ability to generate humorous responses for use in a chat dialog system capable of generating appropriate ”Boke-Tsukkomi” utterances. We also confirmed that ChatGPT has sufficient ability to generate humorous responses. From evaluation results, we confirmed that the generated humor responses can be classified into several patterns.

Key words Humor, Non-task-oriented dialogue system, ChatGPT

1. はじめに

近年，対話システムの研究が盛んに行われ，応答性能は向上を続けている．話題を限定しない雑談を目的とする雑談対話システム（非タスク指向型対話システム）についても，ユーザ発話に対して適切な応答を生成することで，自然な流れでの雑談を行うことが可能となった．しかしながら，ユーザがもう一度対話をしたいと感じるような「楽しい雑談」の実現は達成されていない．雑談対話システムの主目的は，雑談を通じてユーザの対話欲求を満たし，信頼を得ることであるため，ユーザが話していて楽しい・面白いと感じるかどうかは非常に重要な課題である．

この課題を解決するために，雑談中にユーモア発話を行う雑談対話システムの検討が必要である．ユーモア表現により，ユーザはシステムに対して好感を抱くことが報告されている [1]．日本の伝統的な対話型ユーモアとして，漫才のボケとツッコミがある．これは，ユーモアの生起過程の 1 つである「不適合 - 解決モデル」に当てはまるものであり [2]，雑談中にも自然な形で取り入れやすい．しかし，雑談の中で自然なボケ発話を行うこと，そしてボケ発話に対して適切なツッコミ発話を行うことは，非常に高度なタスクである．本研究では，ユーザとの雑談中に，適切な「ボケ・ツッコミ」発話を行うことができる雑談対話システムの実現への第 1 段階として，大規模言語モデルである ChatGPT のユーモア応答生成能力についてプロンプトベー

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©2023 by IEICE

スでの分析を行う．

2. 関 連 研 究

2.1 ユーモア応答生成

雑談中に，ユーモア発話を行う雑談対話システムに関する研究はいくつかある．呉ら [3] [4] [5] の研究では，ユーザ発話の特定の単語に対して，予め用意した単語の読み方リストを用いて，聞き間違いとなる単語を加えたボケ発話を行い，ユーモアを提示する．また，ボケエージェントとは別に，ツッコミエージェントを用意した実験を行い，ツッコミがボケ発話のユーモアを指摘することで，ユーザの負担を減らすことを明らかにした．藤倉ら [6] の研究では，ユーザの発話から名詞を抽出し，その名詞と用意した知識データから，単語間類似度を用いて，不適合を生じさせるユーモア発話を生成する．

これらの研究は，ユーザ発話から特定の単語を利用して，ユーモア応答生成を行うものであり，対話文脈全体を利用した応答生成は行っていない．また，雑談中の日本語ユーモア応答生成の研究で, 大規模言語モデルを利用した研究は行われていない．

2.2 ChatGPT

ChatGPT[1]は、昨年 11 月に，OpenAI によって開発された大規模言語モデル（LLM：Large Language Model) である．ChatGPT は，Zero-Shot や Few-Shot のプロンプトを与えることで，様々なタスクにおいて驚くべき性能を発揮するとして，世界中で話題となった．現在では，GPT-3.5 および GPT-4 のモデルを，Web ブラウザ上または API 経由で利用することができる．

ChatGPT は，その影響力の大きさとモデルが公開されていないという点から，様々な NLP タスクにおいてその性能を分析する研究が行われている [7] [8] [9]．Jentzsch ら [10] は，ChatGPT のユーモアセンスについて，生成・検出・説明の 3 つのタスクから分析を行い，ChatGPT のユーモアが限定的であることを明らかにした．また，ChatGPT の日本語タスクに関する研究も行われている [11] が，日本語のユーモアに関する研究は行われていない．

3. ユーモア応答生成

ChatGPT の様々な状況での対話に対するユーモア応答生成の分析を行うため，対話データを入力プロンプトに与え，その対話の最後の発話に対する応答として，ボケ発話及びツッコミ発話を生成させる．本章では，利用した対話データ，プロンプトの設計，生成結果について説明する．

3.1 対話データ

ChatGPT の入力プロンプトに対話文脈として与える対話データとして JEmpatheticDialogues [12] を用いた．JEmpatheticDialogues データセットには，2 ターン 4 発話の対話が 20,000 件含まれている．また，それぞれの対話について，感情を表す 32 種類の状況文の内，いずれか 1 つが付与されている．今回の実験では，32 種類のそれぞれの状況文について，49 対話ずつをランダムに選択し，ユーモア応答生成の対話文脈として利用した．（合計 1,568 対話）

3.2 プロンプトの設計

ChatGPT を API 経由で利用する場合, role というパラメータを設定することができる．role には,「system」,「user」,「assistant」の 3 種類がある．「system」では，ChatGPT の振る舞いを設定する．今回の実験では,「あなたは、お笑い芸人です。」と設定した．「user」で，ChatGPT に対して指示を行う．ボケ発話生成については**図 3.2**，ツッコミ発話生成については，**図 3.2** の形式のプロンプトを入力した．また,「assistant」というパラメータを利用することで，過去の文脈を利用した指示を行うことができる．ツッコミ発話生成については，ボケ発話生成の結果を「assistant」に加えて，生成を行った．

ChatGPT に与える**図 3.2** および**図 3.2** のプロンプトの形式は，OpenAI が公開するプロンプトガイド[2]を参考に設計した．今回の実験では，ボケ発話は対話データ中の A さん，ツッコミ発話は第 3 者である C さんの発話として生成する．これは，最終的な雑談対話システムの設計において，ユーザと対話するメインシステムのボケに対するツッコミ発話を，第 3 者となる 2 つ目のシステムが行うことを想定しているためである．

予備実験として，**図 3.2** の命令と対話文の部分のみをプロンプトに用いてボケ発話生成を行った結果，対話文の続きとして複数の発話を生成したものが，224 対話中 42 対話あったため，プロンプト内に制約条件と出力形式の項目を追加した．ツッコミ発話生成についても，予備実験を行った結果，ボケ発話の指摘を行わない，対話の続きとしてのボケ発話に同調するような発話を多く生成したため，制約条件にボケ発話の間違いを指摘するという指示を追加した．これは, [13] の否定型，否定感想型，訂正型のツッコミを誘導するものである．

```
### 命令：
（「###」を用いてプロンプト内で，明確な区切りを示している）
以下の制約条件に従って、対話文の最後の発話に対する A さんの
発話として、面白い漫才の「ボケ」を 1 発話で生成してください。

### 制約条件：
• 文字数は 60 トークン程度。
• A さんの発話のみを生成する

### 対話文：
    対話データより抽出

### 出力形式：
A さん：
```

図 1　ボケ発話生成プロンプトの形式

（注1）：https://openai.com/blog/chatgpt

（注2）：https://help.openai.com/en/articles/6654000-best-practices-for-prompt-engineering-with-openai-api

命令：
この生成されたボケを説明するような、面白い漫才の「ツッコミ」を 1 発話で生成してください。

制約条件：
• 文字数は 60 トークン程度。
• C さんの発話のみを生成する
• 最初に、「なんでやねん！」や「何言ってんねん！」、「なんやそれ！」、「なんやねんそれ！」、「どういうことやねん！」等のフレーズを用いて、間違いを指摘する。

出力形式：
C さん：

図 2　ツッコミ発話生成プロンプトの形式

3.3 生成結果

ChatGPT について 2023 年 7 月時点では，GPT-4 の API 利用はできなかったため，今回の実験では，再現性の確保のために，2023 年 6 月 13 日時点のスナップショット（モデルがその時点から更新されない）である「gpt-3.5-turbo-0613」のモデルを API 経由で利用し, 出力のランダム性を決定するパラメータである temperature の値を 0 に設定した．1,568 対話それぞれについて，ボケ発話およびツッコミ発話を生成した結果，以下のような発話が生成された．

- ボケ：ラベンダー畑に行ったら、香りに癒されて、
  頭が紫色になっちゃったよ！
  ツッコミ：なんでやねん！頭が紫色になるって、
  ラベンダー畑で魔法使ってんのか！？

- ボケ：でもさ、あの牡蠣は身が小さいって言っても、
  まるで僕の給料みたいに小さいわけじゃ
  ないから安心して！
  ツッコミ：なんでやねん！給料の話になんで持って
  くるねん！牡蠣の話やろ！

発話生成の中で，複数の発話を生成してしまうことがあり，対話に対する評価発話数を等しくする必要があった．今回の実験では，1,568 対話中で，生成された発話の中に改行文字「￥n」を含んでいた 34 対話（全体の約 2 %）を発話生成に失敗したとして扱う．これは，ChatGPT が一度に複数の発話を出力する際には，その発話区切りに改行文字を出力していたためである．

4. 評　　価

評価者は，生成されたユーモア発話を評価するため，それぞれの対話（例を**図 4.** に示す）について，**表 1** に示した 7 つの質問に 5 段階評価（1: 全く感じない〜5：とても感じる）で回答する．ツッコミ発話による影響を調査するために，評価者には「質問 1〜3 に回答するまでは，②の発話はまだされていないものとしてください」という指示を与えた．今回の研究では，第 1 著者を含めた 20 代の学生 7 名により，1,344 対話（1 人当たり 192 対話）に対して評価を行った．

A さん：妹の結婚式に行ってきたんだけど、姉の私まで
　　緊張しまくったよ。
B さん：一緒に緊張するなんて、仲良し姉妹なんだね。
A さん：緊張しすぎて、途中から酔っ払っちゃったんだよね。
　　反省してもしきれないよ。
B さん：仲良しの妹さんなら、きっと気にしてないって。
①A さん：でも、私の酔っ払いっぷりは、結婚式の主役より
　　目立ってたかも！
②C さん：なんでやねん！結婚式の主役が酔っ払いより
　　目立ってたら、それはもう大事件やん！

図 3　評価用対話形式の例（前 4 発話は，JEmpatheticDialogues [12] より引用）

表 1　評価者への質問一覧（1: 全く感じない〜5：とても感じる）

質問	
質問 1	①の発話までの対話は自然であると感じますか？
質問 2	対話の中で，①の発話は面白いと感じますか？
質問 3	①の発話で，A さんは「ボケている」（漫才のボケ）と感じますか？
質問 4	②の C さんの発話を踏まえて，①の発話で A さんは「ボケていた」と感じますか？
質問 5	②の発話までの対話は自然であると感じますか？
質問 6	対話の中で，2 つの発話（①+②）は面白いと感じますか？
質問 7	②の発話で，C さんは適切な「ツッコミ」（漫才のツッコミ）をしていると感じますか？

また，評価者によるユーモアの感じやすさの違いに考慮するため，実験の最後にユーモア測定尺度 [14] の「ユーモアへの気づき（SHQ）」および「ユーモアに対する好悪（MSHS）」に関する質問を 4 問ずつ行った．それぞれの質問項目について高い順に，SHQ に関しては 1〜4 点，MSHS に関しては 1〜5 点を配点した．各評価者のユーモア測定尺度アンケートの結果を**表 2** に示す．各評価者によって，ユーモアの気づきやすさおよびユーモアに対する好悪に差があることが分かる．

表 2　各評価者のユーモア測定尺度（SHQ は最大 16，MSHS は最大 20）

評価者	SHQ	MSHS
No.1	10	14
No.2	10	18
No.3	12	20
No.4	12	16
No.5	8	19
No.6	16	20
No.7	13	19

5. 結　　果

評価スコアの平均を，**表 3** に示す．また，評価スコアの詳細な分布を，**表 4** に示す．全体的に，評価スコアが 1〜5 の間で分かれて分布することで，平均値が 3 前後になっていることが分かる．しかし，発話の面白さに関する質問である質問 2 およ

び質問 6 については他の項目と比較して，低いスコアとなっている．さらに，各質問間の評価値の関連性を調べるため，各質問の間でスピアマンの順位相関係数を算出した．各質問間の相関分布について，結果を**図 4** に示す．**図 4** より，質問 2 と質問 3，質問 3 と質問 4，質問 2 と質問 6，質問 5 と質問 7 の間に，強い正の相関があることが分かる．

表 3　評価スコアの平均値

質問	平均値
質問 1	3.12
質問 2	2.40
質問 3	2.89
質問 4	3.03
質問 5	2.77
質問 6	2.39
質問 7	2.70

表 4　評価スコアの分布

質問	スコア 1	スコア 2	スコア 3	スコア 4	スコア 5	計
質問 1	195	303	247	349	250	1344
質問 2	425	336	278	230	75	1344
質問 3	324	224	270	323	203	1344
質問 4	277	225	253	360	229	1344
質問 5	261	376	271	282	154	1344
質問 6	397	375	294	207	71	1344
質問 7	376	291	236	241	200	1344

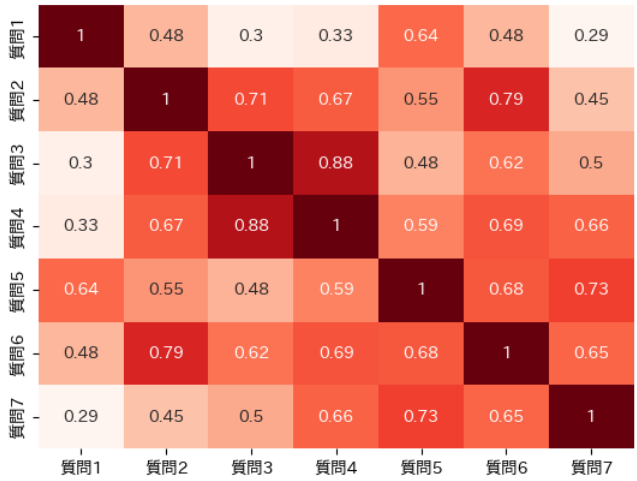


図 4　相 関 分 布

6. 考　　察

6.1　評価結果による考察

表 3 および**表 4** の結果より，質問 1 の評価スコアの平均が 3.12 と 3 を超えており，評価スコアも 4 と 5 に多く入れられていることが分かる．このことから，ChatGPT が入力した対話データの内容に沿った発話を生成できていると考えられる．また，質問 2 および質問 6 の評価スコアの平均が，他の項目よりも低くなっていることから，ChatGPT にとって人間が面白いと感じる発話を生成することの難易度が高いことが分かる．しかし，評価 4 と 5 にもスコアは一定数分布していることから，ChatGPT のユーモア応答は全く面白くないわけではなく，対話によっては人間が面白いと感じることができるようなユーモア応答を生成できていることが分かる．プロンプトの指示に例を加えることや対話データの形式や内容を工夫することで，より面白い発話を生成できる可能性があると考える．さらに，ボケていると感じるか（質問 3 および質問 4）と適切なツッコミができているか（質問 7）の評価についても，1,344 対話の過半数がスコア 3 以上に分布していることから，ボケ・ツッコミ発話を行うことができる雑談対話システムへの ChatGPT の利用は，十分に可能であると考える．

次に，各質問間の相関係数による考察を行う．**図 4** より，スピアマンの相関係数が 0.7 以上で高い正の相関を示したのは，質問 2 と質問 3，質問 3 と質問 4，質問 2 と質問 6，質問 5 と質問 7 である．それぞれの結果について，考察を行う．

質問 2 と質問 3 の結果から，評価者はより強くボケていると感じる発話に対して，面白さを感じているということが考えられる．これは，[2] の不適合によるユーモアの生起過程を証明する結果でもあり，ChatGPT の生成する漫才のボケが，雑談においてユーモアとして機能することを示す．

質問 3 と質問 4 の間には，スピアマンの相関係数が 0.88 であり，とても強い正の相関がある．この結果から，ツッコミ発話の前後で，ボケていると感じるかどうかの評価は変化しない傾向があることが分かる．実際，質問 3 と質問 4 の間で，評価スコアが 2 以上変化したものは，64 対話（全体の 4.8 %）であった．また，質問 2 と質問 6 の結果についても同様に，ツッコミ発話の前後で面白いと感じるかどうかの評価は変化しない傾向があることが分かる．このことから，ボケていると感じない，面白くないボケ発話に対するツッコミ発話は，違和感のあるものになりやすく，ツッコミによる評価の向上がうまくできていないことが考えられる．

質問 5 と質問 7 の相関からは，対話の最後のツッコミ発話が，対話全体の自然さに大きな影響を与えていることが分かる．ツッコミ発話はボケ発話を指摘する性質上，強い表現を使うため，不適切なツッコミ発話は，対話の中で違和感を生じさせやすい．自然さのスコアの平均値がツッコミ発話の前後で，0.25 下がっていることからも，不適切なツッコミ発話が対話の印象を大きく下げてしまっていると考えられる．

6.2　生成された例を用いた考察

今回の実験で得られた評価結果および生成例の中には，いくつか特徴的なパターンがみられた．それらの例を用いて，考察を行う．

全ての質問について，評価が高かった例（質問 1：5，質問 2：5，質問 3：5，質問 4：5，質問 5：5，質問 6：5，質問 7：5）を**図 6.2** に示す．この例のように，①のボケ発話がプロンプト内の対話の内容を踏まえたうえで簡潔に伝わりやすい内容であり，そのボケ発話に対して②のツッコミ発話が適切に指摘できている対話では，自然さと面白さの両方が高く評価されていた．

質問 1〜7 の評価全てについて，スコアが 4 以上だった対話は，1,344 対話中 97 対話（全体の 7.2 %）であった．このような発話をうまく雑談中に組み込むことができれば，楽しい・面白いと感じるような雑談対話システムが実現できると考える．

A さん：さっき、洗濯物を取り込んでたら、蜂が紛れ込んでて、冷や汗かいたよ。
B さん：危ないっ！大丈夫だったの？
A さん：刺激しないように、部屋中の窓とドアを開けて、外に出ていくまで見守ったよ。
B さん：何ごともなくて良かったー！蜂の方もビックリしただろうね！
①A さん：でもさ、蜂が窓から出ていくときに「バイバイ！」って手を振ってくれたんだよ！
②C さん：なんでやねん！蜂が手を振るなんて、蜂のマナーが良すぎるやろ！

図 5　評価が高かった対話の例（前 4 発話は，JEmpatheticDialogues [12] より引用）

次に，全ての質問について，評価が低かった例（質問 1：1，質問 2：1，質問 3：1，質問 4：1，質問 5：1，質問 6：1，質問 7：1）を**図 6.2** に示す．この例のように，対話の中でボケ発話の意味が伝わりにくいものは，ボケているという認識がされないため，自然さと面白さの両方で低い評価となっていた．このことから，対話の流れから完全に破綻したり，そもそも文章の意味がよく理解できない発話は，ボケとして伝わっていないということが分かる．また，このようなボケ発話に対しては，ツッコミ発話も長くなる傾向にあり，適切なツッコミができていないため，低い評価となっていた．質問 1〜7 の評価全てについて，スコアが 2 以下だった対話は，1,344 対話中 200 対話（全体の 14.9 %）であった．

A さん：ショッピングモールに行ってきたけど、めっちゃ混んでたー。
B さん：お疲れさま！いい買い物はできた？
A さん：うん、いっぱい買った。エレベーターが激混みでさ、乗り降りする時に、エレベーターガール役をやってあげたよ。
B さん：親切だね。みんな安心して乗り降りできただろうね。
①A さん：エレベーターガールやったら、お客さんが「ありがとう」と言ってくれたんだけど、なんかお礼にエレベーターのボタンを押してくれたらよかったのになー。
②C さん：なんでやねん！エレベーターのボタンを押してもらうために、エレベーターガールやるんやったら、逆にエレベーターのボタンを押してもらうために、エレベーターガールやるんちゃうんかい！？

図 6　評価が低かった対話の例（前 4 発話は，JEmpatheticDialogues [12] より引用）

次に，生成発話の特徴的な例として，自然さ（質問 1）の評価のみが高いボケ発話の例を**図 6.2**（質問 1：4，質問 2：1，質問 3：1，質問 4：1，質問 5：2，質問 6：1，質問 7：1）に示す．この例のように，対話の続きの発話としては適切であるが，ボケ発話としてはユーモアが弱く，ボケているということが評価者に伝わらない発話は，自然さが高く，面白さ（質問 2）とボケていると感じるかどうか（質問 3）のスコアは低く評価されていた．これは，ChatGPT が，ボケを作ることよりも，対話の流れに沿った発話を作るというタスクを優先した結果であると考える．また，このような発話に対してツッコミ発話を行うと，対話全体が違和感のある流れとなってしまい，ツッコミ発話後の自然さ（質問 5）の評価スコアが下がってしまう．自然さのスコア（質問 1）が 4 以上で，ボケていると感じるか（質問 3）のスコアが 2 以下であった対話は，1,344 対話中 195 対話（全体の 14.5 %）であった．

A さん：友だちとプチ旅行に出かけることになったから、とっても楽しみ。
B さん：それは楽しみだね。どこへ行くことになったの？
A さん：箱根へ行くんだ。温泉旅館に泊まって、ちょっと観光する予定。
B さん：箱根、温泉で有名だもんね。1 泊旅行なの？
①A さん：そうなんだよ。でも、温泉に入るときは気をつけないといけないんだよね。なんせ、湯船に入っていると、時間があっという間に過ぎちゃうからさ！
②C さん：なんでやねん！湯船に入って時間が過ぎるって、そんなことあるんかい！それはただの時間の流れを感じることができる才能やんけ！

図 7　自然さ評価のみが高いボケ発話の例（前 4 発話は，JEmpathetic-Dialogues [12] より引用）

次に，ツッコミ発話の前後で，ボケていると感じるかどうかの評価が大きく上がった例を**図 6.2**（質問 1：5，質問 2：3，質問 3：2，質問 4：4，質問 5：5，質問 6：4，質問 7：5）に示す．この例のように，ボケとして微妙だった発話を，ツッコミ発話によってボケ発話であると評価者に示すことができている対話では，ツッコミ発話の前後でボケていると感じるかどうかの評価が大きく上がってた．これは，[13] で定義される漫才中のツッコミの役割と同等の働きをできていると考えられる．しかし，適切なツッコミができているか（質問 7）のスコアが 4 以上で，ツッコミ発話の前後でボケていると感じるかどうかの評価が 2 以上増加した対話は，1,344 対話中 36 対話（全体の 2.7 %）と少なかった．ボケであると評価者に伝わりにくいボケ発話に対して，ツッコミ発話は失敗しやすいと考えられる．

A さん：ラインがこんなに便利なものだとは、思わなかったですよ。
B さん：使ってみると、とても便利ですよね。
A さん：最初は必要ないって思っていたんですけど、孫に言われて。
B さん：ビデオ通話もできるし、便利ですよね。
①A さん：ビデオ通話で孫に「おじいちゃん、顔が怖い！」って言われちゃったんですよ！
②C さん：なんでやねん！ビデオ通話で孫に「おじいちゃん、顔が怖い！」って言われるほどの顔やったんかい！

図 8　ツッコミ発話後に評価が上がったの発話例（前 4 発話は，JEmpatheticDialogues [12] より引用）

最後に，特徴的なタイプの発話例を，**図 6.2**（質問 1：2，質問 2：1，質問 3：1，質問 4：1，質問 5：2，質問 6：1，質問 7：1）に示す．今回の実験で生成されたボケ発話およびツッコミ発話の中に，この例のような「ボケ」「ツッコミ」「お笑い」「芸人」などの単語を含む発話が多く見られた．このような発話は，プロンプト内にこれらの単語が入っていることにより生成されたものであると考えられる．これらのタイプの発話は，対話の流れに関係なく，お笑いに関する単語を出力しているので，違和感のある発話になっているものが多い．また，A さん自身がお笑い芸人であるというペルソナを持ってしまう発話も多く見られたので，実際の雑談ではペルソナの情報に矛盾が生まれてしまう可能性が考えられる．全 1,344 対話を，第一著者 1 名で確認した結果，このような単語を含む発話は，156 対話（全体の 11.6 %）あった．

A さん：アメリカ旅行に出かけるんですけど。
B さん：いいですね、羨ましい。
A さん：英会話がうまくないんで、ちゃんとコミュニケーション取れるか気になります。
B さん：片言でもなんとかなるって言いますよ。
①A さん：でも、英語で「ボケ」って言ったら通じるかな？
②C さん：なんでやねん！英語で「ボケ」って言ったら、相手は「ツッコミ」で返すんやで！

図 9　特徴的なタイプの発話例（前 4 発話は，JEmpatheticDialogues [12] より引用）

また，以下に示すような，不適切な発話もいくつか生成されていた．大規模言語モデルを利用した雑談応答生成では，生成された不適切な発話をフィルタ等で検出し，応答のランダム性を上げて生成し直すといった工夫が必要となると考える．

- A さん：最後の発話が B さんの発話であるため、A さんの発話を生成する必要がありません。

7. ま と め

本研究では，ユーザとの雑談中に，適切な「ボケ・ツッコミ」発話を行うことができる雑談対話システムの実現への第 1 段階として，ChatGPT のユーモア応答生成能力についてプロンプトベースでの分析を行った．ChatGPT を用いて，対話データの最後の発話に対するボケ発話とツッコミ発話を生成させ，ユーザ評価を行った．1,344 対話について人手で評価を行った結果，ChatGPT は対話によって，人間が面白いと感じるユーモア応答を生成できるということが明らかとなった．また，ボケ発話およびツッコミ発話についても過半数が高い評価を得ていたことから，ChatGPT は適切な「ボケ・ツッコミ」発話を行うことができる雑談対話システムに活用するために，十分なユーモア応答生成能力を持っているということを確認した．さらに分析の結果，ChatGPT が生成するユーモア応答には，いくつかのパターンがあることが分かった．

今後は，今回の生成結果および評価結果をより深く考察し，面白いと感じるボケ発話と適切であると感じるツッコミ発話を自動分類できるような特徴を見つけることを課題とする．また，GPT-4 や ChatGPT 以外の大規模言語モデルの利用についても検討を行う．さらに，ロングターンの雑談で活用する場合，ツッコミ後の発話や発話順番などの設計上の問題が生まれる．そのような問題についても分析を重ね，「楽しい雑談」ができる雑談対話システムの実現を目指す．

8. 謝　　辞

本研究は JSPS 科研費 21K12007 の助成を受けたものである．

文　　献

[1] P. Khooshabeh, C. McCall, S. Gandhe, J. Gratch, and J. Blascovich, “Does it matter if a computer jokes,” CHI ’11 Extended Abstracts on Human Factors in Computing Systems, p.77–86, CHI EA ’11, Association for Computing Machinery, New York, NY, USA, 2011. https://doi.org/10.1145/1979742.1979604

[2] 伊藤大幸，“ユーモアの生起過程における論理的不適合および構造的不適合の役割，” 認知科学，vol.17，no.2，pp.297–312，2010.

[3] 呉健朗，中原涼太，長岡大二，中辻真，宮田章裕，“ボケて返す対話型エージェント，” 日本バーチャルリアリティ学会論文誌，vol.23，no.4，pp.231–238，2018.

[4] 呉健朗，富永詩音，武藤佑太，宮田章裕他，“複数対話型エージェントの役割分担によるユーモア生成システム，” 情報処理学会論文誌，vol.61，no.8，pp.1353–1362，2020.

[5] 呉健朗，長岡大二，中原涼太，宮田章裕他，“文のトピックを考慮した単語置換によるユーモア発話を行う対話型エージェント，” 情報処理学会論文誌，vol.61，no.1，pp.113–122，2020.

[6] 藤倉将平, 小川義人, 菊池英明, “非タスク指向対話システムにおけるユーモア応答生成手法，” 人工知能学会全国大会論文集 第 29 回 (2015) 一般社団法人 人工知能学会，pp.2L5OS07b1–2L5OS07b1 2015.

[7] M. Heck, N. Lubis, B. Ruppik, R. Vukovic, S. Feng, C. Geishauser, H.-c. Lin, C. vanNiekerk, and M. Gasic, “ChatGPT for zero-shot dialogue state tracking: A solution or an opportunity?,” Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), pp.936–950, Association for Computational Linguistics, Toronto, Canada, July 2023. https://aclanthology.org/2023.acl-short.81

[8] M.T.R. Laskar, M.S. Bari, M. Rahman, M.A.H. Bhuiyan, S. Joty, and J. Huang, “A systematic study and comprehensive evaluation of ChatGPT on benchmark datasets,” Findings of the Association for Computational Linguistics: ACL 2023, pp.431–469, Association for Computational Linguistics, Toronto, Canada, July 2023. https://aclanthology.org/2023.findings-acl.29

[9] C. Qin, A. Zhang, Z. Zhang, J. Chen, M. Yasunaga, and D. Yang, “Is chatgpt a general-purpose natural language processing task solver?,” arXiv preprint arXiv:2302.06476, pp.••–••, 2023.

[10] S. Jentzsch and K. Kersting, “ChatGPT is fun, but it is not funny! humor is still challenging large language models,” Proceedings of the 13th Workshop on Computational Approaches to Subjectivity, Sentiment, & Social Media Analysis, pp.325–340, Association for Computational Linguistics, Toronto, Canada, July 2023. https://aclanthology.org/2023.wassa-1.29

[11] 鈴木雅人，新納浩幸他，“日本語 commongen に対する chatgpt の性能調査，” 研究報告自然言語処理 (NL)，vol.2023，no.7，pp.1–6，2023.

[12] H. Sugiyama, M. Mizukami, T. Arimoto, H. Narimatsu, Y. Chiba, H. Nakajima, and T. Meguro, “Empirical analysis of training strategies of transformer-based japanese chit-chat systems,” 2022 IEEE Spoken Language Technology Workshop (SLT)IEEE, pp.685–691 2023.

[13] 安部達雄，“漫才における「ツッコミ」の類型とその表現効果，” 国語学研究と資料，vol.28，pp.48–60，2005.

[14] 宇惠弘他，“ユーモア測定尺度の作成，” 関西福祉科学大学紀要，vol.11，pp.31–40，2008.