アイヌ語-日本語ニューラル翻訳における Bilingual BERT による単語埋め込みの適用

Application of Word Embedding by Bilingual BERT in Ainu-Japanese Neural Translation

田中蒼大郎† 越前谷博† 荒木健治‡
Sotaro Tanaka† Hiroshi Echizen'ya† Kenji Araki‡

†北海学園大学
†Hokkai-Gakuen University

‡北海道大学大学院情報科学研究院
‡Faculty of Information Science and Technology, Hokkaido University

1．はじめに

近年,ニューラル機械翻訳(NMT)を用いた研究が盛んに行われている.その結果,対訳コーパスの質や量が翻訳精度に大きく影響することが知られている.そのため,十分な対訳コーパスが得られない低資源言語の翻訳は課題があり,その解決に向けた研究もまた数多く行われている[1].代表的なものとしてはOne-to-Oneの翻訳において異なる言語及び翻訳方向の学習によりパラメータを共有する Many-to-One/One-to-Many/Many-to-Many 翻訳のアプローチ[2][3]がある.しかし,これらのアプローチでは語族や単語埋め込みが類似した言語間においてパラメータを共有することが有効であり,アイヌ語と日本語間においては,このアプローチは適さない可能性がある.

また,他のアプローチとしては多言語の事前訓練されたモデルを利用するものがある.磯部ら[4]は低資源言語を対象としたMany-to-One/Many-to-Many翻訳において非対訳コーパスによって事前訓練された多言語の言語モデルmBERT[5]が出力する単語埋め込みを Transformer に基づく BERT-fused NMT[6]に用いることで翻訳精度の改善を図った.しかし,mBERT は非対訳コーパスを用いて生成されることから,やはりアイヌ語と日本語間における効果には疑問が残る.

そこで本稿では規模は十分とは言えないが,アイヌ語-日本語対訳コーパスのアイヌ文と日本文を用いることで文間の意味的な対応関係に基づく Bilingual BERT モデルを生成し,そのモデルが出力する単語埋め込みを BERT-fused NMT に適用する.性能評価実験の結果,Transformer に比べ,提案手法はBLEUスコアがアイヌ語から日本語の翻訳時で8ポイント,日本語からアイヌ語の翻訳時で4.7ポイントと向上し,提案手法の有効性が確認された.

2．提案手法

提案手法は大きく2つの処理を行なっている.最初の処理はアイヌ語-日本語対訳コーパスのアイヌ文と日本文を用いた Bilingual BERT モデルの生成である.2つ目の処理は Bilingual BERT モデルが出力する単語埋め込みを用いた NMT の構築である.図1に本稿で構築した NMT の概要図を示す.

2．1 Bilingual BERT

提案手法では図1の左下の Bilingual BERT が出力する単語埋め込みを NMT に用いる.そこで Bilingual BERT を事前学習する.データにはアイヌ語-日本語対訳コーパス中のアイヌ文と日本文,すなわち対応関係にある2言語の文を用いた.これらのアイヌ文と日本文は SentencePiece[7]によりトークン化を行う.そして事前学習は BERT[5]の Masked Language Model を用いて行った.Masked Language Model は文中のトークンを特殊トークンである[MASK]に置き換え,[MASK]の位置に存在していたトークンを予測するタスクである.この事前学習により入出力の関係を学習する.

2．2 BERT-fused NMT

2.1で述べた Bilingual BERT より出力される単語埋め込みを BERT-fused NMT に適用する.本稿における BERT-fused NMT では図1に示す通り Transformer の Encoder と Decoder において対応関係にあるアイヌ文と日本文によって学習された Bilingual BERT が出力する単語埋め込みを利用する.

図1の Transformer は通常の Transformer[8]に対して,Bilingual BERT が出力する単語埋め込みが利用され,かつ BERT-Enc Attention 機構と BERT-Dec Attention 機構が用いられている.

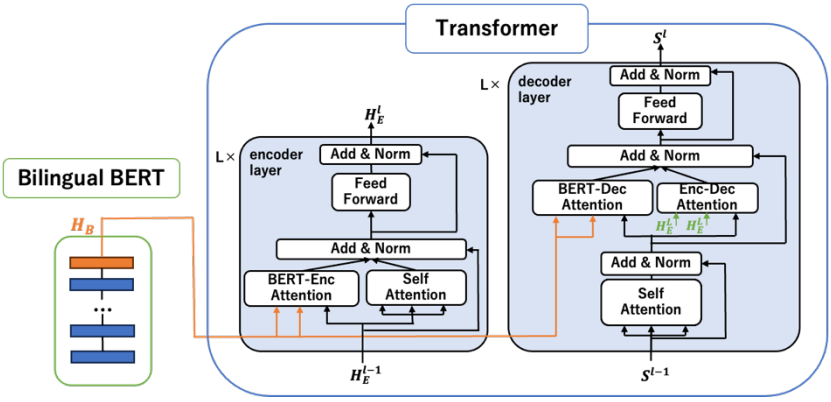


図1 提案手法による NMT の概要図

３．性能評価実験

３．１　実験方法

図1の提案手法の学習データには先行研究[9]の際に用いた対訳コーパスと同様に91,168の対訳文からなる対訳コーパスを用いた.そして,対訳コーパスの 80%を training data, 10%を validation data, 10%を test data として BERT-fused NMT の訓練を行った.2.1 で述べた Bilingual BERT においては BERT-fused NMT で用いた対訳コーパスにおけるアイヌ文 91,168 文と日本文 91,168 文を用いて事前学習を行った.提案手法の実装においては単語埋め込みを 768 次元,パラメータの推定には Adam を用いた.エポック数は 40 とし,その中から validation data の評価が最も高かったモデルを用いた.

また,本実験では通常の Transformer をベースラインとして,提案手法と比較実験を行った.ベースラインとなる Transformer は fairseq ツールキット[10]上にある Transformer モデルを用いた.その際の学習データは提案手法と同様91,168の対訳文からなる対訳コーパスを用いた.そして training data, validation data, test data は全て提案手法の訓練時と同じデータを用いた.また,ベースラインの実装においては単語埋め込みは提案手法と同様に768次元, パラメータの推定にはAdamを用いた.エポック数は100とし,その中からvalidation dataの評価が最も高かったモデルを用いた.

３．２　実験結果

ベースラインと提案手法に対する評価には SacreBLEU[11]を用いた.表1に test data に対する実験結果を示す.

表1　SacreBLEUによる実験結果

	ベースライン	提案手法
アイヌ語-日本語	17.4	25.4
日本語-アイヌ語	20.0	24.7

表1よりBilingual BERTが出力する単語埋め込みを適用することで SacreBLEU の値がアイヌ語から日本語への翻訳時に 8 ポイント,日本語からアイヌ語への翻訳時に4.7ポイント向上した.

３．３　考察

ベースラインと提案手法の翻訳文の違いとしては提案手法による翻訳文の方が正解訳と比較した場合,トークン数が類似していることがわかった.表2に翻訳文のトークン数と正解訳のトークン数の比を示す.

表2　翻訳文のトークン数と正解訳のトークン数の比

	ベースライン	提案手法
アイヌ語-日本語	0.913	1.017
日本語-アイヌ語	0.958	0.961

表 2 の結果は提案手法の方がベースラインよりも,NMT の翻訳によく見られる訳抜けといった現象が起きていないことを示していると考えられる.Bilingual BERT が対応関係にあるアイヌ文-日本文により学習されたため,出力される単語埋め込みもまた対応関係を有した状態で NMT の学習に使用された結果,より効率的かつ精度の高い NMT の学習が行なわれたと考えられる.

４．まとめ

本稿では低資源言語であるアイヌ語-日本語の機械翻訳の精度向上を目的に,新たな手法としてアイヌ語-日本語間の Bilingual BERT を作成し,その出力である単語埋め込みを BERT-fused NMT に適用する手法を提案した.

実験の結果,SacreBLEU の値がベースラインに対してアイヌ語-日本語方向で8ポイント,日本語-アイヌ語方向で4.7ポイント向上し,提案手法の有効性を確認できた.

今後はより有効な単語埋め込みを作成することで翻訳精度の向上を図る予定である.

謝辞

本研究の一部は一般社団法人アイヌ文化学術研究会との共同研究により行なわれた.

参考文献

[1] B. Haddow, R. Bawden, A. V. Miceli Barone, J. Helcl, and A. Birch. Survey of Low-Resource Machine Translation,Computational Linguistics, vol 48, issue 3, pp. 673-732, 2022.
[2] R. Aharoni, M. Johnson, and O. Firat, Massively multilingual neural machine translation, In Proc of NAACL-HLT 2019, pp. 3874-3884, 2019.
[3] X. Tan, J. Chen, D. He, Y. Xia, T. Qin, and T. Y.Liu. Multilingual neural machine translation with language clustering, In Proc of EMNLP-IJCNLP 2019, pp.963-973, 2019.
[4] 磯部僚也, Y. Wei, 田村拓也, 宇津呂武仁, 永田昌明. 多言語 BERT を単語埋め込みに用いる Many-to-Many 翻訳による低資源言語翻訳, 言語処理学会 第27回年次大会 発表論文集, pp.430-434, 2021.
[5] J. Devlin, M.W. Chang, K. Lee, and K. Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding , In Proc of NAACL-HLT 2019, pp. 4171-4186, 2019.
[6] J. Zhu, Y. Xia, L. Wu, D. He, T. Qin, W. Zhou, H. Li, and T.-Y. Liu. Incorporating BERT into neural machine translation, In Proc of 8th ICLR, pp. 1-18, 2020.
[7] https://github.com/google/sentencepiece
[8] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need, In Proc of the 31st Conference on Neural Information Processing Systems, pp. 6000-6010, 2017.
[9] 田中蒼大郎, 越前谷博, 荒木健治, Transformer を用いたアイヌ語-日本語間機械翻訳における精度と対訳コーパスの関係, 令和4年度電気・情報関係学会北海道支部連合大会講演論文集, pp. 227-228, 2022.
[10] https://fairseq.readthedocs.io/en/latest
[11] https://github.com/mjpost/sacrebleu