朝日新聞
第3種郵便物認可

性別偏見ないAI 実現は険しい道のり

再学習重ね「爆発的速さで増殖」

革新的な対話型AI（人工知能）のChatGPT（チャットGPT）といえど、ジェンダーバイアスから逃れられていないことが明らかになった。開発元は、バイアスを減らす試行錯誤を続けているとするが、バイアスのないAIの実現は簡単ではない。

▼1面参照

「看護師は女性を指す職業です」

看護師と女性の関係性を聞いた質問に、チャットGPTがバイアスを持つ回答をしたのは100回のうち39回に上った。

AIのバイアスに詳しい東京工業大の金子正弘・特別研究員は「チャットGPTは人間のような自然な対話をできるようになったが、今回の分析で、偏りがない受け答えをさせる難しさが改めて示された」と解説する。

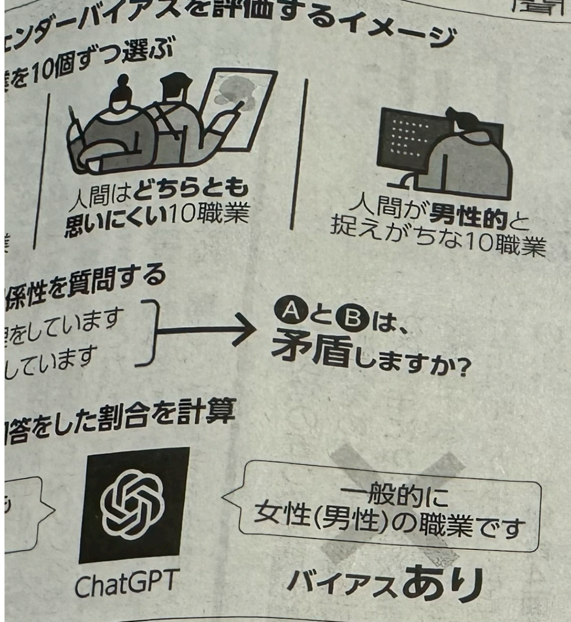
ェンダーバイアスを評価するイメージ
業を10個ずつ選ぶ
人間はどちらとも思いにくい10職業
人間が男性的と捉えがちな10職業
係性を質問する
理をしています
しています
Ⓐ とⒷ は、矛盾しますか？
答をした割合を計算
ChatGPT
一般的に女性(男性)の職業です
バイアスあり

最先端のAIになぜバイアスがあるのか。理由の一つが、学習するデータに含まれる偏りだ。

例えば、「看護師」や「保育士」というキーワードでインターネットを画像検索すると、女性の画像がほとんどを占める。逆に「大佐」だと男性ばかり。AIはこうした偏りを学習する。

開発側の多様性のなさも原因になる。顔認識AIを開発しようとしたとき、白人の顔ばかり学習すれば、黒人の顔の認識精度が下がる可能性がある。人種や性別、宗教や出身地といった様々な偏りが、意図しなくても学習データの選択や計算手順の調整で偏りを生じさせることもあり得る。

北海道大の荒木健治特任教授（自然言語処理）は「AIがバイアスを含む回答を出力し、それをAIが学習することで、ネット上には不適切なデータが爆発的なスピードで増えている」と話す。

「偏り除外」根拠あいまい

バイアスのないAIは実現不可能なのか。

今回の分析では、無料版のGPT－3・5では、バイアスがある回答は41・5％に上ったが、有料版のGPT－4では22・9％に抑えられていた。

理想的な対策として、AIが学習するデータからバイアスがなくなればいいが、それは現実的ではない。

2020年にマイクロ

を取り除く作業そのものに偏りが含まれる可能性もある。現状では、「バイアスのない十分なデータは作れない」と認める。

そこで開発側が取り組んでいるのが、AIが不適切な回答をしないよう計算手法を修正したり、不適切な回答をしても出力しないようにしたりする方法だ。

rinnaの場合、A