Vol.2024-NL-262 No.20
Vol.2024-SLP-154 No.20
2024/12/13

ベクトル間類似度に基づくベクトル変換モデルを用いた低資源言語のためのニューラル機械翻訳

田中蒼大郎[1]　越前谷博[1]　荒木健治[2]

概要: 本稿では低資源言語を対象としたニューラル機械翻訳の精度向上のための新たな手法を提案する.提案手法では原文と訳文の文ベクトル間のコサイン類似度と人手スコアに基づきベクトル変換モデルを構築する.そして,構築したモデルに原文の文ベクトルを入力することで訳文の情報を有するベクトルを生成する.さらに生成されたベクトルをニューラル機械翻訳のエンコーダ側の単語埋め込みに用いることで翻訳精度の向上を図る.本研究ではアイヌ語-日本語間,ベトナム語-日本語間の翻訳実験を行った.性能評価実験の結果,アイヌ語-日本語間の翻訳においては BLEU スコアの平均がベクトル変換モデルを利用することにより向上した. また, ベトナム語-日本語間ではベトナム語から日本語方向の翻訳において BLEU スコアの向上を確認した. この結果より提案手法の有効性が確認された.

キーワード：ベクトル変換モデル,ニューラル機械翻訳

Neural machine translation for low-resource languages using vector transformation models based on similarity between vectors

SOTARO TANAKA[†1]　HIROSHI ECHIZEN' YA[†1]
KENJI ARAKI[†2]

Abstract: In this paper, we propose a new method to improve the quality of neural machine translation for low-resource languages. The proposed method constructs a vector transformation model based on the human score and the cosine similarity between the source and target sentence vectors. The constructed model obtains the vector, which possesses the information of target sentence, using sentence vectors of source and target. Moreover, the model improves the translation quality using the obtained vector for word embedding of encoder in NMT. We performed the translation experiments for Ainu-Japanese and Vietnamese-Japanese. As the results of evaluation experiments, the average of BLEU scores improved using vector transformation model in Ainu-to-Japanese. In Vietnamese-Japanese, BLEU score in Vietnamese-to-Japanese improved by the proposed method. Therefore, we confirmed the effectiveness of the proposed method.

Keywords: Vector transformation model, Neural machine translation

1. はじめに

近年，ニューラル機械翻訳（NMT）の研究が盛んに行われている．その結果，機械翻訳の精度向上は著しい．しかし低資源言語においては学習データの不足などにより，十分な精度が得られるまでには至っていない．そのため，低資源言語における機械翻訳の精度向上のための研究が盛んに行われている．Sennrich ら[1]は目的言語となるモノリンガルコーパスに対し NMT モデルを用いた原言語への逆翻訳を行うことで擬似的な対訳コーパスを生成し，それらを既存の対訳データと併せて学習に用いる，データ拡張による翻訳精度の向上を図った．しかし，低資源言語においては擬似的な対訳文を得るために使用する NMT モデルの精度が不十分な場合には，擬似的な対訳コーパスの精度も不十分となる．また，生成 AI によりデータ拡張を行う研究も行われている．Yang ら[2]は LLM の一つである ChatGPT を用いた data hallucination におけるデータの生成について，その可能性に言及している．しかし，低資源言語においては独立した言語も数多く存在するため生成 AI の使用をゼロショットで行わざるを得ない．その結果，質の高いデータの生成は難しく機械翻訳モデルの学習時への悪影響が問題となる．

一方，低資源言語の機械翻訳においてはデータ拡張とは異なる観点の研究も行われている．Zhu[3]らは Transformer[4]に対して事前学習済みのエンコーダモデルである BERT[5]による出力を使用することで，高度な文脈処理が可能な NMT として BERT-fused NMT を提案している．

本稿では，BERT-fused NMT のエンコーダ側の単語埋め込みにおいて訳文の情報を有したベクトルを適用する，新たな NMT の提案を行う．提案手法では単語埋め込みに用いるベクトルは構築したモデルにより自動生成される．その際，ベクトルは原文の文ベクトルとの間のコサイン類似度が人手による評価スコアと等価になるように生成されるため，原文ベクトルに対応する擬似的な訳文ベクトルと位

1 北海学園大学
Hokkai-Gakuen University
2 北海道大学
Hokkaido University

ⓒ2024 Information Processing Society of Japan

Vol.2024-NL-262 No.20
Vol.2024-SLP-154 No.20
2024/12/13

置づけることができる．このようなベクトルを NMT の単語埋め込みに適用することで入力された原文ベクトルには訳文の情報が既に反映されているため翻訳精度の向上が期待できる．本稿では，低資源言語としてアイヌ語−日本語間及びベトナム語−日本語間を対象とした性能評価実験を行い，その結果，アイヌ語−日本語間においては提案手法により BLEU スコアとして 0.39 ポイントの向上が確認された．また，ベトナム語−日本語間においてもベトナム語から日本語方向では BLEU スコアが 0.73 ポイント向上し，本手法の有効性が確認された．

2. 提案手法

提案手法では原文の文ベクトルに対し，訳文の情報を反映させた文ベクトルを生成し，NMT に適用することで翻訳精度の向上を図る．その際，訳文の情報を有する文ベクトルの生成はフルスクラッチ実装 [1)]のモデルにより行う．以降，本稿ではこのモデルをベクトル変換モデルと記す．提案手法における NMT はベクトル変換モデルの構築とそのモデルの NMT への適用の 2 つの処理から構成される．

2.1 ベクトル変換モデルの構築

ベクトル変換モデルは訳文の文ベクトルである訳文ベクトルとの間のコサイン類似度が訳文に対する評価スコアと一致するように原文のベクトルである原文ベクトルを変換する．すなわち原文ベクトルを訳文の情報を反映した文ベクトルに変換する．図 1 にベクトル変換モデル構築の概要図を示す．

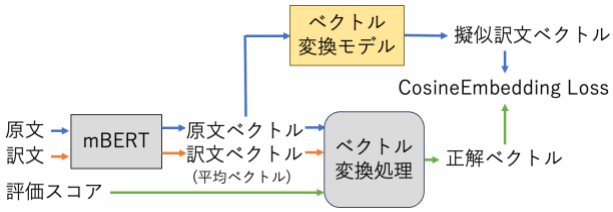


図 1 ベクトル変換モデル構築の概要図

ベクトル変換モデルの構築には原文と訳文のペアと訳文に対する評価スコアを用いる．はじめに，原文と訳文を多言語エンコーダモデルによりベクトルに変換する．本研究では多言語エンコーダモデルとして Multilingual BERT（mBERT）[5]を用いる．その場合，mBERT により得られるベクトルは単語毎のベクトルとなっているため，それらに対して平均ベクトルを求めることで原文ベクトルと訳文ベクトルを得る．次いで，原文ベクトルを入力としてベクトル変換モデルより訳文の情報を含んだベクトルを生成する．本稿ではこのようにベクトル変換モデルより生成される文ベクトルを擬似訳文ベクトルと記す．

本研究は mBERT より得られる原文ベクトルと訳文ベクトルの対応関係が明確ではないため，原文に対する訳文の情報を有する擬似訳文ベクトルの生成が重要であることを前提としている．また，原文とその訳文の対応関係が等価であるとした場合，訳文に対する評価スコアにはコサイン類似度の最大値である 1.0 を用いることも考えられるが，本研究では全ての原文と訳文の対応関係が常に完全な等価であるとは限らないとして，一律には 1.0 を用いないこととしている．評価スコアの決定方法については 2.2 節で詳細を述べる．

生成された擬似訳文ベクトルに対する正解ベクトルはベクトル変換処理にて原文と訳文のベクトル間のコサイン類似度が評価スコアと等価になるように原文ベクトルを変換することで得られる．正解ベクトルの生成については 2.3 節で詳細を述べる．また，ベクトル変換モデルは擬似訳文ベクトルと正解ベクトルに基づく Cosine Embedding Loss を損失関数として学習される．

2.2 評価スコアの算出

図 1 において正解ベクトルを得る際に必要となる評価スコアの算出方法について述べる．評価スコアには人手による評価値を用いることが理想ではあるが，低資源言語の訳文に対して人手による評価値を収集することは困難と考えられるため，本研究では Google 翻訳と多言語の文間類似度を得るためのモデルである mSBERT[6]を用いて擬似的な評価スコアを生成する．mSBERT とは 2 つのニューラルネットワークモデルを Siamese Network と Triplet Networks によりファインチューニングを行うことで高精度な文間類似度を導出するために構築された SBERT モデルを多言語に対応させたものである．具体的には単一言語の SBERT を教師モデル，mBERT を生徒モデルとした知識蒸留[7]により多言語においても精度の高い文間類似度を導出できるように拡張を行ったモデルである．この mSBERT を用いた評価スコアの算出の概要図を図 2 に示す．

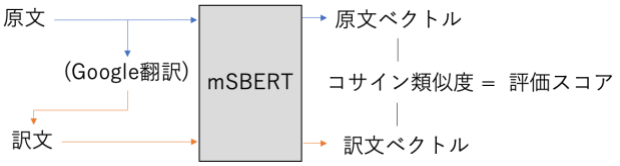


図 2 評価スコア算出の概要図

図 2 より，原文と訳文を mSBERT に入力することで，それぞれのベクトルを得る．しかし，mSBERT は全ての低資源言語に対応しているわけではない．したがって，その場合は原文に対して Google 翻訳から得た他の言語の訳文を用いる．そして，原文と訳文を mSBERT に入力することで．それぞれの文ベクトルを得る．さらに 2 つの文ベクトルを用いてコサイン類似度を算出することでその値を擬似的な評価スコアとする．ただし，得られた擬似的な評価ス

1) 既存のモデルを使用せずにゼロから構築したモデル

ⓒ2024 Information Processing Society of Japan

Vol.2024-NL-262 No.20
Vol.2024-SLP-154 No.20
2024/12/13

コアに対しては全てが高いスコアが得られるとは限らないため一定の閾値を設け，閾値以上のスコアを示す原文と訳文のみをベクトル変換モデルの学習データとして利用する．

2.3 ベクトル変換処理

図 1 に示すベクトル変換モデルについて述べる．ベクトル変換処理の目的はベクトル変換モデルの学習の際の正解ベクトルを生成することにある．正解ベクトルの生成のアルゴリズムを以下に示す．ここで，n 次元の原文ベクトルを $S=(s_1,s_2,\ldots,s_n)$，n 次元の原文ベクトルを $T=(t_1,t_2,\ldots,t_n)$とする．

1. 原文ベクトル S と訳文ベクトル T の全要素について要素毎の比とそれらの平均値を m として求める．そして，要素毎の比と m の差の絶対値の並びを原文ベクトルの変換要素の箇所の決定の際に用いる．要素毎の比から平均 m を引いたものの絶対値の集合 R は以下のようになる．

$$R=\left\{\left|\frac{s_1}{t_1}-m\right|,\ \left|\frac{s_2}{t_2}-m\right|,\ \ldots,\ \left|\frac{s_n}{t_n}-m\right|\right\}$$

2. 原文ベクトル S と訳文ベクトル T のコサイン類似度と評価スコアを比較する．
   2-1 コサイン類似度の方が大きい場合は R の要素の中で値が最小である要素位置 i を取得する．
   2-2 評価スコアの方が大きい場合は R の要素の中で値が最大である要素位置 i を取得する．
3. 2 の処理により変換箇所として決定された原文ベクトルの i 番目の要素に変数 x を付与した原文ベクトルを以下の S'とする．

$$S=(s_1,\ldots,s_i+x,\ldots,s_n)$$

4. ベクトル S'とベクトル T をコサイン類似度の計算式に当てはめる．その際，コサイン類似度の値として，2.2 節で述べた評価スコアを用いる．

$$\frac{\sum_{j=1}^{i-1}(s_j\times t_j)+(s_i+x)\times t_i+\sum_{j=i+1}^{n}(s_j\times t_j)}{\sqrt{\sum_{j=1}^{i-1}s_j^2+(s_i+x)^2+\sum_{j=i+1}^{n}s_j^2}\times\sqrt{\sum_{j=1}^{n}t_j^2}}=\text{評価スコア} \quad (1)$$

5. 式(1)は変数 x を含んでおり，変数 x の二次方程式となる．したがって，この二次方程式の解を求めることでベクトル S'を決定することができ，正解ベクトルが得られる．
   5-1 解が 2 つの実数解の場合，絶対値が小さい方の解を x の値とする．また，解が 1 つの場合はその値を x の値とする．そして，x の値を付与したベクトル S' を正解ベクトルとする
   5-2 解が 2 つの複素数解の場合，実数部分のみを x の値とし，ベクトル S'とベクトル T の間のコサイン類似度を求める．その結果，評価スコアとの差が 0.005 以下となった時点のベクトル S'を正解ベクトルとする．0.005 を超える場合には処理の 1 以降を繰り返す．その際，ベクトル S'を新たなベクトル S とする．

ここで，処理の 2 においてコサイン類似度が評価スコアよりも大きい場合にはコサイン類似度を下げる必要がある．そのためには要素間の比が小さい箇所に着目し，その差を拡大するために R の中で最小値が存在する位置を決定し，その位置に対応する原文ベクトルの要素に変数 x を加える．

また，評価スコアの方が大きい場合には逆に差を縮小させるために， R の中で値が最大の位置を決定し,その位置に対応する原文ベクトルの要素に変数 x を加える．

さらに，複素数解の実部を用いて要素を更新した場合，コサイン類似度を評価スコアと一致させることは困難であるため厳密には正解ベクトルではなく正解ベクトルの近似となる．

2.4 ベクトル変換モデルの NMT への適用

本研究では 2.1 節で述べたベクトル変換モデルを NMT に適用する．NMT には BERT-fused NMT[3]を用いる．BERT-fused NMT は事前学習済みエンコーダモデルの BERT より得られるベクトルをモデル内の BERT-Enc Attention 機構と BERT-Dec Attention 機構に用いる．これらの機構によりエンコーダとデコーダ内で BERT による高精度な文脈情報を使用することができ，より精度の高い翻訳が可能となる．BERT-fused NMT にベクトル変換モデルを適用した本研究における NMT の概要図を図 3 に示す．

図 3 より．ベクトル変換モデルはエンコーダ層の入力として用いる．その際，ベクトル変換モデルの入力は擬似訳文ベクトルであり，文ベクトルとなっているため単語の埋め込みの形状に変換する必要がある．具体的には mBERT より得られる原文の単語ベクトルに基づいて，全単語ベクトルの要素毎の平均が擬似訳文ベクトルと一致するように任意の固定値を原文の全単語ベクトルの同じ位置の要素に加える．例えば擬似文ベクトルが $T'=(t'_1, t'_2, \ldots, t'_n)$, 原文の単語数が m かつそれぞれの単語のベクトルが $W_1=(w_{1\,1}, w_{1\,2},\ldots, w_{1\,n}),\ldots, W_m=(w_{m\,1}, w_{m\,2}, \ldots, w_{m\,n})$, 原文の単語ベクトルの第 1 要素から第 n 要素に加える固定値をそれぞれ $x_1,\ldots, x_n$ とした場合，

$$\frac{(w_{1\,1}+x_1)+(w_{2\,1}+x_1)+\ldots+(w_{m\,1}+x_1)}{m}=t'_1\ ,$$

$$\ldots,$$

$$\frac{(w_{1\,n}+x_n)+(w_{2\,n}+x_n)+\ldots+(w_{m\,n}+x_n)}{m}=t'_n \quad (2)$$

ⓒ2024 Information Processing Society of Japan

Vol.2024-NL-262 No.20
Vol.2024-SLP-154 No.20
2024/12/13

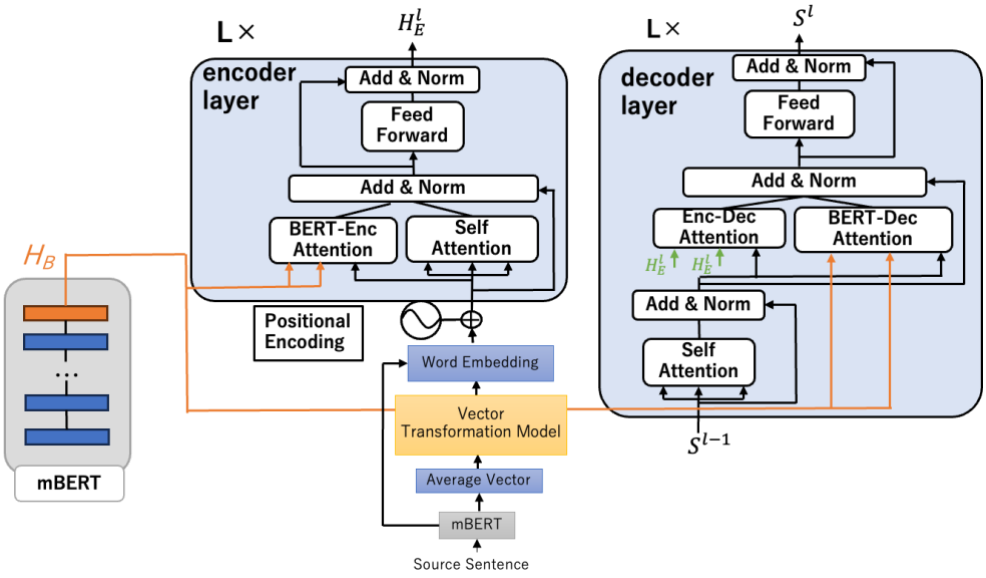


図 3 ベクトル変換モデルを適用した BERT-fused NMT

が成り立つ $x_1, ..., x_n$ の値を求める. そして，単語ベクトル $W_1, ..., W_m$ の各要素にそれぞれ $x_1, ..., x_n$ の値を加えることで擬似訳文ベクトルに対応する単語ベクトルを生成し，BERT-fused NMT のエンコーダ層に入力する.

3. 性能評価実験

本研究では低資源言語の観点よりアイヌ語−日本語間，ベトナム語−日本語間について両方向の翻訳を提案手法及び BERT-fused NMT を用いて行った.

3.1 実験方法

はじめに正解ベクトルを生成するために必要となる評価スコアについて述べる．アイヌ語−日本語間では，翻訳モデルの学習時に使用したアイヌ語−日本語対訳文 91,168 対[8]のうち検証データと評価データを除いた訓練データの対訳文 72,936 を 2.2 節に述べた評価スコアの算出に用いた. その際，アイヌ語は Google 翻訳で扱うことが困難であるため，図 2 に従いアイヌ語の代替言語としてモンゴル語，トルコ語，そして，韓国語を用いて日本語との間で Google 翻訳により翻訳を行い，mSBERT を通して原文ベクトルと訳文ベクトルを得た．アイヌ語は言語学的には独立言語であるが，日本語との共通点もあるため，日本語と文法構造が比較的類似していると考えられる 3 つの言語を用いた．そして，得られた日本語−モンゴル語，日本語−トルコ語，そして，日本語−韓国語のコサイン類似度の平均値を求め，それらが閾値 0.95 より高い場合にその日本文とアイヌ文の対，そして，評価スコアをベクトル変換モデルの構築に用いた. また，ベトナム語−日本語間においても正解スコアの生成に使用するデータには翻訳モデル学習時の対訳文 20,101 対[9]のうち訓練データである対訳文 16,081 を 2.2 節の評価スコアの算出に適用した．その際，ベトナム語は mSBERT 構築時の学習データに含まれているため Google 翻訳は用いない．また，コサイン類似度に対する閾値には 0.9 を用いた．この閾値より高いコサイン類似度を示した，ベトナム文と日本文の対，そして，評価スコアをベクトル変換モデルの構築に用いた．その結果，ベクトル変換モデルはアイヌ語−日本語間の対訳文より訓練データ 4,787 文, 検証データ 1,000 文の合計 5,787 の対訳文とそれらに対する評価スコアを用いて構築した．また，ベトナム語−日本語間の対訳文より訓練データ 5,543 文，検証データ 1,000 文の合計 6,543 の対訳文とそれらに対する評価スコアを用いてベクトル変換モデルを構築した.

ベクトル変換モデルのアーキテクチャには入力層(ニューロン数:768)，2 つの中間層(ニューロン数:1536(=768×2)と 768)，そして，出力層(ニューロン数:768)からなる多層パーセプトロンを用いた．入力層と出力層のニューロン数は mBERT より得られるベクトルの次元数に合わせ 768 とした.

また，翻訳モデルにおいてはベクトル変換モデルを用いた BERT-fused NMT，ベクトル変換モデルを用いない BERT-fused NMT 共にアイヌ語−日本語間では 91,168 対[8]，ベトナム語−日本語では 20,101 対[9]の対訳コーパスに対して 8:1:1 の割合で，訓練データ，検証データ，そして評価データ用に分割してモデルを構築した．本稿ではベクトル変換モデルを用いない BERT-fused NMT をベースラインとして用いた.

3.2 実験結果

提案手法とベースラインの 2 つの NMT が生成する訳文に対しては自動評価尺度である SacreBLEU[10]を用いて評価を行った．アイヌ語−日本語間の BLEU スコアを用いた比較実験の結果を表 1 に，ベトナム語−日本語間の BLEU スコアを用いた結果を表 2 に示す. また，提案手法とベースラインが出力した訳文の例を表 3 に示す.

ⓒ2024 Information Processing Society of Japan

Vol.2024-NL-262 No.20
Vol.2024-SLP-154 No.20
2024/12/13

表 1 日本語–アイヌ語間の BLEU スコア

	アイヌ語から日本語	日本語からアイヌ語	平均
提案手法	24.52	33.36	28.94
ベースライン	24.89	32.20	28.55

表 2 日本語–ベトナム語間の BLEU スコア

	ベトナム語から日本語	日本語からベトナム語	平均
提案手法	9.42	7.79	8.61
ベースライン	8.69	8.60	8.65

表 3 翻訳例

アイヌ語から日本語		
翻訳例 1	原文	[UNK] toy pan aun pe we n pan aun pe
	参照訳文	「ひどいパナウンペ、悪いパナウンペ。
	提案手法	「ひどいパナウンペ、悪いパナウンペ
	ベースライン	「ひどいパナウンペ
翻訳例 2	原文	a = kot ekt uri ri kon no kira ho rka kira
	参照訳文	手を伸ばすと逃げて、逆さに逃げて
	提案手法	手を差し出すと逃げて逃げて逃げて

適用によりBLEUスコアが向上した．これはベクトル変換モデルにより生成された擬似訳文ベクトルに訳文の情報を反映させることができたためと考えられる．それに対して，ベトナム語−日本語間においては BLEU スコアの平均はベースラインに比べて 0.04 ポイント低かった．ベトナム語から日本語方向の翻訳においては提案手法のBLEUスコアがベースラインを上回っているためベクトル変換モデルが有効であると考えられる． 日本語からベトナム語の翻訳におけるBLEUスコアについてはベースラインの方が高いため，今後検討及び改良を行う予定である. また，表 3 の翻訳例より，提案手法により翻訳精度が向上した翻訳例 1 と翻訳例 3 ではベースラインの翻訳結果に比べNMTの問題として指摘されている訳抜けの現象が少ないことがわかる. 一方，翻訳例 2 と翻訳例 4 では何度も同じ単語を出力する重複訳が発生している．したがって, 提案手法は重複訳の問題を抱えており，これについては今後の課題としたい.

4. まとめ

本稿では低資源言語における NMT の翻訳精度向上のための新たな手法を提案した．具体的にはエンコーダモデルより得られる原文の文ベクトルに対して訳文の情報を反映させることを目的に擬似的な訳文の文ベクトルを生成するベクトル変換モデルを構築した．そして，その有効性を検証するために，ベクトル変換モデルを BERT-fused NMT に適用し，アイヌ語−日本語間，ベトナム語−日本語間の翻訳実験を行った．性能評価実験の結果，アイヌ語−日本語間の翻訳において BLEU スコアが提案手法により向上した．ベトナム語−日本語間においてもベトナム語から日本語間の翻訳においてはBLEUスコアが向上し，提案手法の有効性が確認された.

今後はベクトル変換モデルの改良により翻訳精度の向上を図る予定である．また，他の低資源言語を用いた性能評価実験を行う予定である.

謝辞

本研究の一部は一般社団法人アイヌ文化学術研究会との共同研究により行なわれた.

参考文献

[1] R. Sennrich, B. Haddow, and A. Birch. Improving Neural Machine Translation Models with Monolingual Data. In Proc of the 54th Annual Meeting of the Association for Computational Linguistics ,pp. 86–96, 2016.

[2] W.Yang, G.Nicolai, Neural Machine Translation Data Generation and Augmentation using ChatGPT. arXiv, 2023. arXiv:2307.05779.

[3] J. Zhu, Y. Xia, L. Wu, D. He, T. Qin, W. Zhou, H. Li, and T.Y. Liu. Incorporating BERT into neural machine translation, In Proc of 8th ICLR, pp. 1–18, 2020.

[4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need, In Proc of the 31st Conference on Neural Information Processing Systems, pp. 6000–6010, 2017.

[5] J. Devlin, M.W. Chang, K. Lee, and K. Toutanova.BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, In Proc of NAACL-HLT 2019, pp. 4171-4186,2019.

[6] N. Reimers, I. Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks, In Proc of EMNLP-IJCNLP 2019, pp.3982–3992, 2019.

[7] N. Reimers and I. Gurevych. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. In Proc. of EMNLP, pp. 4512–4525, 2020.

[8] 田中蒼大郎，越前谷博，荒木健治，Transformer を用いたアイヌ語-日本語間機械翻訳における精度と対訳コーパスの関係，令和 4 年度電気・情報関係学会北海道支部連合大会講演論文集, pp. 227-228, 2022.

[9] H. Riza, M. Purwoadi, Gunarso, T. Uliniansyah, A. A. Ti, S. M. Aljunied, L. C. Mai, V. T. Thang, N. P. Thai, V. Chea, R. Sun, S. Sam, S. Seng, K. M. Soe, K. T. Nwet, M. Utiyama, and C. Ding. Introduction of the Asian language treebank. In Proc of. 19th O-COCOSDA, pp. 1–6, 2016.

[10] https://github.com/mjpost/sacrebleu

ⓒ2024 Information Processing Society of Japan