常識知識グラフによる知識拡張プロンプトの有効性

Effectiveness of Knowledge Augmentation Prompts from Commonsense Knowledge Graphs

岡田憩 *1　ジェプカ ラファウ *2　荒木健治 *2
Kei Okada　Rafal Rzepka　Kenji Araki

*1北海道大学 大学院情報科学院
Graduate School of Information Science and Technology, Hokkaido University

*2北海道大学 大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University

Before large language models (LLMs), models such as BERT were combined with external knowledge such as knowledge graphs to improve performance on various tasks. However, LLMs can achieve similar performance without the need to use external knowledge, by changing the input (prompt). In this study, we investigated the effectiveness of knowledge augmentation with knowledge graphs for LLMs. In the Japanese commonsense reasoning task JCommonsenseQA, we added knowledge from the commonsense knowledge graph ConceptNet to the input and tested five language models in mostly zero-shots settings. As validation data, we randomly selected 100 questions from the JCommonsenseQA train set. Then, we converted the ConceptNet knowledge into natural sentences, and extracted the top 10 most similar knowledge for each question. These 10 knowledge were added to the input prompt, and given to LLMs. Evaluation was done using exact match, and accuracy was calculated. Our experiment showed that the accuracy decreased or remained the same for all models when knowledge augmentation was applied. This suggests that knowledge augmentation prompt using commonsense knowledge graphs may not be effective in LLM.

1. はじめに

大規模言語モデル (LLM) は様々なベンチマークにおいて高い性能を出しており，追加学習を行わないゼロショットでも高い性能を出すことが報告されている．例えば，JCommonsenseQA という常識推論タスクにおいて，dev セットの人間のスコアは 0.986 であり [Kurihara 22]，GPT-4 はゼロショットで 0.9 を超える正解率が報告されている *1．LLM 以前のモデルでは，ベンチマークを解くにあたって，知識グラフなどの外部知識と組み合わせた手法が提案された [Yasunaga 21] が，ゼロショットで高い性能を出せる現在の言語モデルにおいてはその必要がないことが考えられる．

そこで，本研究では，常識知識グラフの知識を入力に加える知識拡張プロンプト手法を提案し，LLM において当手法が有効的か検証する．

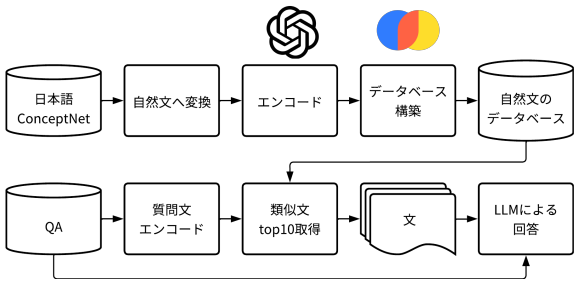


図 1: 提案システム図

連絡先: 岡田憩，北海道大学大学院情報科学院，北海道札幌市北区北 14 条西 9 丁目 北海道大学 大学院情報科学院 言語メディア学研究室 7-09，keiokada@ist.hokudai.ac.jp

*1 https://wandb.ai/wandb-japan/llm-leaderboard/reports/Nejumi-Leaderboard-Neo--Vmlldzo2MTkyMTU0

2. 関連研究

2.1 常識知識グラフ

常識知識グラフとは，知識グラフの一種であり，そのグラフ G は次の式で表される．

$$G = (N, R, E), E = (N, R, N)$$

N はノード (node) を示し，常識知識グラフの場合は物象 (entity) を示す．R はノード同士の関係性 (relation) をす．E はノードと関係性のタプルのことで，エッジ (edge) と呼ばれる．ConceptNet の場合は，assertion (主張，表明) とも言う．ノードが複数のエッジを持つことで，グラフを成すことができる．

常識知識グラフの代表例に，ConceptNet [Speer 18]，ATOMIC [Sap 19] がある．前者は物の概念 (concept) を記述したものであり，後者はイベントの因果関係を記述したものである．ConceptNet は多言語対応しており，10 以上の言語の知識タプルを持つ．ATOMIC は日本語のものを作成し，LLM で拡張した [井手 23, 村田 23] ものがある．

2.2 知識拡張

知識拡張には，拡張知識をエンコードするものと，プロンプトとして入力に加える手法がある．LLM 以前の研究では，関係する知識グラフのサブグラフを抽出し，エンコードし，言語モデルの結果と組み合わせる手法も提案されている [Yasunaga 21]．

LLM 以降では，エンコードせずに，文として言語モデルに追加する Retrieval-Augmented Generation (RAG) と呼ばれる手法が注目されている．RAG の論文 [Lewis 20] で提案されている手法では retriever (query encoder, document indexer) と generator の 2 つの要素を持ち，fine-tuning で retriever, generator の両方のパラメータを更新する．

RAG の要素をパラメータ更新しないで知識拡張を行う試みも行われている．KAPING [Baek 23] では知識グラフの情報を固定した retriever で取得し，直接プロンプトに加え，固定

次の情報は有用かもしれません：
- コピーは印刷することができる。
- コピーは絵を印刷することができる。
- コピーは複写することができる。
- コピー機はコピーすることができる。
- プリンタはコピーすることができる。
- プリンタは複写することができる。
- プリンターは複写することができる。
- 紙はすることができる。
- プリントは複製である。
- 印刷は複製である。

図 2: 知識拡張プロンプトの例．“次の情報は有用かもしれません：” の後に取得されたエッジを列挙する．なお言語モデルへ入力する入力文は：(例 +) 知識拡張プロンプト + 指示 + 質問文と選択肢

した generator で QA タスクを行っている．結果としては，プロンプトに加える情報が QA タスクに関連していれば正解できるものの，誤っている場合は，悪影響を及ぼすと報告されている．

3. 提案手法

本研究では，Baek らの KAPING に倣い，日本語の常識推論 QA タスクにおいて知識グラフの情報をプロンプトに追加する知識拡張手法の有効性を調査する．なおシステムは図 1 のように，データベースと質問応答システムから成る．

常識知識グラフのデータベースは，知識グラフのエッジを自然文へ変換，自然文となったエッジをエンコードし，構築した．知識グラフは ConceptNet のエッジのうち，両ノードが日本語であるものを使用し，エッジから自然文への変換は [Otani 18] らのテンプレート [*2]，埋め込み表現にするドキュメントエンコーダーは text-embedding-ada-002[*3]，データベース構築は Chroma[*4] を使用した．

各 QA タスクにおいての知識拡張の処理は次の通りである．質問を埋め込み表現にエンコードし類似文を検索し，結果を知識拡張プロンプトとして入力に加え，言語モデルによって質問への回答を生成する．

質問をエンコードするクエリエンコーダーは Chroma の.query() で text-embedding-ada-002 を使い，エンコードした質問との二乗 L2 ノルムが小さい top10 のエッジを検索をした．結果は図 2 のように羅列し，入力に追加した．LLM は以下のモデルを使用した．

- gpt-4-0613
- gpt-3.5-turbo-1106
- gpt-3.5-turbo-0613
- japanese-stablelm-instruct-alpha-7b
- ELYZA-japanese-Llama-2-7b-instruct

*2 https://github.com/notani/CLKP-MTKBC/blob/master/src/surface_text/get_surfaceText_ja.py
*3 https://platform.openai.com/docs/guides/embeddings/embedding-models
*4 https://www.trychroma.com/

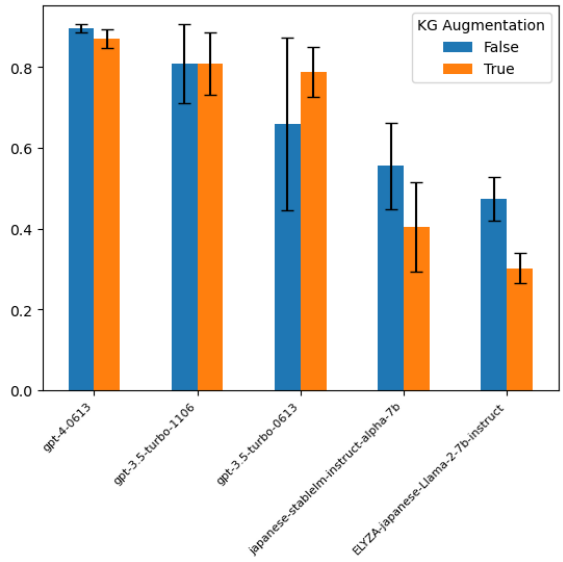


図 3: 知識拡張による正解率の変化

言語モデルへは GPT シリーズは 0-shot で行った．その他のモデルでは，0-shot 時に選択肢から回答が選択されないこともあったため，1-shot で行った．

4. 実験

提案手法を検証するため，JCommonsenseQA の train データセットからランダムな 100 問をテストセットとし，実験を行った．実験は各セットアップで 10 回行った．ただし，gpt-4-0613 のみ，資金的考慮より各セットアップで 3 回行った．

4.1 セットアップ

手法の結果を比較するため，以下のセットアップで実験を行った．提案手法である知識拡張，chain-of-thought プロンプト，temperature を変え，各モデルで計 8 パターン実験した．

- 知識拡張: あり / なし
- chain-of-thought プロンプト: あり / なし
- temperature: (0, 0.01) / 1

chain-of-thought プロンプトは複雑な課程を踏むタスクにおいて，有効性が報告されている手法 [Wei 23] である．本実験では，知識拡張プロンプトとの比較対象，また知識拡張プロンプトとの組み合わせの評価のため導入した．具体的には，“推論課程を明示して、” を指示の前に加えた．

temperature の影響も調べるため，temperature=1 に加え，GPT シリーズでは最低の 0 を使用し，その他のモデルでは 0 は設定できないため，0.01 を使用した．

4.2 評価指標

回答の正誤は exact match で判定し，正解ラベル以外の出力は不正解とした．

なお，chain-of-thought プロンプトを行ったセットアップでは，判定までに 1 ステップを挟んでいる．GPT シリーズでは，理由の後回答を出力する傾向が見られたため，回答を判定するための聞き直しを行い，その出力を回答とした．その他のモデルでは 1-shot で，出力形式を ‘‘回答\n\n 回答の理由’’ と指定しているため，出力の最初の改行までを回答とした．

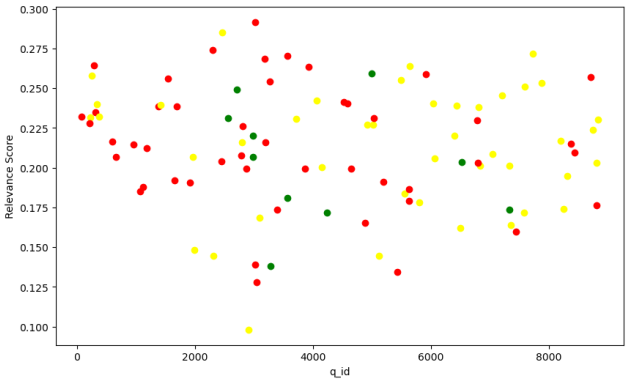


図 4: ELYZA-japanese-Llama-2-7b-instruct における関連度 (Relevance score) と同じセットアップで 10 回実行した際の正答頻度の比較．赤：毎回不正解，緑：毎回正解，黄：それ以外．q_id は JCommonsenseQA の質問 ID.

4.3 結果

図 3 に実験の結果を示す．gpt3.5-turbo-0613 を除く全てのモデルのおいて，提案手法の知識拡張を行ったことにより正解率が減少，あるいは同程度であった．

5. 考察

5.1 拡張プロンプトと QA 質問の関連度

Baek らの先行研究 [Baek 23] では，retriever が関連する情報を取得できない場合，QA タスクでのスコアが低下し，知識拡張として与える情報の質問との関連度が重要だと報告されている．よって，関連度を評価する指標が必要である．しかし，本実験で使用した JCommonsenseQA には基準となるような正解エッジ群はないため，以下の式 (1) を用いた関連度の評価を試みた．

$$\text{関連度} = \text{ランダムなエッジ 10 個と質問の距離の平均} - \text{取得したエッジ 10 個と質問の距離の平均} \quad (1)$$

本研究では関連するエッジの取得に，質問文との二乗 L2 ノルムで近いもの top10 を使っている．ランダムに取得したエッジの距離と比べることで，取得したエッジの相対的な関連度を評価できると予想していた．また，Baek らの報告より，質問と関連度の高いエッジを抽出できていれば，質問に正答できると仮定し，各質問に対して取得したエッジの関連度を各質問での正答頻度と比較した．ELYZA-japanese-Llama-2-7b-instruct にて関連度を評価した結果を図 4 に示す．なお，chain-of-thought はなし，temperature は 1 である．

関連度と正答頻度に相関があれば，正答率が高い場合 (緑色) に関連度も高いと予想されるが，図 4 の結果より，関連度と正答率には明確な相関はない．

これが意味することは 3 つ考えられる：

A) 式 1 で定義した関連度が取得したエッジの関連性を正しく評価できていない．

B) 提案手法においては関連するエッジを取得できておらず，プロンプトにノイズを入れている．

5.1.1 関連度の指標が適切ではない

A について，式 1 では，埋め込み表現の距離で評価しており，JCommonsenseQA の質問を**解く**のに関連するエッジかどうかは考慮できていない．そのため，語彙的には関連していても，QA を解くこととは関連していないこともある．例えば，関連度が高い，問 3016 では，庭にあるものが取得できているものの，庭にあって水を汲むものは取得できておらず，正解である “井戸” にたどり着けていない．これは **5.1** の B にもつながっており，関連性が低い場合，取得したエッジが問題を解くにあたってノイズになっていることも考えられる．

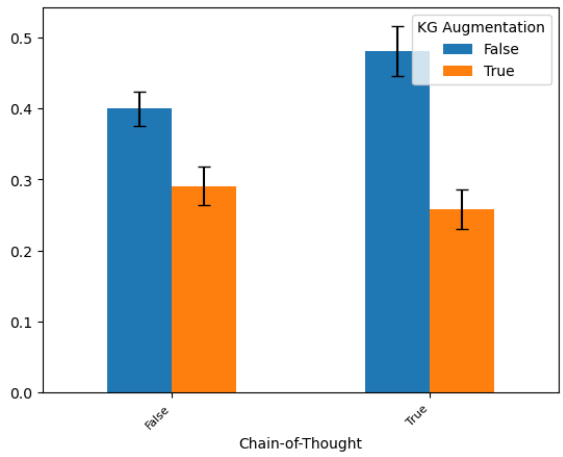


図 5: 知識拡張における chain-of-thought ありなしによる正解率の変化．モデルは ELYZA-japanese-Llama-2-7b-instruct で temperature は 1．chain-of-thought あり (右) のときに知識拡張を行う (橙) とさらに正解率が下がる．

> 問 3016：“昔水を汲むのに各家庭の庭にあった物は?”
>
> 取得したエッジ：
>
> お水は園庭にある．お水は庭にある．噴水は庭にある．噴水は庭園にある．水は園庭にある．水は庭にある．水は庭園にある．水槽は園にある．水源は田園にある．水やりは庭の一部分である．
>
> 回答：庭 / 庭園 / 水槽 / 水やり

このような問題があるため，知識取得において，埋め込み表現の距離だけを用いるのは適切ではないと考えられる．

5.2 chain-of-thought の知識拡張への影響

図 5 にあるように，chain-of-thought (CoT) ありの場合には知識拡張の有無による正解率の差が大きく，知識拡張による悪影響が大きいと考えられる．例えば，temperature=1 の条件のもと，CoT なしでは知識拡張を行うことによって，全 10 回正解から少なくとも一部不正解に変化した質問は 3 問 [*5] にとどまるものの，CoT ありの場合は 13 問 [*6] に増える．

5.3 gpt3.5-turbo-0613 の結果について

図 3 において，gpt-3.5-turbo-0613 のみ，知識拡張によって正解率が改善している．しかし，これは知識拡張なしでの CoT の正解率が低いことによって相対的に良く見えているだけだと考えられる．図 6 にあるように，gpt3.5-turbo-0613 では CoT による正解率の下落幅が他より大きく，およそ半分になっている．この理由の 1 つは，CoT の結果を抽出するため

*5 q_id: 4520, 8254, 7358
*6 q_id: 288, 7329, 2562, 961, 4997, 2985, 2795, 1423, 7358, 6069, 6521, 2812, 8254

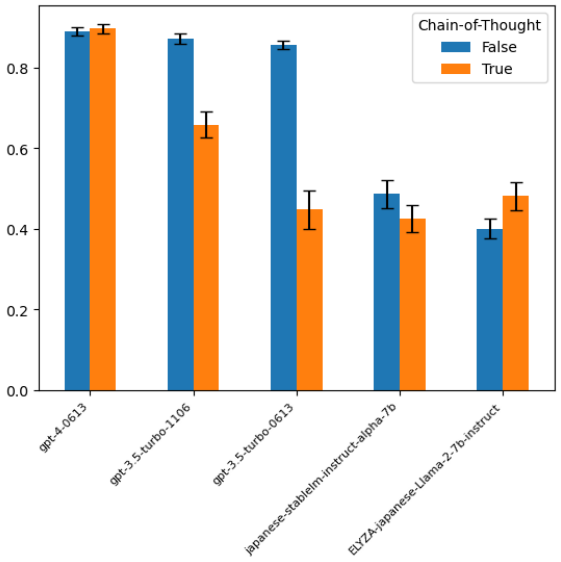


図 6: chain-of-thought の有無によるモデルの正解率の変化. 知識拡張はなし，temperature は 1 の場合.

の言い直し [*7] による悪影響である．この言い直しによって，全 100 問中 31-48 個の回答は「です。」で終わり，半数近くが exact match で不正解と判定されている．よって，言い直しのプロンプト及び手法，および，判定方法の改善が必要である．

しかし，興味深いことに，同じプロンプト，アルゴリズムで検証した gpt-4-0613 および gpt-3.5-turbo-1106 では CoT 時の正解率の下落幅はそこまで大きくない．

6. おわりに

本研究では，常識知識グラフによる知識拡張プロンプトの有効性を ConceptNet の日本語部分と JCommonsenseQA を用いて検証した．本提案手法では，質問文と類似した ConceptNet のエッジを取得し，プロンプトへ追加し QA タスクを解いた．結果，ほぼ全てのモデルで知識拡張による正解率の減少が見られた．

今後は，質問文に適切な知識取得のための関連度指標の検証を行う．また，消去法 [Balepur 24] などの回答戦略，JCommonsenseQA 以外のデータセットでの知識拡張プロンプトの有効性の検証を行う．

参考文献

[Baek 23] Baek, J., Aji, A. F., and Saffari, A.: Knowledge-Augmented Language Model Prompting for Zero-Shot Knowledge Graph Question Answering, in Dalvi Mishra, B., Durrett, G., Jansen, P., Neves Ribeiro, D., and Wei, J. eds., *Proceedings of the 1st Workshop on Natural Language Reasoning and Structured Explanations (NLRSE)*, pp. 78–106, Toronto, Canada (2023), Association for Computational Linguistics

[Balepur 24] Balepur, N., Palta, S., and Rudinger, R.: It's Not Easy Being Wrong: Large Language Models Struggle with Process of Elimination Reasoning (2024)

[Kurihara 22] Kurihara, K., Kawahara, D., and Shibata, T.: JGLUE: Japanese General Language Understanding Evaluation, in *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pp. 2957–2966, Marseille, France (2022), European Language Resources Association

[Lewis 20] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D.: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, in Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., and Lin, H. eds., *Advances in Neural Information Processing Systems*, Vol. 33, pp. 9459–9474, Curran Associates, Inc. (2020)

[Otani 18] Otani, N., Kiyomaru, H., Kawahara, D., and Kurohashi, S.: Cross-lingual Knowledge Projection Using Machine Translation and Target-side Knowledge Base Completion, in *Proceedings of the 27th International Conference on Computational Linguistics*, Santa Fe, New Mexico USA (2018)

[Sap 19] Sap, M., Bras, R. L., Allaway, E., Bhagavatula, C., Lourie, N., Rashkin, H., Roof, B., Smith, N. A., and Choi, Y.: ATOMIC: An Atlas of Machine Commonsense for If-Then Reasoning, *ArXiv*, Vol. abs/1811.00146, (2019)

[Speer 18] Speer, R., Chin, J., and Havasi, C.: ConceptNet 5.5: An Open Multilingual Graph of General Knowledge (2018)

[Wei 23] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., and Zhou, D.: Chain-of-Thought Prompting Elicits Reasoning in Large Language Models (2023)

[Yasunaga 21] Yasunaga, M., Ren, H., Bosselut, A., Liang, P., and Leskovec, J.: QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering, in Toutanova, K., Rumshisky, A., Zettlemoyer, L., Hakkani-Tur, D., Beltagy, I., Bethard, S., Cotterell, R., Chakraborty, T., and Zhou, Y. eds., *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 535–546, Online (2021), Association for Computational Linguistics

[井手 23] 井手竜也, 村田栄樹, 堀尾海斗, 河原大輔, 山崎天, 李聖哲, 新里顕大, 佐藤敏紀：人間と言語モデルに対するプロンプトを用いたゼロからのイベント常識知識グラフ構築, 言語処理学会第 29 回年次大会 (2023)

[村田 23] 村田栄樹, 井手竜也, 榮田亮真, 河原大輔, 山崎天, 李聖哲, 新里顕大, 佐藤敏紀：大規模言語モデルによって構築された常識知識グラフの拡大と低コストフィルタリング, 言語処理学会第 29 回年次大会 (2023)

*7 “{ 回答出力 } つまり答えは：”