DanStoデータセットを用いた大規模言語モデルの否定理解の性能評価

Performance Evaluation of Large-scale Language Model on Negation Understanding using DanSto Dataset

阿部 有紗[*1] Arisa Abe
ジェプカ ラファウ[*2] Rafal Rzepka
荒木 健治[*2] Kenji Araki

[*1] 北海道大学 大学院情報科学院
Graduate School of Information Science and Technology, Hokkaido University

[*2] 北海道大学 大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University

This research aims to investigate the performance of large language models by conducting experiments using a Japanese story dataset. For this purpose, we utilized recently developed DanSto dataset consisting of approximately 9,000 sets containing 5-sentence stories. Various tests were conducted, such as swapping affirmations and negations in the concluding sentences and creating new endings, to assess whether large language models can correctly choose the appropriate final sentence. The results of this study revealed that some current large language models face difficulties in understanding negations in stories written from scratch in Japanese language. Future challenges include experiments on causality for story comprehension and the automatic expansion of the DanSto dataset using generative models.

1. はじめに

近年，大規模言語モデルの進化が著しく，その性能向上が注目を集めている．代表的な言語モデルとして OpenAI 社が開発したモデルである GPT-3 [Brown 20]や GPT-4 [Achiam 23]が挙げられる．これらの GPT（Generative Pre-trained Transformer）シリーズはその先進的なアーキテクチャと大規模なトレーニングデータにより，自然言語生成や理解において優れた成果を収めている．本研究では，GPT シリーズの言語モデルに焦点を当て，その性能をより詳細に調査することを目的としている．GPT シリーズはその複雑な構造や学習された知識により，言語理解のタスクにおいて高い性能を発揮することが期待されているが，具体的なタスクや言語における性能の特徴についてはまだ明確には解明されていない．

特に，自然言語処理における否定処理の精度は依然として向上の余地がある．否定文は文脈において意味が逆転するため，これを正確に理解することは自然言語処理において必要不可欠である．しかし，この問題に関する研究や実用的な適用においては未だ充分な進展が見られていない．加えて，日本語における言語モデルの性能調査についても注目が必要である．多くの言語モデルの研究が英語に焦点を当てている中，日本語においても同様に高性能なモデルが求められている．しかしながら日本語での性能調査は限られており，特に否定理解に関する研究は未だに不足している．

本研究ではこの課題に着目し，Rzepka らが開発した常識理解に焦点を当てた日本語データセットである DanSto データセット [Rzepka 24] を活用して，GPT シリーズの大規模言語モデルが否定理解においてどのような性能を発揮するかを調査した．

2. 関連研究

Hossain ら[Hossain 22]は自然言語処理において頻繁に使用されるコーパスにおいて肯定文に比べて否定文の登場頻度が少ないことからモデルが適切に否定を処理することができないことを指摘している．[Kassner 20]らは事前学習済みモデルが英語の穴埋めタスクにおいて否定を含む質問（"Birds cannot [MASK]"）と否定を含まない質問（"Birds can [MASK]"）を区別していないことを示した．

栗原ら[栗原 22]は事前学習モデルの評価するためのベンチマークである JGLUE を作成した．[Rzepka 24]らは文脈理解度を評価するためにタイトルと 5 文のストーリーを含む約 9,000 セットからなる日本語データセット DanSto を作成した．

3. 評価データ作成

DanSto のデータにはもっともらしい結末文のラベルついているがテストセットに否定の結末文が含まれておらず，JGLUEも否定に注目したものではないため DanSto ストーリーを元にして新たな評価セットを作成した．新たな評価セット作成の目的は，言語モデルが与えられたストーリーの結末文が肯定文か否定文であるか文脈を考慮して正確に判定することができるかを調査するためである．

3.1 新たな結末文の作成

DanSto データセットの第5文目に当たる文（以下，結末文と記す）は複雑な文が多かったため（例:弾は店員にはあたらず，強盗は駆け付けた警官に取り押さえられた），第一著者が新たに簡単な結末文（例:店員は弾を避けた)を作成した．これにより，文中に含まれる副詞が予測のヒントになることを防いだ(例:文中に副詞“じわり”が含まれると文末は肯定文に限定されてしまう)．

3.2 結末文を肯定文と否定文の2種類に変更

新たな評価セットにおいて，各結末文に対して肯定文と否定文の2種類を用意した（例: 店員は弾を避けた，店員は弾を避けなかった）．これにより，モデルが結末文を予測する際の選択肢とした．

連絡先:阿部有紗，北海道大学大学院情報科学院，札幌市北区北18条西13丁目，arisa.abe.aa@gmail.com

表 1.作成したデータセットの例（太字は正解となる結末）

タイトル	ストーリー	正しい結末文	間違った結末
「子供が遊びで水風船の爆弾を作る」	子供が公園で友達と遊んでいた．友達は水風船を持っていた．蛇口に水風船を付け，ふくらませて爆弾を作った．水風船の爆弾をぶつけあって遊んだ．	**二人はびしょびしょになった．**	二人はびしょびしょにならなかった．
「子供がストローを指してオレンジジュースを飲む」	子供はグラスに入ったオレンジジュースを注文した． 子供はグラスに入ったオレンジジュースを注文した．子供はグラスを上手に持つことができなかった． 子供はストローをもらった．ストローでオレンジジュースを飲んだ．	**子供はジュースをこぼさなかった．**	子供はジュースをこぼした．

表 2.実験に使用したプロンプト

system prompt	user prompt 1	user prompt 2
以下の「子供が遊びで水風船の爆弾を作る」についてのストーリーを読んで続きの文章を選択してください。解答は A か B で答えてください。	A) 二人はびしょびしょになった． B) 二人はびしょびしょにならなかった．	A) 二人はびしょびしょにならなかった． B) 二人はびしょびしょになった．

3.3 データ数

新たな評価セットは肯定文を正解とするデータと否定文を正解とするデータをそれぞれ 100 セットずつ，合計 200 セット作成した．

4. 実験

4.1 実験設定

使用した言語モデルは GPT シリーズの 6 つのモデル，具体的には gpt-4-0125-preview，gpt-4-1106-preview，gpt-4-0613，gpt-3.5-turbo-0125，gpt-3.5-turbo-1106，gpt-3.5-turbo-0613 を使用した．すべての実験は zero-shot で行い，temperature=0，max tokens=1，日本語のプロンプトを設定した．Recency bias により大規模言語モデルが後方の選択肢を選ぶ傾向にある[Gupta 23]ことから，前半の選択肢を正解とするプロンプト（user prompt 1）と後方の選択肢を正解とするプロンプト（user prompt 2）の 2 種類を使用した．実験は各モデル，各プロンプトにおいて 3 回ずつ行い，正解率の平均を取った．なお，実験に使用したプロンプトを 表 2 に示す．

4.2 実験結果

以下に各モデルの正解率を示す．

表 3.各モデルの正解率

モデル名	正解率
pt-4-0125-preview	0.881
gpt-4-1106-preview	0.890
gpt-4-0613	0.873
gpt-3.5-turbo-0125	0.726
g pt-3.5-turbo-1106	0.731
gpt-3.5-turbo-0613	0.750

GPT-4 系のモデルは GPT-3.5 系のモデルよりも正解率が高かったものの，新しいモデルになるにつれて一様に正解率が高まったわけではなかった．また，プロンプトでは解答を A か B の一文字で答えるように設定していたが「この」，「体」，「子」など“A”や“B”以外の出力も GPT-4 系のモデルよりも GPT-3.5 系のモデルの方が多かった．これらの結果から，モデルの否定理解において進展があったわけではないことが示唆される．すべてのモデルで 3 回すべて正解となったストーリーは

「男性が不要な情報の書かれたノートを消す」授業で説明されたことをとにかくノートに書いていた．男性が無駄な記載が多いことを指摘した．男性は不要な情報の書かれたノートを消した．授業の内容が理解できるようになった．

というストーリで，正解の選択肢は「成績が良くなった．」，不正解の選択肢は「成績が良くならなかった．」である．
これは，授業の内容が理解できるようになると成績が上がるという常識をモデルが知識として持っているということだと予想される．すべてのモデルで不正解となったストーリーは

「子供が大人に見守られながらくるみ割り器を使ってくるみを割る」子供はクルミを拾った．子供は家にクルミを持ち帰った．大人にくるみ割り器の使い方を教わった．大人にくるみ割り器の使い方を教わった．子供は大人に見守られながら初めて自分でクルミを割った．

というストーリーである．正解の結末文は「上手くいかなかった．」で，すべてのモデルは肯定的な文を選択したが，このストーリーは人間でも意見が分かれるようなものであり，評価セットの中ではっきりとした正解・不正解のボーダーラインが存在していないことがわかった．なお，全 200 セットのデータ中 41 セットを 20 代~50 代の 8 人に人手で評価してもらった．人手評価を行うことでデータセット内で正解と設定したデータが確からしいかどうかを検証し，41 セット中 39 セットが確からしいと評価された．人手評価で意見が分かれたストーリーが2セットあり，1つ目に

https://platform.openai.com/docs/models

「親が虐待によりペットを殺す」親は子供がペットの面倒を見ないので処分したいと思った. いっさいの餌やりを止めた. 水を与えなかった. 叩いて虐待して殺した.

というストーリーが挙げられる. 8 人中 5 人が「子供は気にしていなかった. 」という結末を選び, 3 人が「子供は気にしていた. 」という結末を選んだ. 評価セット内での正解は「子供は気にしていなかった. 」である. 2つ目は

「客が皿の上に落としたパンを食べる」客がフレンチのコースを食べた. パンを取ってオリーブオイルにつけた. 口に運ぶ時にメインディッシュに落としてしまった. 何事もないようにそれを取って食べた.

というストーリーである. 8 人中 5 人が「味は変わった. 」という結末を選び 3 人が「味は変わらなかった. 」という結末を選んだ. このことから, 人手評価は評価者の経験や性格によって変化すると予想される.

5. 結論と今後の課題

5.1 結論

実験結果から, GPT-4 系のモデルは GPT-3.5 系のモデルよりも一般的に高い正解率を示したが, 新しいモデルになるにつれて必ずしも正解率が向上しているわけではなかった. これは否定理解の向上が一様ではないことを示唆している.

5.2 今後の課題

一部のストーリーでは, 人手評価で意見が分かれるような結果が得られた. これらの事例において, モデルが確からしい結果を予測できるかどうかを検証するためには, 人手評価を通じた更なる検証が必要である. 本実験では人手評価を行なったのは 200 セット中 41 セットのみであるためすべてのデータにおいての人手評価が必要となる. また, モデルの改善や性能向上に向けて fine-tuning の必要性やプロンプトの改善が挙げられる.

なお, 本実験と同じプロンプトでの実験を ELYZA-japanese-Llama-2-7b でも行なったが, GPT 系のモデルは解答を A か B の一文字で答えたのに対して, ELYZA は以下のような理由付きの解答を出力した.

与えられた文章に続く文章を選択いたします.
-A:少年が授業の板書内容を移すために自分のノートを与える
-B:貧しい少年はノートをもっていなかった
少年がノートをもらったので, 答えは A になります.

プロンプト内で解答を一文字にするように強く求めると

与えられた文章に続く文章を選択いたします.
少年が授業の板書内容を移すために自分のノートを与えるに続く文章は, A が適切です.
「少年が授業の板書内容を移すために自分のノートを与える」の後に, 少年が感謝したという内容は, 少年が先生にノートを渡したことが前提になっているので, 少年がノートを渡した後の状況を示している A が適切です.
したがって, 答えは A です.

と出力して解答の根拠をより強く説明しただけでこちらの意図した通りの解答にはならなかった. これは max token=256 のときで, max token を 2 や 4 に設定して同じ質問をすると「与」や「承」など意味をなさない答えが返ってきた. 今後は GPT シリーズ以外のモデルでも使用できるようなプロンプトの改善が必要とされる. また, データセットも人間の経験が根拠となるようなストーリーではなく共通認識である常識が根拠となるストーリーを増やすことが求められる.

研究全体として, 言語モデルが否定理解においてどの程度信頼性があるか, また人間との評価の齟齬を埋めるための改善策が今後の研究の焦点となる.

参考文献

[Brown 20] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D. Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al.: Language Models are Few-Shot Learners, Advances in Neural Information Processing Systems, 33:1877–1901, 2020.

[Achiam 23] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al.: GPT-4 Technical Report , arXiv preprint arXiv:2303.08774, 2023.

[Rzepka 24] Rafal Rzepka, Kacper Dudzic, Arisa Abe, Kenji Araki: DanSto – Japanese Dataset of Short Stories for Evaluating Context Understanding, 人工知能学会第二種研究会資料, SIG-AGI-26-06, 2024.

[Hossain 22] Md Mosharaf Hossain, Dhivya Chinnappa,and Eduardo Blanco: An Analysis of Negation in Natural Language Understanding Corpora, In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, pp. 5833–5847, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics, 2022

[Kassner 20] Nora Kassner and Hinrich Schütze. : Negated and Misprimed Probes for Pretrained Language Models:Birds Can Talk, But Cannot Fly, In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp. 7811–7818, 2020.

[栗原 22] 栗原健太郎 ,河原大輔 ,柴田知秀: JGLUE: 日本語言語理解ベンチマーク, 言語処理学会 第 28 回年次大会発表論文集 ,2022.

[Gupta 23] Gupta, Karan, et al.: How robust are LLMs to in-context majority label bias?, arXiv preprint arXiv:2312.16549, 2023.