低資源言語翻訳のためのベクトル変換モデルを用いた機械翻訳

Machine translation using vector transformation model for low-resource languages

田中蒼大郎[†] 越前谷博[†] 荒木健治[‡]
Sōtaro Tanaka[†] Hiroshi Echizen'ya[†] Kenji Araki[‡]

[†]北海学園大学
[†]Hokkai-Gakuen University

[‡]北海道大学
[‡]Hokkaido University

1. はじめに

近年, ニューラル機械翻訳(NMT)に関する研究が盛んに行われている.しかし,低資源言語の翻訳精度は十分とはいえない.この問題に対してはこれまでに様々な研究が行われているが,その一つとして NMT のエンコーダ部分に対し事前学習済みの BRET モデルを適用するアプローチが提案されている[1].

本研究では Transformer のエンコーダの単語埋め込みにおいて,訳文のベクトル間との類似度が高くなるように原文のベクトルを変換したうえで翻訳モデルを学習することで低資源言語の翻訳精度の向上を図った.

2. 提案手法

提案手法では Transformer のエンコーダとして使用する原文の単語埋め込みを,訳文との対応関係を反映したベクトルに変換することで,より精度の高い翻訳モデルの構築を行う.また,ベクトルの変換はニューラルネットワークにより学習したモデル(以降,ベクトル変換モデルと記す.)により行う.

図1に提案手法によるベクトル変換モデル構築の流れを示す.

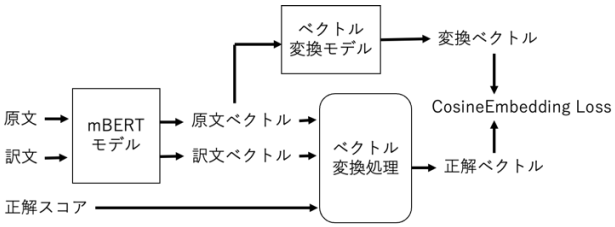


図1ベクトル変換モデル構築

図1より原文とその訳文のペアを mBERT モデルに入力し,それぞれをベクトルに変換する.さらに,それらと正解スコアを用いて,訳文のベクトルとのコサイン類似度が正解スコアと一致するように原文のベクトルを変換することで正解ベクトルを得る.

一方,ベクトル変換モデルは,原文のベクトルに対して変換を行う.変換されたベクトルと正解ベクトルに対して CosineEmbeddingLoss より,ベクトル変換モデルを学習する.

3. 性能評価実験

3.1 実験方法

ベクトル変換モデルの構築では, WMT20 の自動評価タスクにより提供されている原文と参照訳,そして,参照訳に対する DA スコアを用いた.原文と参照訳のペアは 12,552 対である.

Transformer モデルの学習においてはアイヌ語と日本語間の対訳コーパス 91,168 文[2]を用い,fairseq ツールキットで公開されている Transformer を使用した.また,ベースラインには mBERT より得られたベクトルを単語埋め込みに使用した Transformer モデルを用いた.

3.2 実験結果と考察

本研究の評価方法には SacreBLEU を用いた.表1に実験結果を示す.

表1実験結果

	日本語-アイヌ語	アイヌ語-日本語
ベースライン	25.18	22.08
提案手法	26.36	21.26

表1より日本語からアイヌ語への翻訳においては提案手法の BLEU スコアは向上したが,アイヌ語から日本語への翻訳においてはわずかにベースラインを下回った.その原因としてはベクトル変換モデルの構築時にアイヌ語が使用されていないため,変換されたベクトルの精度が十分ではなかったためと考えられる.

4. まとめ

本研究では低資源言語の翻訳のために,訳文のベクトルの情報を原文のベクトルに反映させるモデルを構築した.性能評価実験の結果,日本語からアイヌ語への翻訳においては提案手法の有効性を確認できた.

今後はベクトル変換モデルの学習時のデータを増やすことで精度の向上を図る予定である.

謝辞

本研究の一部は一般社団法人アイヌ文化学術研究会との共同研究により行なわれた.

参考文献

[1] Kenji Imamura, Eiichiro Sumita, Recycling a Pre-trained BERT Encoder for Neural Machine Translation, In Proc of the 3rd Workshop on Neural Generation and Translation, pp. 23-31, 2019.

[2] 田中蒼大郎, 越前谷博, 荒木健治, Transformer を用いたアイヌ語-日本語間機械翻訳における精度と対訳コーパスの関係, 令和4年度電気・情報関係学会北海道支部連合大会講演論文集, pp. 227-228, 2022.

Copyright © 2024 IEICE