翻訳対象言語の情報を利用した低資源言語のためのニューラル機械翻訳

Neural machine translation for low-resource languages using information in the target language

田中蒼大郎† 越前谷博† 荒木健治‡
Sōtaro Tanaka† Hiroshi Echizen’ya† Kenji Araki‡

†北海学園大学
†Hokkai-Gakuen University

‡北海道大学
‡Hokkaido University

1. はじめに

近年，ニューラル機械翻訳(NMT)に関する研究が盛んに行われている．それに伴い，NMT による翻訳の精度が向上している．しかし，低資源言語においては学習データの不足などにより翻訳精度が十分とはいえない．そのような状況において低資源言語における機械翻訳の精度を向上させるための研究[1]が行われている．磯部ら[2]は低資源言語だけでなく大規模な対訳文集合を同時に学習させる Many-to-One 翻訳及び Many-to-Many 翻訳において，多言語文を用いて事前学習された言語モデル mBERT より得られる文脈埋め込みを BERT-fused NMT[3]に適用した．その際，BERT-fused NMT では原言語の文脈情報は使用されているが，翻訳対象言語の情報は使用されていない．

そこで本稿では原言語の情報だけでなく翻訳対象言語の情報も付与した単語ベクトルを用いることで BERT-fused NMT の精度向上を図る．具体的には単語埋め込み層の単語ベクトルにおいて原文の単語ベクトルを翻訳対象文とのコサイン類似度が人手による評価スコアと等価になるように変換した文ベクトルを用いる．またその変換は事前に学習したベクトル変換モデルを用いることで行う．本稿ではベクトル変換モデルを用いた NMT の提案とその有効性について述べる．

2. 提案手法

2.1 ベクトル変換モデルの構築

翻訳対象言語の情報を付与した文ベクトルの生成はベクトル変換モデルを用いて行う．図１にベクトル変換モデル構築の流れを示す．

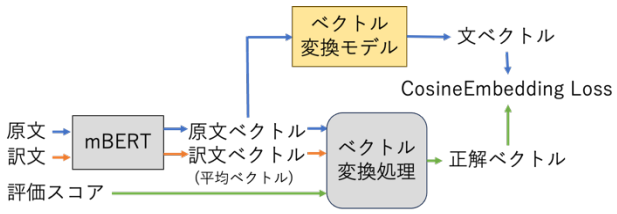


図１ベクトル変換モデル構築の流れ

図 1 より原文と翻訳対象言語文である訳文を多言語で学習した事前学習モデル mBERT に入力する．ベクトル変換モデルは入力と出力共に文ベクトルであるため，mBERT の出力である単語ベクトルの平均ベクトルを求めることで原文ベクトルおよび訳文ベクトルを得る．得られた原文ベクトルが入力されるとベクトル変換モデルは訳文との間のコサイン類似度が人手による評価スコアと等価になるように原文ベクトルを変換する．ベクトル変換モデルは変換された文ベクトルとベクトル変換処理による正解ベクトルに対して CosineEmbeddingLoss を用いて学習が行われる．ベクトル変換処理における正解ベクトルは原文ベクトルを $A=(a_1, a_2, \ldots, a_n)$，訳文ベクトルを $B=(b_1, b_2, \ldots, b_n)$ とした場合，原文ベクトル A の第１要素に変数 x を加えたベクトル $A'=(a_1+x, a_2, \ldots, a_n)$ と B の間のコサイン類似度の式より求める．すなわち，以下の方程式を満たす x を求めることで A' を決定する．次に求めたベクトル A' を正解ベクトルとして用いる．

$$\frac{(a_1+x)\times b_1+\sum_{i=2}^{n}(a_i\times b_i)}{\sqrt{(a_1+x)^2+\sum_{i=2}^{n}a_i^2}\times\sqrt{\sum_{i=1}^{n}b_i^2}}=\text{評価スコア}$$

2.2 ベクトル変換モデルの NMT への適用

本稿では構築したベクトル変換モデルを BERT-fused NMT のエンコーダに組み込む．図２に提案手法による NMT の概要を示す．

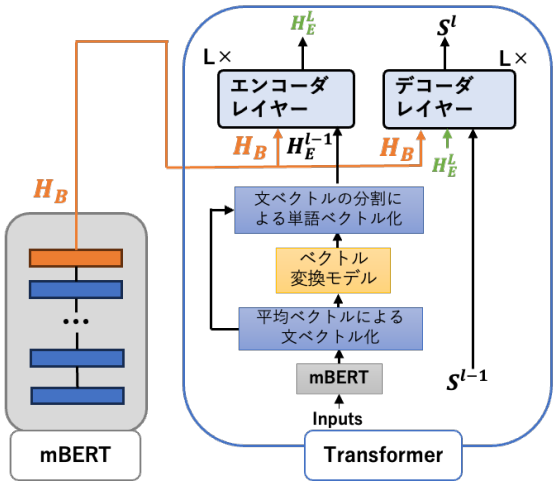


図２提案手法による NMT の概要

図 2 より NMT のエンコーダの単語埋め込み層の単語ベクトルとしてベクトル変換モデルより得られる文ベクトルを使用する．ここで，単語埋め込み層の入力は単語ベクトルであるため，文ベクトルを単語ベクトルに分割する．分割は mBERT により得られる単語ベクトルの平均ベクトルがベクトル変換モデルより得られる文ベクトルになるように全単語ベクトルの第１要素に同じ値を付与することにより行う．

３．性能評価実験

3.1 実験方法

ベクトル変換モデルの構築には学習データとして，WMT20[4]の自動評価タスクより提供されている原文と人

手による訳文,及びその訳文に対する人手による評価スコアの組の 12,552 組を用いた.その際の原文とその訳文の言語ペアはドイツ語→英語,英語→チェコ語,英語→ドイツ語,英語→日本語,英語→ポーランド語,英語→ロシア語,英語→タミル語,英語→中国語,ロシア語→英語,クメール語→英語,中国語→英語,パシュトゥー語→英語である.また,NMT の構築においては,低資源言語の観点からアイヌ語-日本語間,ベトナム語-日本語間の翻訳を対象とし,これらの言語間の対訳コーパスを実験データとした.アイヌ語-日本語間の対訳コーパス[5]には91,168対,日本語-ベトナム語間の対訳コーパス[6]には 20,101 対を用いた.これらの実験データを8:1:1の割合で,学習データ,検証データ,そして評価データに用いた.ここで,ベクトル変換モデルの構築においては,アイヌ語とベトナム語が学習データとして含まれていないため,NMT の構築時に利用した対訳コーパスを含めて学習を行っている.その際の人手スコアは近似的に1.0を与えた.

また,提案手法による NMT と比較するために,ベクトル変換モデルを使用していない BERT-fused NMT をベースラインとした.

3.2 実験結果

ベースラインと提案手法に対する評価には SacreBLEU を用いた.表1に実験結果を示す.

表1 実験結果

	ベースライン	提案手法
日本語-アイヌ語	32.20	33.46
アイヌ語-日本語	24.89	24.36
日本語-ベトナム語	8.60	8.76
ベトナム語-日本語	8.69	9.33
平均	18.60	18.98

3.3 考察

表1の実験結果よりアイヌ語から日本語への翻訳を除き,提案手法の BLEU スコアはベースラインを上回った.このような結果はベクトル変換モデルが生成する文ベクトルに翻訳対象言語の情報が含まれているためと考えられる.そこでベクトル変換モデルによって変換された文ベクトルに訳文との関係性が含まれているかを調査した.具体的にはベクトル変換モデルから得られる文ベクトルが対応する訳文ベクトルと類似しているかをコサイン類似度を求めることで検証した.調査対象の対訳文は評価データより任意に抽出した500対である.ベクトル変換モデルより得られる文ベクトルと訳文ベクトル間のコサイン類似度が変換前の mBERT より得られる文ベクトルと訳文ベクトル間のコサイン類似度よりも高い値であれば変換された文ベクトルは翻訳対象言語の情報を含んでいると考えられる.調査結果を表2に示す.

表 2 よりベクトル変換モデルを用いた文ベクトルと mBERT による訳文ベクトル間のコサイン類似度が BLEU スコアに反映されていることがわかる.アイヌ語-日本語においてはベクトル変換モデルを日本文に適用した際のコサイン類似度が 0.4499 と高く,表1の BLEU スコアにおいても日本語からアイヌ語の翻訳精度が向上している.ベトナム語-日本語ではベトナム語にベクトル変換モデルを適用した場合のコサイン類似度が 0.6234 と高く,表1の BLEU スコアにおいてもベトナム語から日本語の翻訳精度が比較的大きく向上している.したがって,ベクトル変換モデルによる文ベクトルと訳文ベクトル間のコサイン類似度が高くなるほど翻訳精度が向上することを確認できた.

表2 ベクトル変換の有無と
原文と訳文のコサイン類似度の関係

	原文側に用いたモデル (訳文側のモデルは全て mBERT)	コサイン 類似度
アイヌ語 - 日本語	アイヌ語及び日本語:mBERT	0.3619
	日本語:ベクトル変換モデル	0.4499
	アイヌ語:ベクトル変換モデル	0.3859
ベトナム語 - 日本語	ベトナム語及び日本語:mBERT	0.6197
	日本語:ベクトル変換モデル	0.6155
	ベトナム語:変換モデル	0.6234

4. まとめ

本稿では,低資源言語を対象とした NMT の翻訳精度の向上のために,NMT のエンコーダの単語埋め込み層において翻訳対象言語の情報を含んだベクトルを利用した新たな手法を提案した.性能評価実験の結果,翻訳対象言語の情報を含むベクトルを生成するベクトル変換モデルの利用が翻訳精度を向上させることを確認した.今後はベクトル変換モデルの性能向上のための改良を行う予定である.

謝辞

本研究の一部は一般社団法人アイヌ文化学術研究会との共同研究により行なわれた.

参考文献

[1] B. Haddow, R. Bawden, A. V. Miceli Barone, J. Helcl, and A. Birch. Survey of Low-Resource Machine Translation,Computational Linguistics, vol 48, issue 3, pp. 673-732, 2022.

[2] 磯部僚也, Y. Wei, 田村拓也, 宇津呂武仁, 永田昌明. 多言語 BERT を単語埋め込みに用いる Many-to-Many 翻訳による低資源言語翻訳, 言語処理学会 第27回年次大会発表論文集, pp.430-434, 2021.

[3] J. Zhu, Y. Xia, L. Wu, D. He, T. Qin, W. Zhou, H. Li, and T.-Y. Liu. Incorporating BERT into neural machine translation, In Proc of 8th ICLR, pp. 1-18, 2020.

[4] L.Barrault, M.Biesialska, O.Bojar, M.R.Costa-jussa, C.Federmann, Y.Graham, R.Grundkiewicz, B.Haddow, M.Huck, E.Joanis, T.Kocmi, P.Koehn, C.Lo, N.Ljubsic, C.Monzm, M.Morishita, M.Nagata, T.Nakazawa, S.Pal, M.Post, M.Zampieri, Findings of the 2020 Conference on Machine Translation (WMT20), In Proc of WMT, pp. 1-55,2020.

[5] 田中蒼大郎, 越前谷博, 荒木健治, Transformer を用いたアイヌ語-日本語間機械翻訳における精度と対訳コーパスの関係, 令和4年度電気・情報関係学会北海道支部連合大会講演論文集, pp. 227-228, 2022.

[6] H. Riza, M. Purwoadi, Gunarso, T. Uliniansyah, A. A. Ti, S. M. Aljunied, L. C. Mai, V. T. Thang, N. P. Thai, V. Chea, R. Sun, S. Sam, S. Seng, K. M. Soe, K. T. Nwet, M. Utiyama, and C. Ding. Introduction of the Asian language treebank. In Proc of. 19th O-COCOSDA, pp. 1-6, 2016.