THE TRANSACTIONS OF THE INSTITUTE OF ELECTRONICS, INFORMATION AND COMMUNICATION ENGINEERS D-II

電子情報通信学会 論文誌 D-II

VOL.J82-D-II NO.11 NOVEMBER

情報・システムII—パターン処理

1999

情報・システムソサイエティ

社団法人 電子情報通信学会

THE INFORMATION AND SYSTEMS SOCIETY

THE INSTITUTE OF ELECTRONICS, INFORMATION AND COMMUNICATION ENGINEERS

論　文

学習型機械翻訳手法に適用された遺伝的アルゴリズムにおける知識による制約の有効性について

工藤　晃一[†*]　荒木　健治[††]　桃内　佳雄[†]　栃内　香次[††]

Effectiveness of Constraint by Knowledge for Genetic Algorithms in Machine Translation Method with Learning

Koichi KUDO[†*], Kenji ARAKI[††], Yoshio MOMOUCHI[†], and Koji TOCHINAI[††]

あらまし　我々は，学習型機械翻訳手法への遺伝的アルゴリズムの適用の有効性を確認するために，遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法（GA-ILMT）を提案した．そして，GA-ILMTの有効性は，評価実験により既に確認されている．遺伝的アルゴリズムの適用により，システムが自動的に全く新しい翻訳例を生成し，翻訳例から獲得される翻訳ルールの多様性も増加して，全体として正翻訳率を向上させることができた．しかし，多様性の増加は，同時に誤った翻訳例も多数生成し，正しい翻訳結果の生成を妨げるという問題を含んでいる．我々は，この問題を解決するために，翻訳例生成における多様性を制約し，最適な新翻訳例の生成を行うことを目的とした多段階交叉位置決定手法を提案する．本手法を適用したGA-ILMTの評価実験により，本手法は，有効な翻訳例の一部を損失させるが，翻訳の妨げとなる誤った翻訳例の生成を大幅に減少させることができ，また，正翻訳率を向上させることが明らかになった．そして，学習型機械翻訳手法に適用された遺伝的アルゴリズムへの本手法による制約が有効であることが確認された．

キーワード　遺伝的アルゴリズム，交叉，制約，翻訳例

1. まえがき

インターネットの普及により，海外から様々な情報を容易に獲得することが可能になり，日本語以外の言語に触れる機会が大幅に増大している．このような状況から，翻訳を大量かつ迅速に行うため，機械翻訳システムへの要求が高まり，製品化も進んできている[1]．我々は，機械翻訳システムの更なる性能向上を目指し，学習により知識を獲得する能力をもった学習型機械翻訳システムの実現[2],[3]に向けて，遺伝的アルゴリズムを適用した学習型機械翻訳手法（GA-ILMT）を提案した[3],[4]．遺伝的アルゴリズムは，多様な個体を生成しながら，周囲の環境に適応することで進化していく生物の進化過程を模倣したものであって[5]～[7]，様々な分野に適用され，その有効性が立証されている[3]～[7]．GA-ILMTは，翻訳パターンや文法規則をあらかじめ大量に与え，構文解析を行うパターンベース翻訳[8]とは異なり，与えられた翻訳例から字面レベルで自動的かつ帰納的に翻訳ルールを獲得し，そこで学習された翻訳ルールを用いて翻訳を行う．更に，遺伝的アルゴリズムの適用により，与えられた少量の翻訳例から多様な新翻訳例をシステムが自動的に生成し，大量の翻訳例を獲得することを可能にした．これにより，不足する翻訳例の学習を補うことが可能になるため，正翻訳率を向上させることができる．

これまでに行われた性能評価実験により，GA-ILMTの有効性は立証されているが[3],[4]，様々な問題が残されている．本来，遺伝的アルゴリズムでは，多様な個体を生み出しながら淘汰により適応度の低い個体は消滅し，適応度の高い個体のみが残り，周囲の環境に適した集団となっていく．GA-ILMTにおいても，翻訳結果の正誤は利用者が判定し，適用された個体である翻訳ルールをその正誤判定から評価して適応度を決定し，淘汰処理を行っているが，自然界における生物

† 北海学園大学大学院工学研究科電子情報工学専攻，札幌市
Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University, S 26-Jo, W 11-Chome, Chuo-ku, Sapporo-shi, 064–0926 Japan
†† 北海道大学大学院工学研究科，札幌市
Graduate School of Engineering, Hokkaido University, N 13-Jo, W 8-Chome, Kita-ku, Sapporo-shi, 060–8628 Japan
* 現在，北海道ソフト・エンジニアリング株式会社

(1) The input sentence
She is my sister.
(2) The initial group
ENGLISH JAPANESE
(She is @0. : 彼女は@0です.)
(@0 is my @1. : @0は私の@1です.)
(@0 is @1. : @0は@1です.)
(3)The translation rule generated by crossover
(She is my @1 : 彼女は私の@1です.)
(4)The evaluation of population
(sister : 妹)
(She is my @1. : 彼女は私の@1です.)
(5)The translation result
彼女は私の妹です.

図3 翻訳部の処理例
Fig. 3 Example of the translation process.

Two translation examples.
(He likes tennis.:彼はテニスが好きです.)
(He likes tea. :彼はお茶が好きです.)
↓ Extraction of common and different parts
Common part.
(He likes @0. :彼は@0が好きです.)
Different part
(tennis:テニス) ,(tea:お茶)

図4 翻訳ルールの抽出例
Fig. 4 Example of the extraction of translation rule.

アルゴリズムの基本操作を用いて翻訳結果を生成する．そして，この生成された翻訳ルールを翻訳結果として出力する．また，翻訳結果が複数生成される場合は，使用した翻訳ルールの適応度や抽象度の大きさにより順位付けして出力する．翻訳ルールの適応度は，各翻訳ルールにおける翻訳に適用された際の正翻訳率であり，次の式で計算される．

$$\text{適応度}\,(\%)=\frac{\text{正翻訳度数}}{\text{全翻訳度数}}\times 100 \qquad (1)$$

正翻訳度数とは，翻訳ルールが正翻訳に適用されたときに加算される値である．また，全翻訳度数とは，翻訳に使用された回数である．適応度が高いほど有効な翻訳ルールである．また，抽象度とは，翻訳に適用された翻訳ルールの単語数に対する変数の割合である．変数とは，図3，図4中の翻訳ルールに含まれる“@0, @1”のことである．抽象度は，次の式で計算される．

$$\text{抽象度}\,(\%)=\frac{\text{翻訳ルール中の変数の個数}}{\text{翻訳ルール中の単語数}}\times 100 \qquad (2)$$

そして，順位付けは，生成された複数の翻訳結果に対して以下に示す三つの方法を用いて決定される．

① 使用した翻訳ルールの適応度が最大もの．
② 使用した翻訳ルールの抽象度が最小のもの．
③ 使用した翻訳ルールの登録順位が最上位のもの．

ただし，番号が上位である方法を優先する．次に，フィードバック部において，ユーザが与えた正しい日本語訳文を用い，翻訳部で用いられた翻訳ルールに対する適応度の決定と淘汰を行う．そして，学習部において，与えられた翻訳例（英文とその日本語訳文）に対して，交叉及び突然変異を行って多様な翻訳例を生成し，また，同時に翻訳ルールの抽出も行う．翻訳ルールの抽出は，二つの翻訳例の共通部分と差異部分を多段階に抽出することによって行う．

図3に翻訳結果の生成例を示す．まず，入力文の翻訳に適用可能な翻訳ルールを辞書から選択し，その集団を初期集団とする．次に，共通部分をもつ二つの翻訳ルールを選択し，その共通部分を交叉位置として，一点交叉を行う．図の例の場合では，上から1番目と2番目の翻訳ルールに対して，“is”を交叉位置として一点交叉を適用する．次いで，翻訳ルールの変数部分に，適用可能な翻訳ルールを代入する．次に，図4に翻訳ルールの抽出例を示す．この例では，原文において“tennis”と“tea,”訳文において“テニス”と“お茶”が差異部分であり，その他の部分は共通部分である．したがって，この差異部分を翻訳ルールとして抽出し，抽出された部分を変数化する．また，図のように共通部分は，変数付き翻訳ルールとして，抽出される．多段階交叉位置決定手法は，学習部の翻訳例の生成に対して適用し，翻訳例に対する制約を行う．

2.2 多段階交叉位置決定手法

2.2.1 概　　要

GA-ILMTの学習部に適用される本手法は，翻訳例同士の類似性による交叉の制約と確実な対応関係をもつ交叉位置の単語を決定する手法である[9],[10]．本手法の処理過程を図5に示す．本手法では，二つの翻訳例における原文同士及び訳文同士の対応関係を多段階に確実性の高い順に決定し，次いで原文同士の類似度と訳文同士の類似度をそれぞれ計算する．類似度がしきい値未満のときは，その翻訳例を処理対象から除外し，交叉を行わない．しきい値以上のときは，処理を続行し，対応関係から交叉位置の候補を決定する．そして，その候補における原文と訳文の対応関係を決定し，この対応関係をもつ交叉位置の候補のみを交叉位置として交叉を行う．また，本手法では，英文と日本語訳文の両方で品詞情報を使用するため，入力

位の段階では，処理対象としない．ここで使用する対応関係は，文同士の類似性を示すために重要と考えられるものを使用した[14]．また，対応関係の順位は，確実性が高いと考えられる順に決定した．ここで決定された対応関係がある二つの単語は，対となって原文または訳文の交叉位置の候補となる．

2.2.3 類似度の計算

次に，翻訳例の対応関係から決定される文同士の類似度の計算について述べる．この類似度は，決定された各段階における対応関係の個数に基づいて式(3)で計算される．

$$\text{類似度}=\frac{100.0}{S}\times(2.0\times N_1+1.8\times N_2+1.6\times N_3+1.0\times N_4+0.8\times N_5+0.4\times N_6+0.2\times N_7-0.5\times N_8) \quad (3)$$

S:二つの翻訳例の原文または訳文の単語の合計
N_n:(n) 段階における対応関係の数　$(n=1,...,7)$
N_8:対応関係がなかった単語数

この式において，全く同じ文同士の類似度は100となる．また，各項の係数は，上位の段階の対応関係の単語が多いと類似度が高くなり，下位の段階の対応関係や対応関係をもたない単語が多くなるほど類似度が低くなるように設定した．上位の段階の対応関係が多いほど，類似度が高くなり，二つの文の類似性が高いことになる．類似度は，原文同士及び訳文同士のそれぞれについて計算される．各項の係数は予備実験の結果より最適な値に設定されている．

図6に，対応関係と類似度の計算の例を示す．それぞれの矢印は，対応関係が存在する単語を示す．()内に示された数字は，対応関係の段階の数である．この各段階の対応関係の個数を式(3)に代入することにより，類似度が決定される．また，図6では，原文同士の対応関係において“you”と“he”の対応関係が(6)段階で決定し，訳文同士の対応関係において“あなた”と“彼”の対応関係が(5)段階で決定している．原文と訳文の対応関係が存在する原文の単語と訳文の単語の対応関係が同じ段階で決定していない．これは，英語と日本語の上位概念を検索する辞書が異なっているため，対応関係の整合性にずれが生じているためである．使用する辞書による整合性のずれを起こさないようにすることは本手法の今後の課題の一つである．

2.2.4 類似度の係数の妥当性について

2.2.3の式(3)における各項の係数の妥当性について述べる．式(3)における係数は，対応関係の確実性

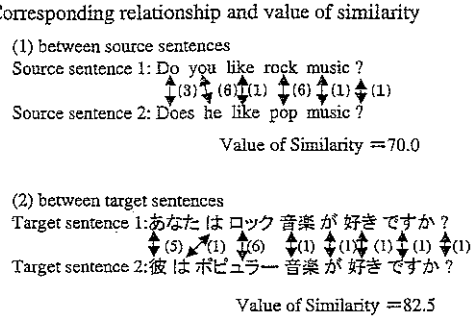


図6　対応関係と類似度の例
Fig. 6　Example of corresponding relationship and value of similarity.

や経験的な側面から妥当な値だと判断された値を用いている．この対応関係とは，**2.2.3**で述べた七つの対応関係である．この対応関係は，上位の段階の方が対応関係の確実性が高いことから，等差級数的に係数の値を減少させている．また，式(3)における係数は，本研究の以前に提案されていた翻訳誤りを復元する手法[15]における予備実験からその妥当性が議論された．この翻訳誤りを復元する手法について述べる．この手法は，翻訳システムの翻訳結果に含まれている誤りを自動的に復元する手法である．復元に用いる復元ルールは，翻訳結果と利用者が校正した翻訳結果を帰納的に学習することによって得られる．そのときに，翻訳結果と校正した翻訳結果に対して多段階交叉位置決定手法と同じ七つの対応関係を決定し，類似度を計算する．あるしきい値以上のときにこれらの対応関係を利用して復元ルールを抽出する．そして，復元ルールを用いて誤った翻訳結果を復元する．このとき，正しい復元が行われたときに適用した復元ルールの抽出に用いた対応関係と復元が誤っているときに適用した復元ルールの抽出に用いた対応関係の種類と数を用いて式(3)の係数を自動的に変化させ，復元に最適な係数を求めた．このときの類似度の計算は，以下の式(4)で求める．

$$\text{類似度}=\frac{100.0}{S}\times(\alpha_1\times N_1+\alpha_2\times N_2+\alpha_3\times N_3+\alpha_4\times N_4+\alpha_5\times N_5+\alpha_6\times N_6+\alpha_7\times N_7-0.5\times N_8) \quad (4)$$

S:翻訳結果と校正結果の単語の合計
N_n:(n) 段階における対応関係の数　$(n=1,...,7)$
N_8:対応関係がなかった単語数

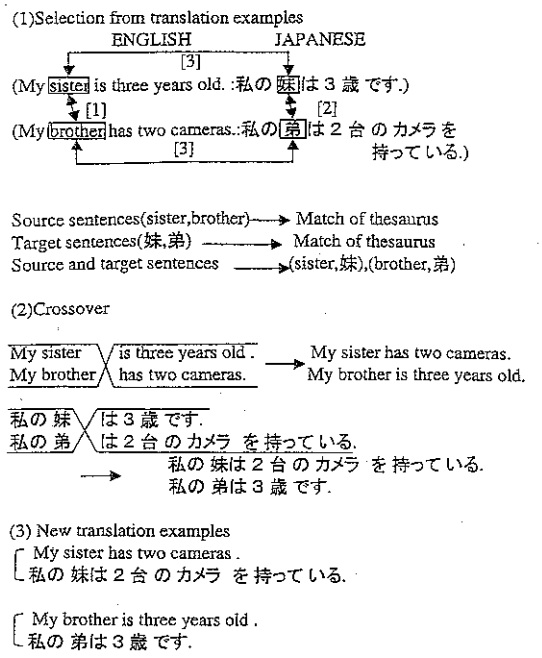


図７　翻訳例の生成例
Fig. 7　Examples of generation of translation examples.

3. 評価実験

3.1 評価方法

本手法に基づいたシステムの翻訳結果に対する評価方法について述べる．翻訳結果は以下の二つの評価方法で分類する．

(1)　正翻訳
(2)　誤翻訳

正翻訳とは，訳文が文法的に正しく，かつ，原文の訳であるときの翻訳である．このとき未登録語を含んでいる翻訳結果において，未登録語に単語の翻訳ルールを与えることで容易に未登録語を含まない正翻訳を導き出せる．したがって，未登録語を含んでいる翻訳結果も正翻訳に含めることにする．誤翻訳とは，訳文が原文の正しい訳ではないか，あるいは，訳文が文法的に誤っているときの翻訳である．また，適用可能な翻訳ルールが全くないときに翻訳不能となる場合も誤翻訳に含む．正翻訳率は以下の式 (7) で決定される．正翻訳率とは，入力された英文を翻訳したときにシステムが正しい訳文を出力する率である．

$$\text{正翻訳率 (\%)}=\frac{\text{正翻訳となる数}}{\text{全入力文数}}\times 100 \qquad (7)$$

表３　実験結果
Table 3　Results of the experiments.

しきい値	正翻訳数	誤翻訳数	正翻訳率 (%)
25	342	455	42.9
40	353	444	44.3
50	364	433	45.7
55	370	427	46.4
60	356	440	44.6
70	355	441	44.4

（全翻訳文数 797）

また，生成された翻訳結果が複数存在する場合には，順位付けされて出力される翻訳結果の最上位から 10 位までを評価対象とする．10 個の翻訳結果中に正翻訳に該当するものが存在していた場合，その翻訳結果を正翻訳とする．

3.2 実験方法

実験には，中学校１年生用教科書ガイド・ワンワールド [17] に掲載されている英文と訳文の 797 組を使用した．実験では１文ごとに翻訳を行い，翻訳終了時に正翻訳文を与え，学習も同時に行った．交叉を制約する類似度のしきい値は，最適な値を見つけるため，値を変化させて実験を行った．また，多段階交叉位置決定手法を適用していない GA-ILMT の実験も同様に行った．

3.3 実験結果

実験結果を表３に示す．しきい値が 25，40，50，55，60，70 のとき，正翻訳率はそれぞれ，42.9%，44.3%，45.7%，46.4%，44.6%，44.4%となった．図８にしきい値の変化に対する正翻訳率の推移を示す．また，表４に実験で生成された翻訳例の総計を示す．生成された翻訳例は，文法が正しく，かつ，原文と訳文の対応が正しいものを正しい翻訳例とし，反対に文法に誤りがあるもの，または，原文と訳文の対応に誤りが生じているものを誤った翻訳例とした．そして，図９に生成された翻訳例の精度の変化を示す．ここで，生成された翻訳例の精度は，式 (8) で計算される．この精度とは，生成されたすべての翻訳例中における正しい翻訳例の割合である．

$$\text{精度 (\%)}=\frac{\text{生成された正翻訳例数}}{\text{生成された翻訳例の総数}}\times 100 \qquad (8)$$

また，表５で示したように従来の GA-ILMT では，正翻訳率が 39.8%，生成された翻訳例の精度が，24.1%となった．この結果より，最も翻訳率が高いしきい値 55 のときの本手法を適用した GA-ILMT の方

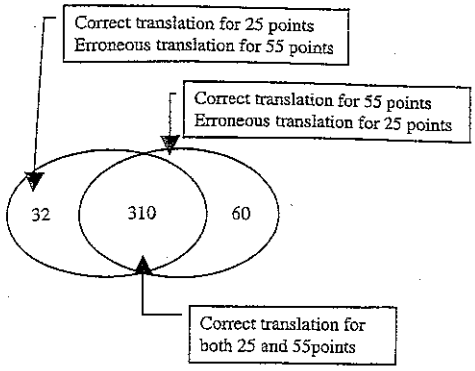


図 10　しきい値 25 と 55 における翻訳数の比較
Fig. 10　The comparison for number of translations between 25 points and 55 points .

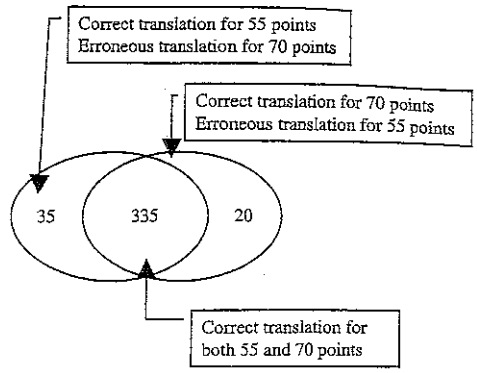


図 11　しきい値 55 と 70 における翻訳数の比較
Fig. 11　The comparison for number of translations between 55 points and 70 points.

図 10 は，25 で正翻訳となるが，55 で誤翻訳となる数が 32 個，反対に，25 で誤翻訳となり，55 で正翻訳となる数が 60 個，そして，25 及び 55 の両方で正翻訳となる数が 310 個となっていることを示している．また，図 12 は，しきい値 25 で誤翻訳，55 で正翻訳となる例である．図 12 中のしきい値 25 における最上位の誤った翻訳結果としきい値 55 における正しい翻訳結果は，図 13 に示した処理過程で生成される．しきい値 25 では，生成された翻訳結果の上位 10 位以内に正しい翻訳結果が出力されていない．一方，しきい値 55 では，正しい翻訳結果が最上位の候補となっている．しきい値 25 では，下位の翻訳結果に正しい翻訳結果が出力されている．これは，25 において誤った翻訳結果を生成する翻訳ルールを抽出する翻訳例が生成されるため，正しい翻訳結果が上位 10 位以内に入ることができないためである．また，55 では，しきい値の上昇により，そのような翻訳ルールが抽出される翻訳例が生成されないため，正しい翻訳結果が最上位の候補になる．この例からも，しきい値を高くすることによる誤った翻訳例に対する制約の効果が確認できる．そして，図 14 は，しきい値 25 で正翻訳，55 で誤翻訳となる例である．図 14 中のしきい値 25 における正しい翻訳結果としきい値 55 における最上位の誤った翻訳結果は，図 15 に示した処理過程で生成される．この例では，55 のときにしきい値が高くなることにより，この入力文の正しい翻訳結果を生成するための翻訳ルールを抽出する翻訳例が生成されない．そのため，正しい翻訳結果が生成できないのである．一方，25 のときは，正しい翻訳結果の生成に必要な翻訳例が生成されるので，正しい翻訳結果が生成されるのである．したがって，この図からしきい値の増加による多様性の損失を確認できる．このように，しきい値 55 で 60 文が正翻訳となったのは，しきい値が高くなることによる誤った翻訳例の生成に対する制約の効果によるものであり，また，誤翻訳となった 32 文は，制約が厳しくなることによる多様性の損失の影響が原因であると考えられる．

次に，図 11 において，表 3 中のしきい値 55 と 70 における正翻訳と誤翻訳の数とその相互関係を示す．この図では，55 で正翻訳となるが，70 で誤翻訳となる数が 35 個，反対に，55 で誤翻訳となり，70 で正翻訳となる数が 20 個，そして，55 及び 70 の両方で正翻訳となる数が 335 個であることが示されている．また，55 と 70 の翻訳結果に，しきい値が 25 と 55 の翻訳結果と同様な傾向が見られる．55 と 70 の場合では，70 のときの多様性の損失の影響が翻訳例の生成精度の向上の効果を上回るため，正翻訳となる翻訳が少なく，55 の正翻訳から誤翻訳になった翻訳数を上回ることができない．しきい値 25 と 70 よりも，55 の方が，正翻訳となった文が，誤翻訳となった文を上回っていることから，しきい値 55 による翻訳例の生成への制約が正翻訳率の向上に有効であると考えられる．

4.2　生成される翻訳例に対する制約の有効性

実験結果より，しきい値の変化が翻訳例の生成及び正翻訳率に大きく影響することが確認された．特にしきい値の変化は，生成される翻訳例の数や精度に大きな効果を与える．しかし，実験結果からもわかるように，正翻訳率に対する影響は翻訳例の生成ほどではな

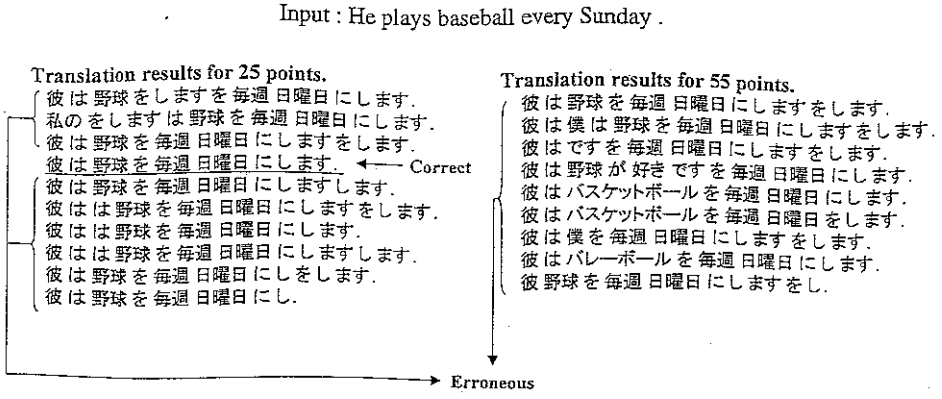


図 14　しきい値 25 で正翻訳，しきい値 55 で誤翻訳となる例
Fig. 14　Example of correct translation for 25 points and erroneous translation for 55 points.

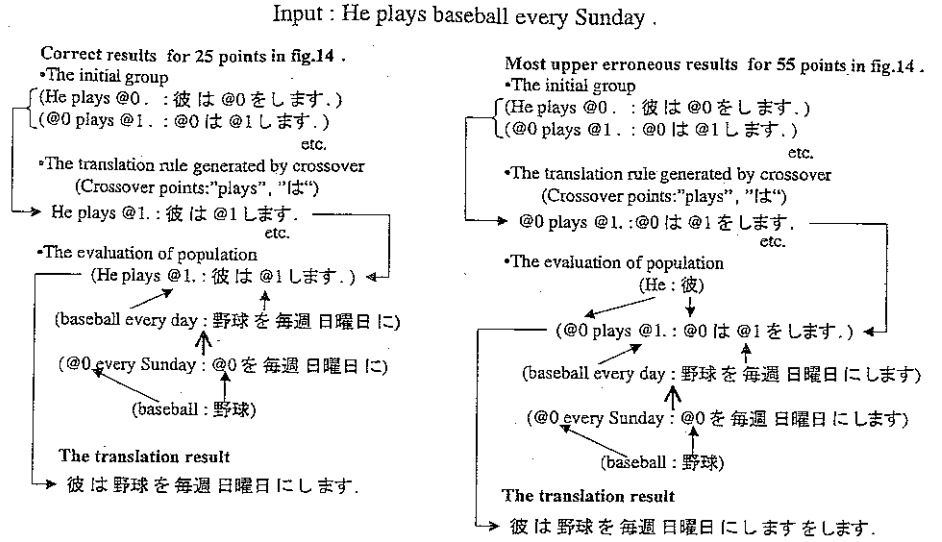


図 15　図 14 における翻訳結果の生成過程
Fig. 15　Generation processes of translation results in Fig14.

このような問題は解決する．本手法は，GA-ILMT の学習能力の最適化に有効であると考えられる．これらから，GA-ILMT への知識導入による制約は，有効であると考えられる．

5. むすび

本論文では，GA-ILMT において翻訳例生成の制約を行う多段階交叉位置決定手法を提案し，その手法に基づく実験システムを用いて行った性能評価実験から，GA-ILMT に対する知識を用いた制約の有効性を確認し，GA-ILMT に対して最適な制約を与えるしきい値を実験的に定めることができた．これにより，知識による最適な制約が GA-ILMT の機械翻訳システムとしての性能を向上させることが示され，学習型機械翻訳に適用された遺伝的アルゴリズムへの知識導入による制約は有効であるとの結論が得られた．しかし，実験結果から最適な制約を適用したときの正翻訳率の向上の効果は，それほど大きくはない．これは，学習部に



栃内　香次　（正員）

昭37北大・工・電気卒．昭39同大大学院工学研究科電気工学専攻修士課程了．現在，北大・工・電子情報工学専攻教授．主として音声情報処理，自然言語処理の研究に従事．工博．情報処理学会，日本音響学会各会員．