THE IEICE TRANSACTIONS ON INFORMATION AND SYSTEMS, PT.2 (JAPANESE EDITION)

電子情報通信学会 論文誌 D-II

VOL.J88-D-II NO.4 APRIL

情報・システムII—パターン処理 2005

情報・システムソサイエティ

社団法人 電子情報通信学会

THE INFORMATION AND SYSTEMS SOCIETY

THE INSTITUTE OF ELECTRONICS, INFORMATION AND COMMUNICATION ENGINEERS

論　文

隣接情報学習を用いた多言語対訳コーパスからの対訳語の自動抽出

越前谷　博[†a)]　　荒木　健治[††]　　桃内　佳雄[†]

Automatic Extraction of Bilingual Word Pairs from Parallel Corpora with Various Languages Using Learning for Adjacent Information

Hiroshi ECHIZEN-YA[†a)], Kenji ARAKI[††], and Yoshio MOMOUCHI[†]

あらまし　本論文では，言語リソースの乏しい言語も含めた，様々な言語の対訳コーパスから対訳語を効率良く抽出する手法として，隣接情報学習を用いた対訳語の自動抽出手法を提案する．提案手法では，対訳語と隣接関係にある単語列の情報を獲得し，それを用いることで，単語間の対応関係のあいまい性を解消する．獲得される情報は，対訳文において抽出対象の対訳語の原言語の単語に隣接する単語列が目的言語文中のどの単語列に対応するのかの情報，更に，対応する目的言語文中の単語列とどのような隣接関係にある単語が対訳語の目的言語の単語となるのかの情報である．性能評価実験では，本手法に基づくシステムを用いて，原言語の異なる5種類の対訳コーパスから対訳語を自動抽出した結果，60.1%の抽出率が得られた．この結果は，Dice係数に基づくシステムの抽出率に比べ，8.0ポイント高い値であり，本手法の有効性が確認された．

キーワード　対訳語，隣接情報，学習，多言語，類似度

1. まえがき

対訳コーパスは，計算機で扱うデータとして利用する以外にも，新たな言語を学習する際の教材としても利用価値が高い．そのため，言語習得教材として用例集を掲載した多くの書籍やインターネットサイトが存在している．このような用例集をよりいっそう有効利用するために，単語レベルの対応関係をユーザに提供することは重要と考えられる．文レベルの対応関係のみが示されているよりも，単語レベルでの対応関係も得られた方がユーザにとって有益である．しかし，対訳文をベースにした教材には，単語レベルの情報が存在しないものや対訳文とは関連なくそれが掲載されているものも多い．その際に，ユーザが手作業で単語情報を得ることは，不慣れな言語の場合，負担が大きく効率も悪い．こうした状況において，対訳コーパスからの対訳語の自動抽出は非常に有効と考えられる．そこで，本論文では，新たな言語の学習教材として対訳文を利用するユーザの支援を目的に，言語解析ツールなどの言語リソースが乏しい言語も含め，様々な言語の対訳コーパスから対訳語を効率良く自動抽出する手法を提案する．

対訳対を自動抽出する手法としてDice係数により類似度計算を行い，その結果を利用する手法の有効性が既に報告されている[1],[2]．しかし，そこではデータスパースネスの問題が指摘されている．例えば，(There is your book on the table.；テーブル/に/あなた/の/本/が/あり/ます．(注1)) の “book” の対訳語を式(1)のDice係数[4],[5]を用いて抽出することを考える．

$$Dice(X,Y) = \frac{2 \times f_{XY}}{f_X + f_Y} \tag{1}$$

f_X と f_Y は単語 X，Y が独立に出現する頻度であり，f_{XY} は単語 X，Y が対訳文中に同時に出現する頻度である．ここで，“book”，“本”，そして，“テーブル” が先述した対訳文のみに出現する場合，“book” と “本” の類似度と “book” と “テーブル” の類似度は

† 北海学園大学工学部，札幌市
Faculty of Engineering, Hokkai-Gakuen University, Minami 26 Nishi 11, Chuo-ku, Sapporo-shi, 064–0926 Japan
†† 北海道大学大学院情報科学研究科，札幌市
Graduate School of Information Science and Technology, Hokkaido University, Kita 14 Nishi 9, Kita-ku, Sapporo-shi, 060–0814 Japan
a) E-mail: echi@eli.hokkai-s-u.ac.jp

(注1)：“/” は単語の境界として用いている．本論文では，日本語文の単語分割は日本語形態素解析ツール「茶筌」[3]を用いて行う．

ともに，1.0 $(=\frac{2\times1}{1+1})$ となり，“book” の対訳語を一意に決定することができない．このように，出現頻度に基づく手法では，単語間の対応関係にあいまい性が生じ，対訳語を一意に抽出できない場合がある [2], [6]．

そこで，我々は，対訳語と隣接関係にある単語列の情報を自動獲得し，それを利用することでこの問題の解決を図る．すなわち，対訳文において抽出対象の対訳語の原言語の単語に隣接する単語列が目的言語文中のどの単語列に対応するのかの情報と，対応する目的言語文中の単語列の左右のどちらに隣接している単語が対訳語の目的言語の単語となるのかの情報を獲得する．これらの情報を用いることにより，出現頻度だけでは対応関係のあいまい性を解消できない場合でも，対訳語を一意に抽出できる．例えば，先述した例の場合，“book” に隣接する単語列 “your” が “あなた/の” と対応関係にあるという情報，更に，“your” の右側に “book” が隣接する場合，日本語文では “あなた/の” の右側に “本” が隣接するという情報を獲得することで，“book” と “本” の対応関係を決定できる．

なお，このような隣接情報は，解析的な知識を用いて得るのではなく，学習の観点 [7], [8] により自動的に獲得する．その結果，使用する対訳コーパスの置き換えだけで，システムの変更を必要とせずに様々な言語に対処できる．このような考え方に基づき，本論文では，多言語対訳コーパスから対訳語を効率良く抽出する，隣接情報学習を用いた対訳語の自動抽出手法を提案する．隣接情報学習とは，隣接情報を自動獲得し，それを利用することで対訳語を抽出する処理である．性能評価実験では，英語と日本語，フランス語と日本語，ドイツ語と日本語，上海語と日本語，そして，アイヌ語と日本語の 5 種類の対訳コーパスを対象に，本手法に基づくシステムを用いて対訳語の自動抽出を行った．その結果，個々の対訳コーパスでは 56.7〜62.9%，全体では 60.1%の抽出率が得られた．また，隣接情報学習を用いない，Dice 係数のみに基づくシステムにおいては，個々の対訳コーパスの抽出率は 47.9〜54.9%となり，全体の抽出率は 52.1% であった．本手法により全体の抽出率は 8.0 ポイント向上し，その有効性が確認された．

2. 処理概要

本手法は，形態素情報が付与された対訳文が用意されていれば特定の言語に依存することなく，対訳語を自動抽出できる．それは，対訳コーパスを他の言語の対訳コーパスに置き換えるだけで，システムの変更を必要としないことを意味する．本手法に基づくシステムの処理概要を図 1 に示す．対訳コーパス中の文が膠着語の場合には，あらかじめ単語分割する．

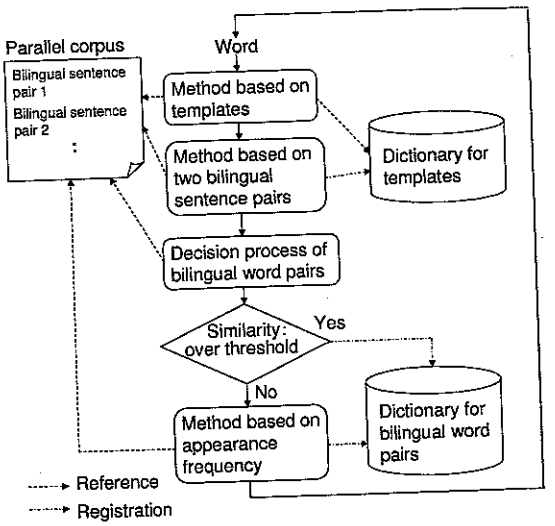


図 1 処理概要
Fig. 1 Process flow.

抽出対象の対訳語の原言語の単語(注2)を入力してから，対応関係にある目的言語の単語を決定し，対訳語を得るまでの本システムの処理の流れを述べる．本システムは大きく二つの処理からなる．隣接情報学習に基づき対訳語を抽出する処理と隣接情報学習を用いずに出現頻度のみに基づき対訳語を抽出する処理である．更に，隣接情報学習はテンプレート方式 (Method based on templates)，対訳文ペア方式 (Method based on two bilingual sentence pairs)，そして，対訳語決定処理部 (Decision process of bilingual word pairs) の三つの処理を有する．テンプレート方式では，それまでに獲得されたテンプレートを用いて対訳語を抽出する．本論文におけるテンプレートとは対訳語を抽出するための隣接情報を有する対訳知識である．対訳文ペア方式では，対訳文のペアに基づき対訳語と新たなテンプレートを得る．抽出された対訳語とテンプレートには類似度が付与され，テンプレートはテンプレート辞書に登録される．なお，類似度は対訳コーパスを参照することで得られる．複数の対訳語が得られた場

(注2)：対訳語に用いる単語は 1 語以上でも構わないため，正確には 1 語以上の単語列と記すべきであるが，隣接情報の単語列と区別するために，本論文では便宜上，対訳語に使用される 1 語以上の単語列はすべて “単語” と記述している．